

# Bài giảng R, số 2

## -Dự đoán mật độ và xu hướng dữ liệu-

TS.Tô Đức Khánh

20/01/2025

Chú ý các files code R được cập nhật liên tục trên Github: [https://github.com/toduckhanh/labs\\_K35](https://github.com/toduckhanh/labs_K35)

## 1 Một số nhận xét trong lập trình

Công thức ước lượng cần thi hành cho hồi quy kernel được trình bày như sau:

$$\hat{m}_{K,h_X}(x) = \frac{\sum_{i=1}^n Y_i k\left(\frac{x - X_i}{h_X}\right)}{\sum_{i=1}^n k\left(\frac{x - X_i}{h_X}\right)},$$

với băng thông  $h_X > 0$ .

- Cho trước hàm kernel  $k(u)$  với  $u$  là một vector, băng thông  $h_X$  và một điểm  $x$ , ta tạo được một hàm tính  $\hat{m}_{K,h_X}(x)$ , với input là dữ liệu  $X$  và  $Y$  tương ứng là các vector có chung kích cỡ  $n$ .
- Sau đó, áp dụng `Vectorize()` để vector hóa hàm vừa viết nhằm tính đồng thời tại nhiều điểm  $x$ .

Đối với hồi quy tuyến tính địa phương (local linear regression), công thức dự đoán là:

$$\hat{m}_{LL,h_X}(x) = \sum_{i=1}^n W_{i,h_X}^1(x) Y_i,$$

trong đó,

$$W_{i,h_X}^1(x) = \frac{1}{n} \frac{\hat{s}_2(x; h_X) - \hat{s}_1(x; h_X)(X_i - x)}{\hat{s}_2(x; h_X)\hat{s}_0(x; h_X) - \hat{s}_1^2(x; h_X)} k\left(\frac{x - X_i}{h_X}\right),$$

với

$$\hat{s}_r(x; h_X) = \frac{1}{n} \sum_{i=1}^n (X_i - x)^r k\left(\frac{x - X_i}{h_X}\right),$$

và  $r = 0, 1, 2$ .

- Cho trước hàm kernel  $k(u)$  với  $u$  là một vector, băng thông  $h_X$  và một điểm  $x$ , ta tạo được một đoạn code tính  $\hat{s}_r(x; h_X)$  với input là dữ liệu  $X$  và  $Y$  tương ứng là các vector có chung kích cỡ  $n$ .
- Sau đó, tính các  $W_{i,h_X}^1(x)$  tại mỗi  $X_i$ , với  $i = 1, \dots, n$ .
- $\hat{m}_{LL,h_X}(x)$  được xác định bởi phép tính tổng của phép nhân  $W_{i,h_X}^1(x)$  với  $Y_i$ .
- Áp dụng `Vectorize()` để vector hóa hàm vừa viết nhằm tính đồng thời tại nhiều điểm  $x$ .

Công thức tính cross-validation được xác định bởi:

$$CV^p(h) = \frac{1}{n} \sum_{i=1}^n \left( \frac{Y_i - \hat{m}_{LP, h_X, p}(X_i)}{1 - W_{i, h_X}^p(X_i)} \right)^2.$$

Cụ thể, với  $p = 0$ , thì

$$CV^0(h) = \frac{1}{n} \sum_{i=1}^n \left( \frac{Y_i - \hat{m}_{K, h_X}(X_i)}{1 - W_{i, h_X}^0(X_i)} \right)^2,$$

trong đó,

$$W_{i, h_X}^0(X_i) = \frac{k(0)}{\sum_{j=1}^n k\left(\frac{X_i - X_j}{h_X}\right)},$$

và

$$\hat{m}_{K, h_X}(X_i) = \frac{\sum_{j=1}^n Y_j k\left(\frac{X_i - X_j}{h_X}\right)}{\sum_{j=1}^n k\left(\frac{X_i - X_j}{h_X}\right)},$$

Với  $p = 1$ , ta có

$$CV^1(h) = \frac{1}{n} \sum_{i=1}^n \left( \frac{Y_i - \hat{m}_{LL, h_X}(X_i)}{1 - W_{i, h_X}^1(X_i)} \right)^2,$$

trong đó

$$W_{i, h_X}^1(X_i) = \frac{1}{n} \frac{\hat{s}_2(X_i; h_X)}{\hat{s}_2(X_i; h_X) \hat{s}_0(X_i; h_X) - \hat{s}_1^2(X_i; h_X)} k(0),$$

với

$$\hat{s}_r(X_i; h_X) = \frac{1}{n} \sum_{j=1}^n (X_j - X_i)^r k\left(\frac{X_i - X_j}{h_X}\right),$$

và  $r = 0, 1, 2$  và

$$\hat{m}_{LL, h_X}(x) = \sum_{j=1}^n W_{j, h_X}^1(X_i) Y_j.$$

Công thức tính generalized cross-validation được xác định bởi:

$$GCV^p(h) = \frac{\sum_{i=1}^n (Y_i - \hat{m}_{LP, h_X, p}(X_i))^2}{\left( n - \sum_{i=1}^n W_{i, h_X}^p(X_i) \right)^2}.$$

với  $W_{i, h_X}^p(X_i)$  được tính tương tự như trong cross-validation.

Sau khi thi hành các hàm tính cross-validation theo 1 vector gồm các điểm  $h$  tiềm năng (chia lưới), ta xác định  $h^*$  bằng cách truy xuất theo vị trí tương ứng điểm giá trị nhỏ nhất của cross-validation thông qua hàm `which.min()`.

## 2 Bài tập

**Bài tập 1:** Khi áp dụng hàm tính cross-validation, giải thích tại sao xuất hiện các giá trị NaN (không xác định) tại các giá trị  $h$  rất nhỏ, nhưng khi tính generalized cross-validation thì lại không có. Đề xuất phương án giải quyết.

**Bài tập 2:** Tích hợp các hàm tính cross-validation và generalized cross-validation vào trong một hàm, có input một đối số để lựa chọn 1 trong 2 hoặc tính cả hai đại lượng này.

**Bài tập 3:** Viết hàm thực hiện hồi quy đa thức, với input  $p$  là số nguyên có các giá trị  $0, 1, \dots$ . Trong đó, bảng thông  $h$  được truyền vào là 1 số hoặc không truyền vào (đặt mặc định  $h = \text{NULL}$ ), nếu không truyền vào thì trong thân hàm cần có một đoạn tính  $h$  theo CV hoặc GCV.

**Bài tập 4:** Dữ liệu `mars.dat` cung cấp dữ liệu về hồ sơ nhiệt độ-áp suất của khí quyển sao Hỏa, được tàu vũ trụ Mars Global Surveyor đo vào năm 2003 bằng kỹ thuật che khuất sóng vô tuyến. Nhiệt độ (`temperatures`) nhìn chung giảm khi bán kính (`radius`) tâm hành tinh (độ cao) tăng.

- (a) Áp dụng hàm đã làm trong câu 3 để làm dự đoán xu hướng thay đổi của nhiệt độ theo bán kính tâm hành tinh thay đổi.
- (b) Dữ liệu này bắt nguồn từ bảy quỹ đạo riêng biệt của tàu vũ trụ. Các quỹ đạo này đi qua các vùng hơi khác nhau của sao Hỏa. Một tập dữ liệu đầy đủ hơn bao gồm số quỹ đạo, áp suất khí quyển, kinh độ, vĩ độ và các biến khác có sẵn trong tệp `marsbig.dat`. Hãy xác định xu hướng thay đổi của nhiệt độ theo bán kính tâm hành tinh khi tàu vũ trụ bay trong các quỹ đạo (`orbit`) khác nhau.
- (c) Trong trường hợp thay thế bán kính (`radius`) bằng áp suất (`pressure`) thì xu hướng thay đổi của nhiệt độ là như thế nào?

**Bài tập 5:** Xét mô hình phát sinh dữ liệu như sau

$$Y_i = m(X_i) + \varepsilon_i,$$

trong đó,  $m(x) = 1 + \sin(x^2)/x^2$ ,  $\varepsilon_i$  độc lập cùng phân phối chuẩn với trung bình 0 và phương sai  $m^2(x)/64$ , với  $i = 1, \dots, n$  và  $X_i$  là độc lập cùng phân phối  $\mathcal{U}(0, \pi)$  - phân phối đều trên đoạn  $(0, \pi)$ .

- (a) Tạo mẫu ngẫu nhiên gồm  $n = 100$  quan sát. Sử dụng hàm `rnorm(n, mean, sd)` để khởi tạo sai số  $\varepsilon_i$ , với `sd` là dãy kết quả độ lệch chuẩn (căn bậc hai của phương sai), và hàm `runif(n, a, b)` để tạo mẫu ngẫu nhiên của  $X_i$ .
- (b) Xác định bằng thông tối ưu cho hồi quy tuyến tính địa phương, thông qua phương pháp plug-in rule of thumb, CV và GCV. Sử dụng kernel Epanechnikov và kernel Gaussian. So sánh kết quả các bảng thông này.
- (c) Dự đoán xu hướng của dữ liệu  $Y$  theo  $X$  bằng hồi quy tuyến tính địa phương với các bảng thông tối ưu và kernel được sử dụng trong câu (b).
- (d) Lặp lại ý (a) - (b) trong 100 lần, vẽ biểu đồ biểu diễn sự thay đổi của các bảng thông tối ưu được tìm thấy theo từng bộ dữ liệu trong mỗi lần lặp. Nhận xét về kết quả.