

Thống kê tính toán - Computational Statistics

Bài tập 02: Bootstrap và Resampling Methods

Bài tập 1. Dữ liệu `salmon.dat` cung cấp dữ liệu về 40 số liệu thống kê hàng năm về số lượng cá con và cá bố mẹ trong quần thể cá hồi (đơn vị: là nghìn con cá). Cá con (recruits) là những con cá gia nhập quần thể có thể đánh bắt, cá bố mẹ (spawners) là những con cá đang đẻ trứng. Cá bố mẹ chết sau khi đẻ trứng.

Trong sinh thái học, mô hình Beverton-Holt được dùng cho việc mô tả mối quan hệ giữa cá bố mẹ và cá con:

$$R = \frac{1}{\beta_0 + \beta_1/S},$$

trong đó, với $\beta_0 \geq 0$ và $\beta_1 \geq 0$, R và S lần lượt là số lượng cá con và cá bố mẹ [46]. Mô hình này có thể được ước lượng bằng hồi quy tuyến tính với các biến đổi $1/R$ và $1/S$.

Tại các nước đánh bắt cá hồi tự nhiên, các nhà quản lý luôn quan tâm tới vấn đề duy trì một nghề cá bền vững. Tổng số lượng quần thể chỉ ổn định nếu $R = S$. Tổng quần thể sẽ giảm nếu số lượng cá con được sinh ra ít hơn số lượng cá bố mẹ đã chết để sinh ra chúng. Nếu có quá nhiều cá con được sinh ra, quần thể cuối cùng cũng sẽ giảm vì không đủ thức ăn cho tất cả chúng. Do đó, chỉ có một mức độ cá con trung bình nào đó có thể được duy trì vô thời hạn trong một quần thể ổn định. Mức độ quần thể ổn định này là điểm mà đường thẳng $x = y$ cắt đường cong liên hệ giữa R và S .

- (a) Áp dụng mô hình Beverton-Holt và tìm ước lượng điểm cho mức dân số ổn định khi $R = S$, gọi là θ .
- (b) Sử dụng phương pháp bootstrap để thu được khoảng tin cậy 95% (bootstrap percentile) và sai số chuẩn cho ước lượng $\hat{\theta}$ theo hai cách sau.

- Bootstrap dữ liệu: xáo trộn có lặp lại cặp quan sát (R_i, S_i) sau đó, ước lượng mô hình Beverton-Holt và xác định $\hat{\theta}^*$. Ta gọi ước lượng theo cách này là $\hat{\theta}_1^*$.
- Residual-based bootstrap: sử dụng mô hình hồi quy tuyến tính

$$\frac{1}{R_i} = \beta_0 + \beta_1/S_i + \varepsilon_i$$

trong đó, $\varepsilon_i \stackrel{\text{i.i.d.}}{\sim} F(\cdot)$, với $\mathbb{E}(\varepsilon_i) = 0$ và $\text{Var}(\varepsilon_i) = \sigma^2 < +\infty$. Với ước lượng $\hat{\beta}_0, \hat{\beta}_1$, ta xác định được tiên đoán:

$$\frac{1}{\hat{R}_i} = \hat{\beta}_0 + \hat{\beta}_1/S_i,$$

và thặng dư $\hat{\varepsilon}_i$:

$$\hat{\varepsilon}_i = \frac{1}{\hat{R}_i} - \left(\hat{\beta}_0 + \hat{\beta}_1/S_i \right).$$

Phát sinh dữ liệu bootstrap từ mô hình hồi quy tuyến tính

$$\hat{R}_i^* = \left(\hat{\beta}_0 + \hat{\beta}_1/S_i + \hat{\varepsilon}_i^* \right)^{-1},$$

trong đó, $\hat{\varepsilon}_i^*$ là dữ liệu bootstrap được tạo ra dựa trên $\hat{\varepsilon}_i$. Sử dụng dữ liệu bootstrap $(\hat{R}_i^*, S_i)$ để ước lượng mô hình Beverton-Holt và xác định $\hat{\theta}^*$. Ta gọi ước lượng theo cách này là $\hat{\theta}_2^*$.

Vẽ biểu đồ histogram cho phân phối bootstrap của $\hat{\theta}_1^*$ và $\hat{\theta}_2^*$; và nhận xét về sự khác biệt trong kết quả.

- (c) Xác định khoảng tin cậy 95% với phương pháp BC_a cho θ theo hai cách bootstrap sử dụng trong (a).
- (d) Xác định khoảng tin cậy 95% với phương pháp studentized cho θ theo hai cách bootstrap sử dụng trong (a), kết hợp với một quy trình bootstrap thứ 2.

Bài tập 2. Bệnh nhân mắc ung thư dạ dày hoặc ung thư vú giai đoạn cuối được điều trị bằng ascorbate nhằm kéo dài thời gian sống [2]. Dữ liệu `cancersurvival.dat` cung cấp thời gian sống (ngày) của hai nhóm bệnh nhân (`disease = 1` là nhóm ung thư dạ dày). Làm việc với dữ liệu trên thang logarit, $\log(\cdot)$.

- (a) Sử dụng phương pháp bootstrap studentized và BC_a để xây dựng khoảng tin cậy 95% cho thời gian sống trung bình của mỗi nhóm.
- (b) Sử dụng permutation test để kiểm tra giả thuyết rằng không có sự khác biệt về thời gian sống trung bình giữa các nhóm.
- (c) Sau khi đã tính toán được khoảng tin cậy trong (a), chúng ta hãy xem xét một số sai sót có thể xảy ra. Xây dựng khoảng tin cậy 95% cho thời gian sống trung bình của bệnh ung thư vú bằng cách áp dụng phương pháp bootstrap percentile cho dữ liệu đã được chuyển đổi logarit và sau đó áp dụng $\exp(\cdot)$ cho chặn dưới và chặn trên của khoảng tin cậy. Xây dựng một khoảng tin cậy khác bằng cách áp dụng phương pháp bootstrap percentile cho dữ liệu trên thang đo gốc. So sánh với (a).

Bài tập 3. Thực hiện các bài toán mô phỏng sau:

- (a) Sử dụng bài toán ước lượng trung bình của phân phối Cauchy chuẩn để minh họa cách phương pháp bootstrap có thể thất bại đối với các phân phối có đuôi nặng. (Trong R, để mô phỏng dữ liệu theo phân phối Cauchy, ta dùng hàm `rcauchy(n, location, scale)`, với `location` và `scale` là hai tham số được xác định trước).
- (b) Sử dụng bài toán ước lượng θ cho phân phối $\mathcal{U}(0, \theta)$ để minh họa cách phương pháp bootstrap có thể thất bại đối với các giá trị cực trị.

Bài tập 4. (Bootstrap aggregating - Bagging). Một trong những ứng dụng quan trọng của phương pháp bootstrap là trong mô hình tiên đoán với máy học (chẳng hạn cây phân loại - decision tree).

Xét dữ liệu `breast_cancer.csv` trong nghiên cứu về phân biệt khối u¹ lành tính (benign

¹<https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic>

- B) và ác tính (malignant - M).

- (a) Chia dữ liệu thành 70% training và 30% testing. Huấn luyện một cây phân loại trên tập training. Đánh giá Accuracy và AUC trên tập test. Thay đổi random seed và nhận xét về độ ổn định của mô hình. (Trong R, cây phân loại được xác định thông qua hàm `rpart()` của thư viện `rpart`).
- (b) Tạo mẫu bootstrap cho dữ liệu training, sau đó, huấn luyện một cây phân loại trên mẫu bootstrap. Tổng hợp dự đoán bằng trung bình xác suất (ngưỡng 0.5). Lặp lại $B = 200$ lần bootstrap. Tính Accuracy và AUC của mô hình Bagging trên tập test.
- (c) Lặp lại toàn bộ quá trình train/test 50 lần. Ghi lại Accuracy của cây phân loại và Bagging. Tính trung bình và phương sai của Accuracy dựa trên kết quả của 50 lần lặp. Tính phần trăm giảm phương sai của Bagging so với cây đơn lẻ.
- (d) Huấn luyện Random Forest với `ntree = 200` (Trong R, sử dụng hàm `randomForest()` trong thư viện `randomForest`). So sánh hiệu năng với Bagging. Giải thích sự khác biệt (random feature selection).

Tài liệu tham khảo

- [1] R. J. H. Beverton and S. J. Holt. *On the Dynamics of Exploited Fish Populations, volume 19 of Fisheries Investment Series 2*. UK Ministry of Agriculture and Fisheries, London, 1957.
- [2] E. Cameron and L. Pauling. Supplemental ascorbate in the supportive treatment of cancer: Re-evaluation of prolongation of survival times in terminal human cancer. *Proceedings of the National Academy of Sciences of the USA*, 75(9):4538-4542, 1978.