

Bài giảng 2: Dự đoán mật độ dữ liệu và xu hướng

TS. Tô Đức Khánh

Khoa Toán-Tin Học, Trường Đại Học Khoa Học Tự Nhiên
Đại Học Quốc Gia Tp. HCM

Thống kê Tính Toán - Computational Statistics

Mục lục

1 Dự đoán mật độ dữ liệu

2 Tối ưu hóa lựa chọn tham số

3 Dự đoán xu hướng

1 Dự đoán mật độ dữ liệu

2 Tối ưu hóa lựa chọn tham số

3 Dự đoán xu hướng

Hàm mật độ xác suất

Nhắc lại, hàm mật độ xác suất cung cấp thông tin về mật độ tập trung của giá trị của một biến ngẫu nhiên.

Thông thường, $f(x)$ là một hàm được xác định, sao cho:


■ $f(x) \geq 0$, với mọi giá trị của x ;

■ $\int_S f(x) dx = 1$;

Ví dụ: $X \sim \mathcal{N}(0, 1)$, tức là X tuân theo phân phối chuẩn với trung bình 0 và phương sai 1. Hàm mật độ xác suất

$$f(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right),$$

với mọi $x \in \mathbb{R}$.




Hàm mật độ xác suất

Ví dụ: $X \sim 0.6 \times \mathcal{N}(0, 1) + 0.4 \times \mathcal{N}(4, 1)$, tức là X có phân phối hỗn hợp (mixture distributions).

Hàm mật độ xác suất được xác định bởi:

$$f(x) = 0.6 \times \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) + 0.4 \times \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x-4)^2}{2}\right),$$

với mọi $x \in \mathbb{R}$.



Mật độ cho dữ liệu


Tuy nhiên, trong thực tế, ta chỉ có dữ liệu (tức là giá trị quan sát được của biến ngẫu nhiên).

⇒ cần dự đoán (ước lượng) mật độ xác suất của X từ dữ liệu.

Ví dụ: Xét dữ liệu về số giờ xuất hiện liên tục, thu được trong một nghiên cứu về sự di cư của cá voi đầu bò (bowhead whale) tại Point Barrow, Alaska vào mùa xuân 2001, tính từ sau nửa đêm 5/4/2001.


id	số giờ
1	1007.044
2	1009.079
3	1025.044
⋮	⋮
120	1356.006
121	1359.475

Mật độ cho dữ liệu



Mật độ cho dữ liệu

- Biểu đồ histogram cho thấy có hai khu vực tập trung dữ liệu.
- Phần lớn tập trung quanh mức 1250 giờ, với khoảng từ 1200 tới 1400.



⇒ Hàm mật độ phù hợp là gì?

Ước lượng thực nghiệm

Với một mẫu ngẫu nhiên, $Y_1, \dots, Y_n$ của Y tuân theo phân phối $F(y)$. Hàm phân phối thực nghiệm của Y được xác định bởi

$$\hat{F}_n(y) = \frac{1}{n} \sum_{i=1}^n \mathbf{I}(Y_i \leq y),$$

là một ước lượng của F_Y , với $\mathbf{I}(\cdot)$ là hàm chỉ (indicator function) và được định nghĩa như sau:

$$\mathbf{I}(y \leq a) = \begin{cases} 1 & \text{nếu } y \leq a, \\ 0 & \text{nếu } y > a. \end{cases}$$

Ước lượng thực nghiệm

Áp dụng tính chất

$$f(y) = \frac{d}{dy} F(y),$$

cho $\hat{F}_n(y)$, ta có thu được ước lượng

$$\hat{f}_n(y) = \frac{d}{dy} \hat{F}_n(y),$$

Tuy nhiên ước lượng $\hat{F}_n(y)$ là không liên tục, do đó ta cần áp dụng xấp xỉ đạo hàm sai phân trung tâm (central difference approximation).

Sai phân trung tâm

Xấp xỉ đạo hàm của một hàm $g(x)$ bằng phương pháp sai phân trung tâm (central difference approximation) được xác định bởi:

$$g'(x) = \frac{g(x + h/2) - g(x - h/2)}{h},$$

với bước nhảy $h > 0$.

Ước lượng thực nghiệm

Áp dụng cho hàm phân phối tích xác suất thực nghiệm, ta có

$$\begin{aligned}\hat{f}_n(y) &= \frac{\hat{F}_n(y + h/2) - \hat{F}_n(y - h/2)}{h} \\ &= \frac{1}{nh} \sum_{i=1}^n \mathbf{I}\left(\frac{|Y_i - y|}{h} \leq \frac{1}{2}\right),\end{aligned}$$

với $h > 0$ là băng thông (bandwidth).

Ước lượng này được gọi là ước lượng mật độ tần số thực nghiệm (the histogram estimator) được đề xuất và nghiên cứu các tính chất thống kê bởi Freedman and Diaconis (1981).

Ước lượng thực nghiệm

Ước lượng mật độ kernel

Hạn chế của ước lượng histogram:

- đường mật độ bị gấp khúc, không trơn;
- $\hat{f}_n(y)$ là không liên tục.

Ta có thể thay thế hàm $I\left(\frac{|Y_i - y|}{h} \leq \frac{1}{2}\right)$ bằng một hàm:

- dương, trơn,
- liên tục, khả vi
- tạo ra ước lượng mật độ thỏa tính chất của hàm mật độ xác suất.

Ước lượng mật độ kernel

Xét hàm $k(u)$ sao cho thỏa các tính chất sau:

(i) $k(u) \geq 0$,

(ii) $k(u) = k(-u)$ (tính đối xứng),

(iii) $\int_{-\infty}^{+\infty} k(u) du = 1$,

(iv) $\int_{-\infty}^{+\infty} uk(u) du = 0$.

Hàm $k(u)$ như vậy được gọi là một hàm Kernel (hay hàm nhân).

Ví dụ: $k(u) = 1$ nếu $|u| \leq 1/2$, chính là hàm $I(|u| \leq 1/2)$.

Khi đó, ước lượng hàm mật độ histogram là một dạng đặc biệt của ước lượng mật độ kernel (Kernel density estimation - KDE):

$$\hat{f}_{K,h}(y) = \frac{1}{nh} \sum_{i=1}^n k\left(\frac{Y_i - y}{h}\right).$$

Hàm Kernel

Có nhiều hàm toán học thỏa điều kiện (i) - (iv) để trở thành một hàm Kernel.

Gaussian kernel

Hàm nhân Gauss (Gaussian kernel) được xác định là hàm mật độ xác suất của phân phối chuẩn $\mathcal{N}(0, 1)$:

$$k(u) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{u^2}{2}\right),$$

với $-\infty < u < +\infty$.

Epanechnikov kernel

Hàm nhân Epanechnikov (Epanechnikov kernel) được xác định bởi:

$$k(u) = \begin{cases} 0.75 (1 - u^2), & \text{nếu } |u| \leq 1, \\ 0 & \text{ngược lại.} \end{cases}$$

Hàm Kernel

Triangle kernel

Hàm nhân tam giác (Triangle kernel) được xác định bởi

$$k(u) = \begin{cases} 1 - |u|, & \text{nếu } |u| \leq 1, \\ 0 & \text{ngược lại.} \end{cases}$$

Quartic kernel

Hàm nhân bậc 2 (Quartic kernel) được xác định bởi

$$k(u) = \begin{cases} \frac{15}{16} (1 - u^2)^2, & \text{nếu } |u| \leq 1, \\ 0 & \text{ngược lại.} \end{cases}$$

Triweight kernel

Hàm nhân bậc 3 (Triweight kernel) được xác định bởi

$$k(u) = \begin{cases} \frac{35}{32} (1 - u^2)^3, & \text{nếu } |u| \leq 1, \\ 0 & \text{ngược lại.} \end{cases}$$

Hàm Kernel

Tricube kernel

Hàm nhân tam thức bậc 3 (Tricube kernel) được xác định bởi

$$k(u) = \begin{cases} \frac{70}{81} (1 - |u|^3)^3, & \text{nếu } |u| \leq 1, \\ 0 & \text{ngược lại.} \end{cases}$$

Cosine kernel

Hàm nhân cos (Cosine kernel) được xác định bởi


$$k(u) = \begin{cases} \frac{\pi}{4} \cos\left(\frac{\pi}{2}u\right), & \text{nếu } |u| \leq 1, \\ 0 & \text{ngược lại.} \end{cases}$$

Uniform kernel


Hàm nhân đều (Uniform kernel) được xác định bởi

$$k(u) = \begin{cases} 0.5, & \text{nếu } |u| \leq 1, \\ 0 & \text{ngược lại.} \end{cases}$$


Hàm Kernel




Gaussian kernel



Epanechnikov kernel




Triangle kernel




Quartic kernel


Hàm Kernel




Tricube kernel



Triweighted kernel



Cosine kernel




Uniform kernel


Ví dụ - Whale data

Áp dụng ước lượng mật độ kernel cho dữ liệu thời gian xuất hiện của cá voi đầu bò:

- sử dụng Gaussian kernel;
- băng thông $h = 5, 10, 15, 30$;




$h = 5$




$h = 10$

Ví dụ - Whale data



$h = 15$



$h = 30$

⇒ khi h càng lớn thì đường ước lượng mật độ kernel càng “trơn”.

1 Dự đoán mật độ dữ liệu

2 Tối ưu hóa lựa chọn tham số

3 Dự đoán xu hướng

Đánh giá sai số

Khi áp dụng ước lượng mật độ kernel $\hat{f}_{K,h}(y)$ với

- hàm kernel $k(u)$ cố định;
- băng thông h .

Sai số ước lượng tại một điểm y được tính bởi:

$$\hat{f}_{K,h}(y) - f(y),$$

với $f(y)$ là hàm mật độ chính xác.

Integrated Squared Error (ISE)

Integrated squared error (ISE) của $\hat{f}_{K,h}(y)$ được xác định theo sự thay đổi của băng thông h bởi

$$\text{ISE}(h) = \int_{-\infty}^{+\infty} \left(\hat{f}_{K,h}(y) - f(y) \right)^2 dy$$

Sai số này phụ thuộc vào h và dữ liệu.

$\Rightarrow$ ISE cung cấp thông tin tổng hợp về hiệu suất của $\hat{f}_{K,h}(\cdot)$ dưới điều kiện đã quan sát được dữ liệu thực tế và thông tin của $f(y)$.

Đánh giá sai số

Tuy nhiên, dữ liệu có tính ngẫu nhiên $\implies \hat{f}_{K,h}(\cdot)$ cũng sẽ ngẫu nhiên.
 $\implies \text{ISE}(h)$ không cố định.

Mean Integrated Squared Error (MISE)

Mean Integrated Squared Error (MISE) là cách đánh giá sai số toàn diện, bao hàm tính ngẫu nhiên của dữ liệu và do đó là của ước lượng:

$$\text{MISE}(h) = \mathbb{E}(\text{ISE}(h)) = \int_{-\infty}^{+\infty} \mathbb{E} \left\{ \left(\hat{f}_{K,h}(y) - f(y) \right)^2 \right\} dy.$$

Đánh giá sai số

Ta chứng minh được rằng

$$\mathbb{E} \left\{ \left(\hat{f}_{K,h}(y) - f(y) \right)^2 \right\} = \text{Var} \left\{ \hat{f}_{K,h}(y) \right\} + \text{Bias}^2 \left\{ \hat{f}_{K,h}(y) \right\},$$

với

$$\text{Bias} \left\{ \hat{f}_{K,h}(y) \right\} = \mathbb{E} \left\{ \hat{f}_{K,h}(y) \right\} - f(y).$$

Khi đó, MISE được xác định bởi

$$\text{MISE}(h) = \int_{-\infty}^{+\infty} \text{Var} \left\{ \hat{f}_{K,h}(y) \right\} dy + \int_{-\infty}^{+\infty} \text{Bias}^2 \left\{ \hat{f}_{K,h}(y) \right\} dy.$$

Ghi chú: Do MISE yêu cầu phải có $f(y)$ hàm mật độ chính xác, nên việc đánh giá sai số thường được thực hiện thông qua việc mô phỏng.

Ví dụ - Dữ liệu mô phỏng

Xét $Y_1, \dots, Y_n$ là dãy biến ngẫu nhiên, phát sinh từ phân phối chuẩn hỗn hợp:

$$Y \sim 0.6\mathcal{N}(0, 1) + 0.4\mathcal{N}(4, 1).$$

Khi đó, hàm mật độ xác suất $f(y)$ là

$$f(y) = 0.6 \times \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{y^2}{2}\right) + 0.4 \times \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(y-4)^2}{2}\right).$$

Quá trình mô phỏng như sau:

- (1) Tạo ngẫu nhiên $n = 100$ dữ liệu từ phân phối cho trước.
- (2) Ước lượng $\hat{f}_{K,h}(y)$ với Gaussian kernel, và h trong $(0, 2)$.
- (3) Tính xấp xỉ ISE bởi:

$$\widehat{\text{ISE}}(h) = \frac{1}{m} \sum_{j=1}^m \left\{ \hat{f}_{K,h}(y_j) - f(y_j) \right\}^2,$$

với m là nút lưới chia của y .

Ví dụ - Dữ liệu mô phỏng


- (4) Lặp lại (1) - (3) trong M lần (chẳng hạn, 100 lần), và lưu lại $\widehat{\text{ISE}}_k(h)$ với $k = 1, \dots, M$.
- (5) Tính xấp xỉ MISE bởi:

$$\widehat{\text{MISE}}(h) = \frac{1}{M} \sum_{k=1}^M \widehat{\text{ISE}}_k(h),$$


Ta đánh giá tại

- $h \in \{0.1, 0.15, 0.2, \dots, 1.9, 1.95, 2\}$ - 39 điểm;
- $y \in \{-5.00, -4.97, -4.94, \dots, 9.94, 9.97, 10.00\}$ - 501 điểm.


Ví dụ - Dữ liệu mô phỏng



Ví dụ - Dữ liệu mô phỏng



Ví dụ - Dữ liệu mô phỏng



- Đường màu xanh dương biểu diễn xấp xỉ của $\int_{-\infty}^{+\infty} \text{Bias}^2 \left\{ \hat{f}_{K,h}(y) \right\} dy$.
- Đường màu đỏ biểu diễn xấp xỉ của $\int_{-\infty}^{+\infty} \text{Var} \left\{ \hat{f}_{K,h}(y) \right\} dy$
- Đường màu đen biểu diễn xấp xỉ của $\text{MISE}(h)$.

Phân tích MISE

Để phân tích kỹ hơn $MISE(h)$, ta giả sử rằng, hàm kernel $k(u)$ thỏa các tính chất sau:

- (i) đối xứng qua 0;
- (ii) là hàm mật độ xác suất với trung bình 0 và phương sai $0 < \sigma_k^2 < +\infty$;
- (iii) độ gồ ghề (roughness) của kernel:

$$R(k) = \int_{-\infty}^{+\infty} k^2(u) du,$$

là xác định, tức là $R(k) < +\infty$.

Ngoài ra, ta giả sử rằng hàm $f(y)$ là hàm trơn, và khả vi.

Nhận xét: độ lớn của $R(k)$ cho biết độ nhọn/gồ ghề của hàm nhân, cụ thể

- $R(k)$ nhỏ $\Rightarrow$ hàm kernel trơn/dàn trải (ví dụ, Gaussian kernel có $R(k) = 1/(2\sqrt{\pi}) \approx 0.282$);
- $R(k)$ lớn $\Rightarrow$ hàm kernel nhọn/gồ ghề (ví dụ, Triangular kernel có $R(k) = 2/3 \approx 0.6$).

Phân tích MISE

Nhắc lại rằng

$$\widehat{f}_{K,n}(y) = \frac{1}{nh} \sum_{i=1}^n k\left(\frac{Y_i - y}{h}\right),$$

với $Y_1, \dots, Y_n$ là mẫu ngẫu nhiên.

Với một điểm y bất kỳ, ta chứng minh được rằng

$$\mathbb{E} \left\{ \widehat{f}_{K,n}(y) \right\} = \int_{-\infty}^{+\infty} k(t) f(y - ht) dt.$$

Áp dụng khai triển Taylor cho $f(y - ht)$:

$$f(y - ht) = f(y) - ht f'(y) + \frac{1}{2} h^2 t^2 f''(y) + o(h^2),$$

trong đó, $o(h^2)$ là thành phần sai số bậc h^2 , tiến về 0 khi $h \rightarrow 0$.

Theo đó, kết hợp tới tính chất (i) và (ii):

$$\mathbb{E} \left\{ \widehat{f}_{K,n}(y) \right\} = f(y) + \frac{1}{2} h^2 \sigma_k^2 f''(y) + o(h^2).$$

Phân tích MISE

Dẫn tới

$$\text{Bias}^2 \left\{ \widehat{f}_{K,h}(y) \right\} = \frac{1}{4} h^4 \sigma_k^4 \left\{ f''(y) \right\}^2 + o(h^4).$$

Do đó,

$$\int_{-\infty}^{+\infty} \text{Bias}^2 \left\{ \widehat{f}_{K,h}(y) \right\} dy = \frac{1}{4} h^4 \sigma_k^4 R(f'') + o(h^4).$$

Phân tích phương sai của $\widehat{f}_{K,n}(y)$ như sau:

$$\mathbb{V}\text{ar} \left\{ \widehat{f}_{K,h}(y) \right\} = \frac{1}{n^2} \sum_{i=1}^n \mathbb{V}\text{ar} \left\{ \frac{1}{h} k \left(\frac{Y_i - y}{h} \right) \right\}.$$

Sử dụng tính chất cùng phân phối của mẫu ngẫu nhiên $Y_1, \dots, Y_n$, ta thu được:

$$\mathbb{V}\text{ar} \left\{ \widehat{f}_{K,h}(y) \right\} = \frac{1}{n} \mathbb{V}\text{ar} \left\{ \frac{1}{h} k \left(\frac{Y_i - y}{h} \right) \right\},$$

với i bất kỳ.

Phân tích MISE

Áp dụng công thức $\text{Var}(g(Y)) = \mathbb{E}\{g^2(Y)\} - [\mathbb{E}\{g(Y)\}]^2$,

$$\text{Var}\left\{\widehat{f}_{K,h}(y)\right\} = \frac{1}{nh} \int_{-\infty}^{+\infty} k^2(t) f(y - ht) dt - \frac{1}{n} \left[\mathbb{E}\left\{\frac{1}{h} k\left(\frac{Y_i - y}{h}\right)\right\} \right]^2.$$

Áp dụng khai triển Taylor, dạng $f(y - ht) = f(y) + o(1)$, ta thu được

$$\text{Var}\left\{\widehat{f}_{K,h}(y)\right\} = \frac{1}{nh} \int_{-\infty}^{+\infty} k^2(t) [f(y) + o(1)] dt - \frac{1}{n} [f(y) + o(1)]^2.$$

Sau một vài bước biến đổi, ta thu được

$$\text{Var}\left\{\widehat{f}_{K,h}(y)\right\} = \frac{1}{nh} f(y) R(k) + o\left(\frac{1}{nh}\right).$$

Suy ra,

$$\int_{-\infty}^{+\infty} \text{Var}\left\{\widehat{f}_{K,h}(y)\right\} dy = \frac{1}{nh} R(k) + o\left(\frac{1}{nh}\right).$$

Phân tích MISE

Như vậy, ta có biểu thức biểu diễn MISE là

$$\text{MISE}(h) = \frac{1}{nh}R(k) + \frac{1}{4}h^4\sigma_k^4R(f'') + o\left(\frac{1}{nh} + h^4\right)$$

Nhận xét:

- Cố định n , nếu $h \rightarrow 0$ thì thành phần độ chệch (bias) tiến về 0, trong khi thành phần phương sai tiến về $+\infty \Rightarrow$ **variance-bias trade off**.
- Nếu $nh \rightarrow +\infty$ và $h \rightarrow 0$ khi $n \rightarrow +\infty$ thì $\text{MISE}(h) \rightarrow 0$.
- Thành phần sai số $o\left(\frac{1}{nh} + h^4\right)$ được chứng minh là bằng với $O(n^{-1} + h^5)$, tức là sai số sẽ bị chặn khi hoặc $n \rightarrow +\infty$ hoặc $h \rightarrow 0$.

Chọn h tối ưu hóa sai số


Asymptotic Mean Integrated Squared Error - AMISE

Trung bình tích phân bình phương sai số tiệm cận (Asymptotic Mean Integrated Squared Error), hay AMISE, của ước lượng mật độ kernel được xác định bởi:

$$\text{AMISE}(h) = \frac{1}{nh} R(k) + \frac{1}{4} h^4 \sigma_k^4 R(f'').$$

Cố định cỡ mẫu n , $\text{AMISE}(h)$ là hàm lõm (concave) theo h , tức là tồn tại 1 điểm cực tiểu duy nhất.

Chọn h tối ưu hóa sai số



Chọn h tối ưu hóa sai số

Chọn h cực tiểu hóa AMISE

Về mặt lý thuyết, ta có thể tìm h sao cho cực tiểu hóa $\text{AMISE}(h)$ tức là cân bằng độ chệch và phương sai:

$$h^* = \arg \min_{h>0} \left\{ \frac{1}{nh} R(k) + \frac{1}{4} h^4 \sigma_k^4 R(f'') \right\}.$$

Áp dụng cách tìm cực tiểu, ta thu được

$$h^* = \left(\frac{R(k)}{n \sigma_k^4 R(f'')} \right)^{1/5}.$$

Tuy nhiên, công thức này không hữu dụng trong thực tế, vì cần thông tin của f .

Nhận xét: từ công thức của h^* ta có thể rút ra rằng $h = O(n^{-1/5})$.

$\Rightarrow$ bằng thông h sẽ giảm theo chiều tăng của cỡ mẫu n .

Plug-in methods

Plug-in methods

Nhắc lại rằng, từ lý thuyết ta có

$$h^* = \left(\frac{R(k)}{n\sigma_k^4 R(f'')} \right)^{1/5}.$$

- Cố định hàm kernel $k(\cdot) \Rightarrow$ xác định $R(k)$ và σ_k^2 .
- Nếu ta giả định một dạng hợp lý cho $f \Rightarrow$ xấp xỉ $R(f'')$.

Thay thế các giá trị này vào công thức h^* ta có được h^* plug-in.

Plug-in methods

Silverman's method - Rule-of-thumb (RoT) method

Silverman đề xuất một cách làm đơn giản với:

- Gaussian kernel $\Rightarrow R(k) = \frac{1}{2\sqrt{\pi}}$ và $\sigma_k^2 = 1$.
- f là phân phối chuẩn với trung bình μ và phương sai $\sigma^2 \Rightarrow R(f'')$ là

$$R(f'') = \frac{3}{4} \frac{1}{2\sqrt{\pi}\sigma^5}.$$

Khi đó, ta thu được

$$h_{S,0}^* = \left(\frac{4}{3n}\right)^{1/5} \hat{\sigma} \approx 1.06n^{-1/5} \hat{\sigma}.$$

Nhận xét: trong trường hợp tổng quát, nếu f có đa đỉnh (multimodal), $h_{S,0}^*$ sẽ tạo ra ước lượng mật độ kernel là quá trơn (oversmoothing).

Silverman đề xuất thay thế

$$h_{S,1}^* \approx 1.06n^{-1/5} \min \left\{ \hat{\sigma}, \frac{IQR}{\Phi^{-1}(0.75) - \Phi^{-1}(0.25)} \right\} = 1.06n^{-1/5} \min \left\{ \hat{\sigma}, \frac{IQR}{1.35} \right\}.$$

Plug-in methods

Sheather-Jones method

Thay vì xấp xỉ $R(f'')$ thông qua việc chỉ định một dạng f cụ thể, Sheather và Jones đã đề xuất tìm h^* thông qua giải phương trình

$$\left(\frac{R(k)}{n\sigma_k^4 \hat{R}_{\alpha(h)}(f'')} \right)^{1/5} - h = 0,$$

trong đó,

$$\hat{R}_{\alpha(h)}(f'') = \frac{1}{n(n-1)\alpha^5} \sum_{i=1}^n \sum_{j=1}^n \phi^{(4)} \left(\frac{Y_i - Y_j}{\alpha} \right),$$

$$\hat{\alpha}(h) = \left(\frac{6\sqrt{2}h^5 \hat{R}_a(f'')}{\hat{R}_b(f'')} \right)^{1/7}$$

$$\hat{R}_a(f'') = \frac{1}{n(n-1)a^5} \sum_{i=1}^n \sum_{j=1}^n \phi^{(4)} \left(\frac{Y_i - Y_j}{a} \right),$$

$$\hat{R}_b(f'') = \frac{1}{n(n-1)b^7} \sum_{i=1}^n \sum_{j=1}^n \phi^{(6)} \left(\frac{Y_i - Y_j}{b} \right),$$

Plug-in methods

và

$$\begin{aligned}a &= \frac{0.920 \, IQR}{n^{1/7}} \\ b &= \frac{0.912 \, IQR}{n^{1/9}},\end{aligned}$$

$\phi^{(4)}(u)$ và $\phi^{(6)}(u)$ là đạo hàm cấp 4 và 6 của hàm mật độ xác suất của phân phối chuẩn $\mathcal{N}(0, 1)$.

Nghiệm h_{SJ}^* của phương trình này có thể tìm được bằng:

- grid search; hoặc
- phương pháp tối ưu số Newton.

Plug-in methods

Thay vì giải phương trình, phương pháp Sheather-Jones có thể tính h^* trực tiếp
 $\Rightarrow h_{\text{SJ-DPI}}^*$ (Sheather-Jones direct plug-in):

$$h_{\text{SJ-DPI}}^* = \left(\frac{R(k)}{n\sigma_k^4 \widehat{R}(f'')} \right)^{1/5},$$

trong đó, $\widehat{R}(f'')$ được ước lượng qua các bước sau:

Bước 1: ước lượng $\tilde{\sigma} = \min \left\{ \widehat{\sigma}, \frac{IQR}{1.35} \right\}$;

Bước 2: ước lượng bằng thông g_1 bởi

$$g_1 = \left(-\frac{64k^{(6)}(0)\sqrt{\pi}}{105\sigma_k^2 n} \right)^{1/9} \tilde{\sigma}$$

sau đó, ước lượng

$$a = \frac{1}{n^2 g_1^7} \sum_{i=1}^n \sum_{j=1}^n k^{(6)} \left(\frac{X_i - X_j}{g_1} \right);$$

Plug-in methods

Bước 3: ước lượng g_2 theo

$$g_2 = \left(-\frac{2k^{(4)}(0)}{a\sigma_k^2 n} \right)^{(1/7)},$$

sau đó, ước lượng

$$\widehat{R}(f'') = \frac{1}{n^2 g_2^5} \sum_{i=1}^n \sum_{j=1}^n k^{(4)} \left(\frac{X_i - X_j}{g_2} \right).$$

Thông thường, ta thường chọn $k(\cdot)$ là Gaussian kernel (các phần mềm áp dụng cách chọn này).

Data-driven method

Thay sử dụng plug-in method dựa trên cực tiểu hóa $AMISE(h)$, có nhiều phương pháp data-driven đã được phát triển:

- không phụ thuộc vào giả định của hàm f ;
- tự động tương thích với dữ liệu cụ thể.

Các phương pháp này thường dựa trên nguyên lý của cross-validation.

Ước lượng loại bỏ một điểm

Ước lượng mật độ kernel loại bỏ một điểm dữ liệu Y_i được định nghĩa bởi:

$$\hat{f}_{-i,K,h}(Y_i) = \frac{1}{(n-1)h} \sum_{j=1, j \neq i}^n k\left(\frac{Y_j - Y_i}{h}\right),$$

tức là, ta ước lượng dựa trên $n-1$ dữ liệu còn lại.

Tuy nhiên, vì ta không có $f(Y_i)$ nên không thể tính trực tiếp sai số

$$\frac{1}{n} \sum_{i=1}^n \left\{ \hat{f}_{-i,K,h}(Y_i) - f(Y_i) \right\}^2,$$

và tìm h sao cho sai số cross-validation là nhỏ nhất.

Data-driven method

Pseudo-likelihood method

Nhắc lại rằng $Y_1, \dots, Y_n$ là mẫu ngẫu nhiên, độc lập cùng phân phối $F(\cdot; \theta)$, nên do đó, ta xây dựng được hàm log-likelihood (hàm log-hợp lý):

$$\ell(\theta; Y_1, \dots, Y_n) = \sum_{i=1}^n \log \{f(Y_i; \theta)\}.$$

Sử dụng $\hat{f}_{-i,K,h}(Y_i)$ thay thế cho $f(Y_i; \theta)$ ta có hàm pseudo log-likelihood:

$$\ell(h; Y_1, \dots, Y_n) = \sum_{i=1}^n \log \left\{ \hat{f}_{-i,K,h}(Y_i) \right\}.$$

Áp dụng nguyên lý hợp lý cực đại, ta tìm h tối ưu sao cho ước lượng mật độ kernel là phù hợp với dữ liệu nhất, tức là:

$$h_{\text{PL}}^* = \arg \max_{h>0} \ell(h; Y_1, \dots, Y_n).$$

Data-driven method

Nhược điểm của phương pháp Pseudo-likelihood:

- ước lượng mật độ kernel với h_{PL}^* thường gập ghềnh (wiggly);
- kết quả thường rất nhạy (sensitivity) với các điểm ngoại lai;
- kết quả h_{PL}^* thường không nhất quán (consistent).

Least squares cross-validation method

Một cách tiếp cận khác là sử dụng cross-validation nhằm xấp xỉ $ISE(h)$.

$$\begin{aligned}
 ISE(h) &= \int_{-\infty}^{+\infty} \left(\hat{f}_{K,h}(y) - f(y) \right)^2 dy \\
 &= R\left(\hat{f}_{K,h}\right) - 2\mathbb{E}\left(\hat{f}_{K,h}(y)\right) + R(f).
 \end{aligned}$$

Thành phần $R(f)$ có thể coi như là một hằng số. Thành phần $\mathbb{E}\left(\hat{f}_{K,h}(y)\right)$ được xấp xỉ bởi

$$\mathbb{E}\left(\hat{f}_{K,h}(y)\right) = \frac{1}{n} \sum_{i=1}^n \hat{f}_{-i,K,h}(Y_i).$$

Data-driven method

Khi đó, ta có phiên bản cross-validation cho $\text{ISE}(h)$ là

$$\text{LSCV}(h) = R\left(\hat{f}_{K,h}\right) - \frac{2}{n} \sum_{i=1}^n \hat{f}_{-i,K,h}(Y_i).$$

Từ đây, ta tìm h sao cho cực tiểu hóa $\text{LSCV}(h)$, tức là:

$$h_{\text{LSCV}}^* = \arg \min_{h>0} \text{LSCV}(h).$$

Chú ý: $\text{LSCV}(h)$ còn được gọi là **Unbias Cross-Validation** (UCV) vì

$$\mathbb{E}(\text{LSCV}(h) + R(f)) = \text{MISE}(h).$$

Ta chứng minh được rằng

$$\text{LSCV}(h) = \frac{1}{n^2 h} \sum_{i,j=1}^n \left\{ g\left(\frac{Y_i - Y_j}{h}\right) - 2k\left(\frac{Y_i - Y_j}{h}\right) \right\} + \frac{2k(0)}{nh} + O(n^{-2}),$$

trong đó, $g(u) = \int_{-\infty}^{+\infty} k(u-t)k(t)dt$ (tích chập - convolution của k).

Data-driven method

Phương pháp Bias Cross-Validation

Khác với LSCV, phương pháp Bias Cross-Validation (BCV) nhằm mục tiêu tìm h^* so cho cực tiểu $\text{AMISE}(h)$. Nhắc lại rằng

$$\text{AMISE}(h) = \frac{1}{nh} R(k) + \frac{1}{4} h^4 \sigma_k^4 R(f'').$$

Scoll và Terrell đã đề xuất thay thế $R(f'')$ bởi $\hat{R}(f'')$ được xác định là

$$\begin{aligned} \hat{R}(f'') &= R\left(\hat{f}_{K,h}''\right) - \frac{R(k'')}{nh^5} \\ &= \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1, j \neq i}^n (k'' * k'') \left(\frac{X_i - X_j}{h} \right) \end{aligned}$$


và định nghĩa

$$\text{BCV}(h) = \frac{1}{nh} R(k) + \frac{1}{4} h^4 \sigma_k^4 \hat{R}(f'').$$

Từ đây, ta tìm h tương ứng cực tiểu địa phương nhỏ nhất của $\text{BCV}(h)$, tức là:

$$h_{\text{BCV}}^* = \arg \text{locmin}_{h>0} \text{BCV}(h).$$

Ví dụ - Whale data



- Đường màu xanh, $h_S^* = 18.89$
- Đường màu đỏ, $h_{SJ}^* = 10.25$
- Đường màu đen nét đứt, $h_{LSCV}^* = 5.08$
- Đường màu đen nét đứt chấm, $h_{BCV}^* = 26.52$

Thảo luận mở

Phương pháp không dùng kernel

Logspline là một phương pháp ước lượng hàm mật độ không sử dụng hàm kernel mà thay vào đó là các hàm cơ sở (cubic spline) trên các phân hoạch nhỏ của dữ liệu.

⇒ Chương 10.3 sách “Computational Statistics” của Givens, G. H., & Hoeting, J. A. (2013).

Ước lượng mật độ nhiều chiều

Trong thực tế, ta thường quan tâm tới việc ước lượng mật độ xác suất đồng thời cho nhiều biến - vector ngẫu nhiên $(Y_1, Y_2, \dots, Y_p)$.

⇒ Chương 10.4 sách “Computational Statistics” của Givens, G. H., & Hoeting, J. A. (2013):

- Multivariate Kernel Estimators (phần 10.4.2)
- Adaptive Kernels and Nearest Neighbors (phần 10.4.3)
- Exploratory Projection Pursuit (phần 10.4.4)

Thảo luận mở

Ứng dụng của ước lượng mật độ

Trong thống kê và khoa học dữ liệu, ước lượng hàm mật độ luôn là công cụ quan trọng với các ứng dụng sau:

- xác định khu vực các mức tập trung cao của dữ liệu (Density level set estimation);
- phân cụm dữ liệu dựa trên hàm mật độ (mean shift clustering);
- phân loại dữ liệu (Bayesian classifier);
- xác định và mô tả đặc trưng quan trọng của dữ liệu (density ridge estimation).

Tối ưu hóa lựa chọn kernel

Ý tưởng lựa chọn hàm kernel $k(\cdot)$ dựa trên tiêu chí cực tiểu hóa $\text{AMISE}(h)$:

$$\text{AMISE}(h) = \frac{1}{nh} R(k) + \frac{1}{4} h^4 \sigma_k^4 R(f''),$$

với

$$h^* = \left(\frac{R(k)}{n \sigma_k^4 R(f'')} \right)^{1/5}.$$

Ta có cực tiểu của AMISE được xác định bởi

$$\text{AMISE}(h^*) = \frac{5}{4} \left(\frac{R(k) \sigma_k}{n} \right)^{4/5} \{R(f'')\}^{1/5}.$$

Như vậy, giá trị của AMISE tối thiểu là phụ thuộc vào hàm kernel thông qua:

- độ gồ ghề $R(k)$;
- độ phân tán σ_k .

Tối ưu hóa lựa chọn kernel

Ví dụ: Giả sử ta có hai kernel $k_1(\cdot)$ và $k_2(\cdot)$ tương ứng với h_1^* và h_2^* , sao cho $R(k_2)\sigma_{k_2} = 2R(k_1)\sigma_{k_1}$, thì

$$\text{AMISE}(h_2^*) = \frac{5}{4} \left(\frac{2R(k_1)\sigma_{k_1}}{n} \right)^{4/5} \{R(f'')\}^{1/5}.$$

Điều đó có nghĩa là ta cần $n^* = 2n$ để $\text{AMISE}(h_2^*) = \text{AMISE}(h_1^*)$.

$\Rightarrow$ cùng một bộ dữ liệu, ta cần chọn kernel sao cho tối thiểu hóa $\text{AMISE}(h^*)$, tức là

$$k^*(\cdot) = \arg \min_{k(\cdot)} R^2(k)\sigma_k^2.$$

Đây là bài toán biến phân (variational calculus problem). Nghiệm giải tích là

$$k^*(u) = \begin{cases} 0.75(1 - u^2), & \text{nếu } |u| \leq 1, \\ 0 & \text{ngược lại.} \end{cases}$$

Đây chính là Epanechnikov kernel.

$\Rightarrow$ Epanechnikov kernel là kernel **tối ưu** cho $\text{AMISE}(h^*)$.

Tối ưu hóa lựa chọn kernel

Relative efficiencies

Để so sánh độ hiệu quả của hai kernel $k_1(\cdot)$ và $k_2(\cdot)$, ta đánh giá dựa trên tỷ số giữa hai AMISE, và được định danh là **Relative efficiencies** (RE):

$$\text{RE} = \frac{\text{AMISE}(h_1^*)}{\text{AMISE}(h_2^*)} = \frac{R(k_1)\sigma_{k_1}}{R(k_2)\sigma_{k_2}}.$$

Cụ thể $k_1(\cdot)$ luôn là Epanechnikov kernel, do nó là tối ưu.

Ví dụ: $k_2(\cdot)$ là Gaussian kernel, ta có:

$$\text{RE} = \frac{(3/5)(1/\sqrt{5})}{1/2\sqrt{\pi}} \approx 0.9512$$

tức là, Gaussian kernel có độ hiệu quả là 95.12% so với Epanechnikov kernel.
Bảng dưới đây tổng hợp các kernel thông dụng kèm theo thông tin:

Tối ưu hóa lựa chọn kernel


- độ gồ ghề $R(k)$;
- độ phân tán σ_k ;
- RE so với Epanechnikov kernel.

Kernel	$R(k)$	σ_k^2	RE
Epanechnikov	3/5	1/5	1.000
Gaussian	$1/2\sqrt{\pi}$	1	0.951
Triangle	2/3	1/6	0.986
Quartic	5/7	1/7	0.994
Triweight	350/429	1/9	0.987
Tricube	175/247	35/243	0.998
Cosine	$\pi^2/16$	$1 - 8/\pi^2$	0.999
Uniform	1/2	1/3	0.929

Nhận xét: các hàm kernel có độ hiệu quả khá gần với Epanechnikov kernel.
 $\Rightarrow$ việc lựa chọn kernel không gây ra nhiều sự khác biệt!

Kết luận: việc lựa chọn kernel **không** quá quan trọng!

Tối ưu hóa lựa chọn kernel



Bảng thông $h = 12$,

- Đường màu xanh, Epanechnikov kernel;
- Đường màu đỏ, Gaussian kernel;
- Đường màu đen nét đứt, Triangular kernel;
- Đường màu đen nét đứt chấm, Biweight kernel.

Mối liên hệ giữa h^* và kernel

Nhắc lại rằng:

$$h^* = \left(\frac{R(k)}{n\sigma_k^4 R(f'')} \right)^{1/5}.$$

Khi đó, với hai kernel $k_1(\cdot)$ và $k_2(\cdot)$ tương ứng với h_1^* và h_2^* , ta có

$$\frac{h_1^*}{h_2^*} = \frac{(R(k_1)/\sigma_{k_1}^4)^{1/5}}{(R(k_2)/\sigma_{k_2}^4)^{1/5}}.$$

Hay tương đương với

$$h_2^* = h_1^* \frac{(R(k_2)/\sigma_{k_2}^4)^{1/5}}{(R(k_1)/\sigma_{k_1}^4)^{1/5}}.$$

Do đó, ta có thể chuyển đổi bằng thông tối ưu AMISE khi thay đổi kernel.

1 *Dự đoán mật độ dữ liệu*

2 *Tối ưu hóa lựa chọn tham số*

3 *Dự đoán xu hướng*

Xác định xu hướng

Trong phân tích dữ liệu, ta thường làm việc với dữ liệu có đa biến, khi đó, ta thường quan tâm tới bài toán

Dự đoán xu hướng thay đổi của 1 biến theo dữ liệu của một biến còn lại.

Tức là, xác định hàm $m(\cdot)$ trong mô hình

$$Y_i = m(x_i) + \varepsilon_i,$$

với (x_i, Y_i) là cặp dữ liệu quan sát được của hai biến ngẫu nhiên (X_i, Y_i) độc lập cùng phân phối $F_{X,Y}(x, y)$, với $i = 1, \dots, n$.


Trong mô hình trên

- $m(\cdot)$ là một hàm trơn biểu diễn xu hướng thay đổi của Y theo X ;
- ε_i là thành phần sai số không quan sát được khi mô hình hóa dữ liệu.

Mục tiêu: Hàm $m(\cdot)$ là chưa biết $\Rightarrow$ cần ước lượng từ dữ liệu.

Xác định xu hướng

Ví dụ: Để kiểm tra giới hạn chịu đựng của mũ bảo hiểm xe máy, một nghiên cứu đã được tiến hành, trong đó, gia tốc đầu (head acceleration) đã được đo đạc nhưng một biến gián tiếp (proxy variable) cho nguy cơ bị chấn thương đầu.




- Biến X: thời gian va chạm (mili giây);
- Biến Y: head acceleration (g).

Xác định xu hướng

Do $m(\cdot)$ là chưa biết, một cách tiếp cận đơn giản là mô hình dạng tuyến tính:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$



⇒ rõ ràng là mô hình tuyến tính là không phù hợp.

Nonparametric regression

Xu hướng thay đổi của Y theo X có thể được mô hình hóa bởi

$$Y_i = m(X_i) + \varepsilon_i,$$

trong đó,

- (X_i, Y_i) là cặp mẫu ngẫu nhiên của (X, Y) ;
- ε_i là sai số ngẫu nhiên, độc lập, cùng phân phối sao cho $\mathbb{E}(\varepsilon_i) = 0$ và $\text{Var}(\varepsilon_i)$ là hữu hạn;
- ε và X là độc lập nhau.

Nhận xét:

Mục tiêu dự đoán xu hướng $\Leftrightarrow$ ước lượng hàm $m(x)$ từ dữ liệu.

Từ mô hình kết hợp với tính chất thống kê của ε , ta có:

$$m(x) = \mathbb{E}(Y|X = x),$$

tức là kỳ vọng của Y khi có điều kiện $X = x \Rightarrow$ ước lượng của $m(x)$:

$$\hat{m}(x) = \hat{\mathbb{E}}(Y|X = x).$$

KNN regression

Với mục tiêu ước lượng $m(x)$ bởi

$$\hat{m}(x) = \hat{\mathbb{E}}(Y|X = x),$$

ta có thể làm một cách thô:

$$\hat{m}(x) = \frac{1}{r} \sum_{j: X_j = x} Y_j,$$

với $r = \#\{X_i = x; i = 1, \dots, n\}$.

Tuy nhiên, ước lượng này là không thực tế do r có thể bằng 0.

$\Rightarrow$ xác định X_i theo nghĩa "lân cận" của x , hơn là chính xác bằng.

KNN regression

Lân cận delta - δ -neighborhood

Cho trước $\delta > 0$, lân cận delta của x , $N_\delta(x)$, được định nghĩa bởi

$$N_\delta(x) = \{X_i : \text{distance}(X_i, x) \leq \delta, i = 1, \dots, n\},$$

tức là tập hợp gồm các điểm X_i sao cho $\text{distance}(X_i, x)$ là bé hơn δ .

Nhận xét: cố định $\delta \Rightarrow$ ước lượng mất tính ổn định! (Tại sao?)

Lân cận k - k -neighborhood

Cho trước $1 \leq k \leq n$, $k \in \mathbb{N}$, lân cận k của x , $N_k(x)$, được định nghĩa bởi

$$N_k(x) = \{X_j : \text{distance}(X_j, x) \text{ là nhỏ nhất}, j = 1, \dots, k\},$$

tức là tập hợp gồm k điểm X_i sao cho $\text{distance}(X_i, x)$ là bé nhất.

Nhận xét: số lượng điểm trong 1 lân cận luôn cố định, nhưng độ rộng của khoảng sẽ thay đổi.

KNN regression

K-nearest neighborhood regression

K-nearest neighborhood regression (KNN regression) hay hồi quy K-lân cận là ước lượng hồi quy dựa trên định nghĩa của lân cận k , trong đó:

$$\hat{m}_K(x) = \frac{1}{k} \sum_{j \in N_k(x)} Y_j.$$

Khoảng cách giữa x và một điểm X_i :

- Euclidean distance


$$\text{distance}(X_i, x) = |X_i - x|,$$

- Canberra distance

$$\text{distance}(X_i, x) = \frac{|X_i - x|}{|X_i| + |x|},$$

Thông thường, Euclidean distance được sử dụng.

KNN regression



KNN regression

KNN regression

Nhận xét:

- 1 Số lượng điểm lân cận k ảnh hưởng đến mức độ “chính xác cục bộ” của ước lượng;
- 2 Khi k thấp $\Rightarrow \hat{m}_K(x)$ có độ biến thiên cao. Trường hợp cực đoan, $k = 1$ tương ứng với giá trị “trung bình” của một điểm dữ liệu duy nhất.
- 3 Khi k cao $\Rightarrow \hat{m}_K(x)$ không mang tính địa phương và có độ lệch cao. Trường hợp cực đoan $k = n \Rightarrow \hat{m}_K(x)$ là một hằng số, tức là giá trị trung bình của tất cả các quan sát.
- 4 Do đó, có sự đánh đổi giữa độ lệch và phương sai trong việc lựa chọn k , cần được lựa chọn, ví dụ, thông qua phương pháp cross-validation.
- 5 Đường ước lượng (dự đoán) là gồ ghề, bởi vì $\hat{m}_K(x)$ không liên tục.
- 6 Khi ta di chuyển x từ trái sang phải, vùng lân cận k gần nhất vẫn không đổi cho đến khi một điểm X_i mới ở bên phải của x được thêm vào và một điểm ở bên trái bị loại bỏ.

$\Rightarrow$ ta cần tìm kiếm một dự đoán mượt mà hơn.

Kernel regression method

Áp dụng định nghĩa của kỳ vọng có điều kiện, ta có

$$\begin{aligned}\mathbb{E}(Y|X=x) &= \int_{-\infty}^{+\infty} y f_{Y|X=x}(y) dy \\ &= \int_{-\infty}^{+\infty} y \frac{f_{X,Y}(x,y)}{f_X(x)} dy \\ &= \frac{1}{f_X(x)} \int_{-\infty}^{+\infty} y f_{X,Y}(x,y) dy\end{aligned}$$

$\Rightarrow$ ta cần ước lượng hai hàm mật độ xác suất $f_{X,Y}(x,y)$ và $f_X(x)$.

Áp dụng phương pháp ước lượng mật độ kernel, ta có

$$\hat{f}_{X,K,h_X}(x) = \frac{1}{nh_X} \sum_{i=1}^n k\left(\frac{x-X_i}{h_X}\right)$$

với $h_X > 0$ là băng thông.

Kernel regression method

Với hàm mật độ xác suất đồng thời $f_{X,Y}(x,y)$, áp dụng phương pháp ước lượng mật độ kernel đa chiều, với product kernel:

$$\hat{f}_{X,Y,K,h_X,h_Y}(x,y) = \frac{1}{nh_Xh_Y} \sum_{i=1}^n k\left(\frac{x-X_i}{h_X}\right) k\left(\frac{y-Y_i}{h_Y}\right)$$

Do đó, ta có

$$\begin{aligned} \int_{-\infty}^{+\infty} y \hat{f}_{X,Y,K,h_X,h_Y}(x,y) dy &= \frac{1}{nh_Xh_Y} \int_{-\infty}^{+\infty} y \sum_{i=1}^n k\left(\frac{x-X_i}{h_X}\right) k\left(\frac{y-Y_i}{h_Y}\right) dy \\ &= \frac{1}{nh_Xh_Y} \sum_{i=1}^n k\left(\frac{x-X_i}{h_X}\right) \int_{-\infty}^{+\infty} y k\left(\frac{y-Y_i}{h_Y}\right) dy \\ &= \frac{1}{nh_X} \sum_{i=1}^n Y_i k\left(\frac{x-X_i}{h_X}\right) \end{aligned}$$

Kernel regression method

Dẫn tới ước lượng hồi quy kernel:

$$\hat{m}_{K,h_X}(x) = \frac{\sum_{i=1}^n Y_i k\left(\frac{x - X_i}{h_X}\right)}{\sum_{i=1}^n k\left(\frac{x - X_i}{h_X}\right)},$$

với băng thông $h_X > 0$.

Ước lượng này có tên là Nadaraya-Watson estimation.

Ước lượng này còn có thể được biểu diễn dưới dạng trung bình trọng số của Y khi biết $X = x$:

$$\hat{m}_{K,h_X}(x) = \sum_{i=1}^n W_i Y_i,$$

$$\text{với } W_i = k\left(\frac{x - X_i}{h_X}\right) \left[\sum_{i=1}^n k\left(\frac{x - X_i}{h_X}\right) \right]^{-1}.$$

Kernel regression method

Local linear regression method

Xét lại mô hình hồi quy xu hướng

$$Y_i = m(X_i) + \varepsilon_i,$$

Từ đây, ta định nghĩa được tổng bình phương thặng dư (Residual Sum of Squares) - RSS:

$$\text{RSS} = \sum_{i=1}^n (Y_i - m(X_i))^2.$$

Lúc này, ta sẽ tìm $\hat{m}(x)$ theo phương pháp bình phương tối thiểu.

Tuy nhiên do $m(x)$ chưa có dạng cụ thể $\Rightarrow$ tham số hóa $m(x)$.

Áp dụng khai triển Taylor tại x xung quanh X_i :

$$\begin{aligned} m(X_i) &= m(x) + m'(x)(X_i - x) + \frac{m^{(2)}(x)}{2}(X_i - x)^2 + \dots + \frac{m^{(p)}(x)}{p!}(X_i - x)^p \\ &= \sum_{j=0}^p \frac{m^{(j)}(x)}{j!}(X_i - x)^j, \end{aligned}$$

Local linear regression method

trong đó, $m^{(j)}(x)$ là đạo hàm cấp j .

Đặt $\frac{m^{(j)}(x)}{j!} = \beta_j$, hệ số chưa biết, ta thu được dạng tham số hóa cho $m(x)$:

$$m(x) = \sum_{j=0}^p \beta_j (X_i - x)^j.$$

Thay thế vào RSS, ta xác định được bài toán phương pháp bình phương tối thiểu:

$$\hat{\beta} = \arg \min_{\beta \in \mathbb{R}^{p+1}} \sum_{i=1}^n \left(Y_i - \sum_{j=0}^p \beta_j (X_i - x)^j \right)^2,$$

với $\beta = (\beta_0, \beta_1, \dots, \beta_p)$.

Nhận xét 1: Ta hoàn toàn có thể tìm được $\hat{\beta}$ từ biểu thức trên, tuy nhiên, khi đó, ước lượng $\hat{\beta}$ thu được là nghiệm toàn cục (trên toàn miền dữ liệu) thay vì là nghiệm địa phương lân cận x .

Local linear regression method

Nhận xét 2: Thực tế, $\beta_j \equiv \beta_j(x)$, do đó, ta cần cập nhật thêm thành phần trọng số để xác định khu vực lân cận x của X_i .

Nhận xét 3: Trọng số cần phải phụ thuộc h_X và giảm dần khi $h_X \rightarrow 0$.

Nhận xét 4: Giá trị của hàm kernel $k\left(\frac{x - X_i}{h_X}\right)$ xác định tập các điểm X_i lân cận gần x tương ứng theo độ lớn của h_X .

Như vậy, ta có bài toán bình phương tối thiểu địa phương:

$$\hat{\beta}_h(x) = \arg \min_{\beta \in \mathbb{R}^{p+1}} \sum_{i=1}^n \left(Y_i - \sum_{j=0}^p \beta_j (X_i - x)^j \right)^2 k\left(\frac{x - X_i}{h_X}\right),$$

với p được xác định trước.

Local linear regression method

Bằng cách đặt ma trận trọng số:

$$\mathbf{W} = \begin{pmatrix} k \left(\frac{x - X_1}{h_X} \right) & 0 & \dots & 0 \\ 0 & k \left(\frac{x - X_2}{h_X} \right) & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & k \left(\frac{x - X_n}{h_X} \right) \end{pmatrix},$$

ma trận thiết kế:

$$\mathbf{Z} = \begin{pmatrix} 1 & (X_1 - x) & (X_1 - x)^2 & \dots & (X_1 - x)^p \\ 1 & (X_2 - x) & (X_2 - x)^2 & \dots & (X_2 - x)^p \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & (X_n - x) & (X_n - x)^2 & \dots & (X_n - x)^p \end{pmatrix}$$

vector dữ liệu quan sát $\mathbf{Y} = (Y_1, Y_2, \dots, Y_n)^\top$, ta viết được bài toán về dạng ma trận:

$$\hat{\beta}_h(x) = \arg \min_{\beta(x) \in \mathbb{R}^{p+1}} (\mathbf{Y} - \mathbf{Z}\beta(x))^\top \mathbf{W} (\mathbf{Y} - \mathbf{Z}\beta(x)),$$

Local linear regression method

Áp dụng đạo hàm của ma trận, ta xác định được phương trình đạo hàm

$$\mathbf{Z}^\top \mathbf{W} (\mathbf{Y} - \mathbf{Z}\beta) = 0.$$

Từ đây, ta tính được

$$\hat{\beta}_h(x) = (\mathbf{Z}^\top \mathbf{W} \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{W} \mathbf{Y}.$$

Nhắc lại rằng $\beta_j(x) = \frac{m^{(j)}(x)}{j!}$ và với $j = 0$, $\beta_0(x) = m(x)$. Do đó ta thu được ước lượng Local Polynomial (LP) regression bởi:

$$\hat{m}_{\text{LP}, h_X, p}(x) = \mathbf{e}_1^\top (\mathbf{Z}^\top \mathbf{W} \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{W} \mathbf{Y},$$

với $\mathbf{e}_1 = (1, 0, \dots, 0)$ - chứa p phần tử 0.

Thêm vào đó, ta có thể biểu diễn $\hat{m}_{\text{LP}, h_X, p}(x)$ dưới dạng tổng tuyến tính:

$$\hat{m}_{\text{LP}, h_X, p}(x) = \sum_{i=1}^n W_{i, h_X}^p(x) Y_i = \mathbf{S} \mathbf{Y}.$$

Local linear regression method

Hai trường hợp được sử dụng nhiều:

- $p = 0$ là ước lượng local constant, lúc này $\mathbf{Z} = (1, 1, \dots, 1)^\top$, do đó $\hat{m}_{\text{LP}, h_X, 0}(x) \equiv \hat{m}_{K, h_X}(x)$ (Nadaraya-Watson estimator).
- $p = 1$ là ước lượng local linear, khi đó ta có $\hat{m}_{\text{LP}, h_X, 1}(x) \equiv \hat{m}_{\text{LL}, h_X}(x)$:

$$\hat{m}_{\text{LL}, h_X}(x) = \sum_{i=1}^n W_{i, h_X}^1(x) Y_i,$$

trong đó,

$$W_{i, h_X}^1 = \frac{1}{n} \frac{\hat{s}_2(x; h_X) - \hat{s}_1(x; h_X)(X_i - x)}{\hat{s}_2(x; h_X)\hat{s}_0(x; h_X) - \hat{s}_1^2(x; h_X)} k\left(\frac{x - X_i}{h_X}\right),$$

với

$$\hat{s}_r(x; h_X) = \frac{1}{n} \sum_{i=1}^n (X_i - x)^r k\left(\frac{x - X_i}{h_X}\right),$$

và $r = 0, 1, 2$.

Local linear regression method

Đánh giá dự đoán xu hướng

Tương tự như trong đánh giá dự đoán mật độ của dữ liệu, ta định nghĩa tích phân bình phương sai số (ISE) của $\widehat{m}_{\text{LP},h_X,p}(x)$ bởi:

$$\text{ISE}[\widehat{m}_{\text{LP},h_X,p}(\cdot)] = \int_{-\infty}^{+\infty} \{\widehat{m}_{\text{LP},h_X,p}(x) - m(x)\}^2 f_X(x) dx.$$

$\text{ISE}[\widehat{m}_{\text{LP},h_X,p}(\cdot)]$ là đại lượng ngẫu nhiên phụ thuộc trực tiếp vào dữ liệu $(X_1, Y_1), \dots, (X_n, Y_n)$.

Trung bình tích phân bình phương sai số (MISE) của $\widehat{m}_{\text{LP},h_X,p}(x)$ được định nghĩa bởi:

$$\begin{aligned} \text{MISE}[\widehat{m}_{\text{LP},h_X,p}(\cdot) | X_1, \dots, X_n] &= \mathbb{E} \left(\text{ISE}[\widehat{m}_{\text{LP},h_X,p}(\cdot)] | X_1, \dots, X_n \right) \\ &= \int_{-\infty}^{+\infty} \mathbb{E} \left[\{\widehat{m}_{\text{LP},h_X,p}(x) - m(x)\}^2 | X_1, \dots, X_n \right] f_X(x) dx \\ &= \int_{-\infty}^{+\infty} \text{Var}[\widehat{m}_{\text{LP},h_X,p}(x) | X_1, \dots, X_n] f_X(x) dx \\ &\quad + \int_{-\infty}^{+\infty} \text{Bias}^2[\widehat{m}_{\text{LP},h_X,p}(x) | X_1, \dots, X_n] f_X(x) dx \end{aligned}$$

Đánh giá dự đoán xu hướng

Để phân tích MISE, ta cần các giả định sau:

(A1) Hàm $m(x)$ có đạo hàm cấp hai liên tục.

(A2) Phương sai điều kiện $\sigma^2(x) = \mathbb{V}\text{ar}(Y|X = x)$ là liên tục và là hàm dương.

(A3) Hàm mật độ xác suất của X , $f_X(x)$ có đạo hàm liên tục và bị chặn cách xa 0.

(A4) Hàm kernel $k(\cdot)$ là một hàm mật độ xác suất đối xứng và bị chặn, có mômen bậc hai hữu hạn và khả tích bình phương.

(A5) $h_X = h_n$ là một chuỗi bang thông sao cho $n \rightarrow \infty$, $h_X \rightarrow 0$ và $nh_X \rightarrow \infty$.

Đánh giá dự đoán xu hướng

Dưới các giả định (A1) - (A5), ta chứng minh được rằng

$$\text{Bias} [\widehat{m}_{\text{LP}, h_X, p}(x) | X_1, \dots, X_n] = B_p(x)h^2 + o_p(h^2),$$

trong đó

$$B_p(x) = \begin{cases} \frac{\sigma_k^2}{2} \left\{ m''(x) + 2 \frac{m'(x)f'_X(x)}{f_X(x)} \right\} & \text{nếu } p = 0, \\ \frac{\sigma_k^2}{2} m''(x) & \text{nếu } p = 1, \end{cases}$$

và

$$\text{Var} [\widehat{m}_{\text{LP}, h_X, p}(x) | X_1, \dots, X_n] = \frac{R(k)}{nh_X f_X(x)} \sigma^2(x) + o_p((nh_X)^{-1}).$$

Khi đó,

$$\begin{aligned} \text{MISE} [\widehat{m}_{\text{LP}, h_X, p}(\cdot) | X_1, \dots, X_n] &= \frac{R(k)}{nh_X} \int_{-\infty}^{+\infty} \sigma^2(x) dx + h_X^4 \int_{-\infty}^{+\infty} B_p^2(x) f_X(x) dx \\ &\quad + o_p \left(h_X^4 + \frac{1}{nh_X} \right). \end{aligned}$$

Đánh giá dự đoán xu hướng

Khi này, ta xác định được AMISE là:

$$\text{AMISE}[\widehat{m}_{\text{LP}, h_X, p}(\cdot) | X_1, \dots, X_n] = \frac{R(k)}{nh_X} \int_{-\infty}^{+\infty} \sigma^2(x) dx + h_X^4 \int_{-\infty}^{+\infty} B_p^2(x) f_X(x) dx.$$

Tương tự như đánh giá AMISE của ước lượng mật độ kernel, AMISE của $\widehat{m}_{\text{LP}, h_X, p}(x)$ là

■ hàm lõm;

⇒ tồn tại duy nhất 1 cực tiểu.

Do đó, ta có thể tìm h_X^* sao cho cực tiểu hóa AMISE.

Lựa chọn h : Plug-in method

Nhắc lại

$$\text{AMISE}[\widehat{m}_{\text{LP}, h_X, p}(\cdot) | X_1, \dots, X_n] = \frac{R(k)}{nh_X} \int_{-\infty}^{+\infty} \sigma^2(x) dx + h_X^4 \int_{-\infty}^{+\infty} B_p^2(x) f_X(x) dx.$$

Với $p = 1$ (local linear), ta chứng minh được

$$h_{\text{LL}}^* = \left(\frac{R(k)}{\sigma_k^2 n a(m)} \int_{-\infty}^{+\infty} \sigma^2(x) dx \right)^{1/5},$$

trong đó

$$a(m) = \int_{-\infty}^{+\infty} [m''(x)]^2 f_X(x) dx.$$

$\Rightarrow$ yêu cầu xấp xỉ được $a(m)$ và $\int_{-\infty}^{+\infty} \sigma^2(x) dx$.

Lựa chọn h: Plug-in method

Nhận xét: $a(m)$ có dạng là trung bình của $[m''(X)]^2$, do đó, ta có

$$\widehat{a}(m) = \frac{1}{n} \sum_{i=1}^n [m''(X_i)]^2.$$

Như vậy, ta cần ước lượng được $m''(X)$ một cách toàn cục.

Một trong những lựa chọn là sử dụng hồi quy đa thức bậc 4 (fourth-order polynomial regression):

$$m_Q(x) = \alpha_0 + \sum_{j=1}^4 \alpha_j x^j + \varepsilon$$

khi này

$$\widehat{m}_Q''(x) = 2\widehat{\alpha}_2 + 6x\widehat{\alpha}_3 + 12x^2\widehat{\alpha}_4,$$

với $\widehat{\alpha}_2, \widehat{\alpha}_3, \widehat{\alpha}_4$ được ước lượng từ dữ liệu $(X_1, Y_1), \dots, (X_n, Y_n)$. Theo đó, ta xác định được

$$\widehat{a}(\widehat{m}_Q(x)) = \frac{1}{n} \sum_{i=1}^n [\widehat{m}_Q''(X_i)]^2.$$

Lựa chọn h: Plug-in method

Để thuận tiện trong ước lượng $\sigma^2(x)$, ta giả định $\sigma^2(x) = \sigma^2$ (hằng số).

Khi này, ta ước lượng σ^2 như là phương sai của sai số trong mô hình hồi quy tuyến tính:

$$\hat{\sigma}_Q^2 = \frac{1}{n-5} \sum_{i=1}^n (Y_i - \hat{m}_Q(X_i))^2,$$

$\hat{m}_Q(X_i)$ được xác định trong mô hình hồi quy đa thức bậc 4.

Khi này

$$\begin{aligned} \int_{-\infty}^{+\infty} \sigma^2(x) dx &\approx \hat{\sigma}_Q^2 \int_{-\infty}^{+\infty} 1 dx \\ &\approx \hat{\sigma}_Q^2 (X_{(n)} - X_{(1)}). \end{aligned}$$

Theo đó

$$h_{\text{LL, RoT}}^* = \left(\frac{R(k)}{\sigma_k^2 n \hat{a}(\hat{m}_Q(x))} \hat{\sigma}_Q^2 (X_{(n)} - X_{(1)}) \right)^{1/5}.$$

Lựa chọn h : Cross-validation method

Bên cạnh tìm h_X cực tiểu hóa AMISE, ta có thể tìm h cực tiểu hóa RSS:

$$\text{RSS}(h) = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{m}_{\text{LP}, h_X, p}(X_i))^2.$$

Tuy nhiên, $\text{RSS}(h) \approx 0$ khi $h \rightarrow 0$.

$\Rightarrow$ sử dụng tập validation để chọn h .

Sai số cross-validation (leave-one-out cross-validation - LOOCV)

$$\text{CV}(h) = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{m}_{-i, \text{LP}, h_X, p}(X_i))^2,$$

trong đó $\hat{m}_{-i, \text{LP}, h_X, p}(X_i)$ là kết quả dự đoán $m(x)$ tại X_i khi dùng $n - 1$ dữ liệu bỏ đi quan sát thứ i để ước lượng.

Ta chọn bằng thông h được chọn bởi

$$h_{\text{CV}}^* = \arg \min_{h > 0} \text{CV}(h).$$

Lựa chọn h : Cross-validation method

Tuy nhiên, chi phí tính toán cao:

- tại mỗi giá trị h là $O(n^2)$;
- toàn bộ tập h tiềm năng là $O(n^2 h)$.

⇒ tính chỉnh các tính $CV(h)$.

Ta biểu diễn

$$\hat{m}_{-i, \text{LP}, h_X, p}(x) = \sum_{j=1, j \neq i}^n W_{-i, j, h_X}^p(x) Y_j.$$

Ta chứng minh được rằng

$$W_{-i, j, h_X}^p(x) = \frac{W_{j, h_X}^p(x)}{\sum_{k=1, k \neq i}^n W_{k, h_X}^p(x)} = \frac{W_{j, h_X}^p(x)}{1 - W_{i, h_X}^p(x)}.$$

Theo đó

$$CV(h) = \frac{1}{n} \sum_{i=1}^n \left(\frac{Y_i - \hat{m}_{\text{LP}, h_X, p}(X_i)}{1 - W_{i, h_X}^p(X_i)} \right)^2,$$

Lựa chọn h : Cross-validation method

Công thức CV mới này yêu cầu tính

- $\hat{m}_{\text{LP}, h_X, p}(X_i)$; và
- $W_{i, h_X}^p(x)$.

Cả hai nhiệm vụ có thể được thực hiện đồng thời từ ma trận $n \times n$ lưu trữ $\{W_{i, h_X}^p(x)\}_{ij}$.

$\Rightarrow$ chi phí lưu trữ là $O((n^2 - n)/2) \Rightarrow$ tính toán nhanh hơn.

Bên cạnh công thức này, ta có thể cải thiện thời gian tính toán bằng cách sử dụng Generalized Cross-Validation (GCV):

$$\text{GCV}(h) = \frac{\sum_{i=1}^n (Y_i - \hat{m}_{\text{LP}, h_X, p}(X_i))^2}{\left(n - \sum_{i=1}^n W_{i, h_X}^p(X_i)\right)^2}.$$

Khi đó, ta chọn băng thông h được chọn bởi

$$h_{\text{GCV}}^* = \arg \min_{h > 0} \text{GCV}(h).$$

Boundary effect

Boundary effect hay (Boundary bias) miêu tả sự kém chính xác của ước lượng Nadaraya-Watson khi dự đoán kết quả tại x nằm gần biên của dữ liệu quan sát.

Nhắc lại rằng

$$\text{Bias} [\widehat{m}_{\text{LP}, h_X, p}(x) | X_1, \dots, X_n] = B_p(x)h^2 + o_p(h^2),$$

trong đó

$$B_p(x) = \begin{cases} \frac{\sigma_k^2}{2} \left\{ m''(x) + 2 \frac{m'(x)f'_X(x)}{f_X(x)} \right\} & \text{nếu } p = 0, \\ \frac{\sigma_k^2}{2} m''(x) & \text{nếu } p = 1, \end{cases}$$


$\Rightarrow$ độ chệch của $\widehat{m}_{K, h_X}(x)$ phụ thuộc vào $m''(x)$, $m'(x)$, $f_X(x)$ và $f'(x)$.

Khi x nằm gần biên của dữ liệu, thì

- số lượng X_i xung quanh x giảm xuống, do vùng xác định bởi băng thông bị cắt bớt
- $f_X(x)$ sẽ nhỏ

$\Rightarrow$ độ chệch tăng lên, dù cho có giảm h_X xuống.

Boundary effect



- Đường màu đỏ tương ứng $\hat{m}_{K,h_X}(x)$;
- Đường màu xanh dương tương ứng $\hat{m}_{LL,h_X}(x)$.

⇒ $\hat{m}_{LL,h_X}(x)$ hiệu chỉnh được boundary effect.