

Bài giảng 3: Bootstrap và Resampling Methods

TS. Tô Đức Khánh

Khoa Toán-Tin Học, Trường Đại Học Khoa Học Tự Nhiên
Đại Học Quốc Gia Tp. HCM

Thống kê Tính Toán - Computational Statistics

Mục lục

1 Nhắc lại phân phối mẫu

2 Xấp xỉ phân phối của ước lượng

3 Khoảng tin cậy bootstrap

4 A/B testing

1 Nhắc lại phân phối mẫu

2 Xấp xỉ phân phối của ước lượng

3 Khoảng tin cậy bootstrap

4 A/B testing

Phân phối mẫu của một thống kê

Thống kê - a Statistic

Một thống kê - a statistic, là một tên gọi ám chỉ tới các đại lượng được tính toán từ một dữ liệu, ví dụ:

- trung bình mẫu $\bar{Y}$;
- độ lệch chuẩn mẫu S ;
- hệ số tương quan tuyến tính Pearson;
- thống kê $T = \frac{\bar{Y} - \mu}{S/\sqrt{n}}$;
- dự đoán xu hướng $\hat{m}(x)$.

Phân phối mẫu của một thống kê

Thống kê - a Statistic

Một thống kê - a statistic, là một tên gọi ám chỉ tới các đại lượng được tính toán từ một dữ liệu, ví dụ:

- trung bình mẫu $\bar{Y}$;
- độ lệch chuẩn mẫu S ;
- hệ số tương quan tuyến tính Pearson;
- thống kê $T = \frac{\bar{Y} - \mu}{S/\sqrt{n}}$;
- dự đoán xu hướng $\hat{m}(x)$.

Bởi vì dữ liệu là ngẫu nhiên $\Rightarrow$ thống kê (ước lượng) cũng là đại lượng ngẫu nhiên.

$\hookrightarrow$ có các đặc trưng của một đại lượng ngẫu nhiên:

- trung bình;
- phương sai, độ lệch chuẩn;
- phân phối.

Phân phối mẫu của một thống kê

Phân phối mẫu

Phân phối mẫu là thuật ngữ nhằm tới phân phối của một thống kê, khi ta thực hiện lấy mẫu nhiều lần từ quần thể.

Phân phối này không phải bản chất vốn có mà là được phát sinh do quá trình lấy mẫu.

Độ chệch - Bias


Độ chệch (Bias) là thuật ngữ nhằm tới sự chênh lệch của trung bình của một thống kê so với giá trị “chính xác” (dựa trên quần thể/dữ liệu lớn), khi ta thực hiện lấy mẫu nhiều lần từ quần thể.

Sai số chuẩn - Standard error

Sai số chuẩn (Standard error) ám chỉ tới độ lệch chuẩn của một thống kê (ước lượng), đo sự biến động của ước lượng ở trên nhiều mẫu.

Phân phối mẫu của một thống kê

Sơ đồ dưới đây minh họa phân phối mẫu của trung bình mẫu $\bar{Y}$.



Ví dụ - Phân phối mẫu của trung bình


Xét dữ liệu về thu nhập theo năm của 50,000 hồ sơ vay tiền gửi tới Lending Club.

Từ dữ liệu lớn này, ta thực hiện như sau:

- Chọn ngẫu nhiên 1000 quan sát, coi như một quần thể.
- Từ 1000 quan sát, chọn ngẫu nhiên 1000 mẫu, có cỡ 5, và tính trung bình thu nhập của mỗi mẫu.
↪ ta có một tập hợp 1000 trung bình mẫu của cỡ mẫu 5.
- Từ 1000 quan sát, chọn ngẫu nhiên 1000 mẫu, có cỡ 20, và tính trung bình thu nhập của mỗi mẫu.
↪ ta có một tập hợp 1000 trung bình mẫu của cỡ mẫu 20.

Biểu đồ histogram dưới đây biểu diễn phân phối tương ứng của các dữ liệu, cùng với trung bình mẫu của mẫu gồm 1000 quan sát (đường nét đứt màu xanh).

Ví dụ - Phân phối mẫu của trung bình



Ví dụ - Phân phối mẫu của trung bình

Ta có bảng tổng hợp sau

	Trung bình	Độ lệch	SE
Mẫu 1000	68199.66	—	—
Trung bình của mẫu 5	69154.31	954.65	14979.52
Trung bình của mẫu 20	68751.65	551.99	7245.36

trong đó,

- độ lệch bằng trung bình của mẫu gồm 1000 trung bình trừ đi trung bình của mẫu 1000 quan sát;
- SE là sai số chuẩn (standard error) bằng độ lệch chuẩn của mẫu gồm 1000 trung bình.

Định lý giới hạn trung tâm

Định lý giới hạn trung tâm - Central Limit Theorem:

- cung cấp kết quả phân phối mẫu (lý thuyết) cho trung bình;
- là một trong số các kết quả quan trọng trong lý thuyết xác suất-thống kê;
- là xương sống cho các suy luận thống kê (khoảng tin cậy, kiểm định thống kê).

Central Limit Theorem

Cho mẫu ngẫu nhiên $Y_1, \dots, Y_n$ độc lập cùng phân phối, sao cho $\mathbb{E}(Y_i) = \mu$ và $\text{Var}(Y_i) = \sigma^2$ với mọi $i = 1, 2, \dots, n$. Xét trung bình mẫu $\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$. Khi n đủ lớn, ta chứng minh được:

$$\bar{Y} \xrightarrow{d} \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

Tức là trung bình mẫu $\bar{Y}$ sẽ xấp xỉ phân phối chuẩn, với trung bình μ , phương sai $\frac{\sigma^2}{n}$, khi cỡ mẫu n đủ lớn.

Định lý giới hạn trung tâm

Theo kết quả của định lý Giới Hạn Trung Tâm, ta có sai số chuẩn cho trung bình mẫu $\bar{Y}$ là

$$SE = \frac{s}{\sqrt{n}},$$

với

- s là độ lệch chuẩn mẫu;
- n là cỡ mẫu.

Khi cỡ mẫu n tăng lên b lần thì sai số chuẩn giảm xuống với tỷ lệ là $\sqrt{b}$.

Mặt khác, trong ví dụ trên:

- với cỡ mẫu 5, $SE = 14979.52$;
- với cỡ mẫu 20, $SE = 7245.36$.

↪ cỡ mẫu tăng 4 lần, thì SE giảm xấp xỉ 2 lần.

Nhắc lại, trong ví dụ trên, ta không tính SE theo công thức dựa trên định lý Giới Hạn Trung Tâm.

Định lý giới hạn trung tâm

Sai số chuẩn SE ở ví dụ trên được tính theo cách thức sau:

1. thu thập một loạt M bộ dữ liệu khác nhau, cùng cỡ mẫu n ;
2. với mỗi mẫu, tính giá trị của thống kê (chẳng hạn, trung bình);
3. tính độ lệch chuẩn của tất cả các giá trị thống kê được tính trong bước 2, và sử dụng kết quả thu được như là ước lượng của sai số chuẩn.

Trong thực tế, việc áp dụng phương thức này không thực tế, do phải lấy nhiều mẫu.

Phân phối mẫu của ước lượng

Cho $X_1, \dots, X_n$ là mẫu ngẫu nhiên, độc lập cùng phân phối $F_X(x)$.

Đặt $\hat{\theta} = T(X_1, \dots, X_n)$ là ước lượng của tham số θ , với $T(\cdot)$ là một hàm thực.

Do $X_1, \dots, X_n$ là ngẫu nhiên, nên $\hat{\theta}$ cũng là ngẫu nhiên.

$\Rightarrow$ Phân phối của $\hat{\theta}$ bị ảnh hưởng bởi phân phối $F_X(\cdot)$ của dữ liệu.

$\Rightarrow$ Ta có thể biểu diễn $\hat{\theta} = T(F)$.

Bài toán

Trong thống kê suy luận, ta quan tâm tới việc xác định **phân phối lý thuyết** của $\hat{\theta}$ từ mẫu ngẫu nhiên $X_1, \dots, X_n \stackrel{\text{i.i.d}}{\sim} F_X(x)$.

Phân phối này được ký hiệu là $F_{\hat{\theta}}(u)$, và có thể ở dạng:

- phân phối chính xác;
- phân phối tiệm cận (asymptotic distribution).

Phân phối mẫu của ước lượng

Phân phối mẫu chính xác

Phân phối mẫu chính xác $F_{\hat{\theta}}(u)$ được xác định dạng tường minh (các phân phối thông dụng) thông qua việc giả định dạng cụ thể cho phân phối $F_X(x)$ của mẫu ngẫu nhiên.

Ví dụ: Giả sử $X_1, \dots, X_n \stackrel{\text{i.i.d}}{\sim} \mathcal{N}(\mu, \sigma^2)$. Xét $\hat{\theta} \equiv \bar{X}$ tức là trung bình mẫu. Khi đó, ta chứng minh được

$$\hat{\theta} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right),$$

nếu σ^2 đã biết, ngược lại

$$\frac{\hat{\theta} - \mu}{S/\sqrt{n}} \sim t_{n-1},$$

phân phối t -student bậc tự do $n - 1$, với S là độ lệch chuẩn mẫu

$$S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}.$$

Phân phối mẫu của ước lượng

Phân phối mẫu tiệm cận

Phân phối mẫu tiệm cận $F_{\hat{\theta}}(u)$ được xác định dạng tường minh (các phân phối thông dụng) thông qua quá trình chứng minh hội tụ phân phối (convergence in distribution) của $\hat{\theta}$ khi cỡ mẫu $n \rightarrow +\infty$, mà **không** cần giả định dạng cụ thể cho phân phối $F_X(x)$ của mẫu ngẫu nhiên.

Ví dụ: Giả sử $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F_X(x)$, với trung bình μ và phương sai σ^2 . Xét $\hat{\theta} = \bar{X}$ tức là trung bình mẫu. Khi đó, ta chứng minh được

$$\hat{\theta} \xrightarrow{d} \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right),$$

khi $n \rightarrow +\infty$, trong đó ký hiệu " $\xrightarrow{d}$ " có nghĩa là hội tụ phân phối (convergence in distribution).

Phân phối mẫu của ước lượng

Vấn đề thực tế

Khi làm việc với dữ liệu $X_1, \dots, X_n$ ta thường đối mặt với

- phân phối $F_X(x)$ là không biết;
- cỡ mẫu n là không đủ lớn;
- ước lượng $\hat{\theta}$ phức tạp để có thể tìm được phân phối sai số chuẩn.

Điều này dẫn tới

- phân phối mẫu chính xác không thể xác định;
- xấp xỉ phân phối tiệm cận không đủ tốt;
- không tính chính xác được sai số chuẩn.

⇒ ta cần xây dựng được quy trình **ước lượng** được phân phối mẫu của ước lượng từ 1 bộ dữ liệu.

1 Nhắc lại phân phối mẫu

2 Xấp xỉ phân phối của ước lượng

3 Khoảng tin cậy bootstrap

4 A/B testing

Ý tưởng từ phân phối thực nghiệm

Nhắc lại: Với một mẫu ngẫu nhiên, $Y_1, \dots, Y_n$ của Y tuân theo phân phối $F(y)$. Hàm phân phối thực nghiệm (the empirical cumulative distribution function - ecdf) của Y được xác định bởi

$$\hat{F}_n(y) = \frac{1}{n} \sum_{i=1}^n \mathbf{I}(Y_i \leq y),$$

là một ước lượng của F_Y , với $\mathbf{I}(\cdot)$ là hàm chỉ (indicator function) và được định nghĩa như sau:

$$\mathbf{I}(y \leq a) = \begin{cases} 1 & \text{nếu } y \leq a, \\ 0 & \text{nếu } y > a. \end{cases}$$

Hơn nữa, theo Định lý Glivenko-Cantelli, ta chứng minh được

$$\sup_{y \in \mathbb{R}} \left| \hat{F}_n(y) - F(y) \right| \rightarrow 0,$$

khi $n \rightarrow +\infty$, tức là $\hat{F}_n(y)$ là ước lượng vững của $F(y)$, hay nói cách khác, giá trị $\hat{F}_n(y)$ sẽ xấp xỉ bằng $F(y)$.

Ý tưởng từ phân phối thực nghiệm

Xét ước lượng $\hat{\theta}$ là hàm của mẫu ngẫu nhiên.

Giả sử rằng, ta có 1 bộ mẫu ngẫu nhiên gồm m quan sát: $\hat{\theta}_1, \dots, \hat{\theta}_m$. Khi đó hàm phân phối thực nghiệm của $\hat{\theta}$ được xác định là:

$$\hat{F}_{m,\hat{\theta}}(u) = \frac{1}{m} \sum_{i=1}^m \mathbf{I}(\hat{\theta}_i \leq u).$$

$\Rightarrow$ ta cần có m mẫu gồm n quan sát $Y_1, \dots, Y_n$ (được lấy ngẫu nhiên từ quần thể) để xác định

- $\hat{\theta}_i$;
- qua đó xác định $\hat{F}_{m,\hat{\theta}}(u)$,

thêm vào đó, ta còn chứng minh được rằng sai số chuẩn của $\hat{\theta}$ là

$$\text{SE}(\hat{\theta}) = \sqrt{\frac{1}{m-1} \sum_{i=1}^m (\hat{\theta}_i - \bar{\hat{\theta}})^2},$$

trong đó, $\bar{\hat{\theta}}$ là trung bình của m ước lượng.

Phương pháp resampling

Trong thực tế, ta không thể thực hiện lấy dữ liệu m lần, mà chỉ có 1 lần duy nhất. $\Rightarrow$ cách làm trên không khả thi.

Tuy nhiên, nếu dữ liệu thu được là đủ tốt để đại diện cho quần thể

$\Rightarrow$ ta có thể dùng mẫu đó như quần thể

$\Rightarrow$ tạo mẫu ngẫu nhiên từ dữ liệu này.



Khi ta tạo đi tạo lại mẫu ngẫu nhiên từ 1 dữ liệu gốc $\Rightarrow$ ta đang thực hiện phương pháp resampling.

Ta có hai cách lấy mẫu chính:

- lấy mẫu không hoàn lại (sampling without replacement);
- lấy mẫu có hoàn lại (sampling with replacement).

Phương pháp resampling


Sampling with Replacement



Phương pháp bootstrap

Phương pháp bootstrap

Phương pháp bootstrap hoạt động trên nguyên lý lấy lại mẫu có hoàn lại dựa trên dữ liệu gốc (original data).



Phương pháp bootstrap

Cụ thể, thuật toán của phương pháp bootstrap với một mẫu cỡ n như sau:

1. Tạo một mẫu ngẫu nhiên cỡ n từ dữ liệu gốc, có hoàn lại (with replacement);
2. Tính giá trị của ước lượng $\hat{\theta}^*$ với mẫu vừa tạo;
3. Lặp lại bước 1 và 2 trong R lần (ít nhất 500 lần), và lưu kết quả lại:
 $\hat{\theta}_1^*, \dots, \hat{\theta}_R^*$.

Từ R giá trị ước lượng bootstrap này, ta xác định được

- phân phối bootstrap cho $\hat{\theta}$ (coi như là phân phối mẫu thực nghiệm xấp xỉ)

$$\hat{F}_{R, \hat{\theta}}(u) = \frac{1}{R} \sum_{b=1}^R \mathbf{I}(\hat{\theta}_b^* \leq u).$$

- độ lệch chuẩn của các ước lượng bootstrap $\Leftrightarrow$ sai số chuẩn của $\hat{\theta}$

$$\text{SE}(\hat{\theta}) = \sqrt{\frac{1}{R-1} \sum_{b=1}^R \left(\hat{\theta}_b^* - \bar{\theta}^* \right)^2}.$$

Phương pháp bootstrap

Nhận xét:

- Việc tạo mẫu ngẫu nhiên tại bước 1 được coi là “mô phỏng dữ liệu” dựa trên thông tin của dữ liệu gốc.
- Việc mô phỏng được thực hiện dựa vào phân phối của dữ liệu.

⇒ ta cần $\hat{F}_Y(y)$.

Có hai phương pháp xác định $\hat{F}_Y(y)$:

- Phương pháp tham số (parametric estimation): giả định một dạng tham số cụ thể cho $F_Y(y; \beta) \Rightarrow$ xác định $\hat{\beta} \Rightarrow$ xác định $\hat{F}_Y(y) \equiv F_Y(y; \hat{\beta})$
⇒ parametric bootstrap.
- Phương pháp phi tham số (non-parametric estimation): sử dụng trực tiếp phân phối tích lũy thực nghiệm $\hat{F}_n(y)$
⇒ non-parametric bootstrap.

Phương pháp non-parametric bootstrap được sử dụng phổ biến do tính đơn giản và sát với dữ liệu.

Tạo dữ liệu từ hàm phân phối

Cho Y là một biến ngẫu nhiên tuân theo phân phối $F_Y(y)$. Khi đó, ta có

$$F_Y(y) = \Pr(Y \leq y) = p,$$

với $p \in (0, 1)$.

- Nếu $F_Y(y)$ là hàm liên tục thì, với p cho trước, ta xác định được một y sao cho

$$y = F_Y^{-1}(p),$$

trong đó $F_Y^{-1}(\cdot)$ là hàm ngược của $F_Y(\cdot)$.

- Nếu $F_Y(y)$ là hàm không liên tục thì, với p cho trước, ta xác định được một y sao cho

$$y = F_Y^{-1}(p) \equiv \inf \{y \in \mathbb{R} : p \leq F(y), p \in (0, 1)\}.$$

$\Rightarrow$ phát sinh ngẫu nhiên p trong $(0, 1) \Rightarrow$ xác định được y ngẫu nhiên.

Trong lập trình, ta có thể sử dụng thuật toán **Mersenne twister** để phát sinh ngẫu nhiên p .

Chú ý: hàm $F_Y^{-1}(p)$ còn gọi là hàm phân vị (quantile function).

Non-parametric bootstrap

Với dữ liệu $Y_1, \dots, Y_n$ của Y tuân theo phân phối $F_Y(y)$. Hàm phân phối thực nghiệm của Y được xác định bởi

$$\hat{F}_n(y) = \frac{1}{n} \sum_{i=1}^n \mathbf{I}(Y_i \leq y),$$

là một ước lượng của $F_Y(y)$.

Gọi $Y_1^*, Y_2^*, \dots, Y_n^*$ là bộ dữ liệu được tạo mô phỏng từ $\hat{F}_n(y)$.

Theo công thức, $\hat{F}_n(y)$ sẽ luôn nhận giá trị trong tập $\left\{0, \frac{1}{n}, \frac{2}{n}, \dots, \frac{n}{n}\right\}$.

Xét các điểm dữ liệu được sắp xếp thứ tự

$$Y_{(1)} \leq Y_{(2)} \leq \dots \leq Y_{(n)}$$

Tại điểm thứ i , luôn có i dữ liệu $\leq Y_{(i)}$, nên,

$$\hat{F}_n(Y_{(i)}) = \frac{i}{n}.$$

Non-parametric bootstrap

Khi đó ta có

$$Y_{(i)} = \hat{F}_n^{-1} \left(\frac{i}{n} \right),$$

với $\hat{F}_n^{-1}(p)$ được xác định bởi:

$$\hat{F}_n^{-1}(p) = \inf \left\{ y \in \mathbb{R} : p \leq \hat{F}_n(y), p \in (0, 1) \right\}.$$

Áp dụng phương pháp tạo mẫu ngẫu nhiên từ hàm phân phối, ta phát sinh y ngẫu nhiên thông qua

$$y = \hat{F}_n^{-1}(p),$$

với p được chọn ngẫu nhiên từ tập $\left\{ 0, \frac{1}{n}, \frac{2}{n}, \dots, \frac{n}{n} \right\}$.

$\Rightarrow$ giá trị y được phát sinh sẽ luôn là một điểm trong bộ dữ liệu.

Do đó, tạo mẫu ngẫu nhiên từ $\hat{F}_n(y)$ tương đương với việc lấy mẫu ngẫu nhiên có hoàn lại từ dữ liệu quan sát $Y_1, Y_2, \dots, Y_n$.

Non-parametric bootstrap

Ví dụ: ta có một bộ dữ liệu gồm thu nhập hàng năm tương ứng 10 người.

Ta quan tâm $\hat{\theta} \equiv \bar{Y}$ - trung bình thu nhập.

Quá trình bootstrap $R = 1000$ lần, được minh họa như sau.

data
86000
40000
55000
35000
53000
140000
128000
105000
66500
100000



$$\bar{y} = 80850$$

lần 1
66500
86000
55000
55000
100000
86000
66500
128000
66500
53000



$$\bar{y}_1 = 76250$$

lần 2
53000
105000
128000
100000
100000
55000
140000
40000
100000
100000



$$\bar{y}_2 = 92100$$


...

lần R
100000
66500
140000
55000
86000
35000
140000
105000
140000
86000



$$\bar{y}_R = 95350$$

Non-parametric bootstrap



Non-parametric bootstrap

- độ chệch bootstrap:

$$\text{bias}(\hat{\theta}^*) = \hat{\theta} - \bar{\hat{\theta}}^* = -421.35$$

- sai số chuẩn cho $\hat{\theta}$:

$$\text{SE}(\hat{\theta}) = \sqrt{\frac{1}{1000 - 1} \sum_{b=1}^{1000} \left(\hat{\theta}_b^* - \bar{\hat{\theta}}^* \right)^2} = 11000.69.$$

Mở rộng cho dữ liệu nhiều chiều


Dữ liệu nhiều chiều là dữ liệu gồm nhiều cột, với mỗi cột là một biến ngẫu nhiên.

id	X_1	X_2	$\dots$	X_q
1	x_{11}	x_{21}	$\dots$	x_{q1}
2	x_{12}	x_{22}	$\dots$	x_{q2}
3	x_{13}	x_{23}	$\dots$	x_{q3}
4	x_{14}	x_{24}	$\dots$	x_{q4}
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
n	x_{1n}	x_{2n}	$\dots$	x_{qn}

Khi này, mỗi một dòng tương ứng là một vector giá trị quan sát được của một vector ngẫu nhiên $(X_1, X_2, \dots, X_q)$.

Mở rộng cho dữ liệu nhiều chiều

Khi áp dụng Phương pháp bootstrap cho dữ liệu nhiều chiều (multivariate data), ta sẽ tạo dữ liệu bootstrap bằng cách lấy ngẫu nhiên 1 dòng của dữ liệu từ n dòng ban đầu.



Bootstrapping dependent data - Đọc thêm

Phương pháp bootstrap được thiết kế cho dữ liệu $X_1, \dots, X_n$ độc lập cùng phân phối.

Nếu dữ liệu phụ thuộc nhau, tức là $\text{Cov}(X_i, X_j) \neq 0 \Rightarrow$ phương pháp bootstrap cơ bản không còn dữ được cấu trúc của dữ liệu:

- dữ liệu chuỗi thời gian (time series data);
- dữ liệu phân lớp (stratified data);
- dữ liệu phân cụm (clustered data).

$\Rightarrow$ cần thay đổi cách lấy mẫu bootstrap.

- Xem trong *Chương 9.5, trang 303 - 315* về các phương pháp lấy mẫu bootstrap cho dữ liệu chuỗi thời gian (model-based approach, block bootstrap: non-moving block bootstrap, moving block bootstrap, blocks-of-blocks bootstrapping, centering and studentizing).
- Tìm hiểu các tài liệu mở về stratified bootstrap với phương pháp lấy mẫu phân tầng (stratified sampling).
- Tìm hiểu các tài liệu mở về clustered bootstrap với phương pháp lấy mẫu theo cụm (clustered sampling).

1 Nhắc lại phân phối mẫu

2 Xấp xỉ phân phối của ước lượng


3 Khoảng tin cậy bootstrap

4 A/B testing

Khoảng tin cậy

Ta xét ví dụ như sau:

- dữ liệu lớn gồm 1000 ghi chép thu nhập hàng năm của 1000 người;
- ước lượng trung bình thu nhập trong 1000 mẫu có cỡ 5, được lấy ngẫu nhiên từ dữ liệu lớn (các điểm đen trên hình);
- trung bình thu nhập trong dữ liệu lớn (đường nét đứt màu xanh).



Khoảng tin cậy

Khoảng tin cậy

Khoảng tin cậy (confidence interval) là kết quả của một quá trình ước lượng khoảng (interval estimation), và cung cấp một khoảng hợp lý mà giá trị “thật sự” của thống kê có thể thuộc vào.

Ví dụ: Khoảng tin cậy 95% cho trung bình thu nhập (của quần thể) là (65000, 82300), ta có thể nói rằng:

“Ta tin cậy 95% rằng trung bình thu nhập tổng thể μ nằm trong khoảng từ 65000 đến 82300”.

Hơn nữa, ta có thể chọn một số bất kỳ trong khoảng tin cậy làm đại diện cho trung bình quần thể μ .

Đối với một nhà khoa học dữ liệu, khoảng tin cậy là một công cụ:

- để biết được kết quả mẫu có thể thay đổi như thế nào;
- để thông báo lỗi tiềm ẩn trong ước tính;
- để tìm hiểu xem liệu có cần một mẫu lớn hơn không.

Xây dựng khoảng tin cậy cho θ

Giả sử ta có

- $Y_1, Y_2, \dots, Y_n \stackrel{\text{i.i.d.}}{\sim} F_Y(y)$, của biến Y ;
- $\hat{\theta}$ là ước lượng của θ .

Để xây dựng khoảng tin cậy cho tham số θ , ta cần thông tin về phân phối mẫu của $\hat{\theta}$, $F_{\hat{\theta}}(u)$.

Khoảng tin cậy chính xác (exact confidence interval)

Nếu $F_{\hat{\theta}}(u)$ được xác định chính xác, thì khoảng $(L(Y_1, \dots, Y_n), U(Y_1, \dots, Y_n))$ được gọi khoảng tin cậy **chính xác** $100 \times (1 - \alpha)\%$ cho θ nếu với mọi $\theta \in \Theta$

$$\Pr(L(Y_1, \dots, Y_n) \leq \theta \leq U(Y_1, \dots, Y_n)) = 1 - \alpha,$$

hay tương đương với

$$F_{\hat{\theta}}(U(Y_1, \dots, Y_n)) - F_{\hat{\theta}}(L(Y_1, \dots, Y_n)) = 1 - \alpha,$$

với mọi $\alpha \in (0, 1)$.

Xây dựng khoảng tin cậy cho θ

Khoảng tin cậy tiệm cận (asymptotic confidence interval)

Nếu $F_{\hat{\theta}}(u)$ được xác định là phân phối mẫu tiệm cận, thì một khoảng ngẫu nhiên $(L(Y_1, \dots, Y_n), U(Y_1, \dots, Y_n))$ được gọi khoảng tin cậy **tiệm cận** $100 \times (1 - \alpha)\%$ cho θ nếu với mọi $\theta \in \Theta$:

$$\Pr(L(Y_1, \dots, Y_n) \leq \theta \leq U(Y_1, \dots, Y_n)) \rightarrow 1 - \alpha,$$

hay tương đương với

$$F_{\hat{\theta}}(U(Y_1, \dots, Y_n)) - F_{\hat{\theta}}(L(Y_1, \dots, Y_n)) \rightarrow 1 - \alpha,$$

với mọi $\alpha \in (0, 1)$, khi $n \rightarrow +\infty$.

Một cách vắn tắt, ta gọi chúng là khoảng tin cậy $100 \times (1 - \alpha)\%$ cho θ .

Tuy nhiên, trong thực tế

- phân phối mẫu chính xác không thể xác định;
- xấp xỉ phân phối tiệm cận không đủ tốt.

$\Rightarrow$ ta sử dụng phân phối mẫu bootstrap, $\hat{F}_{R,\hat{\theta}}(u)$ thay thế.

$\Rightarrow$ khoảng tin cậy bootstrap.

Khoảng tin cậy bootstrap percentile

Nhắc lại rằng, sau quá trình bootstrap, ta có 1 bộ dữ liệu ước lượng bootstrap: $(\hat{\theta}_1^*, \dots, \hat{\theta}_R^*)$ cho $\hat{\theta}$.

Đặt θ_q^* là phân vị mẫu thứ q của $(\hat{\theta}_1^*, \dots, \hat{\theta}_R^*)$.

Khi đó, theo định nghĩa của phân vị mẫu, ta có

$$\Pr(\theta_{\alpha/2}^* \leq \hat{\theta}^* \leq \theta_{1-\alpha/2}^*) \approx 1 - \alpha.$$

Tuy nhiên, ta mục tiêu là tìm khoảng tin cậy dạng:

$$\Pr(\theta_{\alpha/2}^* \leq \theta \leq \theta_{1-\alpha/2}^*) \approx 1 - \alpha.$$

⇒ cần xây dựng một liên kết tới khoảng phân vị.

Khoảng tin cậy bootstrap percentile

Giả sử rằng ta có một biến đổi đơn điệu tăng $m(\theta)$ của θ .

Đặt $U = \frac{m(\hat{\theta}) - m(\theta)}{\tau}$ sao cho $U \sim \mathcal{N}(0, 1)$, với $\tau > 0$.

Chú ý: ta không giả định rằng ta có dạng tường minh của biến đổi m , ta chỉ cần nó tồn tại.

Khi đó, phân vị mức q của U được xác định bởi $U_q = z_q$, trong đó, z_q là phân vị mức q của phân phối $\mathcal{N}(0, 1)$.

Theo tính chất của phân phối chuẩn, ta có

$$\begin{aligned} 1 - \alpha &= \Pr(U_{\alpha/2} \leq U \leq U_{1-\alpha/2}) \\ &= \Pr\left(z_{\alpha/2} \leq \frac{m(\hat{\theta}) - m(\theta)}{\tau} \leq z_{1-\alpha/2}\right) \\ &= \Pr\left(m(\hat{\theta}) + \tau z_{\alpha/2} \leq m(\theta) \leq m(\hat{\theta}) + \tau z_{1-\alpha/2}\right) \end{aligned}$$

Khoảng tin cậy bootstrap percentile

Theo tính đơn điệu của $m(\cdot)$, ta có

$$1 - \alpha = \Pr \left(m^{-1} \left(m(\hat{\theta}) + \tau z_{\alpha/2} \right) \leq \theta \leq m^{-1} \left(m(\hat{\theta}) + \tau z_{1-\alpha/2} \right) \right)$$

Ta áp dụng biến đổi này cho ước lượng bootstrap: $U_b^* = \frac{m(\hat{\theta}_b^*) - m(\hat{\theta})}{\tau}$.

Với mẫu $(\hat{\theta}_1^*, \dots, \hat{\theta}_R^*)$ ta luôn xác định được phân vị mẫu mức q là θ_q^*

$$\Rightarrow U_q^* = \frac{m(\theta_q^*) - m(\hat{\theta})}{\tau}.$$

Mặt khác, $U_q^* \approx U_q = z_q$. Do đó, ta có

$$m(\theta_q^*) \approx m(\hat{\theta}) + \tau z_q.$$

Khoảng tin cậy bootstrap percentile

Khi này, ta chứng minh được:

$$\begin{aligned}
1 - \alpha &= \Pr \left(m^{-1} \left(m(\hat{\theta}) + \tau z_{\alpha/2} \right) \leq \theta \leq m^{-1} \left(m(\hat{\theta}) + \tau z_{1-\alpha/2} \right) \right) \\
&\approx \Pr \left(m^{-1} \left(m(\theta_{\alpha/2}^*) \right) \leq \theta \leq m^{-1} \left(m(\theta_{1-\alpha/2}^*) \right) \right) \\
&= \Pr \left(\theta_{\alpha/2}^* \leq \theta \leq \theta_{1-\alpha/2}^* \right)
\end{aligned}$$

Từ đây, ta có được khoảng tin cậy $100 \times (1 - \alpha)\%$ cho θ là $(\theta_{\alpha/2}^*, \theta_{1-\alpha/2}^*)$.

Vì θ_p^* là phân vị mẫu thứ p của $(\hat{\theta}_1^*, \dots, \hat{\theta}_R^*)$, nên ta xác định được

- $\theta_{\alpha/2}^* = \hat{\theta}_{\lfloor R \alpha/2 \rfloor}^*$;
- $\theta_{1-\alpha/2}^* = \hat{\theta}_{\lfloor R (1-\alpha/2) \rfloor}^*$.

Như vậy, khoảng tin cậy bootstrap percentile $100 \times (1 - \alpha)\%$ cho θ là

$$(\hat{\theta}_{\lfloor R \alpha/2 \rfloor}^*, \hat{\theta}_{\lfloor R (1-\alpha/2) \rfloor}^*).$$

Khoảng tin cậy bootstrap BC_a

Phương pháp **Accelerated Bias-Corrected Percentile** - BC_a được thiết kế để hiệu chỉnh những thiếu sót của phương pháp khoảng tin cậy bootstrap percentile.

Giả sử rằng ta có một biến đổi đơn điệu tăng $m(\cdot)$. Đặt

$$U = \frac{m(\hat{\theta}) - m(\theta)}{1 + a m(\theta)} + b,$$

với a và b là các hằng số và $1 + a m(\theta) > 0$. Giả sử rằng $U \sim \mathcal{N}(0, 1)$.

Khi $a = b = 0$ (không có sai lệch trong phân phối bootstrap) thì U quay trở lại trường hợp trước đó với $\tau = 1$.

Áp dụng cho mẫu bootstrap, ta có

$$U^* = \frac{m(\hat{\theta}^*) - m(\hat{\theta})}{1 + a m(\hat{\theta})} + b,$$

và $U^* \xrightarrow{d} \mathcal{N}(0, 1)$.

Khoảng tin cậy bootstrap BCa

Do $U^* \xrightarrow{d} \mathcal{N}(0, 1)$, nên ta có

$$\begin{aligned} 1 - \alpha &\approx \Pr(z_{\alpha/2} \leq U^* \leq z_{1-\alpha/2}) \\ &= \Pr\left(z_{\alpha/2} \leq \frac{m(\hat{\theta}^*) - m(\hat{\theta})}{1 + a m(\hat{\theta})} + b \leq z_{1-\alpha/2}\right) \\ &= \Pr\left(m(\hat{\theta}) + [z_{\alpha/2} - b] [1 + a m(\hat{\theta})] \leq m(\hat{\theta}^*)\right. \\ &\quad \left. \leq m(\hat{\theta}) + [z_{1-\alpha/2} - b] [1 + a m(\hat{\theta})]\right) \\ &= \Pr\left(m^{-1}\left(m(\hat{\theta}) + [z_{\alpha/2} - b] [1 + a m(\hat{\theta})]\right) \leq \hat{\theta}^*\right. \\ &\quad \left. \leq m^{-1}\left(m(\hat{\theta}) + [z_{1-\alpha/2} - b] [1 + a m(\hat{\theta})]\right)\right) \end{aligned}$$

Hơn nữa, với bộ dữ liệu ước lượng bootstrap, ta luôn có

$$\Pr\left(\theta_{\alpha/2}^* \leq \hat{\theta}^* \leq \theta_{1-\alpha/2}^*\right) \approx 1 - \alpha.$$

Khoảng tin cậy bootstrap BCa

Do đó,

$$m^{-1} \left(m(\hat{\theta}) + [z_{\alpha/2} - b] \left[1 + a m(\hat{\theta}) \right] \right) \approx \theta_{\alpha/2}^*,$$

và

$$m^{-1} \left(m(\hat{\theta}) + [z_{1-\alpha/2} - b] \left[1 + a m(\hat{\theta}) \right] \right) \approx \theta_{1-\alpha/2}^*.$$

Kết quả này rất quan trọng vì ta không cần phải xác định $m(\cdot)$, thay vào đó, ta hoàn toàn có thể tính thông qua phân vị mẫu bootstrap.

Khoảng tin cậy bootstrap BCa

Mặt khác, do $U \sim \mathcal{N}(0, 1)$ nên ta cũng có

$$\begin{aligned}1 - \alpha &= \Pr(z_{\alpha/2} \leq U \leq z_{1-\alpha/2}) \\&= \Pr\left(z_{\alpha/2} \leq \frac{m(\hat{\theta}) - m(\theta)}{1 + a m(\theta)} + b \leq z_{1-\alpha/2}\right) \\&= \Pr\left(m(\hat{\theta}) + u(a, b; \alpha/2) \left[1 + a m(\hat{\theta})\right] \leq m(\theta)\right. \\&\quad \left.\leq m(\hat{\theta}) + u(a, b; 1 - \alpha/2) \left[1 + a m(\hat{\theta})\right]\right) \\&= \Pr\left(m^{-1}\left(m(\hat{\theta}) + u(a, b; \alpha/2) \left[1 + a m(\hat{\theta})\right]\right) \leq \theta\right. \\&\quad \left.\leq m^{-1}\left(m(\hat{\theta}) + u(a, b; 1 - \alpha/2) \left[1 + a m(\hat{\theta})\right]\right)\right)\end{aligned}$$

$$\text{với } u(a, b; \alpha) = \frac{b + z_{\alpha}}{1 - a(b + z_{\alpha})}.$$

Khoảng tin cậy bootstrap BCa

Nếu ta có thể tìm được β_1 và β_2 sao cho

$$u(a, b; \alpha/2) = z_{\beta_1} - b, \quad \text{và} \quad u(a, b; 1 - \alpha/2) = z_{\beta_2} - b,$$

thì ta có

$$\begin{aligned} 1 - \alpha &= \Pr \left(m^{-1} \left(m(\hat{\theta}) + (z_{\beta_1} - b) \left[1 + a m(\hat{\theta}) \right] \right) \leq \theta \right. \\ &\quad \left. \leq m^{-1} \left(m(\hat{\theta}) + (z_{\beta_2} - b) \left[1 + a m(\hat{\theta}) \right] \right) \right) \\ &\approx \Pr \left(\theta_{\beta_1}^* \leq \theta \leq \theta_{\beta_2}^* \right). \end{aligned}$$

Như vậy ta có thể sử dụng bộ dữ liệu ước lượng bootstrap để xác định khoảng tin cậy cho θ .

Khoảng tin cậy bootstrap BC_a

Mức phân vị β_1 và β_2 được xác định bởi

$$\beta_1 = \Phi \left(b + \frac{b + z_{\alpha/2}}{1 - a(b + z_{\alpha/2})} \right) \quad \text{và} \quad \beta_2 = \Phi \left(b + \frac{b + z_{1-\alpha/2}}{1 - a(b + z_{1-\alpha/2})} \right),$$

$\Phi(u)$ là hàm phân phối tích lũy của phân phối $\mathcal{N}(0, 1)$, với

$$b = \Phi^{-1} \left(\frac{1}{R} \sum_{b=1}^R \mathbf{I} \left(\hat{\theta}_b^* \leq \hat{\theta} \right) \right)$$

và

$$a = \left[\frac{1}{6} \sum_{i=1}^n \left(\hat{\theta}_{(\cdot)} - \hat{\theta}_{(-i)} \right)^3 \right] \left[\sum_{i=1}^n \left(\hat{\theta}_{(\cdot)} - \hat{\theta}_{(-i)} \right)^2 \right]^{-3/2}$$

trong đó, $\hat{\theta}_{(-i)}$ là ước lượng $\hat{\theta}$ trên tập dữ liệu bỏ đi i , và $\hat{\theta}_{(\cdot)} = \frac{1}{n} \sum_{i=1}^n \hat{\theta}_{(-i)}$.

Như vậy, khoảng tin cậy bootstrap BC_a $100 \times (1 - \alpha)\%$ cho θ là

$$\left(\hat{\theta}_{[R\beta_1]}^*, \hat{\theta}_{[R\beta_2]}^* \right).$$

Khoảng tin cậy bootstrap studentized

Khoảng tin cậy bootstrap studentized dựa trên ý tưởng về thống kê studentized

$$Z = \frac{\bar{Y} - \mu}{(S^2/n)^{1/2}} \sim t_{n-1},$$

với $Y_1, \dots, Y_n \stackrel{i.i.d}{\sim} \mathcal{N}(\mu, \sigma^2)$.

Trong thực tế

- ta không có phân phối chuẩn;
- quan tâm tới một ước lượng bất kỳ $\hat{\theta}$.

Tuy nhiên, ta vẫn có thể sử dụng ý tưởng về thống kê studentized để xây dựng khoảng tin cậy.

Một cách tổng quát hóa, ta có thể viết

$$Z = \frac{\hat{\theta} - \theta}{\sqrt{V(\hat{\theta})}},$$

với $V(\hat{\theta})$ là phương sai của $\hat{\theta}$ được tính từ dữ liệu.

Khoảng tin cậy bootstrap studentized

Đặt $z_{\alpha/2}$ là phân vị của Z (giả sử đã biết), khi đó, theo quy tắc phân vị

$$\Pr(z_{\alpha/2} \leq Z \leq z_{1-\alpha/2}) = \Pr\left(z_{\alpha/2} \leq \frac{\hat{\theta} - \theta}{\sqrt{V(\hat{\theta})}} \leq z_{1-\alpha/2}\right) = 1 - \alpha$$

hay tương đương

$$\Pr\left(\hat{\theta} - \sqrt{V(\hat{\theta})}z_{1-\alpha/2} \leq \theta \leq \hat{\theta} - \sqrt{V(\hat{\theta})}z_{\alpha/2}\right) = 1 - \alpha$$

Như vậy, ta xác định được khoảng tin cậy $100 \times (1 - \alpha)\%$ cho θ là

$$\left(\hat{\theta} - \sqrt{V(\hat{\theta})}z_{1-\alpha/2}, \hat{\theta} - \sqrt{V(\hat{\theta})}z_{\alpha/2}\right).$$

Khoảng tin cậy bootstrap studentized

Do Z là không biết (hoặc chỉ biết 1 giá trị duy nhất), do đó, ta cần sử dụng bootstrap để tạo ra một bộ R ước lượng $Z^* \Rightarrow$ ước tính phân vị mẫu.

Sau quá trình bootstrap, ta có

- $(\hat{\theta}_1^*, \dots, \hat{\theta}_R^*);$
- $(V(\hat{\theta}_1^*), \dots, V(\hat{\theta}_R^*)).$

Từ dữ liệu bootstrap này, ta tính được

$$Z_b^* = \frac{\hat{\theta}_b^* - \hat{\theta}}{\sqrt{V(\hat{\theta}_b^*)}}$$

Với bộ $(Z_1^*, \dots, Z_R^*)$, ta xác định được

- $z_{\alpha/2} = Z_{\lfloor R\alpha/2 \rfloor}^*;$
- $z_{1-\alpha/2} = Z_{\lfloor R(1-\alpha/2) \rfloor}^*.$

Do đó, ta xác định được khoảng tin cậy studentized $100 \times (1 - \alpha)\%$ cho θ là

$$\left(\hat{\theta} - \sqrt{V(\hat{\theta})} Z_{\lfloor R(1-\alpha/2) \rfloor}^*, \hat{\theta} + \sqrt{V(\hat{\theta})} Z_{\lfloor R\alpha/2 \rfloor}^* \right).$$

Khoảng tin cậy bootstrap studentized

Để ước lượng được $V(\hat{\theta}_b^*)$ ta có hai lựa chọn như sau:

- sử dụng công thức tường minh của $V(\hat{\theta})$ cho mẫu bootstrap;

ví dụ: xét $\hat{\theta} = \bar{Y}$, khi đó, ta có $V(\hat{\theta}) = \frac{S^2}{n}$, với S^2 là phương sai mẫu;

áp dụng công thức này vào mẫu bootstrap $Y_{i,b}^*, \dots, Y_{i,b}^*$

$$V(\hat{\theta}_b^*) = \frac{1}{n(n-1)} \sum_{i=1}^n (Y_{i,b}^* - \bar{Y}_b^*)^2$$

- sử dụng một quy trình bootstrap thứ hai:

với mẫu bootstrap $Y_{1,b}^*, \dots, Y_{n,b}^*$

$\Rightarrow$ tạo một mẫu bootstrap $Y_{1,b,j}^{**}, \dots, Y_{n,b,j}^{**}$, với $j = 1, \dots, R'$ lần lặp

$\Rightarrow$ ước lượng $\hat{\theta}_{n,b,j}^{**}$


$$V(\hat{\theta}_b^*) = \frac{1}{R-1} \sum_{j=1}^{R'} \left(\hat{\theta}_{b,j}^{**} - \bar{\theta}_b^{**} \right)^2,$$

với $\bar{\theta}_b^{**}$ là trung bình của bộ ước lượng bootstrap $(\hat{\theta}_{b,1}^{**}, \dots, \hat{\theta}_{b,R'}^{**})$.

Ví dụ: Khoảng tin cậy cho hệ số tương quan

Ví dụ: hệ số tương quan tuyến tính Pearson:

$$\hat{r}_n = \frac{1}{n-1} \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{S_X} \right) \left(\frac{Y_i - \bar{Y}}{S_Y} \right).$$



Ví dụ: Khoảng tin cậy cho hệ số tương quan

Nhận xét:

- phân phối mẫu của $\hat{r}_n$ không xấp xỉ một phân phối chuẩn;
- khi r gần ± 1 , thì phân phối của $\hat{r}_n$ bị lệch (không đối xứng).

Quy trình bootstrap cho ước lượng hệ số tương quan

Cho bộ dữ liệu ngẫu nhiên $(X_1, Y_1), \dots, (X_n, Y_n)$ của biến hai ngẫu nhiên X và Y .

1. Tạo một mẫu ngẫu nhiên cỡ n (cùng với cỡ của dữ liệu gốc) từ dữ liệu gốc, có lặp lại (with replacement): $(X_1^*, Y_1^*), \dots, (X_n^*, Y_n^*)$.
2. Tính hệ số tương quan Pearson $\hat{r}_n^*$ dựa trên mẫu vừa tạo.
3. Lặp lại bước 1 và 2 trong R lần (ít nhất 1,000 lần), và lưu kết quả lại.

Ví dụ: Khoảng tin cậy cho hệ số tương quan


Ví dụ: ta xét dữ liệu về nghiên cứu về mối liên hệ giữa khiếm khuyết gen và tay thuận của một người:

id	dnan	hand
1	13	1
2	18	1
3	20	3
4	21	1
⋮	⋮	⋮
36	41	4
37	44	8

- tổng cộng 37 quan sát là các bà mẹ có con trai bị chậm phát triển trí tuệ do thừa hưởng nhiễm sắc thể X khiếm khuyết;
- `dnan` thể hiện chỉ số khiếm khuyết DNA;
- `hand` thể hiện chỉ số khuynh hướng sử dụng tay trái hoặc phải cho các công việc khác nhau, gần 1 tương ứng tay phải, gần 8 tương ứng tay trái.

Giả thuyết: các giá trị lớn của `dnan` có thể liên quan đến khuynh hướng sử dụng tay trái.


Ví dụ: Khoảng tin cậy cho hệ số tương quan



Hệ số tương quan tuyến tính (Pearson), $\hat{r} = 0.509$.

Ví dụ: Khoảng tin cậy cho hệ số tương quan

Phân phối bootstrap sau 5,000 lần lặp



Khoảng tin cậy bootstrap percentile 95% cho hệ số tương quan giữa khiếm khuyết gen và khuynh hướng thuận tay trái là $(-0.0012, 0.7564)$.

Ví dụ: Khoảng tin cậy cho hệ số tương quan

Khoảng tin cậy bootstrap studentized cho hệ số tương quan r được xây dựng theo quy trình sau:

1. Tạo mẫu ngẫu nhiên cỡ n (cùng với cỡ của dữ liệu gốc) từ dữ liệu gốc, có lặp lại (with replacement): $(X_{1,b}^*, Y_{1,b}^*), \dots, (X_{n,b}^*, Y_{n,b}^*)$.
2. Tính hệ số tương quan Pearson, $\widehat{r}_b^*$, dựa trên mẫu vừa tạo.
3. Tạo một mẫu bootstrap $(X_{1,b,j}^{**}, Y_{1,b,j}^{**}), \dots, (X_{n,b,j}^{**}, Y_{n,b,j}^{**})$, với $j = 1, \dots, R$ lần lặp (ít nhất 200 lần), trong mỗi lần tính $\widehat{r}_{b,j}^{**}$ và tính

$$V(\widehat{r}_b^*) = \frac{1}{R-1} \sum_{j=1}^R (\widehat{r}_{b,j}^{**} - \widehat{r}_b^*)^2,$$

$$\text{với } \widehat{r}_b^{**} = \frac{1}{R} \sum_{j=1}^R \widehat{r}_{b,j}^{**}.$$

4. Lặp lại bước 1 - 3 trong B lần (ít nhất 1000 lần), lưu kết quả $\widehat{r}_b^*$ và $V(\widehat{r}_b^*)$.
5. Tính Z_b^* và xác định $z_{\alpha/2}$ và $z_{1-\alpha/2}$.
6. Tính khoảng tin cậy studentized dựa trên các ước lượng đã thu được, với $\sqrt{V(\widehat{r})}$ chính là se_{boot} .

Ví dụ: Khoảng tin cậy cho hệ số tương quan

Áp dụng quy trình trên cho dữ liệu về kiểm khuyết gen và khuynh hướng sử dụng tay trái.

- số lần lặp bootstrap $B = 5000$ lần;
- số lần lặp bootstrap cho phương sai $V(\hat{r}_b^*)$, $R = 200$;
- $\hat{r} = 0.509$;
- $\sqrt{V(\hat{r})} = \text{se}_{\text{boot}} = 0.2007$;
- $z_{0.05/2} = -3.476$;
- $z_{1-0.05/2} = 2.152$;

suy ra, khoảng tin cậy studentized 95% cho r là

$$(0.509 - 0.2007 \times 2.152, 0.509 - 0.2007 \times (-3.476)) = (0.0771, 1.2066)$$

$$\Rightarrow \text{ta cần sử dụng biến đổi Fisher } u = \frac{1}{2} \log \left(\frac{1+r}{1-r} \right).$$

Khoảng tin cậy trong dự đoán xu hướng

Xét dữ liệu của hai biến ngẫu nhiên (X_i, Y_i) độc lập cùng phân phối $F_{X,Y}(x, y)$, với $i = 1, \dots, n$, ta muốn xác định hàm $m(\cdot)$ trong mô hình:

$$Y_i = m(x_i) + \varepsilon_i,$$

với (x_i, Y_i) là cặp dữ liệu quan sát được.


Sử dụng local polynomial regression, ta thu được ước lượng $\hat{m}(x)$ của $m(x)$ là

$$\hat{m}_{\text{LP}, h_X, p}(x) = \mathbf{e}_1^\top (\mathbf{Z}^\top \mathbf{W} \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{W} \mathbf{Y},$$

với $\mathbf{e}_1 = (1, 0, \dots, 0)$ - chứa p phần tử 0.

Trong thống kê suy luận, ta cũng quan tâm tới khoảng tin cậy cho $m(x)$.

Khoảng tin cậy trong dự đoán xu hướng



Khoảng tin cậy trong dự đoán xu hướng

Quy trình bootstrap xác định khoảng tin cậy cho $m(x)$


Cho bộ dữ liệu ngẫu nhiên $(X_1, Y_1), \dots, (X_n, Y_n)$.

1. Tạo một mẫu ngẫu nhiên cỡ n (cùng với cỡ của dữ liệu gốc) từ dữ liệu gốc, có lặp lại (with replacement): $(X_1^*, Y_1^*), \dots, (X_n^*, Y_n^*)$.
2. Tính hệ số tương quan Pearson $\hat{m}_{\text{LP}, h_X, p}^*(x)$ dựa trên mẫu vừa tạo.
3. Lặp lại bước 1 và 2 trong R lần (ít nhất 1,000 lần), và lưu kết quả lại.
4. Áp dụng khoảng tin cậy bootstrap percentile


$$\left(\hat{m}_{\text{LP}, h_X, p, \lfloor R \alpha / 2 \rfloor}^*(x), \hat{m}_{\text{LP}, h_X, p, \lfloor R (1 - \alpha / 2) \rfloor}^*(x) \right).$$

Khi ta lặp lại quy trình này cho toàn bộ giá trị của x , ta thu được kết quả là một **confidence band** (hay dải tin cậy) cho $m(x)$.

Khoảng tin cậy trong dự đoán xu hướng



Khoảng tin cậy trong dự đoán xu hướng



1 Nhắc lại phân phối mẫu

2 Xấp xỉ phân phối của ước lượng

3 Khoảng tin cậy bootstrap

4 A/B testing

Khái niệm cơ bản

Kiểm định giả thuyết là một bài toán cơ bản trong thống kê lý thuyết cũng như thống kê ứng dụng.

Thông thường, kiểm định giả thuyết hướng tới trả lời một giả thuyết cho 1 đặc trưng của dữ liệu:

- Trung bình đối với biến định lượng;
- Tỷ lệ đối với biến định tính;
- Sự tương quan giữa hai biến.


Khái niệm cơ bản

Kiểm định giả thuyết là một bài toán cơ bản trong thống kê lý thuyết cũng như thống kê ứng dụng.

Thông thường, kiểm định giả thuyết hướng tới trả lời một giả thuyết cho 1 đặc trưng của dữ liệu:

- Trung bình đối với biến định lượng;
- Tỷ lệ đối với biến định tính;
- Sự tương quan giữa hai biến.

Quy trình kiểm định giả thuyết thống kê:



A/B testing

Một kiểm định A/B (A/B testing) là một thí nghiệm với hai nhóm nhằm xác định xem nhóm nào trong: hai phương pháp điều trị, hay hai sản phẩm, hay hai quy trình là tốt hơn cái còn lại.

Thông thường, hai nhóm gồm:

nhóm đối chứng - control group là nhóm gồm các đối tượng được tiếp xúc với điều kiện thông thường (không được áp dụng các biện pháp mới) - được ký hiệu là A;

nhóm điều trị - treatment group là nhóm gồm các đối tượng được tiếp xúc với 1 điều kiện điều trị cụ thể - được ký hiệu là B.

Giả thuyết và đối thuyết của A/B testing thường là

- Giả thuyết: Phương pháp điều trị có hiệu quả tương đồng với đối chứng.
- Đối thuyết: Phương pháp điều trị có hiệu quả tốt hơn đối chứng.

A/B testing

Ví dụ cho A/B testing:

- Thử nghiệm hai phương pháp xử lý đất để xác định phương pháp nào giúp hạt nảy mầm tốt hơn.
- Thử nghiệm hai liệu pháp để xác định liệu pháp nào ngăn chặn ung thư hiệu quả hơn.
- Kiểm tra hai mức giá để xác định mức giá nào mang lại nhiều lợi nhuận ròng hơn.
- Kiểm tra hai dòng tiêu đề trên web để xác định dòng tiêu đề nào tạo ra nhiều lượt nhấp chuột hơn.
- Thử nghiệm hai quảng cáo trên web để xác định quảng cáo nào tạo ra nhiều chuyển đổi hơn.

Đối tượng nghiên cứu trong một A/B test, có thể là:

- người;
- hạt mầm cây;
- người ghé thăm trang web.

A/B testing

Mỗi đối tượng sẽ được tiếp xúc với

- điều kiện thông thường (control); hoặc
- điều kiện điều trị (treatment).

Để có dữ liệu phục vụ cho việc phân tích, ta cần thiết kế thí nghiệm đảm bảo tính ngẫu nhiên (randomness).

↔ Các đối tượng được chỉ định một cách ngẫu nhiên (**randomization**) vào nhóm đối chứng hoặc nhóm điều trị.

↔ Khi đó, ta sẽ biết rằng bất kỳ sự khác biệt nào giữa các nhóm là do một trong hai điều sau:

- Hiệu quả của các phương pháp điều trị khác nhau.
- Sự may mắn trong kết quả do các đối tượng được chỉ định ngẫu nhiên vào các phương pháp điều trị (tức là, việc phân công ngẫu nhiên có thể dẫn đến việc các đối tượng có thành tích tốt hơn một cách tự nhiên tập trung vào A hoặc B).

Mở rộng A/B testing

A/B testing là khá phổ biến trong các lĩnh vực kinh doanh hoặc thương mại điện tử.

Tuy nhiên, vẫn có những loại kiểm định khác, là biến thể hoặc mở rộng của A/B testing:

- Số nhóm điều trị nhiều hơn hai.

Ví dụ: so sánh độ gắn kết khách hàng của 4 trang web.

- Sự liên hệ của hai biến định tính.

Ví dụ: kiểm tra sự tác động của 3 kiểu headline tới tương tác của người dùng (click hoặc no-click).

- Các đối tượng được quan sát lặp lại.

Mở rộng A/B testing

Trong thống kê, ta thường quan tâm tới các câu hỏi dạng:

“Sự khác biệt giữa phương pháp điều trị A và phương pháp điều trị B có ý nghĩa thống kê hay không?”

Tuy nhiên, các nhà khoa học dữ liệu quan tâm tới câu hỏi dạng:

“Trong số nhiều phương pháp điều trị khác nhau, cái nào là tốt nhất?”

tức là dạng câu hỏi trực diện hơn.

Với câu hỏi dạng này, một loại thiết kế thử nghiệm tương đối mới được sử dụng: the multi-armed bandit hay **Multi-Armed Bandit Algorithms**.

Sai lầm trong kiểm định

Bảng sau đây biểu diễn bốn hậu quả có thể của một quyết định trong bài toán kiểm định thống kê:

Quyết định	Sự thật của giả thuyết gốc H_0	
	Đúng	Sai
Không bác bỏ	Chính xác	Sai lầm loại II
Bác bỏ	Sai lầm loại I	Chính xác

Sai lầm loại I - Type I error

Sai lầm loại I là sai lầm có thể mắc phải trong kiểm định giả thuyết thống kê, nó xảy ra khi ta quyết định **bác bỏ** giả thuyết gốc H_0 khi nó thực sự đúng.

Sai lầm loại II - Type II error

Sai lầm loại II là sai lầm có thể mắc phải trong kiểm định giả thuyết thống kê, nó xảy ra khi ta quyết định **không bác bỏ** giả thuyết gốc H_0 khi nó thực sự sai.

Sai lầm trong kiểm định

- Xác suất mắc sai lầm loại I thường được ký hiệu là α và nó là **mức ý nghĩa**.
- Xác suất mắc sai lầm loại II thường được ký hiệu là β .
- $1 - \beta$ được gọi là độ mạnh của kiểm định (power), tức là khả năng nhận ra được Giả thuyết là sai.

Trong khuôn khổ một kiểm định thống kê, chúng ta giả định rằng giả thuyết gốc H_0 là đúng. Vì vậy, chúng ta có thể nhận được:

- quyết định chính xác nếu ta không bác bỏ giả thuyết gốc H_0 ; hoặc,
- sai lầm loại I nếu ta bác bỏ Giả thuyết.

Để kiểm soát khả năng bị sai lầm loại I, ta cố định xác suất mắc sai lầm loại I (*mức ý nghĩa*), thường là 0.05 (hay 5%) và so sánh nó với một đại lượng được gọi là *p-value*, được tính từ dữ liệu.

Trong khi đó, sai lầm loại II được kiểm soát bằng việc xác định cỡ mẫu của dữ liệu.

p-value và quyết định

p -value là xác suất mà mô hình kiểm định tạo ra kết quả cực đoan hơn kết quả quan sát được, dưới giả định rằng giả thuyết gốc H_0 là đúng.

Ví dụ: p -value bằng 0.308 có nghĩa là ta có thể kỳ vọng rằng, ta sẽ thu được kết quả cực đoan như của dữ liệu được quan sát hoặc cực đoan hơn, một cách ngẫu nhiên trong hơn 30% số lần lấy mẫu, khi giả sử rằng Giả thuyết là đúng.

Nói cách khác, p -value có thể được dùng để đo sự tương thích của dữ liệu với giả thuyết gốc H_0 .

- nếu p -value là lớn, có nghĩa là dữ liệu tương thích với giả thuyết gốc H_0
↪ dữ liệu cung cấp bằng chứng ủng hộ giả thuyết gốc H_0 ;
- nếu p -value là nhỏ, có nghĩa là dữ liệu không tương thích với giả thuyết gốc H_0
↪ dữ liệu cung cấp bằng chứng chống lại giả thuyết gốc H_0
↪ đưa ra quyết định bác bỏ giả thuyết gốc H_0 .

p-value và quyết định

Để xác định mức nhỏ của p -value, ta so sánh nó với mức ý nghĩa α :

- nếu $p\text{-value} \geq \alpha$, thì chưa đủ nhỏ;
- nếu $p\text{-value} < \alpha$, thì đủ nhỏ để bác bỏ giả thuyết gốc H_0 với sai lầm loại I thấp.

Ví dụ: với p -value bằng 0.308:

- so sánh với $\alpha = 0.05 \implies$ không bác bỏ giả thuyết gốc H_0 ;
- so sánh với $\alpha = 0.1 \implies$ không bác bỏ giả thuyết gốc H_0 ;
- so sánh với $\alpha = 0.35 \implies$ bác bỏ Giả thuyết, với mức sai lầm loại I là 35%;

Bài toán

A/B testing là một thí nghiệm nhằm tìm ra phương pháp A hay phương pháp B là tốt hơn phương pháp còn lại.

↪ ta cần so sánh dữ liệu từ hai nhóm A và nhóm B.

- Khi dữ liệu ở dạng biến định lượng $\Rightarrow$ so sánh giá trị **trung bình** của dữ liệu của hai nhóm $\Rightarrow$ bài toán kiểm định hai trung bình.
- Khi dữ liệu ở dạng biến định tính $\Rightarrow$ so sánh giá trị **tỷ lệ** của dữ liệu của hai nhóm $\Rightarrow$ bài toán kiểm định hai tỷ lệ.

Ví dụ 1: Xét câu hỏi sau: “thời gian tương tác của trang web A và của trang web B có tương đồng nhau?”. Nếu:

- thời gian tương tác là không tương đồng
↪ một trong hai trang web (A hoặc B) giúp cải thiện (hoặc giảm) khả năng tương tác với khách hàng;
- thời gian tương tác là như nhau
↪ không có sự cải thiện (giảm) sự tương tác.

So sánh trung bình thời gian tương tác của web A và web B.

Bài toán

Ví dụ 2: Xét câu hỏi sau: “sự lựa chọn cánh gà chiên cay (hot wings) có phụ thuộc giới tính khách hàng (nam/nữ)?”. Nếu:

- có ảnh hưởng
 $\hookrightarrow$ một trong hai giới (nam hoặc nữ) mua nhiều hơn giới còn lại
- không ảnh hưởng
 $\hookrightarrow$ lượng mua cánh gà chiên cay là như nhau cho cả hai giới.

So sánh trung bình số lượng cánh gà chiên cay được mua bởi khách hàng nam và khách hàng nữ.

Ví dụ 3: Xét câu hỏi sau: “tỷ lệ chuyển đổi sản phẩm của một mặt hàng trên trang thương mại điện tử có khác biệt giữa hai mức giá?”. Nếu:

- có sự khác biệt
 $\hookrightarrow$ một trong hai giá (A hoặc B) tạo ra sự hấp dẫn với khách hàng
- nếu không có sự khác biệt
 $\hookrightarrow$ cả hai giá đều có sự hấp dẫn khách hàng như nhau.

So sánh tỷ lệ bán được sản phẩm của hai mức giá.

Kiểm định một phía, hai phía

Trong thống kê kiểm định nói chung và A/B testing nói riêng, ta luôn có:

- kiểm định hai phía (two sided)
- kiểm định một phía bên trái (left sided)
- kiểm định một phía bên phải (right sided)

Những kiểm định này được xác định theo tuyên bố của đối thuyết.

- $\mu_A \neq \mu_B \implies$ kiểm định hai phía;
- $\mu_A < \mu_B \implies$ kiểm định một phía bên trái;
- $\mu_A > \mu_B \implies$ kiểm định một phía bên phải.

Kiểm định hai phía được sử dụng khi ta không xác định được hướng so sánh từ ban đầu.

Nếu xác định được hướng/mục tiêu so sánh ngay từ đầu:

- trung bình thời gian tương tác của web A là thấp hơn so với web B;
- trung bình lượng cánh gà được mua bởi nam giới (nhóm A) là cao hơn bởi nữ giới (nhóm B);

thì kiểm định một phía sẽ được áp dụng.

Permutation test

Kiểm định hoán vị - Permutation test

Kiểm định hoán vị (Permutation test hay randomization test) là một phương pháp kiểm định phi tham số, hoạt động dựa trên hai nguyên tắc:

- Giả định về sự giống nhau giữa hai nhóm;
- xáo trộn và hoán đổi tất cả dữ liệu ở hai nhóm với nhau;

nhằm kiểm tra xem liệu sự khác biệt giữa hai nhóm có phải là do ngẫu nhiên.

Trong kiểm định hoán vị, giả thuyết gốc H_0 được phát biểu là phân phối xác suất của hai nhóm là như nhau, tức là $F_{Y_A} = F_{Y_B}$.

⇒ Nếu H_0 đúng thì có nghĩa là dữ liệu có thể hoán đổi (exchangeable) giữa các nhóm.

Definition (Exchangeability)

Xét mẫu ngẫu nhiên $\mathbf{Y} = (Y_1, \dots, Y_n)$ có hàm mật độ xác suất đồng thời $f_Y(y_1, \dots, y_n)$. Nếu $f_Y(y_1, \dots, y_n) = f_Y(y_{\pi_1}, \dots, y_{\pi_n})$ với mọi hoán vị π của tập chỉ số $\{1, \dots, n\}$, thì ta nói $Y_1, \dots, Y_n$ là có thể hoán đổi.

Permutation test

Xét hai nhóm dữ liệu

- $(Y_{A,1}, Y_{A,2}, \dots, Y_{A,n_A})$ độc lập cùng phân phối F_{Y_A} ;
- $(Y_{B,1}, Y_{B,2}, \dots, Y_{B,n_B})$ độc lập cùng phân phối F_{Y_B} .

Gộp lại ta có một dữ liệu đồng thời

$$(Y_{A,1}, Y_{A,2}, \dots, Y_{A,n_A}, Y_{B,1}, Y_{B,2}, \dots, Y_{B,n_B}).$$

Giả định rằng H_0 là đúng, tức là $F_{Y_1} = F_{Y_2} = F_Y$, khi đó, việc hoán đổi nhãn của hai nhóm dữ liệu cũng sẽ không thay đổi phân phối của chúng, tức là,

$$f_Y(y_1, \dots, y_n) = f_Y(y_{\pi_1}, \dots, y_{\pi_n})$$

với mọi hoán vị π của tập chỉ số $\{1, \dots, n\}$ và $n = n_A + n_B$.

Nhắc lại: phân phối của biến ngẫu nhiên được đặc trưng bởi:

- trung bình (kỳ vọng),
- trung vị (median),
- phương sai (độ phân tán của dữ liệu).

⇒ có thể sử dụng các đặc trưng này như là thống kê kiểm định cho việc so sánh các phân phối của mẫu hoán vị.

Permutation test

Sử dụng sự khác biệt trung bình làm thống kê kiểm định.

⇒ giả thuyết gốc H_0 được viết lại thành

$$\begin{cases} H_0 : & \mu_A - \mu_B = 0 \\ H_1 : & \mu_A - \mu_B \neq 0. \end{cases}$$

Khi này, giá trị thống kê kiểm định trên mẫu sẽ là $t_{\text{diff}} = \bar{Y}_1 - \bar{Y}_2$.

Nếu giả thuyết H_0 là đúng thì sẽ rất bất ngờ nếu ta quan sát thấy t_{diff} là lớn hơn hoặc nhỏ hơn hầu hết các giá trị $t_{\text{diff},j}$ (với $j = 1, \dots, n!$, $n!$ là tổng số lượng hoán vị).

Khi này, ta định nghĩa được p -value là

$$p\text{-value} = \frac{1}{n!} \sum_{j=1}^{n!} \mathbf{I}(|t_{\text{diff},j}| \geq |t_{\text{diff}}|).$$

Nếu $p\text{-value} \leq \alpha \Rightarrow$ giả thuyết gốc H_0 là không tương thích với dữ liệu, hay việc gán nhãn của hai nhóm là **không** ngẫu nhiên

⇒ có sự khác biệt về giá trị của hai nhóm.

Permutation test

Quy trình kiểm định hoán vị được thực hiện qua các bước như sau:

Bước 1 Tính $t_{\text{diff}} = \bar{Y}_A - \bar{Y}_B$ từ dữ liệu gốc.

Bước 2 Gộp chung hai dữ liệu thành một dữ liệu chung, ký hiệu chung là $(Y_1, \dots, Y_n)$ với $n = n_A + n_B$.

Bước 3 Hoán vị các vị trí trong dữ liệu chung, sau đó, chia ngẫu nhiên dữ liệu thành hai bộ dữ liệu có kích cỡ n_A và n_B .

Bước 4 Tính $t_{\text{diff},\pi} = \bar{Y}_{A,\pi} - \bar{Y}_{B,\pi}$ từ dữ liệu hoán vị.

Bước 5 Lặp lại bước 3 và 4 trong $n!$ lần (tương ứng với tổng số lần hoán vị).

Bước 6 Tính p -value theo công thức và so sánh với mức ý nghĩa α .

Tuy nhiên, $n!$ sẽ rất lớn ngay cả khi với cỡ mẫu nhỏ ($10! = 3,628,800$)

Permutation test

⇒ không thể tính toán được toàn bộ số hoán vị. Vì vậy, trong áp dụng thực tế, bước 5 và 6 sẽ được thay thế bởi:

*Bước 5** Lặp lại bước 3 và 4 trong R lần (tối thiểu 10,000 lần).

*Bước 6** Tính p -value theo công thức

$$p\text{-value} = \frac{1}{R} \sum_{j=1}^R \mathbf{I}(|t_{\text{diff},j}| \geq |t_{\text{diff}}|),$$

và so sánh với mức ý nghĩa α .

Permutation test

Trong trường hợp ta muốn kiểm định các cặp giả thuyết một phía (II) và (III)

$$(II) : \begin{cases} H_0 : \mu_A \leq \mu_B \\ H_1 : \mu_A > \mu_B \end{cases}, \quad (III) : \begin{cases} H_0 : \mu_A \geq \mu_B \\ H_1 : \mu_A < \mu_B \end{cases}$$

khi đó, p -value được xác định bởi:

- cặp giả thuyết (II) kiểm định một phía bên phải

$$p\text{-value} = \frac{1}{R} \sum_{j=1}^R \mathbf{I}(t_{\text{diff},j} \geq t_{\text{diff}});$$

- cặp giả thuyết (III) kiểm định một phía bên trái

$$p\text{-value} = \frac{1}{R} \sum_{j=1}^R \mathbf{I}(t_{\text{diff},j} \leq t_{\text{diff}}).$$

Bootstrap test

Xét hai nhóm dữ liệu:

- $(Y_{A,1}, Y_{A,2}, \dots, Y_{A,n_A})$ độc lập cùng phân phối F_{Y_A} , với $\mathbb{E}(Y_A) = \mu_A$;
- $(Y_{B,1}, Y_{B,2}, \dots, Y_{B,n_B})$ độc lập cùng phân phối F_{Y_B} , với $\mathbb{E}(Y_B) = \mu_B$.

Ta quan tâm tới kiểm định giả thuyết:

$$\begin{cases} H_0 : & \mu_A = \mu_B \\ H_1 : & \mu_A \neq \mu_B. \end{cases}$$

Theo Định lý giới hạn trung tâm, thống kê kiểm định

$$T_{n_1, n_2} = \frac{(\bar{Y}_1 - \bar{Y}_2)}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}} \xrightarrow{d} \mathcal{N}(0, 1),$$

nếu H_0 đúng, với điều kiện $n_1 \rightarrow +\infty$, $n_2 \rightarrow +\infty$ và $n_1/n_2 \rightarrow \lambda$ khi $n_1 \rightarrow +\infty$.

Bootstrap test

Khi này, p -value được xác định bởi:

$$p\text{-value} = \Pr_{F_0} \left(\frac{|\bar{X} - \bar{Y}|}{\sqrt{\frac{S_X^2}{n_1} + \frac{S_Y^2}{n_2}}} > |t_{\text{obs}}| \right),$$

với phân phối F_0 xấp xỉ phân phối chuẩn $\mathcal{N}(0, 1)$ nếu n_A, n_B lớn.

Trong thực tế, sự xấp xỉ chuẩn còn phụ thuộc vào:

- độ lệch của phân phối;
- cỡ mẫu có thể không đủ lớn.

⇒ việc áp dụng xấp xỉ chuẩn theo định lý giới hạn trung tâm không cho kết quả tốt.

Ta áp dụng phương pháp bootstrap nhằm xấp xỉ phân phối F_0 dưới giả định H_0 .

Chú ý: Đối với phương pháp này, ta **không** giả định dữ liệu là có thể hoán đổi nên ta không thể ghép hai bộ dữ liệu này thành một.

Bootstrap test

Gọi Y_A^* và Y_B^* là hai mẫu bootstrap của Y_A và Y_B .

Để đảm bảo mẫu bootstrap được xây dựng dưới giả thuyết H_0 , ta cần $\mathbb{E}(Y_A^*) = \mathbb{E}(Y_B^*)$.

Nếu Y_A^* và Y_B^* được tạo theo phân phối thực nghiệm $\hat{F}_{Y_A, n_1}$ và $\hat{F}_{Y_2, n_2}$ thì

$$\mathbb{E}_{\hat{F}_{Y_A, n_A}}(Y_A^*) = \bar{Y}_A \neq \bar{Y}_B = \mathbb{E}_{\hat{F}_{Y_B, n_B}}(Y_B^*).$$

Do đó, mẫu bootstrap Y_A^* và Y_B^* sẽ được tạo bởi

$$Y_A^* = Y_A - \bar{Y}_A, \quad \text{và} \quad Y_B^* = Y_B - \bar{Y}_B.$$

Bootstrap test

Quá trình kiểm định bootstrap cho A/B testing với hai trung bình:

Bước 1: Tính ước lượng $\bar{Y}_A$, S_A , $\bar{Y}_B$ và S_B từ hai bộ dữ liệu gốc.

Bước 2: Tạo hai bộ dữ liệu mới $\tilde{Y}_{A,j}, \dots, \tilde{Y}_{A,n_A}$ với $\tilde{Y}_{A,j} = Y_{A,j} - \bar{Y}_A$; và $\tilde{Y}_{2,j}, \dots, \tilde{Y}_{B,n_B}$ với $\tilde{Y}_{B,j} = Y_{B,j} - \bar{Y}_B$.

Bước 3: Ta tạo hai mẫu ngẫu nhiên cùng với cỡ n_1 và n_2 của 2 dữ liệu gốc từ dữ liệu tạo bởi Bước 2, có lặp lại (with replacement), tức là, $Y_{A,1}^*, Y_{A,2}^*, \dots, Y_{A,n_A}^*$ và $Y_{B,1}^*, Y_{B,2}^*, \dots, Y_{B,n_2}^*$.

Bước 4: Tính ước lượng $\bar{Y}_A^*$, S_A^* , $\bar{Y}_B^*$ và S_B^* từ dữ liệu bootstrap vừa tạo.

Bước 5: Tính giá trị thống kê

$$t^* = \bar{Y}_A^* - \bar{Y}_B^*, \quad \text{hoặc} \quad t^* = \frac{(\bar{Y}_A^* - \bar{Y}_B^*)}{\sqrt{\frac{S_A^{*2}}{n_A} + \frac{S_B^{*2}}{n_B}}},$$

Bước 6: Lặp lại bước 1, 2 và 3 trong R lần (ít nhất 5,000 lần), và lưu kết quả.

Bootstrap test

Bước 7: Tính p -value theo công thức

$$p\text{-value} = \frac{1}{R} \sum_{j=1}^R \mathbf{I}(|t_j^*| \geq |t_{\text{obs}}|),$$

với

$$t_{\text{obs}} = \bar{Y}_A - \bar{Y}_B, \quad \text{hoặc} \quad t_{\text{obs}} = \frac{(\bar{Y}_A - \bar{Y}_B)}{\sqrt{\frac{S_A^2}{n_A} + \frac{S_B^2}{n_B}}}.$$

Bootstrap test

Trong trường hợp ta muốn kiểm định các cặp giả thuyết một phía (II) và (III)

$$(II) : \begin{cases} H_0 : \mu_A \leq \mu_B \\ H_1 : \mu_A > \mu_B \end{cases}, \quad (III) : \begin{cases} H_0 : \mu_A \geq \mu_B \\ H_1 : \mu_A < \mu_B \end{cases}$$

thì quy trình bootstrap sẽ là tương tự như trường hợp kiểm định hai phía, tuy nhiên, p -value sẽ được tính bởi:

- cặp giả thuyết (II) kiểm định một phía bên phải

$$p\text{-value} = \frac{1}{R} \sum_{j=1}^R \mathbf{I}(t_j^* \geq t_{\text{obs}}),$$

- cặp giả thuyết (III) kiểm định một phía bên trái

$$p\text{-value} = \frac{1}{R} \sum_{j=1}^R \mathbf{I}(t_j^* \leq t_{\text{obs}}).$$