

Statistical Theory: Exercises and Solutions

Quang Nguyen

Ngày 4 tháng 4 năm 2026

1 Ước lượng Moment (MOM) và Maximum Likelihood (MLE)

Ví dụ 1

Cho $X_1, X_2, \dots, X_n$ i.i.d. $\sim P(\lambda)$. Tìm ước lượng moment cho tham số λ .

Motivation & Ý nghĩa

Phương pháp Moment (MOM) dựa trên luật số lớn, khẳng định rằng các moment mẫu sẽ hội tụ về các moment quần thể tương ứng. Với phân phối Poisson, tham số λ vừa là kỳ vọng vừa là phương sai. Do đó, việc giải phương trình moment bậc 1 là cách tiếp cận trực diện nhất để tìm ước lượng điểm cho λ .

Chi tiết Toán học

1. **Moment quần thể:** Đối với $X \sim P(\lambda)$, ta có:

$$\mu_1 = \mathbb{E}[X] = \lambda$$

2. **Moment mẫu:** Moment mẫu bậc 1 là trung bình mẫu:

$$m_1 = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

3. **Thiết lập phương trình:** Gán $m_1 = \mu_1$, ta thu được ước lượng:

$$\hat{\lambda}_{MOM} = \bar{X}$$

Ví dụ 2

Xét $X_1, \dots, X_n$ i.i.d. $\sim \text{NB}(r, p)$. Hãy tìm ước lượng moment cho (r, p) .

Motivation & Ý nghĩa

Khi mô hình có k tham số, ta cần thiết lập một hệ gồm k phương trình moment. Với phân phối Nhị thức âm (Negative Binomial), ta sử dụng kỳ vọng ($\mathbb{E}[X]$) và phương sai ($\text{Var}(X)$) để giải ngược ra các tham số cấu thành là r (số lần thành công mục tiêu) và p (xác suất thành công).

Chi tiết Toán học

1. **Hệ phương trình lý thuyết:** Dựa trên giả thiết:

$$\mathbb{E}[X] = \frac{r(1-p)}{p}, \quad \text{Var}(X) = \frac{r(1-p)}{p^2}$$

2. **Thay thế bằng đặc trưng mẫu:** Gọi $\bar{X}$ là trung bình mẫu và S^2 là phương sai mẫu. Ta có hệ:

$$\bar{X} = \frac{r(1-p)}{p} \quad (1)$$

$$S^2 = \frac{r(1-p)}{p^2} \quad (2)$$

3. **Giải hệ:** Chia (2) cho (1):

$$\frac{S^2}{\bar{X}} = \frac{1}{p} \Rightarrow \hat{p}_{MOM} = \frac{\bar{X}}{S^2}$$

Thay $\hat{p}$ vào (1):

$$\bar{X} = \hat{r} \left(\frac{1 - \frac{\bar{X}}{S^2}}{\frac{\bar{X}}{S^2}} \right) = \hat{r} \left(\frac{S^2 - \bar{X}}{\bar{X}} \right) \Rightarrow \hat{r}_{MOM} = \frac{\bar{X}^2}{S^2 - \bar{X}}$$

Ví dụ 3

Xét $X_1, \dots, X_n$ i.i.d. $\sim \text{Exp}(\lambda)$. Hãy tìm MLE của λ .

Motivation & Ý nghĩa

Ước lượng cực đại hóa khả năng (MLE) tìm giá trị tham số khiến cho bộ dữ liệu quan sát được có xác suất xảy ra cao nhất. Với hàm mũ, việc chuyển sang hàm Log-likelihood là bước kỹ thuật quan trọng để biến phép nhân các mật độ thành phép cộng, giúp tối ưu hóa bằng đạo hàm dễ dàng hơn.

Chi tiết Toán học

1. **Hàm Likelihood:** Với $f(x|\lambda) = \lambda e^{-\lambda x}$:

$$L(\lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n \exp\left(-\lambda \sum_{i=1}^n x_i\right)$$

2. **Hàm Log-likelihood:**

$$\ell(\lambda) = \ln L(\lambda) = n \ln \lambda - \lambda \sum_{i=1}^n x_i$$

3. **Tối ưu hóa:** Lấy đạo hàm theo λ và giải phương trình điểm dừng:

$$\frac{d\ell(\lambda)}{d\lambda} = \frac{n}{\lambda} - \sum_{i=1}^n x_i = 0 \Rightarrow \hat{\lambda}_{MLE} = \frac{n}{\sum x_i} = \frac{1}{\bar{X}}$$

Ví dụ 4

Xét $X_1, \dots, X_n$ i.i.d. $\sim U(0, \theta)$. Hãy tìm MLE của θ .

Motivation & Ý nghĩa

Đây là bài toán MLE tại biên (boundary case). Khác với các phân phối thông thường, đạo hàm của hàm Likelihood ở đây không bằng 0 tại điểm cực trị. Chúng ta phải dựa trên tính đơn điệu của hàm số và miền xác định phụ thuộc vào tham số (Support dependence) để xác định MLE thông qua thống kê thứ tự (Order Statistics).

Chi tiết Toán học

1. **Hàm Likelihood:**

$$L(\theta) = \prod_{i=1}^n \frac{1}{\theta} \mathbb{I}(0 \leq x_i \leq \theta) = \frac{1}{\theta^n} \mathbb{I}(\max(x_i) \leq \theta)$$

2. **Phân tích:** Hàm $L(\theta)$ chỉ khác 0 khi $\theta \geq x_i$ với mọi i , tức là $\theta \geq \max(x_1, \dots, x_n)$. Trong miền $\theta \in [X_{(n)}, \infty)$, hàm $L(\theta) = \theta^{-n}$ là hàm nghịch biến (giảm dần).

3. **Kết luận:** Để cực đại hóa $L(\theta)$, ta cần chọn θ nhỏ nhất có thể trong miền cho phép.

$$\hat{\theta}_{MLE} = X_{(n)} = \max(X_1, \dots, X_n)$$

Ví dụ 5

Xét n cặp dữ liệu (X_i, Y_i) với $Y_i | X_i \sim N(\alpha + \beta X_i, \sigma^2)$. Hãy tìm MLE cho $(\alpha, \beta, \sigma^2)$.

Motivation & Ý nghĩa

Ví dụ này thiết lập mối liên hệ giữa thống kê cổ điển và học máy (Machine Learning). Ta chứng minh được rằng dưới giả định nhiễu Gauss (Gaussian noise), việc cực đại hóa khả năng (MLE) cho các hệ số hồi quy tương đương hoàn toàn với việc cực tiểu hóa tổng bình phương sai số (Ordinary Least Squares - OLS).

Chi tiết Toán học

1. **Hàm Log-likelihood:**

$$\ell(\alpha, \beta, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \alpha - \beta x_i)^2$$

2. **Ước lượng α và β :** Để cực đại hóa ℓ theo α và β , ta cần cực tiểu hóa biểu thức $Q = \sum_{i=1}^n (y_i - \alpha - \beta x_i)^2$. Đây là bài toán OLS tiêu chuẩn, dẫn đến hệ phương trình chuẩn (Normal Equations):

$$\hat{\beta} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}, \quad \hat{\alpha} = \bar{y} - \hat{\beta} \bar{x}$$

3. **Ước lượng σ^2 :** Lấy đạo hàm theo σ^2 và cho bằng 0:

$$\begin{aligned} \frac{\partial \ell}{\partial \sigma^2} &= -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (y_i - \hat{\alpha} - \hat{\beta} x_i)^2 = 0 \\ \Rightarrow \hat{\sigma}_{MLE}^2 &= \frac{1}{n} \sum_{i=1}^n (y_i - \hat{\alpha} - \hat{\beta} x_i)^2 \end{aligned}$$

Lưu ý: Ước lượng MLE của phương sai trong hồi quy bị chệch (chia cho n thay vì $n - 2$).

Ví dụ 6

Xét $X_1, \dots, X_n$ i.i.d. $\sim N(\mu, 1)$ với $\mu \geq 0$. Tìm MLE cho μ .

A. Motivation & Ý nghĩa

Đây là bài toán MLE trên không gian tham số bị chặn (restricted parameter space). Thông thường, MLE của μ là $\bar{X}$, nhưng nếu $\bar{X}$ rơi vào miền không cho phép ($\bar{X} < 0$), ta phải tìm giá trị gần nhất trong miền $\mu \geq 0$ để tối đa hóa hàm Likelihood.

B. Chi tiết Toán học

1. Hàm log-likelihood (bỏ qua hằng số):

$$\ell(\mu) = -\frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2$$

2. Đạo hàm $\ell'(\mu) = \sum (x_i - \mu) = n(\bar{x} - \mu)$.

3. Xét các trường hợp:

- Nếu $\bar{x} \geq 0$: Điểm cực trị $\mu = \bar{x}$ thỏa mãn điều kiện $\mu \geq 0$. Vậy $\hat{\mu}_{MLE} = \bar{X}$.
- Nếu $\bar{x} < 0$: Hàm $\ell(\mu)$ là hàm nghịch biến trên $[0, \infty)$ vì $\ell'(\mu) < 0$ với mọi $\mu \geq 0$. Do đó, giá trị cực đại đạt được tại biên nhỏ nhất. Vậy $\hat{\mu}_{MLE} = 0$.

4. Kết luận: $\hat{\mu}_{MLE} = \max(0, \bar{X})$.

Ví dụ 7

Xét $X_1, \dots, X_n$ i.i.d. $\sim B(p)$, $0 < p < 1$. Xác định MLE của p và odds $\nu = \frac{p}{1-p}$.

A. Motivation & Ý nghĩa

Ví dụ này minh họa tính bất biến (Invariance Property) của ước lượng MLE. Nếu $\hat{\theta}$ là MLE của θ , thì $g(\hat{\theta})$ là MLE của $g(\theta)$ với mọi hàm g đơn điệu.

B. Chi tiết Toán học

1. **MLE của p :**

$$L(p) = p^{\sum x_i} (1-p)^{n-\sum x_i} \Rightarrow \ell(p) = (\sum x_i) \ln p + (n - \sum x_i) \ln(1-p)$$

$$\text{Giải } \ell'(p) = 0 \Rightarrow \hat{p}_{MLE} = \bar{X}.$$

2. **MLE của odds:** Theo tính bất biến của MLE, vì $\nu = g(p) = \frac{p}{1-p}$ là hàm đơn điệu tăng theo p :

$$\hat{\nu}_{MLE} = \frac{\hat{p}_{MLE}}{1 - \hat{p}_{MLE}} = \frac{\bar{X}}{1 - \bar{X}}$$

Ví dụ 8

Xét $X_1, \dots, X_n$ i.i.d. $\sim B(p)$ với tiên nghiệm $p \sim \text{Beta}(\alpha, \beta)$. Tìm phân phối hậu nghiệm và ước lượng Bayes.

A. Motivation & Ý nghĩa

Đây là ví dụ kinh điển về liên hợp (conjugacy). Beta là phân phối liên hợp của Bernoulli. Ước lượng Bayes (thường là kỳ vọng hậu nghiệm) đóng vai trò như một sự kết hợp giữa niềm tin ban đầu (prior) và dữ liệu thực tế.

B. Chi tiết Toán học

1. **Phân phối hậu nghiệm:**

$$\begin{aligned} \pi(p|x) &\propto L(x|p)\pi(p) \propto p^{\sum x_i} (1-p)^{n-\sum x_i} \cdot p^{\alpha-1} (1-p)^{\beta-1} \\ \pi(p|x) &\propto p^{(\alpha+\sum x_i)-1} (1-p)^{(\beta+n-\sum x_i)-1} \end{aligned}$$

$$\text{Vậy } p|x \sim \text{Beta}(\alpha + \sum x_i, \beta + n - \sum x_i).$$

2. **Ước lượng Bayes:** Với hàm mất mát bình phương, ước lượng Bayes là kỳ vọng hậu nghiệm:

$$\hat{p}_{Bayes} = \mathbb{E}[p|x] = \frac{\alpha + \sum x_i}{\alpha + \beta + n}$$

Ví dụ 9

Xét $X_1, \dots, X_n$ i.i.d. $\sim \text{Exp}(\lambda)$, tiên nghiệm $\lambda \sim \text{Exp}(\alpha)$. Tìm ước lượng Bayes cho λ .

A. Motivation & Ý nghĩa

Học cách cập nhật tham số tỷ lệ (rate) trong mô hình Poisson/Exponential. Tiên nghiệm $\text{Exp}(\alpha)$ thực chất là Gamma(1, α), và Gamma là liên hợp của Exponential.

B. Chi tiết Toán học

1. **Phân phối hậu nghiệm:**

$$\pi(\lambda|x) \propto (\lambda^n e^{-\lambda \sum x_i}) \cdot (\alpha e^{-\alpha \lambda}) \propto \lambda^n e^{-\lambda(\alpha + \sum x_i)}$$

$$\text{Nhận diện đây là hạt nhân của phân phối Gamma}(n+1, \alpha + \sum x_i).$$

2. **Ước lượng Bayes:**

$$\hat{\lambda}_{Bayes} = \mathbb{E}[\lambda|x] = \frac{n+1}{\alpha + \sum x_i}$$

Ví dụ 10

Xét $X_1, \dots, X_n$ i.i.d. $\sim B(p)$, $p \sim U(0, 1)$. Tìm ước lượng Bayes cho p .

A. Motivation & Ý nghĩa

Phân phối đều $U(0, 1)$ là trường hợp đặc biệt của Beta(1, 1), đại diện cho trạng thái "vô định" (non-informative prior) khi ta chưa có thông tin gì về p .

B. Chi tiết Toán học

1. Áp dụng kết quả Ví dụ 8 với $\alpha = 1, \beta = 1$:

$$\pi(p|x) \sim \text{Beta}(\sum x_i + 1, n - \sum x_i + 1)$$

2. Ước lượng Bayes:

$$\hat{p}_{\text{Bayes}} = \frac{\sum x_i + 1}{n + 2}$$

(Đây chính là quy tắc cộng 1 của Laplace - Laplace's Rule of Succession).

Ví dụ 11 (Beta-Binomial conjugate)

Chứng minh phân phối hậu nghiệm của mô hình Beta-Binomial.

B. Chi tiết Toán học

- Likelihood: $P(x|p) = \prod \binom{m}{x_i} p^{x_i} (1-p)^{m-x_i} \propto p^{\sum x_i} (1-p)^{nm - \sum x_i}$.
- Prior: $\pi(p) \propto p^{\alpha-1} (1-p)^{\beta-1}$.
- Posterior: $\pi(p|x) \propto p^{\sum x_i + \alpha - 1} (1-p)^{nm - \sum x_i + \beta - 1}$.
- Kết luận: $\pi(p|x) \sim \text{Beta}(\sum x_i + \alpha, nm - \sum x_i + \beta)$.

Ví dụ 12 (Gamma-Poisson conjugate)

Chứng minh phân phối hậu nghiệm của mô hình Gamma-Poisson.

B. Chi tiết Toán học

- Likelihood: $P(x|\lambda) = \prod \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} \propto e^{-n\lambda} \lambda^{\sum x_i}$.
- Prior: $\pi(\lambda) \propto \lambda^{\alpha-1} e^{-\lambda/\beta}$.
- Posterior: $\pi(\lambda|x) \propto \lambda^{\sum x_i + \alpha - 1} e^{-\lambda(n+1/\beta)}$.
- Đặt tham số scale mới $\beta' = (n + 1/\beta)^{-1}$.
- Kết luận: $\pi(\lambda|x) \sim \text{Gamma}(\sum x_i + \alpha, \beta')$.

Ví dụ 13 (Normal Bayes estimators)

Xét $X \sim N(\theta, \sigma^2)$ và tiên nghiệm $\theta \sim N(\mu, \tau^2)$. Chứng minh phân phối hậu nghiệm của θ cũng là phân phối chuẩn.

Motivation & Ý nghĩa

Đây là mô hình liên hợp chuẩn (Normal-Normal conjugate). Ý nghĩa quan trọng nhất ở đây là công thức kỳ vọng hậu nghiệm: nó là một **trung bình có trọng số** giữa niềm tin ban đầu (μ) và dữ liệu quan sát ($\bar{x}$). Trọng số này tỉ lệ thuận với độ tin cậy (nghịch đảo của phương sai) của từng nguồn thông tin.

Chi tiết Toán học

1. Hàm mật độ hậu nghiệm:

$$\pi(\theta|x) \propto \exp\left(-\frac{(x-\theta)^2}{2\sigma^2}\right) \exp\left(-\frac{(\theta-\mu)^2}{2\tau^2}\right)$$

2. Khai triển và gom cụm: Ta khai triển các bình phương và gom các số hạng liên quan đến θ^2 và θ :

$$\pi(\theta|x) \propto \exp\left(-\frac{1}{2} \left[\theta^2 \left(\frac{1}{\sigma^2} + \frac{1}{\tau^2} \right) - 2\theta \left(\frac{x}{\sigma^2} + \frac{\mu}{\tau^2} \right) + \text{const} \right] \right)$$

3. **Nhận diện thông số:** Đây là hạt nhân của phân phối chuẩn $N(\mu_{post}, \tau_{post}^2)$ với:

$$\frac{1}{\tau_{post}^2} = \frac{1}{\sigma^2} + \frac{1}{\tau^2} \Rightarrow \tau_{post}^2 = \frac{\sigma^2 \tau^2}{\sigma^2 + \tau^2}$$

$$\mu_{post} = \tau_{post}^2 \left(\frac{x}{\sigma^2} + \frac{\mu}{\tau^2} \right) = \frac{\tau^2}{\sigma^2 + \tau^2} x + \frac{\sigma^2}{\sigma^2 + \tau^2} \mu$$

Ví dụ 14

Xét $X_i \sim B(p)$. $\bar{X}$ có phải là ước lượng không chệch tốt nhất cho p không? Nó có đạt được CRLB không?

Motivation & Ý nghĩa

Ví dụ này kiểm tra tính "hiệu quả" (efficiency). Một ước lượng không chệch được coi là tốt nhất (UMVUE) nếu phương sai của nó đạt đến giới hạn vật lý nhỏ nhất có thể, chính là CRLB.

Chi tiết Toán học

1. **Lượng tin Fisher:** Với Bernoulli, $f(x|p) = p^x(1-p)^{1-x}$.

$$\ln f = x \ln p + (1-x) \ln(1-p) \Rightarrow \frac{\partial^2 \ln f}{\partial p^2} = -\frac{x}{p^2} - \frac{1-x}{(1-p)^2}$$

$$I(p) = -\mathbb{E} \left[\frac{\partial^2 \ln f}{\partial p^2} \right] = \frac{p}{p^2} + \frac{1-p}{(1-p)^2} = \frac{1}{p(1-p)}$$

2. **CRLB cho mẫu cỡ n :** $CRLB = \frac{1}{nI(p)} = \frac{p(1-p)}{n}$.

3. **Phương sai của $\bar{X}$:** $\text{Var}(\bar{X}) = \frac{\text{Var}(X_1)}{n} = \frac{p(1-p)}{n}$.

4. **Kết luận:** Vì $\text{Var}(\bar{X}) = CRLB$, nên $\bar{X}$ là ước lượng hiệu quả nhất và đạt được CRLB.

Ví dụ 15

So sánh hai ước lượng cho λ trong $P(\lambda)$: $\hat{\lambda}_1 = \bar{X}$ và $\hat{\lambda}_2 = S^2$.

Motivation & Ý nghĩa

Trong phân phối Poisson, $\mathbb{E}[X] = \text{Var}(X) = \lambda$, nên cả $\bar{X}$ và S^2 đều không chệch. Tuy nhiên, $\bar{X}$ là một thống kê đủ (sufficient statistic), còn S^2 thì không. Ví dụ này cho thấy việc sử dụng thông tin không tối ưu dẫn đến phương sai lớn hơn.

Chi tiết Toán học

1. **Fisher Information:** $I(\lambda) = 1/\lambda \Rightarrow CRLB = \lambda/n$.

2. **Phương sai của $\hat{\lambda}_1$:** $\text{Var}(\bar{X}) = \lambda/n$. (Đạt CRLB).

3. **Phương sai của $\hat{\lambda}_2$:** Dựa trên công thức $\text{Var}(S^2)$ đã cho, với Poisson có $\mu_4 = \lambda + 3\lambda^2$ và $\mu_2 = \lambda$:

$$\text{Var}(S^2) = \frac{\lambda(1+2\lambda)}{n} + \text{bậc thấp hơn} > \frac{\lambda}{n}$$

4. **Kết luận:** $\hat{\lambda}_1$ tốt hơn vì có phương sai nhỏ hơn và đạt CRLB.

Ví dụ 16

Xét $X_i \sim U[0, \theta]$. Tìm CRLB và chứng tỏ $\frac{n+1}{n}Y$ (với $Y = \max X_i$) có phương sai nhỏ hơn CRLB.

Motivation & Ý nghĩa

Đây là một "bẫy" lý thuyết. Định lý Cramer-Rao chỉ áp dụng khi các **điều kiện chính quy (regularity conditions)** được thỏa mãn. Với phân phối đều, miền xác định phụ thuộc vào

tham số θ , khiến đạo hàm của mật độ không tồn tại tại biên. Do đó, CRLB không áp dụng được và có thể bị "vượt qua".

Chi tiết Toán học

1. **Tính toán CRLB (nếu có thể áp dụng):** $I(\theta) = 1/\theta^2 \Rightarrow CRLB = \theta^2/n$.

2. **Phương sai của ước lượng:** Xét $\hat{\theta} = \frac{n+1}{n}Y$. Ta biết Y có mật độ $f_Y(y) = \frac{ny^{n-1}}{\theta^n}$.

$$\mathbb{E}[Y] = \frac{n}{n+1}\theta, \quad \mathbb{E}[Y^2] = \frac{n}{n+2}\theta^2$$

$$\text{Var}(Y) = \theta^2 \left[\frac{n}{n+2} - \left(\frac{n}{n+1} \right)^2 \right] = \frac{n\theta^2}{(n+2)(n+1)^2}$$

$$\text{Var}\left(\frac{n+1}{n}Y\right) = \left(\frac{n+1}{n}\right)^2 \text{Var}(Y) = \frac{\theta^2}{n(n+2)}$$

3. **Số sánh:** $\frac{\theta^2}{n(n+2)} < \frac{\theta^2}{n}$ (CRLB giả định). Điều này chứng tỏ CRLB không có hiệu lực ở đây.

Ví dụ 17

Sử dụng Hệ quả 3 để chứng tỏ $\bar{X}$ trong $B(p)$ đạt CRLB.

Motivation & Ý nghĩa

Hệ quả 3 phát biểu rằng nếu ta có thể viết đạo hàm của log-likelihood dưới dạng $k(\theta, n) \cdot (\hat{\theta} - \theta)$, thì $\hat{\theta}$ chắc chắn đạt CRLB. Đây là cách nhanh nhất để kiểm tra tính hiệu quả mà không cần tính phương sai trực tiếp.

Chi tiết Toán học

1. **Đạo hàm Log-likelihood:**

$$\ell'(p) = \frac{\sum x_i}{p} - \frac{n - \sum x_i}{1-p} = \frac{(1-p)\sum x_i - np + p\sum x_i}{p(1-p)}$$

$$\ell'(p) = \frac{\sum x_i - np}{p(1-p)} = \frac{n}{p(1-p)}(\bar{x} - p)$$

2. **Nhận dạng:** Biểu thức có dạng $A(p)(\bar{X} - p)$ với $A(p) = \frac{n}{p(1-p)}$.

3. **Kết luận:** Theo hệ quả 3, $\bar{X}$ đạt CRLB.

Ví dụ 18

Xét $X_i \sim N(\mu, \sigma^2)$, μ chưa biết. CRLB có đạt được cho phương sai của ước lượng σ^2 không?

Motivation & Ý nghĩa

Khi có hai tham số chưa biết, CRLB cho một tham số phụ thuộc vào việc tham số kia có được biết hay không. Thông thường, ước lượng mẫu S^2 (chia cho $n-1$) là không chệch nhưng không đạt được CRLB trong mẫu hữu hạn.

Chi tiết Toán học

1. **Fisher Information Matrix:** Trong trường hợp Normal, thông tin cho σ^2 là $I(\sigma^2) = \frac{1}{2\sigma^4}$.

2. **CRLB:** $CRLB(\sigma^2) = \frac{2\sigma^4}{n}$.

3. **Thực tế:** Phương sai của ước lượng không chệch S^2 là $\frac{2\sigma^4}{n-1}$.

4. **Kết luận:** Vì $\frac{2\sigma^4}{n-1} > \frac{2\sigma^4}{n}$, ước lượng không đạt được CRLB. Giới hạn này chỉ đạt được khi $n \rightarrow \infty$ (tính hiệu quả tiệm cận).

Ví dụ 19

Xét X_i i.i.d. $\sim N(\theta, 1)$. $W(X) = \frac{1}{2}(X_1 + X_2)$ là ước lượng không chệch của θ . Đặt $T(X) = X_1$ và $\phi(T) = \mathbb{E}[W(X) | T]$. Tính $\mathbb{E}[\phi(T)]$ và $\text{Var}(\phi(T))$. $\phi(T)$ có phải là một ước lượng cho θ ?

Motivation & Ý nghĩa

Ví dụ này minh họa điều kiện tiên quyết của định lý Rao-Blackwell: Thống kê điều kiện T phải là một **thống kê đủ**. Nếu T không đủ, kỳ vọng điều kiện có thể vẫn phụ thuộc vào tham số θ , dẫn đến kết quả không phải là một "ước lượng" (vì ước lượng không được phép chứa tham số chưa biết).

Chi tiết Toán học

1. Tính $\phi(T)$:

$$\phi(T) = \mathbb{E}\left[\frac{1}{2}(X_1 + X_2) \mid X_1\right] = \frac{1}{2}\mathbb{E}[X_1|X_1] + \frac{1}{2}\mathbb{E}[X_2|X_1]$$

Vì X_1, X_2 độc lập, $\mathbb{E}[X_2|X_1] = \mathbb{E}[X_2] = \theta$. Do đó:

$$\phi(T) = \frac{1}{2}X_1 + \frac{1}{2}\theta$$

2. Tính kỳ vọng và phương sai:

$$\mathbb{E}[\phi(T)] = \frac{1}{2}\mathbb{E}[X_1] + \frac{1}{2}\theta = \theta$$

$$\text{Var}(\phi(T)) = \text{Var}\left(\frac{1}{2}X_1 + \frac{1}{2}\theta\right) = \frac{1}{4}\text{Var}(X_1) = \frac{1}{4}$$

3. **Kết luận:** $\phi(T)$ **không** phải là một ước lượng cho θ vì biểu thức của nó vẫn chứa tham số θ . Điều này xảy ra do $T = X_1$ không phải là thống kê đủ cho θ .

Ví dụ 20

Xét X_i i.i.d. $\sim N(\theta, 1)$. $W(X) = X_1$, $T(X) = \bar{X}$. Tính $\phi(T) = \mathbb{E}[W(X) | T]$. $\phi(T)$ có phải là một ước lượng cho θ ?

Motivation & Ý nghĩa

Ngược lại với ví dụ 19, ở đây $T = \bar{X}$ là một thống kê đủ cho θ . Theo định lý Rao-Blackwell, kỳ vọng điều kiện của một ước lượng không chệch bất kỳ theo một thống kê đủ sẽ cho ta một ước lượng mới không chệch và có phương sai không lớn hơn ước lượng ban đầu.

Chi tiết Toán học

1. Sử dụng tính đối xứng: Vì X_i là i.i.d, ta có $\mathbb{E}[X_1|\bar{X}] = \mathbb{E}[X_2|\bar{X}] = \dots = \mathbb{E}[X_n|\bar{X}]$.
2. Tổng các kỳ vọng:

$$\sum_{i=1}^n \mathbb{E}[X_i|\bar{X}] = \mathbb{E}\left[\sum_{i=1}^n X_i \mid \bar{X}\right] = \mathbb{E}[n\bar{X}|\bar{X}] = n\bar{X}$$

3. Suy ra: $n\mathbb{E}[X_1|\bar{X}] = n\bar{X} \Rightarrow \phi(T) = \bar{X}$.

4. Kỳ vọng và phương sai:

$$\mathbb{E}[\phi(T)] = \theta, \quad \text{Var}(\phi(T)) = \frac{1}{n}$$

5. **Kết luận:** $\phi(T) = \bar{X}$ là một ước lượng (vì không phụ thuộc θ). Theo Rao-Blackwell, $\text{Var}(\bar{X}) = 1/n \leq \text{Var}(X_1) = 1$.

Ví dụ 21

Cho X_1, X_2 i.i.d. $\sim P(\theta)$. Tìm UMVUE cho $\tau(\theta) = e^{-\theta}$.

Motivation & Ý nghĩa

Đây là bài toán tìm ước lượng không chệch tốt nhất bằng cách "Rao-Blackwell hóa" một ước lượng thô sơ. Thống kê đủ và đầy đủ cho Poisson là tổng các quan sát.

Chi tiết Toán học

1. **Thống kê đủ:** $T = X_1 + X_2 \sim P(2\theta)$.
2. **Ước lượng không chệch thô sơ:** Chọn $W = \mathbb{I}(X_1 = 0)$. Ta có $\mathbb{E}[W] = P(X_1 = 0) = \frac{e^{-\theta}\theta^0}{0!} = e^{-\theta}$. Vậy W không chệch.
3. **Tính kỳ vọng điều kiện:**

$$\begin{aligned}\mathbb{E}[W|T = y] &= P(X_1 = 0|X_1 + X_2 = y) = \frac{P(X_1 = 0, X_2 = y)}{P(X_1 + X_2 = y)} \\ &= \frac{e^{-\theta} \cdot \frac{e^{-\theta}\theta^y}{y!}}{\frac{e^{-2\theta}(2\theta)^y}{y!}} = \frac{e^{-2\theta}\theta^y/y!}{e^{-2\theta}2^y\theta^y/y!} = \left(\frac{1}{2}\right)^y\end{aligned}$$

4. **Kết luận:** Ước lượng không chệch tốt nhất là $\hat{\tau} = (1/2)^{X_1+X_2}$.

Ví dụ 22

Cho X_i i.i.d. $\sim N(\mu, \sigma^2)$. Tìm UMVUE cho μ, σ^2, μ^2 .

Motivation & Ý nghĩa

Dựa trên định lý Lehmann-Scheffé, nếu T là thống kê đủ và đầy đủ, thì bất kỳ hàm nào của T mà không chệch cho tham số mục tiêu đều là UMVUE. Với phân phối chuẩn, $(\bar{X}, S^2)$ là bộ thống kê đủ và đầy đủ.

Chi tiết Toán học

1. UMVUE cho μ : Là $\bar{X}$ (vì $\bar{X}$ không chệch và là hàm của thống kê đủ).
2. UMVUE cho σ^2 : Là $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$.
3. UMVUE cho μ^2 : Ta biết $\mathbb{E}[\bar{X}^2] = \text{Var}(\bar{X}) + (\mathbb{E}[\bar{X}])^2 = \frac{\sigma^2}{n} + \mu^2$. Suy ra $\mu^2 = \mathbb{E}[\bar{X}^2] - \frac{\sigma^2}{n}$. Vì S^2 không chệch cho σ^2 , ta có:

$$\mathbb{E}\left[\bar{X}^2 - \frac{S^2}{n}\right] = \mu^2$$

Vậy UMVUE của μ^2 là $\hat{\theta} = \bar{X}^2 - \frac{S^2}{n}$.

Ví dụ 23

Cho X_i i.i.d. $\sim U[0, \theta]$. Tìm UMVUE cho θ và $1/\theta$.

Motivation & Ý nghĩa

Với phân phối đều, thống kê đủ và đầy đủ là cực đại mẫu $Y = X_{(n)}$. Mọi UMVUE phải là hàm của Y .

Chi tiết Toán học

1. Hàm mật độ của $Y = X_{(n)}$: $f_Y(y) = \frac{ny^{n-1}}{\theta^n}, 0 \leq y \leq \theta$.

2. UMVUE cho θ :

$$\mathbb{E}[Y] = \int_0^\theta y \frac{ny^{n-1}}{\theta^n} dy = \frac{n}{n+1} \theta \Rightarrow \hat{\theta}_{UMVUE} = \frac{n+1}{n} X_{(n)}$$

3. UMVUE cho $1/\theta$:

$$\begin{aligned} \mathbb{E}[Y^k] &= \frac{n}{n+k} \theta^k. \text{ Chọn } k = -1 : \mathbb{E}[1/Y] = \frac{n}{n-1} \frac{1}{\theta} \\ \Rightarrow \widehat{(1/\theta)}_{UMVUE} &= \frac{n-1}{n} \frac{1}{X_{(n)}} \end{aligned}$$

Ví dụ 24

Cho X_i i.i.d. $\sim B(k, p)$. Tìm UMVUE cho $P(X = 1)$.

Motivation & Ý nghĩa

Trong phân phối Nhị thức, tổng các quan sát $T = \sum X_i$ là thống kê đủ và đầy đủ. Ta tìm một hàm của T sao cho kỳ vọng của nó bằng $kp(1-p)^{k-1}$.

Chi tiết Toán học

Tương tự ví dụ 21, ta xét ước lượng không chệch thô sơ $W = \mathbb{I}(X_1 = 1)$. UMVUE là $\phi(t) = P(X_1 = 1 | \sum X_i = t)$. Sử dụng phân phối Hypergeometric (siêu bội) khi điều kiện hóa tổng của các biến Bernoulli:

$$\phi(t) = \frac{\binom{k}{1} \binom{k(n-1)}{t-1}}{\binom{kn}{t}}$$

(Đây là xác suất chọn được đúng 1 thành công từ nhóm k phần tử đầu tiên, biết rằng có tổng cộng t thành công trong kn phần tử).

Bài tập 1

Chứng minh Bổ đề 2: $\mathbb{E}_\theta \left[\frac{\partial}{\partial \theta} \ln f(X | \theta) \right] = 0$.

Motivation & Ý nghĩa

Bổ đề này là điều kiện tiên quyết (regularity condition) để định nghĩa Lượng tin Fisher và thiết lập chặn dưới Cramer-Rao. Nó phát biểu rằng giá trị kỳ vọng của "điểm số" (score function) luôn bằng 0, nghĩa là tại điểm thực của tham số, hàm Likelihood không có xu hướng "ngiên" về một phía nào trong bình diện kỳ vọng.

Chi tiết Toán học

Giả sử các điều kiện chính quy cho phép hoán vị dấu tích phân và dấu đạo hàm:

1. Ta biết rằng tổng xác suất trên toàn không gian mẫu luôn bằng 1:

$$\int_{\mathcal{X}} f(x | \theta) dx = 1$$

2. Lấy đạo hàm hai vế theo θ :

$$\frac{\partial}{\partial \theta} \int_{\mathcal{X}} f(x | \theta) dx = \frac{\partial}{\partial \theta} (1) = 0$$

3. Hoán vị đạo hàm và tích phân:

$$\int_{\mathcal{X}} \frac{\partial}{\partial \theta} f(x | \theta) dx = 0$$

4. Sử dụng quy tắc chuỗi cho logarit: $\frac{\partial}{\partial \theta} f = f \cdot \frac{\partial}{\partial \theta} \ln f$. Thay vào biểu thức trên:

$$\int_{\mathcal{X}} \left(\frac{\partial}{\partial \theta} \ln f(x | \theta) \right) f(x | \theta) dx = 0$$

5. Biểu thức này chính là định nghĩa của kỳ vọng:

$$\mathbb{E}_\theta \left[\frac{\partial}{\partial \theta} \ln f(X | \theta) \right] = 0$$

Bài tập 2

Cho $f(x | \theta) = \frac{1}{2} \theta^3 x^2 e^{-\theta x} \mathbb{I}_{[0, \infty)}(x)$. Chứng minh $\bar{X}_n$ là UMVUE cho $\mu = \mathbb{E}[X]$.

Motivation & Ý nghĩa

Đây là một bài toán tổng hợp: từ việc xác định các đặc trưng moment đến việc sử dụng CRLB để khẳng định tính tối ưu của trung bình mẫu. Hàm mật độ này thực chất là một phân phối Gamma $\Gamma(3, \theta)$.

Chi tiết Toán học

1. Tính μ và σ^2 :

$$\mathbb{E}[X] = \int_0^\infty x \cdot \frac{1}{2} \theta^3 x^2 e^{-\theta x} dx = \frac{\theta^3}{2} \int_0^\infty x^3 e^{-\theta x} dx = \frac{\theta^3}{2} \cdot \frac{3!}{\theta^4} = \frac{3}{\theta}$$

$$\mathbb{E}[X^2] = \frac{\theta^3}{2} \int_0^\infty x^4 e^{-\theta x} dx = \frac{\theta^3}{2} \cdot \frac{4!}{\theta^5} = \frac{12}{\theta^2}$$

$$\sigma^2 = \text{Var}(X) = \frac{12}{\theta^2} - \left(\frac{3}{\theta} \right)^2 = \frac{3}{\theta^2}$$

2. Kỳ vọng và phương sai của $\bar{X}_n$:

$$\mathbb{E}[\bar{X}_n] = \mathbb{E}[X] = \frac{3}{\theta}, \quad \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n} = \frac{3}{n\theta^2}$$

3. Tính không chệch: Vì $\mathbb{E}[\bar{X}_n] = \mu$, nên $\bar{X}_n$ là ước lượng không chệch của μ .

4. CRLB và UMVUE: Tìm lượng tin Fisher $I(\theta)$:

$$\ln f = \ln(\theta^3/2) + 2 \ln x - \theta x \Rightarrow \frac{\partial^2 \ln f}{\partial \theta^2} = -\frac{3}{\theta^2}$$

$$I(\theta) = -\mathbb{E} \left[-\frac{3}{\theta^2} \right] = \frac{3}{\theta^2}$$

CRLB cho ước lượng không chệch của $\mu(\theta) = 3/\theta$:

$$CRLB = \frac{[\mu'(\theta)]^2}{nI(\theta)} = \frac{(-3/\theta^2)^2}{n(3/\theta^2)} = \frac{9/\theta^4}{3n/\theta^2} = \frac{3}{n\theta^2}$$

Vì $\text{Var}(\bar{X}_n) = CRLB$, nên $\bar{X}_n$ là ước lượng không chệch tốt nhất (UMVUE).

Bài tập 3

Tìm hàm $g(\theta)$ sao cho tồn tại ước lượng đạt CRLB.

Motivation & Ý nghĩa

Hệ quả 3 (hay điều kiện đẳng thức trong BDT Cramer-Rao) chỉ ra rằng một ước lượng chỉ đạt được CRLB khi và chỉ khi đạo hàm của Log-likelihood có thể viết dưới dạng tuyến tính của sai số ước lượng. Ta sẽ dùng kỹ thuật này để "ngược dòng" tìm ra hàm $g(\theta)$ khả thi.

Chi tiết Toán học

1. $f(x | \theta) = \theta x^{\theta-1}, 0 < x < 1$.

$$\ln f = \ln \theta + (\theta - 1) \ln x \Rightarrow \frac{\partial \ln f}{\partial \theta} = \frac{1}{\theta} + \ln x = -(-\ln x - \frac{1}{\theta})$$

Biểu thức này có dạng $A(\theta)(W(X) - g(\theta))$ với $W(X) = -\ln X$, $A(\theta) = -1$ và $g(\theta) = 1/\theta$. Vậy tồn tại ước lượng đạt CRLB cho $g(\theta) = 1/\theta$, đó chính là $-\frac{1}{n} \sum \ln X_i$.

2. $f(x | \theta) = \frac{\log \theta}{\theta-1} \theta^x, 0 < x < 1$.

$$\ln f = \ln(\ln \theta) - \ln(\theta - 1) + x \ln \theta$$

Lấy đạo hàm theo θ :

$$\frac{\partial \ln f}{\partial \theta} = \frac{1}{\theta \ln \theta} - \frac{1}{\theta - 1} + \frac{x}{\theta} = \frac{1}{\theta} \left[x - \left(\frac{\theta}{\theta - 1} - \frac{1}{\ln \theta} \right) \right]$$

Biểu thức này có dạng $\frac{1}{\theta}(X - g(\theta))$. Vậy tồn tại ước lượng đạt CRLB cho hàm:

$$g(\theta) = \frac{\theta}{\theta - 1} - \frac{1}{\ln \theta}$$

Ước lượng đó chính là trung bình mẫu $\bar{X}$.

2 Kiểm định Giả thuyết: Khái niệm cơ bản và Hàm độ mạnh

Ví dụ 1 & 2

Xác định cấu trúc giả thuyết cho các bài toán về huyết áp và tỷ lệ sản phẩm lỗi.

Motivation & Ý nghĩa

Bước đầu tiên và quan trọng nhất của Testing là thiết lập cặp giả thuyết H_0 (Null Hypothesis) và H_1 (Alternative Hypothesis).

- H_0 thường đại diện cho trạng thái "hiện trạng" (status quo) hoặc không có sự thay đổi.
- H_1 là giả thuyết mà chúng ta thực sự muốn tìm kiếm bằng chứng để ủng hộ.

Việc chọn kiểm định một phía (One-sided) hay hai phía (Two-sided) phụ thuộc vào mục tiêu nghiên cứu: chỉ quan tâm đến sự thay đổi theo một hướng nhất định hay quan tâm đến sự khác biệt nói chung.

Chi tiết Toán học

1. **Ví dụ 1:** Kiểm định hai phía (Two-tailed test).

$$H_0 : \theta = 0 \quad \text{vs} \quad H_1 : \theta \neq 0$$

Không gian tham số được chia thành $\Theta_0 = \{0\}$ và $\Theta_1 = \mathbb{R} \setminus \{0\}$.

2. **Ví dụ 2:** Kiểm định một phía (One-tailed test).

$$H_0 : \theta \leq \theta_0 \quad \text{vs} \quad H_1 : \theta > \theta_0$$

Đây là bài toán kiểm soát rủi ro phía trên (upper-tail), nơi ta chỉ bác bỏ H_0 nếu bằng chứng cho thấy tỷ lệ lỗi vượt ngưỡng cho phép.

Ví dụ 3

So sánh hai kiểm định R_1 và R_2 cho $X_i \sim B(p), n = 3$.

Motivation & Ý nghĩa

Ví dụ này minh họa sự đánh đổi (trade-off) trong thống kê. Khi ta mở rộng miền bác bỏ (từ R_1 sang R_2), ta sẽ dễ dàng bác bỏ H_0 hơn. Điều này làm tăng xác suất sai lầm loại I (bác bỏ sai H_0) nhưng lại làm tăng độ mạnh của kiểm định (khả năng phát hiện H_1 đúng).

Chi tiết Toán học

Xét $T = \sum_{i=1}^3 X_i \sim \text{Binomial}(3, p)$.

1. **Kiểm định 1 (R_1):** Bác bỏ khi $T = 3$.

$$\beta_1(p) = P(T = 3 \mid p) = p^3$$

2. **Kiểm định 2 (R_2):** Bác bỏ khi $T \geq 2$.

$$\beta_2(p) = P(T \geq 2 \mid p) = \binom{3}{2} p^2(1-p) + p^3 = 3p^2 - 2p^3$$

3. **Nhận xét:** Với mọi $p \in (0, 1)$, ta luôn có $3p^2 - 2p^3 > p^3$ (tương đương $3p^2(1-p) > 0$). Vậy R_2 luôn "nhạy" hơn nhưng cũng dễ mắc sai lầm loại I hơn R_1 tại biên $p = 0.5$.

Ví dụ 4

Phân tích miền bác bỏ $R = \{\mathbf{x} : \frac{\bar{x}}{s_x/\sqrt{n}} > 3\}$.

Motivation & Ý nghĩa

Đây là cấu trúc của một kiểm định t (Student's t-test) một phía. Thống kê $T(\mathbf{X}) = \frac{\bar{X}}{S/\sqrt{n}}$ đo

lượng khoảng cách từ trung bình mẫu đến giả thuyết null theo đơn vị sai số chuẩn (Standard Error). Con số 3 đóng vai trò là giá trị tới hạn (Critical Value).

Chi tiết Toán học

1. Thống kê kiểm định: $T = \frac{\bar{X}}{S/\sqrt{n}}$.
2. Nếu n đủ lớn, theo Định lý giới hạn trung tâm (CLT), $T \xrightarrow{d} N(0, 1)$ dưới H_0 .
3. Với $c = 3$, xác suất sai lầm loại I (Significance level) là $P(T > 3 \mid \theta = 0) \approx 0.0013$. Đây là một kiểm định rất khắt khe đối với H_1 .

Ví dụ 5

Tính toán cho $B(\theta)$, $n = 5$ với miền bác bỏ $R = \{\sum X_i = 5\}$.

Motivation & Ý nghĩa

Hàm độ mạnh $\beta(\theta)$ là công cụ vạn năng để đánh giá một kiểm định. Nó cho biết xác suất bác bỏ H_0 tại mỗi giá trị của θ . Một kiểm định lý tưởng sẽ có $\beta(\theta)$ thấp trên miền H_0 và cao trên miền H_1 .

Chi tiết Toán học

Đặt $T = \sum X_i \sim \text{Binomial}(5, \theta)$.

1. **Hàm độ mạnh:** $\beta(\theta) = P(T = 5 \mid \theta) = \theta^5$.
2. **Sai lầm loại I (Type I Error):** Xảy ra khi $\theta \in \Theta_0 = [0, 0.5]$. Xác suất lớn nhất (Size of test): $\alpha = \sup_{\theta \leq 0.5} \beta(\theta) = (0.5)^5 = 0.03125$.
3. **Sai lầm loại II (Type II Error):** Xảy ra khi $\theta \in \Theta_1 = (0.5, 1]$. Tại $\theta = 2/3$: $P(\text{Type II}) = 1 - \beta(2/3) = 1 - (2/3)^5 = 1 - \frac{32}{243} \approx 0.868$. *Nhận xét:* Kiểm định này có độ mạnh rất thấp (chỉ khoảng 13% khả năng phát hiện $\theta = 2/3$).

Ví dụ 6

Tính toán cho $B(\theta)$, $n = 5$ với miền bác bỏ $R = \{\sum X_i \geq 3\}$.

Motivation & Ý nghĩa

Bằng cách hạ thấp tiêu chuẩn bác bỏ (từ $T = 5$ xuống $T \geq 3$), chúng ta làm tăng sức mạnh phát hiện H_1 , nhưng cái giá phải trả là sự gia tăng đột biến của sai lầm loại I.

Chi tiết Toán học

1. **Hàm độ mạnh:**

$$\beta(\theta) = P(T \geq 3 \mid \theta) = \binom{5}{3}\theta^3(1-\theta)^2 + \binom{5}{4}\theta^4(1-\theta) + \binom{5}{5}\theta^5$$

2. **Size of test:** Vì $\beta(\theta)$ đồng biến theo θ , giá trị lớn nhất trên Θ_0 đạt tại $\theta = 0.5$:

$$\alpha = \beta(0.5) = \frac{1}{2^5} \left(\binom{5}{3} + \binom{5}{4} + \binom{5}{5} \right) = \frac{10 + 5 + 1}{32} = 0.5$$

3. **Sai lầm loại II tại $\theta = 2/3$:**

$$\beta(2/3) = 10(2/3)^3(1/3)^2 + 5(2/3)^4(1/3) + (2/3)^5 = \frac{80 + 80 + 32}{243} = \frac{192}{243} \approx 0.79$$

$$\Rightarrow P(\text{Type II}) = 1 - 0.79 = 0.21$$

4. **So sánh:** So với ví dụ 5, kiểm định này mạnh hơn nhiều (0.79 vs 0.13) nhưng mức ý nghĩa lại quá tệ (0.5 vs 0.03).

Ví dụ 7

Xét $X_1, \dots, X_n$ i.i.d. $\sim N(\mu, \sigma^2)$ (σ^2 đã biết). Kiểm định $H_0 : \mu \leq \mu_0, H_1 : \mu > \mu_0$.

Motivation & Ý nghĩa

LRT là một phương pháp tổng quát để xây dựng miền bác bỏ bằng cách so sánh "khả năng tối đa" dưới giả thuyết null (Θ_0) so với toàn bộ không gian tham số (Θ). Nếu tỷ lệ này quá nhỏ, chúng ta có dữ liệu ủng hộ H_1 mạnh mẽ hơn nhiều so với H_0 .

Chi tiết Toán học

1. Thống kê LRT: $\lambda(\mathbf{x}) = \frac{\sup_{\mu \leq \mu_0} L(\mu)}{\sup_{\mu \in \mathbb{R}} L(\mu)}$.
2. MLE toàn cục là $\hat{\mu} = \bar{x}$.
 - Nếu $\bar{x} \leq \mu_0$, tử số và mẫu số bằng nhau $\Rightarrow \lambda(\mathbf{x}) = 1$.
 - Nếu $\bar{x} > \mu_0$, tử số đạt cực đại tại biên $\mu = \mu_0$, mẫu số tại $\bar{x}$.
3. Miền bác bỏ $\lambda(\mathbf{x}) < k$ tương đương với $\bar{x} > c$. Chuẩn hóa ta được:

$$R = \left\{ \mathbf{x} : \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} > z_\alpha \right\}$$

4. Hàm độ mạnh: $\beta(\mu) = P\left(Z > z_\alpha + \frac{\mu_0 - \mu}{\sigma/\sqrt{n}}\right) = \Phi\left(\frac{\mu - \mu_0}{\sigma/\sqrt{n}} - z_\alpha\right)$.

Ví dụ 8

Tung đồng xu 5 lần. Kiểm định $H_0 : p \leq 0.5, H_1 : p > 0.5$. Tìm K nguyên bé nhất để cỡ kiểm định là 0.05.

Motivation & Ý nghĩa

Trong các phân phối rời rạc như Binomial, LRT thường dẫn đến miền bác bỏ dựa trên thống kê đủ (tổng số mặt hình). Tuy nhiên, do tính rời rạc, ta không luôn có được mức ý nghĩa α chính xác mà phải chọn giá trị tối hạn sao cho mức thực tế $\leq \alpha$.

Chi tiết Toán học

1. Thống kê kiểm định: $T = \sum X_i \sim \text{Binomial}(5, p)$. Miền bác bỏ: $T \geq K$.
2. Dưới H_0 , $\beta(p)$ đạt cực đại tại $p = 0.5$. Ta cần:

$$P(T \geq K \mid p = 0.5) \leq 0.05$$

3. Tra bảng Binomial ($n = 5, p = 0.5$):
 - $P(T \geq 4) = \binom{5}{4}0.5^5 + \binom{5}{5}0.5^5 = \frac{6}{32} = 0.1875 > 0.05$.
 - $P(T = 5) = 0.5^5 = \frac{1}{32} = 0.03125 < 0.05$.
4. Vậy $K = 5$. Miền bác bỏ là $\{\mathbf{x} : \sum x_i = 5\}$.

Ví dụ 9

Xét $X_i \sim e^{-(x-\theta)} \mathbb{I}_{[\theta, \infty)}(x)$. Kiểm định $H_0 : \theta \leq 0, H_1 : \theta > 0$.

Motivation & Ý nghĩa

Đây là một ví dụ về phân phối không chính quy (non-regular). MLE của θ là $X_{(1)}$ (thống kê thứ tự nhỏ nhất). LRT ở đây sẽ dựa trên giá trị nhỏ nhất này thay vì trung bình mẫu.

Chi tiết Toán học

1. Hàm Likelihood: $L(\theta) = e^{-\sum x_i + n\theta} \mathbb{I}(X_{(1)} \geq \theta)$.
2. $\lambda(\mathbf{x}) = \frac{\sup_{\theta \leq 0} L(\theta)}{\sup_{\theta \in \mathbb{R}} L(\theta)}$. MLE $\hat{\theta} = X_{(1)}$.

- Nếu $X_{(1)} \leq 0, \lambda = 1$.
- Nếu $X_{(1)} > 0, \lambda = \frac{L(0)}{L(X_{(1)})} = \frac{e^{-\sum x_i}}{e^{-\sum x_i - nX_{(1)}}} = e^{-nX_{(1)}}$.

3. Miền bác bỏ $\lambda < k \iff e^{-nX_{(1)}} < k \iff X_{(1)} > C$.

4. **Cỡ kiểm định:** Tại $\theta = 0, X_{(1)}$ có mật độ $f_{X_{(1)}}(x) = ne^{-nx}$.

$$\alpha = P(X_{(1)} > C \mid \theta = 0) = \int_C^\infty ne^{-nx} dx = e^{-nC}$$

$$\Rightarrow C = -\frac{\ln \alpha}{n}$$

Ví dụ 10

Kiểm định hai phía $H_0 : \mu = \mu_0$ trong $N(\mu, \sigma^2)$ dùng thống kê đủ.

Motivation & Ý nghĩa

Với bài toán hai phía, LRT sẽ không dẫn đến miền bác bỏ một bên mà dẫn đến miền bác bỏ "đều hai bên". Thống kê đủ $\bar{X}$ chứa toàn bộ thông tin cần thiết, giúp đơn giản hóa việc xây dựng tỷ lệ hợp lý.

Chi tiết Toán học

1. $\lambda(\mathbf{x}) = \frac{L(\mu_0)}{L(\bar{x})} = \frac{\exp[-\frac{1}{2\sigma^2} \sum (x_i - \mu_0)^2]}{\exp[-\frac{1}{2\sigma^2} \sum (x_i - \bar{x})^2]} = \exp\left[-\frac{n}{2\sigma^2} (\bar{x} - \mu_0)^2\right]$.
2. $\lambda(\mathbf{x}) < k \iff \frac{n}{2\sigma^2} (\bar{x} - \mu_0)^2 > -\ln k$.
3. Miền bác bỏ: $\left\{ \mathbf{x} : \frac{|\bar{x} - \mu_0|}{\sigma/\sqrt{n}} > z_{\alpha/2} \right\}$.

Ví dụ 11

Chứng minh kiểm định $H_0 : \mu \leq \mu_0$ vs $H_1 : \mu > \mu_0$ là không chệch (unbiased).

Motivation & Ý nghĩa

Một kiểm định được gọi là không chệch nếu độ mạnh của nó trên miền H_1 luôn lớn hơn hoặc bằng cỡ của kiểm định (α). Điều này đảm bảo kiểm định có khả năng bác bỏ H_0 khi H_1 đúng tốt hơn là khi H_0 đúng.

Chi tiết Toán học

1. Hàm độ mạnh $\beta(\mu) = \Phi\left(\frac{\mu - \mu_0}{\sigma/\sqrt{n}} - z_\alpha\right)$.
2. Xét đạo hàm theo μ : $\beta'(\mu) = \phi(\dots) \cdot \frac{1}{\sigma/\sqrt{n}} > 0$.
3. Vì $\beta(\mu)$ là hàm đồng biến:
 - Với $\mu \in \Theta_0$ ($\mu \leq \mu_0$): $\beta(\mu) \leq \beta(\mu_0) = \alpha$.
 - Với $\mu \in \Theta_1$ ($\mu > \mu_0$): $\beta(\mu) > \beta(\mu_0) = \alpha$.
4. Vậy $\beta(\mu) \geq \alpha$ với mọi $\mu \in \Theta_1$, kiểm định không chệch.

Ví dụ 12

Tìm kiểm định UMP mức α cho $X \sim B(2, \theta)$, $H_0 : \theta = 1/2$ vs $H_1 : \theta = 3/4$.

Motivation & Ý nghĩa

Định lý Neyman-Pearson chỉ ra rằng kiểm định mạnh nhất giữa hai giả thuyết đơn được xây dựng bằng cách so sánh tỷ số hợp lý tại từng điểm dữ liệu. Ta sắp xếp dữ liệu theo thứ tự "ủng hộ H_1 tăng dần" và đưa vào miền bác bỏ cho đến khi đạt mức α .

Chi tiết Toán học

1. Tính tỷ số $R(x) = \frac{f(x|1/2)}{f(x|3/4)}$ cho $x \in \{0, 1, 2\}$:

- $x = 0 : R(0) = \frac{(1/2)^2}{(1/4)^2} = 4.$
- $x = 1 : R(1) = \frac{2(1/2)(1/2)}{2(3/4)(1/4)} = \frac{1/2}{3/8} = \frac{4}{3} \approx 1.33.$
- $x = 2 : R(2) = \frac{(1/2)^2}{(3/4)^2} = \frac{1/4}{9/16} = \frac{4}{9} \approx 0.44.$

2. Thứ tự ưu tiên bác bỏ (từ $R(x)$ nhỏ nhất): $x = 2$ trước, rồi đến $x = 1$, cuối cùng là $x = 0$.

3. Ví dụ nếu $\alpha = 0.25$: $P(X = 2 | \theta = 1/2) = \binom{2}{2}(1/2)^2 = 0.25$. Vậy miền bác bỏ là $R = \{2\}$.

Ví dụ 13 & 14

Xét X_i i.i.d. $\sim N(\theta, \sigma^2)$, kiểm định $H_0 : \theta = \theta_0$ vs $H_1 : \theta = \theta_1$ ($\theta_1 > \theta_0$).

Motivation & Ý nghĩa

Định lý Neyman-Pearson khẳng định rằng đối với các giả thuyết đơn (simple vs simple), kiểm định mạnh nhất (MP) luôn có dạng tỷ số hợp lý. Khi sử dụng thống kê đủ $\bar{X}$, bài toán trở nên đơn giản hơn vì tỷ số hợp lý trở thành một hàm đơn điệu của $\bar{X}$. Điều này đặt nền móng cho việc mở rộng sang giả thuyết phức (UMP).

Chi tiết Toán học

1. Tỷ số hợp lý (Likelihood Ratio):

$$\frac{L(\theta_1)}{L(\theta_0)} = \frac{\exp[-\frac{1}{2\sigma^2} \sum (x_i - \theta_1)^2]}{\exp[-\frac{1}{2\sigma^2} \sum (x_i - \theta_0)^2]} = \exp \left[\frac{\theta_1 - \theta_0}{\sigma^2} \sum x_i - \frac{n(\theta_1^2 - \theta_0^2)}{2\sigma^2} \right]$$

2. Miền bác bỏ: Vì $\theta_1 > \theta_0$, tỷ số này đồng biến theo $\sum x_i$. Do đó, miền bác bỏ MP mức α là:

$$R = \left\{ \mathbf{x} : \sum x_i > C \right\} \iff \left\{ \mathbf{x} : \frac{\bar{x} - \theta_0}{\sigma/\sqrt{n}} > z_\alpha \right\}$$

3. **Lưu ý:** Vì miền bác bỏ này không phụ thuộc vào giá trị cụ thể của θ_1 (chỉ cần $\theta_1 > \theta_0$), nó cũng chính là kiểm định UMP cho $H_1 : \theta > \theta_0$.

Ví dụ 15

Kiểm định $H_0 : \theta \leq \theta_0, H_1 : \theta > \theta_0$ cho phân phối mũ dịch chuyển $f(x|\theta) = e^{-(x-\theta)} \mathbb{I}_{[\theta, \infty)}(x)$.

Motivation & Ý nghĩa

Đây là một họ phân phối có tính chất tỷ số hợp lý đơn điệu (MLR) theo thống kê thứ tự $X_{(1)}$. Trong các mô hình không chính quy (non-regular), UMP thường dựa trên các cực trị của mẫu thay vì trung bình mẫu.

Chi tiết Toán học

1. Tỷ số hợp lý cho $\theta' > \theta$:

$$\frac{L(\theta')}{L(\theta)} = \frac{e^{n\theta'} \mathbb{I}(x_{(1)} \geq \theta')}{e^{n\theta} \mathbb{I}(x_{(1)} \geq \theta)} = e^{n(\theta' - \theta)} \frac{\mathbb{I}(x_{(1)} \geq \theta')}{\mathbb{I}(x_{(1)} \geq \theta)}$$

2. Nhận xét: Tỷ số này là hàm không giảm theo $x_{(1)}$.

3. Miền bác bỏ UMP: Theo định lý Karlin-Rubin, miền bác bỏ có dạng $X_{(1)} > C$.

4. Với cỡ α : $P(X_{(1)} > C | \theta_0) = \alpha \Rightarrow e^{-n(C-\theta_0)} = \alpha \Rightarrow C = \theta_0 - \frac{\ln \alpha}{n}$.

Ví dụ 16 & 17

Tìm kiểm định UMP cho tham số vị trí θ và tham số quy mô σ^2 trong phân phối chuẩn.

Motivation & Ý nghĩa

Họ phân phối lũy thừa (Exponential Family) như phân phối chuẩn luôn có tính chất MLR. Điều này cho phép ta xây dựng kiểm định UMP một phía cho bất kỳ tham số nào của nó thông qua thống kê đủ đầy đủ.

Chi tiết Toán học

1. Với θ : Thống kê đủ là $\bar{X}$.

- $H_1 : \theta > \theta_0 \Rightarrow R = \{\bar{X} > \theta_0 + z_\alpha \sigma / \sqrt{n}\}.$
- $H_1 : \theta < \theta_0 \Rightarrow R = \{\bar{X} < \theta_0 - z_\alpha \sigma / \sqrt{n}\}.$

2. Với σ^2 : Thống kê đủ là $T = \sum (X_i - \mu)^2$. Dưới H_0 , $T/\sigma_0^2 \sim \chi_n^2$. Miền bác bỏ UMP cho $H_1 : \sigma^2 > \sigma_0^2$ là:

$$R = \left\{ \mathbf{x} : \sum (x_i - \mu)^2 > \sigma_0^2 \chi_{\alpha, n}^2 \right\}$$

Ví dụ 18 & 19

Tìm LRT và p-giá trị cho kiểm định trung bình phân phối chuẩn.

Motivation & Ý nghĩa

p-giá trị là mức ý nghĩa nhỏ nhất mà tại đó dữ liệu quan sát được dẫn đến việc bác bỏ H_0 . Nó cung cấp một cái nhìn liên tục về bằng chứng chống lại H_0 thay vì chỉ là quyết định "đúng/sai" nhị phân.

Chi tiết Toán học

Xét thống kê chuẩn hóa $Z = \frac{\bar{X} - \theta_0}{\sigma / \sqrt{n}}$. Giả sử giá trị quan sát được là z_{obs} .

1. Kiểm định hai phía ($H_1 : \theta \neq \theta_0$):

$$p\text{-value} = P(|Z| > |z_{obs}| \mid H_0) = 2(1 - \Phi(|z_{obs}|))$$

2. Kiểm định một phía ($H_1 : \theta > \theta_0$):

$$p\text{-value} = P(Z > z_{obs} \mid H_0) = 1 - \Phi(z_{obs})$$

3. LRT: LRT cỡ α cho bài toán hai phía dẫn đến miền bác bỏ $|Z| > z_{\alpha/2}$, tương đương với $p\text{-value} < \alpha$.

Ví dụ 20

Kiểm định so sánh hai tỷ lệ $p_1 = p_2$ vs $p_1 > p_2$.

Motivation & Ý nghĩa

Đây là bài toán so sánh hai quần thể độc lập. Khi cỡ mẫu lớn, ta sử dụng xấp xỉ chuẩn cho hiệu hai tỷ lệ mẫu. p-giá trị được tính dựa trên giả định rằng nếu H_0 đúng, sự khác biệt quan sát được chỉ là do ngẫu nhiên.

Chi tiết Toán học

1. Thống kê kiểm định (Z-test):

$$Z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1-\hat{p})(\frac{1}{n_1} + \frac{1}{n_2})}}$$

với $\hat{p} = \frac{x_1 + x_2}{n_1 + n_2}$ là tỷ lệ gộp (pooled proportion).

2. p-giá trị có hiệu lực: $p = 1 - \Phi(z_{obs})$.

3. Nếu mẫu nhỏ, ta sử dụng kiểm định chính xác Fisher (Fisher's Exact Test) dựa trên phân phối siêu bội (Hypergeometric).

Bài tập 1

Xét $X_i \sim N(\theta, \sigma^2)$, kiểm định $H_0 : \theta = \theta_0$ vs $H_1 : \theta \neq \theta_0$ bác bỏ khi $|Z| > c$ với $Z = \frac{\bar{X} - \theta_0}{\sigma/\sqrt{n}}$.

Motivation & Ý nghĩa

Đây là bài toán thiết kế thực nghiệm (Experimental Design). Chúng ta không chỉ thực hiện kiểm định mà còn phải xác định cỡ mẫu (n) và giá trị tới hạn (c) để đồng thời kiểm soát cả hai loại sai lầm: Sai lầm loại I (α) và Sai lầm loại II (β).

Chi tiết Toán học

1. Tìm hàm độ mạnh:

$$\beta(\theta) = P_\theta \left(\frac{\bar{X} - \theta_0}{\sigma/\sqrt{n}} > c \text{ hoặc } \frac{\bar{X} - \theta_0}{\sigma/\sqrt{n}} < -c \right)$$

Biến đổi về biến chuẩn tắc $Z = \frac{\bar{X} - \theta}{\sigma/\sqrt{n}} \sim N(0, 1)$:

$$\beta(\theta) = P \left(Z > c + \frac{\theta_0 - \theta}{\sigma/\sqrt{n}} \right) + P \left(Z < -c + \frac{\theta_0 - \theta}{\sigma/\sqrt{n}} \right)$$

$$\beta(\theta) = 1 - \Phi \left(c + \frac{\theta_0 - \theta}{\sigma/\sqrt{n}} \right) + \Phi \left(-c + \frac{\theta_0 - \theta}{\sigma/\sqrt{n}} \right)$$

2. Xác định n và c :

- Sai lầm loại I = 0.05 $\Rightarrow \beta(\theta_0) = \alpha \Rightarrow 2(1 - \Phi(c)) = 0.05 \Rightarrow \Phi(c) = 0.975 \Rightarrow c = 1.96$.
- Sai lầm loại II tại $\theta = \theta_0 + \sigma$ là 0.25 $\Rightarrow \text{Power } \beta(\theta_0 + \sigma) = 0.75$.

$$\beta(\theta_0 + \sigma) \approx 1 - \Phi \left(1.96 + \frac{-\sigma}{\sigma/\sqrt{n}} \right) = 1 - \Phi(1.96 - \sqrt{n}) = 0.75$$

$$\Rightarrow \Phi(1.96 - \sqrt{n}) = 0.25 \Rightarrow 1.96 - \sqrt{n} = z_{0.25} = -0.67$$

$$\sqrt{n} = 1.96 + 0.67 = 2.63 \Rightarrow n \approx 7$$

Bài tập 2

Tìm LRT cho $H_0 : \theta = \mu$ vs $H_1 : \theta \neq \mu$ với $X_i \sim \text{Exp}(\theta)$, $Y_j \sim \text{Exp}(\mu)$.

Motivation & Ý nghĩa

Bài toán so sánh hai tham số tỉ lệ (rate parameters). LRT giúp ta xác định xem liệu sự khác biệt giữa hai trung bình mẫu có đủ lớn để bác bỏ giả thuyết rằng chúng đến từ cùng một nguồn hay không.

Chi tiết Toán học

- Likelihood dưới H_1 : $L(\theta, \mu) = \theta^n e^{-\theta \sum x_i} \mu^m e^{-\mu \sum y_j}$. MLE: $\hat{\theta} = \frac{n}{\sum x_i}$, $\hat{\mu} = \frac{m}{\sum y_j}$.
- Likelihood dưới H_0 ($\theta = \mu = \omega$): $L(\omega) = \omega^{n+m} e^{-\omega(\sum x_i + \sum y_j)}$. MLE: $\hat{\omega} = \frac{n+m}{\sum x_i + \sum y_j}$.
- Tỷ số hợp lý:

$$\lambda = \frac{L(\hat{\omega})}{L(\hat{\theta}, \hat{\mu})} = \frac{\hat{\omega}^{n+m}}{\hat{\theta}^n \hat{\mu}^m} = \frac{(n+m)^{n+m}}{n^n m^m} \left(\frac{\sum x_i}{\sum x_i + \sum y_j} \right)^n \left(\frac{\sum y_j}{\sum x_i + \sum y_j} \right)^m$$

- Đặt $T = \frac{\sum X_i}{\sum X_i + \sum Y_j}$. Ta có $\lambda = \text{const} \cdot T^n (1-T)^m$. Kiểm định bác bỏ khi $\lambda < k$, tương đương với T quá lớn hoặc quá bé.

Bài tập 1

Tung đồng xu 1000 lần (560 H, 440 T). Kiểm định đồng xu cân đối ($p = 0.5$).

Chi tiết Toán học

Sử dụng xấp xỉ chuẩn cho tỷ lệ: $Z = \frac{\hat{p}-p_0}{\sqrt{p_0(1-p_0)/n}} = \frac{0.56-0.5}{\sqrt{0.5^2/1000}} = \frac{0.06}{0.0158} \approx 3.8$. Vì $|Z| > 1.96$ (mức 0.05), ta bác bỏ H_0 . Kết luận: Đồng xu không cân đối.

Bài tập 2

Poisson: $\lambda_0 = 15$. Năm nay $X = 10$. Kiểm định $H_0 : \lambda = 15$ vs $H_1 : \lambda < 15$.

Chi tiết Toán học

p-giá trị: $P(X \leq 10 \mid \lambda = 15) = \sum_{k=0}^{10} \frac{e^{-15} 15^k}{k!} \approx 0.1185$. Vì p -value > 0.05 , ta chưa đủ bằng chứng để bác bỏ H_0 . Không thể khẳng định số vụ tai nạn đã giảm.

Bài tập 3

Phân phối Pareto $f(x \mid \theta, \nu) = \frac{\theta \nu^\theta}{x^{\theta+1}} \mathbb{I}_{[\nu, \infty)}(x)$.

Motivation & Ý nghĩa

Đây là một ví dụ nâng cao về LRT cho phân phối có tham số vị trí (ν) và tham số hình dạng (θ). Ta cần kết hợp MLE tại biên và MLE bằng đạo hàm.

Chi tiết Toán học

1. **Tìm MLE:** - Với ν : L đồng biến theo ν trên $(0, X_{(1)}]$, nên $\hat{\nu} = X_{(1)}$. - Với θ : $\ln L = n \ln \theta + n \ln \nu - (\theta + 1) \sum \ln x_i$. $\frac{\partial \ln L}{\partial \theta} = \frac{n}{\theta} + n \ln \hat{\nu} - \sum \ln x_i = 0 \Rightarrow \hat{\theta} = \frac{n}{\sum \ln(x_i/X_{(1)})}$.
2. **Tìm LRT:** $H_0 : \theta = 1$ (ν tự do $\Rightarrow \hat{\nu}_0 = X_{(1)}$).

$$\lambda = \frac{L(1, X_{(1)})}{L(\hat{\theta}, X_{(1)})} = \frac{1^n X_{(1)}^n / \prod X_i^2}{\hat{\theta}^n X_{(1)}^{n\hat{\theta}} / \prod X_i^{\hat{\theta}+1}} = \frac{1}{\hat{\theta}^n} \left(\frac{\prod X_i}{X_{(1)}^n} \right)^{\hat{\theta}-1}$$

Đặt $T = \sum \ln(X_i/X_{(1)})$, ta có $\hat{\theta} = n/T$. Thay vào λ :

$$\lambda = \left(\frac{T}{n} \right)^n e^{T(n/T-1)} = \left(\frac{T}{n} e^{1-T/n} \right)^n$$

Hàm $g(t) = te^{1-t}$ đạt cực đại tại $t = 1$. $\lambda < k$ tương đương với T/n quá lớn hoặc quá bé. Vậy miền bác bỏ có dạng $\{T \leq c_1 \text{ hoặc } T \geq c_2\}$.

3 Thống kê đủ (Sufficient Statistics) và Định lý Tách

Ví dụ 1

Xét $X_1, \dots, X_n$ i.i.d. $\sim B(\theta)$. Chứng tỏ $T = \sum X_i$ là thống kê đủ cho θ .

Motivation & Ý nghĩa

Thống kê đủ (Sufficient Statistic) là một "bản tóm tắt" dữ liệu mà không làm mất bất kỳ thông tin nào về tham số θ . Trong phân phối Bernoulli, thay vì phải nhớ cả chuỗi 0 và 1, ta chỉ cần biết tổng số lần thành công. Định lý Tách (Fisher-Neyman Factorization Theorem) là công cụ mạnh nhất để kiểm tra điều này mà không cần tính phân phối điều kiện phức tạp.

Chi tiết Toán học

- Viết hàm Likelihood cho mẫu ngẫu nhiên:

$$L(\theta | \mathbf{x}) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^{\sum x_i} (1 - \theta)^{n - \sum x_i}$$

- Biến đổi biểu thức:

$$L(\theta | \mathbf{x}) = \left[\left(\frac{\theta}{1 - \theta} \right)^{\sum x_i} (1 - \theta)^n \right] \cdot 1$$

- Áp dụng Định lý Tách: Đặt $T(\mathbf{x}) = \sum x_i$. Ta có $L(\theta | \mathbf{x}) = g(T(\mathbf{x}), \theta) \cdot h(\mathbf{x})$ với:

$$g(t, \theta) = \left(\frac{\theta}{1 - \theta} \right)^t (1 - \theta)^n, \quad h(\mathbf{x}) = 1$$

- Kết luận:** Vì Likelihood tách được thành tích của một hàm chỉ phụ thuộc vào T và θ , và một hàm chỉ phụ thuộc vào dữ liệu $\mathbf{x}$, nên $T = \sum X_i$ là thống kê đủ cho θ .

Ví dụ 2

Xét $X_1, \dots, X_n$ i.i.d. $\sim P(\lambda)$. Chứng tỏ $T = \sum X_i$ là thống kê đủ cho λ .

Motivation & Ý nghĩa

Tương tự như Bernoulli, phân phối Poisson thuộc họ hàm mũ (Exponential Family). Đặc điểm của họ này là tổng các quan sát thường mang toàn bộ thông tin của tham số tốc độ (rate parameter).

Chi tiết Toán học

- Hàm Likelihood:

$$L(\lambda | \mathbf{x}) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} = \frac{e^{-n\lambda} \lambda^{\sum x_i}}{\prod_{i=1}^n x_i!}$$

- Tách hàm:

$$L(\lambda | \mathbf{x}) = \underbrace{\left(e^{-n\lambda} \lambda^{\sum x_i} \right)}_{g(T(\mathbf{x}), \lambda)} \cdot \underbrace{\left(\frac{1}{\prod x_i!} \right)}_{h(\mathbf{x})}$$

- Kết luận:** Theo định lý tách, $T = \sum X_i$ là thống kê đủ cho λ .

Ví dụ 3

Xét $X_1, \dots, X_n$ i.i.d. $\sim N(\mu, \sigma^2)$ với σ^2 đã biết. Tìm thống kê đủ cho μ .

Motivation & Ý nghĩa

Trong phân phối chuẩn, vị trí của tâm (mean) được quyết định bởi giá trị trung bình. Ta sẽ chứng minh rằng tổng (hoặc trung bình) các giá trị quan sát là đủ để mô tả μ .

Chi tiết Toán học

1. Hàm Likelihood:

$$L(\mu | \mathbf{x}) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right)$$

2. Khai triển biểu thức trong hàm mũ:

$$\sum (x_i - \mu)^2 = \sum x_i^2 - 2\mu \sum x_i + n\mu^2$$

3. Thay ngược vào Likelihood:

$$L(\mu | \mathbf{x}) = \exp\left(\frac{\mu \sum x_i}{\sigma^2} - \frac{n\mu^2}{2\sigma^2}\right) \cdot \left[(2\pi\sigma^2)^{-n/2} \exp\left(-\frac{\sum x_i^2}{2\sigma^2}\right)\right]$$

4. **Kết luận:** Đặt $T = \sum X_i$. Phần chứa μ chỉ tương tác với dữ liệu thông qua T . Vậy $T = \sum X_i$ (hoặc $\bar{X}$) là thống kê đủ cho μ .

Ví dụ 4

Xét $X_1, \dots, X_n$ i.i.d. $\sim U([0, \theta])$. Tìm thống kê đủ cho θ .

Motivation & Ý nghĩa

Đây là bài toán về tham số biên (Support dependent parameter). Với phân phối đều từ 0 đến θ , thông tin quan trọng nhất về θ nằm ở giá trị lớn nhất mà ta quan sát được. Nếu ta biết giá trị lớn nhất là 10, thì chắc chắn $\theta \geq 10$.

Chi tiết Toán học

1. Hàm mật độ có sử dụng hàm chỉ thị: $f(x | \theta) = \frac{1}{\theta} 1_{\{0 \leq x \leq \theta\}}$.

2. Hàm Likelihood cho mẫu:

$$L(\theta | \mathbf{x}) = \frac{1}{\theta^n} \prod_{i=1}^n 1_{\{0 \leq x_i \leq \theta\}}$$

3. Nhận xét quan trọng: $\prod 1_{\{0 \leq x_i \leq \theta\}} = 1$ khi và chỉ khi $x_{\min} \geq 0$ và $x_{\max} \leq \theta$.

$$L(\theta | \mathbf{x}) = \frac{1}{\theta^n} 1_{\{\max(x_i) \leq \theta\}} \cdot 1_{\{\min(x_i) \geq 0\}}$$

4. **Kết luận:** Đặt $T = X_{(n)} = \max(X_1, \dots, X_n)$. Likelihood được tách thành $g(T, \theta) = \theta^{-n} 1_{\{T \leq \theta\}}$ và $h(\mathbf{x}) = 1_{\{x_{(1)} \geq 0\}}$. Vậy $X_{(n)}$ là thống kê đủ cho θ .

Ví dụ 5

Tính chất của thống kê đủ qua các hàm biến đổi.

Motivation & Ý nghĩa

Thống kê đủ không phải là duy nhất. Bất kỳ phép biến đổi 1-1 (bijective) nào của một thống kê đủ cũng tạo ra một thống kê đủ mới. Điều này cho phép các kỹ sư (Data Engineer/MLOps) lưu trữ dữ liệu dưới các định dạng khác nhau (ví dụ: tổng, trung bình, hoặc log-sum) mà vẫn giữ nguyên giá trị thông tin.

Chi tiết Toán học

- Nếu T là đủ cho θ và tồn tại hàm ψ sao cho $T = \psi(T^*)$ (với ψ là hàm 1-1), thì T^* cũng là thống kê đủ.
- Ví dụ: Trong $N(\mu, \sigma^2)$, $T_1 = \sum X_i$ là đủ $\Rightarrow T_2 = \bar{X} = T_1/n$ là đủ.

- Tương tự, $T_3 = \exp(T_1)$ cũng là đủ vì hàm e^x là hàm 1-1. Tuy nhiên, $T_4 = (\sum X_i)^2$ có thể không đủ nếu miền giá trị của $\sum X_i$ bao gồm cả số âm (do không còn là hàm 1-1).

Ví dụ 6

Xét $X_1, \dots, X_n$ i.i.d. $\sim \text{Beta}(\alpha, \beta)$ với α đã biết, β chưa biết.

1. Tìm thống kê đủ cho β .
2. Chứng tỏ $\tilde{T} = \frac{1}{n} \left(\sum \log \frac{1}{1-X_i} \right)^3$ cũng là thống kê đủ.

Motivation & Ý nghĩa

Ví dụ này củng cố tính chất: Mọi hàm 1-1 của một thống kê đủ đều là thống kê đủ. Trong thực tế Engineering, đôi khi ta không lưu trữ trực tiếp tổng $\sum X_i$ mà lưu trữ một hàm của nó (như log-transform) để ổn định phương sai hoặc phục vụ tính toán song song, nhưng thông tin về tham số vẫn được bảo toàn trọn vẹn.

Chi tiết Toán học

1. Hàm mật độ: $f(x | \beta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}$. Likelihood cho mẫu:

$$L(\beta | \mathbf{x}) = \left[\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \right]^n \left(\prod x_i \right)^{\alpha-1} \left(\prod (1-x_i) \right)^{\beta-1}$$

Tách hàm theo định lý Neyman:

$$g(T(\mathbf{x}), \beta) = \left[\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \right]^n \left(\prod (1-x_i) \right)^{\beta-1}, \quad h(\mathbf{x}) = \left(\prod x_i \right)^{\alpha-1}$$

Vậy $T = \prod (1-X_i)$ hoặc tương đương $T' = \sum \log(1-X_i)$ là thống kê đủ cho β .

2. Đặt $U = \sum \log \frac{1}{1-X_i} = -\sum \log(1-X_i)$. Vì $0 < X_i < 1$, nên $1-X_i \in (0, 1)$, suy ra $\log \frac{1}{1-X_i} > 0$. Hàm $f(u) = \frac{1}{n} u^3$ là hàm 1-1 trên miền $u > 0$. Do đó, $\tilde{T}$ là hàm 1-1 của thống kê đủ U , nên $\tilde{T}$ cũng là thống kê đủ.

Ví dụ 7 & 8

Xét $X_1, \dots, X_n$ i.i.d. $\sim N(\mu, \sigma^2)$, cả hai tham số đều chưa biết.

Motivation & Ý nghĩa

Khi số lượng tham số tăng lên, số lượng thống kê cần thiết để "tóm tắt" dữ liệu cũng tăng theo. Một bộ thống kê đủ cho $\theta = (\mu, \sigma^2)$ phải có khả năng mô tả cả vị trí (location) và độ phân tán (scale) của dữ liệu. Việc chuyển đổi giữa $(\sum X_i, \sum X_i^2)$ sang $(\bar{X}, S^2)$ là một phép biến đổi 1-1 rất phổ biến trong Data Science để dễ diễn giải kết quả.

Chi tiết Toán học

1. Hàm Likelihood:

$$\begin{aligned} L(\mu, \sigma^2 | \mathbf{x}) &= (2\pi\sigma^2)^{-n/2} \exp \left(-\frac{1}{2\sigma^2} \sum (x_i - \mu)^2 \right) \\ &= (2\pi\sigma^2)^{-n/2} \exp \left(-\frac{1}{2\sigma^2} \left[\sum x_i^2 - 2\mu \sum x_i + n\mu^2 \right] \right) \end{aligned}$$

2. Theo định lý tách, bộ $T = (\sum X_i, \sum X_i^2)$ là bộ thống kê đủ đồng thời cho (μ, σ^2) .
3. Vì $(\bar{X}, S^2)$ có thể tính được từ $(\sum X_i, \sum X_i^2)$ và ngược lại thông qua hệ phương trình 1-1:

$$\bar{X} = \frac{1}{n} \sum X_i, \quad S^2 = \frac{1}{n-1} \left(\sum X_i^2 - n\bar{X}^2 \right)$$

nên $(\bar{X}, S^2)$ cũng là bộ thống kê đủ.

Ví dụ 9

Chúng tỏ $T = (\sum X_i, \sum X_i^2)$ là thống kê đủ tối tiểu cho $N(\mu, \sigma^2)$.

Motivation & Ý nghĩa

Thống kê đủ tối tiểu (Minimal Sufficient Statistic) là thống kê đủ có "kích thước" nhỏ nhất, đại diện cho việc nén dữ liệu tối đa mà không mất thông tin. Ta sử dụng tiêu chuẩn tỷ số Likelihood: Tỷ số $L(\mathbf{x})/L(\mathbf{y})$ không phụ thuộc vào tham số khi và chỉ khi $T(\mathbf{x}) = T(\mathbf{y})$.

Chi tiết Toán học

1. Xét tỷ số Likelihood tại hai mẫu $\mathbf{x}$ và $\mathbf{y}$:

$$\frac{L(\mu, \sigma^2 | \mathbf{x})}{L(\mu, \sigma^2 | \mathbf{y})} = \exp \left(-\frac{1}{2\sigma^2} \left[(\sum x_i^2 - \sum y_i^2) - 2\mu(\sum x_i - \sum y_i) \right] \right)$$

2. Để tỷ số này không phụ thuộc vào (μ, σ^2) với mọi giá trị của chúng, các hệ số của $1/\sigma^2$ và μ/σ^2 trong hàm mũ phải bằng 0.
3. Điều này dẫn đến hệ phương trình:

$$\begin{aligned} \sum x_i^2 - \sum y_i^2 &= 0 \quad \text{và} \quad \sum x_i - \sum y_i = 0 \\ \iff (\sum x_i, \sum x_i^2) &= (\sum y_i, \sum y_i^2) \end{aligned}$$

4. Vậy $T(\mathbf{X}) = (\sum X_i, \sum X_i^2)$ là đủ tối tiểu.

Ví dụ 10

Xét $X_1, \dots, X_n$ i.i.d. $\sim U([0, \theta + 1])$. Chúng tỏ $T = (X_{(1)}, X_{(n)})$ là đủ tối tiểu.

Motivation & Ý nghĩa

Đây là một ví dụ kinh điển về việc thông tin của tham số θ bị "kẹp" giữa hai đầu của mẫu. Không giống như $U([0, \theta])$ chỉ cần $X_{(n)}$, ở đây do cả hai biên đều dịch chuyển theo θ , ta cần cả giá trị nhỏ nhất và lớn nhất.

Chi tiết Toán học

1. Hàm Likelihood: $L(\theta | \mathbf{x}) = 1_{\{\theta \leq x_{(1)} \leq x_{(n)} \leq \theta+1\}}$. Hàm này bằng 1 nếu $x_{(n)} - 1 \leq \theta \leq x_{(1)}$ và bằng 0 nếu ngược lại.
2. Xét tỷ số $L(\theta | \mathbf{x})/L(\theta | \mathbf{y})$. Để tỷ số này là hằng số (không phụ thuộc θ), các miền giá trị của θ làm cho Likelihood bằng 1 phải trùng nhau.
3. Tức là: $[x_{(n)} - 1, x_{(1)}] = [y_{(n)} - 1, y_{(1)}]$.
4. Điều này kéo theo $x_{(n)} = y_{(n)}$ và $x_{(1)} = y_{(1)}$.
5. Vậy $T = (X_{(1)}, X_{(n)})$ là đủ tối tiểu.

Ví dụ 11

Xét họ $f(x | \lambda) = P(\lambda)$ với $\lambda \in \{1, 2\}$. Chúng tỏ họ này không đầy đủ.

Motivation & Ý nghĩa

Tính đầy đủ (Completeness) đảm bảo rằng không tồn tại một hàm phi trị (non-trivial) của thống kê đủ nào có kỳ vọng bằng 0 với mọi θ . Nếu không gian tham số Θ quá "bé" (như ở đây chỉ có 2 điểm), nó sẽ không đủ sức "ép" hàm $g(T)$ phải bằng 0, dẫn đến việc mất tính đầy đủ.

Chi tiết Toán học

1. Điều kiện đầy đủ: $\mathbb{E}_\lambda[g(X)] = 0$ với $\lambda \in \{1, 2\}$ phải kéo theo $g(X) = 0$ hầu chắc chắn.

2. Ta có phương trình kỳ vọng:

$$\sum_{x=0}^{\infty} g(x) \frac{\lambda^x e^{-\lambda}}{x!} = 0 \iff \sum_{x=0}^{\infty} \frac{g(x)}{x!} \lambda^x = 0$$

3. Với $\lambda = 1$: $\sum \frac{g(x)}{x!} = 0$.

4. Với $\lambda = 2$: $\sum \frac{g(x)}{x!} 2^x = 0$.

5. Hệ này có vô số nghiệm phi trị cho $g(x)$ (ví dụ: chọn $g(x) = 0$ với mọi $x > 2$, ta còn 2 phương trình cho $g(0), g(1), g(2)$).

6. Vì tồn tại $g(x) \neq 0$ thỏa mãn $\mathbb{E}_\lambda[g(X)] = 0$, họ này **không đầy đủ**.

Ví dụ 12

Xét $X_1, \dots, X_n$ i.i.d. $\sim P(\lambda), \lambda > 0$. Chứng tỏ $T = \sum X_i$ là thống kê đầy đủ.

Motivation & Ý nghĩa

Ngược lại với ví dụ 11, khi λ có thể nhận bất kỳ giá trị dương nào, phương trình kỳ vọng trở thành một chuỗi lũy thừa (Power Series) bằng 0 trên một khoảng. Theo lý thuyết giải tích, các hệ số của chuỗi lũy thừa đó bắt buộc phải bằng 0.

Chi tiết Toán học

1. Ta biết $T = \sum X_i \sim P(n\lambda)$. Xét $\mathbb{E}_\lambda[g(T)] = 0$:

$$\sum_{t=0}^{\infty} g(t) \frac{(n\lambda)^t e^{-n\lambda}}{t!} = 0 \iff e^{-n\lambda} \sum_{t=0}^{\infty} \frac{g(t) n^t}{t!} \lambda^t = 0$$

2. Vì $e^{-n\lambda} > 0$, ta có $\sum_{t=0}^{\infty} a_t \lambda^t = 0$ với mọi $\lambda > 0$, trong đó $a_t = \frac{g(t) n^t}{t!}$.

3. Theo định lý về sự duy nhất của chuỗi lũy thừa, $a_t = 0$ với mọi t .

4. Suy ra $g(t) = 0$ với mọi t . Vậy T là thống kê đầy đủ.

Ví dụ 13

Xét $X_i \sim U([0, \theta])$. Tính $\mathbb{E}[X_{(1)}/X_{(n)}]$ và $\mathbb{E}[(X_{(1)} + X_{(2)})/X_{(n)}]$.

Motivation & Ý nghĩa

Đây là ứng dụng thực tế tuyệt vời của ****Định lý Basu****. Với phân phối đều $U([0, \theta])$, tham số θ là một tham số quy mô (scale parameter). Bất kỳ thống kê nào có dạng tỷ số "không đơn vị" (dimensionless) sẽ có phân phối không phụ thuộc vào θ (Ancillary statistic). Định lý Basu cho phép ta tách kỳ vọng của tích thành tích các kỳ vọng.

Chi tiết Toán học

1. $T = X_{(n)}$ là thống kê đủ đầy đủ cho θ .

2. $V_1 = X_{(1)}/X_{(n)}$ và $V_2 = (X_{(1)} + X_{(2)})/X_{(n)}$ là các thống kê phụ (ancillary) vì phân phối của chúng không phụ thuộc θ .

3. Theo định lý Basu, T độc lập với V_1 và V_2 . Do đó:

$$\begin{aligned} \mathbb{E}[X_{(1)}] &= \mathbb{E}[V_1 \cdot X_{(n)}] = \mathbb{E}[V_1] \cdot \mathbb{E}[X_{(n)}] \\ \Rightarrow \mathbb{E}\left[\frac{X_{(1)}}{X_{(n)}}\right] &= \frac{\mathbb{E}[X_{(1)}]}{\mathbb{E}[X_{(n)}]} \end{aligned}$$

4. Ta biết $\mathbb{E}[X_{(k)}] = \frac{k}{n+1}\theta$. Thay vào:

$$\mathbb{E}\left[\frac{X_{(1)}}{X_{(n)}}\right] = \frac{1/(n+1)}{n/(n+1)} = \frac{1}{n}$$

$$\mathbb{E}\left[\frac{X_{(1)} + X_{(2)}}{X_{(n)}}\right] = \frac{1/(n+1) + 2/(n+1)}{n/(n+1)} = \frac{3}{n}$$

Định lý Basu và Thống kê phụ

- **Thống kê phụ (Ancillary):** Là thống kê mà phân phối của nó hoàn toàn không chứa tham số θ . Ví dụ: $X_1 - X_2$ trong $N(\theta, 1)$, hoặc các tỷ số trong họ quy mô.
- **Định lý Basu:** Nếu T là đủ đầy đủ và V là phụ, thì $T \perp V$.
- **Ứng dụng trong $N(\mu, \sigma^2)$:** $\bar{X}$ là đủ đầy đủ cho μ , S^2 là phụ đối với μ (nhưng không phụ đối với σ^2). Theo Basu, $\bar{X}$ độc lập với S^2 . Đây là chứng minh ngắn gọn nhất cho tính độc lập của trung bình mẫu và phương sai mẫu trong phân phối chuẩn.

Họ hàm mũ (Exponential Family)

- Nếu phân phối thuộc họ hàm mũ chính quy: $f(x | \theta) = h(x)c(\theta) \exp(\sum w_i(\theta)t_i(x))$, thì $T = \sum t_i(X)$ luôn là thống kê đủ và đầy đủ. Điều này giúp ta tránh việc phải giải phương trình chuỗi lũy thừa hay tích phân phức tạp.

Bài tập 1

Chứng tỏ $T(X) = \sum X_i$ là thống kê đủ tối thiểu cho $B(\theta)$.

Motivation & Ý nghĩa

Trong khi Định lý Tách giúp tìm thống kê đủ, tiêu chuẩn tỷ số Likelihood (Lehmann-Scheffé Criterion) là cách trực tiếp nhất để kiểm tra tính tối thiểu. Nó đảm bảo rằng ta không thể "nén" dữ liệu thêm nữa mà không làm mất thông tin về θ .

Chi tiết Toán học

1. Xét tỷ số Likelihood tại hai điểm dữ liệu $\mathbf{x}$ và $\mathbf{y}$:

$$\frac{L(\theta | \mathbf{x})}{L(\theta | \mathbf{y})} = \frac{\theta^{\sum x_i} (1-\theta)^{n-\sum x_i}}{\theta^{\sum y_i} (1-\theta)^{n-\sum y_i}} = \left(\frac{\theta}{1-\theta}\right)^{\sum x_i - \sum y_i}$$

2. Để tỷ số này là hằng số đối với mọi $\theta \in (0, 1)$, số mũ phải bằng 0:

$$\sum x_i - \sum y_i = 0 \iff \sum x_i = \sum y_i$$

3. **Kết luận:** Theo tiêu chuẩn Lehmann-Scheffé, $T = \sum X_i$ là thống kê đủ tối thiểu.

Bài tập 2

Tìm thống kê đủ tối thiểu cho $f(x | \theta) = \frac{x!/\theta^x}{\sum_{k=0}^{\theta} k!/\theta^k}$, $x = 0, \dots, \theta$.

Chi tiết Toán học

1. Likelihood cho mẫu: $L(\theta | \mathbf{x}) = \frac{\prod x_i!/\theta^{\sum x_i}}{(\sum k!/\theta^k)^n} 1_{\{x_{(n)} \leq \theta\}}$.
2. Xét tỷ số $L(\theta | \mathbf{x})/L(\theta | \mathbf{y})$:

$$\frac{L(\theta | \mathbf{x})}{L(\theta | \mathbf{y})} = \frac{\prod x_i!}{\prod y_i!} \theta^{\sum y_i - \sum x_i} \frac{1_{\{\theta \geq x_{(n)}\}}}{1_{\{\theta \geq y_{(n)}\}}}$$

- Để tỷ số này không phụ thuộc θ , ta cần đồng thời: - $\sum x_i = \sum y_i$ (để triệt tiêu $\theta \dots$). - $x_{(n)} = y_{(n)}$ (để các hàm chỉ thị triệt tiêu nhau trên miền θ).
- Kết luận:** Bộ thống kê đủ tối tiểu là $T = (\sum X_i, X_{(n)})$.

Bài tập 1

Chúng ta $R = X_{(n)} - X_{(1)}$ là thống kê phụ cho họ dịch chuyển $f(x - \theta)$.

Motivation & Ý nghĩa

Trong một họ dịch chuyển (location family), khi ta dịch chuyển toàn bộ dữ liệu đi một khoảng θ , các khoảng cách tương đối giữa các điểm dữ liệu không đổi. Do đó, các thống kê mô tả "độ trải rộng" (như Range R) sẽ không chứa thông tin về "vị trí" θ .

[Image of a distribution being shifted along the x-axis, showing that the distance between any two order statistics remains constant]

Chi tiết Toán học

- Đặt $Z_i = X_i - \theta$. Khi đó $Z_1, \dots, Z_n$ là mẫu ngẫu nhiên từ $f(z)$ (không phụ thuộc θ).
- Ta có $X_{(i)} = Z_{(i)} + \theta$.
- Khoảng biến thiên: $R = X_{(n)} - X_{(1)} = (Z_{(n)} + \theta) - (Z_{(1)} + \theta) = Z_{(n)} - Z_{(1)}$.
- Vì R là hàm của các Z_i mà phân phối của Z_i không phụ thuộc θ , nên phân phối của R cũng không phụ thuộc θ . Vậy R là thống kê phụ.

Bài tập 2

Chúng ta $T = (X_1/X_n, \dots, X_{n-1}/X_n)$ là thống kê phụ cho họ quy mô (scale family).

Chi tiết Toán học

- Đặt $Z_i = X_i/\sigma$. Khi đó $Z_i \sim f(z)$ không phụ thuộc σ .
- Ta có $X_i/X_n = (\sigma Z_i)/(\sigma Z_n) = Z_i/Z_n$.
- Tương tự bài trên, T là hàm của các Z_i nên phân phối của T không phụ thuộc σ .

Bài tập 1

Chúng ta $X_{(n)}$ là thống kê đầy đủ cho $U(0, \theta)$.

Chi tiết Toán học

- Mật độ của $T = X_{(n)}$ là $f_T(t) = \frac{nt^{n-1}}{\theta^n}, 0 < t < \theta$.
- Xét $\mathbb{E}_\theta[g(T)] = 0 \iff \int_0^\theta g(t) \frac{nt^{n-1}}{\theta^n} dt = 0 \iff \int_0^\theta g(t) t^{n-1} dt = 0$ (vì $\theta > 0$).
- Lấy đạo hàm hai vế theo θ (theo định lý cơ bản của giải tích):

$$\frac{d}{d\theta} \left[\int_0^\theta g(t) t^{n-1} dt \right] = g(\theta) \theta^{n-1} = 0$$

- Vì $\theta^{n-1} > 0$ trên miền xác định, ta suy ra $g(\theta) = 0$ với mọi $\theta > 0$.
- Vậy $X_{(n)}$ là thống kê đầy đủ.

Bài tập 2

Chúng ta $T = (X_{(1)}, X_{(n)})$ không đầy đủ cho $U(\theta, \theta + 1)$.

Chi tiết Toán học

1. Ta tìm một hàm $g(X_{(1)}, X_{(n)})$ có kỳ vọng bằng 0 nhưng hàm đó không phải là hàm không.
2. Xét thống kê phụ $R = X_{(n)} - X_{(1)}$. Ta biết $\mathbb{E}_\theta[R] = \text{const} = c$.
3. Đặt $g(T) = R - c$. Khi đó $\mathbb{E}_\theta[g(T)] = c - c = 0$ với mọi θ .
4. Tuy nhiên $g(T) = X_{(n)} - X_{(1)} - c$ rõ ràng không phải là hàm bằng 0 hầu chắc chắn.
5. **Kết luận:** T không đầy đủ. (Lưu ý: Đây là ví dụ cho thấy đủ tối tiểu chưa chắc đã đầy đủ).

Bài tập 1

Xét $f(x | \theta) = \theta x^{\theta-1}, 0 < x < 1$. Kiểm tra $T = \prod X_i$.

Chi tiết Toán học

1. Đây là họ hàm mũ (Exponential Family) vì $f(x | \theta) = \theta \exp((\theta - 1) \ln x)$.
2. Likelihood: $L \propto \theta^n \exp((\theta - 1) \sum \ln x_i)$.
3. a) **Đủ:** $T' = \sum \ln X_i$ là đủ $\Rightarrow T = \exp(T') = \prod X_i$ là đủ.
4. b) **Đầy đủ:** Vì đây là họ hàm mũ chính quy, thống kê đủ T' (và hàm 1-1 của nó là T) là đầy đủ.
5. c) **Đủ tối tiểu:** Vì T là đủ đầy đủ, theo định lý Lehmann-Scheffé, nó là đủ tối tiểu.

Bài tập 2

Xét $X \sim U(-\theta, \theta)$. Chứng tỏ $|X| \perp \text{sgn}(X)$.

Motivation & Ý nghĩa

Đây là ứng dụng kinh điển của Basu. Trong các phân phối đối xứng qua 0, "độ lớn" (magnitude) thường mang thông tin về tham số quy mô, còn "dấu" (sign) là ngẫu nhiên thuần túy.

Chi tiết Toán học

1. $T_1 = |X|$ là thống kê đủ đầy đủ cho θ (chứng minh tương tự $U(0, \theta)$).
2. $T_2 = \text{sgn}(X)$ có phân phối: $P(T_2 = 1) = 1/2, P(T_2 = -1) = 1/2$. Phân phối này không phụ thuộc θ , nên T_2 là thống kê phụ.
3. Theo định lý Basu, $T_1 \perp T_2$.

Bài tập 3

Xét $X_i \sim e^{-(x-\theta)}, x > \theta$. Chứng tỏ $X_{(1)}$ là đủ đầy đủ và $X_{(n)} - X_{(1)}$ là phụ.

Chi tiết Toán học

1. Tương tự Ví dụ 15 phần Kiểm định: $X_{(1)}$ là đủ. Tính đầy đủ chứng minh bằng đạo hàm tích phân như Bài tập 1 phần này.
2. Đây là họ dịch chuyển, nên theo Bài tập 1 phần Phụ, $R = X_{(n)} - X_{(1)}$ là thống kê phụ.
3. Hệ quả (Basu): $X_{(1)}$ độc lập với Khoảng biến thiên R .