


**Section 0:
Natural Languages Processing**




Lecturer: Assoc.Prof. Dr. Dinh Dien
ddien@fit.hcmus.edu.vn

Lecturer

Đinh Điền 丁田

Dinh Dien
Динх Диэн



딘 디엔
ディンディエン

Teaching Assistant: Dr. Buu Long – Dr. An Vinh

Giới thiệu

- Sản phẩm **AI**: ChatBot: ChatGPT, Gemini, Grok 3, ...
- **Đối thoại** với con người bằng **ngôn ngữ con người**
- ✓ Tại sao: **AI** gần đây ảnh hưởng sâu rộng đến mọi người
- hơn so với các thành quả AI trước đây (chơi cờ: 97,17)?
- Vì: nó liên quan đến **Ngôn ngữ con người**.
- **Ngôn ngữ**: Phương tiện giao tiếp, truyền đạt thông tin quan trọng nhất của loài người.
- **AI** tác động rất lớn đến tất cả các lĩnh vực trong đời sống
- vì tất cả đều phải dùng đến **ngôn ngữ** của con người.
- ❖ “(thông) TIN”: 信 = 人 (nhân) + 言 (ngôn)
- Ngôn ngữ: **tiếng nói** và **chữ viết**
- NLP: **Xử lý ngôn ngữ tự nhiên** (bằng AI, LLM, ...)

Natural Language Processing (NLP)


1. What is NLP ?
2. Why NLP is hard?
3. NLP applications
4. What will this course be about?
5. Textbooks - Website - dataset
6. Grading:
 - Mid-term: Exercise/Seminar (50%): Corpus
 - Project (Model): oral examination (50%)
 - Bonus: unlimited

What is NLP?

Using computer (Artificial Intelligence) to deal with human languages.

What is Natural Language Processing?

computers using natural language as input and/or output



Why NLP is hard?

- Reason (1) – human language is **ambiguous**:
- Ex1 (pronoun resolution):
- Jack drank the wine on the table. ***It*** was red and round.
- Jack saw Sam at the party. ***He*** went back to the bar to get another drink.
- Jack saw Sam at the party. ***He*** clearly had drunk too much.
- Ex2: PrePosition Attachment:
- I ate **the bread with pecans**.
- I **ate** the bread **with fingers**.


Why NLP is hard?

- Reason (2) – requires reasoning beyond what is explicitly mentioned (*A,B*) , and some of the reasoning requires world knowledge (*C*).
- *Ex: I couldn't submit my homework because my horse ate it.*
Implies that...
- *A. I have a horse.*
- *B. I did my homework.*
- *C. My homework was done on a soft object (such as papers) as opposed to a hard/heavy object (such as a computer). – it's more likely that my horse ate papers than a computer.*



NLP APPLICATIONS

1. Linguistics analysis:

An example of NLP



5. Text stylometry:



Văn phong khác biệt tố cáo vụ ngộ sát, làm giả thư tuyệt mệnh

Qua phân tích cách dùng từ "and", "but", "hopefully", "truly" trong thư tuyệt mệnh, các chuyên gia tại Mỹ xác định nạn nhân không phải là người viết.

• Thói quen lạ của chú chó tố cáo ông chủ vứt xác bốn cô gái bán dâm

Vào buổi sáng năm 1992, khoa cấp cứu một bệnh viện tại Mỹ nhận được cuộc gọi khẩn cấp từ người sống tại căn hộ ở Bắc Carolina. Khi đến nơi, các nhân viên y tế thấy một thanh niên đã tử vong.

Nạn nhân được xác định là Michael Hunter, 23 tuổi, vừa tốt nghiệp đại học và đang làm lập trình viên. Bạn cùng phòng khai với cảnh sát rằng sáng hôm ấy, khi đánh thức Michael Hunter dậy để đi làm thì thấy anh ta bất tỉnh từ bao giờ.

Michael Hunter không có thương tích khả nghi nào trên cơ thể. Xét nghiệm máu cho kết quả dương tính với một loại thuốc gây tê với nồng độ gây chết người. Thông thường, loại thuốc này được sử dụng trong một số trường hợp khẩn cấp để làm ổn định nhịp tim. Tuy nhiên, nhân viên y tế khẳng định khi đến nơi thì thấy nạn nhân đã tử vong và họ không hề tiêm bất cứ thuốc gì.

Cái chết của Michael Hunter làm gia đình anh suy sụp. Cha của anh vì quá đau buồn đã rơi vào cơn trầm cảm kéo dài và tự tử sau đó.



FBI Profiler Says Linguistic Work Was Pivotal In Capture Of Unabomber

August 22, 2017 · 12:18 PM ET

Heard on Fresh Air

DAVE DAVIES

FRESH AIR



Ted Kaczynski is flanked by federal agents as he is led to prison. Kaczynski is now serving a life sentence in prison for the

his victims. In 1995, he sent a sprawling, 35,000-word

"manifesto" to *The New York Times* and *The Washington*

Post, in which he explained why he believed technology to be evil and how society should disband the technological system and live in agrarian tribes.

Fitzgerald says the Unabomber's writings were a "pivotal factor" in cracking the case. He and his colleagues used them to help pinpoint the age and geographic origin of their suspect — evidence that helped lead to the April 6, 1996, arrest of Ted Kaczynski,

Ex-Math-Prof.
UC Berkeley

ChatGPT translation

DD

Hãy dịch câu sau sang tiếng Anh, Pháp, Hoa, Nhật, Hàn, Đức, Nga, Latin và Quốc tế ngữ: "Chúng tôi đang học một ngôn ngữ"



- Tiếng Anh: "We are learning a language"
- Tiếng Pháp: "Nous apprenons une langue"
- Tiếng Hoa: "我们正在学习一种语言" (Wǒmen zhèngzài xuéxí yī zhǒng yǔyán) 门
- Tiếng Nhật: "私たちは言語を学んでいます" (Watashitachi wa gengo o manande imasu)
- Tiếng Hàn: "우리는 언어를 배우고 있습니다" (Urineun eoneoreul baeugo issseubnida)
- Tiếng Đức: "Wir lernen eine Sprache"
- Tiếng Nga: "Мы изучаем язык" (My izuchayem yazyk) учим
- Tiếng Latin: "Nos discimus linguam"
- Quốc tế ngữ: "Emang volapükik" Ni lernas lingvon

ChatGPT translation

DD

Hãy dịch câu sau sang tiếng Anh, Pháp, Hoa, Nhật, Hàn, Đức, Nga, Latin và Esperanto: "Chúng tôi đang học một ngôn ngữ"



- Tiếng Anh: "We are learning a language"
- Tiếng Pháp: "Nous apprenons une langue"
- Tiếng Hoa: "我们正学习一门语言" (Wǒmen zhèngzài xuéxí yī mén yǔyán)
- Tiếng Nhật: "私たちは言語を学んでいます" (Watashitachi wa gengo o manande imasu)
- Tiếng Hàn: "우리는 언어를 배우고 있습니다" (Urineun eoneoreul baeugo issseubnida)
- Tiếng Đức: "Wir lernen eine Sprache"
- Tiếng Nga: "Мы изучаем язык" (My izuchayem yazyk)
- Tiếng Latin: "Nos discimus linguam"
- Esperanto: "Ni lernas lingvon"



Không chính xác: ngữ nghĩa từ Hán-Việt

DD

Hãy giải thích nghĩa của chữ "giai" trong thành ngữ "bách niên giai lão"



Trong thành ngữ "bách niên giai lão", chữ "giai" có nghĩa là "già nua", "đã già".

"Bách niên" nghĩa là "trăm tuổi", "lão" có nghĩa là "người già". Vì vậy, "bách niên giai lão" được dịch là "trăm tuổi đã già nua" hoặc "trăm tuổi đời đã già".

Một lần khác, Bác đến dự chiêu đãi do Chính phủ tổ chức nhân dịp đầu xuân dành cho chuyên gia nước ngoài. Trưởng đoàn chuyên gia Liên Xô đọc đáp từ, trong đó chúc **Bác Hồ** sống lâu; phiên dịch dịch là chúc Bác "bách niên giai lão". Lúc ấy, tôi đứng sau lưng, nghe thấy Bác rĩ tai bác Tôn: "Mình có lấy vợ đâu mà chúc bách niên giai lão?"

[Vũ Khoan "Kể chuyện Bác Hồ"]

giai (階): *giai cấp, giai đoạn, ...*

"bậc thềm"

giai (佳): *giai diệu, giai thoại, giai nhân, ...*

"hay/đẹp"

giai (偕): *giai lão, ...*

"sống cùng nhau"

Không chính xác: cả ngữ nghĩa từ thông dụng

Model: GPT-4

Talk-t

DD

Hãy giải thích ý nghĩa của chữ "trắc" trong từ "bất trắc"



Trong tiếng Việt, từ "bất trắc" thường được dùng để mô tả một tình huống không ổn định, khó lường, rủi ro hoặc gặp phải những khó khăn và vấn đề. Từ này bao gồm hai chữ "bất" và "trắc".

Chữ "trắc" trong từ "bất trắc" có nghĩa là không ổn định, không chắc chắn. Khi kết hợp với chữ "bất", nó nhấn mạnh ý nghĩa của sự không ổn định, rủi ro hoặc tình trạng khó lường. Ví dụ, bạn có thể dùng từ "bất trắc" để mô tả tình hình kinh tế, chính trị, thời tiết, hoặc một mối quan hệ nào đó.

Tóm lại, ý nghĩa của chữ "trắc" trong từ "bất trắc" là sự không ổn định, không chắc chắn, phản ánh một tình huống không tốt hoặc khó khăn.

Trắc: đo/lường: trắc nghiệm, quan trắc, sinh trắc, ...

“Sông sâu khó đo, lòng người không lường được”

Chưa thể hiểu: nghĩa hàm ý, ẩn dụ, hoán dụ

2. "Thiều quang chín chục đã ngoài sáu mươi": "Thiều quang" có nghĩa là ánh sáng mờ nhạt, chỉ thời gian gần hoàng hôn. Số "chín chục" ở đây ám chỉ tuổi thọ trung bình của con người, còn "sáu mươi" là thời gian mà ánh sáng bắt đầu mờ dần, tượng trưng cho tuổi già. Như vậy, câu thơ này có thể hiểu là thời gian cuộc đời đã đi qua nhanh chóng, giống như cách mà ánh sáng của ngày chuyển mình vào hoàng hôn.

Tổng kết lại, hai câu thơ này mang ý nghĩa về sự vụt qua của thời gian, sự thay đổi từ mùa xuân sang hoàng hôn tượng trưng cho quá trình từ thanh xuân đi vào tuổi già. Đồng thời, chúng cũng nêu lên một cảm giác nuối tiếc về những thời gian đã qua nhưng vẫn phải đón nhận và chấp nhận sự thay đổi của cuộc sống.

*Ngày xuân con én đưa thoi => dật nên Tầm lựa mùa Xuân (90 ngày)
60 ngày = đã qua 2 tháng => Thanh minh trong tiết Tháng Ba*

Không thể hiểu: Nghĩa hình tượng

2. "Phận liễu sao mà nẩy nét ngang."

- "Phận liễu" là số phận tầm thường, không có gì nổi bật, giống như cây liễu nhỏ bé và mong manh.
- "Sao mà" là "làm sao" hoặc "làm cách nào".
- "Nẩy nét ngang" là phát triển và đạt được sự kiên cường, mạnh mẽ trong cuộc sống.

Câu thơ này thể hiện sự trăn trở của tác giả về số phận của mình, liệu với một số phận tầm thường như cây liễu, có thể kiên cường và vượt qua khó khăn, thử thách trong cuộc sống hay không.

Nhìn chung, hai câu thơ này diễn đạt nỗi lòng của tác giả về sự trăn trở, tiếc nuối về số phận và duyên nợ trong cuộc đời. Tác giả nhấn mạnh rằng mỗi con người phải đối mặt với những khó khăn và thử thách trong cuộc sống, dù số phận có tốt hay không. Đồng thời, tác giả cũng đặt câu hỏi liệu có thể vượt qua những thử thách đó để trở nên kiên cường và mạnh mẽ hơn.

Tiếng Anh: chính xác hơn

DD

Xin cho tôi biết nguồn gốc của từ "breakfast"



Từ "breakfast" được hình thành từ hai từ "break" và "fast". Trong tiếng Anh cổ, "to break" có nghĩa là "phá vỡ, làm gián đoạn", và "fast" có nghĩa là "đói khát" trong thời gian dài, thường là do tôn giáo hay y học. Vì vậy, "breakfast" có nghĩa là bữa ăn đầu tiên trong ngày, giúp phá vỡ trạng thái đói khát sau một đêm ngủ.

break: phá vỡ **fast:** ăn chay/nhịn ăn (do đêm: ngủ)

breakfast: bữa đầu tiên trong ngày mà phá chay

Tiếng Anh: hiểu rất tốt

DD

Xin cho biết nguồn gốc của từ "disaster" trong tiếng Anh?



Từ "disaster" trong tiếng Anh có nguồn gốc từ tiếng Ý, từ "disastro". "Disastro" được ghép từ hai phần: tiền tố "dis-" mang nghĩa "không tốt" hay "xấu" và "astro" nghĩa là "sao" (trong ngữ cảnh thiên văn học). Trong tiếng Ý, "disastro" được sử dụng để chỉ một sự kiện xấu xảy ra do ảnh hưởng của các vì sao, vì người xưa thường tin rằng các thiên thể có ảnh hưởng đến cuộc sống trên Trái đất.

astro/aster: astronomy, astronaut, asteroid

disappear: biến mất => **disaster:** tai họa

Từ "disastro" sau đó được chuyển sang tiếng Pháp dưới dạng "désastre" và cuối cùng trở thành "disaster" trong tiếng Anh vào khoảng thế kỷ 16. Ngày nay, từ "disaster" được sử dụng để chỉ một sự kiện đột ngột và khủng khiếp gây hậu quả nghiêm trọng về mặt nhân vật, kinh tế, môi trường hoặc xã hội.

Tiếng Anh: hiểu rất tốt

DD

Hãy giải thích nguồn gốc của nghĩa từ NVIDIA



NVIDIA là tên của một công ty đa quốc gia chuyên sản xuất chip đồ họa và nhiều sản phẩm khác liên quan đến công nghiệp công nghệ thông tin. Tên NVIDIA không phải xuất phát từ một từ hoặc cụm từ cụ thể trong bất kỳ ngôn ngữ nào, nhưng theo chính sáng lập viên và CEO của NVIDIA, Jensen Huang, tên này có nguồn gốc từ tiếng Latinh.

NVIDIA được lấy từ từ "**invidia**" trong tiếng Latinh, nghĩa là "ghen tị" hoặc "sự dè dặt". Có lẽ cái tên này được chọn vì công nghệ và sản phẩm của NVIDIA thường đứng ở vị trí tiên phong và đem lại sự "ghen tị" cho các đối thủ cạnh tranh.

Tuy nhiên, không chỉ là tên thương hiệu, NVIDIA cũng đã xây dựng một biểu tượng mạnh mẽ và được biết đến rộng rãi trong ngành công nghiệp đồ họa, máy tính và trí tuệ nhân tạo.

Invidere

The term **invidia** comes from the Latin word **invidere**, which means "to look too closely" ¹. Invidia is associated with envy and reflects the ancient belief that envy originates from **the eyes** ¹. The Latin word invidia is derived from the Latin word video, which means "to see" ². Invidia is also related to the Latin word invidus, which means "envious" or "hostile" ².

Learn more: [1. wikipedia.org](https://en.wikipedia.org/wiki/Invidia) [2. etymologeek.com](https://www.etymologeek.com/word/invidia)



Tiếng Anh: hiểu rất sâu rộng

nguồn gốc của từ "Milky Way"




Thần thoại Hy Lạp:

Thần Zeus: Chúa tể các vị thần


Hera: Vợ thần Zeus


Hercule: Con rơi của thần Zeus

Parsing Natural Scene Images



Parsing Natural Language Sentences



- 
- AI/Chatbots (ChatGPT, Gemini, DeepSeek, Grok, ...): extremely intelligent
 - Capable of solving all human problems—
 - even better than humans.
 - For Vietnamese: outperforms all Vietnamese chatbots today,
 - except for one thing:
 - the Sino–Nôm problem.

VTV3

VTV.vn

06:40





VĂN HÓA

aa



Theo Hội bảo tồn di sản chữ Nôm thì hiện nay trên thế giới chỉ còn khoảng 100 người đọc thông viết thạo chữ Nôm, trong khi có đến 90% thư tịch chữ Nôm chưa từng được dịch sang quốc ngữ. Đây là một nguy cơ rất cao về khả năng mai một những thư tịch chữ Nôm. Trong khi ngay tại VN, các khóa Hán Nôm trong trường đại học cũng rất ít người theo học và số người theo chuyên ngành Nôm trong khoa Hán Nôm còn ít hơn.

Ứng dụng:

TTNT: Các kỹ thuật ML, LLM, KG, ...

=> Xử lý tự động văn bản Hán Nôm




GS. Nguyễn Tài Cẩn đang xem quyển "Chỉ nam ngọc âm giải nghĩa"


Các dạng ảnh văn bản Hán Nôm

蘇解勳揆馭些
 峽戈沒局波欒
 選之彼嗇斯豐
 稿蕢吝拱礪烟
 浪蕩嘉靖朝明
 固茹員外戶王
 沒黠猓次卒悉
 頭悉仝柯素娥
 枚骨格雪精神
 雲祐莊重恪鴻
 花琪王說端莊
 翻強色稍漫麻

符才符命審哭怙饒
 仍調鸞覽匏勃疸悉
 忝撐涓貝鴈紅打榷
 風情固錄群傳史撐
 眾方榜潮仝京僥鑽
 家資擬拱常又堀中
 王覓兕符綏泃儒家
 翠翹毘姊掩兕翠雲
 沒馭沒錄迤分院壯
 困賸苔憚惶蜉妄囊
 遷輸渚還雪議牟腹
 揚皮才色吏兕分欣



- Chữ **Quốc ngữ**: **Ghi âm** (Latin, Hy Lạp, Cyrillic, Hangeul, Kana,...)
- Chữ **Nôm**: **Ghi ý** (giống chữ **Hán**) {ChatGPT/Gemini chưa hiểu chữ Nôm}
- ❑ **Kho tàng văn bản Hán Nôm**: *lịch sử, địa lý, y học DT, văn học, ...*



CÁC NHÓM BÀI TOÁN

1. OCR văn bản Hán Nôm
2. Dịch âm (transliteration) Hán/Nôm=>âm Hán Việt/thuần Việt
3. Dịch nghĩa (meaning translation) Hán => Việt hiện đại
4. Truy vấn (ChatBot) kho vb Hán-Nôm bằng chữ Quốc ngữ
5. Khám phá/giải mã kho tàng di sản Hán Nôm
6. Trực quan hóa sử liệu VN thời kỳ phong kiến

1. OCR văn bản Hán Nôm

1a. Nhận diện và gán nhãn từng vùng văn bản (layout)



- Page box: Khung trang.
- Bibliography: Mục lục, đóng vai trò như dàn ý
- Ear note: Mép sách, khoảng trống ở góc trên b
- Centerfold strip: Gáy sách, dải trống hẹp ở gi hoặc số trang.
- Title: Tựa đề sách.
- Subtitle: Tên chương hoặc phần trong sách.
- Volume number: Số thứ tự tập.
- Compiler: Người biên soạn hoặc hiệu đính.
- Author: Tác giả.
- Chapter title: Tiêu đề chương.
- Section title: Tiêu đề mục.
- Text: Chính văn.
- Marginal annotation: Ghi chú bên lề.
- Figure: Hình minh họa.
- Caption: Chú thích hình.
- Foliation: Số trang.



1. OCR văn bản Hán Nôm

1b. Nhận diện cột/hàng văn bản (bounding box)

- Xác định tọa độ từng box
- Sắp xếp thứ tự từng box



1. OCR văn bản Hán Nôm

1c. Nhận diện từng ký tự (Hán Nôm tự)

Khải thư

Triện thư
篆書

天 地 玄 黃

Lệ Thư
隸書

天 地 玄 黃

Khải thư
楷書

天 地 玄 黃

Thảo thư
草書

天 地 玄 黃

Hành thư
行書

天 地 玄 黃

Âm Hán Việt:

Thiên Địa Huyền Hoàng

Nghĩa:

Trời Đất Đen Vàng

Năm kiểu chữ thông dụng

Biến thể (chữ Quốc)

國: biên giới, ngôn ngữ, quân đội

国: vương (vua)

国: ngọc

国: dân

...

玄 燁



玄

燁



燁

Huyền Diệp
(Khang Hy)

Bút khuyết


縣辭勅揆馭些

Dị thể (21)

秦 口 国 囯 國 國 囯 或 呿 圉 圉 氏
方 玄 方 方 國 或 或 璽 璽

1. OCR văn bản Hán Nôm

1d. Khó khăn do ảnh (qua thời gian) bị mờ, mất nét, mất chữ



Bia Tiến hiền Nguyễn Tử (Tiến hiền làng Mỹ Trà) lập ngày 15 tháng 10 năm Tự Đức thứ 29 (1876)
có nhắc đến địa điểm này ngày trước là khu trường Bá Canh - một trong 9 khu trường thời chúa Nguyễn



Phải “đoán” (LLM, KG, ...)

2. Dịch âm văn bản Hán Nôm

2a. Dịch âm chữ Nôm sang âm thuần Việt

詠馭籒荒

奇你朱輒化攢揚

餒悉扞固別庄扞

緣天渚覓嚙頭育

分了輶拖抵涅昂

Vịnh Người Chử Hoang

Cả nê cho nên hóa dờ dang

Nỗi lòng chàng có biết chẳng chàng

Duyên thiên chưa thấy nhô đầu dọc

Phận liễu sao đà đẩy nét ngang

2b. Dịch âm chữ Hán sang âm Hán Việt

汝
等
行
看
取
敗
虛

如
何
逆
虜
來
侵
犯

截
然
定
分
在
天
書

南
國
山
河
南
帝
居

南
國
山
河

Nam quốc sơn hà

Nam quốc sơn hà Nam đế cư,

Tiết nhiên định phận tại thiên thưⁱ.

Như hà nghịch lỗ lai xâm phạm,

Nhữ đẳng hành khan thủ bại hư.

3. Dịch nghĩa văn bản Hán

汝 如 截 南 南
等 何 然 國 國
行 逆 定 山 山
看 虜 分 河 河
取 來 在 南
敗 犯 天 帝
虛 犯 書 居

Nam quốc sơn hà

Nam quốc sơn hà Nam đế cư,
Tiệt nhiên định phận tại thiên thưⁱ.
Như hà nghịch lỗ lai xâm phạm,
Nhữ đẳng hành khan thủ bại hư.

- Cần Dịch nghĩa để “giải nghĩa” các từ Hán Việt khó hiểu đó.
- ✓ “nhữ”(汝): mày; “đẳng”(等): bằng/bạc/chờ/chúng; ...
- ✓ “hành”(行): đi/hàng/hạng/hạnh/làm/giỏi/qua/lũ/tiệm/dùng/...;
- ✓ “khan”(看): khán, khan (xem, nhìn)
- ✓ “tri”(知): biết (tri nhận); “để cho biết” (tri hô, thông tri); ...
- ✓ “cổ” (Hán): cổ xưa (古: ancient), cổ vũ (鼓: đánh trống, nhẩy múa), cổ phần (股: share), cổ trướng (臙: xơ gan), ...
- ✓ “cổ” (neck): 頸 (cảnh: động mạch cảnh)

3. Dịch nghĩa văn bản Hán

Nam quốc sơn hà

Nam quốc sơn hà Nam đế cư,
Tiệt nhiên định phận tại thiên thưⁱ.
Như hà nghịch lỗ lai xâm phạm,
Nhữ đẳng hành khan thủ bại hư.

Dịch nghĩa

Núi sông nước Nam thì vua Nam ở,
Cương giới đã ghi rành rành ở trong sách trời.
Cớ sao lũ giặc bạo ngược kia dám tới xâm phạm?
Chúng bay hãy chờ xem, thế nào cũng chuốc lấy bại vong.

Bản dịch nôm của Nguyễn Hùng Vĩ:^[12]

Sông núi nước Nam, Nam đế quản trị
Hiển nhiên đã định phận tại thiên thư
Cớ sao bọn giặc ngỗ ngược đến xâm phạm
Mà chúng bay, xem ra, lại chịu bại ư?

3. Dịch nghĩa văn bản Hán: Tri thức hình thái, ngữ pháp

- Tri thức phân đoạn ngữ (chunking): cần thêm dấu ngừng-ngỉ (punctuation) vì gốc Hán không có (vị trí dấu khác nhau, nghĩa dịch sẽ khác nhau):

(TT&VH) - Nhìn ra sai sót của mình và cho tới khi nhắm mắt vẫn băn khoăn tìm cách dịch nghĩa câu cuối trong bài thơ chữ Hán *Nam quốc sơn hà* - câu chuyện về cố GS Nguyễn Tài Cẩn đã thật sự làm nhiều người xúc động trong cuộc hội thảo về ông mang tên *Tưởng nhớ GS Nguyễn Tài Cẩn* (diễn ra tại Hà Nội vào hôm qua, 26/3/2011).

- “汝等行看取敗虛” => “nhữ đẳng hành khan thủ bại hư”
- “nhữ đẳng hành, khan thủ bại hư” => “*Chúng bay sẽ bị đánh tơi bời*”
- “nhữ đẳng hành khan, thủ bại hư” => “*Mà chúng bay, xem ra, lại chịu bại ư*” (GS.Nguyễn Tài Cẩn mất 19 năm để chỉnh nhịp 3-4, 4-3)

3. Dịch nghĩa văn bản Hán: Tri thức từ vựng

□ Tri thức tên riêng (NER): cần xác định các thực thể có tên để không dịch nghĩa (vì trong chữ Hán, không có dạng viết Hoa):

承天府香水縣安舊社 : *thừa thiên phủ hương thủy huyện an cựu xã*

承天府,香水縣,安舊社: *phủ Thừa Thiên, huyện Hương Thủy, xã An Cựu*

✓ Các thực thể có tên (PER, LOC, ORG, ...) ở VN không giống ở TQ

- 雄王: Hùng Vương !=> *vua khỏe*
- 昇龍: Thăng Long !=> *rồng bay*
- 安陽王: An Dương Vương !=> *vua mặt trời yên ổn*

□ Tri thức từ/ngữ gốc Hán cố định: thành ngữ, quán ngữ, điển tích, ...

- 熱血: nhiệt huyết !=> *máu nóng*
- *an cư lạc nghiệp, án binh bất động, hào hoa phong nhã*: ko dịch
- *Tri âm* (Chung Tử Kỳ, Du Bá Nha), *hàn thực* (Giới Tử Thôi),...

3. Dịch nghĩa văn bản Hán: Tri thức ngữ nghĩa

Từ cổ	Nghĩa
chác	<i>mua</i>
chí	<i>con tin</i>
tĩnh	<i>bàn thờ</i>
bao nả	<i>cao nhiều</i>
báo bổ	<i>báo đáp</i>

Từ Hán (VN)	Từ Hán TQ	
Tiến sĩ	<i>Bác sĩ</i>	
Kỹ sư	<i>Công trình sư</i>	
Sinh học	<i>Sinh vật</i>	
	<i>Khẩu thủy</i>	<i>Nước miếng</i>

Từ Hán (Việt)	Nghĩa VN	Nghĩa TQ
Hạ thủ	<i>Xuống tay, Sát hại</i>	<i>Bắt tay làm</i>
Đình ninh	<i>Yên trí</i>	<i>Dặn dò</i>
Mê ly	<i>Rất hay</i>	<i>Mơ hồ</i>
Dã tâm	<i>Lòng dạ hiểm ác</i>	<i>Tham vọng</i>
Thủ đoạn	<i>Mưu mẹo</i>	<i>Phương pháp</i>
Bồi hồi	<i>lo lắng, bồn chồn</i>	<i>Đi đi lại lại</i>

TQ	VN
Trừ tịch	Giao thừa
Hải triều	Thủy triều

3. Dịch nghĩa văn bản Hán: Đồ thị Tri thức (KG)

- ❑ Gia phả các nhân vật lịch sử
- ❑ Lịch sử (niên đại, triều đại, niên hiệu, tước vị, ..)
- ❑ Văn hóa (kỵ húy, điển tích, điển cố, dân gian, tôn giáo)
- ❑ Địa lý (vùng miền, nhân danh, địa danh thay đổi theo thời gian)
- Về mặt Không gian: *Hà Nội: Thăng Long (1010), Đông Đô (1397), Đông Quan (1408), Đông Kinh (1427), ...*
- Về mặt Thời gian: *chiến thắng Kỷ Dậu => năm 1789, nhà Tây Sơn; Luật Hồng Đức ban hành vào năm Hồng Đức thứ 14 => năm 1483, triều đại nhà Lê, dưới đời vua Lê Thánh Tông*

5. Khám phá/Giải mã sử liệu Hán Nôm

1. Cho máy đọc hàng vạn quyển sách lịch sử (Đại Việt Sử ký toàn thư, Đại Nam thực lục; Đại Nam nhất thống chí, Khâm định Đại Nam Hội điển sự lệ, ...) chữ Hán/Nôm/QN.
2. Các tài liệu này đã được gán nhãn thực thể (người, tổ chức, nơi chốn, thời gian), biến cố (lên ngôi, thoái vị, băng hà,)
3. Khám phá mối liên hệ/quy luật giữa các biến cố
4. Xác nhận/phản bác các giả thuyết trong lịch sử

Ví dụ:

- *Mộ hoàng đế Quang Trung có còn không? Ở đâu?*
- *Hoàng đế Quang Trung có cho người đóng giả sang triều kiến vua Càn Long không?*
- *Chúa Nguyễn Ánh có giam vợ (thứ phi Phi Yến: Lê Thị Rằm) và ném con xuống biển (hoàng tử Hội An: Cải) không?*
- **Cdao:** {Gió đưa cây cải về trời; Rau răm ở lại chịu đời đắng cay}

Khám phá quy luật giữa các biến cố (trong lịch sử):

"Thượng Hoàng ban yến cho các quan ở Diên Hiên, yến chưa xong, bỗng có sao chổi xuất hiện ở phương đông bắc, đuôi dài suốt trời, Thượng Hoàng ra xem bảo: Ta xem sao chổi này rất sáng, đuôi rất dài, không phải là tai họa của nước ta, lệnh cứ dự xong yến. Tháng 10 mùa đông năm ấy, vua Tống băng."

from Dai Viet Su Ki Toan Thu, during the reign of King Tran Thanh Tong

(sao) astro/aster: asterisk, astronomy, astronaut, asteroid, ...

disappear: biến mất = disaster: tai họa

Bảy giờ, ở Thanh Hoa mưa dầm nhiều, nước lụt đến 7 lần, lúa má bị hạn nhiều, dân đói to.

Họ Mạc sách phong Vũ Thị Hoành là con gái của thự vệ sự vệ Cẩm y Phú Sơn hầu Vũ Văn Khê làm chính phi.

Tháng 11, sao Chổi mọc, trời thẳng hướng đông nam, tua sáng dài đến 40 trượng, sắc hồng và tia ánh nhau, người người đều kinh hãi.

Tháng 12, ngày mồng 1, sao Chổi hết.

Xuống chiếu đôi năm sau làm Quang Hưng

5b. Giải mã tài liệu lịch sử Hán Nôm



Vua Quang Trung (ảnh minh họa).

1753-1792

車: xa (xe)

心: tâm (tim)

惠: huệ (ơn)

車
心
折
軸
多
田
鼠

X
A
T
Â
M
C
H
I
Ê
T
T
R
Ú
C
Đ
A
Đ
I
Ê
N
T
H
Ủ

Theo sách Hoàng Lê nhất thống chí ghi lại thì khi vua Quang Trung giả làm sứ giả sang Bắc Kinh (Trung Quốc) gặp vua Càn Long, được vua Càn Long tặng cho chiếc áo, có thêu 7 chữ: **Xa tâm chiết trục, đa điền thử**. Nghĩa là: Bụng xe gãy trục, nhiều **chuột** đồng.

Theo phép chiết tự, chữ "**xa**" và chữ "**tâm**" ghép lại thành chữ "**Huệ**" là tên của Nguyễn Huệ; "chuột" nghĩa là năm **Tý** (Nhâm Tý 1792). Ý của dòng chữ trên áo là **Nguyễn Huệ sẽ chết vào năm Tý**. Giả thiết này ý nói rằng, vua Quang Trung chết do áo bị yểm bùa?



5c. Mơ ước: Giải mã sấm Trạng Trình

“Đầu Thu gà gáy xôn xao

Trăng xưa sáng tỏ soi vào Thăng Long”

“Đầu Thu”: Tháng 7 (âm lịch)

=> Tháng 8 (dương)


“gà”: năm Dậu (1945)

“Trăng xưa” => “cổ nguyệt”

古: cổ

月: nguyệt

胡: Hồ



Tượng đài Trạng Trình Nguyễn Bình Khiêm.

=> Sự kiện CMT8: Bác Hồ đọc bản tuyên ngôn độc lập

萬里東溟歸把握
億年南極奠隆平

Vạn lý Đông minh quy bả ác,
Ưc niên Nam cực điện long bình.

巨鰲戴山

Cự ngao đới sơn

Biển Đông vạn dặm dang tay giữ
Đất Việt muôn năm vững trị bình

Hán/Nôm Nôm 

Dạng chữ In

 HÌNH ẢNH

Văn bản thông thường nằm dọc in

File: Tho_HXH_1.JPG

HÁN - NÔM


QUỐC NGŨ

空𩚑麻渚
奇恹朱𩚑化拱揚
事尼固透吹庄抃
緣天渚𩚑儒頭育
分了牢麻扔湟昂
巧罪𩚑𩚑抃𩚑奇
𩚑情艾塊妾𩚑**𩚑**
管之𩚑世𩚑貞歷
庄勞仍麻勞買頑

không chồng mà chửa
cả nể cho nên hoá dở dang
sự này có thấu xui chẳng chàng
duyên thiên chưa thấy nhô đầu dọc
phận liễu sao mà nẩy nét ngang
cái tội trăm năm chàng chịu cả
chữ tình một khối thiếp xin **giảng**
quản chi miệng thề lời chênh lệch
chẳng thể nhưng mà thể mới ngoan


☐ Gõ Hán-Nôm

84/500

☒ Hiện kết quả hình ảnh

Các công cụ AI khác không hiểu được chữ Nôm => ảo giác

ChatGPT 5 ▾



Hãy OCR, phiên âm và dịch nghĩa ảnh văn bản Hán Nôm trên

OCR trực tiếp bằng công cụ nhận diện chưa đọc được chính xác do đây là văn bản Hán Nôm cổ. Tôi sẽ xử lý bằng cách đọc thủ công các chữ trong ảnh.

空囊無宿食
貧病化為殃
藥方仍舊買
雜草豈能湯
傷頭尋分了
卒麻抄淨易
寫罪驚辭訟
披苔發古香
草情茲猶委
委哀呼救蒼
筆之四世醫
貞鑑壓芳仍

Dịch nghĩa tiếng Việt

less

Túi rỗng không còn gì để ăn,
Nghèo bệnh trở thành tai ương.
Thuốc thang vẫn cứ phải mua,
Cỏ tạp sao có thể nấu thành thuốc?
Đầu thương tổn tìm cách chia giải,
Bệnh tật chợt đến khó gỡ sạch.
Viết tội, kinh hãi vì lời tụng,
Rêu phủ mà vẫn toả hương xưa.
Lòng cỏ tình này vẫn phó mặc,
Kêu than cầu cứu trong thương xót.
Bút ghi lại: bốn đời lương y,
Gương trong soi tỏ, công phượng còn mãi.

Các công cụ AI khác không hiểu được chữ Nôm => ảo giác

Gemini

3. Dịch nghĩa

Bài thơ sử dụng hình ảnh "cái chổi" để diễn tả cuộc đời con người, đặc biệt là thân phận người phụ nữ, với nhiều từ Hán Việt và chữ Nôm mang tính đa nghĩa, trào lộng.

o nhận dạng, đọc từ phải sang trái, từ trên xuống dưới:

:堪場

- **Lập liên đăng đồ, kỳ hiệp mang kham trường:**
 - **Nghĩa đen:** Dựng đứng, liên cuộn lại, ngã đổ xuống, một hiệp sĩ lạ lùng mang theo sự chịu đựng khó khăn. (Miêu tả hình dáng và công việc của cái chổi).
 - **Nghĩa bóng:** Cuộc đời đầy những lúc đứng lên, rồi ngã xuống, phải gánh vác, chịu đựng nhiều gian khổ.
- **Sự vĩ viên đồ, thấu khái khái trang tư:**
 - **Nghĩa đen:** Mọi việc đến cuối cùng đều thành tròn vẹn (viên đồ), xuyên qua tiếng ho khù khụ và vẻ ngoài riêng tư. (Miêu tả cây chổi khi quét nhà, bụi bay lên gây ho).
 - **Nghĩa bóng:** Cuộc đời dẫu cuối cùng có thể viên mãn, nhưng cũng phải trải qua nhiều vất vả, khó nhọc một cách riêng tư.

g chữ Quốc ngữ như sau:

ng kham trường.

trang tư.

ng thương đầu dục.

ững dầm.



Hi, I'm DeepSeek.

How can I help you today?



Extract only text from images and files.



Tho_HXH_1.JPG

No text extracted



*"Dân ta phải biết sử ta,
cho tường gốc tích nước nhà
Việt Nam"*

.....
*"Lịch sử nước ta" -
Chủ tịch Hồ Chí Minh*



THIỆT THA

Thiệt (切) = “cắt, khắc, đục”
Tha (磋) = “mài, giũa”

*Ngày đêm **thiết tha** được thực hiện
công trình để đời này cho dân tộc mình*

*Rất mong các bạn
cùng tham gia thực hiện công trình đặc thù này*


Computational Models in NLP:

Artificial Intelligence: A branch of computer science dealing with the simulation of intelligent behavior

Machine Learning: is a type of artificial intelligence (**AI**) that allows software applications to become more accurate at predicting outcomes via **training data**.

- ❑ **Deep Learning:** requires big data
- ❑ **Computational Linguistics:** Data = **Corpus**
- ❑ **Corpus:** 语料库/yǔ liào kù/ “ngữ liệu khố”
- ❑ = Collection of spoken/written text
- ❑ Building **Corpus:** by **native-speakers** (Computational Linguistics), Data Science.

CORPUS in NLP



Archimedes 

Ancient Greek
mathematician



[Số hóa](#) > [Công nghệ](#) > [AI](#)

Thứ bảy, 8/4/2023, 15:00 (GMT+7)

Google Bard thử nghiệm vội vã trước khi ra mắt

Google được cho là đã không thực hiện quá trình thử nghiệm Bard, chatbot AI đối đầu ChatGPT, đủ chín chu trước khi công bố.

Theo *Business Insider*, [Google](#) không có thời gian và nhân lực đánh giá và cải thiện chất lượng phản hồi do Bard đưa ra. Thay vào đó, công ty giao nhiệm vụ cho các đối tác thực hiện điều này.

Theo bốn nguồn tin từ nhà thầu của Google cũng như tài liệu nội bộ, việc thử nghiệm Bard diễn ra vội vã do họ không có đủ thời gian để xác minh câu trả lời đúng từ chatbot AI.



Google [ra mắt](#) Bard ngày 6/2. Tuy nhiên, ngay khi vừa trình làng, chatbot được xem là đối thủ của ChatGPT đã [trả lời sai](#) câu hỏi về kiến thức. Điều này khiến Google [mất 100 tỷ USD](#) giá trị vốn hóa thị trường sau đó. Trước khi giới thiệu Bard, Google cũng được cho là đã yêu cầu nhân viên toàn thời gian dành từ hai đến bốn giờ để trò chuyện với bot mới. Họ sẽ đặt câu hỏi, gán cờ các câu trả lời không đáp ứng các tiêu chuẩn về độ chính xác và các yếu tố khác.

Bảo Lâm (theo *Business Insider*)

Data production

The New York Times

THE NEW NEW WORLD

How Cheap Labor Drives China's A.I. Ambitions



Workers at the headquarters of Ruijin Technology Company in Jiaxian, in central China's Henan Province. They identify objects in images to help artificial intelligence make sense of the world. Yan Cong for The New York Times

Data is the new oil, it has been said for years now. If data is the new oil, then China is already the largest producer with its factories packed with laborers working hard to annotate images and data for machine learning (*Analytics India Magazine*).

Vietnamese Computational Linguistics

Rank	Language Name	Primary Country	Population
1	CHINESE, MANDARIN	China	885,000,000
2	SPANISH	Spain	332,000,000
3	ENGLISH	United Kingdom	322,000,000
4	BENGALI	Bangladesh	189,000,000
5	HINDI	India	182,000,000
6	PORTUGUESE	Portugal	170,000,000
7	RUSSIAN	Russia	170,000,000
8	JAPANESE	Japan	125,000,000
9	GERMAN, STANDARD	Germany	98,000,000
10	CHINESE, WU (Ngô)	China	77,175,000
11	JAVANESE	Indonesia, Java, Bali	75,500,800
12	KOREAN	Korea, South	75,000,000
13	FRENCH	France	72,000,000
14	VIETNAMESE	Vietnam	67,662,000
15	TELUGU	India	66,350,000
16	CHINESE, YUE (Việt)	China	66,000,000

Abilities of Vietnamese language perception?

Việt Nam giành huy chương Vàng môn kiếm chém đồng đội

VietNam+ 06/12/2019 38 liên quan

Đây là tấm huy chương Vàng thứ 4 của đoàn thể thao Việt Nam trong ngày thi đấu chính thức thứ 6 của SEA Games 30.



Thích



Bình luận



Chia sẻ

Á hậu, MC bình thân khai nhận
nhiều lần bán dâm ngàn USD cho
khách ở trụ sở công an

Viết Dũng - Theo Trí Thức Trẻ, 06/09/2018 17:34



Á hậu có bầu với cựu HLV trưởng đội
làng Đầy

BÙI TIẾN DŨNG THỎ LỘ VIỆC VỢ CÓ BẦU VỚI CỰU HLV TRƯỞNG ĐỘI TUYỂN VIỆT NAM TẠI SÂN HÀNG ĐẦY

ttvn.vn | 07/07/2019 12:00 AM

Bùi Tiến Dũng và Viettel đã có chiến thắng tối thiểu 1-0 trước CLB TPHCM ở vòng 14 V.League 2019 diễn ra vào tối 7/7. Sau trận đấu, anh cũng có cuộc gặp mặt ngắn với





"BỎ QUA"

- Qua cũng có nói là, nếu như em thấy qua có gì không phải thì em hãy bỏ qua! Vậy mà cuối cùng cô ấy bỏ qua...
- Thì ông nói vậy mà ?
- Hồng phải, ý của qua là nếu như qua không phải thì hãy bỏ qua, chứ đừng có bỏ qua! Vậy mà cô ấy không chịu bỏ qua, cô ấy bỏ qua...

NĂM CON HỔ - NHÂM DẦN 2022

Thật ra, thì NĂM CON HỔ và NĂM CON HỔ có hai nghĩa hoàn toàn khác nhau.

Một bên là NĂM CON HỔ và bên kia là NĂM CON HỔ.

Nếu hiểu theo nghĩa NĂM CON HỔ thì nó sẽ là NĂM CON HỔ, còn nếu ta hiểu theo nghĩa của NĂM CON HỔ thì nó phải được hiểu là NĂM CON HỔ.

Vietnamese-native speaker: our strong point.

=> Our strong point: Vietnamese-native speakers

Inquiry about Machine Translation for Vietnamese

Inbox x



임행선 <hs00.lim@samsung.com>

8/9/13



to me ▾

Dear Professor Dinh Dien,

This is the Software Center at **Samsung Electronics** in Korea. Our lab is currently researching the development of Korean <-> Vietnamese machine translation.

While searching for Vietnamese universities and companies which have expertise in MT, we came across your name.

We wonder whether you have conducted research on MT for Vietnamese language, and whether you have an ongoing research or project. If you share with us how things are with you, it will be very helpful to us.

We also need the info on MT companies which work on Vietnamese. If you know any company or institution which supports Vietnamese with its own MT engine, please let us know.

Thank you in advance.

Best regards,

Haengsun Eunice Lim

Haengsun Eunice Lim

Mobile. +82-10-2320-5040 / Tel. +82-31-279-2395

E-mail. hs00.lim@samsung.com

Web Platform Lab/ Software Center

Samsung Electronics Co., LTD in Suwon, Korea

Inquiry about Machine Translation for Vietnamese



Inbox x



임행선 <hs00.lim@samsung.com>

8/9/13



to me ▾

Dear Professor Dinh Dien,

This is the Software Center at **Samsung Electronics** in Korea. Our lab is currently researching the development of Korean <-> Vietnamese machine translation.

While searching for Vietnamese universities and companies which have expertise in MT, we came across your name.

We wonder whether you have conducted research on MT for Vietnamese language, and whether you have an ongoing research or project. If you share with us how things are with you, it will very helpful to us.

We also need the info on MT companies which work on Vietnamese. If you know any company or institution which supports Vietnamese with its own MT engine, please let us know.

Thank you in advance.

Best regards,

Haengsun Eunice Lim

Haengsun Eunice Lim

Mobile. +82-10-2320-5040 / Tel. +82-31-279-2395

E-mail. hs00.lim@samsung.com

Web Platform Lab/ Software Center

Samsung Electronics Co., LTD in Suwon, Korea

Sent: Tuesday, January 19, 2016 1:58 PM
To: ddien@fit.hcmus.edu.vn
Subject: Acquiring Vietnamese treebank

Dear Prof. Dinh Dien,

HyunJeong Choe <hyunjeongc@google.com>

1/21/16



to me

Thank you so much your prompt reply!

If your treebank contain 300k, then we would like to acquire the entire set.

We are Natural language understanding team under Google research team and focusing on several NLP projects. We'd like to use your treebank to train our Vietnamese segmenter, PoS tagger and NER tagger. These analyzer will be used several Google projects such as conversational search.

The Licensee may use the data internally only. The Licensee may not:

1. Distribute the data;
2. Publish any research in which the data was used without providing a citation acknowledging that the data was developed by the Computation Linguistics Center of HCMUS.

Best,

-HJ

Date: 15-Oct-2015

From: Kohei Saito <AdvancedLinguistics@gmail.com>

Subject: Vietnamese; Computational Linguistics; Morphology; Phonology; Semantics; Syntax: Analytic Linguistic Project Manager, Google, Inc., Singapore

University or Organization: **Google, Inc.**

Department: Natural Language Understanding

Job Location: Singapore, Singapore

Job Title: Analytic Linguistic Project Manager [Vietnamese]

Job Rank: Analytic Linguistic Project Manager; Manager

Specialty Areas: Computational Linguistics; Morphology; Phonology; Semantics; Syntax

Required Language(s): [Vietnamese \(vie\)](#)

Description:

The role of the Analytic Linguistic Project Manager is to consult with Natural Language Understanding Researchers on creating guidelines and setting standards for a variety of NLP projects as well as to manage the work of a team of junior linguists to achieve high quality data output.

This includes:

- Training, managing and overseeing the work of a team of junior linguists
- Creating guidelines for semantic, syntactic and morphological projects
- Evaluating and analyzing data quality
- Consulting with researchers and engineers on the development of linguistic databases

Job requirements:

- **Native-level speaker of Vietnamese** and fluent in English
- **Master's degree or higher in Linguistics or Computational Linguistics**, specializing in semantics, syntax, morphology or lexicography
- Ability to quickly grasp technical concepts; should have an interest in natural language processing
- Excellent oral and written communication skills
- Good organizational skills
- Previous project management and people management experience preferred
- Some programming language or previous experience working in a Linux environment a plus

Hivan Fagnano hivan.fagnano@

Số hóa > Công nghệ

Thứ tư, 30/9/2020, 13:00 (GMT+7)

to clc

Greetings,

Our company is looking for
well known multinational cc
We're building up a team of
studies.

Apple tuyển người nói tiếng Việt làm Siri

Apple đang tuyển nhân sự thành thạo tiếng Việt trên trang tuyển dụng của mình, nhiều khả năng sẽ phát triển trợ lý ảo Siri cho thị trường Việt Nam.

Trên trang tuyển dụng, Apple mới bổ sung vị trí chuyên viên Ngôn ngữ Việt Nam cho mảng trí tuệ nhân tạo và học máy. Người được tuyển dụng sẽ làm việc trong đội ngũ phát triển Siri, tại văn phòng ở khu Ang Mo Kio (Singapore). Siri là trợ lý ảo của Apple và là một trong những ứng dụng thực tế nhất về AI mà Apple đang phát triển.

The project, which would last 3-5 months, involves performing quality control tasks of audio-recorded files \ voice overs in the linguists' native language, so phonetic transcription, pronunciation transcription and proofreading skills are required.

Please note that the right candidates must be native speakers of Vietnamese.

By visiting your site, I've noticed the the Computational Linguistic Center focuses on spelling checker, grammar checker, Text Translation, Contrastive Linguistics, etc. and I thought students from your course might be considered good candidates, as we need native Vietnamese speakers with the above mentioned skills.

Would it be possible talking with teachers from the Center?

MY PRODUCTS

Dictionary

An entry in the Chinese-Vietnamese Dictionary:

<WORD>

<HEAD>油然</HEAD>

<PHONETIC>yóurán</PHONETIC>

<BODY>

<TXT_V>Tự nhiên</TXT_V>

<EXAMPLE>

<TXT_C>敬慕之心，油然而生</TXT_C>

<TXT_V>Lòng ngưỡng mộ, tự nhiên mà có</TXT_V>

</EXAMPLE>

</BODY>

<BODY>

<TXT_V>hơi nước bốc lên</TXT_V>

<EXAMPLE>


<TXT_C>油然作云</TXT_C>

<TXT_V>Hơi nước bốc lên thành mây</TXT_V>


</EXAMPLE>

</BODY>

</WORD>




KÝ HIỆU CHỮ BRAILLE VIỆT NGỮ



A



Ă



Â



B



C



D



Đ



E




Ê



F




G



H



I



J



K



L



M



N



O



Ô



Ơ



P



Q



R



S




T



U




Ư




V



W



X



Y



Z



sắc



huyền



hỏi



ngã



nặng



hai chấm :




phẩy ,



chấm phẩy ;



chấm câu .



chấm thang !



chấm hỏi ?



Báo viết hoa



(



)



mở "



đóng "

Phép toán:



+



-



x



:



=



<



>



Báo số



0



1



2



3



4



5



6



7



8



9


Trung tâm dữ liệu đa ngữ

Kim Từ Điển (KMDC) chúng

tôi chuyên sản xuất các

phần mềm có hỗ trợ tiếng

Việt cho người khiếm thị.



Unit 1

Exercises

Practice

English Songs

Section A

Vocabulary

Section B





Language Technology

making good progress

mostly solved

Spam detection

Let's go to Agra!

Buy VIAGRA ...

Part-of-speech (POS) tagging

ADJ ADJ NOUN VERB ADV

Colorless green ideas sleep furiously.

Named entity recognition (NER)

PERSON ORG LOC

Einstein met with UN officials in Princeton

Sentiment analysis

Best roast chicken in San Francisco!

The waiter ignored us for 20 minutes.

Coreference resolution

Carter told Mubarak he shouldn't run again.

Word sense disambiguation (WSD)

I need new batteries for my *mouse*.

Parsing

I can see Alcatraz from the window!

Machine translation (MT)

第13届上海国际电影节开幕...

The 13th Shanghai International Film Festival...

Information extraction (IE)

You're invited to our dinner party, Friday May 27 at 8:30

Party
May 27
add

still really hard

Question answering (QA)

Q. How effective is ibuprofen in reducing fever in patients with acute febrile illness?

Paraphrase

XYZ acquired ABC yesterday

ABC has been taken over by XYZ

Summarization

The Dow Jones is up

The S&P500 jumped

Housing prices rose



Economy is good

Dialog



Where is Citizen Kane playing in SF?

Castro Theatre at 7:30. Do you want a ticket?

What do you need for NLP?



What will you learn in this NLP course?



Course content

Part I: (Assoc. Prof. Dinh Dien)

1. Introduction to Natural Languages
2. Review Formal Languages
3. Rule-based NLP: parsing
4. Corpus-based NLP: corpus linguistics

PART II: (Dr. Buu Long)

AI-ML, DL, LLM, Gen-AI,

NLP project: (4-member group)


- **Mid-term:** building Dataset
- **Final-term:** training Model

List of topics: (in various languages/scripts/fields/domains)


LLM (pre-train, finetuning,...), xxxBERT, ChatBot,
Translation, Text Mining, Classifier, OCR, Spelling checker, ...

Textbooks (theory)

01



02



(Coursera textbooks)

Speech and Language Processing

An Introduction to Natural Language Processing,
Computational Linguistics, and Speech Recognition
with Language Models

Third Edition draft

Daniel Jurafsky
Stanford University

James H. Martin
University of Colorado at Boulder

Copyright ©2024. All rights reserved.

Draft of January 12, 2025. Comments and typos welcome!

Understanding LLMs: A Comprehensive Overview from Training to Inference

Yiheng Liu^a, Hao He^a, Tianle Han^a, Xu Zhang^a, Mengyuan Liu^a, Jiaming Tian^a,
Yutong Zhang^b, Jiaqi Wang^c, Xiaohui Gao^d, Tianyang Zhong^d, Yi Pan^e, Shaochen Xu^e,
Zihao Wu^e, Zhengliang Liu^e, Xin Zhang^b, Shu Zhang^c, Xintao Hu^d, Tuo Zhang^d,
Ning Qiang^a, Tianming Liu^a and Bao Ge^a

^aSchool of Physics and Information Technology, Shaanxi Normal University, Xi'an, 710119, Shaanxi, China

^bInstitute of Medical Research, Northwestern Polytechnical University, Xi'an, 710072, Shaanxi, China

^cSchool of Computer Science, Northwestern Polytechnical University, Xi'an, 710072, Shaanxi, China

^dSchool of Automation, Northwestern Polytechnical University, Xi'an, 710072, Shaanxi, China

^eSchool of Computing, The University of Georgia, Athens, 30602, USA

CHAPTER

15

Chatbots & Dialogue Systems

Les lois de la conversation sont en général de ne s'y appesantir sur aucun objet, mais de passer légèrement, sans effort et sans affectation, d'un sujet à un autre ; de savoir y parler de choses frivoles comme de choses sérieuses

[The rules of conversation are, in general, not to dwell on any one subject, but to pass lightly from one to another without effort and without affectation; to know how to speak about trivial topics as well as serious ones.]

The 18th C. *Encyclopedia* of Diderot, start of the entry on conversation

The literature of the fantastic abounds in inanimate objects magically endowed with the gift of speech. From Ovid's statue of Pygmalion to Mary Shelley's story about Frankenstein, we continually reinvent stories about creating something and then having a chat with it. Legend has it that after finishing his sculpture *Moses*, Michelangelo thought it so lifelike that he tapped it on the knee and commanded it to speak. Perhaps this shouldn't be surprising. Language is the mark of humanity and sentience, and conversation or dialogue is the most fundamental arena of language. It is the first kind of language we learn as children, and the kind we engage in constantly, whether we are ordering lunch, buying train tickets, or talking with our families, friends, or coworkers.


This chapter introduces the fundamental algorithms of programs that use conversation to interact with users. We often distinguish between two kinds of archi-



conversation
dialogue

- Build a Large Language Model (From Scratch): <http://github.com/rasbt/LLMs-from-scratch>

Build a Large Language Model from Scratch



GitHub - rasbt/LLMs-from-scratch: Implement a...

Implement a ChatGPT-like LLM in PyTorch from scratch,
step by step - rasbt/LLMs-from-scratch

github.com

Textbooks (practice)

03

Python Natural Language Processing

Explore NLP with machine learning
and deep learning techniques

Jalaj Thanaki


Packt>

BIRMINGHAM - MUMBAI


- >  Introduction
- >  Corpus & Dataset
- >  Structure of Sentences
- >  Preprocessing
- >  Feature Engineering & NLP Algorithms
- >  Advanced Feature Engineering & NLP Algorithms
- >  Rule-based System for NLP
- >  Machine Learning for NLP Problems
- >  Deep Learning for NLU & NLG Problems
- >  Advanced Tools
- >  Improve your NLP Skills
-  Installation Guide

Reference books (ML techniques)

04




05



Reference books (training corpus)

06

A Guide to Corpus-Building for Applications



Natural Language Annotation

for Machine Learning

O'REILLY®

*James Pustejovsky
& Amber Stubbs*

- > > Preface
- > > Chapter 1. The Basics
- > > Chapter 2. Defining Your Goal and Dataset
- > > Chapter 3. Corpus Analytics
- > > Chapter 4. Building Your Model and Specification
- > > Chapter 5. Applying and Adopting Annotation Standards
- > > Chapter 6. Annotation and Adjudication
- > > Chapter 7. Training: Machine Learning
- > > **Chapter 8. Testing and Evaluation**
- > > Chapter 9. Revising and Reporting
- > > Chapter 10. Annotation: TimeML
- > > Chapter 11. Automatic Annotation: Generating TimeML
- > > Chapter 12. Afterword: The Future of Annotation
- > > Appendix A. List of Available Corpora and Specifications

Reference books (linguistics)



MORGAN & CLAYPOOL PUBLISHERS

07 Linguistic Fundamentals for Natural Language Processing

*100 Essentials from
Morphology and Syntax*

Emily M. Bender

**SYNTHESIS LECTURES ON
HUMAN LANGUAGE TECHNOLOGIES**

Graeme Hirst, *Series Editor*


- >  Introduction/motivation
- >  Morphology: Introduction
- >  Morphophonology
- >  Morphosyntax
- >  Syntax: Introduction
- >  Parts of speech
- >  Heads, arguments and adjuncts
- >  Argument types and grammatical functions
- >  Mismatches between syntactic position and semantic roles
- >  Resources

Reference books (Vietnamese)




Reference books (programming)

08



09




Reference books (applications)

10

O'REILLY®

Practical Natural Language Processing

A Comprehensive Guide to Building
Real-World NLP Systems



Sowmya Vajjala,
Bodhisattwa Majumder,
Anuj Gupta & Harshit Surana

- >  Preface
- ✓  Part I. Foundations
 - >  Chapter 1. NLP: A Primer
 - >  Chapter 2. NLP Pipeline
 - >  Chapter 3. Text Representation
- ✓  Part II. Essentials
 - >  Chapter 4. Text Classification
 - >  Chapter 5. Information Extraction
 - >  Chapter 6. Chatbots
 - >  Chapter 7. Topics in Brief
- ✓  Part III. Applied
 - >  Chapter 8. Social Media
 - >  Chapter 9. E-Commerce and Retail
 - >  Chapter 10. Healthcare, Finance, and Law
- ✓  Part IV. Bringing It All Together
 - >  Chapter 11. The End-to-End NLP Process


Reference books (applications)

11 O'REILLY®

Applied Natural Language Processing in the Enterprise

Teaching Machines to Read, Write & Understand

powered by




Ankur A. Patel &
Ajay Uppili Arasanipalai

- ✓  Part I. Scratching the Surface
 - >  Chapter 1. Introduction to NLP
 - >  Chapter 2. Transformers and Transfer Learning
 - >  Chapter 3. NLP Tasks and Applications
- ✓  Part II. The Cogs in the Machine
 - >  Chapter 4. Tokenization
 - >  Chapter 5. Embeddings: How Machines "Understand" Words
 - >  Chapter 6. Recurrent Neural Networks and Other Sequence Models
 - >  Chapter 7. Transformers
 - >  Chapter 8. BERTology: Putting It All Together
- ✓  Part III. Outside the Wall
 - >  Chapter 9. Tools of the Trade
 - >  Chapter 10. Visualization
 - >  Chapter 11. Productionization
 - >  Chapter 12. Conclusion
- >  Appendix A. Scaling

Reference course (Coursera)

1. Natural Language Processing, Dan Jurafsky (Stanford University)



Introduction to NLP

What is Natural Language Processing?



MORE VIDEOS

➔ Main reference slides: Stanford Uni.

Reference websites (papers, dataset)

Association for Computational Linguistics (ACL)

ACL Anthology <https://aclanthology.org>

- A Digital Archive of Top Research Papers in CL, NLP.

<EACL> European Chapter of the ACL

<NAACL> North American chapter of the ACL

<EMNLP> Empirical Methods in Natural Language Processing

CoNLL: Conference on Computational Natural Language Learning

COLING: International Conference on Computational Linguistics

Coursera: https://drive.google.com/file/d/16pqHirJM_HLnZu-643dPLwLgCLaMfrVy/view?usp=drivesdk

❖ Vietnamese NLP:

<https://vlsp.org.vn/> (Vietnamese Language Speech Processing)

<https://www.clc.hcmus.edu.vn/> (Computational Ling

Center, Uni. of Science, HCMC-VNU).





The ACL Anthology is a library of publications in the scientific fields of computational linguistics and speech and natural language processing. It currently hosts 121,832 papers from official venues of the Association for Computational Linguistics and other organizations.

[Info for authors](#)

[Access data](#)

[Give feedback](#)

ACL Events

Venue	2026 – 2020	2019 – 2010	2009 – 2000	1999 – 1990	1989 and older
AACL	25 23 22 20				
ACL	25 24 23 22 21 20	19 18 17 16 15 14 13 12 11 10	09 08 07 06 05 04 03 02 01 00	99 98 97 96 95 94 93 92 91 90	89 88 87 86 85 84 83 82 81 80
ANLP			00	97 94 92	88 83
ArabicNLP	25 24 23				
CL	25 24 23 22 21 20	19 18 17 16 15 14 13 12 11 10	09 08 07 06 05 04 03 02 01 00	99 98 97 96 95 94 93 92 91 90	89 88 87 86 85 84 83 82 81 80
CoNLL	25 24 23 22 21 20	19 18 17 16 15 14 13 12 11 10	09 08 07 06 05 04 03 02 01 00	99 98 97	
EACL	26 24 23 21	17 14 12	09 06 03	99 97 95 93 91	89 87 85 83
EMNLP	25 24 23 22 21 20	19 18 17 16 15 14 13 12 11 10	09 08 07 06 05 04 03 02 01 00	99 98 97 96	
Findings	26 25 24 23 22 21 20				
IWSLT	25 24 23 22 21 20	19 18 17 16 15 14 13 12 11 10	09 08 07 06 05 04		
NAACL	25 24 22 21	19 18 16 15 13 12 10	09 07 06 04 03 01 00		
SemEval	25 24 23 22 21 20	19 18 17 16 15 14 13 12 10	07 04 01	98	
*SEM	25 24 23 22 21 20	19 18 17 16 15 14 13 12			
TACL	26 25 24 23 22 21 20	19 18 17 16 15 14 13			
WMT	25 24 23 22 21 20	19 18 17 16 15 14 13 12 11 10	09 08 07 06		
WS	26 25 24 23 22 21 20	19 18 17 16 15 14 13 12 11 10	09 08 07 06 05 04 03 02 01 00	99 98 97 96 95 94 93 91 90	89 87 85 83 81
SIGs	ANN ARAB BIOMED DAT DIAL EDU EL FSM GEN HAN HUM LEX MEDIA MOL MORPHON MT NLL PARSE REP SEC SEM SEMITIC SLAV SLPAT SLT Turk TYF				

Non-ACL Events

Venue	2026 – 2020	2019 – 2010	2009 – 2000	1999 – 1990	1989 and older
AIME-Con	25				
ALTA	25 24 23 22 21 20	19 18 17 16 15 14 13 12 11 10	09 08 07 06 05 04 03		



Annual Meeting of the Association for Computational Linguistics (2025)

Volumes

- [Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics \(Volume 1: Long Papers\)](#) 1603 papers
- [Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics \(Volume 2: Short Papers\)](#) 98 papers
- [Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics \(Volume 3: System Demonstrations\)](#) 65 papers
- [Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics \(Volume 4: Student Research Workshop\)](#) 87 papers
- [Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics \(Volume 5: Tutorial Abstracts\)](#) 9 papers
- [Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics \(Volume 6: Industry Track\)](#) 110 papers
- [Findings of the Association for Computational Linguistics: ACL 2025](#) 1388 papers
- [Proceedings of the Sixth Workshop on African Natural Language Processing \(AfricaNLP 2025\)](#) 28 papers
- [Proceedings of the 2nd Workshop on Analogical Abstraction in Cognition, Perception, and Language \(Analogy-Angle II\)](#) 10 papers
- [Proceedings of the 12th Argument mining Workshop](#) 40 papers
- [Proceedings of the 20th Workshop on Innovative Use of NLP for Building Educational Applications \(BEA 2025\)](#) 104 papers
- [Proceedings of the 24th Workshop on Biomedical Language Processing](#) 35 papers
- [Proceedings of the 24th Workshop on Biomedical Language Processing \(Shared Tasks\)](#) 35 papers
- [Proceedings of the 10th Workshop on Slavic Natural Language Processing \(Slavic NLP 2025\)](#) 28 papers
- [Proceedings of the 2nd Workshop on Natural Language Processing Meets Climate Change \(ClimateNLP 2025\)](#) 22 papers
- [Proceedings of the 29th Conference on Computational Natural Language Learning](#) 41 papers
- [Proceedings of the Eighth Fact Extraction and VERification Workshop \(FEVER\)](#) 23 papers
- [Proceedings of the Fourth Workshop on NLP Applications to Field Linguistics](#) 9 papers
- [Proceedings of the 6th Workshop on Gender Bias in Natural Language Processing \(GeBNLP\)](#) 36 papers
- [Proceedings of the Fourth Workshop on Generation, Evaluation and Metrics \(GEM²\)](#) 68 papers
- [Proceedings of the 22nd International Conference on Spoken Language Translation \(IWSLT 2025\)](#) 45 papers
- [Proceedings of the 3rd Workshop on Towards Knowledgeable Foundation Models \(KnowFM\)](#) 13 papers
- [Proceedings of the First Workshop on Large Language Model Memorization \(L2M2\)](#) 18 papers
- [Proceedings of the 19th Linguistic Annotation Workshop \(LAW-XIX-2025\)](#) 31 papers
- [Proceedings of the The First Workshop on LLM Security \(LLMSEC\)](#) 16 papers
- [Proceedings of the 1st Workshop on Multimodal Augmented Generation via Multimodal Retrieval \(MAGMaR 2025\)](#) 10 papers

- [pdf](#) [bib](#) [abs](#) **Rethinking Data Use in Large Language Models**
Sewon Min | Hannaneh Hajishirzi | Luke Zettlemoyer
- [pdf](#) [bib](#) [abs](#) **Tokenization as Finite-State Transduction**
Marco Cognition | Naoaki Okazaki
- [pdf](#) [bib](#) [abs](#) **IDT: Dual-Task Adversarial Rewriting for Attribute Anonymization**
Pedro Faustini | Shakila Mahjabin Tonni | Annabelle McIver | Qionghai Xu | Mark Dras
- [pdf](#) [bib](#) [abs](#) **Measuring Grammatical Diversity from Small Corpora: Derivational Entropy Rates, Mean Length of Utterances, and Annotation Invariance**
Fermín Moscoso del Prado Martín
- [pdf](#) [bib](#) [abs](#) **LGDE: Local Graph-based Dictionary Expansion**
Juni Schindler | Sneha Jha | Xixuan Zhang | Kilian Buehling | Annett Heft | Mauricio Barahona
- [pdf](#) [bib](#) [abs](#) **BLiMP-NL: A Corpus of Dutch Minimal Pairs and Acceptability Judgments for Language Model Evaluation**
Michelle Suijkerbuijk | Zoë Prins | Marianne de Heer Kloots | Willem Zuidema | Stefan L. Frank
- [pdf](#) [bib](#) [abs](#) **A Novel Methodology for Enhancing Cross-language and Domain Adaptability in Temporal Expression Normalization**
Alejandro Sánchez de Castro | Lourdes Araujo | Juan Martinez-Romo
- [pdf](#) [bib](#) [abs](#) **Problem Solving Through Human-AI Preference-based Cooperation**
Subhabrata Dutta | Timo Kaufmann | Goran Glavaš | Ivan Habernal | Kristian Kersting | Frauke Kreuter | Mira Mezini | Iryna Gurevych | Eyke Hüllermeier | Hinrich Schütze
- [pdf](#) [bib](#) [abs](#) 🧜♂️ **Siren's Song in the AI Ocean: A Survey on Hallucination in Large Language Models**
Yue Zhang | Yafu Li | Leyang Cui | Deng Cai | Lemao Liu | Tingchen Fu | Xinting Huang | Enbo Zhao | Yu Zhang | Yulong Chen | Longyue Wang | Anh Tuan Luu | Wei Bi | Freda Shi | Shuming Shi
- [pdf](#) [bib](#) [abs](#) **We Should Evaluate Real-World Impact**
Ehud Reiter

Rethinking Data Use in Large Language Models

Sewon Min^{1*}, Hannaneh Hajishirzi², and Luke Zettlemoyer³

¹Paul G. Allen School of Computer Science & Engineering, University of Washington
sewon@cs.washington.edu

²Paul G. Allen School of Computer Science & Engineering, University of Washington
hannaneh@cs.washington.edu

³Paul G. Allen School of Computer Science & Engineering, University of Washington
lsz@cs.washington.edu

Large language models (LMs) such as ChatGPT have revolutionized natural language processing and artificial intelligence more broadly. In this work, we discuss our research on understanding and advancing these models, centered around how they use the very large text corpora they are trained on. First, we describe our efforts to understand how these models learn to perform new tasks after training, demonstrating that their so-called in-context learning capabilities are almost entirely determined by what they learn from the training data. Next, we introduce a new class of LMs—nonparametric LMs—that repurpose this training data as a data store from which they retrieve information for improved accuracy and updatability. We discuss our work establishing the foundations of such models, including one of the first broadly used neural retrieval models and an approach that simplifies a traditional, two-stage pipeline into one. We also discuss how nonparametric models open up new avenues for responsible data use, e.g., by segregating permissive and copyrighted text and using them differently. Finally, we envision the next generation of LMs we should build, focusing on efficient scaling, improved factuality, and decentralization.

1. Introduction

Developing general-purpose NLP systems has long been a central goal of AI research (Turing 1980; Winograd 1971; Lockman and Klappholz 1983; McCarthy et al. 2006). Such models must address varied tasks, such as

- Classifying the sentiment of movie reviews (sentiment analysis)
- Answering user questions about the world (question answering [QA])

* Corresponding author.