

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN



ĐỒ ÁN CUỐI KỲ

Phân tích và dự đoán xác suất kết thúc session từ dữ liệu clickstream

Môn học: Xử Lý Số Liệu Thống Kê

Giáo Viên Hướng Dẫn:
TS. Tô Đức Khánh

Học viên thực hiện:
25C23002 Nguyễn Nhật Quang
25C23014 Lê Hoàng Như
25C23012 Phạm Đoàn Vĩnh Nghi

Thành Phố Hồ Chí Minh, 2026

Mục lục

1	Giới thiệu chung và bản đề xuất phân tích	1
1.1	Giới thiệu bộ dữ liệu	1
1.2	Ý nghĩa các biến và biến mục tiêu	1
1.3	Các mục tiêu phân tích	2
1.4	Phương pháp và chiến lược phân tích	3
1.4.1	Chiến lược cho Mục tiêu 1	3
1.4.2	Chiến lược cho Mục tiêu 2 và Mục tiêu 3	3
2	Khám phá và tổng hợp dữ liệu	4
2.1	Làm sạch dữ liệu	4
2.1.1	Kiểm tra chất lượng và tính toàn vẹn	4
2.1.2	Chuẩn hóa kiểu dữ liệu và biến dẫn xuất	5
2.1.3	Ngoại lai, ngày thu thập dữ liệu và kiểm soát rò rỉ	5
2.2	Thống kê mô tả	6
2.3	Trực quan hóa dữ liệu	8
2.4	Đánh giá tổng hợp và đề xuất bổ sung	11
2.4.1	Đánh giá mức độ sẵn sàng của dữ liệu	11
2.4.2	Các kiểm tra EDA nên bổ sung khi mở rộng báo cáo	12
3	Kết quả phân tích và mô hình hóa	12
3.1	Kết quả so sánh xác suất Exit giữa hai nhóm giá quan sát	12
3.1.1	Kết quả kiểm định	13
3.1.2	Kiểm tra balance giữa hai nhóm	14
3.1.3	Dị biệt hiệu ứng theo danh mục	15
3.1.4	Độ ổn định theo thời gian	16
3.2	Kết quả mô hình dự đoán: xác suất Exit theo tiến trình session	16
3.3	Kết quả mô hình dự đoán: giá trị bổ sung của các nhóm biến	17
3.4	Chẩn đoán mô hình	21
3.5	Kết quả mô hình phân loại: so sánh ba phương pháp	22
3.5.1	Các metric được sử dụng	22
3.5.2	Lựa chọn mô hình trên validation	23
3.5.3	Hiệu năng cuối trên temporal test	24
4	Nhận xét và kết luận	26
4.1	Nhận xét về kết quả phân tích	26
4.1.1	Mô hình nào hoạt động tốt nhất và tại sao	26
4.1.2	Các biến có ảnh hưởng lớn nhất	27
4.1.3	Kết luận về kiểm định hai nhóm giá	27
4.2	Kết luận tổng thể và khuyến nghị	28
4.2.1	Những hiểu biết rút ra	28
4.2.2	Khuyến nghị hành động	28

5	Hạn chế và hướng phát triển	29
5.1	Hạn chế của phân tích	29
5.1.1	Hạn chế về thiết kế nghiên cứu	29
5.1.2	Hạn chế về dữ liệu	29
5.1.3	Hạn chế về mô hình	30
5.2	Đề xuất một thí nghiệm A/B ngẫu nhiên thực sự	30
5.3	Hướng phát triển khác	31
6	Phụ lục	31
6.1	Hiệu năng phân tầng của mô hình được chọn	31
6.2	Phân công công việc	32
6.3	Ghi chú về tính tái lập	32

Danh sách bảng

1	Tổng quan bộ dữ liệu	1
2	Từ điển biến và vai trò trong phân tích	2
3	Chia dữ liệu theo thời gian	4
4	Kết quả kiểm tra chất lượng dữ liệu	5
5	Số quan sát qua các bước làm sạch và chia dữ liệu	6
6	Thống kê mô tả các biến định lượng	6
7	Bảng tần số các biến phân loại chính	7
8	Tỷ lệ Exit theo nhóm giá trên tập validation tháng 7	13
9	Tổng hợp các kiểm định so sánh hai nhóm giá (tháng 7)	13
10	Adjusted risk difference của nhóm giá theo từng danh mục (tháng 7)	15
11	Độ ổn định theo thời gian của khác biệt giữa hai nhóm giá	16
12	Tỷ lệ Exit gộp theo khoảng Order trên tháng 7	16
13	So sánh ba tầng predictor của ba phương pháp trên validation tháng 7	18
14	Mười hai nhóm biến có bằng chứng liên hệ mạnh nhất trong Logistic GLM history-enhanced (Wald robust theo cụm session)	19
15	Kiểm tra kích thước basis của GAM history-enhanced	21
16	Mười GVIF điều chỉnh lớn nhất của Logistic GLM (trái) và năm cặp term có concavity cao nhất trong GAM (phải)	21
17	Metric validation tháng 7 dùng để lựa chọn mô hình	23
18	Hiệu năng cuối của ba mô hình trên temporal test 01–12/08; khoảng tin cậy 95% từ 500 lần cluster bootstrap theo session	24
19	Ma trận nhầm lẫn và các metric phân loại trên temporal test, tại threshold đã khóa từ prediction out-of-fold của train	26
20	Hiệu năng phân tầng của Logistic GLM trên temporal test 01–12/08	31
21	Phân công công việc trong nhóm	32
22	Môi trường thực thi	32

Danh sách hình vẽ

1	Phân phối giá sản phẩm và phân phối độ dài session (trục hoành thang log10)	8
2	Số lượt click theo danh mục sản phẩm và theo vị trí ảnh trên trang	9
3	Phân phối giá theo danh mục sản phẩm	10
4	Lưu lượng click và số session theo ngày	11
5	So sánh tỷ lệ Exit giữa hai nhóm giá trên tháng 7, thanh sai số là khoảng tin cậy Wilson 95%	14
6	Hai mươi covariate mất cân bằng nhất giữa hai nhóm giá	14
7	Forest plot adjusted risk difference của nhóm giá theo danh mục	15
8	Xác suất Exit quan sát và dự đoán theo tiến trình session; ba đường dự đoán được chuẩn hóa trên phân phối covariate tháng 7	17
9	Các hàm trơn của GAM history-enhanced: partial effect của Order, Price, độ lớn thay đổi giá và tỷ lệ quay lại sản phẩm (thang log-odds)	20
10	Binned residual plot của Logistic GLM trên temporal test 01–12/08	22
11	Đường ROC, đường Precision–Recall và calibration plot của ba mô hình trên temporal test 01–12/08	25

1 Giới thiệu chung và bản đề xuất phân tích

1.1 Giới thiệu bộ dữ liệu

Bộ dữ liệu **e-shop clothing 2008** ghi nhận toàn bộ hành vi click trên một cửa hàng quần áo trực tuyến của Ba Lan trong năm 2008. Mỗi dòng dữ liệu là một lượt click; các click có cùng **session_id** tạo thành một phiên duyệt web và biến **order** cho biết vị trí của click trong phiên đó. Dữ liệu được công bố kèm nghiên cứu của Lapczynski và Bialowas (2013) [4] về hành vi người dùng trong cửa hàng trực tuyến, và hiện được lưu trữ tại UCI Machine Learning Repository [5].

Nhóm chọn bộ dữ liệu này vì ba lý do. Thứ nhất, quy mô đủ lớn (165.474 click của 24.026 session) để tách tập huấn luyện và tập kiểm tra theo thời gian mà vẫn còn đủ quan sát. Thứ hai, dữ liệu có cấu trúc tuần tự theo session, cho phép đặt một câu hỏi thống kê phi tầm thường thay vì chỉ mô tả. Thứ ba, dữ liệu kết hợp cả biến liên tục (giá) lẫn nhiều biến phân loại (danh mục, màu sắc, vị trí ảnh, trang hiển thị), phù hợp để so sánh hồi quy tuyến tính, GLM và GAM trên cùng một bài toán.

Bảng 1: Tổng quan bộ dữ liệu

Chỉ tiêu	Giá trị
Số click	165.474
Số session	24.026
Số quốc gia / mã miền	47
Số sản phẩm	217
Số danh mục	4
Khoảng thời gian	01/04/2008 – 13/08/2008
Tỷ lệ Continue	85,48%
Tỷ lệ Exit	14,52%

Bên cạnh các ưu điểm trên, dữ liệu cũng có giới hạn cần nêu ngay từ đầu vì nó quyết định phạm vi kết luận: không có thông tin giao dịch, giỏ hàng hay thanh toán; không có giờ click và thời lượng giữa hai click; và tháng 8 chỉ được thu thập đến ngày 13, trong đó riêng ngày 13/08 chỉ có 200 click. Vì vậy không thể so sánh tổng lưu lượng tháng 8 trực tiếp với các tháng đầy đủ.

1.2 Ý nghĩa các biến và biến mục tiêu

Bảng 2 tóm tắt ý nghĩa và vai trò của từng biến trong phân tích. Có ba điểm dễ hiểu sai cần lưu ý: **location** là vị trí của *bức ảnh* trong sáu vùng của trang web chứ không phải vị trí địa lý của khách hàng; **category** tương ứng cột **PAGE 1** (danh mục chính) còn **page** tương ứng cột **PAGE** (số trang hiển thị 1–5); biến **year** bị loại vì chỉ nhận một giá trị duy nhất nên không có biến thiên.

Bảng 2: Từ điển biến và vai trò trong phân tích

Biến	Ý nghĩa	Vai trò
year, month, day	Ngày lịch; không có giờ hoặc thời lượng	Tạo <code>time_30</code> ; <code>year</code> bị loại vì không biến thiên
order	Thứ tự click trong session	Predictor, dùng $\log_2(\text{order})$ hoặc hàm trơn
country	Quốc gia hoặc loại tên miền của IP	Predictor factor; mức hiếm được gộp trên train
session_id	Mã session	Nhóm dữ liệu và tính robust SE; không làm predictor
category	PAGE 1: trousers, skirts, blouses hoặc sale	Predictor factor
product_model	PAGE 2: mã của 217 sản phẩm	Không đưa vào mô hình chính do có 217 mức
colour	Màu sản phẩm	Predictor factor
location	Vị trí ảnh trong sáu vùng của trang; không phải địa lý	Predictor factor
photography	Kiểu ảnh en face hoặc profile	Predictor factor
price	Giá sản phẩm, USD	Predictor liên tục
price_above_avg	1 = cao hơn trung bình danh mục; 2 = không	Tạo biến phân nhóm để so sánh hai nhóm giá; không đưa đồng thời biến <code>price</code> liên tục vào mô hình điều chỉnh chính.
page	Trang hiển thị trong website, từ 1 đến 5	Predictor factor

Bộ dữ liệu gốc không có sẵn biến mục tiêu. Nhóm định nghĩa target thống nhất cho mọi mô hình xác suất trong báo cáo là biến nhị phân `Exit`:

$$Exit_{it} = \begin{cases} 1, & \text{click hiện tại là click cuối của session;} \\ 0, & \text{session còn click tiếp theo.} \end{cases}$$

Biến `session_length` chỉ được dùng để *tạo* target và tuyệt đối không được đưa vào tập predictor, vì tại thời điểm click thứ t độ dài cuối cùng của session là thông tin tương lai. Đại lượng được nghiên cứu vì vậy là một xác suất nguy cơ rời rạc (discrete-time hazard):

$$P\{Exit_{it} = 1 \mid \text{session đã tiếp tục đến click } t\}.$$

Tại `order = t`, mẫu số chỉ gồm các session còn tồn tại đến click t . Do đó mọi kết quả theo `order` là quan hệ *có điều kiện* trên nhóm session còn sống sót, không phải bằng chứng rằng việc tăng số click gây ra thay đổi nguy cơ kết thúc.

1.3 Các mục tiêu phân tích

1. **So sánh xác suất Exit giữa hai nhóm giá quan sát.** Kiểm định xem xác suất Exit có khác nhau giữa các lượt click vào sản phẩm có giá cao hơn trung bình danh mục (nhóm B) và các lượt click vào sản phẩm có giá không cao hơn trung bình danh mục (nhóm A) hay không.
2. **Phân tích các yếu tố liên quan đến Exit.** Mô tả quan hệ giữa xác suất kết thúc và tiến trình session; đánh giá xem đặc điểm của click hiện tại và lịch sử duyệt đã quan sát có bổ sung thông tin dự báo hay không.

3. **Xây dựng và so sánh mô hình.** So sánh Linear Probability Model (LPM), Logistic GLM và Binomial GAM về khả năng phân biệt, chất lượng xác suất dự đoán, calibration và khả năng diễn giải.

Cần nhấn mạnh một điểm về thiết kế: nhóm giá không được gán ngẫu nhiên cho người dùng mà được xác định từ một thuộc tính sẵn có của sản phẩm. Vì vậy, Mục tiêu 1 là phép so sánh hai nhóm trên dữ liệu quan sát, không phải một thí nghiệm A/B ngẫu nhiên có treatment và control. Mọi kết luận rút ra chỉ phản ánh mối liên hệ, không phải quan hệ nhân quả.

1.4 Phương pháp và chiến lược phân tích

1.4.1 Chiến lược cho Mục tiêu 1

Giả thuyết được phát biểu hai phía tại mức ý nghĩa $\alpha = 0,05$:

$$H_0 : P(\text{Exit} = 1 \mid A) = P(\text{Exit} = 1 \mid B), \quad H_1 : P(\text{Exit} = 1 \mid A) \neq P(\text{Exit} = 1 \mid B).$$

Các bước thực hiện gồm: (i) tính tỷ lệ **Exit** thô và khoảng tin cậy Wilson [8] cho từng nhóm; (ii) ước lượng risk difference thô kèm khoảng tin cậy cluster-bootstrap theo session; (iii) ước lượng adjusted odds ratio và adjusted risk difference từ mô hình logistic có kiểm soát tiến trình session, thời gian, country và đặc điểm sản phẩm, với sai số chuẩn cluster-robust theo **session_id** [10, 1]; (iv) kiểm tra balance giữa hai nhóm bằng standardized mean difference; (v) kiểm tra dị biệt hiệu ứng theo **category** với hiệu chỉnh đa kiểm định Holm [3]; (vi) lặp lại phân tích trên ba giai đoạn thời gian để đánh giá độ ổn định.

1.4.2 Chiến lược cho Mục tiêu 2 và Mục tiêu 3

Ba tầng predictor được so sánh trên cùng một pipeline:

- **Baseline:** $\log_2(\text{order}) + \text{time}_{30} + \text{country}$.
- **Current-click:** thêm **price**, **category**, **colour**, **location**, **photography** và **page**.
- **History-enhanced:** thêm số sản phẩm và số danh mục duy nhất đã xem, cờ quay lại sản phẩm cũ, cờ chuyển danh mục và chuyển trang, chênh lệch giá so với click trước và so với trung bình lịch sử, tỷ lệ quay lại sản phẩm và tỷ lệ chuyển danh mục.

Mọi đặc trưng lịch sử tại click t chỉ sử dụng dữ liệu từ click 1 đến t , nên không rò rỉ thông tin tương lai. Biến **order** được đưa vào dưới dạng $\log_2$ trong LPM và Logistic GLM, và dưới dạng hàm trơn $s(\cdot)$ trong GAM [9], thay vì loại bỏ các session dài nằm ngoài râu boxplot. LPM và Logistic GLM dùng cluster-robust covariance theo **session_id**; GAM dùng link logit với ước lượng fREML. Việc chia dữ liệu được thực hiện theo thời gian chứ không ngẫu nhiên, để mô phỏng đúng tình huống dự báo trong thực tế (Bảng 3).

Bảng 3: Chia dữ liệu theo thời gian

Tập	Thời gian	Số click	Số session
Train	Tháng 4–6	116.095	17.031
Validation	Tháng 7	35.231	5.071
Temporal test	01–12/08	13.948	1.903
Loại khỏi đánh giá	13/08	200	21

Ngày 13/08 bị loại khỏi mọi đánh giá vì chỉ có 200 click, nhiều khả năng là ngày thu thập chưa hoàn tất. Toàn bộ quy tắc tiền xử lý được học trên tập train: các country có dưới 100 click trong train được gộp thành mức `Other`, rồi áp dụng nguyên quy tắc đó cho validation và temporal test. Không có session nào xuất hiện đồng thời trong hai tập bất kỳ, nên không có rò rỉ dữ liệu theo cụm.

Về đánh giá, do lớp `Exit` chiếm thiểu số (14,52%), Accuracy không được dùng làm tiêu chí chọn mô hình. Thay vào đó nhóm dùng ROC–AUC, Average Precision, log loss, Brier score, Brier Skill Score và hai chỉ số calibration (intercept và slope) [7]. Threshold tối đa hóa F_1 được chọn từ prediction out-of-fold của five-fold cross-validation *theo session* trên tập train, và bị khóa lại trước khi chạm vào validation hay temporal test. Tháng 7 được dùng để so sánh đặc tả và chọn mô hình; các ngày 01–12/08 chỉ được mở đúng một lần ở cuối để báo cáo khả năng khái quát hóa.

2 Khám phá và tổng hợp dữ liệu

2.1 Làm sạch dữ liệu

Quy trình làm sạch được thực hiện theo thứ tự cố định: (i) kiểm tra dữ liệu gốc; (ii) sắp xếp và kiểm tra tính toàn vẹn của từng session; (iii) tạo biến ngày, biến mục tiêu và các đặc trưng dẫn xuất; (iv) chia dữ liệu theo thời gian; và (v) chỉ học các quy tắc tiền xử lý từ tập train. Thứ tự này vừa giữ nguyên cấu trúc tuần tự của clickstream, vừa ngăn thông tin từ validation hoặc temporal test ảnh hưởng ngược trở lại tập huấn luyện.

2.1.1 Kiểm tra chất lượng và tính toàn vẹn

Trên toàn bộ 165.474 dòng của 24.026 session, nhóm kiểm tra giá trị khuyết, dòng trùng hoàn toàn, khả năng chuyển đổi ba cột ngày và trình tự `order` trong từng session. Một session hợp lệ phải bắt đầu tại `order = 1` và tăng liên tục từng đơn vị đến click cuối; điều kiện này quan trọng hơn việc chỉ kiểm tra min–max vì nó phát hiện được click bị thiếu hoặc sai thứ tự ở giữa phiên. Kết quả được tổng hợp ở Bảng 4.

Bảng 4: Kết quả kiểm tra chất lượng dữ liệu

Kiểm tra	Số trường hợp vi phạm
Giá trị khuyết thiếu	0
Dòng trùng hoàn toàn	0
Ngày không chuyển đổi được	0
Session có order không liên tục	0
Session không có đúng một Exit	0
Session xuất hiện ở nhiều tập phân tích	0

Hai hàng cuối của bảng là kiểm tra trên dữ liệu *sau biến đổi*, không phải thuộc tính có sẵn trong file gốc. Cụ thể, bộ dữ liệu gốc không có biến **Exit**. Sau khi sắp xếp theo **session_id** và **order**, nhóm tính

$$\text{session_length}_i = \max_t(\text{order}_{it}), \quad \text{Exit}_{it} = \mathbb{I}(\text{order}_{it} = \text{session_length}_i).$$

Sau bước này, mỗi session phải có đúng một dòng **Exit** = 1; kết quả kiểm tra cho thấy không có vi phạm. Biến **session_length** sau đó bị loại khỏi tập predictor vì chứa thông tin về tương lai của session. Như vậy biến này chỉ được dùng để tạo nhãn và kiểm tra dữ liệu, không được phép đi vào mô hình.

2.1.2 Chuẩn hóa kiểu dữ liệu và biến dẫn xuất

Các cột mã số nguyên có bản chất phân loại được chuyển thành factor kèm nhãn đọc được: **country** (47 mức trong dữ liệu gốc), **category** (4 mức), **colour** (14 mức), **location** (6 mức), **photography** (2 mức) và **page** (5 mức). Việc chuyển kiểu này ngăn mô hình diễn giải sai chênh lệch giữa hai mã số như một khoảng cách định lượng. Ngược lại, **price** và **order** được giữ ở dạng số vì độ lớn của chúng có ý nghĩa.

Ba cột **year**, **month**, **day** được ghép thành một biến ngày. Dữ liệu sau chuyển đổi nằm trong khoảng 01/04/2008–13/08/2008 và không phát sinh giá trị ngày bị thiếu. Vì **year** chỉ nhận giá trị 2008, cột này không có biến thiên và không được đưa riêng vào mô hình. Từ biến ngày, nhóm tạo **time_30**, tính theo số đơn vị 30 ngày kể từ 01/04/2008, để mô hình hóa xu hướng thời gian mà không dùng trực tiếp ba mã lịch rời rạc.

Dữ liệu không có giá trị khuyết nên không cần nội suy hay gán giá trị thay thế; không có dòng trùng nên cũng không có quan sát nào bị xóa vì trùng lặp. Đối với **country**, 47 mức gốc tạo ra nhiều nhóm có tần số thấp. Sau khi chia dữ liệu theo thời gian, chỉ các country có ít nhất 100 click trong tập train được giữ thành mức riêng; các mức còn lại được gộp vào **Other**. Ngưỡng và danh sách mức giữ lại được xác định hoàn toàn trên train rồi áp dụng nguyên trạng cho validation và temporal test.

2.1.3 Ngoại lai, ngày thu thập dở dang và kiểm soát rò rỉ

Nhóm **không** xóa và cũng không winsorize các session dài, dù chúng nằm xa ngoài râu boxplot (**order** lớn nhất là 195). Các session này vượt qua kiểm tra thứ tự liên tục và do đó được xem là hành vi duyệt dài hợp lệ, không phải lỗi ghi nhận. Thay vì làm mất thông tin ở phần đuôi, nhóm

dùng $\log_2(\text{order})$ trong LPM/Logistic và hàm trơn trong GAM. Cách xử lý này giảm ảnh hưởng đòn bẩy của các giá trị lớn nhưng vẫn bảo toàn toàn bộ session.

Ngày 13/08 chỉ có 200 click của 21 session và nhiều khả năng là ngày thu thập dở dang. Các dòng này vẫn được giữ khi mô tả phạm vi dữ liệu và kiểm tra chất lượng, nhưng bị loại trước khi đánh giá mô hình để tránh xem một ngày không đầy đủ như một mẫu thời gian bình thường. Bảng 5 trình bày số quan sát còn lại qua các bước; việc giảm 200 dòng là do quy tắc đánh giá theo thời gian, không phải do xóa ngoại lai.

Bảng 5: Số quan sát qua các bước làm sạch và chia dữ liệu

Giai đoạn	Số click	Số session
Dữ liệu gốc / dùng cho EDA	165.474	24.026
Xóa do khuyết, trùng hoặc sai thứ tự	0	0
Loại ngày 13/08 khỏi đánh giá	200	21
Còn lại cho train/validation/test	165.274	24.005

Cuối cùng, việc chia tập được thực hiện ở cấp session theo ngày, không chia ngẫu nhiên từng click. Kiểm tra sau chia xác nhận không session nào xuất hiện ở nhiều tập. Các đặc trưng lịch sử tại click thứ t cũng chỉ được tính từ click 1 đến t ; không sử dụng click $t + 1$, độ dài cuối cùng của session hay bất kỳ thống kê nào được học từ validation/test. Đây là hai lớp kiểm soát chính đối với rò rỉ dữ liệu theo cụm và rò rỉ thông tin tương lai; chi tiết các mốc chia được trình bày ở Bảng 3.

2.2 Thống kê mô tả

Cần phân biệt hai đơn vị phân tích khác nhau. Phân phối **order** được tính trên toàn bộ click, còn phân phối độ dài session được tính ở cấp session. Vì các session dài đóng góp nhiều click hơn vào tổng thể, không được dùng trung vị **order** trên click để kết luận về một session điển hình. Bảng 6 vì vậy ghi rõ đơn vị của từng thống kê; các phân tích suy luận ở phần sau tiếp tục xử lý session như cụm quan sát thay vì giả định mọi click độc lập [1].

Bảng 6: Thống kê mô tả các biến định lượng

Biến	Đơn vị	N	Mean	Median	Q1	Q3	Min	Max	SD
Price	Click	165.474	43,80	43	33	52	18	82	12,55
Order	Click	165.474	9,82	6	2	12	1	195	13,48
Session length	Session	24.026	6,89	4	2	8	1	195	9,00

Giá sản phẩm chỉ nhận 20 mức rời rạc từ 18 đến 82 USD, nên phân phối có nhiều đỉnh; việc trung bình (43,80) gần trung vị (43) *không* đủ để kết luận biến này tuân theo phân phối chuẩn. Ngược lại, độ dài session lệch phải rất mạnh: trung vị chỉ 4 click trong khi trung bình là 6,89; có 2,48% session dài hơn 30 click và 0,071% session dài hơn 100 click.

Do mỗi session có đúng một click cuối, tỷ lệ **Exit** toàn bộ dữ liệu không phải một tỷ lệ lớp hoàn toàn độc lập với độ dài session mà thỏa đẳng thức

$$\hat{P}(Exit = 1) = \frac{\text{số session}}{\text{số click}} = \frac{24.026}{165.474} = 14,52\% \approx \frac{1}{6,89}.$$

Nói cách khác, tỷ lệ **Exit** gộp chính là nghịch đảo của độ dài session trung bình. Nhận xét này giúp tránh diễn giải 14,52% như một “tỷ lệ rời bỏ” độc lập với cách dữ liệu được tổ chức; câu hỏi có ý nghĩa hơn là xác suất kết thúc thay đổi thế nào theo vị trí hiện tại và lịch sử đã quan sát của session.


Bảng 7: Bảng tần số các biến phân loại chính

Biến	Nhóm	Số click	Tỷ lệ
Category	Trousers	49.742	30,06%
	Skirts	38.408	23,21%
	Blouses	38.577	23,31%
	Sale	38.747	23,42%
Location	Top left	34.532	20,87%
	Top middle	33.383	20,17%
	Top right	21.656	13,09%
	Bottom left	27.377	16,54%
	Bottom middle	27.783	16,79%
	Bottom right	20.743	12,54%
Photography	En face	122.439	73,99%
	Profile	43.035	26,01%
Price group	A: Không cao hơn TB	80.779	48,82%
	B: Cao hơn TB	84.695	51,18%
Page	Page 1	93.452	56,48%
	Page 2	41.037	24,80%
	Page 3	19.301	11,66%
	Page 4	8.861	5,35%
	Page 5	2.823	1,71%

Hai nhóm giá gần cân bằng về số lượng (48,82% so với 51,18%), thuận lợi cho việc ước lượng chênh lệch. Tuy nhiên, đây là tỷ trọng trên click; một session có thể đóng góp nhiều click và xuất hiện ở cả hai nhóm, nên không thể xem 165.474 dòng như 165.474 phép gán độc lập. Mức cân bằng covariate, thay vì chỉ cân bằng số dòng, được đánh giá riêng ở Mục 3.1.


Phân phối **page** rất lệch: hơn một nửa số click nằm ở trang 1 và chỉ 1,71% ở trang 5. Biến này được giữ ở dạng factor vì chênh lệch từ trang 1 sang 2 không nhất thiết tương đương chênh lệch từ trang 4 sang 5; cách mã hóa này không áp đặt một xu hướng tuyến tính tùy ý. Đổi lại, hiệu ứng của trang 5 sẽ có độ bất định lớn hơn do số quan sát ít.

2.3 Trực quan hóa dữ liệu




Hình 1: Phân phối giá sản phẩm và phân phối độ dài session (trục hoành thang log10)

Hình 1 cho thấy phân phối giá có dạng răng cưa, phản ánh đúng bản chất rời rạc của các mức giá niêm yết. Phân phối độ dài session lệch phải mạnh, phù hợp với chênh lệch mean–median và các tỷ lệ phần đuôi đã báo cáo ở Bảng 6. Hình này cung cấp bằng chứng trực quan cho quyết định giữ các session dài và xử lý dạng hàm của `order`, thay vì coi chúng là lỗi rồi xóa khỏi mẫu.



Hình 2: Số lượt click theo danh mục sản phẩm và theo vị trí ảnh trên trang

Danh mục Trousers có số click cao hơn rõ rệt so với ba danh mục còn lại (30,06% so với khoảng 23% mỗi nhóm). Đây chỉ là mô tả lưu lượng xem, chưa đủ để kết luận danh mục này hấp dẫn hơn hay tạo chuyển đổi tốt hơn. Bộ dữ liệu chỉ ghi nhận click, không cung cấp số lần mỗi sản phẩm hoặc danh mục đã được hiển thị; do thiếu mẫu số lượt hiển thị, không thể tính click-through rate hay tách mức độ ưa thích khỏi mức độ được tiếp xúc [5]. Tương tự, kiểm tra chéo `product_model` với `location` cho thấy mỗi mã sản phẩm chỉ gắn với một vị trí trong dữ liệu; do đó khác biệt theo `location` không thể tách hoàn toàn khỏi khác biệt giữa các sản phẩm.




Hình 3: Phân phối giá theo danh mục sản phẩm

Hình 3 cho thấy mặt bằng giá khác biệt rõ giữa bốn danh mục. Vì biến `price_above_avg` được xác định theo trung bình của *chính danh mục đó*, mọi phân tích so sánh hai nhóm giá bắt buộc phải kiểm soát `category`, và không được xem nhóm giá là một treatment được ngẫu nhiên hóa.

Lưu lượng theo ngày

Ngày 13/08 có dấu hiệu là ngày thu thập chưa đầy đủ



Hình 4: Lưu lượng click và số session theo ngày

Chuỗi thời gian ở Hình 4 cho thấy lưu lượng biến động rõ theo ngày và theo tuần, củng cố quyết định chia dữ liệu theo thời gian thay vì ngẫu nhiên. Điểm cuối chuỗi chỉ có 200 click, nhất quán với đánh giá ngày 13/08 là ngày thu thập dở dang ở Bảng 5; không nên dùng điểm này để suy ra một xu hướng suy giảm lưu lượng.

Nhóm cố ý *không* trình bày ma trận tương quan Pearson cho toàn bộ các cột, vì phần lớn biến trong bộ dữ liệu là mã factor (country, colour, location, page...); hệ số Pearson tính trực tiếp trên các mã số phụ thuộc vào cách đánh số mức và không có diễn giải thống kê phù hợp. Quan hệ với Exit được đánh giá bằng các mô hình ở Phần 3; nếu cần một phụ lục EDA hai biến, có thể dùng bảng chéo và Cramér's V cho hai biến phân loại, hoặc Spearman cho hai biến thứ bậc/liên tục.

2.4 Đánh giá tổng hợp và đề xuất bổ sung

2.4.1 Đánh giá mức độ sẵn sàng của dữ liệu

Các kết quả trên dẫn đến bốn đánh giá chính, mỗi đánh giá đều dựa trên một bằng chứng quan sát được trong EDA:

1. **Dữ liệu đủ sạch để mô hình hóa mà không cần loại hàng loạt.** Bảng 4 không ghi nhận vi phạm về giá trị khuyết, dòng trùng, ngày hay trình tự session; Bảng 5 cho thấy toàn bộ 165.474 click được giữ cho EDA. Vì vậy sai lệch ở các phân tích sau khó có thể quy chủ yếu cho thao tác nội suy hoặc xóa dữ liệu.
2. **Cỡ mẫu click lớn nhưng lượng thông tin độc lập nhỏ hơn con số 165.474.** Chỉ có 24.026 session và một session đóng góp trung bình 6,89 click (Bảng 6). Đây là bằng chứng

trực tiếp cho việc chia tập, bootstrap và tính sai số chuẩn theo session.

3. **Một số mức có dữ liệu thừa.** Page 5 chỉ chiếm 1,71% số click, trong khi các country hiếm phải gộp thành *Other*. Hệ số ở các mức thừa vì vậy cần được đọc cùng khoảng tin cậy; một p-value không có ý nghĩa không nhất thiết chứng minh hai mức tương đương.
4. **Dữ liệu phù hợp cho dự báo và mô tả liên hệ, nhưng yếu cho suy luận nhân quả.** Hai nhóm giá gần cân bằng về số click, song Hình 3 cho thấy phân phối giá phụ thuộc rõ vào danh mục; Hình 2 cũng cho thấy cơ cấu click không đồng đều giữa danh mục và vị trí. Do đó mọi so sánh nhóm giá phải điều chỉnh covariate và vẫn chỉ được diễn giải như mối liên hệ quan sát.

2.4.2 Các kiểm tra EDA nên bổ sung khi mở rộng báo cáo

Các phân tích dưới đây có thể thực hiện ngay trên dữ liệu hiện có, nhưng được nêu như *đề xuất* chứ không phải kết quả đã hoàn thành:

- **Kiểm tra dịch chuyển phân phối giữa ba tập thời gian.** So sánh tỷ lệ Exit, độ dài session, cơ cấu category, page và country giữa train, validation và temporal test bằng chênh lệch chuẩn hóa. Phân tích này sẽ xác định biến nào góp phần làm calibration thay đổi theo thời gian.
- **Lập bảng độ thừa trước khi ước lượng tương tác.** Dếm số click và số session trong các ô $\text{price group} \times \text{category} \times \text{page}$, riêng cho từng tập thời gian. Các ô quá nhỏ cần được gộp hoặc loại khỏi phân tích tương tác để tránh ước lượng bất ổn.
- **Đánh giá mức tập trung lượt xem theo sản phẩm.** Báo cáo tỷ trọng click của các sản phẩm đứng đầu và một chỉ số tập trung như Herfindahl–Hirschman. Kết quả sẽ cho biết hiệu năng mô hình có bị chi phối bởi một nhóm nhỏ trong 217 mã sản phẩm hay không; đây là phân tích mức tập trung click, không phải click-through rate vì dữ liệu thiếu số lượt hiển thị.
- **Chuẩn hóa phân tích theo lịch.** So sánh lưu lượng theo thứ trong tuần bằng số click/session trung bình trên mỗi ngày quan sát, chỉ dùng các ngày đầy đủ. Cách này kiểm tra nhận xét về chu kỳ tuần trong Hình 4 mà không nhầm số ngày quan sát với mức lưu lượng.

Các đề xuất cần thêm log lượt hiển thị, thời lượng click, giỏ hàng hoặc giao dịch được dành cho Phần 5 để tránh lặp lại phần hạn chế và hướng phát triển.

3 Kết quả phân tích và mô hình hóa

3.1 Kết quả so sánh xác suất Exit giữa hai nhóm giá quan sát

Phân tích chính được thực hiện trên tập validation tháng 7 (35.231 click của 5.071 session). Nhóm A gồm các click vào sản phẩm *không* có giá cao hơn trung bình danh mục; nhóm B gồm các click vào sản phẩm có giá cao hơn trung bình danh mục.

3.1.1 Kết quả kiểm định

Bảng 8: Tỷ lệ Exit theo nhóm giá trên tập validation tháng 7


Nhóm	Click	Session	Exit	Tỷ lệ Exit	CI 95% (Wilson)
A: Không cao hơn TB	16.879	4.147	2.325	13,77%	13,26% – 14,30%
B: Cao hơn TB	18.352	4.249	2.746	14,96%	14,45% – 15,49%

Một session có thể xem sản phẩm thuộc cả hai nhóm giá, nên tổng số session ở hai hàng của Bảng 8 lớn hơn 5.071 và không được cộng lại.

Bảng 9: Tổng hợp các kiểm định so sánh hai nhóm giá (tháng 7)


Đại lượng	Ước lượng	CI 95%	p-value
Chênh lệch thô B – A (điểm %)	1,19	0,46 – 1,93 (cluster bootstrap)	—
Kiểm định hai tỷ lệ (χ^2 , df = 1)	10,08	—	0,002
Adjusted odds ratio (B so với A)	1,071	1,002 – 1,144 (robust)	0,043
Adjusted risk difference (điểm %)	0,82	0,03 – 1,62 (robust)	—
Tương tác nhóm giá × Category	—	—	0,051

Ở mức ý nghĩa 5%, cả kiểm định hai tỷ lệ thô ($p = 0,002$) lẫn adjusted odds ratio với sai số chuẩn cluster-robust theo session ($p = 0,043$) đều cho phép **bác bỏ** H_0 . Tuy nhiên độ lớn hiệu ứng rất khiêm tốn: sau khi điều chỉnh tiến trình session, thời gian, country và toàn bộ đặc điểm sản phẩm, chênh lệch xác suất chuẩn hóa chỉ còn 0,82 điểm phần trăm, với cận dưới của khoảng tin cậy sát 0 (0,03 điểm phần trăm). Nói cách khác, bằng chứng về sự *tồn tại* của khác biệt là có, nhưng khác biệt đó nhỏ và ước lượng kém chính xác.



Hình 5: So sánh tỷ lệ Exit giữa hai nhóm giá trên tháng 7, thanh sai số là khoảng tin cậy Wilson 95%

3.1.2 Kiểm tra balance giữa hai nhóm




Hình 6: Hai mươi covariate mất cân bằng nhất giữa hai nhóm giá

Hình 6 là bằng chứng trực tiếp cho thấy hai nhóm *không* tương đương như trong một thí nghiệm ngẫu nhiên: nhiều covariate có $|SMD| > 0,1$. Đây là lý do báo cáo ưu tiên adjusted risk difference và suy luận robust thay vì chênh lệch thô. Dù vậy, việc điều chỉnh chỉ xử lý được các yếu tố *đã quan sát*; residual confounding vẫn có thể tồn tại.

3.1.3 Dị biệt hiệu ứng theo danh mục

Bảng 10: Adjusted risk difference của nhóm giá theo từng danh mục (tháng 7)

Category	N	Adjusted RD (điểm %)	CI 95%	p-value (Holm)
Trousers	10.871	2,32	0,86 – 3,78	0,008
Skirts	7.382	0,69	−1,25 – 2,62	1,000
Blouses	7.858	0,72	−0,88 – 2,33	1,000
Sale	9.120	−0,66	−2,17 – 0,85	1,000



Hình 7: Forest plot adjusted risk difference của nhóm giá theo danh mục

Kiểm định Wald robust cho toàn bộ nhóm tương tác `price group × Category` cho $p = 0,051$, tức nằm ngay ranh giới 5%. Sau hiệu chỉnh Holm, chỉ riêng danh mục Trousers còn khác biệt có ý nghĩa (2,32 điểm phần trăm, $p = 0,008$); ba danh mục còn lại đều có khoảng tin cậy chứa 0, và Sale thậm chí có dấu ngược lại. Điều này cho thấy hiệu ứng gộp ở Bảng 9 không đại diện đồng đều cho mọi danh mục.

3.1.4 Độ ổn định theo thời gian

Bảng 11: Độ ổn định theo thời gian của khác biệt giữa hai nhóm giá

Giai đoạn	Chênh lệch B – A (điểm %)	OR điều chỉnh	CI 95%	p-value
Train: tháng 4–6	0,78	1,066	1,032 – 1,102	< 0,001
Phân tích chính: tháng 7	1,19	1,108	1,044 – 1,175	< 0,001
Kiểm tra thời gian: 01–12/08	1,36	1,125	1,021 – 1,240	0,017

Để so sánh nhất quán giữa ba giai đoạn, odds ratio trong Bảng 11 chỉ điều chỉnh $\log_2(\text{order})$, thời gian và country; vì vậy nó lớn hơn odds ratio 1,071 của mô hình điều chỉnh chính cho so sánh hai nhóm giá – mô hình đó còn điều chỉnh thêm toàn bộ đặc điểm sản phẩm nên cho ước lượng thận trọng hơn.

Khác biệt có cùng dấu và độ lớn tương đương trong cả ba giai đoạn, cho thấy đây là một mối liên hệ ổn định theo thời gian chứ không phải nhiễu ngẫu nhiên của riêng tháng 7. Tuy nhiên, `price_above_avg` vẫn là một thuộc tính của sản phẩm chứ không phải treatment được gán ngẫu nhiên, nên kết quả này **không** chứng minh rằng tăng giá gây ra việc kết thúc session.

3.2 Kết quả mô hình dự đoán: xác suất Exit theo tiến trình session


Bảng 12: Tỷ lệ Exit gộp theo khoảng Order trên tháng 7

Khoảng Order	Click có nguy cơ	Click kết thúc	Tỷ lệ Exit	CI 95%
1	5.071	1.038	20,47%	19,38% – 21,60%
2	4.033	707	17,53%	16,39% – 18,73%
3–4	6.101	991	16,24%	15,34% – 17,19%
5–7	6.043	875	14,48%	13,61% – 15,39%
8–12	5.621	731	13,00%	12,15% – 13,91%
13–20	4.197	411	9,79%	8,93% – 10,73%
>20	4.165	318	7,64%	6,87% – 8,48%

Xác suất kết thúc giảm gần như đơn điệu theo tiến trình session: từ 20,47% tại click đầu tiên xuống 7,64% với các click sau vị trí 20 – tức giảm hơn một nửa. Lưu ý mẫu số ở mỗi hàng là số click *có nguy cơ* trong khoảng đó, không phải số session ở đầu khoảng; cách tính này tránh diễn giải sai rằng mọi session sống sót qua click 20 đều có cùng xác suất kết thúc ngay lập tức.

Xác suất Exit theo tiến trình session

Đường dự đoán được chuẩn hóa trên phân phối covariate tháng 7



Hình 8: Xác suất Exit quan sát và dự đoán theo tiến trình session; ba đường dự đoán được chuẩn hóa trên phân phối covariate tháng 7

Hình 8 là căn cứ để trả lời câu hỏi liệu quan hệ tuyến tính có đủ hay cần đến GAM. Ba đường dự đoán gần như trùng nhau trong khoảng `order` từ 1 đến 20; chỉ ở phần đuôi đường GAM mới tách xuống thấp hơn hai dạng tuyến tính. Nói cách khác, sau phép biến đổi $\log_2$, dạng hàm tuyến tính đã nắm bắt gần trọn quan hệ và phần phi tuyến còn lại là nhỏ. Các điểm quan sát ở đuôi dao động mạnh hơn đơn giản vì số session còn tồn tại giảm dần.

3.3 Kết quả mô hình dự đoán: giá trị bổ sung của các nhóm biến

Bảng 13 so sánh chín mô hình (ba phương pháp $\times$ ba tầng predictor) trên cùng tập validation tháng 7.

Bảng 13: So sánh ba tầng predictor của ba phương pháp trên validation tháng 7

<i>Khả năng phân biệt và chất lượng xác suất</i>					
Phương pháp	Tầng predictor	ROC–AUC	AP	Log loss	Brier
LPM	Baseline	0,589	0,179	0,406	0,122
LPM	Current-click	0,611	0,197	0,405	0,121
LPM	History-enhanced	0,660	0,233	0,397	0,119
Logistic	Baseline	0,589	0,179	0,407	0,122
Logistic	Current-click	0,611	0,199	0,403	0,121
Logistic	History-enhanced	0,662	0,237	0,392	0,118
GAM	Baseline	0,589	0,179	0,406	0,122
GAM	Current-click	0,612	0,199	0,403	0,121
GAM	History-enhanced	0,662	0,238	0,392	0,118

<i>Brier Skill Score, calibration và AIC</i>					
Phương pháp	Tầng predictor	Brier skill	Cal. int.	Cal. slope	AIC
LPM	Baseline	0,010	−0,066	0,899	—
LPM	Current-click	0,016	−0,067	0,808	—
LPM	History-enhanced	0,038	−0,060	0,755	—
Logistic	Baseline	0,010	−0,065	0,880	94.998,4
Logistic	Current-click	0,016	−0,068	0,873	94.222,0
Logistic	History-enhanced	0,039	−0,059	0,922	91.801,3
GAM	Baseline	0,010	−0,064	0,879	94.957,6
GAM	Current-click	0,016	−0,067	0,864	94.160,7
GAM	History-enhanced	0,040	−0,057	0,932	91.746,6

AP = Average Precision; Cal. int. = calibration intercept; Cal. slope = calibration slope. AIC của LPM không so sánh được với hai mô hình nhị phân vì không cùng họ likelihood.

Cả hai bước bổ sung biến đều có ý nghĩa thống kê. Kiểm định Wald robust chung cho nhóm **Price + Category + Colour + Location + Photography + Page** cho $p < 0,001$ trong cả LPM và Logistic GLM. Sau khi đã có các biến current-click, nhóm biến lịch sử tiếp tục bổ sung với robust joint $p < 0,001$.

Điều đáng chú ý là *độ lớn* của hai bước rất khác nhau. Thêm toàn bộ đặc điểm sản phẩm chỉ nâng ROC–AUC của Logistic GLM từ 0,589 lên 0,611 và giảm log loss 0,004. Trong khi đó nhóm biến lịch sử duyệt nâng ROC–AUC tiếp lên 0,662 và giảm log loss thêm 0,012 – gấp ba lần đóng góp của đặc điểm sản phẩm.¹ Kết luận thực nghiệm: **hành vi đã diễn ra trong session mang nhiều thông tin dự báo hơn hẳn đặc điểm của riêng click hiện tại.**

¹Các mức tăng/giảm được tính trên giá trị chưa làm tròn (+0,050 ROC–AUC và −0,012 log loss), nên có thể lệch một đơn vị ở chữ số thập phân thứ ba so với hiệu của hai giá trị đã làm tròn trong Bảng 13.


Bảng 14: Mười hai nhóm biến có bằng chứng liên hệ mạnh nhất trong Logistic GLM history-enhanced (Wald robust theo cụm session)

Nhóm biến	Wald χ^2	df	p-value	Hiệu ứng / CI 95%
$\log_2(\text{Order})$	1081,19	1	< 0,001	OR 0,640 (0,623–0,657)
Số danh mục duy nhất đến hiện tại	639,64	1	< 0,001	OR 1,562 (1,509–1,617)
Quay lại sản phẩm cũ	469,92	1	< 0,001	OR 2,218 (2,064–2,384)
Page	465,93	4	< 0,001	Joint test
Country	150,60	17	< 0,001	Joint test
Colour	93,18	13	< 0,001	Joint test
Chuyển Category ở click hiện tại	75,32	1	< 0,001	OR 1,311 (1,233–1,394)
Category	48,63	3	< 0,001	Joint test
Chuyển Page ở click hiện tại	46,80	1	< 0,001	OR 1,169 (1,118–1,223)
Số sản phẩm duy nhất đến hiện tại	40,78	1	< 0,001	OR 0,988 (0,984–0,991)
Location	32,76	5	< 0,001	Joint test
Price (mỗi 10 USD)	6,96	1	0,008	OR 1,032 (1,008–1,056)

Năm nhóm biến đứng đầu theo p-value robust và thống kê Wald trên mỗi bậc tự do là: $\log_2(\text{Order})$, số danh mục duy nhất đã xem, hành vi quay lại sản phẩm cũ, **Page** và **Country**. Ba hiệu ứng đơn biến đáng chú ý:

- Mỗi lần **order** tăng gấp đôi, odds kết thúc session nhân với 0,640 – session càng đi sâu càng ít có khả năng dừng ở click kế tiếp.
- Click vào một sản phẩm *đã xem trước đó* trong cùng session có odds kết thúc cao gấp 2,218 lần, hiệu ứng đơn biến lớn nhất trong mô hình.
- Mỗi danh mục mới được xem thêm làm odds kết thúc nhân với 1,562.

Ngược lại, **Price** tuy có ý nghĩa thống kê ($p = 0,008$) nhưng hiệu ứng rất nhỏ: OR 1,032 cho mỗi 10 USD. Cần nhấn mạnh rằng thứ hạng trong Bảng 14 phản ánh *bằng chứng về liên hệ*, không phải mức độ quan trọng nhân quả, và không nên so sánh trực tiếp độ lớn OR giữa các biến có đơn vị khác nhau.



Hình 9: Các hàm trơn của GAM history-enhanced: partial effect của Order, Price, độ lớn thay đổi giá và tỷ lệ quay lại sản phẩm (thang log-odds)

Hình 9 minh họa dạng hàm mà GAM ước lượng. Hàm trơn của **Order** giảm đơn điệu và gần tuyến tính trên thang $\log_2$, phù hợp với Hình 8. Tuy nhiên, như phần chẩn đoán dưới đây chỉ ra, các partial-effect plot này **không** được diễn giải như hiệu ứng riêng biệt của từng biến vì mức concurvity giữa các term rất cao.

3.4 Chẩn đoán mô hình

Bảng 15: Kiểm tra kích thước basis của GAM history-enhanced


Hàm trơn	k'	edf	k-index	p-value
s(log2_order)	9,0	4,52	0,934	0,170
s(price)	7,0	1,88	0,943	0,350
s(repeat_rate)	7,0	3,20	0,950	0,580
s(abs_price_delta_10)	7,0	1,01	0,947	0,362

Không hàm trơn nào có edf tiến sát giới hạn basis k' và mọi p-value đều lớn hơn 0,05, nên kích thước basis đã đủ. Đáng chú ý là edf = 1,01 cho **s(abs_price_delta_10)** và 1,88 cho **s(price)** – hai hàm này gần như tuyến tính, tức GAM hầu như không tìm thấy phi tuyến đáng kể ở các biến giá.

Bảng 16: Mười GVIF điều chỉnh lớn nhất của Logistic GLM (trái) và năm cặp term có concurvity cao nhất trong GAM (phải)

Term	GVIF điều chỉnh																					
log2_order	2,424	<table><tr><th>Term</th><th>Term còn lại</th><th>Concurvity</th></tr><tr><td>s(log2_order)</td><td>para</td><td>0,994</td></tr><tr><td>s(abs_price_delta_10)</td><td>para</td><td>0,966</td></tr><tr><td>s(repeat_rate)</td><td>para</td><td>0,866</td></tr><tr><td>s(log2_order)</td><td>s(repeat_rate)</td><td>0,802</td></tr><tr><td>para</td><td>s(repeat_rate)</td><td>0,769</td></tr></table>			Term	Term còn lại	Concurvity	s(log2_order)	para	0,994	s(abs_price_delta_10)	para	0,966	s(repeat_rate)	para	0,866	s(log2_order)	s(repeat_rate)	0,802	para	s(repeat_rate)	0,769
Term	Term còn lại				Concurvity																	
s(log2_order)	para				0,994																	
s(abs_price_delta_10)	para				0,966																	
s(repeat_rate)	para				0,866																	
s(log2_order)	s(repeat_rate)				0,802																	
para	s(repeat_rate)				0,769																	
unique_products	2,022																					
price_vs_prior_mean_10	1,989																					
unique_categories	1,944																					
price_10	1,729																					
price_delta_10	1,688																					
category_switch_rate	1,627																					
repeat_rate	1,497																					
category_switch	1,442																					
repeat_current	1,441																					

Hai chẩn đoán này cho hai kết luận trái ngược nhau và cần được đọc riêng. Với Logistic GLM, GVIF điều chỉnh lớn nhất chỉ 2,424, thấp hơn nhiều ngưỡng cảnh báo thông thường, nên đa cộng tuyến không phải vấn đề với các hệ số trong Bảng 14. Ngược lại, concurvity trong GAM lên tới 0,994 – gần mức xác định hoàn toàn. Nhóm đã loại **s(unique_products)** khỏi GAM vì gần trùng thông tin với **Order** và **repeat_rate**, nhưng concurvity còn lại vẫn quá cao. Vì vậy GAM chỉ được giữ làm *đối chứng dự báo phi tuyến*, còn các partial-effect plot của nó không được dùng làm bằng chứng về hiệu ứng riêng của từng biến.



Hình 10: Binned residual plot của Logistic GLM trên temporal test 01-12/08

Với outcome nhị phân, đồ thị phần dư thông thường của hồi quy tuyến tính không có ý nghĩa, nên nhóm dùng binned residual plot [2]: dữ liệu được chia thành 20 nhóm theo xác suất dự đoán và vẽ residual trung bình của mỗi nhóm kèm sai số chuẩn. Phần lớn các điểm nằm quanh đường 0 với khoảng sai số phủ 0, nghĩa là không có sai lệch hệ thống rõ rệt theo mức xác suất dự đoán.

3.5 Kết quả mô hình phân loại: so sánh ba phương pháp

3.5.1 Các metric được sử dụng

Với quan sát $i = 1, \dots, n$, ký hiệu $y_i \in \{0, 1\}$ là nhãn **Exit** thực tế và $\hat{p}_i = P(Y_i = 1 | X_i)$ là xác suất do mô hình dự đoán. Báo cáo đánh giá hai khía cạnh tách biệt: *chất lượng xác suất* và *chất lượng phân loại sau khi chọn threshold*.

Nhóm metric không phụ thuộc threshold.

- **ROC-AUC** là diện tích dưới đường ROC. Tương đương,

$$AUC = P(\hat{p}_+ > \hat{p}_-) + \frac{1}{2}P(\hat{p}_+ = \hat{p}_-),$$

với $\hat{p}_+$, $\hat{p}_-$ là xác suất dự đoán của một quan sát dương và một quan sát âm lấy ngẫu nhiên. AUC bằng 0,5 tương ứng xếp hạng ngẫu nhiên; càng gần 1 càng tốt. Metric này chỉ đo khả năng *xếp hạng*.

- **Average Precision (AP)** tóm tắt đường Precision-Recall, $AP = \sum_k (R_k - R_{k-1})P_k$. Mốc tham chiếu của mô hình ngẫu nhiên xấp xỉ bằng prevalence của **Exit**. AP được báo cáo cùng AUC vì ROC có thể quá lạc quan khi lớp dương chiếm thiểu số.

- **Log loss** đánh giá trực tiếp xác suất dự đoán:

$$-\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)].$$

Càng nhỏ càng tốt; phạt rất nặng các dự đoán tự tin nhưng sai.

- **Brier score** là sai số bình phương trung bình của xác suất, $\text{Brier} = \frac{1}{n} \sum_{i=1}^n (\hat{p}_i - y_i)^2$. **Brier Skill Score** so sánh với dự báo hằng bằng prevalence train: $\text{BSS} = 1 - \text{Brier}_{\text{model}} / \text{Brier}_{\text{ref}}$. $\text{BSS} > 0$ nghĩa là tốt hơn mô hình tham chiếu.
- **Calibration intercept và slope** được ước lượng từ $\text{logit}\{P(Y = 1)\} = \alpha + \beta \text{logit}(\hat{p})$. Mô hình hiệu chỉnh lý tưởng có $\alpha = 0$ và $\beta = 1$. Intercept âm cho thấy mô hình dự đoán xác suất thiên cao; slope nhỏ hơn 1 cho thấy dự đoán quá cực đoan.

Nhóm metric phụ thuộc threshold. Sau khi chọn threshold t , dự đoán dương khi $\hat{p}_i \geq t$. Với TP, TN, FP, FN là số dương đúng, âm đúng, dương giả và âm giả:

$$\begin{aligned} \text{Accuracy} &= \frac{TP + TN}{TP + TN + FP + FN}, & \text{Precision} &= \frac{TP}{TP + FP}, \\ \text{Recall (Sensitivity)} &= \frac{TP}{TP + FN}, & \text{Specificity} &= \frac{TN}{TN + FP}, \\ F_1 &= 2 \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}. \end{aligned}$$

3.5.2 Lựa chọn mô hình trên validation

Bảng 17: Metric validation tháng 7 dùng để lựa chọn mô hình

Model	ROC-AUC	AP	Log loss	Brier	Brier skill	Cal. int.	Cal. slope
LPM	0,660	0,233	0,397	0,119	0,038	-0,060	0,755
Logistic GLM	0,662	0,237	0,392	0,118	0,039	-0,059	0,922
Binomial GAM	0,662	0,238	0,392	0,118	0,040	-0,057	0,932

Quy tắc lựa chọn được xác định *trước* khi nhìn kết quả: giữ lại các mô hình nằm trong 1% log loss tốt nhất, rồi trong 1% Brier tốt nhất; nếu vẫn còn nhiều ứng viên thì ưu tiên Logistic GLM vì đơn giản và dễ diễn giải hơn GAM, còn LPM chỉ đóng vai trò benchmark. Logistic GLM và Binomial GAM có log loss và Brier giống nhau đến ba chữ số thập phân, nên cả hai cùng vào nhóm gần tương đương và **Logistic GLM được chọn**. Threshold tối đa F_1 của từng mô hình được chốt từ prediction out-of-fold của five-fold CV theo session trên tập train, trước khi mở temporal test.

3.5.3 Hiệu năng cuối trên temporal test

Bảng 18: Hiệu năng cuối của ba mô hình trên temporal test 01–12/08; khoảng tin cậy 95% từ 500 lần cluster bootstrap theo session

<i>Khả năng phân biệt và chất lượng xác suất</i>				
Model	ROC–AUC	AP	Log loss	Brier
LPM	0,662 (0,644–0,681)	0,224 (0,212–0,241)	0,382 (0,363–0,399)	0,114 (0,107–0,120)
Logistic GLM	0,666 (0,647–0,685)	0,230 (0,218–0,246)	0,379 (0,361–0,396)	0,113 (0,107–0,119)
Binomial GAM	0,666 (0,647–0,686)	0,230 (0,218–0,247)	0,379 (0,361–0,396)	0,113 (0,107–0,119)


<i>Brier Skill Score, calibration và tính hợp lệ của xác suất</i>				
Model	BSS	Cal. int.	Cal. slope	Ngoài [0, 1]
LPM	0,036	–0,138	0,868	1,706%
Logistic GLM	0,039	–0,127	0,934	0,000%
Binomial GAM	0,039	–0,125	0,942	0,000%

Ba mô hình gần như không phân biệt được về khả năng xếp hạng: khoảng tin cậy ROC–AUC chồng lấn gần hoàn toàn. Khác biệt thực chất nằm ở hai chỗ khác. Thứ nhất, **calibration slope**: LPM chỉ đạt 0,868 trong khi Logistic GLM đạt 0,934 và GAM đạt 0,942 – xác suất của LPM cực đoan hơn mức dữ liệu cho phép. Thứ hai, **tính hợp lệ của xác suất**: LPM sinh ra 1,706% dự đoán nằm ngoài khoảng [0, 1], tức những giá trị không thể diễn giải như xác suất; hai mô hình nhị phân theo cấu trúc không bao giờ mắc lỗi này.

Brier Skill Score của cả ba mô hình chỉ nằm trong khoảng 0,036–0,039, nghĩa là chúng chỉ tốt hơn dự báo hăng bằng prevalence khoảng 4%. Đây là mức cải thiện khiêm tốn và cần được nêu rõ thay vì che đi sau con số AUC.


Hiệu năng ba mô hình trên temporal test 01–12/08

ROC curve




Precision–Recall curve

Đường ngang là prevalence Exit



Calibration plot



Hình 11: Đường ROC, đường Precision–Recall và calibration plot của ba mô hình trên temporal test 01–12/08

Bảng 19: Ma trận nhầm lẫn và các metric phân loại trên temporal test, tại threshold đã khóa từ prediction out-of-fold của train

<i>Threshold và ma trận nhầm lẫn</i>					
Model	Threshold	TP	TN	FP	FN
LPM	0,168	1.176	7.428	4.617	727
Logistic GLM	0,162	1.145	7.722	4.323	758
Binomial GAM	0,163	1.123	7.843	4.202	780

<i>Các metric phân loại tại threshold đã khóa</i>					
Model	Accuracy	Precision	Recall	Specificity	F_1
LPM	61,69%	20,30%	61,80%	61,67%	30,56%
Logistic GLM	63,57%	20,94%	60,17%	64,11%	31,07%
Binomial GAM	64,28%	21,09%	59,01%	65,11%	31,07%

Các threshold được chọn (0,162–0,168) đều thấp hơn 0,5 rất nhiều, đúng như kỳ vọng với dữ liệu mất cân bằng. Tại các ngưỡng này, cả ba mô hình đều có Recall khoảng 59–62% nhưng Precision chỉ khoảng 21%: cứ 5 click bị dự báo là kết thúc thì chỉ khoảng 1 click thực sự kết thúc. F_1 tối đa chỉ đạt 31,07%. Accuracy từ 61,69% đến 64,28% *thấp hơn* mức 85,48% mà một mô hình luôn dự đoán “Continue” đạt được – minh chứng cụ thể cho lý do Accuracy không được dùng làm tiêu chí chọn mô hình ở đây.

4 Nhận xét và kết luận

4.1 Nhận xét về kết quả phân tích

4.1.1 Mô hình nào hoạt động tốt nhất và tại sao

Theo quy tắc lựa chọn được chốt trước khi mở dữ liệu đánh giá, **Logistic GLM với tầng predictor history-enhanced** là mô hình được chọn. Lý do không nằm ở khả năng phân biệt – về mặt này ba mô hình gần như không phân biệt được, với ROC–AUC trên temporal test lần lượt là 0,662 (LPM), 0,666 (Logistic GLM) và 0,666 (Binomial GAM), các khoảng tin cậy bootstrap chồng lấn gần hoàn toàn (Bảng 18).

Sự khác biệt thực chất nằm ở ba tiêu chí còn lại:

- **Tính hợp lệ của xác suất.** LPM tạo ra 1,706% dự đoán nằm ngoài khoảng $[0, 1]$ trên temporal test – những giá trị không thể diễn giải như xác suất. Logistic GLM và Binomial GAM theo cấu trúc không bao giờ mắc lỗi này.
- **Calibration.** Calibration slope của LPM chỉ đạt 0,868, trong khi Logistic GLM đạt 0,934 và GAM đạt 0,942 (lý tưởng là 1). Xác suất do LPM sinh ra cực đoan hơn mức dữ liệu thực sự cho phép.
- **Khả năng diễn giải và độ phức tạp.** Logistic GLM và Binomial GAM cho log loss (0,379) và Brier (0,113) giống nhau đến ba chữ số thập phân, tức GAM *không* mua thêm được gì

bằng độ phức tạp của nó. Thêm vào đó, concurvity giữa các term của GAM lên tới 0,994 (Bảng 16), khiến các hàm trơn của nó không thể diễn giải riêng lẻ. Ngược lại, GVIF điều chỉnh lớn nhất của Logistic GLM chỉ 2,424, nên các hệ số của nó đọc được.

Sự tương đương giữa GAM và mô hình tuyến tính có một lý giải rõ ràng từ dữ liệu: sau phép biến đổi $\log_2(\text{order})$, quan hệ giữa tiến trình session và xác suất kết thúc đã gần như tuyến tính. Hình 8 cho thấy ba đường dự đoán trùng nhau trong khoảng `order` từ 1 đến 20, và Bảng 15 cho thấy các hàm trơn của biến giá chỉ có $\text{edf} \approx 1-2$, tức gần như là đường thẳng. Nói cách khác, phần phi tuyến mà GAM có thể khai thác trong bộ dữ liệu này là rất nhỏ.

4.1.2 Các biến có ảnh hưởng lớn nhất

Dựa trên kiểm định Wald robust theo cụm session (Bảng 14), năm nhóm biến có bằng chứng liên hệ mạnh nhất với `Exit` là $\log_2(\text{Order})$, số danh mục duy nhất đã xem, hành vi quay lại sản phẩm cũ, `Page` và `Country`. Ba hiệu ứng đáng chú ý nhất về độ lớn:

- Click vào một sản phẩm *đã xem trước đó* trong cùng session làm odds kết thúc tăng gấp 2,218 lần (CI 95%: 2,064–2,384) – hiệu ứng đơn biến mạnh nhất trong mô hình.
- Mỗi danh mục mới được xem thêm làm odds kết thúc nhân với 1,562 (CI 95%: 1,509–1,617).
- Ngược chiều, mỗi lần `order` tăng gấp đôi làm odds kết thúc nhân với 0,640 (CI 95%: 0,623–0,657): session càng đi sâu thì càng ít khả năng dừng ở click kế tiếp.

Một phát hiện có giá trị phương pháp luận là **nhóm biến lịch sử duyệt quan trọng hơn hẳn đặc điểm sản phẩm**. Thêm toàn bộ giá, danh mục, màu sắc, vị trí ảnh, kiểu ảnh và trang hiển thị chỉ nâng ROC–AUC từ 0,589 lên 0,611; trong khi nhóm biến lịch sử nâng tiếp lên 0,662 – đóng góp hơn gấp đôi về ROC–AUC và gấp ba lần về log loss. Cả hai bước đều có robust joint $p < 0,001$, nhưng ý nghĩa thống kê và độ lớn thực tế là hai chuyện khác nhau, và ở đây độ lớn nghiêng hẳn về nhóm biến hành vi.

Riêng `Price` tuy đạt ý nghĩa thống kê ($p = 0,008$) nhưng hiệu ứng rất nhỏ (OR 1,032 cho mỗi 10 USD). Với cỡ mẫu 116.095 click của tập train, ngay cả những liên hệ rất yếu cũng dễ đạt $p < 0,05$; vì vậy nhóm nhất quán đọc p-value cùng với độ lớn hiệu ứng và khoảng tin cậy.

4.1.3 Kết luận về kiểm định hai nhóm giá

Ở mức ý nghĩa $\alpha = 0,05$, nhóm **bác bỏ giả thuyết** H_0 : xác suất `Exit` của hai nhóm giá không bằng nhau. Bằng chứng đến từ nhiều nguồn nhất quán:

- Kiểm định hai tỷ lệ thô: $\chi^2 = 10,08$, $p = 0,002$.
- Adjusted odds ratio với sai số chuẩn cluster-robust theo session: 1,071 (CI 95%: 1,002–1,144), $p = 0,043$.
- Chênh lệch thô 1,19 điểm phần trăm với cluster-bootstrap CI 95% từ 0,46 đến 1,93 điểm phần trăm – không chứa 0.
- Cùng dấu và độ lớn tương đương trên cả ba giai đoạn thời gian (Bảng 11).

Tuy nhiên, kết luận này cần ba dè dặt quan trọng. *Thứ nhất*, độ lớn hiệu ứng rất nhỏ: adjusted risk difference chỉ 0,82 điểm phần trăm với cận dưới khoảng tin cậy là 0,03 – gần như chạm 0. *Thứ hai*, hiệu ứng không đồng đều giữa các danh mục: sau hiệu chỉnh Holm chỉ riêng Trousers còn có ý nghĩa (2,32 điểm phần trăm, $p = 0,008$), còn Skirts, Blouses và Sale đều có khoảng tin cậy chứa 0, với kiểm định tương tác nằm ngay ranh giới ($p = 0,051$). *Thứ ba* và quan trọng nhất, balance diagnostics (Hình 6) xác nhận hai nhóm không tương đương như trong một thí nghiệm ngẫu nhiên. Đây là dữ liệu quan sát, nên kết quả chỉ chứng minh một **mối liên hệ**, hoàn toàn không chứng minh rằng việc tăng giá *gây ra* việc kết thúc session.

4.2 Kết luận tổng thể và khuyến nghị

4.2.1 Những hiểu biết rút ra

1. Rủi ro rời bỏ tập trung ở đầu session. Xác suất kết thúc giảm từ 20,47% tại click đầu tiên xuống 7,64% sau click thứ 20 – giảm hơn một nửa (Bảng 12). Người dùng vượt qua được vài click đầu có xu hướng ở lại lâu hơn nhiều.

2. Hành vi trong phiên nói nhiều hơn thuộc tính sản phẩm. Biết người dùng *đã làm gì* trong session (đã xem bao nhiêu danh mục, có quay lại sản phẩm cũ không, có nhảy trang không) dự báo tốt hơn hẳn việc biết họ *đang xem sản phẩm nào*.

3. Quay lại sản phẩm cũ là tín hiệu cảnh báo mạnh nhất. Odds kết thúc tăng gấp 2,218 lần. Cần lưu ý đây là quan hệ hai chiều về mặt diễn giải: hành vi này vừa có thể là dấu hiệu người dùng đã tìm được thứ cần và sắp rời đi, vừa có thể là dấu hiệu họ đang loay hoay không tìm thấy gì mới. Dữ liệu hiện có không phân biệt được hai kịch bản này vì thiếu thông tin giao dịch.

4. Những khả năng dự báo tổng thể còn hạn chế. Đây là kết luận trung thực cần nêu rõ: ROC-AUC 0,666 chỉ ở mức trung bình, Brier Skill Score 0,039 nghĩa là mô hình chỉ tốt hơn dự báo hăng khoảng 4%, và tại threshold tối ưu F_1 thì Precision chỉ 20,94% – cứ 5 cảnh báo thì khoảng 1 cảnh báo đúng. Nguyên nhân chính là dữ liệu thiếu những tín hiệu quan trọng nhất: thời lượng dừng lại trên mỗi trang, thao tác thêm vào giỏ hàng, và lịch sử người dùng qua nhiều phiên.

4.2.2 Khuyến nghị hành động

Về mặt vận hành:

- 1. Ưu tiên can thiệp ở vài click đầu tiên.** Vì gần một phần năm session kết thúc ngay sau click đầu, các nỗ lực cải thiện trải nghiệm nên tập trung vào trang đầu tiên người dùng nhìn thấy. Lưu ý **Order** là một chỉ báo về giai đoạn session, không phải một biến có thể can thiệp trực tiếp.
- 2. Tính các đặc trưng hành vi theo thời gian thực.** Số sản phẩm và danh mục đã xem, có quay lại sản phẩm cũ, có chuyển danh mục – toàn bộ đều tính được ngay tại click hiện tại mà không cần biết tương lai của session, nên triển khai được trong hệ thống trực tuyến.
- 3. Không tự động hóa quyết định dựa trên mô hình hiện tại.** Với Precision khoảng 21%, việc tự động kích hoạt ưu đãi cho mọi phiên bị dự báo “sắp rời” sẽ lãng phí phần lớn ngân sách. Nếu dùng, chỉ nên dùng như một tín hiệu xếp hạng ưu tiên trong một hệ thống có chi phí can thiệp thấp.

4. **Theo dõi calibration khi triển khai, không chỉ AUC.** Calibration intercept trên temporal test là $-0,127$, âm hơn so với mức $-0,059$ trên validation, cho thấy chất lượng xác suất suy giảm theo thời gian ngay cả khi AUC giữ nguyên. Mô hình cần được hiệu chỉnh lại định kỳ.

Về mặt thu thập dữ liệu: giá trị gia tăng lớn nhất không đến từ mô hình phức tạp hơn mà đến từ dữ liệu tốt hơn. Ba trường cần bổ sung, theo thứ tự ưu tiên, là: dấu thời gian đầy đủ của từng click (để tính thời lượng dừng), sự kiện thêm vào giỏ hàng và mua hàng (để chuyển từ dự báo “rời phiên” sang dự báo “chuyển đổi”), và định danh người dùng xuyên phiên.

Về nhóm giá: không nên thay đổi chính sách giá dựa trên kết quả của báo cáo này. Bằng chứng thu được là liên hệ trên dữ liệu quan sát, với độ lớn nhỏ và không đồng đều giữa các danh mục. Bước đi đúng đắn là chạy một thí nghiệm ngẫu nhiên thực sự theo thiết kế được trình bày ở Mục 5.2.

5 Hạn chế và hướng phát triển

5.1 Hạn chế của phân tích

5.1.1 Hạn chế về thiết kế nghiên cứu

- **Không có treatment/control ngẫu nhiên.** So sánh hai nhóm giá là phân tích quan sát. Balance diagnostics (Hình 6) cho thấy nhiều covariate có $|SMD| > 0,1$, tức hai nhóm khác nhau một cách hệ thống ngay từ đầu. Việc điều chỉnh bằng mô hình chỉ xử lý được các yếu tố đã quan sát; residual confounding bởi đặc điểm sản phẩm, danh mục và thói quen duyệt vẫn có thể tồn tại.
- **Giả thuyết được định hướng từ EDA.** Nhóm giá trở thành đối tượng kiểm định sau khi quan sát dữ liệu, không phải trước đó. Vì vậy p-value trong báo cáo cần được đọc cùng effect size, balance diagnostics, kiểm tra ổn định theo thời gian và hiệu chỉnh Holm, chứ không đứng một mình.
- **Quan hệ theo Order chịu cấu trúc chọn lọc.** Tại mỗi vị trí t , chỉ những session còn tồn tại đến t được quan sát. Xu hướng giảm của xác suất kết thúc theo tiến trình vì vậy trộn lẫn hai cơ chế: thay đổi hành vi thực sự và việc các session có xu hướng dừng sớm đã bị loại khỏi mẫu.

5.1.2 Hạn chế về dữ liệu

- **Không có thông tin chuyển đổi.** Dữ liệu không ghi giao dịch, giỏ hàng hay thanh toán. Vì vậy Exit chỉ có nghĩa “click cuối của session”, hoàn toàn không phân biệt được một phiên kết thúc vì mua hàng thành công với một phiên kết thúc vì thất vọng bỏ đi. Đây là hạn chế nghiêm trọng nhất đối với giá trị kinh doanh của mô hình.
- **Không có chiều thời gian trong phiên.** Không có giờ click và không có thời lượng giữa hai click liên tiếp – những tín hiệu thường mạnh nhất trong bài toán dự báo rời bỏ. Mô hình vì vậy buộc phải thay thế bằng các đại lượng đếm (số sản phẩm, số danh mục đã xem).
- **Không có định danh người dùng xuyên phiên.** Không thể phân biệt khách quay lại với khách mới, cũng không thể xây dựng đặc trưng lịch sử dài hạn.

- **Phụ thuộc trong cụm.** Các click trong cùng một session không độc lập. Nhóm đã dùng cluster-robust covariance và cluster bootstrap theo session, nhưng đây chỉ là hiệu chỉnh cho suy luận, không mô hình hóa tường minh cấu trúc phụ thuộc; một mô hình hiệu ứng hỗn hợp hoặc survival có thể phù hợp hơn.
- **Tháng 8 không đầy đủ.** Dữ liệu dừng ở ngày 13/08 và riêng ngày này chỉ có 200 click nên đã bị loại. Temporal test vì vậy chỉ gồm 12 ngày với 13.948 click, khiến khoảng tin cậy bootstrap khá rộng (Bảng 18).
- **Tính đại diện.** Dữ liệu từ năm 2008 và của một cửa hàng cụ thể ở Ba Lan. Giao diện thương mại điện tử, thiết bị truy cập và hành vi người dùng đã thay đổi rất nhiều; cần đánh giá lại toàn bộ trước khi áp dụng cho môi trường hiện tại.

5.1.3 Hạn chế về mô hình

- **Concurvity cao trong GAM.** Mức concurvity lớn nhất giữa các term đạt 0,994 (Bảng 16). Đây là lý do các partial-effect plot ở Hình 9 chỉ được dùng để mô tả dạng hàm, không được diễn giải như hiệu ứng riêng của từng biến.
- **Biến product_model bị bỏ qua.** Với 217 mức, biến này không được đưa vào mô hình chính vì chưa có quy tắc gộp mức hiếm được kiểm chứng. Có thể vì vậy mà một phần thông tin về sản phẩm bị bỏ sót.
- **Khả năng phân biệt còn khiêm tốn.** ROC-AUC 0,666 và Brier Skill Score 0,039 chưa đủ để coi mô hình là một hệ thống sẵn sàng triển khai.

5.2 Đề xuất một thí nghiệm A/B ngẫu nhiên thực sự

Để chuyển từ kết luận liên hệ sang kết luận nhân quả, cần một thí nghiệm được thiết kế đúng. Nhóm đề xuất thiết kế sau.

Đơn vị ngẫu nhiên hóa. Randomize ở *cấp session*, lưu `experiment_id` cho từng phiên và đảm bảo mỗi session chỉ thuộc đúng một nhánh trong suốt vòng đời của nó. Ngẫu nhiên hóa ở cấp click sẽ vi phạm giả định độc lập vì các click trong cùng phiên phụ thuộc nhau.

Treatment. Thay vì tùy tiện thay đổi giá sản phẩm – điều vừa rủi ro về doanh thu vừa khó hoàn tác – treatment khả thi hơn là cách *trình bày* thông tin giá:

- **Control:** giao diện hiển thị giá hiện tại.
- **Treatment:** bổ sung thông điệp giá trị hoặc ưu đãi vận chuyển, giữ nguyên giá sản phẩm.

Outcome. Primary outcome là tỷ lệ session kết thúc trong một cửa sổ click được xác định trước (ví dụ trong vòng 3 click kể từ khi nhìn thấy treatment). Secondary outcomes gồm độ dài session và số sản phẩm duy nhất đã xem. Cửa sổ outcome phải được khóa *trước* khi thu thập dữ liệu.

Phân tích. Intention-to-treat, kiểm định hai phía tại $\alpha = 0,05$, không dừng sớm dựa trên p-value chưa điều chỉnh. Nếu cần theo dõi giữa chừng, phải dùng thiết kế sequential có kiểm soát sai lầm loại I.

Về cỡ mẫu. Nhóm cố ý *không* báo cáo một con số cỡ mẫu tính từ hai tỷ lệ click quan sát ở Bảng 8. Lý do là thí nghiệm tương lai randomize theo session và có estimand hoàn toàn khác (tỷ lệ ở cấp

session, không phải cấp click), nên đưa ra con số như vậy sẽ gây hiểu nhầm. Trước khi tính power cần khóa bốn tham số: cửa sổ outcome, tỷ lệ nền ở cấp session, minimum detectable effect có ý nghĩa kinh doanh, và mức hao hụt dự kiến. Cỡ mẫu sau đó được tính trực tiếp theo số session mỗi nhánh.

5.3 Hướng phát triển khác

- **Mô hình sinh tồn thời gian rời rạc.** Bài toán hiện tại về bản chất là ước lượng hazard rời rạc. Một mô hình survival có thể xử lý tương minh cấu trúc chọn lọc theo **Order** thay vì chỉ điều chỉnh gián tiếp.
- **Mô hình hiệu ứng hỗn hợp.** Thêm random intercept theo session sẽ mô hình hóa trực tiếp phần phụ thuộc trong cụm thay vì chỉ hiệu chỉnh sai số chuẩn.
- **Đối chứng bằng mô hình phi tham số.** Gradient boosting hoặc random forest có thể cho biết trần hiệu năng thực sự của bộ đặc trưng hiện tại; nếu chúng cũng chỉ đạt ROC-AUC quanh 0,67 thì giới hạn nằm ở dữ liệu chứ không ở dạng mô hình.
- **Gộp mức của product_model.** Xây dựng quy tắc gộp 217 mã sản phẩm dựa trên tần suất trong tập train, rồi đánh giá phần thông tin bổ sung bằng đúng pipeline hiện tại.

6 Phụ lục

6.1 Hiệu năng phân tầng của mô hình được chọn

Bảng 20 kiểm tra xem Logistic GLM có hoạt động đồng đều trên các phân nhóm hay không, tính trên temporal test 01-12/08.

Bảng 20: Hiệu năng phân tầng của Logistic GLM trên temporal test 01-12/08

Phân tầng	Nhóm	N	Prevalence	ROC-AUC	AP	Log loss	Brier
Category	Trousers	4.067	12,59%	0,638	0,200	0,365	0,107
	Skirts	2.769	15,57%	0,632	0,216	0,420	0,129
	Blouses	3.205	13,92%	0,688	0,252	0,380	0,114
	Sale	3.907	13,16%	0,693	0,252	0,364	0,108
Order	1-2	3.437	18,10%	0,612	0,241	0,465	0,146
	3-4	2.357	15,27%	0,616	0,233	0,418	0,127
	5-7	2.395	13,70%	0,631	0,213	0,388	0,116
	8-12	2.273	13,33%	0,664	0,261	0,370	0,110
	13-20	1.653	9,13%	0,670	0,198	0,292	0,080
	>20	1.833	7,58%	0,723	0,187	0,245	0,066

Hiệu năng *không* đồng đều giữa các phân nhóm. Theo danh mục, ROC-AUC dao động từ 0,632 (Skirts) đến 0,693 (Sale). Theo tiến trình session, xu hướng rõ ràng hơn: AUC tăng đều từ 0,612 ở

khoảng `Order` 1–2 lên 0,723 với các click sau vị trí 20. Nói cách khác, mô hình dự báo tốt hơn ở giai đoạn muộn của phiên – đúng lúc thông tin lịch sử duyệt đã tích lũy đủ. Đây cũng là hạn chế thực tiễn: mô hình yếu nhất chính ở giai đoạn đầu, nơi rủi ro rời bỏ cao nhất.

Lưu ý rằng Brier score giảm dần theo `Order` chủ yếu vì prevalence giảm (từ 18,10% xuống 7,58%), không phải vì mô hình tốt lên; hai chỉ số này phải đọc cùng nhau.

6.2 Phân công công việc

Bảng 21: Phân công công việc trong nhóm

Họ và tên	MSSV	Nội dung phụ trách
Phạm Đoàn Vĩnh Nghi	25C23012	Phần 1: giới thiệu bộ dữ liệu, xác định mục tiêu phân tích và xây dựng bản đề xuất phương pháp; phối hợp viết Phần 4.
Lê Hoàng Như	25C23014	Phần 2: làm sạch dữ liệu, thống kê mô tả và trực quan hóa; phối hợp viết Phần 4; soạn slide thuyết trình.
Nguyễn Nhật Quang	25C23002	Phần 3: xây dựng và đánh giá mô hình, toàn bộ bảng kết quả và biểu đồ; tổng hợp nội dung hai file Rmd thành báo cáo nộp; phối hợp viết Phần 4.

6.3 Ghi chú về tính tái lập

Toàn bộ kết quả trong báo cáo được sinh từ một lần render duy nhất của file `de_xuat_phan_tich_clickstream` bằng R [6] trong một session sạch, không phụ thuộc vào object còn sót lại trong môi trường làm việc.

Bảng 22: Môi trường thực thi

Thành phần	Phiên bản
R	4.6.0 (2026-04-24)
rmarkdown	2.31
knitr	1.51
mgecv	1.9.4
sandwich	3.1.1
lmtest	0.9.40
car	3.1.5
dplyr	1.2.1
tidyr	1.3.2
ggplot2	4.0.3
patchwork	1.3.2
scales	1.4.0
emmeans	2.0.4

Nguồn dữ liệu. File `e-shop clothing 2008.csv` (phân tách bằng dấu chấm phẩy, 14 cột, 165.474 dòng), không chỉnh sửa thủ công.

Seed ngẫu nhiên. Mọi thủ tục có yếu tố ngẫu nhiên đều dùng `set.seed(20260726)`: chia five-fold cross-validation theo session, 1.000 lần cluster bootstrap cho risk difference thô, và 500 lần cluster bootstrap cho khoảng tin cậy của các metric trên temporal test. Nhờ vậy toàn bộ con số trong báo cáo tái lập được chính xác.

Kiểm tra tự động trong pipeline. File Rmd chứa các khẳng định `stopifnot()` được kiểm tra ở mỗi lần chạy: đúng 165.474 dòng và 24.026 session; không có giá trị khuyết thiếu hay dòng trùng lặp; `order` liên tục trong mọi session; mỗi session có đúng một `click Exit = 1`; và không có session nào xuất hiện đồng thời ở hai tập dữ liệu. Nếu bất kỳ điều kiện nào sai, quá trình render sẽ dừng với lỗi thay vì tạo ra báo cáo không hợp lệ.

Lệnh render. Chạy từ thư mục chứa file Rmd và file CSV:

```
1 rmarkdown::render(  
2   "de_xuat_phan_tich_clickstream.Rmd",  
3   params = list(show_code = FALSE),  
4   envir   = new.env()  
5 )
```

Tham số `show_code = FALSE` tạo bản nộp không hiển thị mã nguồn; đặt `show_code = TRUE` sẽ tạo bản kiểm tra có kèm mã R cho từng bảng và biểu đồ. Các hình trong báo cáo LaTeX này được xuất ở độ phân giải 200 dpi từ đúng lần chạy nói trên và lưu trong thư mục `img/` với tiền tố `fig-`.

Tài liệu

- [1] A. Colin Cameron and Douglas L. Miller. A practitioner’s guide to cluster-robust inference. *Journal of Human Resources*, 50(2):317–372, 2015.
- [2] Andrew Gelman and Jennifer Hill. *Data Analysis Using Regression and Multilevel/Hierarchical Models*. Cambridge University Press, 2007.
- [3] Sture Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2):65–70, 1979.
- [4] Mariusz Łapczyński and Sylwester Białowas. Discovering patterns of users’ behaviour in an e-shop: Comparison of consumer buying behaviours in poland and other european countries. *Studia Ekonomiczne*, (151):144–153, 2013.
- [5] Mariusz Łapczyński and Sylwester Białowas. Clickstream data for online shopping. UCI Machine Learning Repository, 2019. <https://archive.ics.uci.edu/dataset/553/clickstream+data+for+online+shopping>.
- [6] R Core Team. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria, 2026. Phiên bản 4.6.0.
- [7] Ewout W. Steyerberg, Andrew J. Vickers, Nancy R. Cook, Thomas Gerds, Mithat Gonen, Nancy Obuchowski, Michael J. Pencina, and Michael W. Kattan. Assessing the performance of prediction models: A framework for traditional and novel measures. *Epidemiology*, 21(1):128–138, 2010.

- [8] Edwin B. Wilson. Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158):209–212, 1927.
- [9] Simon N. Wood. *Generalized Additive Models: An Introduction with R*. Chapman and Hall/CRC, 2 edition, 2017.
- [10] Achim Zeileis. Econometric computing with hc and hac covariance matrix estimators. *Journal of Statistical Software*, 11(10):1–17, 2004.