

Bài giảng 2: Dữ liệu và phân phối mẫu

TS. Tô Đức Khánh

Khoa Toán-Tin Học, Trường Đại Học Khoa Học Tự Nhiên
Đại Học Quốc Gia Tp. HCM

Học phần: Xử lý Số liệu Thống kê

Nội dung buổi học

1 Lấy mẫu ngẫu nhiên

2 Phân phối mẫu

3 Xấp xỉ phân phối của ước lượng

4 Khoảng tin cậy bootstrap

1 Lấy mẫu ngẫu nhiên


2 Phân phối mẫu

3 Xấp xỉ phân phối của ước lượng

4 Khoảng tin cậy bootstrap

Quần thể vs Dữ liệu

Trong phần trước ta đã học về dữ liệu và các đặc tính liên quan.



Quần thể vs Dữ liệu

Nhưng dữ liệu mà ta có, chỉ là một mẫu được quan sát/thu thập của 1 quần thể dữ liệu lớn hơn.



Quần thể vs Dữ liệu





Ví dụ dữ liệu về thời gian cất cánh trễ của máy bay xuất phát ở New York

	year	month	day	dep_time	sched_dep_time	dep_delay	arr_time
1	2013	1	1	517	515	2	830
2	2013	1	1	533	529	4	850
3	2013	1	1	542	540	2	923
4	2013	1	1	544	545	-1	1004
5	2013	1	1	554	600	-6	812
6	2013	1	1	554	558	-4	740
7	2013	1	1	555	600	-5	913
8	2013	1	1	557	600	-3	709
9	2013	1	1	557	600	-3	838
10	2013	1	1	558	600	-2	753
11	2013	1	1	558	600	-2	849

- chỉ trong năm 2013
- chỉ quan sát tại New York

Quần thể vs Dữ liệu


Ví dụ dữ liệu về chữ số viết tay



- giới hạn số người thu thập;
- giới hạn khu vực lấy mẫu.

Quần thể vs Dữ liệu

Một mẫu (dữ liệu) là một tập hợp các đơn vị nhỏ hơn (nhưng hy vọng mang tính đại diện) từ một quần thể được sử dụng để xác định sự thật về quần thể đó.



Quần thể vs Dữ liệu

Trong thực tế,

- các tính chất của một biến trong quần thể thường được giả định
ví dụ, tuân theo một phân phối chưa biết (có thể là phân phối chuẩn);
- tuy nhiên, cái ta có trong tay là dữ liệu và phân phối thực nghiệm.

Để có được mẫu từ một quần thể ta cần một **quá trình lấy mẫu** (sampling procedure).

- Thống kê truyền thống tập trung rất nhiều vào quần thể, sử dụng lý thuyết dựa trên những giả định chắc chắn về quần thể.
- Thống kê hiện đại tập trung vào dữ liệu, nơi mà những giả định về phân phối là không cần thiết.

Lấy mẫu ngẫu nhiên

Các thuật ngữ chính

Mẫu (Sample) một tập con từ một bộ dữ liệu lớn;

Quần thể (Population) một bộ dữ liệu lớn hoặc một dữ liệu lý thuyết;

N (n) Kích cỡ của quần thể (mẫu);

Lấy mẫu ngẫu nhiên (Random sampling) Lấy phần tử một cách ngẫu nhiên từ quần thể;


Lấy mẫu phân tầng (Stratified sampling) Phân chia quần thể thành các tầng khác nhau, và thực hiện lấy mẫu ngẫu nhiên ở mỗi tầng;

Mẫu ngẫu nhiên đơn giản (Simple random sample) là một mẫu kết quả của quá trình lấy mẫu ngẫu nhiên đơn giản (không phân chia tầng trong quần thể);

Mẫu thiên vị (Sample bias) là một mẫu trình bày sai về quần thể.

Lấy mẫu ngẫu nhiên

Lấy mẫu ngẫu nhiên (Random sampling)



Ví dụ, ta chọn ngẫu nhiên 20 chuyến bay bất kỳ trong dữ liệu `flights` (gồm 336,776 chuyến bay).

Lấy mẫu ngẫu nhiên


Có hai dạng lấy mẫu ngẫu nhiên:

lấy có hoàn lại (with replacement) tức là các quan sát sẽ được trả lại quần thể sau khi lấy mẫu, và do đó, có thể được lấy mẫu trong tương lai;

lấy không hoàn lại (without replacement) tức là các quan sát chỉ được lấy mẫu một lần duy nhất, và không được trả lại quần thể.

Lấy mẫu ngẫu nhiên

Lấy mẫu phân tầng (Stratified sampling)



Ví dụ, ta chọn ngẫu nhiên 20 chuyến bay bất kỳ trong mỗi tháng (từ 1 tới 12) của dữ liệu flights (gồm 336,776 chuyến bay).

Chất lượng dữ liệu và số lượng dữ liệu

Chất lượng dữ liệu - Data quality

Chất lượng dữ liệu thường quan trọng hơn số lượng dữ liệu khi đưa ra ước tính hoặc mô hình dựa trên mẫu.

Chất lượng dữ liệu trong khoa học dữ liệu liên quan đến:

- tính đầy đủ;
- nhất quán về định dạng;
- độ rõ ràng;
- độ chính xác của từng điểm dữ liệu.

↪ tính đại diện của dữ liệu cho quần thể.

Chất lượng dữ liệu và số lượng dữ liệu

Số lượng dữ liệu

Số lượng lớn dữ liệu yêu cầu:

- thời gian;
- chi phí;
- công sức.

Ví dụ, theo dõi các dữ liệu cực đoan hoặc bị khuyết:

- chiếm 10% của 1,000,000 quan sát;
- chiếm 10% của 1,000 quan sát.

↪ trong một số trường hợp, số lượng lớn dữ liệu không thực tế và kém hiệu quả.

Nhưng trong một vài nhiệm vụ cụ thể, số lượng lớn dữ liệu lại hữu ích trong việc nâng cao độ chính xác.

Ví dụ, truy vấn từ/cụm từ trên Google, những từ/cụm từ “hot” càng cho ra kết quả chính xác.

Sự lựa chọn thiên vị

Sự lựa chọn thiên vị (Selection bias) đề cập đến việc lựa chọn dữ liệu có chọn lọc - có ý thức hoặc vô thức - theo cách dẫn đến một kết luận sai lệch hoặc không vững chắc.

Cụ thể:

- lấy mẫu không ngẫu nhiên - nonrandom sampling;
- cherry-picking data;
- chọn khoảng thời gian làm nổi bật các phân tích thống kê;
- dừng thử nghiệm khi kết quả trông như “hấp dẫn”.
- **Săn lùng dữ liệu - Data snooping:** Săn lùng rộng rãi thông qua dữ liệu để tìm kiếm điều gì đó thú vị.
- **Vast search effect:** liên tục chạy các mô hình khác nhau và đặt các câu hỏi khác nhau với một tập dữ liệu lớn, chắc chắn ta sẽ tìm thấy điều gì đó thú vị. Tuy nhiên, kết quả tìm thấy có thực sự thú vị hay chỉ là một kết quả không thực?

Lấy mẫu ngẫu nhiên
○○○○○

Phân phối mẫu
●○○○○○

Xấp xỉ phân phối của ước lượng
○○○○○○○

Khoảng tin cậy bootstrap
○○○○○○○

1 Lấy mẫu ngẫu nhiên

2 Phân phối mẫu

3 Xấp xỉ phân phối của ước lượng

4 Khoảng tin cậy bootstrap

Phân phối mẫu của một thống kê

Thống kê - a Statistic

Một thống kê - a statistic, là một tên gọi ám chỉ tới các đại lượng được tính toán từ một dữ liệu, ví dụ:

- trung bình mẫu $\bar{Y}$;
- độ lệch chuẩn mẫu S ;
- median;
- thống kê $Z = \frac{\bar{Y} - \mu}{\sigma/\sqrt{n}}$;
- thống kê $T = \frac{\bar{Y} - \mu}{S/\sqrt{n}}$.

Phân phối mẫu của một thống kê

Thống kê - a Statistic

Một thống kê - a statistic, là một tên gọi ám chỉ tới các đại lượng được tính toán từ một dữ liệu, ví dụ:

- trung bình mẫu $\bar{Y}$;
- độ lệch chuẩn mẫu S ;
- median;
- thống kê $Z = \frac{\bar{Y} - \mu}{\sigma/\sqrt{n}}$;
- thống kê $T = \frac{\bar{Y} - \mu}{S/\sqrt{n}}$.

Bởi vì dữ liệu là ngẫu nhiên, nên các một thống kê cũng là đại lượng ngẫu nhiên.

↪ có các đặc trưng của một đại lượng ngẫu nhiên:

- trung bình;
- phương sai, độ lệch chuẩn;
- phân phối.

Phân phối mẫu của một thống kê

Phân phối mẫu

Phân phối mẫu là thuật ngữ nhằm tới phân phối của một thống kê, khi ta thực hiện lấy mẫu nhiều lần từ quần thể.

Độ chệch - Bias


Độ chệch (Bias) là thuật ngữ nhằm tới sự chênh lệch của trung bình của một thống kê so với giá trị “chính xác” (dựa trên quần thể/dữ liệu lớn), khi ta thực hiện lấy mẫu nhiều lần từ quần thể.

Sai số chuẩn - Standard error

Sai số chuẩn (Standard error) ám chỉ tới độ lệch chuẩn của một thống kê (ước lượng), đo sự biến động của ước lượng ở trên nhiều mẫu.

Phân phối mẫu của một thống kê

Sơ đồ dưới đây minh họa phân phối mẫu của trung bình mẫu $\bar{Y}$.



Ví dụ


Xét dữ liệu về thu nhập theo năm của 50,000 hồ sơ vay tiền gửi tới Lending Club.

Từ dữ liệu lớn này, ta thực hiện như sau:

- Chọn ngẫu nhiên 1000 quan sát, coi như một quần thể.
- Từ 1000 quan sát, chọn ngẫu nhiên 1000 mẫu, có cỡ 5, và tính trung bình thu nhập của mỗi mẫu.
↪ ta có một tập hợp 1000 trung bình mẫu của cỡ mẫu 5.
- Từ 1000 quan sát, chọn ngẫu nhiên 1000 mẫu, có cỡ 20, và tính trung bình thu nhập của mỗi mẫu.
↪ ta có một tập hợp 1000 trung bình mẫu của cỡ mẫu 20.

Biểu đồ histogram dưới đây biểu diễn phân phối tương ứng của các dữ liệu, cùng với trung bình mẫu của mẫu gồm 1000 quan sát (đường nét đứt màu xanh).

Ví dụ



Ví dụ

Ta có bảng tổng hợp sau

	Trung bình	Độ lệch	SE
Mẫu 1000	68199.66	—	—
Trung bình của mẫu 5	69154.31	954.65	14979.52
Trung bình của mẫu 20	68751.65	551.99	7245.36

trong đó,

- độ lệch bằng trung bình của mẫu gồm 1000 trung bình trừ đi trung bình của mẫu 1000 quan sát;
- SE là sai số chuẩn (standard error) bằng độ lệch chuẩn của mẫu gồm 1000 trung bình.

Định lý giới hạn trung tâm - Central Limit Theorem

Định lý giới hạn trung tâm - Central Limit Theorem là:

- một trong số các kết quả quan trọng trong lý thuyết xác suất-thống kê;
- xương sống cho các suy luận thống kê (khoảng tin cậy, kiểm định thống kê).

Central Limit Theorem

Cho dãy mẫu ngẫu nhiên $Y_1, Y_2, \dots, Y_n$ độc lập cùng phân phối xác suất, sao cho $\mathbb{E}(Y_i) = \mu$ và $\mathbb{Var}(Y_i) = \sigma^2$ với mọi $i = 1, 2, \dots, n$. Đặt $\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$ (trung bình mẫu). Khi đó:

$$\bar{Y} \xrightarrow{d} \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right),$$

khi $n \rightarrow +\infty$ (n đủ lớn).

Tức là trung bình mẫu $\bar{Y}$ sẽ xấp xỉ phân phối chuẩn, với trung bình μ , phương sai $\frac{\sigma^2}{n}$, khi cỡ mẫu n đủ lớn.

Sai số chuẩn

Theo kết quả của định lý Giới Hạn Trung Tâm, ta có sai số chuẩn cho trung bình mẫu $\bar{Y}$ là

$$SE = \frac{s}{\sqrt{n}},$$

với

- s là độ lệch chuẩn mẫu;
- n là cỡ mẫu.

Khi cỡ mẫu n tăng lên b lần thì sai số chuẩn giảm xuống với tỷ lệ là $\sqrt{b}$.

Mặt khác, trong ví dụ trên:

- với cỡ mẫu 5, $SE = 14979.52$;
- với cỡ mẫu 20, $SE = 7245.36$.

↔ cỡ mẫu tăng 4 lần, thì SE giảm xấp xỉ 2 lần.

Nhắc lại, trong ví dụ trên, ta không tính SE theo công thức dựa trên định lý Giới Hạn Trung Tâm.

Sai số chuẩn

Sai số chuẩn SE ở ví dụ trên được tính theo cách thức sau:

1. thu thập một loạt M bộ dữ liệu khác nhau, cùng cỡ mẫu n ;
2. với mỗi mẫu, tính giá trị của thống kê (chẳng hạn, trung bình);
3. tính độ lệch chuẩn của tất cả các giá trị thống kê được tính trong bước 2, và sử dụng kết quả thu được như là ước lượng của sai số chuẩn.

Trong thực tế, việc áp dụng phương thức này không thực tế, do phải lấy nhiều mẫu.

Phân phối mẫu của ước lượng

Cho $X_1, \dots, X_n$ là mẫu ngẫu nhiên, độc lập cùng phân phối $F_X(x)$.

Đặt $\hat{\theta} = T(X_1, \dots, X_n)$ là ước lượng của tham số θ , với $T(\cdot)$ là một hàm thực.

Do $X_1, \dots, X_n$ là ngẫu nhiên, nên $\hat{\theta}$ cũng là ngẫu nhiên.

$\Rightarrow$ Phân phối của $\hat{\theta}$ bị ảnh hưởng bởi phân phối $F_X(\cdot)$ của dữ liệu.

$\Rightarrow$ Ta có thể biểu diễn $\hat{\theta} = T(F)$.

Bài toán

Trong thống kê suy luận, ta quan tâm tới việc xác định **phân phối lý thuyết** của $\hat{\theta}$ từ mẫu ngẫu nhiên $X_1, \dots, X_n \stackrel{\text{i.i.d}}{\sim} F_X(x)$.

Phân phối này được ký hiệu là $F_{\hat{\theta}}(u)$, và có thể ở dạng:

- phân phối chính xác;
- phân phối tiệm cận (asymptotic distribution).

Phân phối mẫu của ước lượng

Phân phối mẫu chính xác

Phân phối mẫu chính xác $F_{\hat{\theta}}(u)$ được xác định dạng tường minh (các phân phối thông dụng) thông qua việc giả định dạng cụ thể cho phân phối $F_X(x)$ của mẫu ngẫu nhiên.

Ví dụ: Giả sử $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2)$. Xét $\hat{\theta} \equiv \bar{X}$ tức là trung bình mẫu. Khi đó, ta chứng minh được

$$\hat{\theta} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right),$$

nếu σ^2 đã biết, ngược lại

$$\frac{\hat{\theta} - \mu}{S/\sqrt{n}} \sim t_{n-1},$$

phân phối t -student bậc tự do $n - 1$, với S là độ lệch chuẩn mẫu

$$S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}.$$

Phân phối mẫu của ước lượng

Phân phối mẫu tiệm cận

Phân phối mẫu tiệm cận $F_{\hat{\theta}}(u)$ được xác định dạng tường minh (các phân phối thông dụng) thông qua quá trình chứng minh hội tụ phân phối (convergence in distribution) của $\hat{\theta}$ khi cỡ mẫu $n \rightarrow +\infty$, mà **không** cần giả định dạng cụ thể cho phân phối $F_X(x)$ của mẫu ngẫu nhiên.

Ví dụ: Giả sử $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F_X(x)$, với trung bình μ và phương sai σ^2 . Xét $\hat{\theta} = \bar{X}$ tức là trung bình mẫu. Khi đó, ta chứng minh được

$$\hat{\theta} \xrightarrow{d} \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right),$$

khi $n \rightarrow +\infty$, trong đó ký hiệu " $\xrightarrow{d}$ " có nghĩa là hội tụ phân phối (convergence in distribution).

Phân phối mẫu của ước lượng

Vấn đề thực tế

Khi làm việc với dữ liệu $X_1, \dots, X_n$ ta thường đối mặt với

- phân phối $F_X(x)$ là không biết;
- cỡ mẫu n là không đủ lớn;
- ước lượng $\hat{\theta}$ phức tạp để có thể tìm được phân phối sai số chuẩn.

Điều này dẫn tới

- phân phối mẫu chính xác không thể xác định;
- xấp xỉ phân phối tiệm cận không đủ tốt;
- không tính chính xác được sai số chuẩn.


⇒ ta cần xây dựng được quy trình **ước lượng** được phân phối mẫu của ước lượng từ 1 bộ dữ liệu.

Phương pháp bootstrap

Phương pháp bootstrap

Phương pháp bootstrap là một phương pháp hiệu quả để ước lượng phân phối mẫu (sampling distribution) của một thống kê, hoặc một mô hình.

Phương pháp bootstrap hoạt động trên nguyên lý lấy lại mẫu (resampling) dựa trên dữ liệu gốc (original data).



Phương pháp bootstrap

Cụ thể, thuật toán của phương pháp bootstrap với một mẫu cỡ n như sau:

1. Tạo một mẫu ngẫu nhiên cỡ n từ dữ liệu gốc, có lặp lại (with replacement);
2. Tính giá trị của thống kê (ví dụ, trung bình) với mẫu vừa tạo;
3. Lặp lại bước 1 và 2 trong R lần (ít nhất 500 lần), và lưu kết quả lại.

Ta có thể sử dụng R giá trị của thống kê để:

- xác định độ lệch chuẩn của chúng $\implies$ sai số chuẩn;
- biểu diễn histogram để mô tả phân phối mẫu của thống kê;
- xác định khoảng tin cậy cho thống kê.

Phương pháp bootstrap

Ví dụ, ta có một bộ dữ liệu gồm thu nhập hàng năm tương ứng 10 người.

data
86000
40000
55000
35000
53000
140000
128000
105000
66500
100000



$$\bar{y} = 80850$$

lần 1
66500
86000
55000
55000
100000
86000
66500
128000
66500
53000



$$\bar{y}_1 = 76250$$

lần 2
53000
105000
128000
100000
100000
55000
140000
40000
100000
100000



$$\bar{y}_2 = 92100$$

...


lần R
100000
66500
140000
55000
86000
35000
140000
105000
140000
86000



$$\bar{y}_R = 95350$$

Phương pháp bootstrap


Ta lặp lại quá trình bootstrap 1000 lần.



- độ lệch: -421.35
- sai số chuẩn: 11000.69

Phương pháp bootstrap

Phương pháp bootstrap còn có thể sử dụng cho dữ liệu nhiều chiều (multivariate data), trong đó, với mỗi lần tạo mẫu, ta sẽ lấy ngẫu nhiên 1 dòng của dữ liệu.



Lấy mẫu ngẫu nhiên
○○○○○

Phân phối mẫu
○○○○○○○

Xấp xỉ phân phối của ước lượng
●○○○○○○○

Khoảng tin cậy bootstrap
○○○○○○○

1 Lấy mẫu ngẫu nhiên

2 Phân phối mẫu

3 Xấp xỉ phân phối của ước lượng

4 Khoảng tin cậy bootstrap

Ý tưởng từ phân phối thực nghiệm

Nhắc lại: Với một mẫu ngẫu nhiên, $Y_1, \dots, Y_n$ của Y tuân theo phân phối $F(y)$. Hàm phân phối thực nghiệm (the empirical cumulative distribution function - ecdf) của Y được xác định bởi

$$\hat{F}_n(y) = \frac{1}{n} \sum_{i=1}^n \mathbf{I}(Y_i \leq y),$$

là một ước lượng của F_Y , với $\mathbf{I}(\cdot)$ là hàm chỉ (indicator function) và được định nghĩa như sau:

$$\mathbf{I}(y \leq a) = \begin{cases} 1 & \text{nếu } y \leq a, \\ 0 & \text{nếu } y > a. \end{cases}$$

Hơn nữa, theo Định lý Glivenko-Cantelli, ta chứng minh được

$$\sup_{y \in \mathbb{R}} \left| \hat{F}_n(y) - F(y) \right| \rightarrow 0,$$

khi $n \rightarrow +\infty$, tức là $\hat{F}_n(y)$ là ước lượng vững của $F(y)$, hay nói cách khác, giá trị $\hat{F}_n(y)$ sẽ xấp xỉ bằng $F(y)$.

Ý tưởng từ phân phối thực nghiệm

Xét ước lượng $\hat{\theta}$ là hàm của mẫu ngẫu nhiên.

Giả sử rằng, ta có 1 bộ mẫu ngẫu nhiên gồm m quan sát: $\hat{\theta}_1, \dots, \hat{\theta}_m$. Khi đó hàm phân phối thực nghiệm của $\hat{\theta}$ được xác định là:

$$\hat{F}_{m,\hat{\theta}}(u) = \frac{1}{m} \sum_{i=1}^m \mathbf{I}(\hat{\theta}_i \leq u).$$

$\Rightarrow$ ta cần có m mẫu gồm n quan sát $Y_1, \dots, Y_n$ (được lấy ngẫu nhiên từ quần thể) để xác định

- $\hat{\theta}_i$;
- qua đó xác định $\hat{F}_{m,\hat{\theta}}(u)$,

thêm vào đó, ta còn chứng minh được rằng sai số chuẩn của $\hat{\theta}$ là

$$\text{SE}(\hat{\theta}) = \sqrt{\frac{1}{m-1} \sum_{i=1}^m (\hat{\theta}_i - \bar{\hat{\theta}})^2},$$

trong đó, $\bar{\hat{\theta}}$ là trung bình của m ước lượng.

Phương pháp resampling

Trong thực tế, ta không thể thực hiện lấy dữ liệu m lần, mà chỉ có 1 lần duy nhất. $\Rightarrow$ cách làm trên không khả thi.

Tuy nhiên, nếu dữ liệu thu được là đủ tốt để đại diện cho quần thể

$\Rightarrow$ ta có thể dùng mẫu đó như quần thể

$\Rightarrow$ tạo mẫu ngẫu nhiên từ dữ liệu này.



Khi ta tạo đi tạo lại mẫu ngẫu nhiên từ 1 dữ liệu gốc $\Rightarrow$ ta đang thực hiện phương pháp resampling.

Ta có hai cách lấy mẫu chính:

- lấy mẫu không hoàn lại (sampling without replacement);
- lấy mẫu có hoàn lại (sampling with replacement).

Phương pháp resampling


Sampling with Replacement



Phương pháp bootstrap

Phương pháp bootstrap

Phương pháp bootstrap hoạt động trên nguyên lý lấy lại mẫu có hoàn lại dựa trên dữ liệu gốc (original data).



Phương pháp bootstrap

Cụ thể, thuật toán của phương pháp bootstrap với một mẫu cỡ n như sau:

1. Tạo một mẫu ngẫu nhiên cỡ n từ dữ liệu gốc, có hoàn lại (with replacement);
2. Tính giá trị của ước lượng $\hat{\theta}^*$ với mẫu vừa tạo;
3. Lặp lại bước 1 và 2 trong R lần (ít nhất 500 lần), và lưu kết quả lại:
 $\hat{\theta}_1^*, \dots, \hat{\theta}_R^*$.

Từ R giá trị ước lượng bootstrap này, ta xác định được

- phân phối bootstrap cho $\hat{\theta}$ (coi như là phân phối mẫu thực nghiệm xấp xỉ)

$$\hat{F}_{R, \hat{\theta}}(u) = \frac{1}{R} \sum_{b=1}^R \mathbf{I}(\hat{\theta}_b^* \leq u).$$

- độ lệch chuẩn của các ước lượng bootstrap $\Leftrightarrow$ sai số chuẩn của $\hat{\theta}$

$$\text{SE}(\hat{\theta}) = \sqrt{\frac{1}{R-1} \sum_{b=1}^R (\hat{\theta}_b^* - \bar{\hat{\theta}}^*)^2}.$$

Phương pháp bootstrap

Nhận xét:

- Việc tạo mẫu ngẫu nhiên tại bước 1 được coi là “mô phỏng dữ liệu” dựa trên thông tin của dữ liệu gốc.
- Việc mô phỏng được thực hiện dựa vào phân phối của dữ liệu.

⇒ ta cần $\hat{F}_Y(y)$.

Có hai phương pháp xác định $\hat{F}_Y(y)$:

- Phương pháp tham số (parametric estimation): giả định một dạng tham số cụ thể cho $F_Y(y; \beta) \Rightarrow$ xác định $\hat{\beta} \Rightarrow$ xác định $\hat{F}_Y(y) \equiv F_Y(y; \hat{\beta})$
⇒ parametric bootstrap.
- Phương pháp phi tham số (non-parametric estimation): sử dụng trực tiếp phân phối tích lũy thực nghiệm $\hat{F}_n(y)$
⇒ non-parametric bootstrap.

Phương pháp non-parametric bootstrap được sử dụng phổ biến do tính đơn giản và sát với dữ liệu.

Tạo dữ liệu từ hàm phân phối

Cho Y là một biến ngẫu nhiên tuân theo phân phối $F_Y(y)$. Khi đó, ta có

$$F_Y(y) = \Pr(Y \leq y) = p,$$

với $p \in (0, 1)$.

- Nếu $F_Y(y)$ là hàm liên tục thì, với p cho trước, ta xác định được một y sao cho

$$y = F_Y^{-1}(p),$$

trong đó $F_Y^{-1}(\cdot)$ là hàm ngược của $F_Y(\cdot)$.

- Nếu $F_Y(y)$ là hàm không liên tục thì, với p cho trước, ta xác định được một y sao cho

$$y = F_Y^{-1}(p) \equiv \inf \{y \in \mathbb{R} : p \leq F(y), p \in (0, 1)\}.$$

$\Rightarrow$ phát sinh ngẫu nhiên p trong $(0, 1) \Rightarrow$ xác định được y ngẫu nhiên.

Trong lập trình, ta có thể sử dụng thuật toán **Mersenne twister** để phát sinh ngẫu nhiên p .

Chú ý: hàm $F_Y^{-1}(p)$ còn gọi là hàm phân vị (quantile function).

Non-parametric bootstrap

Với dữ liệu $Y_1, \dots, Y_n$ của Y tuân theo phân phối $F_Y(y)$. Hàm phân phối thực nghiệm của Y được xác định bởi

$$\hat{F}_n(y) = \frac{1}{n} \sum_{i=1}^n \mathbf{I}(Y_i \leq y),$$

là một ước lượng của $F_Y(y)$.

Gọi $Y_1^*, Y_2^*, \dots, Y_n^*$ là bộ dữ liệu được tạo mô phỏng từ $\hat{F}_n(y)$.

Theo công thức, $\hat{F}_n(y)$ sẽ luôn nhận giá trị trong tập $\left\{0, \frac{1}{n}, \frac{2}{n}, \dots, \frac{n}{n}\right\}$.

Xét các điểm dữ liệu được sắp xếp thứ tự

$$Y_{(1)} \leq Y_{(2)} \leq \dots \leq Y_{(n)}$$

Tại điểm thứ i , luôn có i dữ liệu $\leq Y_{(i)}$, nên,

$$\hat{F}_n(Y_{(i)}) = \frac{i}{n}.$$

Non-parametric bootstrap

Khi đó ta có

$$Y_{(i)} = \hat{F}_n^{-1} \left(\frac{i}{n} \right),$$

với $\hat{F}_n^{-1}(p)$ được xác định bởi:

$$\hat{F}_n^{-1}(p) = \inf \left\{ y \in \mathbb{R} : p \leq \hat{F}_n(y), p \in (0, 1) \right\}.$$

Áp dụng phương pháp tạo mẫu ngẫu nhiên từ hàm phân phối, ta phát sinh y ngẫu nhiên thông qua

$$y = \hat{F}_n^{-1}(p),$$

với p được chọn ngẫu nhiên từ tập $\left\{ 0, \frac{1}{n}, \frac{2}{n}, \dots, \frac{n}{n} \right\}$.

$\Rightarrow$ giá trị y được phát sinh sẽ luôn là một điểm trong bộ dữ liệu.

Do đó, tạo mẫu ngẫu nhiên từ $\hat{F}_n(y)$ tương đương với việc lấy mẫu ngẫu nhiên có hoàn lại từ dữ liệu quan sát $Y_1, Y_2, \dots, Y_n$.

Non-parametric bootstrap

Ví dụ: ta có một bộ dữ liệu gồm thu nhập hàng năm tương ứng 10 người.

Ta quan tâm $\hat{\theta} \equiv \bar{Y}$ - trung bình thu nhập.

Quá trình bootstrap $R = 1000$ lần, được minh họa như sau.

data
86000
40000
55000
35000
53000
140000
128000
105000
66500
100000



$$\bar{y} = 80850$$

lần 1
66500
86000
55000
55000
100000
86000
66500
128000
66500
53000



$$\bar{y}_1 = 76250$$

lần 2
53000
105000
128000
100000
100000
55000
140000
40000
100000
100000



$$\bar{y}_2 = 92100$$


...

lần R
100000
66500
140000
55000
86000
35000
140000
105000
140000
86000



$$\bar{y}_R = 95350$$

Non-parametric bootstrap



Non-parametric bootstrap

- độ chệch bootstrap:

$$\text{bias}(\hat{\theta}^*) = \hat{\theta} - \bar{\hat{\theta}}^* = -421.35$$

- sai số chuẩn cho $\hat{\theta}$:

$$\text{SE}(\hat{\theta}) = \sqrt{\frac{1}{1000 - 1} \sum_{b=1}^{1000} \left(\hat{\theta}_b^* - \bar{\hat{\theta}}^* \right)^2} = 11000.69.$$

Mở rộng cho dữ liệu nhiều chiều


Dữ liệu nhiều chiều là dữ liệu gồm nhiều cột, với mỗi cột là một biến ngẫu nhiên.

id	X_1	X_2	$\dots$	X_q
1	x_{11}	x_{21}	$\dots$	x_{q1}
2	x_{12}	x_{22}	$\dots$	x_{q2}
3	x_{13}	x_{23}	$\dots$	x_{q3}
4	x_{14}	x_{24}	$\dots$	x_{q4}
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
n	x_{1n}	x_{2n}	$\dots$	x_{qn}

Khi này, mỗi một dòng tương ứng là một vector giá trị quan sát được của một vector ngẫu nhiên $(X_1, X_2, \dots, X_q)$.

Mở rộng cho dữ liệu nhiều chiều

Khi áp dụng Phương pháp bootstrap cho dữ liệu nhiều chiều (multivariate data), ta sẽ tạo dữ liệu bootstrap bằng cách lấy ngẫu nhiên 1 dòng của dữ liệu từ n dòng ban đầu.



Bootstrapping dependent data - Đọc thêm

Phương pháp bootstrap được thiết kế cho dữ liệu $X_1, \dots, X_n$ độc lập cùng phân phối.

Nếu dữ liệu phụ thuộc nhau, tức là $\text{Cov}(X_i, X_j) \neq 0 \Rightarrow$ phương pháp bootstrap cơ bản không còn dữ được cấu trúc của dữ liệu:

- dữ liệu chuỗi thời gian (time series data);
- dữ liệu phân lớp (stratified data);
- dữ liệu phân cụm (clustered data).

$\Rightarrow$ cần thay đổi cách lấy mẫu bootstrap.

- Xem thêm về các phương pháp lấy mẫu bootstrap cho dữ liệu chuỗi thời gian (model-based approach, block bootstrap: non-moving block bootstrap, moving block bootstrap, blocks-of-blocks bootstrapping, centering and studentizing).
- Tìm hiểu các tài liệu mở về stratified bootstrap với phương pháp lấy mẫu phân tầng (stratified sampling).
- Tìm hiểu các tài liệu mở về clustered bootstrap với phương pháp lấy mẫu theo cụm (clustered sampling).

Lấy mẫu ngẫu nhiên
○○○○○

Phân phối mẫu
○○○○○○○

Xấp xỉ phân phối của ước lượng
○○○○○○○○

Khoảng tin cậy bootstrap
●○○○○○○

1 Lấy mẫu ngẫu nhiên

2 Phân phối mẫu


3 Xấp xỉ phân phối của ước lượng

4 Khoảng tin cậy bootstrap

Khoảng tin cậy

Ta xét ví dụ như sau:

- dữ liệu lớn gồm 1000 ghi chép thu nhập hàng năm của 1000 người;
- ước lượng trung bình thu nhập trong 1000 mẫu có cỡ 5, được lấy ngẫu nhiên từ dữ liệu lớn (các điểm đen trên hình);
- trung bình thu nhập trong dữ liệu lớn (đường nét đứt màu xanh).



Xây dựng khoảng tin cậy cho θ

Giả sử ta có

- $Y_1, Y_2, \dots, Y_n \stackrel{\text{i.i.d.}}{\sim} F_Y(y)$, của biến Y ;
- $\hat{\theta}$ là ước lượng của θ .

Để xây dựng khoảng tin cậy cho tham số θ , ta cần thông tin về phân phối mẫu của $\hat{\theta}$, $F_{\hat{\theta}}(u)$.

Khoảng tin cậy chính xác (exact confidence interval)

Nếu $F_{\hat{\theta}}(u)$ được xác định chính xác, thì khoảng $(L(Y_1, \dots, Y_n), U(Y_1, \dots, Y_n))$ được gọi khoảng tin cậy **chính xác** $100 \times (1 - \alpha)\%$ cho θ nếu với mọi $\theta \in \Theta$

$$\Pr(L(Y_1, \dots, Y_n) \leq \theta \leq U(Y_1, \dots, Y_n)) = 1 - \alpha,$$

hay tương đương với

$$F_{\hat{\theta}}(U(Y_1, \dots, Y_n)) - F_{\hat{\theta}}(L(Y_1, \dots, Y_n)) = 1 - \alpha,$$

với mọi $\alpha \in (0, 1)$.

Xây dựng khoảng tin cậy cho θ

Khoảng tin cậy tiệm cận (asymptotic confidence interval)

Nếu $F_{\hat{\theta}}(u)$ được xác định là phân phối mẫu tiệm cận, thì một khoảng ngẫu nhiên $(L(Y_1, \dots, Y_n), U(Y_1, \dots, Y_n))$ được gọi khoảng tin cậy **tiệm cận** $100 \times (1 - \alpha)\%$ cho θ nếu với mọi $\theta \in \Theta$:

$$\Pr(L(Y_1, \dots, Y_n) \leq \theta \leq U(Y_1, \dots, Y_n)) \rightarrow 1 - \alpha,$$

hay tương đương với

$$F_{\hat{\theta}}(U(Y_1, \dots, Y_n)) - F_{\hat{\theta}}(L(Y_1, \dots, Y_n)) \rightarrow 1 - \alpha,$$

với mọi $\alpha \in (0, 1)$, khi $n \rightarrow +\infty$.

Một cách vắn tắt, ta gọi chúng là khoảng tin cậy $100 \times (1 - \alpha)\%$ cho θ .

Tuy nhiên, trong thực tế

- phân phối mẫu chính xác không thể xác định;
- xấp xỉ phân phối tiệm cận không đủ tốt.

$\Rightarrow$ ta sử dụng phân phối mẫu bootstrap, $\hat{F}_{R,\hat{\theta}}(u)$ thay thế.

$\Rightarrow$ khoảng tin cậy bootstrap.

Khoảng tin cậy bootstrap percentile

Nhắc lại rằng, sau quá trình bootstrap, ta có 1 bộ dữ liệu ước lượng bootstrap: $(\hat{\theta}_1^*, \dots, \hat{\theta}_R^*)$ cho $\hat{\theta}$.

Đặt θ_q^* là phân vị mẫu thứ q của $(\hat{\theta}_1^*, \dots, \hat{\theta}_R^*)$.

Khi đó, theo định nghĩa của phân vị mẫu, ta có

$$\Pr(\theta_{\alpha/2}^* \leq \hat{\theta}^* \leq \theta_{1-\alpha/2}^*) \approx 1 - \alpha.$$

Tuy nhiên, ta mục tiêu là tìm khoảng tin cậy dạng:

$$\Pr(\theta_{\alpha/2}^* \leq \theta \leq \theta_{1-\alpha/2}^*) \approx 1 - \alpha.$$

⇒ cần xây dựng một liên kết tới khoảng phân vị.

Khoảng tin cậy bootstrap percentile

Giả sử rằng ta có một biến đổi đơn điệu tăng $m(\theta)$ của θ .

Đặt $U = \frac{m(\hat{\theta}) - m(\theta)}{\tau}$ sao cho $U \sim \mathcal{N}(0, 1)$, với $\tau > 0$.

Chú ý: ta không giả định rằng ta có dạng tường minh của biến đổi m , ta chỉ cần nó tồn tại.

Khi đó, phân vị mức q của U được xác định bởi $U_q = z_q$, trong đó, z_q là phân vị mức q của phân phối $\mathcal{N}(0, 1)$.

Theo tính chất của phân phối chuẩn, ta có

$$\begin{aligned} 1 - \alpha &= \Pr(U_{\alpha/2} \leq U \leq U_{1-\alpha/2}) \\ &= \Pr\left(z_{\alpha/2} \leq \frac{m(\hat{\theta}) - m(\theta)}{\tau} \leq z_{1-\alpha/2}\right) \\ &= \Pr\left(m(\hat{\theta}) + \tau z_{\alpha/2} \leq m(\theta) \leq m(\hat{\theta}) + \tau z_{1-\alpha/2}\right) \end{aligned}$$

Khoảng tin cậy bootstrap percentile

Theo tính đơn điệu của $m(\cdot)$, ta có

$$1 - \alpha = \Pr \left(m^{-1} \left(m(\hat{\theta}) + \tau z_{\alpha/2} \right) \leq \theta \leq m^{-1} \left(m(\hat{\theta}) + \tau z_{1-\alpha/2} \right) \right)$$

Ta áp dụng biến đổi này cho ước lượng bootstrap: $U_b^* = \frac{m(\hat{\theta}_b^*) - m(\hat{\theta})}{\tau}$.

Với mẫu $(\hat{\theta}_1^*, \dots, \hat{\theta}_R^*)$ ta luôn xác định được phân vị mẫu mức q là θ_q^*

$$\Rightarrow U_q^* = \frac{m(\theta_q^*) - m(\hat{\theta})}{\tau}.$$

Mặt khác, $U_q^* \approx U_q = z_q$. Do đó, ta có

$$m(\theta_q^*) \approx m(\hat{\theta}) + \tau z_q.$$

Khoảng tin cậy bootstrap percentile

Khi này, ta chứng minh được:

$$\begin{aligned}
1 - \alpha &= \Pr \left(m^{-1} \left(m(\hat{\theta}) + \tau z_{\alpha/2} \right) \leq \theta \leq m^{-1} \left(m(\hat{\theta}) + \tau z_{1-\alpha/2} \right) \right) \\
&\approx \Pr \left(m^{-1} \left(m(\theta_{\alpha/2}^*) \right) \leq \theta \leq m^{-1} \left(m(\theta_{1-\alpha/2}^*) \right) \right) \\
&= \Pr \left(\theta_{\alpha/2}^* \leq \theta \leq \theta_{1-\alpha/2}^* \right)
\end{aligned}$$

Từ đây, ta có được khoảng tin cậy $100 \times (1 - \alpha)\%$ cho θ là $(\theta_{\alpha/2}^*, \theta_{1-\alpha/2}^*)$.

Vì θ_p^* là phân vị mẫu thứ p của $(\hat{\theta}_1^*, \dots, \hat{\theta}_R^*)$, nên ta xác định được

- $\theta_{\alpha/2}^* = \hat{\theta}_{\lfloor R \alpha/2 \rfloor}^*$;
- $\theta_{1-\alpha/2}^* = \hat{\theta}_{\lfloor R (1-\alpha/2) \rfloor}^*$.

Như vậy, khoảng tin cậy bootstrap percentile $100 \times (1 - \alpha)\%$ cho θ là

$$(\hat{\theta}_{\lfloor R \alpha/2 \rfloor}^*, \hat{\theta}_{\lfloor R (1-\alpha/2) \rfloor}^*).$$

Khoảng tin cậy bootstrap percentile

Phương pháp khoảng tin cậy bootstrap percentile đơn giản, tuy nhiên, có hai nhược điểm nghiêm trọng:

- không hiệu chỉnh được độ chệch của ước lượng;
- không hiệu chỉnh độ bất đối xứng của phân phối mẫu.

Trong một số trường hợp, nếu

- ước lượng $\hat{\theta}$ là ước lượng bị chệch;
- phân phối bootstrap bị quá lệch

⇒ khoảng tin cậy bootstrap percentile kém chính xác, thiếu tính ổn định.

Khoảng tin cậy bootstrap BC_a

Phương pháp **Accelerated Bias-Corrected Percentile** - BC_a được thiết kế để hiệu chỉnh những thiếu sót của phương pháp khoảng tin cậy bootstrap percentile.

Giả sử rằng ta có một biến đổi đơn điệu tăng $m(\cdot)$. Đặt

$$U = \frac{m(\hat{\theta}) - m(\theta)}{1 + a m(\theta)} + b,$$

với a và b là các hằng số và $1 + a m(\theta) > 0$. Giả sử rằng $U \sim \mathcal{N}(0, 1)$.

Khi $a = b = 0$ (không có sai lệch trong phân phối bootstrap) thì U quay trở lại trường hợp trước đó với $\tau = 1$.

Áp dụng cho mẫu bootstrap, ta có

$$U^* = \frac{m(\hat{\theta}^*) - m(\hat{\theta})}{1 + a m(\hat{\theta})} + b,$$

và $U^* \xrightarrow{d} \mathcal{N}(0, 1)$.

Khoảng tin cậy bootstrap BCa

Do $U^* \xrightarrow{d} \mathcal{N}(0, 1)$, nên ta có

$$\begin{aligned}
1 - \alpha &\approx \Pr(z_{\alpha/2} \leq U^* \leq z_{1-\alpha/2}) \\
&= \Pr\left(z_{\alpha/2} \leq \frac{m(\hat{\theta}^*) - m(\hat{\theta})}{1 + a m(\hat{\theta})} + b \leq z_{1-\alpha/2}\right) \\
&= \Pr\left(m(\hat{\theta}) + [z_{\alpha/2} - b] [1 + a m(\hat{\theta})] \leq m(\hat{\theta}^*)\right. \\
&\quad \left. \leq m(\hat{\theta}) + [z_{1-\alpha/2} - b] [1 + a m(\hat{\theta})]\right) \\
&= \Pr\left(m^{-1}\left(m(\hat{\theta}) + [z_{\alpha/2} - b] [1 + a m(\hat{\theta})]\right) \leq \hat{\theta}^*\right. \\
&\quad \left. \leq m^{-1}\left(m(\hat{\theta}) + [z_{1-\alpha/2} - b] [1 + a m(\hat{\theta})]\right)\right)
\end{aligned}$$

Hơn nữa, với bộ dữ liệu ước lượng bootstrap, ta luôn có

$$\Pr\left(\theta_{\alpha/2}^* \leq \hat{\theta}^* \leq \theta_{1-\alpha/2}^*\right) \approx 1 - \alpha.$$

Khoảng tin cậy bootstrap BCa

Do đó,

$$m^{-1} \left(m(\hat{\theta}) + [z_{\alpha/2} - b] \left[1 + a m(\hat{\theta}) \right] \right) \approx \theta_{\alpha/2}^*,$$

và

$$m^{-1} \left(m(\hat{\theta}) + [z_{1-\alpha/2} - b] \left[1 + a m(\hat{\theta}) \right] \right) \approx \theta_{1-\alpha/2}^*.$$

Kết quả này rất quan trọng vì ta không cần phải xác định $m(\cdot)$, thay vào đó, ta hoàn toàn có thể tính thông qua phân vị mẫu bootstrap.

Khoảng tin cậy bootstrap BCa

Mặt khác, do $U \sim \mathcal{N}(0, 1)$ nên ta cũng có

$$\begin{aligned}
1 - \alpha &= \Pr(z_{\alpha/2} \leq U \leq z_{1-\alpha/2}) \\
&= \Pr\left(z_{\alpha/2} \leq \frac{m(\hat{\theta}) - m(\theta)}{1 + a m(\theta)} + b \leq z_{1-\alpha/2}\right) \\
&= \Pr\left(m(\hat{\theta}) + u(a, b; \alpha/2) [1 + a m(\hat{\theta})] \leq m(\theta)\right. \\
&\quad \left.\leq m(\hat{\theta}) + u(a, b; 1 - \alpha/2) [1 + a m(\hat{\theta})]\right) \\
&= \Pr\left(m^{-1}\left(m(\hat{\theta}) + u(a, b; \alpha/2) [1 + a m(\hat{\theta})]\right) \leq \theta\right. \\
&\quad \left.\leq m^{-1}\left(m(\hat{\theta}) + u(a, b; 1 - \alpha/2) [1 + a m(\hat{\theta})]\right)\right)
\end{aligned}$$

với $u(a, b; \alpha) = \frac{b + z_\alpha}{1 - a(b + z_\alpha)}.$

Khoảng tin cậy bootstrap BCa

Nếu ta có thể tìm được β_1 và β_2 sao cho

$$u(a, b; \alpha/2) = z_{\beta_1} - b, \quad \text{và} \quad u(a, b; 1 - \alpha/2) = z_{\beta_2} - b,$$

thì ta có

$$\begin{aligned} 1 - \alpha &= \Pr \left(m^{-1} \left(m(\hat{\theta}) + (z_{\beta_1} - b) \left[1 + a m(\hat{\theta}) \right] \right) \leq \theta \right. \\ &\quad \left. \leq m^{-1} \left(m(\hat{\theta}) + (z_{\beta_2} - b) \left[1 + a m(\hat{\theta}) \right] \right) \right) \\ &\approx \Pr \left(\theta_{\beta_1}^* \leq \theta \leq \theta_{\beta_2}^* \right). \end{aligned}$$

Như vậy ta có thể sử dụng bộ dữ liệu ước lượng bootstrap để xác định khoảng tin cậy cho θ .

Khoảng tin cậy bootstrap BC_a

Mức phân vị β_1 và β_2 được xác định bởi

$$\beta_1 = \Phi \left(b + \frac{b + z_{\alpha/2}}{1 - a(b + z_{\alpha/2})} \right) \quad \text{và} \quad \beta_2 = \Phi \left(b + \frac{b + z_{1-\alpha/2}}{1 - a(b + z_{1-\alpha/2})} \right),$$

$\Phi(u)$ là hàm phân phối tích lũy của phân phối $\mathcal{N}(0, 1)$, với

$$b = \Phi^{-1} \left(\frac{1}{R} \sum_{b=1}^R \mathbf{I} \left(\hat{\theta}_b^* \leq \hat{\theta} \right) \right)$$

và

$$a = \left[\frac{1}{6} \sum_{i=1}^n \left(\hat{\theta}_{(\cdot)} - \hat{\theta}_{(-i)} \right)^3 \right] \left[\sum_{i=1}^n \left(\hat{\theta}_{(\cdot)} - \hat{\theta}_{(-i)} \right)^2 \right]^{-3/2}$$

trong đó, $\hat{\theta}_{(-i)}$ là ước lượng $\hat{\theta}$ trên tập dữ liệu bỏ đi i , và $\hat{\theta}_{(\cdot)} = \frac{1}{n} \sum_{i=1}^n \hat{\theta}_{(-i)}$.

Như vậy, khoảng tin cậy bootstrap BC_a $100 \times (1 - \alpha)\%$ cho θ là

$$\left(\hat{\theta}_{[R\beta_1]}^*, \hat{\theta}_{[R\beta_2]}^* \right).$$

Khoảng tin cậy bootstrap studentized

Khoảng tin cậy bootstrap studentized dựa trên ý tưởng về thống kê studentized

$$Z = \frac{\bar{Y} - \mu}{(S^2/n)^{1/2}} \sim t_{n-1},$$

với $Y_1, \dots, Y_n \stackrel{i.i.d}{\sim} \mathcal{N}(\mu, \sigma^2)$.

Trong thực tế

- ta không có phân phối chuẩn;
- quan tâm tới một ước lượng bất kỳ $\hat{\theta}$.

Tuy nhiên, ta vẫn có thể sử dụng ý tưởng về thống kê studentized để xây dựng khoảng tin cậy.

Một cách tổng quát hóa, ta có thể viết

$$Z = \frac{\hat{\theta} - \theta}{\sqrt{V(\hat{\theta})}},$$

với $V(\hat{\theta})$ là phương sai của $\hat{\theta}$ được tính từ dữ liệu.

Khoảng tin cậy bootstrap studentized

Đặt $z_{\alpha/2}$ là phân vị của Z (giả sử đã biết), khi đó, theo quy tắc phân vị

$$\Pr(z_{\alpha/2} \leq Z \leq z_{1-\alpha/2}) = \Pr\left(z_{\alpha/2} \leq \frac{\hat{\theta} - \theta}{\sqrt{V(\hat{\theta})}} \leq z_{1-\alpha/2}\right) = 1 - \alpha$$

hay tương đương

$$\Pr\left(\hat{\theta} - \sqrt{V(\hat{\theta})}z_{1-\alpha/2} \leq \theta \leq \hat{\theta} - \sqrt{V(\hat{\theta})}z_{\alpha/2}\right) = 1 - \alpha$$

Như vậy, ta xác định được khoảng tin cậy $100 \times (1 - \alpha)\%$ cho θ là

$$\left(\hat{\theta} - \sqrt{V(\hat{\theta})}z_{1-\alpha/2}, \hat{\theta} - \sqrt{V(\hat{\theta})}z_{\alpha/2}\right).$$

Khoảng tin cậy bootstrap studentized

Do Z là không biết (hoặc chỉ biết 1 giá trị duy nhất), do đó, ta cần sử dụng bootstrap để tạo ra một bộ R ước lượng $Z^* \Rightarrow$ ước tính phân vị mẫu.

Sau quá trình bootstrap, ta có

- $(\hat{\theta}_1^*, \dots, \hat{\theta}_R^*);$
- $(V(\hat{\theta}_1^*), \dots, V(\hat{\theta}_R^*)).$

Từ dữ liệu bootstrap này, ta tính được

$$Z_b^* = \frac{\hat{\theta}_b^* - \hat{\theta}}{\sqrt{V(\hat{\theta}_b^*)}}$$

Với bộ $(Z_1^*, \dots, Z_R^*)$, ta xác định được

- $z_{\alpha/2} = Z_{\lfloor R\alpha/2 \rfloor}^*;$
- $z_{1-\alpha/2} = Z_{\lfloor R(1-\alpha/2) \rfloor}^*.$

Do đó, ta xác định được khoảng tin cậy studentized $100 \times (1 - \alpha)\%$ cho θ là

$$\left(\hat{\theta} - \sqrt{V(\hat{\theta})} Z_{\lfloor R(1-\alpha/2) \rfloor}^*, \hat{\theta} - \sqrt{V(\hat{\theta})} Z_{\lfloor R\alpha/2 \rfloor}^* \right).$$

Khoảng tin cậy bootstrap studentized

Để ước lượng được $V(\hat{\theta}_b^*)$ ta có hai lựa chọn như sau:

- sử dụng công thức tường minh của $V(\hat{\theta})$ cho mẫu bootstrap;

ví dụ: xét $\hat{\theta} = \bar{Y}$, khi đó, ta có $V(\hat{\theta}) = \frac{S^2}{n}$, với S^2 là phương sai mẫu;

áp dụng công thức này vào mẫu bootstrap $Y_{i,b}^*, \dots, Y_{i,b}^*$

$$V(\hat{\theta}_b^*) = \frac{1}{n(n-1)} \sum_{i=1}^n (Y_{i,b}^* - \bar{Y}_b^*)^2$$

- sử dụng một quy trình bootstrap thứ hai:

với mẫu bootstrap $Y_{1,b}^*, \dots, Y_{n,b}^*$

⇒ tạo một mẫu bootstrap $Y_{1,b,j}^{**}, \dots, Y_{n,b,j}^{**}$, với $j = 1, \dots, R'$ lần lặp

⇒ ước lượng $\hat{\theta}_{n,b,j}^{**}$


$$V(\hat{\theta}_b^*) = \frac{1}{R-1} \sum_{j=1}^{R'} \left(\hat{\theta}_{b,j}^{**} - \bar{\theta}_b^{**} \right)^2,$$

với $\bar{\theta}_b^{**}$ là trung bình của bộ ước lượng bootstrap $(\hat{\theta}_{b,1}^{**}, \dots, \hat{\theta}_{b,R'}^{**})$.

Ví dụ: Khoảng tin cậy cho hệ số tương quan

Ví dụ: hệ số tương quan tuyến tính Pearson:

$$\hat{r}_n = \frac{1}{n-1} \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{S_X} \right) \left(\frac{Y_i - \bar{Y}}{S_Y} \right).$$



Ví dụ: Khoảng tin cậy cho hệ số tương quan

Nhận xét:

- phân phối mẫu của $\hat{r}_n$ không xấp xỉ một phân phối chuẩn;
- khi r gần ± 1 , thì phân phối của $\hat{r}_n$ bị lệch (không đối xứng).

Quy trình bootstrap cho ước lượng hệ số tương quan

Cho bộ dữ liệu ngẫu nhiên $(X_1, Y_1), \dots, (X_n, Y_n)$ của biến hai ngẫu nhiên X và Y .

1. Tạo một mẫu ngẫu nhiên cỡ n (cùng với cỡ của dữ liệu gốc) từ dữ liệu gốc, có lặp lại (with replacement): $(X_1^*, Y_1^*), \dots, (X_n^*, Y_n^*)$.
2. Tính hệ số tương quan Pearson $\hat{r}_n^*$ dựa trên mẫu vừa tạo.
3. Lặp lại bước 1 và 2 trong R lần (ít nhất 1,000 lần), và lưu kết quả lại.

Ví dụ: Khoảng tin cậy cho hệ số tương quan


Ví dụ: ta xét dữ liệu về nghiên cứu về mối liên hệ giữa khiếm khuyết gen và tay thuận của một người:

id	dnan	hand
1	13	1
2	18	1
3	20	3
4	21	1
⋮	⋮	⋮
36	41	4
37	44	8

- tổng cộng 37 quan sát là các bà mẹ có con trai bị chậm phát triển trí tuệ do thừa hưởng nhiễm sắc thể X khiếm khuyết;
- `dnan` thể hiện chỉ số khiếm khuyết DNA;
- `hand` thể hiện chỉ số khuynh hướng sử dụng tay trái hoặc phải cho các công việc khác nhau, gần 1 tương ứng tay phải, gần 8 tương ứng tay trái.

Giả thuyết: các giá trị lớn của `dnan` có thể liên quan đến khuynh hướng sử dụng tay trái.


Ví dụ: Khoảng tin cậy cho hệ số tương quan



Hệ số tương quan tuyến tính (Pearson), $\hat{r} = 0.509$.

Ví dụ: Khoảng tin cậy cho hệ số tương quan

Phân phối bootstrap sau 5,000 lần lặp



Khoảng tin cậy bootstrap percentile 95% cho hệ số tương quan giữa khiếm khuyết gen và khuynh hướng thuận tay trái là $(-0.0012, 0.7564)$.

Ví dụ: Khoảng tin cậy cho hệ số tương quan

Áp dụng phương pháp BC_a , ta xác định lần lượt:

- tham số $b = 0.00902$;
- tham số $a = 0.12579$;
- $\beta_1 = 0.05968$;
- $\beta_2 = 0.99568$.

Theo đó, khoảng tin cậy BC_a 95% cho hệ số tương quan giữa khiếm khuyết gen và khuynh hướng thuận tay trái là $(0.1087, 0.8206)$.

Ví dụ: Khoảng tin cậy cho hệ số tương quan

Áp dụng quy trình trên cho dữ liệu về kiểm khuyết gen và khuynh hướng sử dụng tay trái.

- số lần lặp bootstrap $B = 5000$ lần;
- số lần lặp bootstrap cho phương sai $V(\hat{r}_b^*)$, $R = 200$;
- $\hat{r} = 0.509$;
- $\sqrt{V(\hat{r})} = \text{se}_{\text{boot}} = 0.2007$;
- $z_{0.05/2} = -3.476$;
- $z_{1-0.05/2} = 2.152$;

suy ra, khoảng tin cậy studentized 95% cho r là

$$(0.509 - 0.2007 \times 2.152, 0.509 - 0.2007 \times (-3.476)) = (0.0771, 1.2066)$$

$$\Rightarrow \text{ta cần sử dụng biến đổi Fisher } u = \frac{1}{2} \log \left(\frac{1+r}{1-r} \right).$$