

Bài giảng 5: Regression và Prediction - II

TS. Tô Đức Khánh

Khoa Toán-Tin Học, Trường Đại Học Khoa Học Tự Nhiên
Đại Học Quốc Gia Tp. HCM

Học phần: Xử lý Số liệu Thống kê

Nội dung buổi học

1 Chuẩn đoán mô hình

2 Lựa chọn mô hình

3 Mở rộng mô hình

4 Generalized Linear Models

1 Chuẩn đoán mô hình



2 Lựa chọn mô hình

3 Mở rộng mô hình

4 Generalized Linear Models

Kiểm tra tính tuyến tính


- Để kiểm tra sự quan hệ tuyến tính giữa Y và các biến hồi quy $X_1, X_2, \dots, X_p$ (giả định A1), ta sử dụng biểu đồ **Residuals vs Fitted**.
- Nếu phần dư được phân bố ngẫu nhiên (khá đối xứng) xung quanh đường nằm ngang tương ứng với phần thặng dư $= 0$.
 ↪ giả định được thỏa mãn. (xem Hình a)
- Sự hiện diện của một xu hướng nào đó (một loại độ cong nào đó) có thể chỉ ra vấn đề với một số khía cạnh của mô hình tuyến tính.
 ↪ giả định không được thỏa mãn. (xem Hình b)



Kiểm tra tính tuyến tính

Xét biểu đồ **Residuals vs Fitted** của mô hình hồi quy tuyến tính:

$$\text{sales} = \beta_0 + \beta_1 \text{tv} + \varepsilon.$$




Hình vẽ không cho thấy xu hướng đường cong nào đáng kể.

↪ Giả định về tính tuyến tính của mô hình là phù hợp.

Kiểm tra tính tuyến tính

Xét biểu đồ **Residuals vs Fitted** của mô hình hồi quy tuyến tính:

$$\text{sales} = \beta_0 + \beta_1 \text{tv} + \beta_2 \text{radio} + \beta_3 \text{newspaper} + \varepsilon.$$




Hình vẽ cho thấy một xu hướng đường cong rõ ràng.

↪ Giả định về tính tuyến tính của mô hình là không phù hợp.

Kiểm tra tính tuyến tính

Xét biểu đồ **Residuals vs Fitted** của mô hình hồi quy tuyến tính:

$$\text{sales} = \beta_0 + \beta_1 \text{tv} + \beta_2 \text{radio} + \beta_3 \text{tv}:\text{radio} + \varepsilon.$$



Hình vẽ cho thấy một xu hướng đường cong tương đối.

↪ Giả định về tính tuyến tính của mô hình là không phù hợp.

Sự tuyến tính từng phần


Xét mô hình hồi quy tuyến tính:

$$\text{sales} = \beta_0 + \beta_1 \text{tv} + \beta_2 \text{radio} + \beta_3 \text{newspaper} + \varepsilon.$$

Ta xét ba biểu đồ thẳng dư từng phần cho:

- tv
- radio
- newspaper


Sự tuyến tính từng phần



Kết quả cho thấy


- đường thẳng tuyến tính (màu xanh dương) ước lượng không khớp với dữ liệu. Underestimate trong khoảng từ 80 tới 200;
- đường cong nét đứt (màu xanh lá) cho thấy xu hướng mối quan hệ phi tuyến tính của tv và sales.

Sự tuyến tính từng phần



Kết quả cho thấy đường thẳng tuyến tính (màu xanh dương) ước lượng tương đối khớp với dữ liệu.



Sự tuyến tính từng phần



Kết quả cho thấy không có quan hệ tuyến tính giữa sales và newspaper trong mô hình.

Kiểm tra đồng nhất phương sai - Homoskedasticity

- Để kiểm tra giả định đồng nhất phương sai - Homoskedasticity, ta sử dụng biểu đồ **Residuals vs Fitted** hoặc **Scale-Location**.
- Đối với biểu đồ **Residuals vs Fitted**, nếu độ biến thiên của phần thặng dư thay đổi từ trái sang phải, như thế này:




thì điều kiện Homoskedasticity bị vi phạm, khi đó ta nói thặng dư của mô hình bị **heteroskedasticity**.

Kiểm tra đồng nhất phương sai - Homoskedasticity

Xét biểu đồ **Residuals vs Fitted** của mô hình

$$\text{sales} = \beta_0 + \beta_1 \text{tv} + \varepsilon.$$





Các điểm thặng dư tăng theo giá trị ước lượng của biến đáp ứng, cho thấy phương sai không cố định trong các phần thặng dư (hoặc phương sai thay đổi - heteroscedasticity).

Kiểm tra đồng nhất phương sai - Homoskedasticity

Xét biểu đồ **Residuals vs Fitted** và **Scale-Location** của mô hình hồi quy tuyến tính:

$$\text{sales} = \beta_0 + \beta_1 \text{tv} + \beta_2 \text{radio} + \beta_3 \text{newspaper} + \varepsilon.$$



Nhìn vào hình thứ hai, có thể thấy xu hướng của dữ liệu không xấp xỉ đường thẳng 1, ám chỉ phương sai thặng dư là không đồng nhất.

Tính độc lập của thặng dư

Khi tính độc lập của thặng dư không được thỏa mãn, thì

- mô hình được xây dựng là không phù hợp với dữ liệu,
- ước lượng của hệ số không đảm bảo tính vững,
- các kết quả thống kê suy luận không còn chính xác.


Điều kiện này thường sai khi dữ liệu được thu thập theo thời gian:

- thời gian máy bay khởi hành trễ theo các ngày trong năm;
- số lượng sinh viên theo năm học;
- doanh số bán hàng theo tháng.

Tính độc lập của thặng dư


Sự khác biệt của thặng dư trong các tình huống

- độc lập ($\rho = 0$),
- có tương quan ($\rho = 0.5$ và $\rho = 0.8$).



Tính độc lập của thặng dư

Trong thực nghiệm, ta có thể dùng đồ thị Auto Correlation Function (ACF) của các thặng dư để kiểm tra sự tương quan giữa các thặng dư (có ý nghĩa hay không):




Đồ thị trên cho thấy sự tương quan giữa các thặng dư là có ý nghĩa.

Tính độc lập của thặng dư

Đồ thị Auto Correlation Function (ACF) cho thặng dư của mô hình

$$\text{sales} = \beta_0 + \beta_1 \text{tv} + \beta_2 \text{radio} + \beta_3 \text{newspaper} + \varepsilon.$$



Kết quả cho thấy sự độc lập của các thặng dư.

Phát hiện giá trị ngoại lai

Một độ đo khác là khoảng cách Cook (Cook's distance), có thể dùng để xác định điểm ngoại lai trong mô hình tuyến tính:

$$D_i = r_i^2 \frac{h_{ii}}{p(1 - h_{ii})},$$

trong đó,

- p là số hệ số trong mô hình,
- r_i là thặng dư được chuẩn hóa,
- h_{ii} là giá trị leverage.

Những quan sát có giá trị khoảng cách Cook, D_i , lớn (thường là lớn hơn 0.5 - 1), tương ứng với trường hợp cả r_i và h_{ii} là lớn.

⇒ những quan sát đó là các điểm ngoại lai (có ảnh hưởng lớn) trong mô hình.

⇒ kết quả hồi quy sẽ bị thay đổi nếu chúng ta loại trừ những quan sát này.

Ta có thể tích hợp khoảng cách Cook vào trong biểu đồ [Residuals vs Leverage](#), trong đó, khoảng cách Cook biểu thị kích cỡ của các điểm quan sát:


- điểm có kích cỡ nhỏ tương ứng khoảng cách Cook nhỏ;
- điểm có kích cỡ lớn tương ứng khoảng cách Cook lớn.

Phát hiện giá trị ngoại lai

Với mô hình

$$\text{sales} = \beta_0 + \beta_1 \text{tv} + \beta_2 \text{radio} + \beta_3 \text{newspaper} + \varepsilon.$$

biểu đồ Residuals vs Leverage:



Multicollinearity - Đa cộng tuyến


Ví dụ: Xét mô hình

$$\text{balance} = \beta_0 + \beta_1 \text{rating} + \beta_2 \text{limit} + \varepsilon,$$

trong đó,

- balance: số tiền cân bằng trong tài khoản;
- rating: xếp hạng tín dụng;
- limit: giới hạn tín dụng.

Biểu đồ phân tán của rating và limit cho thấy sự tương quan gần như hoàn hảo.



⇒ chắc chắn có hiện tượng multicollinearity trong mô hình.

1 Chuẩn đoán mô hình

2 Lựa chọn mô hình

3 Mở rộng mô hình

4 Generalized Linear Models

Mô hình tốt?

Trong phần “Đánh giá mô hình”, ta đã biết rằng, một mô hình có

- RMSE nhỏ, hoặc
- RSE nhỏ, hoặc
- R^2 hoặc R_a^2 lớn, hoặc
- cross-validation error nhỏ,

sẽ là một mô hình tốt.

Tuy nhiên, khi ta thêm biến vào mô hình hồi quy

- RMSE và RSE sẽ luôn giảm (tối thiểu 0);
- R^2 luôn tăng (tối đa 1).

↪ không thực tế nếu dùng các chỉ số này để so sánh các mô hình có số lượng biến khác nhau.

Mô hình tốt?

Để so sánh các mô hình với số lượng biến khác nhau, ta dùng các chỉ số sau.

- AIC (Akaike's Information Criteria)¹ cho mô hình hồi quy tuyến tính:

$$\text{AIC} = 2p + n \log \left(\frac{\text{RSS}}{n} \right).$$

AIC được xây dựng dựa trên lý thuyết likelihood và giả định phân phối chuẩn.

- BIC (Bayesian Information Criteria) cho mô hình hồi quy tuyến tính:

$$\text{BIC} = p \log(n) + n \log \left(\frac{\text{RSS}}{n} \right).$$

BIC được xây dựng dựa trên lý thuyết likelihood, thống kê Bayes và giả định phân phối chuẩn.


- Mallows's C_p cho mô hình hồi quy tuyến tính

$$C_p = \frac{1}{n} (\text{RSS} + 2p\hat{\sigma}^2).$$

- Adjusted R-squares R_a^2 .

¹do nhà thống kê học Hirotugu Akaike, người Nhật Bản, đề xuất vào thập niên 70

Mô hình tốt?




Hình trên, minh họa giá trị của C_p , BIC và R_a^2 trong việc lựa chọn mô hình hồi quy với số lượng biến hồi quy thay đổi (từ 1 tới 11).

- Tiêu chuẩn C_p cho kết quả là mô hình với 6 biến hồi quy.
- Tiêu chuẩn BIC cho kết quả là mô hình với 4 biến hồi quy.
- Tiêu chuẩn R_a^2 cho kết quả là mô hình với 7 biến hồi quy.

Quy tắc: Khi hiệu suất, sai số của các mô hình là tương đương nhau, thì mô hình đơn giản hơn là mô hình được ưu tiên.

Mô hình tốt?

Ngoài các tiêu chí trên, ta có thể sử dụng validation set hoặc cross-validation để tìm mô hình hồi quy với số biến q ($q < p$), sao cho sai số kiểm tra là nhỏ nhất.



Stepwise regression

Hồi quy lùi từng bước - Backward stepwise regression

1. Bắt đầu với mô hình $\mathcal{M}_p$, chứa tất cả các biến hồi quy:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$$

2. Với $k = p, p - 1, \dots, 1$:

(a) Xem xét tất cả k mô hình chứa tất cả ngoại trừ một trong các yếu tố dự đoán trong $\mathcal{M}_k$, để có tổng số $k - 1$ yếu tố dự đoán.

(b) Chọn mô hình tốt nhất trong số k mô hình này và gọi nó là $\mathcal{M}_{k-1}$. Ở đây mô hình “tốt nhất” được xác định là mô hình có RSS nhỏ nhất hoặc R^2 cao nhất.

3. Chọn một mô hình tốt nhất trong số $\mathcal{M}_0, \mathcal{M}_1, \dots, \mathcal{M}_p$ bằng cách sử dụng C_p , AIC, BIC, R_a^2 hoặc cross-validation.

Phương pháp co hệ số - Shrinkage methods

Xét mô hình hồi quy:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$$

Một cách tiếp cận khác cho việc lựa chọn biến hồi quy, là ước lượng hệ số của mô hình với một ràng buộc sao cho các hệ số không cần thiết sẽ “co lại” về 0.


- Ridge regression

$$\hat{\beta}_R = \arg \min \sum_{i=1}^n \left(Y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ji} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

- Lasso regression

$$\hat{\beta}_L = \arg \min \sum_{i=1}^n \left(Y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ji} \right)^2 + \lambda \sum_{j=1}^p |\beta_j|$$

Phương pháp co hệ số - Shrinkage methods



Sự thay đổi của hệ số ước lượng tương ứng với giá trị λ của ridge regression.

Hồi quy đa thức

Trong các phần trước, ta đã giới thiệu mô hình hồi quy tuyến tính:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon.$$

Thuật ngữ “tuyến tính” ám chỉ sự tuyến tính theo hệ số β_j .

Do đó, X_j có thể được sử dụng dưới dạng một biến đổi: bình phương, log, căn bậc hai.

Đặc biệt, nếu ta sử dụng một đa thức bậc k của X_j , thì khi đó, ta có mô hình hồi quy đa thức (polynomial regression).

Ví dụ: với $k = 2$,

$$Y = \beta_0 + \alpha_1 X_1 + \alpha_2 X_1^2 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon.$$


Hồi quy đa thức thường được dùng trong các trường hợp mà mối quan hệ giữa Y và X_j là phi tuyến.

Hồi quy đa thức

Ví dụ: Trong mô hình tuyến tính:

$$\text{sales} = \beta_0 + \beta_1 \text{tv} + \beta_2 \text{radio} + \beta_3 \text{newspaper} + \varepsilon.$$


thông qua biểu đồ thặng dư từng phần cho biến tv , ước lượng tuyến tính là không phù hợp với dữ liệu



Hồi quy đa thức

Thay vì sử dụng tv , ta sẽ áp dụng dạng đa thức bậc k cho tv . Ta chọn $k = 2$

$$\text{sales} = \beta_0 + \alpha_1 tv + \alpha_2 tv^2 + \beta_2 \text{radio} + \beta_3 \text{newspaper} + \varepsilon.$$




Biểu đồ thặng dư từng phần cho thấy mô hình đã được cải thiện đáng kể.

Hồi quy đa thức

Ta chọn $k = 3$

$$\text{sales} = \beta_0 + \alpha_1 \text{tv} + \alpha_2 \text{tv}^2 + \alpha_3 \text{tv}^3 + \beta_2 \text{radio} + \beta_3 \text{newspaper} + \varepsilon.$$



Biểu đồ thặng dư từng phần cho thấy mô hình đã được cải thiện đáng kể hơn $k = 2$.

Hồi quy đa thức


Như vậy, để áp dụng hồi quy đa thức:

- Xây dựng mô hình hồi quy tuyến tính (không đa thức).
- Kiểm tra mối quan hệ giữa Y và X_j thông qua biểu đồ thặng dư từng phần.
- Nếu mỗi quan hệ giữa Y và X_j (cố định j) không phải là tuyến tính thì ta có sử dụng dạng đa thức bậc k của X_j để cải thiện mô hình.
- Để tìm k tối ưu, ta có thể áp dụng thuật toán cross-validation.
- Điểm hạn chế của hồi quy đa thức, đó là ta không thể làm một cách tự động.
- Mô hình có thể trở nên chồng kênh, với k lớn.

Hồi quy đa thức từng phần


Ví dụ: Xét mô hình dự đoán tiền công của công nhân làm việc ở khu vực Mid-Atlantic, theo độ tuổi.

$$\text{wage} = \begin{cases} \beta_{01} + \beta_{11}\text{age} + \beta_{21}\text{age}^2 + \beta_{31}\text{age}^3 + \varepsilon, & \text{nếu } \text{age} \leq 50 \\ \beta_{02} + \beta_{12}\text{age} + \beta_{22}\text{age}^2 + \beta_{32}\text{age}^3 + \varepsilon, & \text{nếu } \text{age} > 50 \end{cases}$$



Hồi quy splines


Splines là những dải linh hoạt (gỗ hoặc cao su) được sử dụng để vẽ các đường cong.



Hồi quy splines

Ta áp dụng B-spline cho mô hình dựa đoán tiền công của công nhân dựa vào tuổi của họ:

- $r = 3$
- $k = 3$
- ξ_j là các điểm tương ứng với phân vị mức 0.25, 0.5 và 0.75 của age.




Hồi quy splines

Ví dụ: xét lại mô hình dự đoán doanh số bán hàng, với thành phần B-spline:

$$\text{sales} = \beta_0 + \text{bs}(\text{tv}, 3) + \beta_2 \text{radio} + \beta_3 \text{newspaper} + \varepsilon.$$

với $\text{bs}(\text{tv}, 3)$ là thành phần được xác định bởi B-spline bậc 3.




Đường màu xanh dương tương ứng với ước lượng dựa trên B-spline bậc 3, đường nét đứt là đường ước lượng tuyến tính (mô hình ban đầu).

Generalized Additive Models

Ví dụ: xét lại mô hình dự đoán doanh số bán hàng, với thành phần $f(\text{tv})$:

$$\text{sales} = \beta_0 + f(\text{tv}) + \beta_2 \text{radio} + \beta_3 \text{newspaper} + \varepsilon.$$




Đường màu xanh dương tương ứng với ước lượng dựa trên $f(\text{tv})$, đường nét đứt là đường ước lượng tuyến tính (mô hình ban đầu).

Generalized Additive Models

Ví dụ: xét mô hình GAM dự đoán doanh số bán hàng:

$$\text{sales} = \beta_0 + f_1(\text{tv}) + f_2(\text{radio}) + f_3(\text{newspaper}) + \varepsilon.$$



Chú ý: ta có thể thêm thành phần tương tác vào mô hình GAM, ví dụ

$$\text{sales} = \beta_0 + f_1(\text{tv}) + f_2(\text{radio}) + f_3(\text{tv}, \text{radio}) + \varepsilon.$$

1 *Chuẩn đoán mô hình*

2 *Lựa chọn mô hình*

3 *Mở rộng mô hình*

4 *Generalized Linear Models*

Vấn đề của Linear Models

Mô hình tuyến tính (Linear Models) không hiệu quả trong các trường hợp:

- biến phản hồi không liên tục: nhị thức, số đếm, dạng định tính;
- biến phản hồi có phân phối bất đối xứng: lệch phải, có nhiều giá trị lớn (extreme values);
- phương sai của biến phản hồi trong mô hình không phải hằng số (đồng nhất phương sai - homoskedasticity).

Mô hình tuyến tính tổng quát (Generalized Linear Models - GLM) là sự tổng quát mô hình tuyến tính để tương thích với các dạng dữ liệu:

- biến phản hồi có dạng: nhị thức, số đếm, dạng định tính;
- biến phản hồi có phân phối bất đối xứng: lệch phải, có nhiều giá trị lớn (extreme values);
- phương sai của biến phản hồi trong mô hình thay đổi theo giá trị trung bình.

Cấu trúc của Generalized Linear Models

GLM có ba thành phần chính:

- **biến phản hồi:** thành phần này chỉ định biến phản hồi Y và phân phối xác suất của nó. Bộ n quan sát $(y_1, \dots, y_n)$ của Y được coi là quan sát thực tế của các biến ngẫu nhiên độc lập.
- **biến giải thích:** thành phần này chỉ định p biến giải thích cho một *linear predictor*, $\beta_0 + \beta_1 X_{1i} + \dots + \beta_p X_{pi}$, trong đó X_{ji} là giá trị của biến giải thích j cho quan sát thứ i .
- **hàm liên kết:** thành phần này là một hàm g được áp dụng cho kỳ vọng có điều kiện $\mu_i = \mathbb{E}(Y_i | X_{1i} = x_{1i}, \dots, X_{pi} = x_{pi})$ của p biến phản hồi tại các giá trị biến giải thích $(x_{1i}, \dots, x_{pi})$, liên hệ nó với *linear predictor*,

$$g(\mu_i) = \beta_0 + \beta_1 X_{1i} + \dots + \beta_p X_{pi} \equiv \eta_i.$$

Hàm $g(\cdot)$ là hàm đơn điệu, 1-1, khả vi, và do đó



$$\mu_i = g^{-1}(\beta_0 + \beta_1 X_{1i} + \dots + \beta_p X_{pi}) \equiv g^{-1}(\eta_i).$$

Nếu $g(\mu_i) = \mu_i$, thì ta có hàm liên kết đồng nhất (*identity link function*).

GLM cho dữ liệu nhị phân

Xét mô hình

$$\log\left(\frac{\pi_i}{1 - \pi_i}\right) = \beta_0 + \beta_1 X_i$$



Đường cong hồi quy logistic với một biến giải thích định lượng duy nhất là đường đơn điệu tăng hoặc đơn điệu giảm theo dấu của β_1 .

GLM cho dữ liệu nhị phân - Ví dụ

Xét dữ liệu Default về tình trạng tín dụng của 10,000 khách hàng

	default	student	balance	income
1	No	No	729.52650	44361.625
2	No	Yes	817.18041	12106.135
3	No	No	1073.54916	31767.139
4	No	No	529.25060	35704.494
5	No	No	785.65588	38463.496
6	No	Yes	919.58853	7491.559
7	No	No	825.51333	24905.227
8	No	Yes	808.66750	17600.451
9	No	No	1161.05785	37468.529
10	No	No	0.00000	29275.268

- default: tình trạng vỡ nợ tín dụng (Yes/No);
- student: khách hàng là sinh viên (Yes/No);
- balance: số dư trung bình mà khách hàng còn lại trên thẻ tín dụng sau khi thực hiện thanh toán hàng tháng;
- income: thu nhập của khách hàng.

GLM cho dữ liệu nhị phân - Ví dụ

Dự đoán

Sử dụng kết quả ước lượng mô hình, ta có thể dự đoán xác suất vỡ nợ:

- người dùng là sinh viên, $\text{balance} = 1,500\$$ và $\text{income} = 40,000\$$:

$$\begin{aligned}\widehat{\text{Pr}}(\text{default} = 1) &= \frac{\exp(-10.8691 + 0.0057 \times 1500 - 0.6467 \times 1 + 0.0303 \times 10^{-4} \times 40000)}{1 + \exp(-10.8691 + 0.0057 \times 1500 - 0.6467 \times 1 + 0.0303 \times 10^{-4} \times 40000)} \\ &= 0.0579\end{aligned}$$

- người dùng là phải sinh viên, $\text{balance} = 1,500\$$ và $\text{income} = 40,000\$$:

$$\begin{aligned}\widehat{\text{Pr}}(\text{default} = 1) &= \frac{\exp(-10.8691 + 0.0057 \times 1500 - 0.6467 \times 0 + 0.0303 \times 10^{-4} \times 40000)}{1 + \exp(-10.8691 + 0.0057 \times 1500 - 0.6467 \times 0 + 0.0303 \times 10^{-4} \times 40000)} \\ &= 0.1050\end{aligned}$$

GLM cho dữ liệu nhị phân - Áp dụng

GLM cho dữ liệu nhị phân nói chung hay mô hình logistic nói riêng thường được áp dụng trong:

- dự đoán khả năng xảy ra 1 sự kiện, ví dụ: vỡ nợ, giao dịch thành công, có việc/thất nghiệp, sử dụng mạng xã hội (có/không);
- xử lý dữ liệu cho nhiệm vụ xây dựng mô hình credit scoring trong lĩnh vực tài chính;
- xử lý dữ liệu cho nhiệm vụ phân loại hai danh mục đối tượng;
- xử lý dữ liệu số lần sự kiện “thành công” trên tổng số m lần quan sát, ví dụ: số côn trùng chết trong tổng số côn trùng bị phun thuốc diệt côn trùng (dữ liệu dose-response).

GLM cho dữ liệu nhị phân - Vấn đề overdispersion/underdispersion

Đối với mô hình Logistic, tham số phân tán, ϕ , là bằng 1 theo lý thuyết.

$$\Rightarrow \text{Var}(Y) = \mu(1 - \mu).$$

Tuy nhiên, với dữ liệu thực tế, ước lượng $\hat{\phi}$ của ϕ được xác định bởi

$$\hat{\phi} = \frac{1}{n - p - 1} \sum_{i=1}^n \frac{(Y_i - \hat{\mu}_i)^2}{\hat{\mu}_i(1 - \hat{\mu}_i)}$$

có thể khác 1. Cụ thể,

- $\hat{\phi} > 1$, khi đó ta nói dữ liệu quá phân tán - **overdispersion**, so với mô hình Logistic;
- $\hat{\phi} < 1$, khi đó ta nói dữ liệu phân tán thấp - **underdispersion**, so với mô hình Logistic.

Ví dụ, với mô hình Logistic cho dữ liệu default.

Ta tính được $\hat{\phi} = 0.7007$, nhỏ hơn 1 đáng kể.

$\Rightarrow$ mô hình đang bị vấn đề underdispersion.

GLM cho dữ liệu nhị phân - Vấn đề *overdispersion/underdispersion*

Overdispersion hoặc underdispersion làm giảm độ chính xác trong ước lượng sai số chuẩn của hệ số, $SE(\hat{\beta}_j)$.

Cụ thể

- overdispersion $\Rightarrow SE(\hat{\beta})$ bị ước lượng thấp (underestimated);
- underdispersion $\Rightarrow SE(\hat{\beta})$ bị ước lượng cao (overestimated).

Điều này sẽ ảnh hưởng tới kết quả của kiểm định giả thuyết $H_0 : \beta_j = 0$.

Phương án xử lý

Để xử lý vấn đề overdispersion/underdispersion, ta có thể dùng 1 trong các cách sau:

- sử dụng ước lượng $\hat{\phi}$ trong tính toán $SE(\hat{\beta})$, thay vì dùng 1 (giá trị lý thuyết);
- sử dụng mô hình quasi-binomial.

GLM cho dữ liệu đếm

Biến phản hồi dạng số đếm

Xét biến định lượng Y miêu tả số lần một sự kiện A xuất hiện ngẫu nhiên trong

- một khung thời gian;
- một địa điểm/khu vực;
- một nhóm quần thể đối tượng;

với một tỷ lệ cụ thể.

Khi đó, Y cho kết quả là số đếm: 0, 1, 2, 3, ...

Ví dụ:

- Y là lượng thuê xe đạp trong 24h (1 ngày) tại một thành phố;
- Y là số lượng loài cây trong một hòn đảo;
- Y là số lượng khách hàng mua sản phẩm tại một cửa hàng trong một ngày;
- Y là số lượng người bị chết vì một căn bệnh tại một thành phố trong 1 năm.

GLM cho dữ liệu đếm

Giả sử ta có bộ dữ liệu ngẫu nhiên $(Y_i, X_{1i}, X_{2i}, \dots, X_{qi})$, với $i = 1, \dots, n$:

- các quan sát thứ i là độc lập;
- Y_i là biến phản hồi dạng số đếm, nhận giá trị $0, 1, 2, \dots$;
- $X_{1i}, \dots, X_{qi}$ là các biến giải thích có thể liên quan tới Y_i .

Do Y_i có dạng số đếm $\Rightarrow$ ta có thể dùng phân phối Poisson để mô hình hóa.

Khi đó, $Y_i \sim \mathcal{P}(\lambda_i)$, $\lambda_i > 0$, và $\mathbb{E}(Y_i) = \mathbb{V}\text{ar}(Y_i) = \lambda_i$.

Mô hình tiên đoán trung bình của Y_i khi biết $X_{1i}, X_{2i}, \dots, X_{qi}$:

$$\mathbb{E}(Y_i | X_{1i}, X_{2i}, \dots, X_{qi}) = \exp(\beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi}),$$

được gọi là mô hình **Poisson log-linear**. Mô hình này tương đương với,

$$\log(\mu_i) = \beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi},$$

với $\mu_i = \mathbb{E}(Y_i | X_{1i}, X_{2i}, \dots, X_{qi})$.

GLM cho dữ liệu đếm

Trong một số trường hợp, giá trị đếm Y_i là tỷ lệ với một chỉ số t_i , với

- t_i là một lượng thời gian;
- t_i là kích cỡ quần thể;
- t_i là diện tích một khu vực không gian.

Khi đó, tỷ lệ mẫu Y_i/t_i tương ứng với kỳ vọng λ_i/t_i . Điều này dẫn tới mô hình

$$\log\left(\frac{\mu_i}{t_i}\right) = \beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi},$$

hay tương đương,

$$\log(\mu_i) = \log(t_i) + \beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi},$$

thành phần $\log(t_i)$ được gọi là **offset**.

Mean-variance relationship

Theo tính chất của phân phối Poisson,

$$\mu_i = \mathbb{E}(Y_i | X_{1i}, X_{2i}, \dots, X_{qi}) = \text{Var}(Y_i | X_{1i}, X_{2i}, \dots, X_{qi})$$

$\Rightarrow$ mô hình Poisson log-linear có khả năng xử lý vấn đề trung bình và phương sai có liên hệ nhau (1 trường hợp của phương sai không đồng nhất).


GLM cho dữ liệu đếm - Ví dụ

Ta xét dữ liệu Bikeshare cung cấp số lượng xe đạp cho thuê theo giờ và theo ngày trong giai đoạn 2011 và 2012 trong hệ thống Capital Bikeshare (Mỹ) cùng thông tin thời tiết và theo mùa tương ứng.

	bikers	season	mnth	day	hr	holiday	weekday
1	16	1	Jan	1	0	0	6
2	40	1	Jan	1	1	0	6
3	32	1	Jan	1	2	0	6
4	13	1	Jan	1	3	0	6
5	1	1	Jan	1	4	0	6
6	1	1	Jan	1	5	0	6
7	2	1	Jan	1	6	0	6
8	3	1	Jan	1	7	0	6
9	8	1	Jan	1	8	0	6
10	14	1	Jan	1	9	0	6


bikers là số xe đạp được cho thuê trong 1 ngày tương ứng theo giờ.

GLM cho dữ liệu đếm - Ví dụ



⇒ số lượng xe thuê thay đổi theo giờ và là có giá trị: 0, 1, 2,

GLM cho dữ liệu đếm - Ví dụ




Trung bình và Độ lệch chuẩn của bikers theo giờ có liên hệ với nhau.

⇒ mean-variance relationship.

GLM cho dữ liệu đếm - Ví dụ

Kết quả phân tích thặng dư




cho thấy

- cấu trúc tuyến tính là không hợp lý;
- phương sai không đồng nhất.

GLM cho dữ liệu đếm - Ví dụ



Mặt khác,



kết quả tiên đoán cho thấy:

- sai lệch nhiều với dữ liệu bikers;
- giá trị tiên đoán bị âm, khoảng 9.63%.


GLM cho dữ liệu đếm - Ví dụ



Ta có một số nhận xét:

- giá trị âm ở các tháng 1, 2, 3, 4 phản ánh lượng thuê xe thấp ở mùa đông;
- lượng thuê xe tăng cao từ mùa xuân tới mùa thu;
- lượng thuê xe giảm vào các khung giờ khuya, và tăng lại từ 7h sáng.

GLM cho dữ liệu đếm - Ví dụ



Kết quả tiên đoán cho thấy:


- so sánh được với dữ liệu bikers;
- giá trị tiên đoán không bị âm.

GLM cho dữ liệu đếm - Vấn đề overdispersion/underdispersion

Chẳng hạn với mô hình Poisson cho dữ liệu bikers.

Ta tính được $\hat{\phi} = 25.59892$, lớn hơn 1 rất nhiều.

Biểu đồ so sánh giữa $\hat{\mu}_i$ và $(Y_i - \hat{\mu}_i)^2$ dưới đây,




cho thấy vấn đề overdispersion là rất trầm trọng.

GLM cho dữ liệu lệch phải

Trong một số dữ liệu, biến phản hồi Y có thiên hướng bị lệch phải.

Ví dụ giá bán nhà




GLM cho dữ liệu lệch phải

Trong trường hợp này, nếu ta sử dụng mô hình hồi quy tuyến tính, có thể sẽ có các vấn đề:

- phương sai không đồng nhất;
- giá trị ngoại lai ảnh hưởng tới mô hình.


Ví dụ: xét mô hình hồi quy tuyến tính dự đoán giá bán nhà

$$\text{adj_sale_price}_i = \beta_0 + \beta_1 \text{sq_ft_tot_living}_i + \beta_2 \text{bldg_grade}_i + \beta_3 \text{yr_built}_i + \varepsilon_i,$$



GLM cho dữ liệu lệch phải

Kết quả phân tích thặng dư




cho thấy

- cấu trúc tuyến tính là không hợp lý;
- phương sai không đồng nhất.

GLM cho dữ liệu lệch phải

Kết quả Cook's distance và Leverage



cho thấy có nhiều điểm có Cook's distance lớn $\Rightarrow$ các điểm có ảnh hưởng.


GLM cho dữ liệu lệch phải

Phân phối Gamma và dữ liệu lệch phải

Biến $Y \sim \mathcal{G}(\alpha, \beta)$ với $\alpha, \beta > 0$ được gọi là shape và rate parameter:

$$f_Y(y|\alpha, \beta) = \frac{1}{\Gamma(\alpha)} y^{\alpha-1} \exp(-y\beta) \beta^\alpha,$$

với $y > 0$ và $\Gamma(\alpha)$ là hàm Gamma. Ví dụ, với $\alpha = 4, \beta = 1$, ta có hàm mật độ



⇒ hàm mật độ có xu hướng lệch phải.

GLM cho dữ liệu lệch phải

Giả sử ta có bộ dữ liệu ngẫu nhiên $(Y_i, X_{1i}, X_{2i}, \dots, X_{qi})$, với $i = 1, \dots, n$:

- các quan sát thứ i là độc lập;
- Y_i là biến phản hồi có phân phối dạng lệch phải, nhận giá trị dương;
- $X_{1i}, \dots, X_{qi}$ là các biến giải thích có thể liên quan tới Y_i .

Do Y_i có phân phối dạng lệch phải $\Rightarrow$ có thể dùng phân phối Gamma để mô hình hóa. Khi đó, $Y_i \sim \mathcal{G}(\alpha_i, \beta)$ với $\alpha_i > 0, \beta > 0$.

Mô hình tiên đoán trung bình của Y_i khi biết $X_{1i}, X_{2i}, \dots, X_{qi}$:

$$\mathbb{E}(Y_i | X_{1i}, X_{2i}, \dots, X_{qi}) = g(\beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi}),$$

được gọi là mô hình **Gamma**. Mô hình này tương đương với,

$$g^{-1}(\mu_i) = \beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi},$$

với $\mu_i = \mathbb{E}(Y_i | X_{1i}, X_{2i}, \dots, X_{qi})$. Hàm $g(\cdot)$ được xác định:

- $g(u) = u^{-1}$ (inverse link) – không đảm bảo $\mu > 0$;
- $g(u) = \exp(u)$ (log link);
- $g(u) = u$ (identity link).

GLM cho dữ liệu lệch phải - Ví dụ

Xét lại dữ liệu về giá bán nhà.

Do `adj_sale_price` có phân phối lệch phải (histogram slide 105).

⇒ ta xét mô hình Gamma với log link:

$$\mu_i = \exp(\beta_0 + \beta_1 \text{sq_ft_tot_living}_i + \beta_2 \text{bldg_grade}_i + \beta_3 \text{yr_built}_i),$$

Bảng tổng hợp kết quả

	Coefficient	Std. error	t-value	p-value
Intercept	19.9764	0.6345	31.48	<0.0001
sq_ft_tot_living	0.0002	1.635×10^{-5}	13.81	<0.0001
bldg_grade	0.2284	0.2284	17.31	<0.0001
yr_built	-0.0046	0.0132	-13.58	<0.0001

GLM cho dữ liệu trong $(0, 1)$

Trong một số trường hợp, dữ liệu Y có thể nhận giá trị trong $(0, 1)$, chẳng hạn:

- tỷ lệ;
- điểm đánh giá được rescale (ví dụ, điểm chỉ số sức khỏe).

Khi đó, ta có thể dùng phân phối Beta để mô hình hóa Y .

Phân phối Beta, $\mathcal{Be}(\alpha, \beta)$

$$f_Y(y|\alpha, \beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} y^{\alpha-1} (1-y)^{\beta-1},$$

với $y \in [0, 1]$, và $\alpha, \beta > 0$. Ta xác định được

- trung bình $\mathbb{E}(Y) = \mu = \frac{\alpha}{\alpha + \beta} \in (0, 1)$;
- tham số phân tán $\phi = \alpha + \beta > 0$;
- phương sai $\mathbb{V}\text{ar}(Y) = \sigma^2 = \frac{\mu(1 - \mu)}{1 + \phi}$.

Khi đó, ta có hàm mật độ theo cách đổi tham số μ và ϕ , $\mathcal{B}e(\mu, \phi)$:

$$f_Y(y|\mu, \phi) = \frac{\Gamma(\phi)}{\Gamma(\mu\phi)\Gamma((1-\mu)\phi)} y^{\mu\phi-1}(1-y)^{(1-\mu)\phi-1},$$

