

Giả Định Trong Hồi Quy Bội

Tính Tuyến Tính và Tính Chuẩn

Ngày 31 tháng 5 năm 2026

Mục lục

1	Giả Định Tính Tuyến Tính	4
1.1	Nguồn Gốc Lịch Sử	4
1.2	Cơ Sở Lý Thuyết	5
1.2.1	Ý nghĩa cốt lõi 1: Cấu trúc đại số của các tham số β	5
1.2.2	Ý nghĩa cốt lõi 2: Sự tự do của các biến x	5
1.2.3	Dạng Ma Trận: Biểu Diễn Gọn Cho n Quan Sát	6
1.2.4	Liên hệ với giả định $E(\varepsilon X) = 0$	7
1.3	Tại Sao Tuyến Tính Mang Lại Lợi Thế	7
1.4	Hậu Quả Khi Vi Phạm Tuyến Tính	8
1.4.1	Tứ Giác Anscombe	9
1.4.2	Ví Dụ Thực Tế	11
1.5	Phát Hiện Vi Phạm	15
1.5.1	Ma Trận Đồ Thị Phân Tán	15
1.5.2	Phần Dư Theo Giá Trị Khớp (Công Cụ Chính)	17
1.5.3	Phần Dư Theo Từng Biến Dự Báo	18
1.5.4	Đồ Thị Hồi Quy Riêng Phần	19
1.5.5	Kiểm Định Tukey Cho Tính Không Cộng Tính	20
1.5.6	Đồ Thị Nền và Giao Thức Xếp Hàng	21
1.5.7	Phần Dư Chuẩn Hóa	22
1.6	Khắc Phục Vi Phạm	23
1.6.1	Biến Đổi Biến Số	23
1.6.2	Hồi Quy Đa Thức	24
1.6.3	Splines	25

1.6.4	Hồi Quy Phi Tuyến	26
1.6.5	Mô Hình Tuyến Tính Tổng Quát (GLMs)	26
1.6.6	So Sánh Mô Hình	27
1.6.7	Đánh Giá Mô Hình Sau Khi Khắc Phục	27
1.7	Ví Dụ R: Dataset <code>mtcars</code>	30
1.8	Tính Chất Nâng Cao	32
1.8.1	Chiều Trực Giao Lên Không Gian Dự Báo	32
1.8.2	Phân Phối Chuẩn Đa Biến Đảm Bảo Tuyến Tính	33
1.8.3	Định Lý Li-Duan: Bền Vững Trước Phi Tuyến Ẩn	33
1.8.4	Bất Biến Trước Biến Đổi Tuyến Tính Toàn Hạng	34
2	Giả Định Tính Chuẩn Của Phần Dư	35
2.1	Cơ Sở Lý Thuyết	35
2.1.1	Sai Số Thật và Phần Dư Không Phải Là Một	35
2.1.2	Không Bắt Buộc Đối Với Phương Pháp Bình Phương Tối Thiểu	36
2.1.3	Khi Thêm Giả Định Chuẩn: OLS Tương Đương MLE và Suy Diễn Chính Xác Hơn	36
2.1.4	Cơ Sở Bắt Buộc Cho Suy Diễn Mẫu Nhỏ	37
2.1.5	Ma Trận Mũ: Vì Sao Phần Dư Bị Biến Dạng	37
2.1.6	Sự Siêu Chuẩn Của Phần Dư	38
2.1.7	Điểm Dễ Nhầm: Tính Chuẩn Của Y Không Phải Tính Chuẩn Của Sai Số	38
2.2	Công Cụ Trực Quan	39
2.2.1	Biểu Đồ Tần Suất Của Phần Dư	39
2.2.2	Q-Q Plot: Công Cụ Chính Để Đọc Tính Chuẩn	39
2.2.3	Đọc Đồ Thị Cùng Leverage và Ngoại Lai	41
2.2.4	Kết Luận Thực Hành	42
2.3	Kiểm Định Hình Thức	42
2.3.1	Shapiro-Wilk Test	42
2.3.2	Jarque-Bera Test	43
2.3.3	Sự Khác Biệt Bản Chất Giữa Hai Kiểm Định	44
2.3.4	Đọc p-value Theo Cỡ Mẫu và Mục Tiêu Suy Diễn	44
2.4	Hậu Quả Khi Vi Phạm	45
2.4.1	Suy Diễn Mẫu Nhỏ Mất Phân Phối Chính Xác	45
2.4.2	Đuôi Nặng và Ngoại Lai Làm Suy Diễn Kém Ổn Định	46
2.4.3	Không Chuẩn Có Thể Là Triệu Chứng Của Sai Mô Hình	46
2.4.4	Mẫu Lớn Giảm Rủi Ro Nhưng Không Xóa Mọi Vấn Đề	47
2.4.5	Bảng Tổng Hợp Cách Phản Ứng	48

2.5	Giải Pháp Thay Thế	48
2.5.1	Bản Đồ Chọn Phương Pháp	49
2.5.2	Sai Số Chuẩn Vững HC3 / Sandwich	49
2.5.3	Bootstrap	50
2.5.4	Biến Đổi Biến Phản Hồi	50
2.5.5	Mô Hình Tuyến Tính Tổng Quát (GLM)	51
2.5.6	Robust Regression	52
2.5.7	Quantile Regression	52
2.6	Ví Dụ R: Dataset Boston	53
	Tổng Kết	56

1 Giả Định Tính Tuyến Tính

1.1 Nguồn Gốc Lịch Sử

Giả định về tính tuyến tính gắn liền với sự ra đời của phân tích hồi quy, bắt nguồn từ ba dòng nghiên cứu độc lập ở nửa cuối thế kỷ 19.

Ứng dụng đầu tiên từ lý thuyết vật lý: James D. Forbes (1857). Nhà nghiên cứu Forbes có một lý thuyết cho rằng logarit của áp suất khí quyển $\log(\text{pres})$ có *mối quan hệ tuyến tính* với điểm sôi của nước; quan hệ này có nền tảng vật lý từ phương trình Clausius-Clapeyron. Tài liệu của Forbes được xem là một trong những ví dụ sớm nhất về việc dùng biểu đồ tóm tắt để minh họa hàm trung bình tuyến tính dựa trên mô hình vật lý.

Nguồn gốc thuật ngữ “Hồi quy”: Sir Francis Galton (1877–1886). Nhiều ý tưởng nền tảng của hồi quy xuất hiện lần đầu trong công trình của Sir Francis Galton (1822–1911) về sự di truyền đặc tính qua các thế hệ. Vào năm 1877, ông bắt đầu bằng thí nghiệm trên đậu hoa ngọt (sweet peas) để quan sát sự di truyền kích thước hạt. Đến năm 1886, khi biểu diễn hàm trung bình bằng đường thẳng cho dữ liệu chiều cao qua các thế hệ, Galton nhận ra các giá trị cực đoan ở thế hệ trước có xu hướng “hồi quy” (*regress*) về phía giá trị trung bình quần thể ở thế hệ sau. Đây là nguồn gốc lịch sử của thuật ngữ *regression*.

Sự tiếp nối: Karl Pearson (1893–1903). Karl Pearson (1857–1936) mở rộng sang nghiên cứu di truyền học ở người. Trong giai đoạn 1893–1898, ông thu thập dữ liệu chiều cao của các bà mẹ và con gái trưởng thành; bộ dữ liệu này được Pearson và Lee công bố năm 1903 để kiểm tra liệu các bà mẹ cao có xu hướng sinh con gái cao hay không, thông qua phương trình hồi quy tuyến tính.

Lưu ý phạm vi lịch sử. Ba dòng nghiên cứu trên là lịch sử của việc *mô hình hóa quan hệ bằng đường thẳng*. Nền tảng tính toán, tức phương pháp bình phương nhỏ nhất (OLS), được phát triển độc lập bởi Gauss và Legendre (~1805–1809), và OLS chỉ đảm bảo ước lượng tối ưu (BLUE theo định lý Gauss-Markov) khi dạng hàm được chỉ định đúng.

Hệ quả thực tiễn. Nếu quan hệ thực sự là phi tuyến nhưng ta vẫn dùng mô hình tuyến tính, ước lượng OLS trở nên chệch và không nhất quán; mọi kiểm định và dự báo đều sai.

1.2 Cơ Sở Lý Thuyết

Mô hình hồi quy bội tổng quát:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p + \varepsilon$$

Giả định tuyến tính phát biểu rằng:

$$E[Y \mid X_1, X_2, \dots, X_p] = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p$$

Hay nói cách khác: kỳ vọng có điều kiện của Y là một hàm tuyến tính trong các tham số β .

1.2.1 Ý nghĩa cốt lõi 1: Cấu trúc đại số của các tham số β

“Tuyến tính” ở đây là thuộc tính về **cấu trúc đại số** của β , không phải hình dáng của dữ liệu. Cụ thể, các tham số $\beta_0, \beta_1, \dots, \beta_k$ phải:

- Xuất hiện ở **bậc một** (không có $\beta^2, \beta^3, \dots$)
- Đứng **độc lập**, không lồng trong hàm phi tuyến
- Được **cộng lại** với nhau để tạo thành dự báo

Bạn sẽ không bao giờ thấy dạng β^2, e^β , hay $\sin(\beta)$ trong một *mô hình tuyến tính*.

1.2.2 Ý nghĩa cốt lõi 2: Sự tự do của các biến x

Ngược lại, **mô hình không đặt bất kỳ ràng buộc nào lên các biến x** . Bạn hoàn toàn có thể biến đổi x thành bất kỳ dạng phi tuyến nào (bình phương, nghịch đảo, logarit, hàm lượng giác, ...) và mô hình vẫn là *mô hình tuyến tính*. Ví dụ, phương trình sau chứa đồng thời nghịch đảo (x_2^{-1}), bình phương (x_2^2) và hàm sin ($\sin(x_2)$):

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2^{-1} + \beta_3 x_2^2 + \beta_4 \sin(x_2) + \varepsilon$$


Mô hình này **vẫn là mô hình tuyến tính** vì $\beta_0, \dots, \beta_4$ đều xuất hiện ở bậc một và được cộng lại.

Dạng mô hình	Tuyến tính trong β ?	Lý do
$Y = \beta_0 + \beta_1 X + \varepsilon$	Có	β bậc một, cộng tính
$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \varepsilon$	Có	X^2 là biến mới; β vẫn bậc một
$Y = \beta_0 + \beta_1 \log X + \beta_2 X^{-1} + \varepsilon$	Có	$\log X$, X^{-1} là biến mới
$Y = \beta_0 \cdot e^{\beta_1 X} + \varepsilon$	Không	β_1 nằm trong $\exp(\cdot)$
$Y = \beta_0 + X^{\beta_1} + \varepsilon$	Không	β_1 là số mũ của X

Hệ quả thực tiễn. Nhờ đặc tính này, khuôn khổ hồi quy tuyến tính có thể xấp xỉ vô số quan hệ cong trong thực tế, chỉ bằng cách biến đổi các biến x , trong khi vẫn giữ nguyên phương pháp tính toán OLS.

Minh họa hình học: ba trường hợp đặc trưng.

Hình 1 — 'Linear model' không nhất thiết là đường thẳng



Hình 1: Mô hình tuyến tính không nhất thiết tạo ra đường thẳng. (a) Bậc 1 $\rightarrow$ đường thẳng. (b) Bậc 2 $\rightarrow$ parabol, vẫn là mô hình tuyến tính vì $\beta_0, \beta_1, \beta_2$ bậc một. (c) $y = e^{\beta_0 + \beta_1 x}$: β_1 nằm trong $\exp(\cdot)$, không phải mô hình tuyến tính.

1.2.3 Dạng Ma Trận: Biểu Diễn Gọn Cho n Quan Sát

Với n quan sát, dạng đại số tổng quát được gom lại thành phép nhân ma trận:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad E(\mathbf{Y} | \mathbf{X}) = \mathbf{X}\boldsymbol{\beta}$$

trong đó:

- $\mathbf{y}$: vector cột $n \times 1$ chứa các giá trị phản hồi.
- $\mathbf{X}$: ma trận thiết kế kích thước $n \times (k + 1)$, cột đầu là vector đơn vị $\mathbf{1}_n$ (cho β_0), các cột còn lại là giá trị của k biến dự báo.
- $\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_k)^\top$: vector cột $(k + 1) \times 1$ chứa các tham số.

- ε : vector cột $n \times 1$ chứa các sai số ngẫu nhiên.


Nhờ cấu trúc tổ hợp tuyến tính này, OLS tối thiểu hóa $\|\mathbf{y} - \mathbf{X}\beta\|^2$ và dẫn đến **hệ phương trình chuẩn**:

$$\mathbf{X}^\top \mathbf{X} \hat{\beta} = \mathbf{X}^\top \mathbf{y}$$

Khi $\mathbf{X}^\top \mathbf{X}$ khả nghịch (các cột của $\mathbf{X}$ độc lập tuyến tính), nghiệm duy nhất là $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$. Đây là lý do tính tuyến tính trong β mang lại phương pháp ước lượng **đồng nhất và khả tính** cho mọi cấu hình biến dự báo.

1.2.4 Liên hệ với giả định $E(\varepsilon | X) = 0$

Giả định tuyến tính và giả định $E(\varepsilon | X) = 0$ là **hai mặt của cùng một yêu cầu**: khi dạng hàm $E[Y|X]$ được chỉ định đúng, phần dư chỉ là nhiễu ngẫu nhiên, kỳ vọng của chúng bằng 0 tại mọi giá trị X . Khi dạng hàm sai, phần dư mang theo thông tin có hệ thống và $E(\varepsilon | X) \neq 0$.



Hình 2: $E(\varepsilon|X) = 0$ khi mô hình đúng dạng (trái) vs. $E(\varepsilon|X) \neq 0$ khi sai dạng (phải). Trái: phần dư dương (xanh) và âm (cam) phân bố đều hai phía, $\sum \varepsilon \approx 0$. Phải: phần dư dương tập trung ở giữa, âm ở hai đầu, tạo thành mẫu hình có hệ thống.

1.3 Tại Sao Tuyến Tính Mang Lại Lợi Thế

Tính tuyến tính trong tham số không phải là giả định tùy tiện. Nó cung cấp ba lợi thế cụ thể, tất cả đều bắt nguồn từ cùng một tính chất cấu trúc: $\hat{\beta}$ là **tổ hợp tuyến tính của $\mathbf{y}$** .


1. Nghiệm dạng đóng. Tối thiểu hóa tổng bình phương $\|\mathbf{y} - \mathbf{X}\beta\|^2$ trên mô hình tuyến tính-tham số cho ra hệ phương trình chuẩn có nghiệm đóng:

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

Công thức tính được *một lần* từ các thống kê tóm tắt của dữ liệu, không cần lặp số. Mô hình phi tuyến đòi hỏi thuật toán lặp như Gauss-Newton, có thể không hội tụ hoặc hội tụ về cực tiểu cục bộ.

2. Ước lượng tối ưu—Định lý Gauss-Markov. Vì $\hat{\beta}$ là tổ hợp tuyến tính của $\mathbf{y}$, trong lớp tất cả các ước lượng tuyến tính không chệch, OLS đạt phương sai nhỏ nhất—tính chất **BLUE** (Best Linear Unbiased Estimator). Định lý này không đòi hỏi phân phối chuẩn: chỉ cần $E(\varepsilon|X) = 0$, $\text{Var}(\varepsilon) = \sigma^2 I$, và $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$.

3. Suy diễn đáng tin—Định lý Giới Hạn Trung Tâm cho $\hat{\beta}$. Vì $\hat{\beta}$ là tổ hợp tuyến tính của $\mathbf{y}$, CLT đảm bảo $\hat{\beta}$ xấp xỉ chuẩn trong mẫu lớn dù sai số có phân phối bất kỳ. Khi sai số *thực sự* chuẩn, $\hat{\beta}$ chuẩn chính xác và thống kê t , F theo đúng phân phối lý thuyết—nền tảng của mọi kiểm định giả thuyết và khoảng tin cậy.



Hình 3: Minh họa hai lợi thế của tuyến tính trong tham số. **Trái (Gauss-Markov BLUE):** $B = 4000$ lần mô phỏng, $n = 40$, $\beta_1 = 2$. OLS (xanh dương) có phân phối lấy mẫu hẹp hơn đáng kể so với ước lượng tuyến tính không chệch thay thế (đỏ), cả hai đều tập trung tại giá trị thực. **Phải (CLT cho $\hat{\beta}_1$):** sai số có phân phối $\text{Exp}(1) - 1$ lệch phải rõ ràng. Khi n tăng từ 10 lên 200, phân phối lấy mẫu của $\hat{\beta}_1$ nhanh chóng tiến về chuẩn—suy diễn bằng t -test vẫn hợp lệ tiệm cận.

1.4 Hậu Quả Khi Vi Phạm Tuyến Tính

Khi dạng hàm thực là phi tuyến nhưng ta khớp bằng đường thẳng, đường thẳng đó hấp thụ độ cong vào hệ số, tạo ra trung bình *sai ở mọi nơi*—không chỉ ồn ào mà là chệch có cấu trúc. Đây là vi phạm nguy hiểm nhất vì nó phá vỡ tính không chệch ngay tại lõi của OLS. Năm biểu hiện quan sát được:

1. Ước lượng chệch: $E[\hat{\beta}] \neq \beta$ —hệ số sai trung bình, không phải chỉ không chính xác. OLS hấp thụ phần phi tuyến bị bỏ sót vào hệ số, làm lệch ước lượng tốc độ thay

đổi của biến phản hồi.

2. Mẫu hình phần dư có hệ thống: đồ thị phần dư theo giá trị khớp cho thấy dạng cong (chữ U, chữ S) thay vì phân tán ngẫu nhiên—đây là tín hiệu chẩn đoán chính. Đường LOESS lệch khỏi $y = 0$ một cách có quy luật.

3. Khớp kém: s^2 bị thổi phồng vì mô hình quy cho sai số ngẫu nhiên những phần biến động thực ra có cấu trúc. Khoảng tin cậy quá rộng, kiểm định mất sức mạnh thống kê.


4. Suy diễn không hợp lệ: kiểm định t và F dựa trên mô hình sai lệch— p -value và khoảng tin cậy không đáng tin. Một biến có thể có ý nghĩa thống kê không phải vì tác động thực, mà vì nó đang bù đắp cho phần phi tuyến bị thiếu.

5. Dự báo không chính xác: khoảng cách giữa đường khớp và đường cong thực mở rộng ra ngoài vùng huấn luyện, nơi ngoại suy nguy hiểm nhất.

Điểm phân biệt quan trọng. Khác với vi phạm giả định chuẩn tắc (chỉ ảnh hưởng đến suy diễn), vi phạm tuyến tính ảnh hưởng trực tiếp đến *bản thân ước lượng* $\hat{\beta}$ và $\hat{y}$: chúng không còn ước lượng đúng tham số quan tâm nữa.

1.4.1 Tứ Giác Anscombe

Anscombe (1973) đã xây dựng bốn bộ dữ liệu có cùng $\hat{\beta}_0 \approx 3$, $\hat{\beta}_1 \approx 0.5$, $R^2 \approx 0.67$ và p -value—nhưng nhìn hoàn toàn khác nhau. Bộ II rõ ràng là quan hệ bậc hai. Bộ III bị một điểm ngoại lai kéo hệ số. Bộ IV có đòn bẩy cực cao tại một điểm. Kết quả hồi quy không cảnh báo gì cả; chỉ đồ thị phần dư mới tiết lộ vi phạm.



Hình 4: Tứ giác Anscombe: bốn bộ dữ liệu với cùng $\hat{\beta}_1 \approx 0.5$ và $R^2 \approx 0.67$. **Hàng trên:** scatterplot với đường hồi quy bậc nhất—nhìn qua output số không phân biệt được. **Hàng dưới:** đồ thị phần dư theo giá trị khớp. Bộ I (tuyến tính): phần dư ngẫu nhiên, LOESS nằm ngang. Bộ II (phi tuyến bậc 2): LOESS cong hình cung, vi phạm tuyến tính rõ. Bộ III (ngoại lai): một điểm kéo hệ số lên cao, phần dư có điểm ngoại lai lớn. Bộ IV (đòn bẩy): một điểm kiểm soát toàn bộ hồi quy.

```

1 data(anscombe)
2 # Tất cả có cùng hệ số hồi quy và R2
3 fits <- lapply(1:4, function(i)
4   lm(anscombe[[paste0("y",i)]] ~ anscombe[[paste0("x",i)]])
5
6 do.call(rbind, lapply(fits, function(m) {
7   s <- summary(m)
8   round(c(b0 = coef(m)[1], b1 = coef(m)[2],
9         R2 = s$r.squared, p = coef(s)[2,4]), 3)
10 })))

```


	b0	b1	R2	p
[1,]	3.00	0.500	0.667	0.002

[2,]	3.00	0.500	0.666	0.002
[3,]	3.00	0.500	0.666	0.002
[4,]	3.00	0.500	0.667	0.002

1.4.2 Ví Dụ Thực Tế

Bốn bộ dữ liệu từ các lĩnh vực khác nhau minh họa cùng một mẫu hình: đường thẳng OLS không bám sát dữ liệu, và đồ thị phần dư phản chiếu rõ độ cong bị bỏ sót.

Vi phạm tuyến tính: dữ liệu thực tế



Hình 5: Bốn ví dụ thực tế vi phạm tính tuyến tính. **Cột trái:** scatter plot với đường hồi quy OLS bậc 1 (đỏ). **Cột phải:** đồ thị phần dư theo giá trị khớp; đường LOESS (đỏ) lệch có hệ thống khỏi $y = 0$. **(1) Turkey growth:** tốc độ tăng cân theo liều methionine bão hòa dần—đường thẳng đánh giá thấp ở đầu, cao ở cuối. **(2) Mammals:** khối lượng não theo khối lượng cơ thể trải dài hàng nghìn lần—OLS bị chi phối bởi vài loài lớn. **(3) Physics:** tiết diện tán xạ giảm nhanh theo đà—dạng lũy thừa không thể khớp bằng đường thẳng. **(4) Cedar trees:** chiều cao cây tiệm cận mức tối đa khi đường kính lớn—dạng sigmoid.


```

1 # -- (1) Turkey growth:  $E(Y/Dose) = b_0 + b_1(1 - \exp(-b_2 \cdot Dose))$ 
   -----
2 set.seed(101)
3 dose_lvl <- c(0, 0.04, 0.08, 0.12, 0.16, 0.20)
4 dose_t   <- rep(dose_lvl, each = 5)
5 y_turkey <- 639 + 168*(1 - exp(-37*dose_t)) + rnorm(30, 0, 18)
6
7 fit_lin_t <- lm(y_turkey ~ dose_t)
8 plot(dose_t, y_turkey, pch = 16, col = "steelblue",
9      xlab = "Dose (mg/g)", ylab = "Weight gain (g)")
10 abline(fit_lin_t, col = "red", lwd = 2)
11 plot(fit_lin_t, which = 1) # phan du cong ro
12
13 # -- (2) Mammals: brain ~ body (MASS)
   -----
14 library(MASS); data(mammals)
15 fit_raw <- lm(brain ~ body, data = mammals)
16 plot(fit_raw, which = 1) # phan du bien dang nang
17
18 # -- (3) Physics cross sections
   -----
19 set.seed(102)
20 x_phys <- sort(runif(38, 0.3, 3.5))
21 y_phys <- 45 * x_phys^(-1.7) * exp(rnorm(38, 0, 0.15))
22
23 fit_lin_p <- lm(y_phys ~ x_phys)
24 plot(fit_lin_p, which = 1) # LOESS cong chu U
25
26 # -- (4) Cedar trees: height ~ dbh
   -----
27 set.seed(103)
28 dbh <- sort(runif(65, 5, 78))
29 height <- 30*(1 - exp(-0.055*dbh)) + rnorm(65, 0, 2.2)
30
31 fit_lin_d <- lm(height ~ dbh)
32 plot(fit_lin_d, which = 1) # LOESS cong chu S

```

Trong cả bốn trường hợp, đường LOESS trên đồ thị phần dư lệch khỏi $y = 0$ theo mẫu hình có hệ thống—dấu hiệu chẩn đoán chính của vi phạm tuyến tính. Các mô

hình phù hợp cho từng trường hợp (NLS, biến đổi log-log, cubic spline) được trình bày trong Hình 6.



Hình 6: Cùng bốn bộ dữ liệu sau khi áp dụng mô hình phù hợp (xanh lá). **(1) Turkey:** NLS với dạng bão hòa $\beta_0 + \beta_1[1 - e^{-\beta_2 \cdot \text{dose}}]$ —phần dư trở nên ngẫu nhiên. **(2) Mammals:** OLS trên thang log-log—quan hệ tuyến tính, phần dư phân tán đều. **(3) Physics:** khớp lũy thừa qua log-log—phần dư không còn mẫu hình. **(4) Cedar trees:** cubic spline với 3 nút—đường cong bám sát toàn vùng, phần dư ngẫu nhiên.

```

1 # -- (1) Turkey: NLS
   -----
2 fit_nls_t <- nls(y_turkey ~ b0 + b1*(1 - exp(-b2*dose_t)),
3                 start = list(b0 = 630, b1 = 160, b2 = 30))
4
5 # -- (2) Mammals: log-log
   -----
6 fit_log <- lm(log(brain) ~ log(body), data = mammals)
7 # He so: slope ~ 0.75 (dinh luat Kleiber)
8
9 # -- (3) Physics: log-log
   -----
10 fit_logp <- lm(log(y_phys) ~ log(x_phys))
11
12 # -- (4) Trees: cubic spline
   -----
13 library(splines)
14 fit_spl_t <- lm(height ~ bs(dbh, knots = quantile(dbh,
15             c(.25,.5,.75))))

```

1.5 Phát Hiện Vi Phạm


Không có công cụ đơn lẻ nào đủ trong hồi quy bội. Năm công cụ sau được dùng theo thứ tự, từ khảo sát ban đầu đến xác nhận hình thức.

Công cụ	Khi dùng	Phát hiện
Ma trận đồ thị phân tán	Trước khi khớp	Độ cong biên rõ ràng
Phần dư theo giá trị khớp	Sau khi khớp	Có gì đó sai tổng thể
Phần dư theo từng X_j	Sau khi khớp	Biến nào là nguồn gốc
Đồ thị hồi quy riêng phần	Sau khi khớp	Đóng góp tuyến tính riêng biệt của từng biến
Kiểm định Tukey	Sau khi đồ thị gợi ý	Xác nhận hình thức về độ cong

1.5.1 Ma Trận Đồ Thị Phân Tán

Vẽ mọi cặp quan hệ giữa Y và các biến dự báo $X_1, \dots, X_k$ trong một lưới trước khi khớp bất cứ thứ gì. Cho thấy bức tranh trực quan về các mối quan hệ biên và có thể báo hiệu độ cong rõ ràng ngay từ đầu.

Giới hạn: Chỉ nắm bắt quan hệ hai biến. Phi tuyến chỉ xuất hiện trong sự kết hợp của nhiều biến sẽ ẩn ở đây. Không thay thế được các công cụ sau khi khớp.



Hình 7: Ma trận đồ thị phân tán cho bốn biến của mtcars. **Tam giác dưới:** scatter plot với đường LOESS (đỏ)—cho thấy độ cong biến trước khi khớp mô hình. **Đường chéo:** histogram mật độ của từng biến riêng lẻ. **Tam giác trên:** hệ số tương quan Pearson (cỡ chữ theo độ lớn, xanh dương = dương, đỏ = âm). Quan hệ mpg-hp và mpg-disp có đường LOESS cong rõ—gợi ý phi tuyến biến cần kiểm tra kỹ hơn sau khi khớp.

```

1 # Ma tran do thi phan tan co LOESS va tuong quan
2 panel_scatter <- function(x, y, ...) {
3   points(x, y, pch = 16, cex = 0.65, col = "steelblue")
4   lines(lowess(x, y), col = "red", lwd = 2)
5 }
6 panel_cor <- function(x, y, ...) {
7   r <- cor(x, y, use = "complete.obs")
8   text(0.5, 0.5, round(r, 2), cex = 0.8 + 1.8*abs(r),
9       col = if(r > 0) "blue" else "red", font = 2,
10      transform = NULL)

```



```

11 }
12 pairs(mtcars[, c("mpg", "hp", "wt", "disp")],
13       lower.panel = panel_scatter,
14       upper.panel = panel_cor)


```

1.5.2 Phần Dư Theo Giá Trị Khớp (Công Cụ Chính)

Trục x là giá trị khớp $\hat{y}$, trục y là phần dư $e_i = y_i - \hat{y}_i$. Công cụ này hoạt động như “kính lúp”: trừ đi xu hướng tuyến tính, phóng đại những sai lệch nhỏ bên dưới.

- **Không vi phạm:** Điểm phân tán ngẫu nhiên quanh $y = 0$, đường LOESS nằm ngang—đây là “biểu đồ rỗng” lý tưởng.
- **Vi phạm:** Đường LOESS tạo thành dạng cong (chữ U, chữ S): quan hệ phi tuyến bị bỏ sót ở đâu đó trong mô hình.

Trong hồi quy bội, đồ thị này chỉ báo “có điều gì đó sai” nhưng không chỉ ra biến nào là nguyên nhân.



Hình 8: Đồ thị phần dư theo giá trị khốp: “biểu đồ rộng” (không vi phạm) so với mẫu hình cong (vi phạm). (a)–(b) Dữ liệu tuyến tính: LOESS gần nằm ngang, điểm phân tán đều. (c)–(d) Dữ liệu cong khớp bằng bậc 1: LOESS cong hình chữ U xác nhận vi phạm tuyến tính.

1.5.3 Phần Dư Theo Từng Biến Dự Báo

Vẽ phần dư e_i theo từng biến X_j riêng lẻ. Dạng cong trong một trong các đồ thị này *khoanh vùng vấn đề*: biến cụ thể đó không được mô hình hóa đúng dạng. Thường có thể khắc phục bằng cách thêm số hạng X_j^2 hoặc $\log X_j$.

```

1 fit <- lm(mpg ~ hp + wt + disp, data = mtcars)
2 par(mfrow = c(1, 3))
3 for (v in c("hp", "wt", "disp")) {
4   plot(mtcars[[v]], residuals(fit),
5        xlab = v, ylab = "Residuals", pch = 16, col =
6         "steelblue")
7   abline(h = 0, lty = 2)
8   lines(lowess(mtcars[[v]], residuals(fit)), col = "red", lwd =
9         2)

```


1.5.4 Đồ Thị Hồi Quy Riêng Phần

Đồ thị phần dư theo từng X_j có một điểm yếu: nó không loại trừ ảnh hưởng của các biến khác, nên có thể phản ánh sai mối quan hệ của X_j với Y . Đồ thị hồi quy riêng phần (added-variable plot) khắc phục điều này.

Cách xây dựng. Cho biến dự báo X_j :

1. Hồi quy Y lên tất cả các biến trừ $X_j \rightarrow$ lấy phần dư e_Y .
2. Hồi quy X_j lên tất cả các biến trừ $X_j \rightarrow$ lấy phần dư e_{X_j} .
3. Vẽ e_Y theo e_{X_j} .

Độ dốc của đồ thị này bằng *chính xác* hệ số β_j trong mô hình đầy đủ—nó cô lập đóng góp tuyến tính *duy nhất* của X_j sau khi đã tính đến mọi biến khác. Dạng phi tuyến ở đây xác nhận X_j không được đưa vào mô hình đúng dạng.



Hình 9: Đồ thị hồi quy riêng phần cho mô hình $\text{mpg} \sim \text{hp} + \text{wt} + \text{disp}$ (mtcars). Trục x và y là phần dư của X_j và Y sau khi đã loại bỏ ảnh hưởng của các biến còn lại. Chú thích trên mỗi panel: $\hat{\beta}_{AV}$ (độ dốc của đồ thị) và $\hat{\beta}_{full}$ (hệ số trong mô hình đầy đủ)—hai giá trị khớp chính xác nhau. Quan hệ gần thẳng xác nhận dạng tuyến tính là phù hợp cho cả ba biến trong mô hình này.

```

1 # Implement added-variable plot thủ công (không cần package car)
2 av_plot <- function(fit, jname) {
3   vars <- attr(terms(fit), "term.labels")
4   others <- setdiff(vars, jname)
5   fmY <- as.formula(paste("mpg ~", paste(others, collapse =
      "+")))

```

```

6   fmXj   <- as.formula(paste(jname, "~", paste(others,
      collapse = "+")))
7   eY     <- residuals(lm(fmY, data = model.frame(fit)))
8   eXj    <- residuals(lm(fmXj, data = model.frame(fit)))
9   plot(eXj, eY, pch = 16, col = "steelblue",
10      xlab = paste0("e(", jname, " | others)"),
11      ylab = "e(mpg | others)", main = jname)
12   abline(lm(eY ~ eXj), col = "red", lwd = 2)
13 }
14
15 fit_full <- lm(mpg ~ hp + wt + disp, data = mtcars)
16 par(mfrow = c(1, 3))
17 for (v in c("hp", "wt", "disp")) av_plot(fit_full, v)

```

1.5.5 Kiểm Định Tukey Cho Tính Không Cộng Tính

Khi đồ thị phần dư gợi ý độ cong, hình thức hóa ẩn tượng thị giác: chọn một đại lượng U (một biến dự báo cụ thể hoặc giá trị khớp $\hat{y}$), thêm U^2 làm số hạng phụ vào mô hình, và chạy kiểm định t cho hệ số của nó:

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p + \gamma U^2 + \varepsilon, \quad H_0: \gamma = 0$$

Kết quả có ý nghĩa ($p < 0.05$) xác nhận độ cong có hệ thống. Khi $U = \hat{y}$, thủ tục này được gọi là **kiểm định Tukey cho tính không cộng tính**—nó kiểm tra một cách tổng quát xem có bất kỳ dạng phi tuyến nào bị bỏ sót trong mô hình hay không.

```

1 fit_base <- lm(mpg ~ hp + wt, data = mtcars)
2 yhat     <- fitted(fit_base)
3
4 # Tukey's test: thêm yhat^2, kiểm tra hệ số gamma
5 fit_tukey <- lm(mpg ~ hp + wt + I(yhat^2), data = mtcars)
6 summary(fit_tukey)$coefficients["I(yhat^2)", ]

```

	Estimate	Std. Error	t value	Pr(> t)
I(yhat^2)	-0.0033021	0.0016574	-1.992	0.0560

$p = 0.056$ gần ngưỡng: đồ thị phần dư của mô hình `mpg ~ hp + wt` cho thấy độ cong nhẹ, kiểm định Tukey xác nhận đây không phải hoàn toàn ngẫu nhiên. Thêm `I(hp^2)` hoặc dùng `poly(hp, 2)` sẽ giải quyết vấn đề.

1.5.6 Đồ Thị Nền và Giao Thức Xếp Hàng

Khi đọc đồ thị phần dư, mắt người dễ thấy “mẫu hình” ngay cả trong dữ liệu hoàn toàn ngẫu nhiên. Câu hỏi cần đặt ra: mẫu hình ta thấy là vi phạm thực sự hay chỉ là biến động tự nhiên?


Một **đồ thị nền** là đồ thị phần dư được tạo từ dữ liệu mô phỏng *khi mô hình hoàn toàn đúng*—đây là chuẩn gốc của sự ngẫu nhiên với cỡ mẫu n và σ cụ thể:

1. Ước lượng mô hình gốc, thu được $\hat{\beta}$ và $\hat{\sigma}$.
2. Mô phỏng: $y^* = X\hat{\beta} + \varepsilon^*$, $\varepsilon^* \sim \mathcal{N}(0, \hat{\sigma}^2)$.
3. Khớp lại cùng mô hình trên y^* , lấy phần dư và vẽ đồ thị.

Giao thức xếp hàng (Wickham et al., 2010) biến việc đọc đồ thị thành kiểm định thống kê thị giác: tạo $m - 1$ đồ thị nền, chèn đồ thị thực vào vị trí ngẫu nhiên, hiển thị tất cả m đồ thị. Nếu người quan sát xác định đúng đồ thị thực, $p\text{-value} = 1/m$.

```
1 generate_null_residuals <- function(model) {  
2   n      <- length(fitted(model))  
3   y_sim <- fitted(model) + rnorm(n, sd = sigma(model))  
4   fit_null <- update(model, y_sim ~ .)  
5   data.frame(fitted = fitted(fit_null), resid =  
6     residuals(fit_null))  
7 }  
8  
9 set.seed(2025)  
10 fit      <- lm(mpg ~ hp, data = mtcars)  
11 real_pos <- sample(1:9, 1)  
12 par(mfrow = c(3, 3), mar = c(3, 3, 2.5, 1))  
13 for (i in 1:9) {  
14   d <- if (i == real_pos) data.frame(fitted = fitted(fit),  
15     residuals = residuals(fit))  
16   else generate_null_residuals(fit)  
17   plot(d$fitted, d$resid, pch = 16, cex = 0.7, col =  
18     "steelblue",  
19     xlab = "Fitted", ylab = "Residuals", main =  
20     paste("Plot", i))  
21   abline(h = 0, lty = 2, col = "gray60")  
22   lines(lowess(d$fitted, d$resid), col = "red", lwd = 2)  
23 }
```

Lineup: 8 null plots + 1 residual plot thực --- Bạn có thể xác định plot nào là thực không?



Hình 10: Giao thức xếp hàng: 8 đồ thị nền và 1 đồ thị phần dư thực (mô hình bậc 1 trên dữ liệu con). Xác suất đoán ngẫu nhiên đúng là $1/9 \approx 11\%$. Nếu bạn nhận ra đồ thị thực, đó là bằng chứng thị giác có ý nghĩa thống kê. **Hữu ích nhất** khi $n < 30$ và mẫu hình phần dư mơ hồ. (Đáp án: Đồ thị 7.)

1.5.7 Phần Dư Chuẩn Hóa

Phần dư nguyên bản e_i có phương sai không đồng nhất, phụ thuộc vào đòn bẩy h_{ii} :

$$\text{Var}(e_i) = \sigma^2(1 - h_{ii})$$

Tại điểm có đòn bẩy cao (h_{ii} lớn), phần dư bị kéo về gần 0 ngay cả khi mô hình sai—**hiệu ứng che khuất**. Nên dùng phần dư Student hóa ngoài `rstudent(model)` thay thế: chúng có phương sai đồng nhất và nhạy hơn với bất thường cục bộ. Đồ thị hồi

quy riêng phần (mục 1.5.4) bổ sung góc nhìn cục bộ cho từng biến; hai công cụ bổ trợ nhau, không thay thế nhau.

1.6 Khắc Phục Vi Phạm

Năm phương pháp chính, từ đơn giản đến phức tạp. Lựa chọn dựa trên bản chất của dữ liệu và mục tiêu mô hình hóa.

Phương pháp	Phù hợp khi	Giữ nguyên OLS?
Biến đổi biến số	Quan hệ mũ hoặc lũy thừa đơn giản	Có, sau biến đổi
Hồi quy đa thức	Quan hệ cong vừa phải, toàn vùng	Có
Splines	Độ cong cục bộ; tránh méo biên	Có
Hồi quy phi tuyến	Dạng hàm có cơ sở lý thuyết rõ ràng	Không—cần lập số
GLMs	Biến phản hồi bị chặn hoặc là số đếm	Không—dùng hàm liên kết

1.6.1 Biến Đổi Biến Số


Thay thế X , Y , hoặc cả hai bằng một biến đổi làm thẳng quan hệ trước khi khớp OLS.

Dạng quan hệ thực	Biến đổi gợi ý	Mô hình sau biến đổi
$Y = \beta_0 \cdot e^{\beta_1 X}$	$\log(Y)$	$\log(Y) = \gamma_0 + \gamma_1 X$
$Y = \beta_0 \cdot X^{\beta_1}$	$\log(Y)$ và $\log(X)$	$\log(Y) = \gamma_0 + \gamma_1 \log(X)$
$Y = \beta_0 / (\beta_1 + X)$	$1/Y$ hoặc $1/X$	(tùy trường hợp)

Khi không rõ nên dùng biến đổi nào, **phương pháp Box-Cox** tìm kiếm λ tối ưu hóa hàm log-likelihood:

$$y^{(\lambda)} = \begin{cases} (y^\lambda - 1)/\lambda & \lambda \neq 0 \\ \log y & \lambda = 0 \end{cases}$$

$\lambda = 0$ tương ứng biến đổi log; $\lambda = 0.5$ tương ứng căn bậc hai. Khoảng tin cậy 95% cho λ từ profile likelihood chỉ ra biến đổi phù hợp.



Hình 11: Biến đổi $\log(Y)$ tuyến tính hóa quan hệ mũ. Trái: Y theo X dạng cong, OLS bậc 1 bỏ lỡ xu hướng. Phải: $\log(Y)$ theo X quan hệ tuyến tính, OLS và LOESS trùng khớp. Hệ số γ_1 diễn giải trực tiếp là phần trăm thay đổi của Y khi X tăng 1 đơn vị.

```
1 library(MASS)
2 # Box-Cox: tìm lambda tối ưu
3 bc <- boxcox(mpg ~ hp + wt, data = mtcars)
4 lambda_opt <- bc$x[which.max(bc$y)]
5 cat("lambda tối ưu:", round(lambda_opt, 2), "\n")
6 # lambda ~ 0 -> dùng log(Y); lambda ~ 0.5 -> dùng sqrt(Y)
```

1.6.2 Hồi Quy Đa Thức

Bổ sung lũy thừa nguyên của biến dự báo làm biến hồi quy. Đây vẫn là **mô hình tuyến tính** vì tuyến tính trong β .

Một biến dự báo.

$$E(Y | X = x) = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_d x^d$$

Nhiều biến dự báo. Mô hình bậc hai với X_1 và X_2 thêm cả tương tác:

$$E(Y | x_1, x_2) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{11} x_1^2 + \beta_{22} x_2^2 + \beta_{12} x_1 x_2$$

Tổng quát với k biến: $1 + k + k + k(k-1)/2$ tham số cho mô hình bậc hai.

Ứng dụng nổi bật: xác định cực trị. Khi $d = 2$, đỉnh hoặc đáy của parabol xảy ra tại:

$$x_M = -\frac{\beta_1}{2\beta_2}$$


Hữu ích trong tối ưu hóa (liều thuốc tối ưu, nhiệt độ vận hành tốt nhất, ...).

Rủi ro chính. Đa thức là hàm *toàn cục*: bậc cao khớp tốt ở giữa nhưng dao động mạnh ở biên (xem hình 12). Dùng `poly(X, d)` thay vì `I(X^2)` để nhận đa thức trực giao, tránh đa cộng tuyến số.

1.6.3 Splines

Splines chia phạm vi X thành các đoạn tại các **nút** (knots) và khớp một đa thức bậc thấp riêng biệt trong từng đoạn, nối trơn tại ranh giới. Khác với đa thức toàn cục, splines là *cục bộ*: độ cong ở một vùng không làm méo dự báo ở vùng khác.

Cubic B-splines là cơ sở tiêu chuẩn: mỗi hàm cơ sở khác không chỉ trên một khoảng nhỏ, đảm bảo đường cong trơn đến đạo hàm bậc hai tại mọi nút và tính toán ổn định về số.



Hình 12: Đa thức bậc 7 (toàn cục) so với cubic B-spline với 4 nút trên dữ liệu $y = \sin(x) + \varepsilon$. **Trái:** Đa thức bậc 7 khớp tốt ở giữa nhưng dao động mạnh ở biên trái và phải, lệch xa giá trị thực. **Phải:** Cubic B-spline bám sát $\sin(x)$ ổn định trên toàn vùng; các đường đứt nét thẳng đứng là vị trí nút.

```
1 library(splines)
2 # Cubic B-spline với nút tại phân vị 25, 50, 75
3 fit_spl <- lm(mpg ~ bs(hp,
4                     knots = quantile(mtcars$hp, c(0.25,
5                     0.5, 0.75)),
6                     degree = 3),
7               data = mtcars)
```

```

8 hp_seq <- seq(min(mtcars$hp), max(mtcars$hp), length.out = 300)
9 pred_sp <- predict(fit_spl, newdata = data.frame(hp = hp_seq))
10
11 plot(mtcars$hp, mtcars$mpg, pch = 16, col = "gray50",
12       xlab = "hp", ylab = "mpg")
13 lines(hp_seq, pred_sp, col = "blue", lwd = 2)

```

1.6.4 Hồi Quy Phi Tuyến

Khi quan hệ được chi phối bởi một cơ chế lý thuyết đã biết—suy giảm mũ, tăng trưởng logistic, động học Michaelis-Menten—khớp mô hình với tham số tương tác *phi tuyến*:

$$y = \beta_0 + \beta_1 \exp(\beta_2 x) + \varepsilon$$

Nghiem dạng đóng OLS không áp dụng. Tham số được ước lượng lặp bằng **thuật toán Gauss-Newton**: tuyến tính hóa mô hình quanh ước lượng hiện tại, cập nhật tham số, lặp lại cho đến hội tụ. Cần cung cấp giá trị khởi đầu hợp lý; nếu không, thuật toán có thể không hội tụ hoặc hội tụ về cực tiểu cục bộ.

Khi nào nên dùng: chỉ khi có dạng hàm có cơ sở lý thuyết. Nếu chỉ cần khớp đường cong mà không có cơ chế cụ thể, splines thường ưu tiên hơn.

```

1 # Hồi quy phi tuyến: Y = a * exp(b * X) + c
2 # nls() yêu cầu giá trị khởi đầu
3 fit_nls <- nls(mpg ~ a * exp(b * hp) + c,
4               data = mtcars,
5               start = list(a = 50, b = -0.005, c = 5))
6 summary(fit_nls)$coefficients

```

1.6.5 Mô Hình Tuyến Tính Tổng Quát (GLMs)

Khi biến phản hồi có ràng buộc cấu trúc tự nhiên—xác suất bị chặn trong $[0, 1]$, số đếm không thể âm—không có biến đổi nào của X tạo được quan hệ đường thẳng với biến phản hồi bị chặn. GLMs giải quyết bằng **hàm liên kết** $g(\cdot)$:

$$g(E[Y | X]) = X\beta$$

Tham số vẫn tuyến tính trong $X\beta$; hàm liên kết xử lý ánh xạ phi tuyến giữa thang biến phản hồi và không gian dự báo tuyến tính. Ước lượng bằng Maximum Likelihood,

không phải OLS.

Kiểu phản hồi	Mô hình	Hàm liên kết	R
Nhị phân $\{0, 1\}$	Logistic	$\log\left(\frac{\mu}{1-\mu}\right)$	<code>glm(..., binomial)</code>
Số đếm $\{0, 1, 2, \dots\}$	Poisson	$\log(\mu)$	<code>glm(..., poisson)</code>
Tỷ lệ $(0, 1)$	Beta	logit	<code>betareg()</code>

1.6.6 So Sánh Mô Hình

Sau khi đề xuất các mô hình khác nhau, cần tiêu chí khách quan để chọn độ phức tạp phù hợp.

ANOVA (kiểm định F cho mô hình lồng nhau):

H_0 : Mô hình đơn giản hơn là đủ (hệ số bậc cao = 0)

Chỉ áp dụng cho mô hình lồng nhau. $p < 0.05$: mô hình phức tạp hơn cải thiện đáng kể.

AIC và BIC:

$$\text{AIC} = -2\log(L) + 2k \quad \text{BIC} = -2\log(L) + k\log(n)$$

Áp dụng được cho mô hình không lồng nhau. $\Delta\text{AIC} > 2$ đã có ý nghĩa; BIC phạt nặng hơn cho số tham số, ưu tiên mô hình đơn giản hơn.

Tiêu chí	Ưu điểm	Hạn chế
ANOVA	Kiểm định chính xác, p -value rõ ràng	Chỉ cho mô hình lồng nhau
AIC	Linh hoạt, tốt cho dự báo	Có thể chọn mô hình quá phức tạp
BIC	Phạt nặng hơn, ưu tiên mô hình gọn	Đôi khi quá thận trọng

Cảnh báo quá khớp. Bậc đa thức hoặc số nút spline quá cao thường dẫn đến quá khớp. Ưu tiên mô hình đơn giản nhất mà vẫn giải thích được xu hướng chính; kiểm tra đồ thị phần dư sau khi chọn mô hình.

1.6.7 Đánh Giá Mô Hình Sau Khi Khắc Phục


Sau khi áp dụng biến đổi, thêm số hạng đa thức, hoặc dùng spline, cần xác minh rằng mô hình mới thực sự cải thiện. Dưới đây là năm công cụ đánh giá thường dùng.

1. **Đồ thị phần dư — kiểm tra trực quan đầu tiên.** Vẽ lại đồ thị phần dư theo giá trị khớp. Nếu phi tuyến đã được giải quyết, đồ thị trở thành “null plot”: phân tán ngẫu nhiên, đường LOESS nằm ngang gần $y = 0$. Đồng thời kiểm tra xem việc sửa chữa có làm lộ ra vi phạm khác (phương sai không đồng đều, điểm ngoại lai) hay không.
2. **Adjusted R^2 — trừng phạt độ phức tạp.** Khi thêm số hạng mới, R^2 thông thường luôn tăng (dù số hạng đó vô nghĩa). Adjusted R^2 hiệu chỉnh theo bậc tự do:
$$\bar{R}^2 = 1 - \frac{(1 - R^2)(n - 1)}{n - k - 1},$$
trong đó k là số biến dự báo. Nếu thêm bậc mà $\bar{R}^2$ giảm hoặc không đổi, số hạng đó không đóng góp thực sự.
3. **AIC và BIC — cân bằng độ khớp và độ phức tạp.** AIC và BIC đã trình bày ở trên. Chênh lệch $\Delta\text{AIC} > 2$ được coi là có ý nghĩa; BIC phạt nặng hơn nên ưu tiên mô hình gọn hơn khi cỡ mẫu lớn.
4. **Cross-validation — đánh giá khả năng dự báo thực sự.** Chia dữ liệu thành tập huấn luyện và tập kiểm tra; ước lượng tham số trên tập huấn luyện rồi đo sai số dự báo trên tập kiểm tra. k -fold CV (thường $k = 5$ hoặc 10) là lựa chọn phổ biến.
5. **PRESS (Prediction Sum of Squares) — leave-one-out.** PRESS tính tổng bình phương sai số dự báo khi lần lượt loại từng quan sát:

$$\text{PRESS} = \sum_{i=1}^n \left(\frac{e_i}{1 - h_{ii}} \right)^2,$$

với h_{ii} là đòn bẩy (leverage) của quan sát i . Công thức này không yêu cầu fit lại mô hình n lần. Mô hình có PRESS nhỏ hơn dự báo tốt hơn trên dữ liệu mới.

Minh họa trực quan: trước và sau khi sửa. Hình 13 so sánh mô hình tuyến tính (hàng trên) và đa thức bậc 2 (hàng dưới) trên bộ dữ liệu `mtcars` với biến phản hồi `mpg` và biến dự báo `hp`. Đồ thị phần dư ở cột giữa là tín hiệu rõ nhất: đường LOESS cong hình chữ U (mô hình tuyến tính) biến thành đường nằm ngang gần $y = 0$ (mô hình bậc 2).



Hình 13: So sánh mô hình tuyến tính (hàng trên) và đa thức bậc 2 (hàng dưới) trên `mtcars`. Cột trái: scatter và đường fit; cột giữa: phần dư theo giá trị khớp; cột phải: Q-Q plot. Đường LOESS hình chữ U trong panel (b) biến mất ở panel (e), xác nhận phi tuyến đã được khắc phục.

Bảng tổng hợp chỉ số đánh giá (dataset `mtcars`, $n = 32$):

Chỉ số	Linear	Quadratic	Cubic
R^2	0.602	0.756	0.761
Adj. R^2	0.589	0.739	0.735
AIC	181.2	167.6	169.0
BIC	185.6	173.5	176.3
PRESS	552.1	338.0	338.4

Diễn giải bảng. Mô hình bậc 2 cải thiện đáng kể so với tuyến tính: Adj. R^2 tăng từ 0.589 lên 0.739, AIC giảm ≈ 13.6 đơn vị, PRESS giảm từ 552 xuống 338 (giảm 39%). Mô hình bậc 3 không cải thiện thêm (Adj. R^2 giảm, AIC tăng nhẹ, PRESS gần như bằng nhau) — bằng chứng quá khớp tiềm năng. Mô hình bậc 2 là lựa chọn tốt nhất theo cả năm tiêu chí.

```

1 data(mtcars)
2 model_lin  <- lm(mpg ~ hp,                      data = mtcars)
3 model_quad <- lm(mpg ~ poly(hp, 2), data = mtcars)
4 model_cub  <- lm(mpg ~ poly(hp, 3), data = mtcars)

```

```

5
6 # Adj R2
7 sapply(list(model_lin, model_quad, model_cub),
8         function(m) round(summary(m)$adj.r.squared, 3))
9
10 # AIC / BIC
11 AIC(model_lin, model_quad, model_cub)
12 BIC(model_lin, model_quad, model_cub)
13
14 # PRESS (leave-one-out, không cần fit lại n lần)
15 press <- function(fit) sum((residuals(fit) / (1 -
16                             hatvalues(fit)))^2)
17 sapply(list(model_lin, model_quad, model_cub), press)

```

1.7 Ví Dụ R: Dataset mtcars

Bài toán: Dự báo lượng nhiên liệu tiêu thụ (mpg) từ công suất động cơ (hp). Liệu quan hệ này có tuyến tính không?

Bước 1: Khám phá dữ liệu và ước lượng mô hình tuyến tính

```

1 data(mtcars)
2
3 plot(mtcars$hp, mtcars$mpg,
4       xlab = "Horsepower (hp)", ylab = "Miles per gallon (mpg)",
5       main = "mpg vs hp", pch = 16, col = "steelblue")
6
7 model_linear <- lm(mpg ~ hp, data = mtcars)
8 abline(model_linear, col = "red", lwd = 2)
9
10 # Residual plot
11 par(mfrow = c(1, 2))
12 plot(model_linear, which = 1, main = "Residuals vs Fitted
13      (Linear)")
14 plot(model_linear, which = 2)

```

Quan sát. Đường LOESS trong đồ thị phần dư theo giá trị khớp có dạng cong (chữ U): vi phạm tuyến tính rõ ràng.

Bước 2: Fit model đa thức bậc 2 và bậc 3

```

1 model_quad <- lm(mpg ~ poly(hp, 2), data = mtcars)
2 model_cubic <- lm(mpg ~ poly(hp, 3), data = mtcars)
3 summary(model_quad)

```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	20.091	0.570	35.24	<2e-16 ***
poly(hp, 2)1	-26.045	3.225	-8.08	8.3e-09 ***
poly(hp, 2)2	8.720	3.225	2.70	0.011 *

Hệ số bậc 2 có ý nghĩa thống kê ($p = 0.011$) → quan hệ phi tuyến được xác nhận.

Bước 3: So sánh model bằng ANOVA và AIC/BIC

```

1 anova(model_linear, model_quad, model_cubic)
2 AIC(model_linear, model_quad, model_cubic)
3 BIC(model_linear, model_quad, model_cubic)

```

Analysis of Variance Table

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	30	447.67				
2	29	360.37	1	87.303	7.309	0.01149 *
3	28	334.55	1	25.816	2.161	0.15261

	df	AIC	df	BIC
model_linear	3	181.394	model_linear	3 185.887
model_quad	4	175.665	model_quad	4 181.653
model_cubic	5	175.880	model_cubic	5 183.364

<- nhỏ nhất

Diễn giải: Mô hình bậc 2 cải thiện đáng kể so với bậc 1 ($p = 0.011$). Mô hình bậc 3 không thêm giá trị ($p = 0.153$). Cả AIC và BIC đều chỉ mô hình bậc 2 là tốt nhất.

Bước 4: Trực quan hóa kết quả

```

1 hp_seq <- seq(min(mtcars$hp), max(mtcars$hp), length.out =
  200)
2 new_data <- data.frame(hp = hp_seq)
3
4 pred_linear <- predict(model_linear, newdata = new_data)
5 pred_quad <- predict(model_quad, newdata = new_data)

```

```

6 pred_cubic <- predict(model_cubic, newdata = new_data)
7
8 plot(mtcars$hp, mtcars$mpg,
9      xlab = "Horsepower (hp)", ylab = "mpg",
10     main = "So sánh Linear vs Polynomial", pch = 16, col =
11           "gray50")
12 lines(hp_seq, pred_linear, col = "red", lwd = 2, lty = 2)
13 lines(hp_seq, pred_quad, col = "blue", lwd = 2)
14 lines(hp_seq, pred_cubic, col = "green4", lwd = 2, lty = 3)
15
16 legend("topright",
17       legend = c("Linear", "Quadratic (AIC tot nhất)",
18                 "Cubic"),
19       col = c("red", "blue", "green4"), lwd = 2, lty = c(2, 1,
20                 3))

```

Kết luận phần 1. Quan hệ giữa hp và mpg là phi tuyến. Model đa thức bậc 2 cải thiện đáng kể so với model tuyến tính ($\Delta\text{AIC} \approx 5.7$, F-test $p < 0.05$) mà không làm tăng độ phức tạp quá mức.

1.8 Tính Chất Nâng Cao

Bốn kết quả lý thuyết sau giải thích tại sao tuyến tính trong tham số tạo ra sự đảm bảo mạnh mẽ hơn nhiều so với những gì các công cụ chẩn đoán thực hành gợi ý.

1.8.1 Chiều Trục Giao Lên Không Gian Dự Báo

Hình ảnh thông thường của hồi quy là một mặt phẳng qua dữ liệu ba chiều. Bức tranh sâu hơn sống trong không gian n chiều. Mỗi quan sát Y là một điểm trong $\mathbb{R}^n$. Các cột của ma trận thiết kế X trương ra một không gian con thấp chiều hơn—**không gian dự báo** (column space của X). Vì mô hình tuyến tính, tìm $\hat{\beta}$ tương đương với tìm điểm trong không gian dự báo *gần nhất* với Y :


$$\hat{Y} = X(X^\top X)^{-1}X^\top Y = P_X Y$$

trong đó P_X là ma trận chiếu trục giao lên $\text{Col}(X)$.


Vector sai số $e = Y - \hat{Y}$ trục giao với mọi cột của X —đây không phải xấp xỉ, mà là hệ quả hình học chính xác của OLS. Hệ phương trình chuẩn $X^\top e = 0$ chính là phát biểu

đại số của điều kiện trực giao này. Hầu hết lý thuyết mô hình tuyến tính—from định lý Gauss-Markov đến hình học kiểm định F —đều bắt nguồn trực tiếp từ cấu trúc chiếu trực giao này.

OLS = chiếu trực giao lên $\text{Col}(X)$



Kiểm tra $X^T e = 0$ (500 dataset ngẫu nhiên)



Hình 14: Trái: Sơ đồ hình học của OLS trong $\mathbb{R}^n$. Y là điểm quan sát, $\hat{Y} = P_X Y$ là hình chiếu vuông góc lên $\text{Col}(X)$, và $e = Y - \hat{Y}$ là vector sai số vuông góc với không gian dự báo. **Phải:** Xác minh số trên 500 dataset ngẫu nhiên ($n = 40$, $p = 3$). Giá trị $\log_{10} \|X^T e\|$ luôn ở mức sai số máy tính ($\approx 10^{-12}$), xác nhận $X^T e = 0$ là đẳng thức chính xác, không phải xấp xỉ.

1.8.2 Phân Phối Chuẩn Đa Biến Đảm Bảo Tuyến Tính

Tuyến tính thường là giả định làm việc về thế giới. Một trường hợp nó được đảm bảo bởi toán học: nếu biến phản hồi Y và các biến dự báo $X_1, \dots, X_p$ cùng tuân theo **phân phối chuẩn đa biến**, thì từ tính chất của phân phối chuẩn đa biến, phân phối có điều kiện là:

$$Y | X \sim \mathcal{N}(X\beta, \sigma^2)$$

Kỳ vọng có điều kiện $E[Y | X] = X\beta$ là tuyến tính trong X , và phương sai có điều kiện σ^2 là hằng số—cả hai đều bắt nguồn từ cấu trúc ma trận hiệp phương sai của phân phối chuẩn đa biến, không từ bất kỳ giả định ngoại sinh nào. Nếu dữ liệu có thể xuất từ phân phối chuẩn đa biến (kiểm tra bằng Q-Q plot đa biến hoặc kiểm định Mardia), không cần giả định tuyến tính riêng biệt.

1.8.3 Định Lý Li-Duan: Bền Vững Trước Phi Tuyến Ẩn


Giả sử quan hệ thực là phi tuyến nhưng có dạng chỉ số đơn:

$$E[Y | X] = g(\beta^T x)$$

trong đó g là hàm *hoàn toàn ẩn*. Bình thường điều này dường như làm mất hiệu lực OLS hoàn toàn. **Định lý Li-Duan (1989)** cho thấy điều ngược lại: nếu các biến dự báo X tuân theo phân phối đối xứng elip (bao gồm phân phối chuẩn đa biến), thì OLS vẫn ước lượng β **nhất quán đến một hằng số tỷ lệ**:

$$\hat{\beta}_{\text{OLS}} \xrightarrow{p} c \cdot \beta, \quad c \neq 0$$

Nói cách khác: ngay cả khi dạng hàm thực sự bị ẩn và phi tuyến, mô hình tuyến tính khớp một cách mù quáng vẫn phục hồi đúng *hướng* và *tầm quan trọng tương đối* của các biến dự báo. Độ lớn bị chia tỷ lệ, nhưng thứ hạng và dấu của tác động được bảo toàn.



Hình 15: Mô phỏng định lý Li-Duan ($n = 60$, $B = 800$ lần lặp). Mô hình thực: $Y = g(\beta^\top X) + \varepsilon$ với $\beta = (3, 1)^\top$ và $X \sim \mathcal{N}(0, I)$. Mỗi điểm là hướng ước lượng $\hat{\beta}/\|\hat{\beta}\|$ từ một lần lặp. Dấu “ $\times$ ” là hướng thực $\beta/\|\beta\|$. Ba hàm g khác nhau (tuyến tính, mũ, lũy thừa có dấu) đều cho đám mây điểm tập trung tại cùng một hướng thực—OLS phục hồi đúng hướng bất kể dạng hàm.

1.8.4 Bất Biến Trước Biến Đổi Tuyến Tính Toàn Hạng

Vì dự báo $\hat{Y}$ là chiếu trực giao của Y lên $\text{Col}(X)$, và $\text{Col}(X)$ không thay đổi khi nhân X với bất kỳ ma trận toàn hạng nào, ta có:

Định lý: Với mọi ma trận toàn hạng A ($k \times k$), mô hình $Y \sim XA$ cho ra các giá trị khớp $\hat{Y}$, phần dư e , và phương sai sai số s^2 *hoàn toàn giống* mô hình $Y \sim X$.

Hệ quả thực tiễn: Centering, scaling, và orthogonalization là các bước tiền xử lý *an toàn*—chúng thay đổi tham số hóa nhưng không bao giờ thay đổi dự báo hay R^2 .

Giải thích đa cộng tuyến: Đa cộng tuyến làm các hệ số riêng lẻ $\hat{\beta}_j$ không ổn định (vì $\hat{\beta}$ không bất biến với biến đổi tuyến tính), nhưng hoàn toàn không ảnh hưởng đến giá trị khớp $\hat{Y}$ hay khả năng dự báo tổng thể (vì $\hat{Y}$ bất biến).

```

1 # Xac minh: standardize X khong lam thay doi y_hat va R2
2 fit_raw <- lm(mpg ~ hp + wt + disp, data = mtcars)
3 fit_std <- lm(mpg ~ scale(hp) + scale(wt) + scale(disp), data
  = mtcars)
4
5 max(abs(fitted(fit_raw) - fitted(fit_std))) # < 1e-12
6 summary(fit_raw)$r.squared - summary(fit_std)$r.squared # = 0

```

```
[1] 1.065814e-13
```

```
[1] 0
```

2 Giả Định Tính Chuẩn Của Phần Dư

2.1 Cơ Sở Lý Thuyết

Mô hình hồi quy bội ở dạng ma trận được viết là:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad E(\mathbf{Y} | \mathbf{X}) = \mathbf{X}\boldsymbol{\beta}$$

Giả định chuẩn phát biểu rằng **sai số thật** tuân theo phân phối chuẩn đa biến:

$$\boldsymbol{\varepsilon} \sim \mathcal{N}_n(\mathbf{0}, \sigma^2 I)$$

Điểm quan trọng là giả định này thuộc về **sai số thật** $\boldsymbol{\varepsilon}$, không phải trực tiếp thuộc về biến phản hồi Y và cũng không phải trực tiếp thuộc về phần dư quan sát được sau khi khớp mô hình. Trong thực hành, ta không quan sát được $\boldsymbol{\varepsilon}$, nên phải dùng phần dư để chẩn đoán gián tiếp.

2.1.1 Sai Số Thật và Phần Dư Không Phải Là Một

Sai số thật ε_i là đại lượng lý thuyết, không quan sát được:

$$\varepsilon_i = y_i - E(Y_i | X_i)$$

Nó đo phần lệch giữa quan sát thực tế và giá trị kỳ vọng đúng của mô hình sinh dữ liệu.

Phần dư $\hat{e}_i$ là đại lượng tính được sau khi ước lượng mô hình:

$$\hat{e}_i = y_i - \hat{y}_i$$

Nó đo phần lệch giữa quan sát thực tế và giá trị dự đoán từ mô hình đã fit. Vì $\hat{y}_i$ phụ thuộc vào dữ liệu dùng để ước lượng $\hat{\beta}$, phần dư không còn giữ nguyên các tính chất xác suất của sai số thật.

Hệ quả thực tiễn. Khi ta vẽ histogram hoặc Q-Q plot của phần dư, ta không kiểm tra trực tiếp ε . Ta chỉ đang nhìn một phiên bản đã bị biến đổi bởi quá trình ước lượng OLS.

2.1.2 Không Bắt Buộc Đối Với Phương Pháp Bình Phương Tối Thiểu

Các hệ số $\hat{\beta}$ và phương sai s^2 có thể được tính bằng OLS mà không cần bất kỳ giả định nào về phân phối. Theo **Định lý Gauss-Markov**, chỉ cần sai số thỏa mãn các điều kiện chính:

- kỳ vọng bằng 0: $E(\varepsilon | \mathbf{X}) = \mathbf{0}$,
- phương sai không đổi: $\text{Var}(\varepsilon | \mathbf{X}) = \sigma^2 I$,
- không có tương quan giữa các sai số,

OLS đã cho các **ước lượng tuyến tính không chệch tốt nhất** (BLUE). Vì vậy, tính chuẩn không phải điều kiện để tính toán mô hình hay để OLS đạt tính chất BLUE.

2.1.3 Khi Thêm Giả Định Chuẩn: OLS Tương Đương MLE và Suy Diễn Chính Xác Hơn

Khi bổ sung $\varepsilon \sim \mathcal{N}_n(\mathbf{0}, \sigma^2 I)$, bài toán thay đổi theo ba hướng:

1. **Không tương quan $\Rightarrow$ độc lập.** Với phân phối chuẩn đa biến, không tương quan và độc lập là tương đương. Điều này mạnh hơn so với giả định Gauss-Markov thuần túy.
2. **OLS = MLE.** Dưới giả định chuẩn, hàm hợp lý (likelihood) của mô hình đạt cực đại tại đúng nghiệm OLS. Hai phương pháp cho cùng một ước lượng hệ số.
3. **Suy diễn mẫu nhỏ có phân phối chính xác.** Các kiểm định t , kiểm định F và khoảng tin cậy cổ điển có cơ sở phân phối rõ ràng thay vì chỉ dựa vào xấp xỉ tiệm cận.

2.1.4 Cơ Sở Bắt Buộc Cho Suy Diễn Mẫu Nhỏ

Mục đích lớn nhất của giả định chuẩn là thiết lập nền tảng toán học cho kiểm định giả thuyết và khoảng tin cậy, đặc biệt khi n nhỏ:

- Các tổng bình phương liên quan đến phần sai số tuân theo **phân phối** χ^2 .
- Tỷ số giữa các tổng bình phương thích hợp tuân theo **phân phối** F : cơ sở của kiểm định F -test tổng thể.
- Từng hệ số $\hat{\beta}_j$ sau khi chuẩn hóa bằng sai số chuẩn tuân theo **phân phối** t -**Student**: cơ sở của kiểm định t -test và khoảng tin cậy.

Nếu không có giả định chuẩn, cả t -test lẫn F -test đều mất cơ sở phân phối chính xác khi n nhỏ. Với mẫu lớn, Định lý Giới hạn Trung tâm thường giúp $\hat{\beta}$ xấp xỉ chuẩn vì chúng là tổ hợp tuyến tính của các quan sát; giả định chuẩn lúc này ít quan trọng hơn cho suy diễn hệ số.

2.1.5 Ma Trận Mũ: Vì Sao Phần Dư Bị Biến Dạng

Giá trị khớp của OLS có thể viết dưới dạng:

$$\hat{\mathbf{y}} = H\mathbf{y}, \quad H = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$$

trong đó H được gọi là **ma trận mũ** (hat matrix) vì nó biến $\mathbf{y}$ thành $\hat{\mathbf{y}}$.

Vector phần dư là:

$$\hat{\mathbf{e}} = \mathbf{y} - \hat{\mathbf{y}} = (I - H)\mathbf{y} = (I - H)\boldsymbol{\varepsilon}$$

phương trình cuối đúng vì $(I - H)\mathbf{X}\boldsymbol{\beta} = \mathbf{0}$.

Do đó, ngay cả khi sai số thật có ma trận hiệp phương sai $\text{Cov}(\boldsymbol{\varepsilon}) = \sigma^2 I$, phần dư lại có:

$$\text{Cov}(\hat{\mathbf{e}}) = \sigma^2(I - H)$$

Điều này dẫn đến hai hệ quả trực tiếp:

- Phương sai của phần dư thứ i là

$$\text{Var}(\hat{e}_i) = \sigma^2(1 - h_{ii}),$$

trong đó h_{ii} là leverage của quan sát thứ i . Điểm có leverage cao sẽ có phương sai phần dư nhỏ hơn.

- Các phần dư thường có tương quan với nhau vì các phần tử ngoài đường chéo của $I - H$ không nhất thiết bằng 0.

Hệ quả thực tiễn. Phần dư không phải một mẫu i.i.d. đơn giản từ phân phối của sai số thật. Những điểm leverage cao có thể có phần dư nhỏ dù chúng ảnh hưởng mạnh đến đường hồi quy, làm cho một số bất thường bị che khuất nếu chỉ nhìn phần dư thô.

2.1.6 Sự Siêu Chuẩn Của Phần Dư

Từ quan hệ $\hat{e} = (I - H)\varepsilon$, phần dư thứ i có thể viết là:

$$\hat{e}_i = \varepsilon_i - \sum_{j=1}^n h_{ij}\varepsilon_j$$

Nghĩa là mỗi phần dư không chỉ chứa sai số thật tại quan sát đó, mà còn trừ đi một tổ hợp tuyến tính của nhiều sai số khác thông qua hàng thứ i của ma trận H . Vì tổ hợp tuyến tính của nhiều biến ngẫu nhiên có thể trông gần chuẩn hơn từng biến gốc riêng lẻ, phần dư đôi khi có vẻ “chuẩn” hơn sai số thật. Hiện tượng này thường được gọi là **sự siêu chuẩn của phần dư** (Gnanadesikan, 1997).

Cần hiểu thận trọng. Đây không phải định lý nói rằng phần dư luôn chuẩn. Ý nghĩa thực tế là Q-Q plot hoặc histogram của phần dư có thể làm nhẹ bớt dấu hiệu không chuẩn của sai số thật, đặc biệt trong mẫu nhỏ đến trung bình. Vì vậy, chẩn đoán tính không chuẩn của sai số thật thông qua phần dư là một bài toán khó hơn vẻ bề ngoài.

2.1.7 Điểm Dễ Nhầm: Tính Chuẩn Của Y Không Phải Tính Chuẩn Của Sai Số

Sai lầm phổ biến. Nhiều người kiểm tra phân phối của Y thay vì kiểm tra phần sai lệch còn lại sau khi đã mô hình hóa $E(Y | X)$.

Ví dụ: $Y = 2X + \varepsilon$, với $X \sim \text{Uniform}(0, 10)$ và $\varepsilon \sim \mathcal{N}(0, 1)$. Biến Y sẽ không phân phối chuẩn, nhưng sai số thật vẫn chuẩn và phần dư từ mô hình đúng sẽ phản ánh điều đó ở mức xấp xỉ.

Quy tắc: Không yêu cầu Y chuẩn. Điều cần quan tâm là liệu phần nhiễu quanh hàm trung bình $E(Y | X)$ có phù hợp với giả định chuẩn hay không, và trong thực hành ta đánh giá điều này gián tiếp qua phần dư sau khi ước lượng mô hình.

Kết luận thực hành. Giả định chuẩn là giả định về sai số thật ϵ , nhưng ta chỉ quan sát được phần dư $\hat{e}$. Vì phần dư bị biến đổi bởi ma trận mũ, các đồ thị như histogram và Q-Q plot nên được xem là công cụ chẩn đoán tham khảo. Khi nghi ngờ vi phạm chuẩn tác ảnh hưởng đến suy diễn, các phương pháp như sai số chuẩn vững và bootstrap thường đáng tin cậy hơn việc chỉ dựa vào một kiểm định chuẩn tắc.

2.2 Công Cụ Trực Quan

Sau khi khớp mô hình, công cụ trực quan phổ biến nhất để đánh giá giả định chuẩn là các đồ thị của phần dư. Tuy nhiên, cần nhớ lại kết quả ở phần lý thuyết:

$$\hat{e} = (I - H)\epsilon$$

Ta muốn hiểu phân phối của sai số thật ϵ , nhưng chỉ quan sát được phần dư $\hat{e}$. Vì vậy, histogram và Q-Q plot là **công cụ chẩn đoán gián tiếp**: chúng rất hữu ích để phát hiện dấu hiệu bất thường, nhưng không phải bằng chứng tuyệt đối rằng sai số thật chuẩn hay không chuẩn.

2.2.1 Biểu Đồ Tần Suất Của Phần Dư

Histogram cho cái nhìn nhanh về hình dạng phân phối của phần dư. Các dấu hiệu thường gặp gồm:

- **Lệch phải hoặc lệch trái:** một đuôi dài hơn rõ rệt so với đuôi còn lại.
- **Đuôi nặng:** nhiều quan sát nằm xa trung tâm hơn so với phân phối chuẩn.
- **Đa đỉnh:** gợi ý dữ liệu có thể đến từ nhiều nhóm hoặc mô hình đang bỏ sót biến phân nhóm.
- **Ngoại lai:** một vài phần dư nằm rất xa phần còn lại của dữ liệu.

Điểm yếu của histogram là nó phụ thuộc mạnh vào số cột (bins), cỡ mẫu và thang đo. Với mẫu nhỏ, chỉ cần đổi số bins là hình dạng biểu đồ có thể thay đổi đáng kể. Vì vậy, histogram phù hợp như bước khảo sát ban đầu, nhưng không nên là bằng chứng chính khi kết luận về tính chuẩn.


2.2.2 Q-Q Plot: Công Cụ Chính Để Đọc Tính Chuẩn

Q-Q plot so sánh các phân vị thực nghiệm của phần dư với các phân vị lý thuyết của phân phối chuẩn. Nếu phần dư gần chuẩn, các điểm sẽ nằm gần một đường thẳng.

Nếu phân phối lệch, đuôi nặng hoặc có ngoại lai, các điểm sẽ tạo thành mẫu hình có hệ thống.

Lý do Q-Q plot thường hữu ích hơn histogram là nó tập trung trực tiếp vào quan hệ giữa **thứ tự phần dư quan sát được** và **phân vị chuẩn kỳ vọng**. Đây cũng là trực giác phía sau kiểm định Shapiro-Wilk: thống kê kiểm định đo mức độ khớp tuyến tính giữa các giá trị thứ tự quan sát được và giá trị kỳ vọng dưới chuẩn tắc. Q-Q plot chính là phiên bản trực quan của ý tưởng đó.

Mẫu hình trên Q-Q plot	Diễn giải thực hành
Các điểm gần đường thẳng	Phần dư phù hợp tương đối tốt với phân phối chuẩn
Đuôi phải lệch lên mạnh	Lệch phải; có phần dư dương lớn hơn chuẩn dự đoán
Đuôi trái lệch xuống mạnh	Lệch trái; có phần dư âm lớn hơn chuẩn dự đoán
Hai đầu lệch xa khỏi đường thẳng	Đuôi nặng; nhiều giá trị cực đoan hơn phân phối chuẩn
Hai đầu bị ép vào trong	Đuôi mỏng; ít giá trị cực đoan hơn phân phối chuẩn
Một vài điểm tách xa rõ rệt	Ngoại lai hoặc quan sát ảnh hưởng mạnh cần kiểm tra riêng



Hình 16: Bốn mẫu hình thường gặp khi đánh giá tính chuẩn của phần dư. Mỗi hàng gồm histogram và Q-Q plot cho cùng một tập phần dư mô phỏng. Q-Q plot làm nổi bật sai lệch ở đuôi rõ hơn histogram: lệch phải tạo đuôi dương cao hơn đường chuẩn, đuôi nặng làm hai đầu tách xa, và ngoại lai xuất hiện như một vài điểm rời khỏi mẫu hình chung.

2.2.3 Đọc Đồ Thị Cùng Leverage và Ngoại Lai

Một giới hạn quan trọng của đồ thị phần dư thô là phương sai của phần dư không hằng số:

$$\text{Var}(\hat{e}_i) = \sigma^2(1 - h_{ii})$$

trong đó h_{ii} là leverage của quan sát thứ i . Khi h_{ii} lớn, phương sai của phần dư nhỏ lại; điểm leverage cao có thể bị kéo về gần 0 trên đồ thị phần dư dù nó ảnh hưởng mạnh đến đường hồi quy.

Đây là **hiệu ứng che lấp**: histogram hoặc Q-Q plot của raw residuals có thể trông tương đối bình thường trong khi một vài quan sát leverage cao đang chi phối mô hình. Vì vậy, khi mục tiêu là chẩn đoán, nên xem thêm phần dư Student hóa ngoài:

```
1 fit <- lm(y ~ x1 + x2, data = dat)
2 res_student <- rstudent(fit)
3 qqnorm(res_student); qqline(res_student, col = "red", lwd = 2)
```

Phần dư Student hóa điều chỉnh theo leverage và sai số chuẩn ước lượng, nên phù hợp hơn raw residuals khi tìm ngoại lai hoặc quan sát bất thường.

2.2.4 Kết Luận Thực Hành

Cách đọc hợp lý. Dùng histogram để khảo sát nhanh hình dạng tổng quát, dùng Q-Q plot làm công cụ chính để đọc lệch chuẩn và đuôi phân phối. Nhưng mọi đồ thị phần dư đều là chẩn đoán gián tiếp vì ta không quan sát được sai số thật. Với mẫu nhỏ, dấu hiệu không chuẩn có thể khó phát hiện chắc chắn; với mẫu lớn, một chút lệch nhẹ ở hai đuôi không nhất thiết làm hỏng suy diễn hệ số. Nếu kết luận thống kê nhạy với giả định chuẩn, nên kiểm tra thêm sai số chuẩn vững hoặc bootstrap.

2.3 Kiểm Định Hình Thức

Kiểm định chuẩn tắc cung cấp một con số định lượng cho câu hỏi: phần dư có lệch khỏi phân phối chuẩn nhiều đến mức đáng chú ý hay không? Tuy nhiên, kiểm định không thay thế histogram và Q-Q plot. Một kiểm định có thể cho p -value rất nhỏ vì cỡ mẫu quá lớn, hoặc không phát hiện được vi phạm rõ ràng vì cỡ mẫu quá nhỏ.

Do đó, các kiểm định dưới đây nên được đọc như **bằng chứng bổ sung** cho chẩn đoán trực quan, không phải như một nút quyết định tự động.

2.3.1 Shapiro-Wilk Test

Shapiro-Wilk là kiểm định chuẩn tắc phổ biến cho mẫu nhỏ đến vừa. Giả thuyết kiểm định là:

H_0 : phần dư phù hợp với phân phối chuẩn,

H_1 : phần dư không phù hợp với phân phối chuẩn.

Thống kê $W \in [0, 1]$; W càng gần 1 thì phần dư càng gần mẫu hình chuẩn. Trực giác của kiểm định này rất gần với Q-Q plot: nó đo mức độ khớp tuyến tính giữa các giá trị phần dư đã sắp thứ tự và các phân vị kỳ vọng dưới phân phối chuẩn. Vì vậy, nếu Q-Q plot gần đường thẳng, W thường gần 1 và p -value thường lớn.

Khi dùng. Shapiro-Wilk hữu ích khi n nhỏ hoặc vừa, vì nó có khả năng phát hiện nhiều dạng lệch chuẩn tổng quát: lệch, đuôi nặng, đuôi mỏng, hoặc ngoại lai.

Giới hạn. Với mẫu lớn, kiểm định có thể bác bỏ H_0 vì những sai lệch rất nhỏ không quan trọng về mặt thực hành. Ngược lại, với mẫu quá nhỏ, kiểm định có thể thiếu power và không bác bỏ H_0 dù sai số thật không chuẩn. Vì vậy, p -value lớn không chứng minh rằng sai số thật chuẩn; nó chỉ nói rằng dữ liệu hiện tại chưa cung cấp đủ bằng chứng chống lại chuẩn tắc.

```
1 fit <- lm(y ~ x1 + x2, data = dat)
2 shapiro.test(residuals(fit))
```

2.3.2 Jarque-Bera Test

Jarque-Bera là kiểm định phổ biến trong kinh tế lượng, đặc biệt khi cỡ mẫu lớn. Kiểm định này không so sánh toàn bộ hình dạng phân phối như Shapiro-Wilk, mà tập trung vào hai moment đặc trưng của phân phối chuẩn:

- skewness bằng 0: phân phối đối xứng,
- excess kurtosis bằng 0: độ dày đuôi giống phân phối chuẩn.

Thống kê kiểm định là:

$$JB = \frac{n}{6} \left(S^2 + \frac{K^2}{4} \right) \sim \chi^2(2) \quad \text{dưới } H_0,$$

trong đó S là skewness mẫu và $K = \text{kurtosis} - 3$ là excess kurtosis.

Khi dùng. Jarque-Bera phù hợp hơn khi n đủ lớn để ước lượng skewness và kurtosis ổn định. Ưu điểm của nó là giúp chỉ ra nguồn vi phạm: nếu S^2 lớn, vấn đề chính là lệch phân phối; nếu K^2 lớn, vấn đề chính là đuôi nặng hoặc đuôi mỏng.

Giới hạn. Vì chỉ dựa trên moment bậc 3 và bậc 4, Jarque-Bera có thể bỏ sót những dạng lệch chuẩn không thể hiện rõ qua skewness hoặc kurtosis. Với mẫu nhỏ, ước lượng moment bậc cao thường không ổn định, nên kết quả dễ dao động.

```
1 library(tseries)
2 jarque.bera.test(residuals(fit))
```

2.3.3 Sự Khác Biệt Bản Chất Giữa Hai Kiểm Định

Hai kiểm định xuất phát từ hai triết lý khác nhau.

Shapiro-Wilk dựa trên tương quan thứ tự. Kiểm định này hỏi: các phân vị thực nghiệm của phần dư có xếp gần thành một đường thẳng khi so với phân vị chuẩn lý thuyết hay không? Vì vậy, nó là phiên bản định lượng của Q-Q plot và có tính tổng quát cao, nhưng không nói rõ nguồn vi phạm đến từ lệch hay đuôi.

Jarque-Bera dựa trên moment. Kiểm định này hỏi: phân phối phần dư có skewness và excess kurtosis giống phân phối chuẩn hay không? Vì vậy, nó ít tổng quát hơn nhưng diễn giải nguồn vi phạm rõ hơn.

Tiêu chí	Shapiro-Wilk	Jarque-Bera
Trực giác	Độ thẳng của Q-Q plot	Skewness và kurtosis
Cỡ mẫu phù hợp	Nhỏ đến vừa	Lớn
Loại sai lệch phát hiện	Tổng quát	Lệch và đuôi bất thường
Diễn giải nguồn vi phạm	Khó hơn	Rõ hơn qua S và K
R package	Base R	<code>tseries</code>
Vai trò chính	Chẩn đoán tổng thể	Chẩn đoán moment

2.3.4 Đọc p-value Theo Cỡ Mẫu và Mục Tiêu Suy Diễn

Sai lầm phổ biến là xem $p < 0.05$ như bằng chứng rằng mô hình hồi quy “hỏng”. Cách đọc đúng thận trọng hơn:

- **p -value nhỏ không làm OLS vô dụng.** OLS không cần giả định chuẩn để tính $\hat{\beta}$ hoặc để đạt tính chất BLUE dưới các điều kiện Gauss-Markov. Vấn đề chính nằm ở suy diễn mẫu nhỏ: kiểm định t , kiểm định F và khoảng tin cậy cổ điển.
- **p -value lớn không chứng minh chuẩn tắc.** Nó chỉ nói rằng kiểm định chưa tìm thấy bằng chứng đủ mạnh để bác bỏ H_0 . Với mẫu nhỏ, kiểm định có thể thiếu power.
- **Mẫu lớn dễ bác bỏ những sai lệch nhỏ.** Khi n lớn, kiểm định có thể phát hiện những khác biệt rất nhỏ so với chuẩn lý thuyết, dù khác biệt đó không làm thay đổi kết luận thực hành.

- **Mục tiêu phân tích quyết định mức nghiêm trọng.** Nếu chỉ cần ước lượng xu hướng trung bình hoặc dự báo, lệch nhẹ khỏi chuẩn có thể không đáng lo. Nếu cần suy diễn mẫu nhỏ chính xác, tính chuẩn quan trọng hơn nhiều.

Khuyến nghị. Luôn đọc kiểm định chuẩn tắc cùng Q-Q plot, histogram, cỡ mẫu và mục tiêu suy diễn. Nếu Q-Q plot chỉ lệch nhẹ ở mẫu lớn, không nên vội kết luận mô hình thất bại. Nếu mẫu nhỏ và kết luận phụ thuộc mạnh vào p -value hoặc khoảng tin cậy, nên cân nhắc sai số chuẩn vững, bootstrap hoặc mô hình phân phối phù hợp hơn.

2.4 Hậu Quả Khi Vi Phạm

Vi phạm giả định chuẩn không đồng nghĩa với việc mô hình hồi quy trở nên vô dụng. Nếu các điều kiện Gauss-Markov chính vẫn hợp lý, đặc biệt là $E(\boldsymbol{\varepsilon} \mid \mathbf{X}) = \mathbf{0}$ và phương sai sai số được mô hình hóa đúng, OLS vẫn là ước lượng tuyến tính không chệch tốt nhất (BLUE). Normality không phải điều kiện để tính $\hat{\boldsymbol{\beta}}$.

Vấn đề chính của nonnormality nằm ở **suy diễn thống kê**: p -value, khoảng tin cậy, khoảng dự báo và mức độ ổn định của kết luận, nhất là khi cỡ mẫu nhỏ hoặc khi phân phối có đuôi nặng.

2.4.1 Suy Diễn Mẫu Nhỏ Mất Phân Phối Chính Xác

Khi sai số thật chuẩn, các ước lượng hệ số có phân phối chuẩn kết hợp, các tổng bình phương liên quan đến sai số có phân phối χ^2 , và từ đó các thống kê t và F có phân phối chính xác như lý thuyết cổ điển. Đây là cơ sở của kiểm định hệ số, kiểm định tổng thể và khoảng tin cậy trong mẫu nhỏ.

Khi n nhỏ và sai số không chuẩn, chuỗi lập luận này bị đứt:

- thống kê t có thể không còn theo phân phối t -Student chính xác,
- thống kê F có thể không còn theo phân phối F chính xác,
- khoảng tin cậy dạng $\hat{\beta}_j \pm t^* \text{SE}(\hat{\beta}_j)$ có thể có độ phủ thực tế khác mức danh nghĩa,
- các suy diễn liên quan đến phương sai σ^2 mất cơ sở χ^2 chính xác (xem Mục 2.1.4).

Hệ quả thực hành. Với mẫu nhỏ, một Q-Q plot lệch mạnh hoặc kiểm định chuẩn tắc bác bỏ rõ ràng là tín hiệu cần thận trọng: kết luận dựa trên p -value cổ điển có thể quá lạc quan hoặc quá bảo thủ.

2.4.2 Đuôi Nặng và Ngoại Lai Làm Suy Diễn Kém Ổn Định

OLS tối thiểu hóa tổng bình phương phần dư:

$$\sum_{i=1}^n \hat{e}_i^2$$

Do phần dư bị bình phương, các quan sát nằm xa trung tâm được gán trọng số rất lớn trong hàm mục tiêu. Vì vậy, phân phối đuôi nặng hoặc một vài ngoại lai có thể ảnh hưởng mạnh đến đường hồi quy, sai số chuẩn và kết luận suy diễn.

Một quan sát cực đoan có thể:

- kéo lệch hệ số β ,
- làm phình to sai số chuẩn,
- thay đổi đáng kể p -value và khoảng tin cậy,
- làm mô hình trông kém chính xác hơn hoặc chính xác hơn một cách giả tạo.

Ví dụ kinh điển với dữ liệu Forbes cho thấy chỉ một quan sát ngoại lai có thể làm sai số chuẩn của hệ số thay đổi nhiều lần; khi loại bỏ case ngoại lai, sai số chuẩn giảm mạnh và phương sai ước lượng cũng giảm đáng kể. Thông điệp không phải là tùy tiện xóa điểm dữ liệu, mà là: **không nên tin một phân tích nếu kết luận phụ thuộc quá nặng vào một quan sát đơn lẻ.**

Trong thực hành, Q-Q plot có đuôi tách xa hoặc vài điểm cực đoan nên được xem cùng các chẩn đoán ảnh hưởng như leverage, phần dư Student hóa và Cook's distance:

```
1 rstudent(fit)      # phần dư Student hóa ngoại
2 hatvalues(fit)    # leverage  $h_{ii}$ 
3 cooks.distance(fit)
```

2.4.3 Không Chuẩn Có Thể Là Triệu Chứng Của Sai Mô Hình

Nonnormality không phải lúc nào cũng là vấn đề phân phối thuần túy. Nhiều khi nó là dấu hiệu cho thấy mô hình trung bình hoặc cấu trúc dữ liệu đang bị chỉ định sai.

Các nguyên nhân thường gặp gồm:

- **Sai dạng hàm trung bình:** thiếu số hạng bậc hai, tương tác, spline hoặc biến đổi log làm phần dư giữ lại mẫu hình có hệ thống.

- **Thiếu biến quan trọng:** phần dư trộn nhiều nhóm chưa được mô hình hóa, tạo lệch hoặc đa đỉnh.
- **Phương sai không đồng nhất:** độ phân tán tăng/giảm theo $\hat{y}$ hoặc theo một biến dự báo, làm phần dư có đuôi dày giả tạo.
- **Sai bản chất biến phản hồi:** dữ liệu đếm, nhị phân, tỷ lệ hoặc dữ liệu dương lệch mạnh thường không phù hợp với OLS trên thang gốc.

Với dữ liệu đếm hoặc nhị phân, vấn đề không chỉ là sai normality. Phương sai thường phụ thuộc vào kỳ vọng, nên giả định phương sai hằng số cũng bị vi phạm. Khi đó, mô hình tuyến tính tổng quát (GLM) như hồi quy Poisson hoặc logistic hợp lý hơn vì mô hình hóa đúng phân phối và hàm liên kết của phản hồi.

2.4.4 Mẫu Lớn Giảm Rủi Ro Nhưng Không Xóa Mọi Vấn Đề

Khi n đủ lớn, Định lý Giới hạn Trung tâm thường giúp $\hat{\beta}$ xấp xỉ chuẩn ngay cả khi sai số thật không chuẩn. Vì vậy, một kiểm định chuẩn tắc bị bác bỏ trong mẫu lớn không tự động làm suy diễn OLS thất bại.

Tuy nhiên, mẫu lớn không giải quyết mọi vấn đề:

- Nếu phương sai sai số không đồng nhất, ma trận hiệp phương sai cổ điển của $\hat{\beta}$ có thể bị tính sai; cần sai số chuẩn vững kiểu sandwich/HC.
- Nếu có điểm leverage cao hoặc quan sát ảnh hưởng mạnh, hệ số có thể bị kéo lệch dù n lớn.
- Nếu dạng hàm trung bình sai, tăng cỡ mẫu chỉ giúp ta ước lượng chính xác hơn một mô hình sai.

Hệ quả thực hành. Với mẫu lớn, hãy phân biệt giữa *ý nghĩa thống kê* và *ý nghĩa thực tế*. Một lệch nhẹ khỏi chuẩn có thể tạo p -value rất nhỏ trong kiểm định normality, nhưng điều quan trọng hơn là liệu kết luận hệ số, dự báo và khoảng tin cậy có nhạy với lệch đó hay không.

2.4.5 Bảng Tổng Hợp Cách Phản Ứng

Tình huống	Hậu quả chính	Phản ứng hợp lý
Mẫu nhỏ, Q-Q plot lệch mạnh	t -test, F -test và CI cổ điển mất cơ sở chính xác	Dùng bootstrap; báo cáo thận trọng
Mẫu lớn, lệch nhẹ ở đuôi	Kiểm định normality dễ reject dù tác động thực tế nhỏ	Giữ OLS nếu chẩn đoán khác ổn; kiểm tra độ nhạy
Đuôi nặng hoặc ngoại lai	Hệ số, SE và p -value có thể phụ thuộc vào vài điểm	Kiểm tra t -student, leverage, Cook's distance; cân nhắc robust regression
Lệch kèm mẫu hình phần dư	Có thể sai dạng hàm hoặc thiếu biến	Sửa mean function: biến đổi, đa thức, spline, tương tác
Đếm, nhị phân, tỷ lệ	OLS sai cả phân phối lẫn phương sai	Chuyển sang GLM như Poisson hoặc logistic
Phương sai không đồng nhất	SE cổ điển sai dù hệ số có thể vẫn hữu ích	Dùng HC3/sandwich SE hoặc mô hình hóa phương sai

Kết luận cốt lõi. Không chuẩn không tự động làm hỏng OLS. Nó chủ yếu làm ta nghi ngờ suy diễn cổ điển và buộc ta tìm nguyên nhân của sai lệch. Nếu chỉ cởi bỏ giả định chuẩn, OLS vẫn có thể là BLUE dưới Gauss-Markov; điều cần thay đổi là cách đo độ bất định, chẳng hạn dùng bootstrap, sai số chuẩn vững hoặc một mô hình phân phối phù hợp hơn.

2.5 Giải Pháp Thay Thế

Không có một cách sửa chung cho mọi vi phạm chuẩn tắc. Cách xử lý phụ thuộc vào nguyên nhân: mẫu nhỏ, phương sai không đồng nhất, đuôi nặng, ngoại lai, sai dạng hàm trung bình, hoặc biến phản hồi không phù hợp với mô hình Gaussian.

Nguyên tắc thực hành là: **nếu mean function hợp lý nhưng suy diễn không đáng tin, sửa cách đo độ bất định; nếu bản chất mô hình sai, đổi mô hình.**

2.5.1 Bản Đồ Chọn Phương Pháp

Tình huống	Mục tiêu	Phương pháp ưu tiên
OLS ổn, SE nghi ngờ	Giữ hệ số, sửa suy diễn	HC3/sandwich robust SE
Mẫu nhỏ, không chuẩn	CI/test không dựa vào normality	Bootstrap
Phản hồi dương, lệch phải	Làm ổn định phương sai và giảm lệch	Log, căn bậc hai, Box-Cox
Đuôi nặng, outlier chi phối	Giảm ảnh hưởng điểm cực đoan	Robust regression; phân tích độ nhạy
Count/binary/rate	Mô hình hóa đúng phân phối phản hồi	GLM: Poisson, logistic, binomial
Trung bình không đại diện tốt	Ước lượng median hoặc quantile	Quantile regression

2.5.2 Sai Số Chuẩn Vững HC3 / Sandwich

Nếu dạng hàm trung bình có vẻ hợp lý nhưng phần dư cho thấy phương sai không đồng nhất hoặc suy diễn cổ điển không đáng tin, không nhất thiết phải bỏ OLS. Có thể giữ nguyên hệ số β và thay cách ước lượng ma trận hiệp phương sai.

Sai số chuẩn vững kiểu sandwich, đặc biệt HC3, điều chỉnh sai số chuẩn bằng cách dùng phần dư và leverage của từng quan sát. Ý tưởng thực hành là:

- hệ số OLS giữ nguyên,
- sai số chuẩn được tính lại,
- p -value và khoảng tin cậy được cập nhật theo sai số chuẩn mới.

HC3 thường được khuyến nghị khi mẫu không quá lớn vì nó phạt mạnh các quan sát leverage cao hơn các phiên bản HC đơn giản.

```
1 library(sandwich)
2 library(lmtest)
3
4 fit <- lm(y ~ x1 + x2, data = dat)
5 coeftest(fit, vcov = vcovHC(fit, type = "HC3"))
```

Khi dùng. HC3 phù hợp khi mục tiêu chính là suy diễn hệ số trong mô hình tuyến tính đã chọn, nhưng nghi ngờ SE cổ điển bị sai do heteroskedasticity hoặc leverage.

Giới hạn. HC3 không sửa sai dạng hàm trung bình, không loại bỏ ảnh hưởng ngoại lai lên hệ số, và không biến OLS thành mô hình phù hợp cho dữ liệu đếm hoặc nhị phân.

2.5.3 Bootstrap

Bootstrap thay phân phối lý thuyết bằng phân phối thực nghiệm thu được từ lấy mẫu lại. Thay vì giả định $\hat{\beta}_j$ có phân phối t chính xác, ta mô phỏng nhiều lần quá trình ước lượng để xem hệ số biến động như thế nào.

Có hai cách thường dùng:

- **Case bootstrap:** lấy mẫu có hoàn lại các cặp (X_i, Y_i) . Phù hợp khi muốn ít giả định hơn về cấu trúc sai số.
- **Residual bootstrap:** lấy mẫu có hoàn lại từ phần dư, rồi cộng lại vào giá trị khớp. Phù hợp hơn khi tin rằng mean function đã đúng và sai số có cấu trúc tương đối đồng nhất.

```
1 library(boot)
2
3 boot_fn <- function(data, indices) {
4   coef(lm(y ~ x1 + x2, data = data[indices, ]))
5 }
6
7 set.seed(123)
8 boot_out <- boot(dat, boot_fn, R = 2000)
9 boot.ci(boot_out, type = c("perc", "bca"), index = 2)
```

Khi dùng. Bootstrap đặc biệt hữu ích với mẫu nhỏ hoặc vừa, khi Q-Q plot và kiểm định cho thấy normality đáng nghi, nhưng vẫn muốn báo cáo CI/test cho hệ số.

Giới hạn. Bootstrap không cứu được dữ liệu xấu hoặc mô hình sai nặng. Nếu mẫu gốc không đại diện, có outlier chi phối, hoặc mean function sai, bootstrap sẽ mô phỏng lại chính các vấn đề đó.

2.5.4 Biến Đổi Biến Phản Hồi

Khi biến phản hồi dương và lệch phải mạnh, hoặc khi phương sai tăng theo trung bình, biến đổi Y có thể làm phân phối phần dư gần chuẩn hơn và phương sai ổn định hơn.

Các lựa chọn phổ biến:

Tình huống	Biến đổi	Ghi chú
Dữ liệu dương, trải rộng nhiều bậc	$\log(Y)$	Diễn giải theo phần trăm thay đổi
Dữ liệu đếm vừa phải	$\sqrt{Y}$	Làm dịu lệch phải và phương sai tăng
Không rõ biến đổi	Box-Cox	Tìm λ bằng likelihood

Box-Cox định nghĩa họ biến đổi:

$$y^{(\lambda)} = \begin{cases} (y^\lambda - 1)/\lambda, & \lambda \neq 0, \\ \log(y), & \lambda = 0. \end{cases}$$

```
1 library(MASS)
2 boxcox(fit)
3 fit_log <- lm(log(y) ~ x1 + x2, data = dat)
```

Khi dùng. Biến đổi phù hợp khi vấn đề xuất phát từ thang đo của phản hồi: lệch phải, phương sai tăng theo mean, hoặc quan hệ nhân tính.

Giới hạn. Sau biến đổi, mô hình đang giải thích $E[\log(Y) | X]$ hoặc $E[Y^{(\lambda)} | X]$, không còn trực tiếp là $E[Y | X]$. Khi diễn giải hoặc dự báo ngược về thang gốc, cần cẩn thận với bias do biến đổi ngược.

2.5.5 Mô Hình Tuyến Tính Tổng Quát (GLM)

Nếu biến phản hồi có bản chất không Gaussian, việc cố sửa normality bằng biến đổi hoặc robust SE thường chỉ là vá triệu chứng. Với dữ liệu nhị phân, đếm hoặc tỷ lệ, cần mô hình hóa đúng quan hệ giữa kỳ vọng và phương sai.

GLM thay giả định $Y \sim \mathcal{N}$ bằng một họ phân phối phù hợp hơn và dùng hàm liên kết:

$$g(E[Y | X]) = X\beta$$

Kiểu phản hồi	Mô hình	R
Nhị phân 0/1	Logistic regression	<code>glm(..., family = binomial)</code>
Số đếm	Poisson regression	<code>glm(..., family = poisson)</code>
Tỷ lệ / số thành công	Binomial GLM	<code>glm(cbind(success, fail) ..., binomial)</code>

Khi dùng. GLM là lựa chọn đúng khi OLS tạo dự báo ngoài miền hợp lệ, ví dụ xác suất nhỏ hơn 0 hoặc lớn hơn 1, hoặc khi phương sai phản hồi phụ thuộc rõ vào trung

bình.

2.5.6 Robust Regression

Khi Q-Q plot cho thấy đuôi nặng hoặc một vài quan sát cực đoan chi phối kết quả, robust regression là một lựa chọn thực hành để giảm ảnh hưởng của outlier mà không xóa điểm một cách tùy tiện.

Khác với OLS, vốn phạt phần dư theo bình phương, nhiều phương pháp robust dùng hàm mất mát tăng chậm hơn ở đuôi. Nhờ vậy, một quan sát rất xa không còn đủ sức kéo toàn bộ đường fit như trong OLS.

```
1 library(MASS)
2 fit_robust <- rlm(y ~ x1 + x2, data = dat)
3 summary(fit_robust)
```

Khi dùng. Robust regression phù hợp khi kết luận OLS thay đổi mạnh sau khi kiểm tra Cook's distance, leverage hoặc phần dư Student hóa.

Giới hạn. Đây không phải lý do để bỏ qua việc hiểu outlier. Trước khi dùng robust regression, cần kiểm tra liệu điểm bất thường là lỗi dữ liệu, quan sát hợp lệ hiếm gặp, hay dấu hiệu mô hình thiếu biến.

2.5.7 Quantile Regression

Quantile regression là lựa chọn bổ sung khi trung bình không đại diện tốt cho phân phối có lệch mạnh hoặc đuôi nặng. Thay vì mô hình hóa kỳ vọng có điều kiện $E[Y | X]$, nó mô hình hóa median hoặc các phân vị khác của $Y | X$.

Với median regression, mục tiêu gần với việc tối thiểu hóa tổng trị tuyệt đối phần dư thay vì tổng bình phương phần dư. Vì vậy, median ít bị kéo bởi các điểm cực đoan hơn mean.

```
1 library(quantreg)
2 fit_med <- rq(y ~ x1 + x2, tau = 0.5, data = dat)
3 summary(fit_med)
```

Khi dùng. Dùng khi câu hỏi nghiên cứu quan tâm median hoặc phân vị, ví dụ tác động của X lên nhóm giá trị thấp/cao, hoặc khi mean bị chi phối bởi đuôi phân phối.

Giới hạn. Quantile regression trả lời một câu hỏi khác OLS. Không nên dùng nó chỉ để “sửa” OLS nếu mục tiêu thật sự vẫn là kỳ vọng trung bình.

Quy tắc chọn nhanh. Nếu mean function ổn nhưng SE đáng nghi, dùng HC3 hoặc bootstrap. Nếu phản hồi dương và lệch mạnh, cân nhắc biến đổi. Nếu dữ liệu là count/binary/rate, chuyển sang GLM. Nếu một vài điểm cực đoan chi phối kết luận, kiểm tra ảnh hưởng và làm phân tích robust/sensitivity. Nếu trung bình không còn là đại lượng đại diện tốt, cân nhắc quantile regression.

2.6 Ví Dụ R: Dataset Boston

Bài toán. Dự báo giá trị nhà trung vị (`medv`) từ tỷ lệ dân cư thu nhập thấp (`lstat`) và số phòng trung bình (`rm`):


$$\text{medv} = \beta_0 + \beta_1 \text{lstat} + \beta_2 \text{rm} + \varepsilon.$$

Mục tiêu của ví dụ này không chỉ là kiểm tra xem phần dư có chuẩn hay không. Với $n = 506$, các kiểm định chuẩn tắc rất dễ bác bỏ H_0 . Câu hỏi thực hành quan trọng hơn là: **kết luận về hệ số có ổn định khi thay suy diễn OLS cổ điển bằng HC3 và bootstrap hay không?**

Bước 1: Fit mô hình và vẽ chẩn đoán

```
1 library(MASS)
2 data(Boston)
3
4 model_boston <- lm(medv ~ lstat + rm, data = Boston)
5 resid_raw    <- residuals(model_boston)
6 resid_stud   <- rstudent(model_boston)
```

Boston housing: chẩn đoán chuẩn tắc của phần dư



Hình 17: Chẩn đoán chuẩn tắc cho mô hình $\text{medv} \sim \text{lstat} + \text{rm}$. Hàng trên dùng raw residuals; hàng dưới dùng phần dư Student hóa ngoài. Cả hai Q-Q plot đều cho thấy đuôi phải lệch mạnh khỏi đường chuẩn, tức có một số giá trị nhà được dự báo thấp hơn thực tế khá nhiều.

Quan sát. Histogram và Q-Q plot đều cho thấy phần dư lệch phải và có đuôi dày. Phần dư Student hóa làm tín hiệu ở đuôi rõ hơn vì đã điều chỉnh phương sai phần dư theo leverage.

Bước 2: Kiểm định hình thức

```
1 shapiro.test(resid_raw)
2
3 # Jarque-Bera tính thu công: skewness + excess kurtosis
4 n <- length(resid_raw)
5 z <- resid_raw - mean(resid_raw)
6 m2 <- mean(z^2)
7 S <- mean(z^3) / m2^(3/2)
8 K <- mean(z^4) / m2^2 - 3
```

```

9 JB <- n / 6 * (S^2 + K^2 / 4)
10 pchisq(JB, df = 2, lower.tail = FALSE)

```

```

Shapiro-Wilk: W = 0.9098, p-value < 2.2e-16
Jarque-Bera : JB = 457.6899, p-value = 4.11e-100
Skewness    : S = 1.3432
Excess kurt.: K = 3.8068

```

Cả hai kiểm định đều bác bỏ chuẩn tắc rất mạnh. Với $n = 506$, điều này không bất ngờ: kiểm định có power lớn và phát hiện được cả những sai lệch nhỏ. Ở đây sai lệch không chỉ nhỏ; Q-Q plot cho thấy đuôi phải rõ ràng. Vì vậy, ta chuyển sang kiểm tra độ nhạy của suy diễn hệ số.

Bước 3: OLS SE, HC3 SE và Bootstrap CI

Đoạn code sau tính HC3 thủ công để không phụ thuộc vào package ngoài. Ý tưởng là giữ nguyên hệ số OLS, nhưng thay ma trận hiệp phương sai cổ điển bằng sandwich estimator có hiệu chỉnh leverage.

```

1 X      <- model.matrix(model_boston)
2 e      <- residuals(model_boston)
3 h      <- hatvalues(model_boston)
4 XtX_inv <- solve(t(X) %*% X)
5
6 meat <- t(X) %*% diag(as.numeric(e^2 / (1 - h)^2)) %*% X
7 V_hc3 <- XtX_inv %*% meat %*% XtX_inv
8 se_hc3 <- sqrt(diag(V_hc3))
9
10 # Case bootstrap cho hệ số
11 library(boot)
12 boot_fn <- function(data, indices) {
13   coef(lm(medv ~ lstat + rm, data = data[indices, ]))
14 }
15 set.seed(123)
16 boot_out <- boot(Boston, boot_fn, R = 2000)

```

Biến	Estimate	OLS SE	HC3 SE	Tỷ lệ	OLS 95% CI	Bootstrap 95% CI
lstat	-0.6424	0.0437	0.0654	1.50	[-0.7283, -0.5564]	[-0.7628, -0.5152]
rm	5.0948	0.4445	0.7939	1.79	[4.2216, 5.9680]	[3.5423, 6.5887]

Diễn giải. HC3 SE lớn hơn OLS SE khá rõ: khoảng 1.5 lần cho lstat và 1.79 lần cho

`rm`. Bootstrap CI cũng rộng hơn OLS CI và khá gần với suy diễn robust. Tuy vậy, dấu và độ lớn thực hành của hai hệ số vẫn ổn định: `lstat` có quan hệ âm với `medv`, còn `rm` có quan hệ dương.

Bước 4: Kiểm tra ảnh hưởng

```
1 max(abs(rstudent(model_boston)))
2 max(cooks.distance(model_boston))
3 max(hatvalues(model_boston))
```

```
max |rstudent| = 5.2869
max Cook's D   = 0.2566
max leverage   = 0.0633
```

Có phần dư Student hóa rất lớn, nên đuôi phải trên Q-Q plot không chỉ là chi tiết hình thức. Tuy nhiên, leverage lớn nhất không quá cao trong mô hình hai biến này. Workflow hợp lý là báo cáo suy diễn robust/bootstráp và, nếu đây là phân tích chính thức, kiểm tra thêm các quan sát có Cook's distance lớn hoặc cân nhắc biến đổi/mô hình linh hoạt hơn.

Kết Luận Ví Dụ

Bài học từ Boston. Kiểm định chuẩn tắc bác bỏ rất mạnh, nhưng kết luận không phải là “vứt mô hình OLS”. Với $n = 506$, cần nhìn vào độ nhạy của suy diễn: HC3 và bootstrap làm khoảng tin cậy rộng hơn đáng kể, nhưng không đổi kết luận định tính về `lstat` và `rm`. Vì vậy, báo cáo tốt hơn là: mô hình OLS cho xu hướng rõ ràng, nhưng suy diễn nên dùng robust SE hoặc bootstrap CI thay vì chỉ dựa vào SE cổ điển.

Tổng Kết

Sau hai nhóm giả định, điểm quan trọng nhất không phải là ghi nhớ thêm nhiều kiểm định, mà là biết **giả định nào đang bảo vệ phần nào của phân tích**. Giả định tuyến tính bảo vệ hàm trung bình và bản thân hệ số OLS. Giả định chuẩn tắc chủ yếu bảo vệ suy diễn mẫu nhỏ: t -test, F -test, p-value và khoảng tin cậy cổ điển.

	Giả định tuyến tính	Giả định chuẩn tắc
Phát biểu	$E(Y X)$ được mô tả đúng bởi dạng tuyến tính đã chọn.	Sai số thật ε có phân phối chuẩn, thường viết $\varepsilon \sim N(0, \sigma^2 I)$.
Nếu vi phạm	Hệ số có thể chệch vì mô hình sai hàm trung bình.	OLS không tự động hỏng, nhưng suy diễn cổ điển có thể kém tin cậy, nhất là mẫu nhỏ.
Chẩn đoán chính	Residuals vs fitted, component-plus-residual plots, kiểm tra dạng hàm.	Q-Q plot, histogram, Shapiro-Wilk, Jarque-Bera, kiểm tra đuôi và ngoại lai.
Cần xem thêm	Biến thiếu, tương tác, phi tuyến, leverage.	Cỡ mẫu, leverage, outlier, heteroskedasticity, mục tiêu suy diễn.
Phản ứng hợp lý	Đổi mean function: thêm biến, biến đổi, đa thức, spline hoặc mô hình phù hợp hơn.	Dùng HC3, bootstrap, biến đổi, GLM, robust regression hoặc quantile regression tùy nguyên nhân.

Quy Tắc Thực Hành

Một workflow kỷ luật nên đi theo thứ tự sau:

1. Kiểm tra dạng hàm trung bình trước. Nếu residual plot còn pattern rõ ràng, đừng vội bàn sâu về normality.
2. Dùng Q-Q plot để đọc hình dạng vi phạm: lệch, đuôi nặng, outlier hay chỉ vài điểm ở đuôi.
3. Dùng kiểm định chuẩn tắc như bằng chứng bổ sung, không dùng p-value như nút bịt/tắt chất lượng mô hình.
4. Nếu normality bị reject, hỏi tiếp: mẫu nhỏ hay lớn, hệ số có ổn định không, HC3/Bootstrap CI có đổi kết luận không.
5. Nếu kết luận phụ thuộc vào một vài quan sát, kiểm tra leverage, Cook's distance và cân nhắc robust regression hoặc mô hình khác.

Thông điệp cuối. OLS không cần normality để tính hệ số. Normality là giả định thêm để suy diễn cổ điển hoạt động chính xác trong mẫu nhỏ. Khi giả định này yếu đi, ta không vứt mô hình ngay; ta kiểm tra nguyên nhân, đánh giá hậu quả và dùng công cụ suy diễn phù hợp hơn như HC3 hoặc bootstrap.