

Phân tích các yếu tố liên hệ với quyết định nghỉ việc

IBM HR Employee Attrition



Học viên thực hiện

Nguyễn Nhật Quang Lê Hoàng Như Phạm Đoàn Vĩnh Nghi

Môn học: Mô hình hoá thống kê

Giảng viên: TS. Nguyễn Thị Mộng Ngọc

Giới thiệu dữ liệu ban đầu

Nguồn và đơn vị quan sát

IBM HR Analytics Employee Attrition & Performance

Nguồn công bố: Kaggle (2017); dữ liệu mô phỏng phục vụ phân tích nhân sự. Mỗi dòng tương ứng một nhân viên.

1.470

bản ghi

35

cột ban đầu

Cấu trúc: 34 thuộc tính giải thích và 1 biến mục tiêu. Dữ liệu không có giá trị khuyết.

Biến mục tiêu

Attrition: **Yes** = đã nghỉ việc; **No** = còn làm việc.

Mục tiêu bài làm

- 1 Khám phá chân dung và các yếu tố liên hệ với nghỉ việc.
- 2 Xây dựng, so sánh Logistic và LASSO trên dữ liệu ngoài mẫu.
- 3 Chuyển kết quả thành cảnh báo sớm và khuyến nghị giữ chân.

Loại 3 biến hằng và 1 mã định danh; còn 30 biến dự báo trước khi mã hóa dummy. Kết quả phản ánh liên hệ dự báo, không tự chứng minh quan hệ nhân quả.

35 biến ban đầu (1/3): Biến mục tiêu và những đặc điểm cá nhân

Biến	Ý nghĩa	Biến	Ý nghĩa
Attrition	Biến phản hồi: nghỉ việc (Yes/No).	EducationField	Chuyên ngành/lĩnh vực đào tạo.
Age	Tuổi của nhân viên.	DistanceFromHome	Khoảng cách từ nhà đến nơi làm việc.
Gender	Giới tính.	EmployeeNumber	Mã định danh nhân viên; loại khỏi mô hình.
MaritalStatus	Tình trạng hôn nhân.	EmployeeCount	Biến hằng bằng 1; không cung cấp thông tin.
Education	Trình độ học vấn, thang thứ bậc 1–5.	Over18	Biến hằng Yes; toàn bộ nhân viên trên 18 tuổi.

Vai trò trong phân tích: Attrition là biến cần dự báo; mã định danh và biến hằng được loại vì không giải thích sự khác biệt giữa các nhân viên.

35 biến ban đầu (2/3): Công việc và đãi ngộ

Biến	Ý nghĩa	Biến	Ý nghĩa
BusinessTravel	Mức độ thường xuyên đi công tác.	MonthlyIncome	Thu nhập hàng tháng.
Department	Phòng ban làm việc.	DailyRate	Chỉ số mức chi trả/quy đổi theo ngày.
JobRole	Chức danh/vai trò công việc.	HourlyRate	Chỉ số mức chi trả/quy đổi theo giờ.
JobLevel	Cấp bậc công việc, từ 1 đến 5.	MonthlyRate	Chỉ số mức chi trả/quy đổi theo tháng.
JobInvolvement	Mức độ tham gia công việc, thang 1–4.	PercentSalaryHike	Tỷ lệ tăng lương gần nhất (%).
OverTime	Có thường xuyên làm thêm giờ hay không.	StockOptionLevel	Mức quyền chọn cổ phiếu, từ 0 đến 3.
StandardHours	Số giờ chuẩn; biến hằng bằng 80.		


MonthlyIncome phản ánh thu nhập trực tiếp; ba biến Rate là các chỉ số riêng trong dữ liệu mô phỏng và không nên tự động diễn giải như lương thực nhận.

35 biến ban đầu (3/3): Trải nghiệm và thâm niên

Biến	Ý nghĩa	Biến	Ý nghĩa
EnvironmentSatisfaction	Hài lòng với môi trường, thang 1–4.	TotalWorkingYears	Tổng số năm kinh nghiệm làm việc.
JobSatisfaction	Hài lòng với công việc, thang 1–4.	NumCompaniesWorked	Số công ty từng làm việc.
RelationshipSatisfaction	Hài lòng với quan hệ tại nơi làm việc, thang 1–4.	YearsAtCompany	Số năm làm tại công ty hiện tại.
WorkLifeBalance	Cân bằng công việc–cuộc sống, thang 1–4.	YearsInCurrentRole	Số năm ở vai trò hiện tại.
PerformanceRating	Mức đánh giá hiệu suất; dữ liệu chủ yếu ở mức 3–4.	YearsSinceLastPromotion	Số năm kể từ lần thăng chức gần nhất.
TrainingTimesLastYear	Số lần đào tạo trong năm gần nhất.	YearsWithCurrManager	Số năm làm việc với quản lý hiện tại.

Các thang 1–4/1–5 là biến thứ bậc; giá trị lớn hơn biểu thị mức cao hơn, nhưng khoảng cách giữa hai mức không nhất thiết hoàn toàn bằng nhau.

Phân bố biến mục tiêu: nghỉ việc chiếm 16,12%



1.470

nhân viên

35

biến ban đầu

Dữ liệu mô phỏng IBM HR Analytics

Không có giá trị khuyết; loại ba biến hằng và một mã định danh.

Luôn dự báo “ở lại” đã đạt **83,88% accuracy**, nhưng phát hiện **0%** ca nghỉ việc.

⇒ Ưu tiên **AUC**, **sensitivity**, **precision** và **F1**.

Nguồn: IBM HR Analytics Employee Attrition & Performance (Kaggle, 2017); dữ liệu mô phỏng.

Bài toán quản trị: phát hiện sớm, không gấn nhãn

① Nhận diện chân dung rủi ro

Ai thường nghỉ việc và tín hiệu nào đáng chú ý?

② Dự báo ngoài mẫu

Mô hình nào cân bằng giữa hiệu suất và khả năng giải thích?

③ Chuyển thành hành động HR

Can thiệp vào điều kiện có thể cải thiện, không dùng mô hình để tự động ra quyết định bất lợi.

Biến phản hồi


Attrition

Yes = đã nghỉ việc

No = còn làm việc


Kết quả phản ánh liên hệ dự báo,
không tự thân chứng minh nhân
quả.

Quy trình phân tích: sáu bước đã thực hiện




Mỗi bước có kiểm chứng đi kèm: kiểm định giả định trước khi chọn phép kiểm, VIF/GVIF cho đa cộng tuyến, 10-fold CV cho λ , và ngưỡng quyết định được khảo sát bằng ba tiêu chí.

Phân tích nhân khẩu học: tuổi và tình trạng hôn nhân




Đỉnh mật độ nghỉ việc tập trung ở nhóm 28–31 tuổi.




Hồ sơ mô tả ban đầu: nhân sự trẻ và độc thân có tính linh hoạt nghề nghiệp cao hơn; đây là **tín hiệu liên hệ**, không phải nguyên nhân hay tiêu chí để tự động đánh giá cá nhân.

Thu nhập và khoảng cách đi làm



Trung vị: **Yes: 3.202 USD** **No: 5.204 USD**

Wilcoxon: $W = 191601$, $p = 2,95 \times 10^{-14}$.




Trung bình: **10,6** so với **8,9**.

Kiểm định t hai mẫu: $p = 0,0028$.

Nhóm nghỉ việc có phân phối thu nhập thấp hơn và quãng đường đi làm dài hơn. Hai khác biệt này định hướng mô hình đa biến, chưa tự chứng minh tiền lương hay khoảng cách là nguyên nhân trực tiếp.


Điều kiện công việc: làm thêm giờ và mức độ hài lòng

Tỷ lệ nghỉ việc theo Làm thêm giờ (OverTime)



Pearson $\chi^2 = 87,56$, $p < 0,001$.


Tỷ lệ nghỉ việc theo Mức độ hài lòng




Mức 1: Job Satisfaction **22,84%**; Environment Satisfaction **25,35%**.

Có OT: 30,53% nghỉ việc; không OT: 10,44%. Tỷ lệ cao gần gấp ba lần, trong khi hài lòng thấp cũng đi cùng rủi ro lớn hơn — đây là các yếu tố doanh nghiệp có thể can thiệp.

Phòng ban và chức danh có tỷ lệ nghỉ việc cao



Pearson $\chi^2 = 10,80$, $p = 0,0045$.



Chân dung rủi ro từ EDA: nhân sự trẻ, độc thân, thuộc Sales hoặc các vai trò Sales Representative/Laboratory Technician/HR, thường làm OT và có thu nhập thấp hơn. Hồ sơ này chỉ dùng để định hướng mô hình và khảo sát giữ chân.

Tiền xử lý dữ liệu: bốn quyết định chính

1. Loại biến không mang thông tin

Ba biến hằng (EmployeeCount, Over18, StandardHours) và mã định danh EmployeeNumber — phương sai bằng 0, không có giá trị dự báo.

2. Dữ liệu khuyết: không có

0 giá trị NA trên toàn bộ 1.470 quan sát $\Rightarrow$ không cần các phép gán thay thế (imputation).

3. Giới hạn ngoại lệ thu nhập


MonthlyIncome lệch phải (trung bình 6.503 > trung vị 4.919 USD): capping tại $Q_1 - 1,5 \text{ IQR}$ và $Q_3 + 1,5 \text{ IQR}$ thay vì xóa quan sát.

4. Chuẩn hóa và mã hóa

Z-score cho tuổi và thu nhập; biến phân loại dummy hóa full rank ($K - 1$ cột, có nhóm tham chiếu).

Mọi tham số tiền xử lý (ngưỡng capping, μ , σ , bộ mã hóa dummy) đều được **fit lại chỉ trên tập train** — thiết kế chống rò rỉ ở slide tiếp theo.

Thiết kế đánh giá ngoài mẫu, hạn chế rò rỉ dữ liệu



1.030

tập huấn luyện

440

tập kiểm thử

10-fold

CV chọn λ LASSO

Ba đặc tả hồi quy logistic được so sánh

1. Nhân khẩu học

Biến: tuổi, giới tính, hôn nhân, khoảng cách, học vấn.

AUC test: 0,656

2. Công việc

Biến: chức danh, hài lòng, làm thêm giờ, thu nhập.

AUC test: 0,785

3. LASSO (phạt L_1)

Biến: toàn bộ 30 biến gốc; giữ 35 hệ số $\neq 0$.

AUC test: 0,854

Cùng biến phản hồi $Y_i = 1$ nếu nhân viên nghỉ việc, cả ba mô hình hóa $p_i = P(Y_i = 1 \mid \mathbf{x}_i)$:

$$\log\left(\frac{p_i}{1 - p_i}\right) = \beta_0 + \sum_j \beta_j x_{ij}.$$

Công thức của hai mô hình logistic không phạt

Đặt $p_i = P(\text{Attrition}_i = \text{Yes} \mid \mathbf{x}_i)$ và $\text{logit}(p_i) = \log[p_i/(1 - p_i)]$.

Mô hình 1: nhân khẩu học

$$\text{logit}(p_i) = \beta_0 + \beta_1 \text{AgeScaled}_i + \beta_2^\top \text{Gender}_i + \beta_3^\top \text{MaritalStatus}_i + \beta_4 \text{Distance}_i + \beta_5 \text{Education}_i.$$

Mô hình 2: công việc và môi trường

$$\begin{aligned} \text{logit}(p_i) = & \alpha_0 + \alpha_1^\top \text{JobRole}_i + \alpha_2 \text{EnvironmentSatisfaction}_i \\ & + \alpha_3 \text{JobSatisfaction}_i + \alpha_4 \text{OverTime}_i + \alpha_5 \text{IncomeScaled}_i. \end{aligned}$$

Chữ đậm biểu thị một nhóm hệ số dummy. Nhóm tham chiếu lần lượt gồm nữ, đã ly hôn, Healthcare Representative và không làm thêm giờ.

Kết quả đặc tả đầu: mô hình công việc còn Department

Biến	α	SE	z	p
Hằng số	-14,89	954,6	-0,016	0,988
Department: Research & Development	13,43	954,6	0,014	0,989
Department: Sales	-0,2340	1.082,0	0,000	0,9998
JobRole: Human Resources	14,83	954,6	0,016	0,988
JobRole: Laboratory Technician	1,6410	0,5027	3,264	0,001
JobRole: Manager	-0,4037	0,9284	-0,435	0,664
JobRole: Manufacturing Director	0,1588	0,5439	0,290	0,770
JobRole: Research Director	-1,6270	1,1540	-1,403	0,159
JobRole: Research Scientist	0,7135	0,5156	1,384	0,166
JobRole: Sales Executive	14,64	510,1	0,029	0,977
JobRole: Sales Representative	15,92	510,1	0,031	0,975
Hài lòng môi trường	-0,3613	0,0866	-4,172	< 0,001
Hài lòng công việc	-0,2813	0,0831	-3,384	< 0,001
Làm thêm giờ	1,5420	0,1950	7,908	< 0,001
Thu nhập chuẩn hóa	-0,0039	0,2135	-0,018	0,986

Nguồn: `summary(model_2)` của đặc tả có Department (mục 2.3 báo cáo); Fisher scoring: **15 vòng** (bình thường 5–6). Các dòng tô nền có hệ số và sai số chuẩn bất thường trong khi các biến còn lại vẫn lành mạnh — chẩn đoán ở slide tiếp theo.

Chẩn đoán đa cộng tuyến cấu trúc ở mô hình công việc

Dấu hiệu bất thường trong output

$\beta \approx 13-16$: OR hàng triệu lần, phi thực tế.

$SE \approx 510-1.082$: CI chứa mọi giá trị.

$p \rightarrow 1$ ở chính các biến quan trọng.

Fisher scoring 15 vòng (bình thường 5-6).

Nguyên nhân

Department lồng trong JobRole: mọi Sales Executive đều thuộc Sales $\Rightarrow$ thông tin trùng lặp gần hoàn hảo.

Xử lý

Loại Department, giữ JobRole — biến chi tiết hơn, đã bao phủ thông tin phòng ban.

Sau khi sửa

Hội tụ sau 6 vòng; AIC 783,18 $\rightarrow$ 781,32; GVIF lớn nhất $\approx 2,94 < 5$.

Mô hình nhân khẩu học cũng được kiểm tra tương tự: GVIF lớn nhất $\approx 1,10$. Bảng VIF/GVIF đầy đủ ở phần backup.

GVIF mô hình công việc: trước và sau khi loại Department

Trước: có Department

Biến	VIF	GVIF
Department	—	$3,8 \times 10^{13}$
JobRole	—	$1,1 \times 10^{14}$
EnvironmentSatisfaction	1,042	1,042
JobSatisfaction	1,014	1,014
OverTime	1,088	1,088
Income_scaled	2,772	2,772

Sau: đã loại Department

Biến	VIF	GVIF
JobRole	—	2,935
EnvironmentSatisfaction	1,042	1,042
JobSatisfaction	1,013	1,013
OverTime	1,090	1,090
Income_scaled	2,816	2,816

Giá trị lớn nhất giảm từ cỡ 10^{14} xuống **2,94**, dưới ngưỡng tham khảo **5**. Các biến không liên quan hầu như không đổi — cộng tuyến khu trú đúng cặp Department–JobRole.

VIF chỉ định nghĩa cho biến một bậc tự do (khi đó GVIF trùng VIF); biến phân loại nhiều mức phải dùng GVIF.

Kết quả hồi quy logistic nhân khẩu học

Biến	$\hat{\beta}$	SE	z	p
Hằng số	-2,4969	0,3718	-6,716	< 0,001
Tuổi chuẩn hóa	-0,3905	0,0983	-3,972	< 0,001
Nam	0,2795	0,1827	1,529	0,126
Đã kết hôn	-0,1142	0,2558	-0,446	0,655
Độc thân	0,9057	0,2441	3,710	< 0,001
Khoảng cách từ nhà	0,0304	0,0104	2,932	0,003
Học vấn	0,0021	0,0887	0,024	0,981


AIC = 858,89; AUC test = 0,656. Ở mức 5%, tuổi, độc thân và khoảng cách từ nhà có hệ số khác 0; đây là liên hệ có điều kiện, không phải quan hệ nhân quả.

Kết quả logistic công việc và môi trường

Biến	$\hat{\alpha}$	SE	z	p
Hằng số	-1,4438	0,5113	-2,824	0,005
Human Resources	1,3988	0,5932	2,358	0,018
Laboratory Technician	1,6364	0,5028	3,255	0,001
Manager	-0,9600	0,9165	-1,047	0,295
Manufacturing Director	0,1578	0,5439	0,290	0,772
Research Director	-1,6197	1,1541	-1,403	0,160
Research Scientist	0,7086	0,5157	1,374	0,169
Sales Executive	0,9770	0,4471	2,185	0,029
Sales Representative	2,2515	0,5613	4,011	< 0,001
Hài lòng môi trường	-0,3619	0,0866	-4,180	< 0,001
Hài lòng công việc	-0,2847	0,0832	-3,424	0,001
Làm thêm giờ	1,5420	0,1951	7,904	< 0,001
Thu nhập chuẩn hóa	-0,0086	0,2138	-0,040	0,968

AIC = 781,32; AUC test = 0,785. Nhóm tham chiếu của JobRole là Healthcare Representative; Department đã bị loại do phụ thuộc cấu trúc với JobRole.

LASSO: chọn λ bằng 10-fold cross-validation



$$\lambda_{\min} \approx 0,0030$$

$\log \lambda \approx -5,80$; giữ **35** hệ số $\neq 0$.

Dùng cho mọi dự báo: ưu tiên sai số CV nhỏ nhất.

$$\lambda_{1se}$$

$\log \lambda \approx -4,49$; còn **29** biến.

Đối chứng gọn hơn nếu ưu tiên triển khai đơn giản.

Lí do nhóm chọn Lasso: Ma trận dummy lớn; tuổi, thâm niên, cấp bậc, thu nhập tương quan — phạt L1 vừa co hệ số vừa chọn biến.

Yếu tố công việc cung cấp tín hiệu mạnh nhất

Làm thêm giờ

Odds nghỉ việc cao gấp **4,67 lần**.

Hài lòng môi trường

Tăng một bậc $\Rightarrow$ odds giảm **30,3%**.

Hài lòng công việc

Tăng một bậc $\Rightarrow$ odds giảm **24,8%**.

Lưu ý: Odds ratio lấy từ logistic công việc và phụ thuộc nhóm tham chiếu

Chức danh cần theo dõi

Laboratory Technician

Sales Representative

Sales Executive

Human Resources

Thu nhập khác biệt rõ ở EDA nhưng không còn ý nghĩa sau khi kiểm soát chức danh và điều kiện công việc ($p = 0,968$).


LASSO cho kết quả ngoài mẫu tốt nhất

Mô hình	AUC	Acc.	Sens.
Nhân khẩu học	0,656	0,809	0,197
Công việc	0,785	0,818	0,465
LASSO	0,854	0,866	0,648
Random Forest	0,796	0,827	0,479
GBDT	0,841	0,859	0,465


0,575
precision LASSO

0,609
F1 LASSO

Kết quả trên cùng tập test, ngưỡng 0,30.



Chọn ngưỡng quyết định 0,30 bằng tiêu chí F1



0,30

Cực đại F1 = 0,609

Sensitivity: **64,8%**

Specificity: **90,8%**

Vì sao không dùng 0,5?

Lớp nghỉ việc chỉ chiếm 16%: ngưỡng mặc định bỏ sót phần lớn ca rủi ro. Hạ ngưỡng giúp tăng khả năng phát hiện.

Tiêu chí thay thế (Youden, hàm chi phí) cho ngưỡng thấp hơn, $\approx 0,17$ — chi tiết ở phụ lục B3.

Từ mô hình đến hành động HR

1. Kiểm soát làm thêm giờ

Theo dõi OT theo nhóm, phân bổ lại tải việc và đo lường kiệt sức định kỳ.

2. Can thiệp theo chức danh

Stay interview và khảo sát ẩn danh cho các vai trò có tín hiệu rủi ro cao.

3. Cải thiện trải nghiệm

Theo dõi hài lòng, lộ trình nghề nghiệp, đào tạo và cơ hội luân chuyển nội bộ.

4. Cảnh báo sớm có giám sát

Chấm điểm định kỳ, hiệu chỉnh ngưỡng bằng chi phí thực tế và luôn yêu cầu HR rà soát.

Không dùng điểm rủi ro để kỷ luật hoặc sa thải tự động. Kiểm tra fairness, quyền riêng tư và cơ sở pháp lý trước khi triển khai.

Giới hạn cần xử lý trước khi triển khai

Tính đại diện

Dữ liệu mô phỏng, lát cắt và không có thời gian đến khi nghỉ việc; chưa thể khái quát cho doanh nghiệp cụ thể.

Đánh giá hiệu suất

Ngưỡng đang được khảo sát trên test; cần chọn trong validation hoặc nested cross-validation.

Độ tin cậy xác suất

Bổ sung PR-AUC, Brier score, calibration curve và khoảng tin cậy bootstrap cho AUC.

Quản trị mô hình

Kiểm định trên dữ liệu thật, theo dõi drift, fairness và hiệu chỉnh ngưỡng theo chi phí vận hành.

Ba kết luận chính

- ❶ **Điều kiện công việc quan trọng hơn nhân khẩu học:**
làm thêm giờ, sự hài lòng và chức danh tạo tín hiệu dự báo rõ nhất.
- ❷ **LASSO là lựa chọn cân bằng nhất:**
 $AUC = 0,854$, $sensitivity = 64,8\%$, $F1 = 0,609$ tại ngưỡng 0,30.
- ❸ **Mô hình là công cụ hỗ trợ can thiệp:**
ưu tiên cải thiện tải việc và trải nghiệm nhân viên, không tự động gắn nhãn hay ra quyết định bất lợi.

Cảm ơn Thầy/Cô và các bạn!

Câu hỏi & thảo luận

Backup — Hỏi & đáp

Các slide sau chỉ dùng khi thảo luận.

B1. Kiểm tra đa cộng tuyến: VIF/GVIF chi tiết

Mô hình nhân khẩu học

Biến	VIF	GVIF
Age_scaled	1,101	1,101
Gender	1,011	1,011
MaritalStatus	—	1,023
DistanceFromHome	1,008	1,008
Education	1,090	1,090

Mô hình công việc (đã loại Department)

Biến	VIF	GVIF
JobRole	—	2,935
EnvironmentSatisfaction	1,042	1,042
JobSatisfaction	1,013	1,013
OverTime	1,090	1,090
Income_scaled	2,816	2,816


Tất cả dưới ngưỡng tham khảo 5. Lưu ý: VIF thấp cho biết không có cộng tuyến tuyến tính mạnh giữa các biến giải thích, nhưng không đồng nghĩa chúng độc lập thống kê hoàn toàn.

B2. Mô hình phi tuyến: Random Forest và GBM

	AUC	Acc.	Sens.	Prec.	F1
LASSO	0,854	0,866	0,648	0,575	0,609
RF (classwt 1:5)	0,796	0,827	0,479	0,466	0,472
GBM	0,841	0,859	0,465	0,579	0,516

RF: 300 cây, nodesize 5, trọng số lớp 1:5.

GBM: 150 cây, depth 3, shrinkage 0,05, 5-fold CV.



Lưu ý: chú giải ROC trong HTML ghi cứng RF AUC = 0,802; bảng kết quả tính trực tiếp cho 0,796, được dùng trong slide.

B3. Ba tiêu chí chọn ngưỡng quyết định

Quét ngưỡng $0,05 \rightarrow 0,80$ (bước $0,01$) trên xác suất LASSO của tập test:

- ❶ **Tối đa F1** $\Rightarrow$ ngưỡng **0,30** ($F1 = 0,609$)
- ❷ **Youden's J** ($Sens + Spec - 1$) $\Rightarrow$ ngưỡng **0,17**
- ❸ **Tối thiểu chi phí** với giả định $FN = 15.000$ USD, $FP = 1.000$ USD $\Rightarrow$ ngưỡng **0,17**

Kết luận: không có ngưỡng tối ưu duy nhất cho mọi mục tiêu — lựa chọn phụ thuộc chi phí sai sót của tổ chức.

Chi phí FN/FP là giả định minh họa (tham khảo chi phí thay thế nhân sự); khi triển khai cần hiệu chỉnh bằng chi phí thực và chọn ngưỡng trên tập validation, không phải test.

B4. Mất cân bằng lớp và độ tin cậy ước lượng

Đã xử lý bằng gì?

Chia phân tầng giữ tỷ lệ 16,12% ở cả hai tập; hạ ngưỡng về 0,30; đánh giá bằng AUC, sensitivity, F1 thay cho accuracy; trọng số lớp 1:5 trong Random Forest.

Vì sao chưa SMOTE/ROSE?

Giữ phân phối gốc để xác suất dự báo phản ánh tỷ lệ thật; mẫu tổng hợp có rủi ro thêm nhiễu. Đây là hướng cải thiện đã nêu trong báo cáo, không phải thiếu sót bị bỏ qua.

Giới hạn thừa nhận

Kết quả dựa trên một lần chia 70/30 (seed 123) — các chỉ số là ước lượng điểm. Khoảng tin cậy 95% cho accuracy LASSO: [0,830; 0,896].

Hướng nâng cấp: repeated k-fold CV cho toàn pipeline, bootstrap CI cho AUC, và so sánh có kiểm định (DeLong) giữa các mô hình.

B5. Ma trận nhầm lẫn LASSO trên test (ngưỡng 0,30)

	Thực: No	Thực: Yes
Dự báo No	335 (TN)	25 (FN)
Dự báo Yes	34 (FP)	46 (TP)

Tập test $n = 440$ (369 No / 71 Yes)

- Sensitivity (recall): $46/71 = \mathbf{64,8\%}$
- Specificity: $335/369 = \mathbf{90,8\%}$
- Precision: $46/80 = \mathbf{57,5\%}$; F1 = **0,609**
- Accuracy: **86,6%**, CI 95% [0,830; 0,896]; Kappa = 0,529
- Balanced accuracy: 77,8%

Bỏ sót 25/71 ca nghỉ việc — lý do cân nhắc ngưỡng 0,17 cho tăng theo dõi rộng (chấp nhận thêm false positive).

B6. Vì sao chọn các phương pháp này?

- **Logistic làm trực chính, không phải ML thuần:** hệ số $\rightarrow$ odds ratio diễn giải được cho HR; và thực nghiệm cho thấy LASSO thắng cả RF/GBM về AUC trên bộ dữ liệu này.
- $\lambda_{\min}$ **thay vì** λ_{1se} : mục tiêu chính là năng lực dự báo; λ_{1se} (29 biến) được báo cáo làm đối chứng cho phương án triển khai gọn.
- **Không dùng stepwise:** chọn biến từng bước không ổn định và làm sai lệch suy luận sau chọn biến; phạt L1 của LASSO là cách chọn biến có kiểm soát chính quy hóa, chọn bằng CV.
- **Chia 70/30 phân tầng, seed cố định:** giữ nguyên tỷ lệ lớp hiếm ở hai tập và bảo đảm tái lập được toàn bộ kết quả.
- **Kiểm định phi tham số (Wilcoxon):** Shapiro–Wilk bác bỏ tính chuẩn của thu nhập trong nhóm nghỉ việc nên không dùng t-test.

B7. LASSO giữ biến nào tại $\lambda_{\min}$?

Hệ số dương lớn nhất (tăng nguy cơ)

BusinessTravel: Frequently	+1,77
OverTime: Yes	+1,67
JobRole: Sales Representative	+1,08
MaritalStatus: Single	+0,95
JobRole: Laboratory Technician	+0,94
JobRole: Human Resources	+0,92

Hệ số âm lớn nhất (giảm nguy cơ)

JobRole: Research Director	-0,93
JobInvolvement	-0,39
EnvironmentSatisfaction	-0,38
JobSatisfaction	-0,34
JobRole: Manager	-0,31
WorkLifeBalance	-0,27

Tổng cộng 35 hệ số $\neq 0$. Thu nhập bị co về đúng 0 — nhất quán với $p = 0,968$ ở mô hình công việc. Hệ số trên thang biến chuẩn hóa/dummy, tái lập từ pipeline với seed 123.

B8. AIC và các giả định cần kiểm tra

Cách đọc AIC

$$AIC = -2 \log(\widehat{L}) + 2k$$

AIC cân bằng độ phù hợp và độ phức tạp;
càng thấp càng tốt khi so sánh mô hình
dùng cùng dữ liệu và biến phản hồi.

Mô hình công việc: 781,32, thấp hơn mô
hình nhân khẩu học 858,89. LASSO không
dùng AIC truyền thống trong phân tích này
vì hàm mục tiêu chứa hình phạt L_1 ; λ được
chọn bằng cross-validation.

Đã đáp ứng hoặc đã kiểm tra

- Phản hồi nhị phân Yes/No.
- Không có đa cộng tuyến nghiêm trọng sau khi bỏ Department; GVIF hiệu chỉnh < 5 .
- Mô hình hội tụ và không còn dấu hiệu hệ số suy biến.

Chưa thể khẳng định hoàn toàn

- Độc lập quan sát nếu nhân viên cùng nhóm/quản lý.
- Tuyến tính giữa biến liên tục và log-odds (cần spline, GAM hoặc Box–Tidwell).
- Calibration của xác suất (cần Brier score và calibration curve).