

Môn học: MÔ HÌNH HÓA THỐNG KÊ

Đồ án kết thúc học phần

Yêu cầu:

- Học viên thực hiện bài làm của mình theo danh sách nhóm đã đăng ký. Các nhóm phải làm việc độc lập, bài làm nào sao chép lẫn nhau sẽ chia đều số điểm cho các thành viên liên quan.
- Mỗi nhóm nộp bài trên hệ thống Moodle trước **23h59 ngày 30/07/2026**. Hệ thống sẽ tự động khóa sau thời hạn trên, do đó các bài nộp trễ sẽ không được chấp nhận. Giảng viên không nhận bài gửi qua email.
- Mỗi nhóm chỉ nộp một file nén (.zip) bao gồm các tệp sau:
 - 01 file báo cáo định dạng PDF (đặt tên: **NhomXX-DoAn.pdf**);
 - 01 thư mục (hoặc file nén) chứa toàn bộ mã nguồn (.R, .Rmd hoặc .html);
 - 01 thư mục (hoặc file nén) chứa toàn bộ các bộ dữ liệu được sử dụng trong bài.
- Báo cáo cần trình bày đầy đủ các nội dung sau: Trang bìa; Mục lục; Đề bài; Giới thiệu bộ dữ liệu và nguồn dữ liệu; Phương pháp và kết quả phân tích; Hình vẽ, bảng biểu và phần diễn giải kết quả; Kết luận; Tài liệu tham khảo.
- Mỗi nhóm cần trình bày rõ bảng phân công công việc của các thành viên (nhóm nào không có bảng phân công sẽ bị trừ 2 điểm), nêu cụ thể nhiệm vụ của từng thành viên và tự đánh giá mức độ hoàn thành công việc.
- Báo cáo phải được trình bày khoa học, rõ ràng, đồng thời trích dẫn đầy đủ các tài liệu và nguồn dữ liệu đã sử dụng, với độ dài không được vượt quá 80 trang (không tính phụ lục).
- Báo cáo cần nêu rõ các giả định của mô hình thống kê, cách kiểm định các giả định và diễn giải ý nghĩa thống kê cũng như ý nghĩa thực tiễn của các kết quả thu được.
- Tất cả các kết quả phân tích phải được thực hiện bằng phần mềm R; báo cáo cần trình bày đầy đủ mã lệnh (R code) trong phụ lục để đảm bảo tính tái lập của kết quả.

1. Hoạt động 1 (7 điểm)

1. Dự đoán tỷ lệ tội phạm bạo lực trong các cộng đồng ở Hoa Kỳ dựa trên các đặc điểm nhân khẩu học, kinh tế và xã hội.

Bộ dữ liệu Communities and Crime được công bố bởi UCI Machine Learning Repository. Dữ liệu tổng hợp thông tin của các cộng đồng tại Hoa Kỳ từ nhiều nguồn khác nhau, bao gồm: Điều tra dân số Hoa Kỳ năm 1990 (1990 U.S. Census); Khảo sát về quản lý và tổ chức lực lượng thực thi pháp luật (1990 U.S. Law Enforcement Management and Administrative Statistics - LEMAS); Dữ liệu tội phạm của FBI Uniform Crime Reports (UCR) năm 1995. Bộ dữ liệu được xây dựng nhằm nghiên cứu mối quan hệ giữa các đặc điểm kinh tế - xã hội, nhân khẩu học, hoạt động của lực lượng cảnh sát và tỷ lệ tội phạm trong các cộng đồng.

Trong bộ dữ liệu "communities.data" có 1994 quan sát (cộng đồng) và 128 biến, trong đó có 4 biến định danh (state, county, community, communityname), 123 biến mô tả các đặc điểm kinh tế, xã hội, nhân khẩu học và lực lượng cảnh sát, và 01 biến phản hồi ViolentCrimesPerPop, biểu thị tỷ lệ tội phạm bạo lực trên đầu người. Ý nghĩa của các biến được mô tả trong tập tin *communities.names*.

Yêu cầu:

- (a) Khám phá dữ liệu (EDA) và thực hiện tiền xử lý dữ liệu.
- (b) Chia dữ liệu thành tập huấn luyện và tập kiểm định.
- (c) Sử dụng phương pháp hồi quy trên thành phần chính (PCR) để dự đoán tỷ lệ tội phạm bạo lực của cộng đồng (thực hiện đầy đủ các bước: kiểm tra độ phù hợp của bộ dữ liệu với phương pháp, chọn PC phù hợp,...).
- (d) Xây dựng các mô hình hồi quy tuyến tính (OLS), Ridge Regression và LASSO trên cùng bộ dữ liệu.
- (e) Đánh giá và so sánh các mô hình trên tập validation bằng các chỉ số RMSE, MAE và R^2 .
- (f) Phân tích các thành phần chính thông qua ma trận tải (loadings) và thảo luận về ý nghĩa của các nhóm biến ảnh hưởng đến tỷ lệ tội phạm.
- (g) Chuyển các hệ số hồi quy của mô hình PCR từ không gian các thành phần chính về không gian các biến gốc và diễn giải ảnh hưởng của các biến đến tỷ lệ tội phạm bạo lực của cộng đồng.

(h) Thảo luận ưu điểm và hạn chế của PCR, OLS, Ridge Regression và LASSO trong bối cảnh dữ liệu có nhiều biến và hiện tượng đa cộng tuyến. Từ đó đề xuất mô hình phù hợp nhất.

(i) Kết luận và đề xuất hướng cải thiện mô hình (nếu có).

Lưu ý: Trước khi xây dựng mô hình, hãy thực hiện tiền xử lý dữ liệu thích hợp (ví dụ: xử lý dữ liệu khuyết, loại bỏ các biến định danh hoặc các biến không phù hợp với mô hình hồi quy).

2. Mức lương ở các vị trí việc làm trong lĩnh vực khoa học dữ liệu

Hãy phân tích khám phá dữ liệu (EDA) và xây dựng các mô hình dự đoán, đánh giá những yếu tố ảnh hưởng đến mức lương ở các vị trí việc làm trong lĩnh vực khoa học dữ liệu trên phạm vi toàn cầu từ bộ dữ liệu "Data Science Job Salaries" thu thập từ nền tảng Kaggle (<https://www.kaggle.com/datasets/ruchi798/data-science-job-salaries?resource=download>) được cho trong tập tin "ds-salaries.csv" gồm 607 quan trắc và 11 biến sau:

- "work-year": Năm mà mức lương đó được trả;
- "experience-level": Mức độ kinh nghiệm, gồm 4 mức: EN (mới vào), MI (trung cấp), SE (cao cấp), EX (cấp điều hành);
- "employment-type": Hình thức làm việc, gồm 4 hình thức: FT (full time), PT (part-time), CT (hợp đồng), FL (freelance);
- "job-title": chức danh công việc (lưu ý: nên gom nhóm các công việc lại như DA, DS, DE, ... trước khi phân tích và mô hình hoá);
- "salary": Mức lương đã trả;
- "salary-currency": Đơn vị tiền tệ của lương;
- "salary-in-usd": Mức lương đổi qua USD;
- "employee-residence": Mã Quốc gia cư trú chính của người lao động, ghi theo chuẩn ISO;
- "remote-ratio": Tỷ lệ làm việc từ xa, có 3 mức: 0% không làm việc từ xa, 50% làm việc từ xa 1 phần, 100% hoàn toàn làm việc từ xa;
- "company-location": Mã Quốc gia đặt trụ sở công ty, ghi theo chuẩn ISO;
- "company-size": Quy mô công ty, gồm 3 mức: S (dưới 50 nhân viên), M (từ 50 đến 250 nhân viên), L (từ 250 nhân viên trở đi).

Yêu cầu:

- (a) Thực hiện tiền xử lý dữ liệu (xử lý dữ liệu khuyết, chuẩn hóa dữ liệu nếu cần, mã hóa các biến phân loại, gộp các nhóm nghề nghiệp hợp lý, ...).
- (b) Thực hiện phân tích khám phá dữ liệu (EDA), bao gồm thống kê mô tả và trực quan hóa dữ liệu.
- (c) Lựa chọn và giải thích các phương pháp phân tích thống kê phù hợp để:
 - i. phân tích các yếu tố ảnh hưởng đến mức lương;
 - ii. so sánh mức lương giữa các nhóm nghề nghiệp, mức kinh nghiệm, quy mô công ty, hình thức làm việc và khu vực địa lý;
 - iii. phân tích xu hướng thay đổi mức lương theo thời gian.
- (d) Chia dữ liệu thành tập huấn luyện và tập kiểm định.
- (e) Xây dựng ít nhất hai mô hình hồi quy để dự đoán mức lương (ví dụ: hồi quy tuyến tính, Ridge, LASSO, PCR hoặc các phương pháp phù hợp khác).
- (f) Đánh giá và so sánh các mô hình bằng các chỉ số RMSE, MAE và R^2 ; lựa chọn mô hình tốt nhất và giải thích lý do.
- (g) Diễn giải ý nghĩa của các biến quan trọng trong mô hình được lựa chọn.
- (h) Đề xuất các hướng cải thiện mô hình hoặc các phương pháp phân tích khác có thể mang lại kết quả tốt hơn.

2. Hoạt động 2 (3 điểm)

Mỗi nhóm tự lựa chọn một bộ dữ liệu với chủ đề tự do để thực hiện một bài toán phân tích dữ liệu, vận dụng các kiến thức và phương pháp đã học trong học phần nhằm giải quyết một bài toán thực tiễn. Bộ dữ liệu có thể được thu thập từ các nguồn mở như: Kaggle, UCI Machine Learning Repository, EU Open Data Portal, data.gov, Statista,... hoặc các nguồn dữ liệu tin cậy khác. Bộ dữ liệu được lựa chọn phải có ít nhất 8 biến (không kể các biến định danh nếu có) và không được trùng với các bộ dữ liệu đã sử dụng trong học phần.

Yêu cầu:

1. *Giới thiệu đề tài và bộ dữ liệu:* Trình bày tên đề tài, mục tiêu nghiên cứu/phân tích; Giới thiệu nguồn gốc bộ dữ liệu; Mô tả ý nghĩa của các biến và xác định biến phản hồi (nếu có).

2. *Tiền xử lý và khám phá dữ liệu:* Thực hiện tiền xử lý dữ liệu (xử lý dữ liệu khuyết, ngoại lệ, mã hóa biến phân loại, chuẩn hóa dữ liệu nếu cần,...); Thực hiện phân tích khám phá dữ liệu (EDA), trình bày các đặc điểm chính của bộ dữ liệu thông qua thống kê mô tả và các biểu đồ phù hợp.
3. *Xây dựng mô hình:* Lựa chọn và xây dựng mô hình phù hợp với mục tiêu phân tích. Có thể sử dụng một hoặc nhiều phương pháp đã học trong học phần, chẳng hạn: Hồi quy tuyến tính bội (OLS); Hồi quy trên thành phần chính (PCR); Ridge Regression; LASSO; Elastic-Net; ANOVA hai nhân tố hoặc nhiều nhân tố; Hoặc các mô hình thống kê phù hợp khác đã được học.
4. *Đánh giá mô hình:* Kiểm tra các giả định của mô hình (nếu có); Đánh giá chất lượng mô hình bằng các tiêu chí phù hợp (ví dụ: RMSE, MAE, R^2 , Accuracy, AIC, BIC,... tùy theo mô hình được lựa chọn); Nếu xây dựng nhiều mô hình, hãy so sánh và lựa chọn mô hình phù hợp nhất, đồng thời giải thích lý do lựa chọn.
5. *Phân tích và diễn giải kết quả:* Phân tích và diễn giải ý nghĩa của các kết quả thu được; Trả lời bài toán hoặc mục tiêu nghiên cứu đã đặt ra.
6. *Đề xuất và kết luận:* Đề xuất các hướng cải thiện mô hình hoặc các phương pháp phân tích khác có thể cho kết quả tốt hơn (nếu có); Trình bày kết luận của nhóm.

Hết.