

Bài thực hành số 1: Dự đoán giá nhà ở California

Nhóm thực hiện

2026-06-25

Giới thiệu

Bộ dữ liệu California Housing gồm các quan sát ở cấp **census block group** tại bang California. Mục tiêu của bài thực hành là xây dựng mô hình dự đoán **median_house_value**, tức giá trị nhà trung vị của một khu vực, dựa trên các đặc trưng địa lý, nhân khẩu học, thu nhập và vị trí so với biển.

Cần lưu ý rằng mỗi dòng dữ liệu không đại diện cho một căn nhà riêng lẻ. Các biến như **total_rooms**, **population** và **households** là số liệu tổng hợp ở cấp khu vực điều tra dân số.

Đọc dữ liệu

```
housing <- read.csv("California_housing.csv", stringsAsFactors = FALSE)
```

```
dim(housing)
```

```
## [1] 20640    10
```

```
str(housing)
```

```
## 'data.frame':    20640 obs. of  10 variables:
## $ longitude      : num  -122 -122 -122 -122 -122 ...
## $ latitude       : num   37.9 37.9 37.9 37.9 37.9 ...
## $ housing_median_age: num   41 21 52 52 52 52 52 52 42 52 ...
## $ total_rooms     : num   880 7099 1467 1274 1627 ...
## $ total_bedrooms  : num   129 1106 190 235 280 ...
## $ population      : num   322 2401 496 558 565 ...
## $ households      : num   126 1138 177 219 259 ...
## $ median_income   : num   8.33 8.3 7.26 5.64 3.85 ...
## $ median_house_value: num  452600 358500 352100 341300 342200 ...
## $ ocean_proximity : chr   "NEAR BAY" "NEAR BAY" "NEAR BAY" "NEAR BAY" ...
```

```
head(housing) |>
```

```
  kable(caption = "Một số quan sát đầu tiên trong dữ liệu")
```

Table 1: Một số quan sát đầu tiên trong dữ liệu

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	median_house_value	ocean_proximity
- 122.23	37.88		41	880	129	322	126	8.3252	452600	NEAR BAY
- 122.22	37.86		21	7099	1106	2401	1138	8.3014	358500	NEAR BAY

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	median_house_value	ocean_proximity
122.24	-	37.85	52	1467	190	496	177	7.2574	352100	NEAR BAY
122.25	-	37.85	52	1274	235	558	219	5.6431	341300	NEAR BAY
122.25	-	37.85	52	1627	280	565	259	3.8462	342200	NEAR BAY
122.25	-	37.85	52	919	213	413	193	4.0368	269700	NEAR BAY

Khám phá dữ liệu

Kiểm tra dữ liệu thiếu

```
missing_table <- data.frame(
  variable = names(housing),
  missing_count = colSums(is.na(housing)),
  missing_rate = colMeans(is.na(housing))
)

missing_table |>
  arrange(desc(missing_count)) |>
  mutate(missing_rate = percent(missing_rate, accuracy = 0.01)) |>
  kable(caption = "Số lượng và tỷ lệ giá trị thiếu theo biến")
```

Table 2: Số lượng và tỷ lệ giá trị thiếu theo biến

	variable	missing_count	missing_rate
total_bedrooms	total_bedrooms	207	1.00%
longitude	longitude	0	0.00%
latitude	latitude	0	0.00%
housing_median_age	housing_median_age	0	0.00%
total_rooms	total_rooms	0	0.00%
population	population	0	0.00%
households	households	0	0.00%
median_income	median_income	0	0.00%
median_house_value	median_house_value	0	0.00%
ocean_proximity	ocean_proximity	0	0.00%

Dữ liệu chỉ có giá trị thiếu ở biến `total_bedrooms`, với 207 quan sát, tương đương 1.00% toàn bộ dữ liệu. Vì tỷ lệ thiếu thấp, bước tiếp theo cần kiểm tra xem thiếu có tập trung theo một nhóm địa lý hay nhóm `ocean_proximity` cụ thể không. Nếu thiếu tập trung mạnh ở một nhóm, việc thay thế bằng median chung có thể làm mất đặc điểm riêng của nhóm đó; nếu thiếu rải rác và nhóm thiếu có đặc điểm tương đối gần nhóm không thiếu, median imputation là lựa chọn đơn giản và đủ ổn cho bài thực hành tuyến tính này.

```
missing_by_ocean <- housing |>
  group_by(ocean_proximity) |>
  summarise(
    n = n(),
    missing_total_bedrooms = sum(is.na(total_bedrooms)),
    missing_rate = mean(is.na(total_bedrooms)),
```

```

    .groups = "drop"
  )

missing_by_ocean |>
  mutate(missing_rate = percent(missing_rate, accuracy = 0.01)) |>
  kable(caption = "Tỷ lệ thiếu total_bedrooms theo ocean_proximity")

```

Table 3: Tỷ lệ thiếu total_bedrooms theo ocean_proximity

ocean_proximity	n	missing_total_bedrooms	missing_rate
<1H OCEAN	9136	102	1.12%
INLAND	6551	55	0.84%
ISLAND	5	0	0.00%
NEAR BAY	2290	20	0.87%
NEAR OCEAN	2658	30	1.13%

```

missing_pattern_summary <- housing |>
  mutate(
    total_bedrooms_status = ifelse(
      is.na(total_bedrooms),
      "Thiếu total_bedrooms",
      "Không thiếu total_bedrooms"
    )
  ) |>
  group_by(total_bedrooms_status) |>
  summarise(
    n = n(),
    median_income_median = median(median_income),
    median_house_value_median = median(median_house_value),
    total_rooms_median = median(total_rooms),
    population_median = median(population),
    households_median = median(households),
    .groups = "drop"
  )

missing_pattern_summary |>
  kable(
    digits = 2,
    caption = "So sánh nhanh nhóm thiếu và không thiếu total_bedrooms"
  )

```

Table 4: So sánh nhanh nhóm thiếu và không thiếu total_bedrooms

total_bedrooms_status	n	median_income_median	median_house_value_median	total_rooms_median	population_median	households_median
Không thiếu total_bedrooms	20433	3.54	179700	2127	1166	409
Thiếu total_bedrooms	207	3.41	175000	2155	1217	427

Kết quả cho thấy thiếu dữ liệu không phải do toàn bộ một biến bị lỗi, mà chỉ xuất hiện ở `total_bedrooms`. Tỷ lệ thiếu theo các nhóm `ocean_proximity` đều thấp và không chỉ tập trung vào một nhóm lớn duy nhất;

nhóm ISLAND không có giá trị thiếu nhưng chỉ có rất ít quan sát nên không đủ để kết luận riêng. So sánh nhóm thiếu và không thiếu cũng không cho thấy khác biệt cực đoan về thu nhập trung vị hay giá nhà trung vị. Vì vậy, trong phạm vi bài này, có thể xem cơ chế thiếu gần với thiếu ngẫu nhiên có điều kiện theo các đặc trưng quan sát được hơn là lỗi hệ thống rõ ràng. Tuy nhiên, không thể chứng minh dữ liệu là MCAR tuyệt đối chỉ từ bảng này.

Do đó, thay thế `total_bedrooms` thiếu bằng median là hợp lý vì: tỷ lệ thiếu thấp, median bền vững hơn mean khi các biến đếm như số phòng có đuôi phải dài, và median được tính trên tập training để tránh rò rỉ thông tin từ validation. Một cách cải thiện tốt hơn trong nghiên cứu sâu hơn là impute theo nhóm `ocean_proximity` hoặc dùng mô hình imputation dựa trên `total_rooms`, `households` và `population`.

Thống kê mô tả

```
skewness <- function(x) {
  x <- x[!is.na(x)]
  mean((x - mean(x))^3) / sd(x)^3
}

numeric_summary <- housing |>
  select(where(is.numeric)) |>
  pivot_longer(everything(), names_to = "variable", values_to = "value") |>
  group_by(variable) |>
  summarise(
    n = sum(!is.na(value)),
    missing_count = sum(is.na(value)),
    mean = mean(value, na.rm = TRUE),
    sd = sd(value, na.rm = TRUE),
    min = min(value, na.rm = TRUE),
    q1 = quantile(value, 0.25, na.rm = TRUE),
    median = median(value, na.rm = TRUE),
    q3 = quantile(value, 0.75, na.rm = TRUE),
    max = max(value, na.rm = TRUE),
    iqr = IQR(value, na.rm = TRUE),
    skewness = skewness(value),
    .groups = "drop"
  )

numeric_summary |>
  kable(digits = 2, caption = "Thống kê mô tả các biến định lượng")
```

Table 5: Thống kê mô tả các biến định lượng

variable	n	missing_count	mean	sd	min	q1	median	q3	max	iqr	skewness
households	20640	0	499.54	382.33	1.00	280.00	409.00	605.00	6082.00	325.00	3.41
housing_median_age	20640	0	28.64	12.59	1.00	18.00	29.00	37.00	52.00	19.00	0.06
latitude	20640	0	35.63	2.14	32.54	33.93	34.26	37.71	41.95	3.78	0.47
longitude	20640	0	-	2.00	-	-	-	-	-	3.79	-0.30
median_house_value	20640	0	119.57	115395.62	124.35	121.80	118.49	118.01	114.31		
median_income	20640	0	20685.58	215395.62	14999.00	119600.00	179700.00	264725.00	500001.00	45125.00	0.98
population	20640	0	3.87	1.90	0.50	2.56	3.53	4.74	15.00	2.18	1.65
total_bedrooms	20433	207	1425.48	1132.46	3.00	787.00	1166.00	1725.00	35682.00	938.00	4.94
total_rooms	20640	0	537.87	421.39	1.00	296.00	435.00	647.00	6445.00	351.00	3.46
	20640	0	2635.76	2181.62	2.00	1447.75	2127.00	3148.00	39320.00	1700.25	4.15

```
housing |>
  count(ocean_proximity, sort = TRUE) |>
  mutate(rate = percent(n / sum(n), accuracy = 0.01)) |>
  kable(caption = "Phân bố biến ocean_proximity")
```

Table 6: Phân bố biến ocean_proximity

ocean_proximity	n	rate
<1H OCEAN	9136	44.26%
INLAND	6551	31.74%
NEAR OCEAN	2658	12.88%
NEAR BAY	2290	11.09%
ISLAND	5	0.02%

ocean_proximity là biến phân loại mô tả vị trí tương đối của census block group so với biển hoặc vịnh. Các mức chính gồm:


- <1H OCEAN: khu vực cách biển dưới khoảng một giờ di chuyển.
- INLAND: khu vực sâu trong đất liền.
- NEAR BAY: khu vực gần vịnh.
- NEAR OCEAN: khu vực gần biển.
- ISLAND: khu vực đảo.

Biến này quan trọng vì vị trí ven biển hoặc gần vịnh thường gắn với khả năng tiếp cận việc làm, tiện ích, khí hậu, mật độ đô thị và mức khan hiếm đất khác với khu vực sâu trong đất liền. Do đó, ocean_proximity không chỉ là nhân địa lý mà còn là proxy cho nhiều yếu tố kinh tế - xã hội ảnh hưởng đến giá nhà. Phân bố của biến này cũng không cân bằng: nhóm <1H OCEAN và INLAND chiếm phần lớn dữ liệu, trong khi ISLAND chỉ có rất ít quan sát. Vì vậy, hệ số hoặc kết luận riêng cho ISLAND cần được diễn giải rất thận trọng; mô hình có thể học kém cho nhóm hiếm này.

Từ bảng thống kê mô tả, nhiều biến đếm như total_rooms, total_bedrooms, population và households có khoảng cách lớn giữa median và max, cho thấy phân phối lệch phải và có các khu vực rất lớn. Vì các biến này là tổng theo khu vực chứ không phải đặc điểm của một căn nhà riêng lẻ, diễn giải trực tiếp hệ số của chúng cần cẩn trọng. Các biến tỷ lệ được tạo thêm ở phần tiền xử lý như rooms_per_household, bedrooms_per_room và population_per_household giúp chuyển thông tin tổng hợp này thành đặc điểm dễ so sánh hơn giữa các khu vực.

Phân phối biến mục tiêu

```
ggplot(housing, aes(x = median_house_value)) +
  geom_histogram(bins = 50, fill = "#2F6F8F", color = "white") +
  scale_x_continuous(labels = dollar_format()) +
  labs(
    title = "Phân phối giá nhà trung vị",
    x = "Median house value",
    y = "Số quan sát"
  )
```



```
target_summary <- data.frame(
  min = min(housing$median_house_value),
  q1 = quantile(housing$median_house_value, 0.25),
  median = median(housing$median_house_value),
  mean = mean(housing$median_house_value),
  q3 = quantile(housing$median_house_value, 0.75),
  max = max(housing$median_house_value),
  capped_count = sum(housing$median_house_value == max(housing$median_house_value)),
  capped_rate = mean(housing$median_house_value == max(housing$median_house_value)),
  skewness = skewness(housing$median_house_value)
)

target_summary |>
  mutate(capped_rate = percent(capped_rate, accuracy = 0.01)) |>
  kable(digits = 2, caption = "Tóm tắt phân phối median_house_value")
```

Table 7: Tóm tắt phân phối median_house_value

	min	q1	median	mean	q3	max	capped_count	capped_rate	skewness
25%	14999	119600	179700	206855.8	264725	500001	965	4.68%	0.98


Biến mục tiêu `median_house_value` bị lệch phải và có giá trị lớn nhất bằng \$500,001. Có 965 quan sát nằm đúng tại giá trị lớn nhất này, tương đương 4.68% dữ liệu. Đây là dấu hiệu dữ liệu bị chặn trên: các khu vực có giá trị thực tế cao hơn ngưỡng này vẫn được ghi nhận cùng một giá trị.

Đây là một vấn đề quan trọng cho cả dự báo và diễn giải. Với mô hình hồi quy tuyến tính dùng MSE/RMSE, các quan sát giá cao có ảnh hưởng lớn đến hàm mất mát, nhưng do phần đỉnh bị gộp tại 500001, mô hình không thể học được khác biệt thật giữa các khu vực rất đắt. Vì vậy, sai số ở phân khúc cao có thể bị diễn

giải sai: dự đoán thấp hơn 500001 không nhất thiết chỉ là mô hình kém, mà còn phản ánh việc nhân mục tiêu đã bị kiểm duyệt/capping. Khi diễn giải hệ số, cần hiểu rằng tác động của các biến như `median_income` hoặc vị trí gần biển lên giá nhà cao cấp có thể bị đánh giá thấp vì biến mục tiêu không còn tăng sau ngưỡng này.

Thu nhập và giá nhà

```
ggplot(housing, aes(x = median_income, y = median_house_value)) +  
  geom_point(alpha = 0.25, color = "#3B6EA8") +  
  geom_smooth(method = "lm", se = FALSE, color = "#C04B37") +  
  scale_y_continuous(labels = dollar_format()) +  
  labs(  
    title = "Quan hệ giữa thu nhập trung vị và giá nhà trung vị",  
    x = "Median income",  
    y = "Median house value"  
  )
```




`median_income` có xu hướng tương quan dương rõ rệt với `median_house_value`. Đây thường là một trong những biến dự báo quan trọng nhất của giá nhà.

Giá nhà theo vị trí so với biển

```
ggplot(housing, aes(x = ocean_proximity, y = median_house_value, fill = ocean_proximity)) +  
  geom_boxplot(outlier.alpha = 0.15) +  
  scale_y_continuous(labels = dollar_format()) +  
  guides(fill = "none") +  
  labs(  
    title = "Giá nhà theo vị trí so với biển",
```

```
x = "Ocean proximity",
y = "Median house value"
)
```



Các khu vực gần biển hoặc gần vịnh có xu hướng giá nhà cao hơn khu vực INLAND.

Tương quan giữa các biến định lượng

```
cor_data <- housing |>
  select(where(is.numeric)) |>
  cor(use = "pairwise.complete.obs")

cor_long <- as.data.frame(as.table(cor_data))
names(cor_long) <- c("var1", "var2", "correlation")


ggplot(cor_long, aes(x = var1, y = var2, fill = correlation)) +
  geom_tile(color = "white") +
  scale_fill_gradient2(
    low = "#B4433C",
    mid = "white",
    high = "#2F6F8F",
    midpoint = 0,
    limits = c(-1, 1)
  ) +
  coord_equal() +
  labs(
    title = "Ma trận tương quan giữa các biến định lượng",
    x = NULL,
```



```

y = NULL,
fill = "Tương quan"
) +
theme(axis.text.x = element_text(angle = 45, hjust = 1))

```



Tiền xử lý dữ liệu

Chia training và validation

```

n <- nrow(housing)
train_id <- sample(seq_len(n), size = floor(0.8 * n))

train_raw <- housing[train_id, ]
valid_raw <- housing[-train_id, ]

c(
  training_size = nrow(train_raw),
  validation_size = nrow(valid_raw)
)

```

```

##   training_size validation_size
##           16512           4128

```

Impute missing values và tạo biến mới

```

bedrooms_median_train <- median(train_raw$total_bedrooms, na.rm = TRUE)

```

```

prepare_data <- function(data, bedrooms_median) {
  data |>
    mutate(
      total_bedrooms = ifelse(
        is.na(total_bedrooms),
        bedrooms_median,
        total_bedrooms
      ),
      ocean_proximity = factor(ocean_proximity),
      rooms_per_household = total_rooms / households,
      bedrooms_per_room = total_bedrooms / total_rooms,
      population_per_household = population / households
    )
}

train <- prepare_data(train_raw, bedrooms_median_train)
valid <- prepare_data(valid_raw, bedrooms_median_train)

colSums(is.na(train))

```

```

##           longitude           latitude   housing_median_age
##                0                0                0
##      total_rooms      total_bedrooms      population
##                0                0                0
##      households      median_income   median_house_value
##                0                0                0
##      ocean_proximity   rooms_per_household   bedrooms_per_room
##                0                0                0
## population_per_household
##                0

```

```
colSums(is.na(valid))
```

```

##           longitude           latitude   housing_median_age
##                0                0                0
##      total_rooms      total_bedrooms      population
##                0                0                0
##      households      median_income   median_house_value
##                0                0                0
##      ocean_proximity   rooms_per_household   bedrooms_per_room
##                0                0                0
## population_per_household
##                0

```

Ba biến mới được tạo để phản ánh cấu trúc khu vực tốt hơn:

- `rooms_per_household`: số phòng trung bình trên mỗi hộ.
- `bedrooms_per_room`: tỷ lệ phòng ngủ trên tổng số phòng.
- `population_per_household`: số người trung bình trên mỗi hộ.

Tạo ma trận thiết kế cho mô hình

```

model_formula <- median_house_value ~ longitude + latitude +
  housing_median_age + total_rooms + total_bedrooms + population +
  households + median_income + ocean_proximity +

```

```
rooms_per_household + bedrooms_per_room + population_per_household

x_train <- model.matrix(model_formula, data = train)[, -1]
x_valid <- model.matrix(model_formula, data = valid)[, -1]

y_train <- train$median_house_value
y_valid <- valid$median_house_value

dim(x_train)

## [1] 16512    15
dim(x_valid)

## [1] 4128    15
```

Xây dựng mô hình

Hàm đánh giá mô hình

```
calculate_metrics <- function(actual, predicted) {
  residual <- actual - predicted
  data.frame(
    RMSE = sqrt(mean(residual^2)),
    MAE = mean(abs(residual)),
    MAPE = mean(abs(residual / actual)) * 100,
    R2 = 1 - sum(residual^2) / sum((actual - mean(actual))^2)
  )
}
```

Hồi quy tuyến tính bộ OLS

```
ols_model <- lm(model_formula, data = train)
ols_pred <- predict(ols_model, newdata = valid)

ols_metrics <- calculate_metrics(y_valid, ols_pred) |>
  mutate(model = "OLS", .before = 1)

tidy(ols_model) |>
  arrange(desc(abs(estimate))) |>
  head(15) |>
  kable(digits = 4, caption = "15 hệ số OLS có độ lớn tuyệt đối cao nhất")
```

Table 8: 15 hệ số OLS có độ lớn tuyệt đối cao nhất

term	estimate	std.error	statistic	p.value
(Intercept)	-2403022.1748	98268.7478	-24.4536	0.0000
ocean_proximityISLAND	171272.7432	34301.3538	4.9932	0.0000
bedrooms_per_room	152700.4609	12243.1202	12.4723	0.0000
median_income	39351.3558	396.4946	99.2481	0.0000
ocean_proximityINLAND	-36520.4779	1941.4895	-18.8105	0.0000
longitude	-27828.0276	1137.1124	-24.4725	0.0000
latitude	-26469.3852	1122.7020	-23.5765	0.0000

term	estimate	std.error	statistic	p.value
ocean_proximityNEAR OCEAN	5187.8698	1731.4868	2.9962	0.0027
ocean_proximityNEAR BAY	-3930.0999	2120.2070	-1.8536	0.0638
rooms_per_household	2414.7257	257.8429	9.3651	0.0000
housing_median_age	1043.2993	48.7713	21.3917	0.0000
households	115.2015	7.9838	14.4293	0.0000
population_per_household	60.8566	51.8510	1.1737	0.2405
population	-39.0154	1.2328	-31.6473	0.0000
total_bedrooms	15.4638	7.4390	2.0787	0.0377

Ridge Regression

```
ridge_cv <- cv.glmnet(
  x = x_train,
  y = y_train,
  alpha = 0,
  nfolds = 10,
  standardize = TRUE
)

ridge_pred <- as.numeric(predict(ridge_cv, newx = x_valid, s = "lambda.min"))

ridge_metrics <- calculate_metrics(y_valid, ridge_pred) |>
  mutate(model = "Ridge", .before = 1)

ridge_cv$lambda.min

## [1] 7944.534
```

LASSO Regression

```
lasso_cv <- cv.glmnet(
  x = x_train,
  y = y_train,
  alpha = 1,
  nfolds = 10,
  standardize = TRUE
)

lasso_pred <- as.numeric(predict(lasso_cv, newx = x_valid, s = "lambda.min"))

lasso_metrics <- calculate_metrics(y_valid, lasso_pred) |>
  mutate(model = "LASSO", .before = 1)

lasso_cv$lambda.min

## [1] 226.2632
```

Elastic Net Regression

```
alpha_grid <- c(0.1, 0.25, 0.5, 0.75, 0.9)
```

```

elastic_results <- lapply(alpha_grid, function(alpha_value) {
  fit <- cv.glmnet(
    x = x_train,
    y = y_train,
    alpha = alpha_value,
    nfolds = 10,
    standardize = TRUE
  )

  data.frame(
    alpha = alpha_value,
    lambda_min = fit$lambda.min,
    cvm_min = min(fit$cvm),
    fit = I(list(fit))
  )
})

elastic_results <- bind_rows(elastic_results)
best_elastic <- elastic_results |>
  arrange(cvm_min) |>
  slice(1)

elastic_model <- best_elastic$fit[[1]]
elastic_pred <- as.numeric(
  predict(elastic_model, newx = x_valid, s = "lambda.min")
)

elastic_metrics <- calculate_metrics(y_valid, elastic_pred) |>
  mutate(model = "Elastic Net", .before = 1)

elastic_results |>
  select(alpha, lambda_min, cvm_min) |>
  arrange(cvm_min) |>
  kable(digits = 4, caption = "Kết quả Cross Validation theo alpha của Elastic Net")

```

Table 9: Kết quả Cross Validation theo alpha của Elastic Net

alpha	lambda_min	cvm_min
0.10	465.3130	4743956389
0.50	375.6953	4744542655
0.75	363.3797	4746523615
0.90	332.3407	4751001061
0.25	471.8952	4759850917

So sánh mô hình

```

metrics_table <- bind_rows(
  ols_metrics,
  ridge_metrics,
  lasso_metrics,
  elastic_metrics
)

```

```

) |>
  arrange(RMSE)

metrics_table |>
  mutate(
    RMSE = round(RMSE, 2),
    MAE = round(MAE, 2),
    MAPE = round(MAPE, 2),
    R2 = round(R2, 4)
  ) |>
  kable(caption = "So sánh các mô hình trên tập validation")

```

Table 10: So sánh các mô hình trên tập validation


model	RMSE	MAE	MAPE	R2
OLS	67541.59	49108.64	28.15	0.6592
Elastic Net	67630.30	49094.10	28.00	0.6583
LASSO	67651.91	49104.58	28.00	0.6580
Ridge	69188.87	50267.27	28.50	0.6423

```

metrics_table |>
  select(model, RMSE, MAE, MAPE, R2) |>
  pivot_longer(-model, names_to = "metric", values_to = "value") |>
  ggplot(aes(x = reorder(model, value), y = value, fill = model)) +
  geom_col() +
  facet_wrap(~ metric, scales = "free_y") +
  guides(fill = "none") +
  labs(
    title = "So sánh trực quan các chỉ số đánh giá",
    x = "Mô hình",
    y = "Giá trị"
  ) +
  theme(axis.text.x = element_text(angle = 30, hjust = 1))

```

So sánh trực quan các chỉ số đánh giá



```
best_model_name <- metrics_table$model[1]
best_model_name
```

```
## [1] "OLS"
```

Mô hình có RMSE thấp nhất trên tập validation là OLS. Đây là mô hình được ưu tiên nếu mục tiêu chính là độ chính xác dự đoán. Nếu cần diễn giải đơn giản, mô hình OLS vẫn hữu ích vì hệ số hồi quy trực tiếp hơn, nhưng cần chú ý đến đa cộng tuyến giữa các biến tổng hợp như `total_rooms`, `total_bedrooms`, `population` và `households`.

Diễn giải biến ảnh hưởng

Hệ số của mô hình tốt nhất trong nhóm điều chuẩn

```
coef_to_table <- function(model, s = "lambda.min") {
  coef_matrix <- as.matrix(coef(model, s = s))
  data.frame(
    variable = rownames(coef_matrix),
    coefficient = as.numeric(coef_matrix[, 1]),
    row.names = NULL
  ) |>
  filter(variable != "(Intercept)", coefficient != 0) |>
  mutate(abs_coefficient = abs(coefficient)) |>
  arrange(desc(abs_coefficient))
}

regularized_models <- list(
  Ridge = ridge_cv,
  LASSO = lasso_cv,
```

```

`Elastic Net` = elastic_model
)

best_regularized_name <- metrics_table |>
  filter(model %in% names(regularized_models)) |>
  slice(1) |>
  pull(model)

best_regularized_coef <- coef_to_table(regularized_models[[best_regularized_name]])

best_regularized_coef |>
  head(15) |>
  select(variable, coefficient) |>
  kable(digits = 4, caption = paste("15 biến có hệ số lớn nhất theo", best_regularized_name))

```

Table 11: 15 biến có hệ số lớn nhất theo Elastic Net

variable	coefficient
ocean_proximityISLAND	170103.9750
bedrooms_per_room	147751.5195
ocean_proximityINLAND	-41263.0634
median_income	39285.4546
longitude	-23946.1435
latitude	-22626.9049
ocean_proximityNEAR OCEAN	6561.2729
ocean_proximityNEAR BAY	-2466.0893
rooms_per_household	2082.2827
housing_median_age	1048.4126
households	99.8536
population_per_household	37.1702
population	-36.8057
total_bedrooms	21.4232
total_rooms	-0.0665

Các biến thường có ảnh hưởng mạnh đến giá nhà gồm `median_income`, vị trí địa lý (`longitude`, `latitude`), tuổi trung vị của nhà, vị trí so với biển và các biến tỷ lệ như số phòng trung bình trên mỗi hộ. Dấu của hệ số cho biết chiều tác động khi các biến khác được giữ cố định; tuy nhiên đây là phân tích hồi quy dự báo, không khẳng định quan hệ nhân quả.

Nhận xét theo nội dung bài toán

- Thu nhập trung vị cao thường đi kèm giá nhà cao hơn.
- Khu vực gần biển hoặc gần vịnh có xu hướng giá nhà cao hơn khu vực sâu trong đất liền.
- Các biến tổng như `total_rooms`, `population` và `households` cần được hiểu là đặc điểm cấp khu vực, không phải đặc điểm của từng căn nhà.
- Biến mục tiêu bị chặn trên ở 500001, vì vậy mô hình có thể đánh giá thấp hoặc khó phân biệt các khu vực giá rất cao.

Kết luận và đề xuất

Bài thực hành đã xây dựng và so sánh bốn mô hình dự đoán giá nhà ở California: OLS, Ridge Regression, LASSO Regression và Elastic Net Regression. Các mô hình Ridge, LASSO và Elastic Net sử dụng 10-fold

Cross Validation để chọn tham số điều chuẩn tối ưu.

Dựa trên kết quả validation, mô hình OLS là lựa chọn phù hợp nhất theo tiêu chí RMSE. Trong thực tế, nếu mục tiêu là dự báo, nên ưu tiên mô hình có lỗi validation thấp và ổn định. Nếu mục tiêu là giải thích, nên kết hợp kết quả từ OLS với hệ số của LASSO/Elastic Net để nhận diện các biến quan trọng.

Một số hướng cải thiện có thể thực hiện thêm:

- Thử biến đổi log cho `median_house_value` để giảm ảnh hưởng của phân phối lệch phải.
- Xử lý riêng nhóm giá nhà bị chặn trên ở 500001.
- Thêm tương tác giữa vị trí địa lý và `ocean_proximity`.
- So sánh thêm với các mô hình phi tuyến như Random Forest hoặc Gradient Boosting nếu mục tiêu là tăng độ chính xác dự đoán.