TH2 — Thực hành MANOVA

So sánh đặc điểm hình thái của ba loài chim cánh cụt

Học phần High Dimensional Statistics

Mục lục

1 Mục tiêu và phương pháp **1**
- 1.1 Mô hình xác suất và đối tượng suy luận . . . 2
- 1.2 Quy tắc đọc p-value và đa kiểm định . . . 2

2 Khám phá và xử lý dữ liệu **3**
- 2.1 Cấu trúc và dữ liệu thiếu . . . 3
- 2.2 Thống kê mô tả . . . 4

3 Trực quan hóa dữ liệu **4**

4 Đánh giá giả định MANOVA **6**
- 4.1 Tính độc lập và bối cảnh lấy mẫu . . . 6
- 4.2 Tương quan, khả nghịch và cỡ mẫu . . . 6
- 4.3 Phân phối trong nhóm và ngoại lệ đa biến . . . 7
- 4.4 Đồng nhất ma trận hiệp phương sai . . . 10

5 MANOVA một nhân tố **11**
- 5.1 Giả thuyết, giả định và phân phối dưới giả thuyết không . . . 11
- 5.2 Thống kê Pillai và cách tính p-value chính . . . 12

6 Phân tích sau MANOVA **13**
- 6.1 ANOVA từng biến và độ lớn hiệu ứng . . . 13
- 6.2 Tukey HSD: cặp loài nào khác nhau? . . . 14
- 6.3 Kiểm tra độ nhạy: Welch và Holm chung cho 12 cặp . . . 15

7 Kết luận và thảo luận **16**
- 7.1 Giới hạn và hướng phát triển . . . 16

8 Tái lập và kiểm tra kết quả **17**
- 8.1 Bản nguồn để làm việc . . . 17

1 Mục tiêu và phương pháp

Câu hỏi nghiên cứu: Ba loài Adelie, Chinstrap và Gentoo có khác nhau về hình thái khi xét đồng thời chiều dài mỏ, độ sâu mỏ, chiều dài vây và khối lượng cơ thể không?

Bài làm sử dụng dữ liệu gốc `penguins_size.csv` đi kèm `TH2.pdf`, mức ý nghĩa $\alpha = 0{,}05$. Quy trình gồm khám phá và xử lý dữ liệu; trực quan hóa; đánh giá giả định; MANOVA một nhân tố; phân tích sau

MANOVA; kết luận và thảo luận. Mã R tạo trực tiếp các bảng và hình trong báo cáo, không chép tay kết quả.

Với quan sát j của loài i, đặt

$$\mathbf{Y}_{ij} = (\text{dài mỏ}, \text{sâu mỏ}, \text{dài vây}, \text{khối lượng})^T, \qquad \mathbf{Y}_{ij} = \mu_i + \varepsilon_{ij}.$$

MANOVA cổ điển giả định các sai số độc lập, phân phối chuẩn đa biến trong từng nhóm và có cùng ma trận hiệp phương sai Σ. Giả thuyết cần kiểm định là

$$H_0 : \mu_{\text{Adelie}} = \mu_{\text{Chinstrap}} = \mu_{\text{Gentoo}},$$
$$H_1 : \text{có ít nhất hai vector trung bình khác nhau.}$$

Kiểm định tổng thể có ý nghĩa chỉ cho biết có khác biệt về vector trung bình; cần phân tích tiếp để xác định biến và cặp loài liên quan.

1.1 Mô hình xác suất và đối tượng suy luận

Quy ước $i \in \{1, 2, 3\}$ lần lượt chỉ Adelie, Chinstrap, Gentoo; $j = 1, \dots, n_i$; $k = 1, \dots, p$ chỉ biến đáp ứng, với $p = 4$, $g = 3$ và $N = \sum_i n_i = 342$. Ký hiệu $\mu_{ik} = \mathbb{E}(Y_{ijk})$, $\mu_i = \mathbb{E}(\mathbf{Y}_{ij})$ và $\Sigma_i = \text{Cov}(\mathbf{Y}_{ij})$. Tham số suy luận là trung bình của các quần thể mà mẫu có thể đại diện, không chỉ là các trung bình mẫu đã tính được.

Mô hình dùng để hiệu chuẩn kiểm định MANOVA cổ điển là

$$\mathbf{Y}_{ij} \overset{\text{ind}}{\sim} \mathcal{N}_p(\mu_i, \Sigma), \qquad \Sigma \succ 0.$$

Điều này đòi hỏi độc lập giữa các cá thể và các nhóm, cùng phân phối trong mỗi nhóm, chuẩn đa biến và hiệp phương sai chung xác định dương. Nó không đòi hỏi bốn tọa độ trong một cá thể độc lập. Với hiệp phương sai chung, không có tương quan tuyến tính hoàn toàn là điều kiện khả nghịch; tương quan khác 0 không phải điều kiện bắt buộc để được dùng MANOVA.

Nếu R là chỉ báo một dòng đủ bốn số đo, phân tích complete-case trực tiếp mô tả phân phối $\mathbf{Y} \mid (i, R = 1)$. Để suy luận cho toàn bộ quần thể của loài i, cần thêm giả định về cơ chế thiếu; điều kiện đủ ở đây là $R \perp \mathbf{Y} \mid i$. Tệp không cho phép kiểm chứng điều kiện đó.

1.2 Quy tắc đọc p-value và đa kiểm định

Một p-value chỉ có nghĩa khi gắn với **một giả thuyết và phân phối tham chiếu cụ thể**. Với thống kê T mà giá trị lớn chống lại H_0, đặt

$$p_{\text{obs}} = \Pr_{H_0, \mathcal{A}}\{T(\mathbf{Y}^{\text{new}}) \geq T(\mathbf{y}^{\text{obs}})\},$$

trong đó $\mathcal{A}$ là các giả định dùng để xác định phân phối dưới H_0; $\mathbf{Y}^{\text{new}}$ là mẫu giả định lặp lại theo mô hình đó. Với kiểm định phía trái hoặc hai phía, miền cực đoan phải đổi tương ứng. Nếu phân phối còn chứa tham số nhiễu, cần loại chúng bằng một thống kê có phân phối bất biến hoặc nêu rõ phép xấp xỉ được sử dụng. Trong bài này, $p = 4$ khi nói về số chiều; p_{obs} hoặc cột `p` chỉ p-value.

Với một kiểm định đã xác định trước, bác bỏ H_0 khi $p_{\text{obs}} \leq \alpha = 0{,}05$. Mức ý nghĩa kiểm soát xác suất bác bỏ sai trong các lần lặp dưới H_0 nếu phép hiệu chuẩn hợp lệ; p-value không phải $\Pr(H_0 \mid \text{dữ liệu})$.

Không bác bỏ chỉ có nghĩa là chưa đủ bằng chứng chống lại H_0, không phải chấp nhận hoặc chứng minh H_0.

Khi kiểm định một họ m giả thuyết, dùng Holm: sắp $p_{(1)} \le \cdots \le p_{(m)}$, xét lần lượt $p_{(j)} \le \alpha/(m-j+1)$ và dừng ở lần đầu không thỏa. P-value hiệu chỉnh là

$$\tilde{p}_{(j)} = \min\left\{1, \max_{\ell \le j}(m-\ell+1)p_{(\ell)}\right\}.$$

Holm kiểm soát FWER = Pr(bác bỏ ít nhất một H_0 đúng) $\le \alpha$ cho **họ đã chỉ định**, dưới sự hợp lệ của các p-value thành phần, không cần chúng độc lập. Các họ trong bài gồm 12 kiểm định chuẩn biên, 4 kiểm định độ phân tán, 4 ANOVA và 12 so sánh Welch. Không khẳng định kiểm soát FWER 5% cho toàn bộ mọi kiểm định trong báo cáo. MANOVA Pillai là kiểm định nghiên cứu chính; các chẩn đoán không phải thủ tục chọn mô hình có bảo đảm sai lầm chung. Xem tài liệu R về hiệu chỉnh p-value.

2 Khám phá và xử lý dữ liệu

2.1 Cấu trúc và dữ liệu thiếu

Dữ liệu gồm **344 quan sát và 7 cột**. Nhân tố giải thích là `species`; bốn biến đáp ứng là `culmen_length_mm`, `culmen_depth_mm`, `flipper_length_mm` (mm) và `body_mass_g` (g). `island` và `sex` được giữ để mô tả bối cảnh, không đưa vào mô hình một nhân tố của đề.

Biến	Số NA gốc
species	0
island	0
culmen_length_mm	2
culmen_depth_mm	2
flipper_length_mm	2
body_mass_g	2
sex	10

Hai quan sát thiếu đồng thời cả bốn số đo nên bị loại khỏi phân tích. Không điền trung bình vào các ô thiếu vì cách này làm thay đổi phương sai và hiệp phương sai. Các dòng thiếu giới tính vẫn được giữ nếu có đủ số đo. Ngoài 10 giá trị NA gốc ở `sex`, có một nhãn `.` không hợp lệ; mã đổi nhãn này thành NA trong dữ liệu phân tích, không làm giảm cỡ mẫu MANOVA.

Loài	Ban đầu	Phân tích
Adelie	152	151
Chinstrap	68	68
Gentoo	124	123

Mẫu phân tích có **342 quan sát**, gồm 151 Adelie, 68 Chinstrap và 123 Gentoo. Không có dòng trùng hoàn toàn (0 dòng); bốn biến định lượng đều có giá trị dương, không có lỗi miền giá trị hiển nhiên. Không thể kết luận mọi phép đo đều chính xác nếu thiếu hồ sơ đo lường gốc. Chỉ số `source_row` trong bảng xuất cho phép truy ngược thứ tự dòng dữ liệu, không tính hàng tiêu đề.

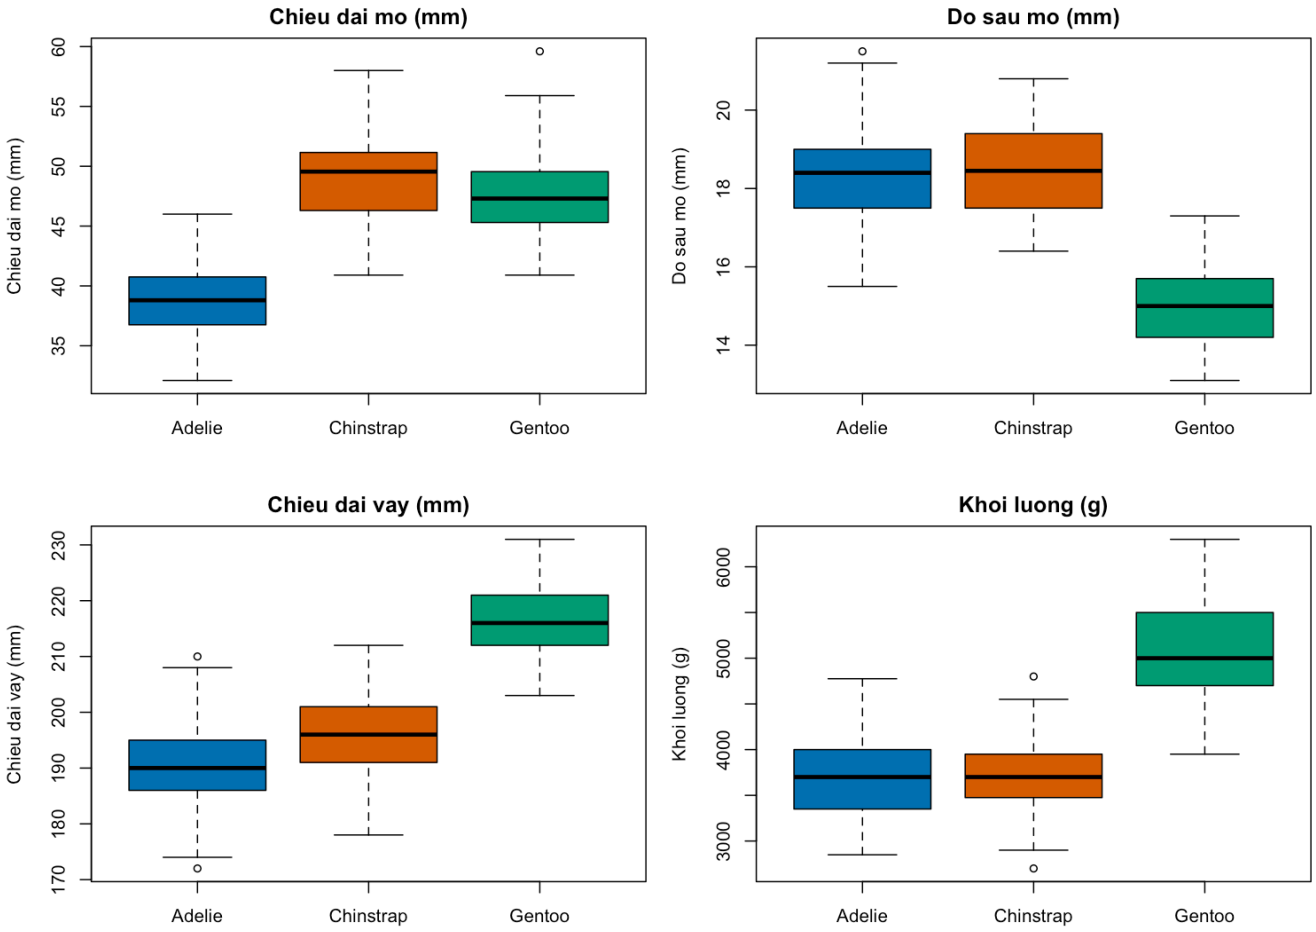
2.2 Thống kê mô tả

Bảng 3: Trung bình ± độ lệch chuẩn theo loài.

Loài	Dài mỏ (mm)	Sâu mỏ (mm)	Dài vây (mm)	Khối lượng (g)
Adelie	38.79 ± 2.66	18.35 ± 1.22	189.95 ± 6.54	3700.66 ± 458.57
Chinstrap	48.83 ± 3.34	18.42 ± 1.14	195.82 ± 7.13	3733.09 ± 384.34
Gentoo	47.50 ± 3.08	14.98 ± 0.98	217.19 ± 6.48	5076.02 ± 504.12

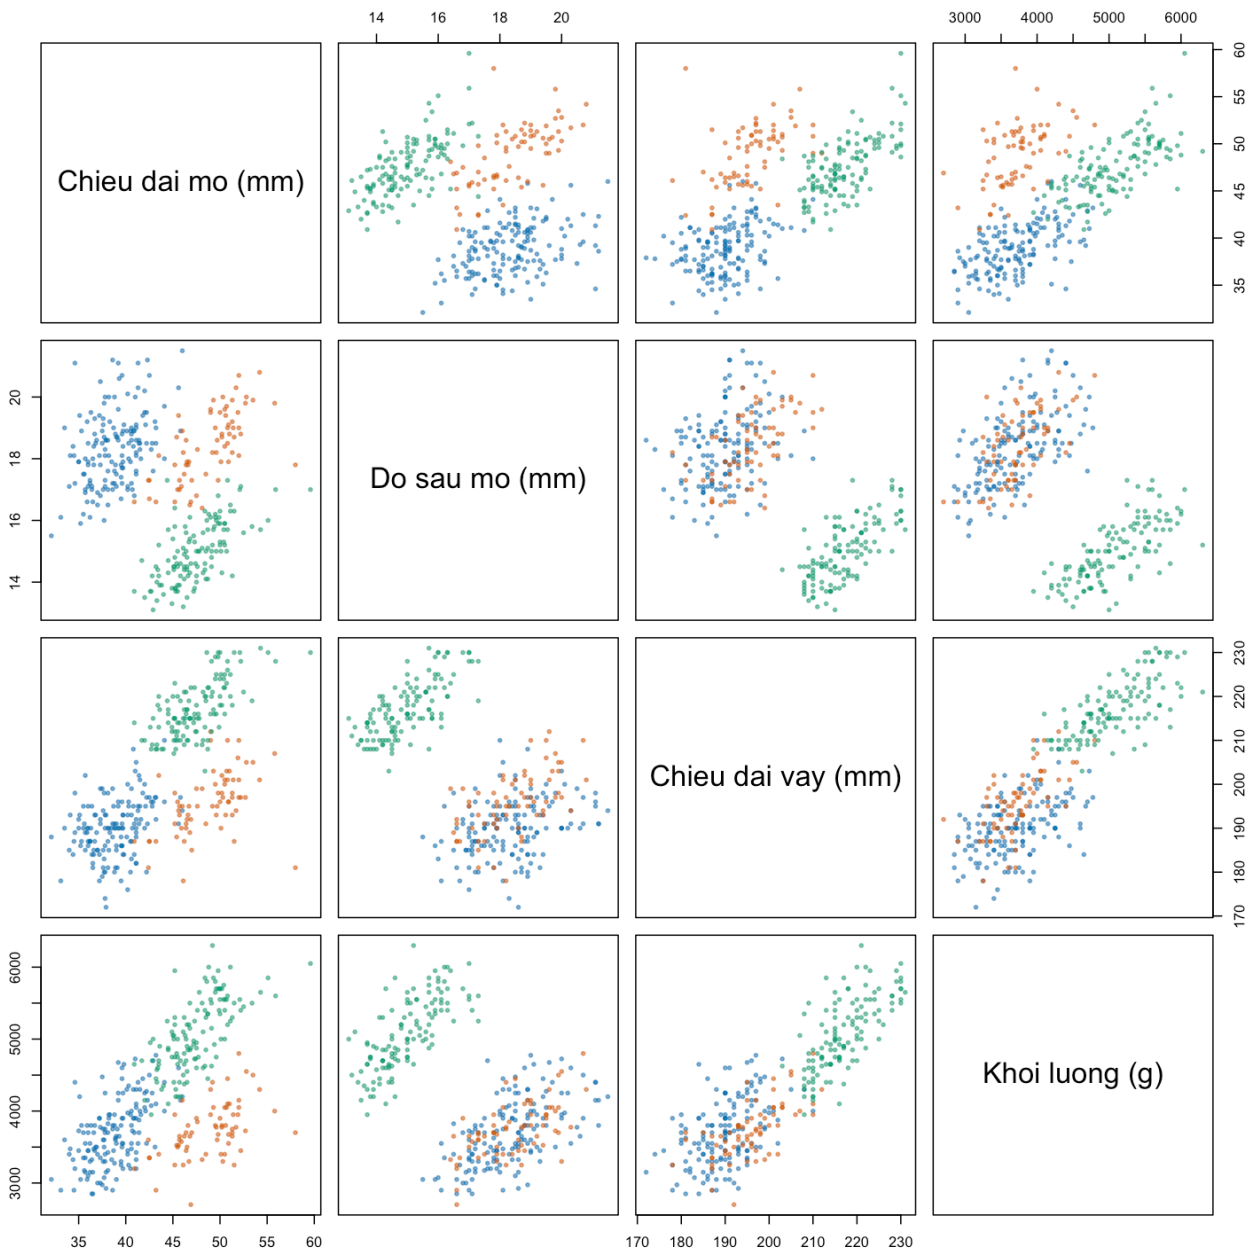
Gentoo có khối lượng và chiều dài vây lớn nhất, nhưng độ sâu mỏ nhỏ nhất. Chinstrap có chiều dài mỏ trung bình lớn nhất; khối lượng và độ sâu mỏ trung bình gần Adelie. Các độ lệch chuẩn ở bảng là độ phân tán giữa cá thể, không phải sai số chuẩn của trung bình.

3 Trực quan hóa dữ liệu



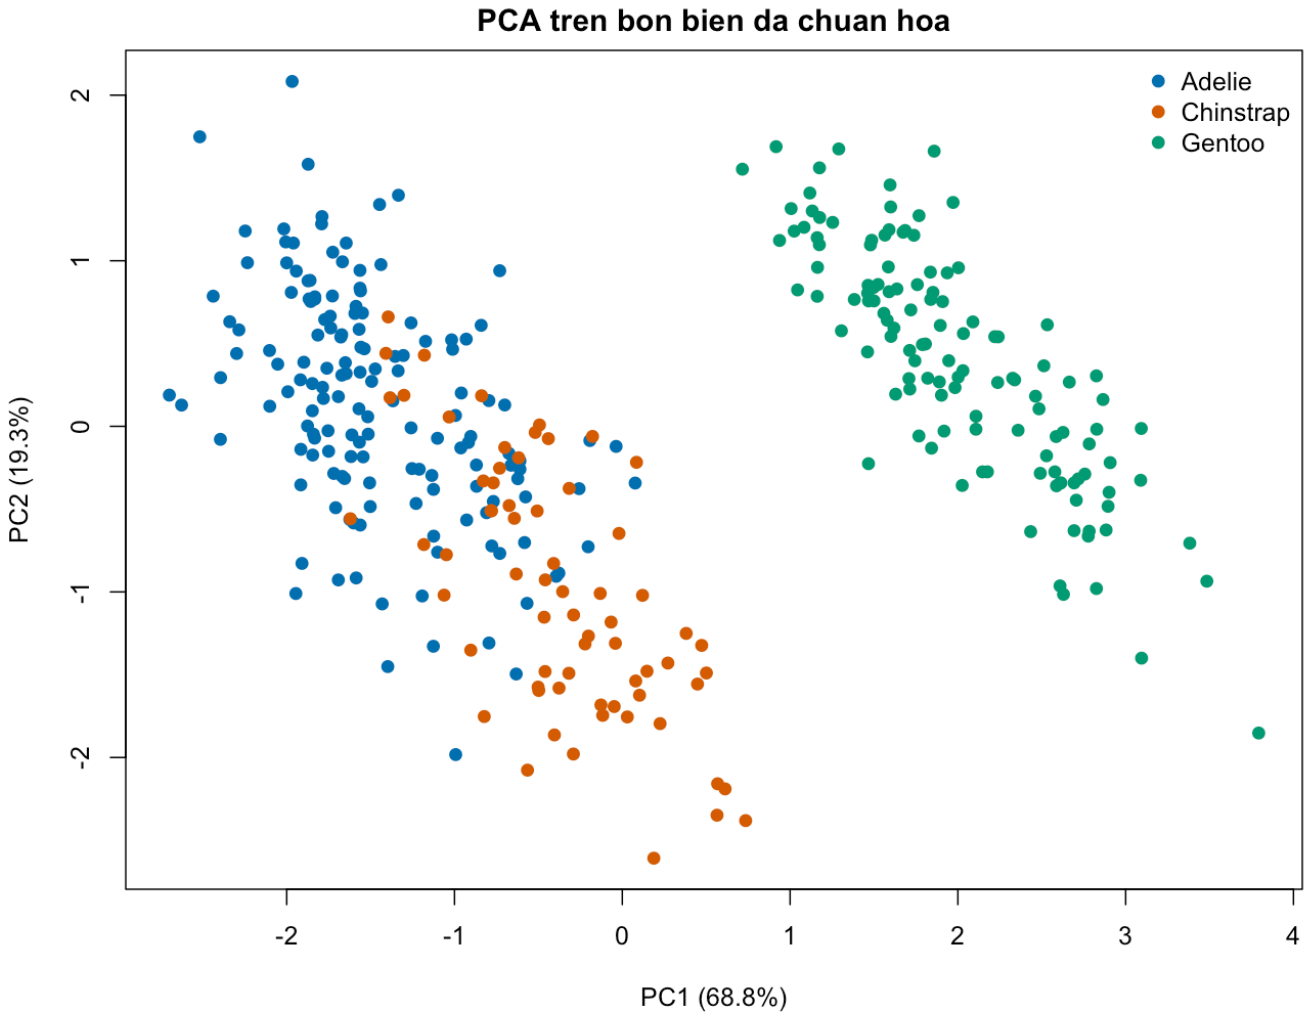
Hình 1: Phân bố bốn đặc điểm theo loài; chấm ngoài râu hộp chỉ là dấu hiệu cần xem xét.

Boxplot cho thấy Gentoo tách rõ ở chiều dài vây và khối lượng; Adelie và Chinstrap còn chồng lấn đáng kể ở khối lượng và độ sâu mỏ. Một điểm nằm ngoài râu hộp chưa đủ để khẳng định đó là lỗi nhập liệu.



Hình 2: Ma trận phân tán: Adelie xanh lam, Chinstrap cam, Gentoo xanh lục.

Các biến liên hệ với nhau và có cấu trúc phân nhóm. Tương quan trên toàn mẫu có thể phản ánh khác biệt giữa loài; vì vậy phần giả định dùng thêm tương quan trong nhóm.



Hình 3: PCA trên biến đã chuẩn hóa về trung bình 0 và độ lệch chuẩn 1.

Hai thành phần đầu giải thích **88.16%** tổng phương sai của dữ liệu chuẩn hóa. Chuẩn hóa trước PCA tránh để đơn vị gram chi phối kết quả. PCA là công cụ khám phá, không thay thế kiểm định MANOVA. MANOVA ở đây sử dụng cả bốn biến gốc; việc thay đổi đơn vị đo bằng phép biến đổi khả nghịch không làm đổi các thống kê kiểm định tổng thể.

4 Đánh giá giả định MANOVA

4.1 Tính độc lập và bối cảnh lấy mẫu

Tệp không chứa mã cá thể hay thông tin lặp đo; mỗi dòng được xem là một cá thể. **Tính độc lập là giả định về thiết kế lấy mẫu**, không thể xác nhận bằng Shapiro–Wilk, Box's M hay biểu đồ. Nếu có các lần đo lặp hoặc phụ thuộc theo cụm, cần mô hình tương ứng và sai số chuẩn phù hợp.

Đây là dữ liệu quan sát. Loài, đảo và giới tính có thể gắn với nhau; mô hình một nhân tố so sánh các nhóm quan sát được, chưa tách ảnh hưởng của các yếu tố khác.

4.2 Tương quan, khả nghịch và cỡ mẫu

Bảng 4: Tương quan từ ma trận hiệp phương sai gộp trong nhóm.

Biến	Dài mỏ	Sâu mỏ	Dài vây	Khối lượng
Dài mỏ	1.000	0.528	0.483	0.585
Sâu mỏ	0.528	1.000	0.488	0.622
Dài vây	0.483	0.488	1.000	0.585
Khối lượng	0.585	0.622	0.585	1.000

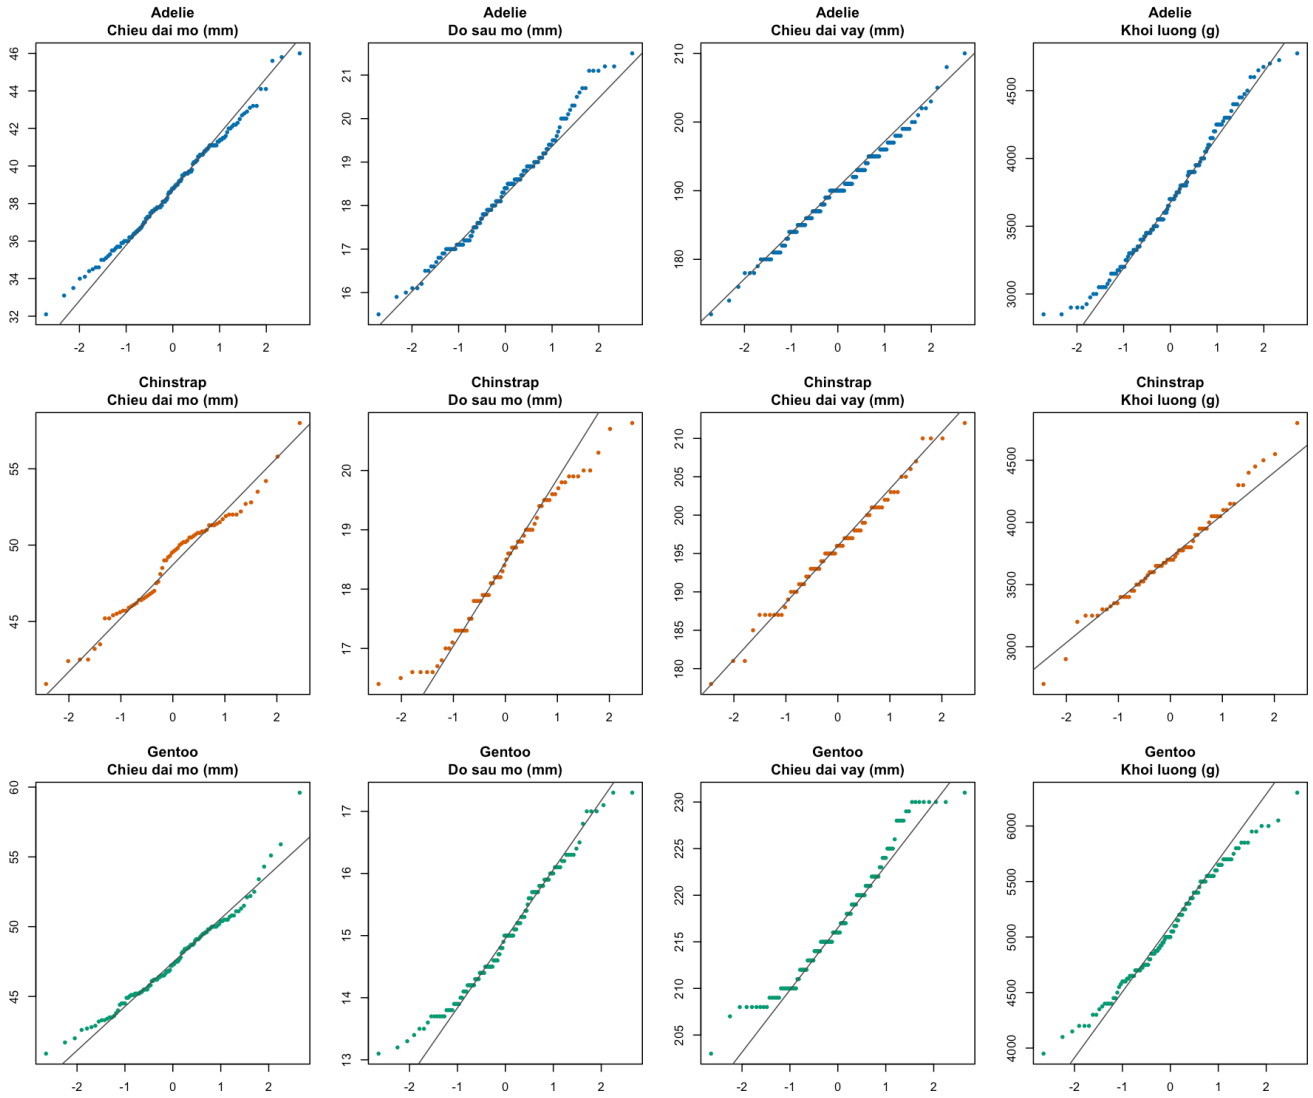
Tương quan trong nhóm nằm khoảng 0,48–0,62: các biến có liên hệ nhưng không gần phụ thuộc tuyến tính hoàn toàn. Điều này ủng hộ việc xem xét đồng thời chúng bằng MANOVA.

Loài	Hạng hiệp phương sai	Số điều kiện tương quan
Adelie	4	6.576
Chinstrap	4	8.459
Gentoo	4	11.008

Cả ba ma trận hiệp phương sai có hạng 4; số điều kiện sau chuẩn hóa không gợi ý mất ổn định nghiêm trọng. Mỗi nhóm có nhiều quan sát hơn bốn biến đáp ứng. Cỡ mẫu không cân bằng (nhóm lớn nhất khoảng 2.22 lần nhóm nhỏ nhất), cần lưu ý khi hiệp phương sai khác nhau.

4.3 Phân phối trong nhóm và ngoại lệ đa biến

Chuẩn đa biến cần được xem xét **trong từng loài**, không phải trên hỗn hợp cả ba loài.



Hình 4: Q–Q chuẩn của từng biến trong từng loài.

4.3.1 Shapiro–Wilk: kiểm định chuẩn của từng phân phối biên

Với từng cặp loài–biến (i, k), kiểm định riêng

$$H_{0,ik}^{\mathrm{SW}}: \ Y_{ijk} \sim \mathcal{N}(\mu_{ik}, \sigma_{ik}^2) \text{ với một } \mu_{ik} \in \mathbb{R}, \ \sigma_{ik}^2 > 0,$$
$$H_{1,ik}^{\mathrm{SW}}: \ \text{phân phối biên này không thuộc họ chuẩn.}$$

Giả định: các quan sát của biến k trong loài i là mẫu độc lập, cùng phân phối, từ một biến liên tục. Dữ liệu làm tròn có thể tạo giá trị trùng và ảnh hưởng phép hiệu chuẩn liên tục. Với $X_{(1)} \leq \cdots \leq X_{(n_i)}$, thống kê là

$$W = \frac{\left(\sum_{j=1}^{n_i} a_j X_{(j)}\right)^2}{\sum_{j=1}^{n_i} (X_j - \bar{X})^2}.$$

Các hệ số a_j được xác định từ kỳ vọng và hiệp phương sai của thống kê thứ tự của mẫu chuẩn tắc, chuẩn hóa về độ dài 1. W nhỏ là bằng chứng chống lại chuẩn. P-value phía trái là $\Pr_{H_0}(W \le W_{\text{obs}})$, không lấy từ phân phối F hoặc χ^2. Hàm `shapiro.test()` dùng xấp xỉ số của phân phối W ở các cỡ mẫu hiện tại. Sau đó hiệu chỉnh Holm cho cả 12 giả thuyết $H_{0,ik}^{\text{SW}}$; bác bỏ từng giả thuyết khi p-value Holm không vượt 0,05.

Loài	Biến	W	p	p Holm (12)
Adelie	Dài mỏ	0.993	0.7166	1.0000
Adelie	Sâu mỏ	0.985	0.0925	0.7399
Adelie	Dài vây	0.993	0.7200	1.0000
Adelie	Khối lượng	0.981	0.0324	0.2916
Chinstrap	Dài mỏ	0.975	0.1941	1.0000
Chinstrap	Sâu mỏ	0.973	0.1418	0.9925
Chinstrap	Dài vây	0.989	0.8106	1.0000
Chinstrap	Khối lượng	0.984	0.5605	1.0000
Gentoo	Dài mỏ	0.973	0.0135	0.1484
Gentoo	Sâu mỏ	0.976	0.0277	0.2770
Gentoo	Dài vây	0.962	0.0016	0.0194
Gentoo	Khối lượng	0.986	0.2336	1.0000

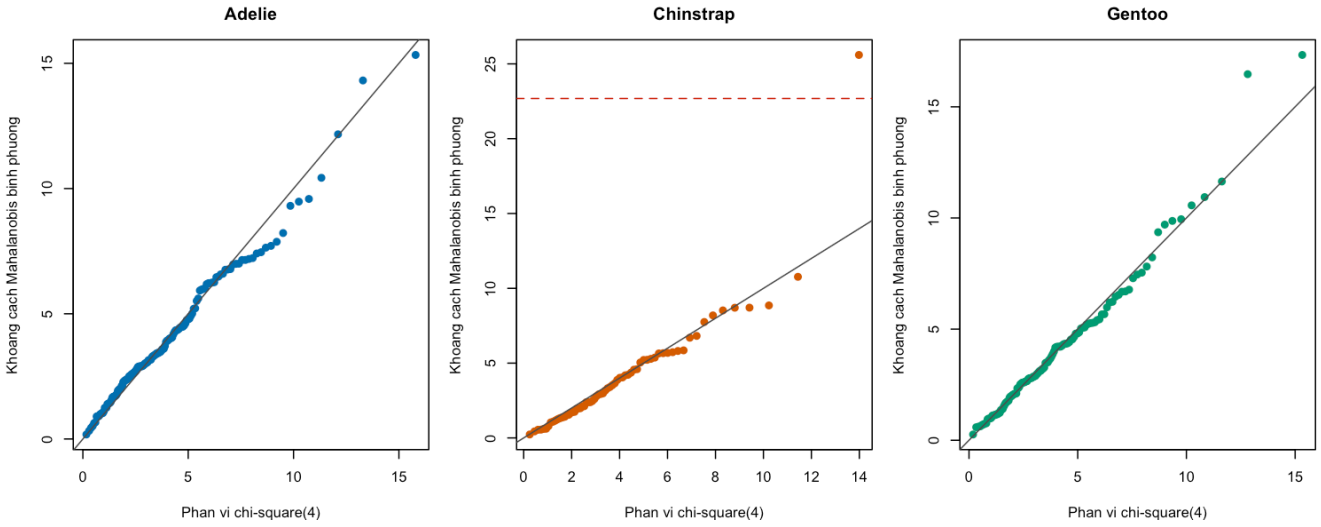
Một số kiểm định Shapiro–Wilk chưa hiệu chỉnh có ý nghĩa; sau Holm trên 12 phép kiểm định, chiều dài vây của Gentoo vẫn lệch chuẩn ($p_{\text{Holm}} = 0.0194$). Các kết quả còn lại không có ý nghĩa sau hiệu chỉnh **không chứng minh phân phối chuẩn đa biến**: chuẩn của từng biên là điều kiện cần, chưa đủ. Các Q–Q plots giúp xem xét mức độ lệch và phần đuôi; giả định chuẩn không nên được xem là hoàn toàn thỏa mãn.

4.3.2 Khoảng cách Mahalanobis: chẩn đoán, không gán p-value kiểm định chính xác

Khoảng cách Mahalanobis được tính riêng theo trung bình và hiệp phương sai của từng loài:

$$D_{ij}^2 = (\mathbf{y}_{ij} - \bar{\mathbf{y}}_i)^T S_i^{-1} (\mathbf{y}_{ij} - \bar{\mathbf{y}}_i).$$

Nếu **biết** trung bình và hiệp phương sai thật, với một quan sát chuẩn đa biến ta có $(\mathbf{Y}-\mu_i)^T \Sigma_i^{-1} (\mathbf{Y}-\mu_i) \sim \chi_p^2$. Ở đây cả hai tham số đều được ước lượng và quan sát đang xét cũng góp vào ước lượng, nên không có đẳng thức phân phối đó cho D_{ij}^2. Đường χ_p^2 và ngưỡng α/N chỉ cung cấp tham chiếu chẩn đoán; không đặt một giả thuyết "điểm là lỗi đo" rồi kết luận từ đường này. Cột `approximate_tail_p` trong CSV là đuôi χ_p^2 tham khảo, không phải p-value ngoại lệ đã hiệu chuẩn chính xác; ngưỡng mang tên Bonferroni không tự bảo đảm FWER nếu các đuôi thành phần không hợp lệ.



Hình 5: Q–Q khoảng cách Mahalanobis với chi-square(4); đường đứt là ngưỡng sàng lọc Bonferroni.

Ngưỡng tham khảo $\chi^2_{4;1-0,05/342} = 22.69$ đánh dấu **1 quan sát**, dòng dữ liệu 170 (Chinstrap, $D^2 = 25.60$). Vì trung bình và hiệp phương sai được ước lượng từ chính mẫu, đây là sàng lọc xấp xỉ, không phải kiểm định ngoại lệ có mức sai lầm chính xác. Khoảng cách cổ điển cũng có thể bị ngoại lệ ảnh hưởng. Giữ điểm này trong phân tích chính vì chưa có bằng chứng là lỗi đo; không xóa quan sát chỉ để cải thiện giả định.

4.4 Đồng nhất ma trận hiệp phương sai

4.4.1 Box's M: giả thuyết về toàn bộ ma trận

Đối tượng kiểm định là Σ_i, không phải vector trung bình:

$$H_0^{\text{Box}} : \Sigma_1 = \Sigma_2 = \Sigma_3, \qquad H_1^{\text{Box}} : \exists i \neq \ell : \Sigma_i \neq \Sigma_\ell.$$

Giả định: mẫu độc lập giữa và trong nhóm, chuẩn đa biến trong từng nhóm, ma trận hiệp phương sai xác định dương và $n_i > p$ để các S_i khả nghịch. Các trung bình nhóm được phép khác nhau dưới H_0^{Box}. Bác bỏ đồng nhất hiệp phương sai không phải là bằng chứng trực tiếp về khác biệt trung bình.

Box's M kiểm định $H_0 : \Sigma_1 = \Sigma_2 = \Sigma_3$. Với $N = 342$, $g = 3$, $p = 4$ và $S_p = E/(N-g)$:

$$M = (N-g)\log|S_p| - \sum_i (n_i - 1)\log|S_i|,$$

$$c = \frac{2p^2 + 3p - 1}{6(p+1)(g-1)} \left[\sum_i \frac{1}{n_i - 1} - \frac{1}{N-g} \right].$$

Dùng xấp xỉ $(1-c)M \sim \chi^2_{(g-1)p(p+1)/2}$ thu được $M = 78.301$, $\chi^2 = 76.795$, $df = 20$, $p = 1.36e-08$. Bác bỏ giả thuyết đồng nhất ma trận hiệp phương sai. Box's M nhạy với lệch chuẩn, nên cần đọc cùng các chẩn đoán phân phối.

Với $B = (1-c)M$, p-value ở trên được tính bằng $\Pr(\chi^2_{20} \geq B_{\text{obs}})$. Quy tắc là bác bỏ H_0^{Box} khi p-value không vượt 0,05. Đây là xấp xỉ dưới chuẩn đa biến, không phải phân phối chính xác hữu hạn mẫu; lệch chuẩn làm giảm độ tin cậy của phép hiệu chuẩn.

4.4.2 Levene dùng trung vị (Brown–Forsythe): kiểm tra từng độ phân tán

Với mỗi biến k, giả thuyết phương sai thường được quan tâm là

$$H_{0,k}^{\text{var}} : \sigma_{1k}^2 = \sigma_{2k}^2 = \sigma_{3k}^2, \qquad H_{1,k}^{\text{var}} : \exists i \neq \ell : \sigma_{ik}^2 \neq \sigma_{\ell k}^2.$$

Đặt $Z_{ijk} = |Y_{ijk} - \widetilde{Y}_{ik}|$, trong đó $\widetilde{Y}_{ik}$ là trung vị mẫu của nhóm. Hàm `leveneTest(..., center=median)` thực hiện ANOVA trên Z, với

$$F_{\text{BF},k} = \frac{\sum_i n_i (\bar{Z}_{ik} - \bar{Z}_{\cdot k})^2/(g-1)}{\sum_{i,j} (Z_{ijk} - \bar{Z}_{ik})^2/(N-g)}.$$

Giả định và ý nghĩa chính xác: cần quan sát độc lập, cùng phân phối trong nhóm và mômen đủ hữu hạn cho xấp xỉ. Thủ tục trực tiếp so sánh kỳ vọng độ lệch tuyệt đối quanh trung vị quần thể, $\tau_{ik} = \mathbb{E}|Y_{ijk} - m_{ik}|$: $H_{0,k}^{\text{BF}} : \tau_{1k} = \tau_{2k} = \tau_{3k}$. Nếu các phân phối có cùng dạng, chỉ khác vị trí và thang đo, τ_{ik} tỉ lệ với σ_{ik} và có thể diễn giải như kiểm tra đồng nhất phương sai. Với dạng phân phối khác nhau tùy ý, hai giả thuyết không tương đương hoàn toàn.

Tham chiếu xấp xỉ là $F_{g-1,N-g} = F_{2,339}$; p-value bằng $\Pr(F_{2,339} \geq F_{\text{BF},k}^{\text{obs}})$. Do dùng trung vị ước lượng và biến đổi trị tuyệt đối, không khẳng định đây là kiểm định F chính xác. Hiệu chỉnh Holm trên bốn p-value trước khi kết luận từng biến. Cách định nghĩa và lựa chọn tâm được trình bày trong NIST: Levene test.

Biến	F	p	p Holm (4)
Dài mỏ	2.242	0.1078	0.3233
Sâu mỏ	2.037	0.1320	0.3233
Dài vây	0.331	0.7188	0.7188
Khối lượng	5.120	0.0064	0.0258

Brown–Forsythe bác bỏ đồng nhất độ phân tán của khối lượng sau Holm; với diễn giải cùng dạng phân phối, điều này gợi ý phương sai khối lượng khác nhau. Các biến còn lại chưa có bằng chứng đủ để bác bỏ, không được kết luận phương sai bằng nhau. Kiểm tra này không xét các hiệp phương sai chéo nên không thay thế Box's M.

Quyết định phân tích: dùng Pillai làm thống kê chính và ba thống kê còn lại để đối chiếu, không chọn theo p-value nhỏ nhất. Pillai **không tự khắc phục** phương sai không đồng nhất, cỡ mẫu không cân bằng hay phụ thuộc quan sát; các p-value MANOVA được diễn giải theo xấp xỉ của mô hình cổ điển. Bổ sung Welch–Holm ở cấp từng biến/cặp loài để đánh giá độ nhạy của kết luận hậu kiểm. Việc chẩn đoán rồi báo cáo Pillai không phải một định lý bảo đảm kiểm soát sai lầm khi mô hình đã sai.

5 MANOVA một nhân tố

5.1 Giả thuyết, giả định và phân phối dưới giả thuyết không

Kiểm định nghiên cứu chính là

$$H_0^{\text{MV}} : \mu_1 = \mu_2 = \mu_3, \qquad H_1^{\text{MV}} : \exists i \neq \ell : \mu_i \neq \mu_\ell.$$

Đây là đẳng thức của các **vector kỳ vọng**, không phải giả thuyết rằng mọi cá thể có cùng hình thái, mọi phân phối hoàn toàn bằng nhau hay cả bốn biến đều phải khác nhau. Giả định dùng để suy ra phân phối tham chiếu là mô hình độc lập–chuẩn đa biến–hiệp phương sai chung ở phần đầu.

Đặt các ma trận tổng bình phương và tích chéo:

$$E = \sum_{i,j} (\mathbf{y}_{ij} - \bar{\mathbf{y}}_i)(\mathbf{y}_{ij} - \bar{\mathbf{y}}_i)^T,$$
$$H = \sum_{i} n_i (\bar{\mathbf{y}}_i - \bar{\mathbf{y}})(\bar{\mathbf{y}}_i - \bar{\mathbf{y}})^T, \qquad T = E + H.$$

Với $S_i = (n_i - 1)^{-1} \sum_j (\mathbf{y}_{ij} - \bar{\mathbf{y}}_i)(\mathbf{y}_{ij} - \bar{\mathbf{y}}_i)^T$, ta có $E = \sum_i (n_i - 1) S_i$. Đặt $q = g - 1 = 2$ và $\nu = N - g = 339$. Dưới H_0^{MV} và mô hình cổ điển,

$$E \sim W_p(\Sigma, \nu), \qquad H \sim W_p(\Sigma, q), \qquad E \perp H.$$

Ở đây $W_p(\Sigma, r)$ ký hiệu phân phối Wishart với ma trận thang Σ và r bậc tự do; H có hạng không quá $q = 2$. Tính độc lập và cấu trúc Wishart là cơ sở của các phân phối tham chiếu MANOVA. Khi Σ_i khác nhau, không còn có thể dùng lập luận này để bảo đảm mức kiểm định cổ điển.

Wilks' lambda là $\Lambda = |E|/|E + H|$. Nếu λ_k là trị riêng của $E^{-1}H$, Pillai là $V = \sum_k \lambda_k/(1 + \lambda_k)$. Có nhiều nhất $\min(p, g - 1) = 2$ trị riêng khác 0, nên V có thể lớn hơn 1 và không vượt 2 trong bài này; không diễn giải V như phần trăm phương sai giải thích.

5.2 Thống kê Pillai và cách tính p-value chính

Với $s = \min(p, q)$, $a = (|p - q| - 1)/2$ và $b = (\nu - p - 1)/2$, phép biến đổi mà `summary.manova()` dùng là

$$F_V = \frac{2b + s + 1}{2a + s + 1} \frac{V}{s - V},$$
$$d_1 = s(2a + s + 1), \qquad d_2 = s(2b + s + 1).$$

Trong bài: $s = 2$, $a = 0{,}5$, $b = 167$, nên $F_V = \frac{337}{4} \frac{V}{2 - V}$, với tham chiếu **xấp xỉ** $F_{8,674}$ dưới H_0^{MV}. P-value chính là

$$p_V = \Pr\{F_{8,674} \geq F_V^{\mathrm{obs}}\}.$$

V lớn (hay F_V lớn) chống lại đẳng thức vector trung bình. Quy tắc đã chọn là bác bỏ H_0^{MV} khi $p_V \leq 0{,}05$, không lựa chọn thống kê có p-value nhỏ nhất trong bốn thống kê.

Wilks dùng $\Lambda = \prod_k (1 + \lambda_k)^{-1}$, giá trị nhỏ chống lại H_0^{MV}. Riêng kích thước bài này, biến đổi Rao dùng trong R là $F_\Lambda = 84(\Lambda^{-1/2} - 1)$, tham chiếu xấp xỉ $F_{8,672}$ và lấy đuôi phải của F_Λ. Hai thống kê bổ sung là Hotelling–Lawley $U = \sum_k \lambda_k$ và Roy $R = \max_k \lambda_k$. Các cột p-value tương ứng cùng nhắm vào H_0^{MV} nhưng dùng các phép xấp xỉ khác nhau; với Roy, giá trị F trong bảng là cận trên khi hiệu ứng có hơn một bậc tự do, nên không xem p-value đó như một phép hiệu chuẩn chính xác. Xem tài liệu chính thức của R về `summary.manova`.

Thống kê	Giá trị	F	df1	df2	p
Pillai	1.637	379.487	8	674	8.62e-244
Wilks	0.019	528.870	8	672	4.16e-284
Hotelling-Lawley	17.342	726.206	8	670	$<$ 1e-300
Roy	15.019	1265.366	4	337	1.66e-201

Kết quả chính: Pillai $V = 1.636648$, $F(8, 674) = 379.487$, $p = 8.62e-244$. Bác bỏ H_0: có khác biệt về vector trung bình của bốn đặc điểm hình thái giữa các loài. Wilks cho cùng kết luận với $\Lambda = 0.018785$. Các p-value cực nhỏ chỉ biểu thị bằng chứng thống kê mạnh trong mô hình, không phải xác suất H_0 đúng; giá trị dưới độ chính xác số được trình bày dưới dạng cận.

Mã đã kiểm tra $T = E + H$ và đối chiếu Pillai/Wilks từ phép tính ma trận với kết quả `manova()`. Vì kết quả tổng thể có ý nghĩa, tiếp tục các phân tích sau MANOVA.

6 Phân tích sau MANOVA

6.1 ANOVA từng biến và độ lớn hiệu ứng

Với từng tọa độ k, kiểm định

$$H_{0,k}^{\mathrm{A}} : \mu_{1k} = \mu_{2k} = \mu_{3k}, \qquad H_{1,k}^{\mathrm{A}} : \exists i \neq \ell : \mu_{ik} \neq \mu_{\ell k}.$$

Giả định để có kiểm định F chính xác: $Y_{ijk} = \mu_{ik} + \varepsilon_{ijk}$ với sai số độc lập, $\varepsilon_{ijk} \sim \mathcal{N}(0, \sigma_k^2)$ và $\sigma_k^2 > 0$ chung cho ba loài. Tương quan giữa các tọa độ không làm hỏng từng kiểm định ANOVA này, nhưng phải tính đến đa kiểm định khi kết luận trên bốn biến.

Đặt

$$SS_{B,k} = \sum_i n_i (\bar{Y}_{ik} - \bar{Y}_{\cdot k})^2, \qquad SS_{E,k} = \sum_{i,j} (Y_{ijk} - \bar{Y}_{ik})^2.$$

Dưới $H_{0,k}^{\mathrm{A}}$ và các giả định trên,

$$F_k = \frac{SS_{B,k}/(g-1)}{SS_{E,k}/(N-g)} \sim F_{2,339}, \qquad p_k = \Pr(F_{2,339} \geq F_k^{\mathrm{obs}}).$$

Bác bỏ $H_{0,k}^{\mathrm{A}}$ khi p-value Holm của nó trong **họ bốn ANOVA** không vượt 0,05. Phương sai chung đã có dấu hiệu không phù hợp, nên bảng ANOVA cổ điển là phân tích theo mô hình tham chiếu; hiệu chỉnh Holm không sửa được p-value thành phần sai hiệu chuẩn.

Thực hiện bốn ANOVA một nhân tố, hiệu chỉnh Holm chung trên bốn p-value. Báo cáo $\eta^2 = SS_B/SS_T$ và $\omega^2 = (SS_B - (g-1)MS_E)/(SS_T + MS_E)$ để mô tả độ lớn khác biệt. Đây là độ lớn hiệu ứng trong mẫu theo nhóm quan sát, không phải tỉ lệ biến thiên do loài gây ra theo nghĩa nhân quả.

Biến	F (2,339)	p Holm (4)	eta2	omega2
Dài mỏ	410.600	8.08e-91	0.708	0.705
Sâu mỏ	359.789	3.02e-84	0.680	0.677
Dài vây	594.802	5.41e-111	0.778	0.776

Biến	F (2,339)	p Holm (4)	eta2	omega2
Khối lượng	343.626	2.89e-82	0.670	0.667

Cả bốn biến đều khác nhau giữa ít nhất hai loài sau Holm. Chiều dài vây có η^2 lớn nhất (0.778); các biến còn lại cũng có độ lớn khác biệt đáng kể trong mẫu. Giả định phương sai của ANOVA vẫn cần được lưu ý, đặc biệt với khối lượng.

6.2 Tukey HSD: cặp loài nào khác nhau?

Với biến k và cặp (a, b), tham số là $\delta_{ab,k} = \mu_{ak} - \mu_{bk}$, kiểm định hai phía

$$H^{\text{pair}}_{0,ab,k} : \delta_{ab,k} = 0, \qquad H^{\text{pair}}_{1,ab,k} : \delta_{ab,k} \neq 0.$$

Giả định: quan sát độc lập, phân phối chuẩn trong từng loài và phương sai chung σ_k^2 cho ba loài ở biến đang xét. Dùng $MS_{E,k} = SS_{E,k}/(N-g)$ từ ANOVA, đặt

$$Q_{ab,k} = \frac{|\bar{Y}_{ak} - \bar{Y}_{bk}|}{\sqrt{\frac{MS_{E,k}}{2}(1/n_a + 1/n_b)}}.$$

P-value Tukey–Kramer báo cáo là đuôi của phân phối **studentized range** $\mathcal{Q}_{g,N-g}$ tại $Q^{\text{obs}}_{ab,k}$; nó đã hiệu chỉnh cho họ tất cả ba cặp của biến k, không phải p-value t-test chưa hiệu chỉnh. Khoảng đồng thời tương ứng có dạng

$$\bar{Y}_{ak} - \bar{Y}_{bk} \;\pm\; q_{1-\alpha;g,N-g}\sqrt{\frac{MS_{E,k}}{2}(1/n_a + 1/n_b)},$$

với $q_{1-\alpha;g,N-g}$ là phân vị studentized range. Bác bỏ $H^{\text{pair}}_{0,ab,k}$ khi p-value Tukey không vượt 0,05, tương đương khoảng tương ứng không chứa 0. Phân phối range cho bảo đảm chính xác trong mô hình chuẩn đồng phương sai, cân bằng; điều chỉnh cỡ mẫu Tukey–Kramer dùng cho mẫu không cân bằng và không biến phương pháp thành kiểm định cho phương sai khác nhau. Do vi phạm giả định trong dữ liệu này, cần đối chiếu với Welch–Holm ở phần tiếp theo.

Với nhóm không bằng nhau, `TukeyHSD()` sử dụng điều chỉnh Tukey–Kramer. Mỗi biến có ba so sánh; p-value và khoảng tin cậy 95% được hiệu chỉnh **trong họ ba cặp của riêng biến đó**, không kiểm soát đồng thời cả 12 so sánh. Chênh lệch luôn tính **loài đứng trước trừ loài đứng sau**; đơn vị là mm, riêng khối lượng là g.

Biến	Cặp	Chênh	CI 95% Tukey	p
Dài mỏ	Chinstrap-Adelie	10.04	[9.02; 11.06]	0 (số học)
Dài mỏ	Gentoo-Adelie	8.71	[7.87; 9.56]	0 (số học)
Dài mỏ	Gentoo-Chinstrap	-1.33	[-2.38; -0.28]	0.0089
Sâu mỏ	Chinstrap-Adelie	0.07	[-0.31; 0.46]	0.8929
Sâu mỏ	Gentoo-Adelie	-3.36	[-3.68; -3.04]	0 (số học)
Sâu mỏ	Gentoo-Chinstrap	-3.44	[-3.84; -3.04]	0 (số học)
Dài vây	Chinstrap-Adelie	5.87	[3.59; 8.15]	1.14e-08
Dài vây	Gentoo-Adelie	27.23	[25.33; 29.13]	0 (số học)
Dài vây	Gentoo-Chinstrap	21.36	[19.00; 23.73]	0 (số học)

Biến	Cặp	Chênh	CI 95% Tukey	p
Khối lượng	Chinstrap-Adelie	32.43	[-126.50; 191.35]	0.8807
Khối lượng	Gentoo-Adelie	1375.35	[1243.18; 1507.53]	0 (số học)
Khối lượng	Gentoo-Chinstrap	1342.93	[1178.48; 1507.38]	0 (số học)

Một số p-value từ `TukeyHSD()` được máy trả về 0 do giới hạn độ chính xác của phép tính đuôi; bảng ghi `0 (số học)`, không diễn giải là xác suất bằng 0 và không tự suy ra một cận chính xác từ giá trị máy trả về. Xem tài liệu R về Tukey HSD.

Adelie–Chinstrap: khác biệt về chiều dài mỏ và chiều dài vây; chưa có bằng chứng khác biệt về độ sâu mỏ hoặc khối lượng. Gentoo–Adelie và Gentoo–Chinstrap: khác biệt ở cả bốn biến. Gentoo có vây dài hơn và cơ thể nặng hơn, nhưng mỏ nông hơn; chiều dài mỏ Gentoo nằm giữa Adelie và Chinstrap.

6.3 Kiểm tra độ nhạy: Welch và Holm chung cho 12 cặp

Welch xét **cùng giả thuyết cặp trung bình** $H^{\text{pair}}_{0,ab,k} : \mu_{ak} = \mu_{bk}$ đối lại $H^{\text{pair}}_{1,ab,k} : \mu_{ak} \neq \mu_{bk}$. Đổi phương pháp không làm đổi tham số cần suy luận; đổi ở mô hình phương sai và phân phối tham chiếu.

Giả định: hai mẫu độc lập, cùng phân phối trong từng nhóm, có phương sai dương hữu hạn, và trung bình mẫu đủ gần chuẩn. Chuẩn trong từng nhóm giúp biện minh phép xấp xỉ hữu hạn mẫu; với phân phối không chuẩn, cần điều kiện cho định lý giới hạn trung tâm và cỡ mẫu đủ lớn, không có bảo đảm chung chỉ từ $n_i > 30$. Không giả định $\sigma^2_{ak} = \sigma^2_{bk}$; Welch vẫn không sửa được phụ thuộc giữa cá thể hay ngoại lệ tùy ý.

Với phương sai mẫu s^2_{ak}, s^2_{bk}, đặt $u = s^2_{ak}/n_a$, $v = s^2_{bk}/n_b$. Thống kê và bậc tự do Welch–Satterthwaite là

$$t_W = \frac{\bar{Y}_{ak} - \bar{Y}_{bk}}{\sqrt{u+v}}, \qquad \widehat{\nu}_W = \frac{(u+v)^2}{u^2/(n_a-1) + v^2/(n_b-1)}.$$

Dưới $H^{\text{pair}}_{0,ab,k}$, dùng $t_W \mathrel{\dot\sim} t_{\widehat{\nu}_W}$; dấu $\dot\sim$ nhấn mạnh xấp xỉ, kể cả với mẫu chuẩn nhưng phương sai khác nhau. P-value hai phía là

$$p_{ab,k} = 2\,\Pr\{t_{\widehat{\nu}_W} \geq |t^{\text{obs}}_W|\}.$$

Áp dụng Holm trên toàn bộ $4\binom{3}{2} = 12$ giá trị $p_{ab,k}$, bác bỏ từng giả thuyết nếu $\tilde{p}_{ab,k} \leq 0{,}05$. Họ 12 cặp này được xác định trước, không chỉ hiệu chỉnh những cặp có vẻ khác nhau trên hình.

Do Box's M và Levene phát hiện vi phạm giả định, thực hiện thêm Welch t-test hai phía cho mỗi biến/cặp loài, cho phép phương sai khác nhau và dùng bậc tự do Welch–Satterthwaite. Áp dụng Holm **chung trên cả 12 p-value**. Phương pháp này kiểm soát sai lầm loại I theo họ 12 kiểm định nếu các p-value thành phần hợp lệ; đây là kiểm tra ở cấp đơn biến, không phải một kiểm định MANOVA tổng thể có tính vững.

Biến	Cặp	Chênh	p Holm (12)	Có ý nghĩa
Dài mỏ	Chinstrap-Adelie	10.04	1.45e-40	Có
Dài mỏ	Gentoo-Adelie	8.71	3.09e-67	Có
Dài mỏ	Gentoo-Chinstrap	-1.33	0.0232	Có
Sâu mỏ	Chinstrap-Adelie	0.07	1.0000	Chưa
Sâu mỏ	Gentoo-Adelie	-3.36	1.66e-72	Có
Sâu mỏ	Gentoo-Chinstrap	-3.44	1.49e-41	Có

Biến	Cặp	Chênh	p Holm (12)	Có ý nghĩa
Dài vây	Chinstrap-Adelie	5.87	2.42e-07	Có
Dài vây	Gentoo-Adelie	27.23	3.83e-98	Có
Dài vây	Gentoo-Chinstrap	21.36	2.42e-41	Có
Khối lượng	Chinstrap-Adelie	32.43	1.0000	Chưa
Khối lượng	Gentoo-Adelie	1375.35	6.94e-64	Có
Khối lượng	Gentoo-Chinstrap	1342.93	2.73e-47	Có

Các kết luận về cặp loài không thay đổi. Đặc biệt, chiều dài mỏ Gentoo thấp hơn Chinstrap khoảng **1,33 mm**, vẫn có ý nghĩa sau hiệu chỉnh toàn bộ 12 so sánh ($p_{\text{Holm}} = 0.0232$). Sự nhất quán này hỗ trợ kết luận hậu kiểm khi cho phép phương sai khác nhau; không chứng minh mọi giả định MANOVA đã được đáp ứng. Các khoảng tin cậy Welch lưu ở CSV là khoảng 95% **riêng lẻ**, chưa hiệu chỉnh đồng thời, nên không dùng chúng như khoảng tin cậy Holm.

7 Kết luận và thảo luận

Theo mô hình tham chiếu MANOVA cổ điển, bác bỏ giả thuyết ba vector trung bình hình thái bằng nhau. Trên 342 quan sát hợp lệ, Pillai cho $V = 1{,}63665$, $F(8, 674) = 379{,}487$, $p < 0{,}001$. Tuy nhiên, đồng nhất hiệp phương sai và tính chuẩn có dấu hiệu không phù hợp, nên không khẳng định phép kiểm định thực tế giữ đúng mức 5% chỉ vì p-value rất nhỏ. Các kiểm định Welch–Holm cho bằng chứng bổ sung ở cấp từng cặp trung bình dưới các giả định riêng đã nêu. Bốn ANOVA cổ điển cũng có ý nghĩa sau Holm, với độ lớn hiệu ứng mô tả η^2 khoảng 0,67–0,78.

Các chênh lệch trung bình ước lượng trên thang đo gốc dưới đây giúp đánh giá độ lớn khác biệt. Bài không có ngưỡng khác biệt tối thiểu quan trọng về sinh học được xác định trước, nên không đồng nhất ý nghĩa thống kê với ý nghĩa thực tiễn:

- **Gentoo so với Adelie:** vây dài hơn khoảng 27,23 mm, nặng hơn 1.375,35 g, mỏ dài hơn 8,71 mm và nông hơn 3,36 mm.
- **Gentoo so với Chinstrap:** vây dài hơn khoảng 21,36 mm, nặng hơn 1.342,93 g, mỏ ngắn hơn 1,33 mm và nông hơn 3,44 mm.
- **Chinstrap so với Adelie:** mỏ dài hơn khoảng 10,04 mm và vây dài hơn 5,87 mm; chưa có bằng chứng khác biệt về độ sâu mỏ và khối lượng sau hiệu chỉnh. Không bác bỏ khác biệt không đồng nghĩa với chứng minh hai loài tương đương.

Giả định hiệp phương sai đồng nhất bị bác bỏ; có dấu hiệu lệch chuẩn trong một nhóm và một điểm cần kiểm tra thêm. Do đó kết luận MANOVA cần đi kèm các giới hạn của mô hình. Kết quả Welch–Holm nhất quán với hậu kiểm Tukey, hỗ trợ tính ổn định của các nhận định theo từng cặp biến.

7.1 Giới hạn và hướng phát triển

- **Thiết kế quan sát và yếu tố đi kèm:** loài có quan hệ với đảo lấy mẫu. Bảng dưới cho thấy Chinstrap chỉ có ở Dream, Gentoo chỉ có ở Biscoe, còn Adelie xuất hiện ở ba đảo. Vì có các ô tổ hợp loài–đảo trống, việc tách riêng hiệu ứng loài và đảo cần lựa chọn mô hình/các so sánh có dữ liệu hỗ trợ; không thể thêm tương tác đầy đủ rồi suy diễn cho mọi tổ hợp.
- **Giới tính và yếu tố chưa đo:** khác biệt đực–cái có thể góp phần vào phân bố hình thái. Mô hình nhiều nhân tố hoặc MANCOVA phù hợp là hướng mở rộng khi làm rõ câu hỏi và giả định; cần xử lý giới tính thiếu trước khi dùng biến này.
- **Dữ liệu thiếu và ngoại lệ:** complete-case analysis mất 2/344 quan sát (0,58%), nhưng tỉ lệ nhỏ không bảo đảm cơ chế thiếu là ngẫu nhiên. Điểm Mahalanobis lớn cần đối chiếu hồ sơ; không tự

động loại bỏ.

- **Suy rộng và nhân quả:** kết quả mô tả các mẫu và bối cảnh lấy mẫu được cung cấp. Không suy ra tác động nhân quả của loài, không mặc định đại diện cho mọi quần thể chim cánh cụt. Nếu cần suy luận đa biến vững hơn, có thể nghiên cứu mô hình hiệp phương sai khác nhau hoặc bootstrap được thiết kế cho tình huống đó; hoán vị nhãn thông thường cũng cần giả định trao đổi được, nên không tự khắc phục bất đồng nhất hiệp phương sai.

Bảng 12: Phân bố loài theo đảo trong mẫu phân tích.

Loài	Biscoe	Dream	Torgersen
Adelie	44	56	51
Chinstrap	0	68	0
Gentoo	123	0	0

8 Tái lập và kiểm tra kết quả

Mở `TH2_MANOVA.Rmd` trong RStudio, chạy các chunk từ trên xuống hoặc chọn **Knit → Knit to HTML**. Mỗi phần kiểm định có giả thuyết và công thức trước chunk tính toán, sau đó là bảng và kết luận. Có thể dùng lệnh trong thư mục Exercise 4:

```
Rscript -e 'rmarkdown::render("TH2_MANOVA.Rmd", output_format="html_document")'
```

Cần R cùng `car`, `knitr`, `rmarkdown` và Pandoc; bản PDF dùng XeLaTeX. Script chỉ đọc dữ liệu cục bộ và ghi vào `TH2_output/`; quá trình render tự chạy lại phân tích. Kết quả gồm bảng CSV, hình PNG, `results.rds` và `sessionInfo.txt` ghi môi trường R.

Các kiểm tra tự động xác nhận đầu vào hợp lệ, dấu định thức của ma trận hiệp phương sai, $T = E + H$, và Wilks/Pillai tính từ ma trận khớp `manova()`. Phép biến đổi F và đuôi phân phối Pillai, cùng thống kê t, bậc tự do và p-value Welch của cả 12 cặp, được đối chiếu với công thức trong bài. Đây là đối chiếu phép tính, không thay thế đánh giá giả định hay chất lượng dữ liệu.

Nguồn bài tập: `TH2.pdf` và `penguins_size.csv` được cung cấp trong thư mục Exercise 4. Các hàm sử dụng: `stats::manova`, `stats::summary.manova`, `stats::aov`, `stats::TukeyHSD`, `stats::t.test`, `stats::p.adjust`, `stats::shapiro.test`, `stats::mahalanobis`, `stats::prcomp` và `car::leveneTest`. Có thể mở tài liệu cài sẵn bằng `help("summary.manova")`, `help("TukeyHSD")`, `help("p.adjust")` và `help("leveneTest", package="car")`. Box's M được tính trực tiếp theo công thức đã nêu.

8.1 Bản nguồn để làm việc

`TH2_MANOVA.Rmd` là nguồn duy nhất của phép tính và phần diễn giải. Các chunk R được đặt ngay trước bảng hoặc hình tương ứng; có thể chạy lần lượt từ trên xuống trong RStudio. Bản HTML cho phép mở/thu gọn mã. `TH2_MANOVA.R` chỉ là trình chạy: trích các chunk tính toán từ R Markdown rồi thực thi, không duy trì một bản sao thuật toán riêng.