Ngân hàng câu hỏi chứng minh cuối kỳ

ECDF, ước lượng chiếu, Nadaraya–Watson và kiểm định

Cách dùng. Tài liệu ưu tiên ước lượng chiếu theo phạm vi ôn thi đã cập nhật. Mỗi câu có lời giải đã thực hiện các phép tính và biến đổi, sau đó là công thức cần nhớ hoặc lưu ý. Ký hiệu trang là số trang trong PDF slide. Các chứng minh của DKW, cận minimax và bất đẳng thức oracle là kết quả sâu được slide *phát biểu*; tài liệu giải các hệ quả và phác thảo đúng mức slide, không nhận là chứng minh đầy đủ.

Mã	Phần	PDF slide trong thư mục `../Slides/`
C1	ECDF	`TKPTS_Chương 1.pdf`
C2	Mật độ	`Chap2_Density_estimation (handout).pdf` `Chap2_Density_Estimation_`
C2P	Phép chiếu	`Projection_estimator-2.pdf`
C3	Hồi quy	`Chap3_Nonparametric_Regression_v2.pdf`
C5	Kiểm định	`Chap5_Kiem_dinh_phi_tham_so_v2.pdf`

1 ECDF và khoảng tin cậy

Câu 1. Định nghĩa ECDF; tại sao nó là một hàm phân phối?

Cho $X_1, \dots, X_n$ i.i.d. có CDF F. Định nghĩa $\widehat{F}_n$; chứng minh không giảm, liên tục phải, giới hạn ở $\pm\infty$. Nếu dữ liệu trùng nhau thì bước nhảy bằng bao nhiêu?

Slide: C1, trang 10–12.

Lời giải.

Đặt $I_i(x) = \mathbf{1}_{\{X_i \le x\}}$. Khi $x \le y$, $I_i(x) \le I_i(y)$ với mọi i, nên

$$\widehat{F}_n(x) = \frac{1}{n}\sum_i I_i(x) \le \frac{1}{n}\sum_i I_i(y) = \widehat{F}_n(y).$$

Khi $t \downarrow x$, $I_i(t) \to I_i(x)$; vì tổng hữu hạn, $\widehat{F}_n(t) \to \widehat{F}_n(x)$. Nếu $x < \min_i X_i$ thì $\widehat{F}_n(x) = 0$; nếu $x \ge \max_i X_i$ thì $\widehat{F}_n(x) = 1$. Cuối cùng, tại a,

$$\widehat{F}_n(a) - \widehat{F}_n(a-) = \frac{1}{n}\sum_i \big(\mathbf{1}_{\{X_i \le a\}} - \mathbf{1}_{\{X_i < a\}}\big) = \frac{\#\{i : X_i = a\}}{n}.$$

Vậy ECDF là một CDF; k quan sát trùng tại a tạo một bước nhảy k/n.

Công thức cần nhớ. Đặt $\widehat{F}_n(x) = n^{-1}\sum_i \mathbf{1}\{X_i \le x\}$. Mỗi hàm chỉ báo theo x không giảm và liên tục phải; tổng hữu hạn giữ hai tính chất ấy. Khi $x < \min_i X_i$, tổng bằng 0; khi $x \ge \max_i X_i$, tổng bằng 1. Tại giá trị a, $\widehat{F}_n(a) - \widehat{F}_n(a-) = \#\{i : X_i = a\}/n$.

Lưu ý. Slide 12 nói "đúng n bước nhảy"; điều này chỉ đúng khi mọi quan sát phân biệt. Có giá trị trùng, số bước nhảy bằng số giá trị *khác nhau*.

Câu 2. Tính ECDF và xác suất thực nghiệm của một khoảng

Với mẫu $(1, 2, 2, 4, 5)$, tính $\widehat{F}_n(2-), \widehat{F}_n(2), \widehat{F}_n(3)$ và $\widehat{P}((2, 4])$.

Slide: C1, trang 11–12.

Lời giải.

Với mẫu đã sắp $1, 2, 2, 4, 5$, ta có

$$\widehat{F}_n(x) = \begin{cases} 0 & x < 1, \\ 1/5 & 1 \le x < 2, \\ 3/5 & 2 \le x < 4, \\ 4/5 & 4 \le x < 5, \\ 1 & x \ge 5. \end{cases}$$

Suy ra $\widehat{F}_n(2-) = 1/5$, $\widehat{F}_n(2) = 3/5$, $\widehat{F}_n(3) = 3/5$. Khoảng $(2, 4]$ chỉ chứa quan sát 4 nên $\widehat{P}((2, 4]) = 1/5 = \widehat{F}_n(4) - \widehat{F}_n(2)$.

Lưu ý. Các giá trị lần lượt là $1/5, 3/5, 3/5$ và $\widehat{F}_n(4) - \widehat{F}_n(2) = 1/5$. Nếu đổi thành $[2, 4]$, kết quả là $\widehat{F}_n(4) - \widehat{F}_n(2-) = 3/5$. Dấu $\le$ trong định nghĩa quyết định giá trị tại điểm nhảy.

Câu 3. Tại sao $n\widehat{F}_n(x)$ có phân phối nhị thức? Từ đó suy ra tính không chệch và phương sai

Slide: C1, trang 14–15, 20.

Lời giải.

Với x cố định, đặt $p = F(x)$. Ta có

$$\mathbb{P}(I_i(x) = 1) = \mathbb{P}(X_i \le x) = p, \qquad \mathbb{P}(I_i(x) = 0) = 1 - p.$$

Do mẫu độc lập, $I_1(x), \dots, I_n(x)$ là Bernoulli(p) độc lập, nên $n\widehat{F}_n(x) = \sum_i I_i(x) \sim \mathrm{Bin}(n, p)$. Tính trực tiếp:

$$\mathbb{E}\widehat{F}_n(x) = \frac{1}{n}\sum_i \mathbb{E}I_i(x) = \frac{np}{n} = F(x),$$
$$\operatorname{Var}\widehat{F}_n(x) = \frac{1}{n^2}\sum_i \operatorname{Var} I_i(x) = \frac{np(1-p)}{n^2} = \frac{F(x)(1-F(x))}{n}.$$

Vì $\mathbb{E}\widehat{F}_n(x) = F(x)$, ECDF không chệch tại x.

Công thức cần nhớ. Với x cố định, $I_i = \mathbf{1}\{X_i \le x\}$ là Bernoulli với tham số $p = F(x)$; các I_i độc lập. Do đó $n\widehat{F}_n(x) = \sum_i I_i \sim \mathrm{Bin}(n, p)$. Suy ra

$$\mathbb{E}\widehat{F}_n(x) = p, \qquad \operatorname{Var}(\widehat{F}_n(x)) = \frac{p(1-p)}{n}.$$

Tính không chệch là $\mathbb{E}\widehat{F}_n(x) - F(x) = 0$. Độc lập giữa *các quan sát* là bước quyết định, không phải độc lập giữa $\widehat{F}_n(x)$ và $\widehat{F}_n(y)$.

Câu 4. Tính hiệp phương sai $\operatorname{Cov}(\widehat{F}_n(x), \widehat{F}_n(y))$

Slide: C1, trang 14–15; mở rộng trực tiếp từ định nghĩa.

Lời giải.

Viết $I_i(x) = \mathbf{1}_{\{X_i \le x\}}$. Khai triển:

$$\operatorname{Cov}(\widehat{F}_n(x), \widehat{F}_n(y)) = \frac{1}{n^2}\sum_{i,j} \operatorname{Cov}(I_i(x), I_j(y)).$$

Các hạng $i \neq j$ bằng 0 do độc lập. Với $i = j$,

$$I_i(x)I_i(y) = \mathbf{1}_{\{X_i \leq \min(x,y)\}},$$

nên

$$\mathrm{Cov}(I_i(x), I_i(y)) = F(\min(x,y)) - F(x)F(y).$$

Có n hạng giống nhau, do đó

$$\boxed{\mathrm{Cov}(\widehat{F}_n(x), \widehat{F}_n(y)) = \frac{F(\min(x,y)) - F(x)F(y)}{n}.}$$

Nếu $x < y$, tử số bằng $F(x)\{1 - F(y)\}$.

Công thức cần nhớ. Viết $I_i(x) = \mathbf{1}\{X_i \leq x\}$. Hạng với $i \neq j$ có hiệp phương sai 0. Với cùng i, $I_i(x)I_i(y) = I_i(\min\{x,y\})$. Vì vậy

$$\mathrm{Cov}(\widehat{F}_n(x), \widehat{F}_n(y)) = \frac{F(\min\{x,y\}) - F(x)F(y)}{n}.$$

Nếu $x < y$, kết quả rút gọn thành $F(x)[1 - F(y)]/n$.

Câu 5. Chứng minh nhất quán tại một điểm và CLT cho ECDF

Slide: C1, trang 15–16.

Lời giải.

Ta đã có $\widehat{F}_n(x) = n^{-1}\sum_i I_i(x)$ và $\mathbb{E}I_i(x) = F(x)$. Luật số lớn cho

$$\widehat{F}_n(x) \xrightarrow{\text{a.s.}} F(x).$$

Vì $\mathrm{Var}\, I_i(x) = F(x)\{1 - F(x)\} < \infty$, CLT cho

$$\frac{\sum_{i=1}^n [I_i(x) - F(x)]}{\sqrt{n}} = \sqrt{n}[\widehat{F}_n(x) - F(x)] \Rightarrow N(0, F(x)\{1 - F(x)\}).$$

Nếu $F(x) \in \{0, 1\}$, mọi chỉ báo bằng cùng một hằng gần chắc chắn; sai số bằng 0, nên giới hạn là phân phối suy biến tại 0.

Công thức cần nhớ. Luật số lớn áp dụng cho các $I_i(x)$ Bernoulli i.i.d., cho $\widehat{F}_n(x) \to F(x)$ gần chắc chắn. CLT cho

$$\sqrt{n}\{\widehat{F}_n(x) - F(x)\} \Rightarrow N(0, F(x)[1 - F(x)]).$$

Khi $F(x) = 0$ hoặc 1, giới hạn suy biến; không được chia cho độ lệch chuẩn bằng 0.

Câu 6. Phát biểu DKW và suy ra băng tin cậy đồng thời

Slide: C1, trang 18–19, 27.

Lời giải.

Đặt $Z_n = \sup_x |\widehat{F}_n(x) - F(x)|$. Bất đẳng thức DKW phát biểu

$$\mathbb{P}(Z_n > \varepsilon) \leq 2e^{-2n\varepsilon^2}.$$

Giải $2e^{-2n\varepsilon^2} = \alpha$:

$$-2n\varepsilon^2 = \log(\alpha/2) \quad \Longrightarrow \quad \varepsilon_{n,\alpha} = \sqrt{\frac{\log(2/\alpha)}{2n}}.$$

Với xác suất ít nhất $1 - \alpha$, $|\widehat{F}_n(x) - F(x)| \leq \varepsilon_{n,\alpha}$ cho mọi x. Chuyển vế rồi cắt tại giới hạn hợp lệ của CDF:

$$\boxed{\max(0, \widehat{F}_n(x) - \varepsilon_{n,\alpha}) \leq F(x) \leq \min(1, \widehat{F}_n(x) + \varepsilon_{n,\alpha}) \quad \forall x.}$$

Đây là băng đồng thời. DKW được dùng như định lý đầu vào.

Công thức cần nhớ. DKW cho $\mathbb{P}(\sup_x |\widehat{F}_n(x) - F(x)| > \varepsilon) \le 2e^{-2n\varepsilon^2}$. Đặt vế phải bằng α, được $\varepsilon_{n,\alpha} = \sqrt{\log(2/\alpha)/(2n)}$. Trên biến cố bù, mọi x đồng thời thỏa

$$L(x) = \max\{0, \widehat{F}_n(x) - \varepsilon_{n,\alpha}\} \le F(x) \le U(x) = \min\{1, \widehat{F}_n(x) + \varepsilon_{n,\alpha}\}.$$

Do đó xác suất phủ *ít nhất* $1 - \alpha$.

Lưu ý. Chứng minh toàn bộ DKW không nằm trong slide; khi thi nên phân biệt *phát biểu định lý* và *suy ra băng*.

Câu 7. Từ DKW chứng minh Glivenko–Cantelli như thế nào?

Slide: C1, trang 16–18.

Lời giải.

Đặt $Z_n = \sup_x |\widehat{F}_n(x) - F(x)|$. Với mỗi số nguyên $k \ge 1$,

$$\sum_{n=1}^{\infty} \mathbb{P}(Z_n > 1/k) \le 2 \sum_{n=1}^{\infty} e^{-2n/k^2} < \infty.$$

Theo Borel–Cantelli, biến cố $Z_n > 1/k$ chỉ xảy ra hữu hạn lần, gần chắc chắn. Gọi A_k là biến cố xác suất 1 đó và đặt $A = \bigcap_{k=1}^{\infty} A_k$; $\mathbb{P}(A) = 1$. Trên A, cho $\eta > 0$, chọn k sao cho $1/k < \eta$. Với n đủ lớn, $Z_n \le 1/k < \eta$. Do đó

$$\boxed{\sup_x |\widehat{F}_n(x) - F(x)| \xrightarrow{\text{a.s.}} 0.}$$

Công thức cần nhớ. Với $Z_n = \sup_x |\widehat{F}_n(x) - F(x)|$ và mỗi $k \ge 1$, $\sum_n \mathbb{P}(Z_n > 1/k) \le 2\sum_n e^{-2n/k^2} < \infty$. Borel–Cantelli cho $Z_n > 1/k$ chỉ xảy ra hữu hạn lần, gần chắc chắn. Lấy giao theo $k \in \mathbb{N}$ suy ra $Z_n \to 0$ gần chắc chắn. Đây là một cách chứng minh hệ quả bằng DKW.

Câu 8. Suy ra khoảng Hoeffding tại một điểm; phân biệt với DKW

Slide: C1, trang 20, 24–27.

Lời giải.

Đặt $Y_i = \mathbf{1}_{\{X_i \le x_0\}}$, $p = F(x_0)$ và $\widehat{p} = n^{-1}\sum_i Y_i = \widehat{F}_n(x_0)$. Hoeffding áp dụng vì $0 \le Y_i \le 1$:

$$\mathbb{P}(|\widehat{p} - p| > \varepsilon) \le 2e^{-2n\varepsilon^2}.$$

Cho vế phải bằng α và giải như câu 6: $\varepsilon = \sqrt{\log(2/\alpha)/(2n)}$. Suy ra khoảng tại điểm

$$\boxed{[\max(0, \widehat{p} - \varepsilon), \min(1, \widehat{p} + \varepsilon)]\,.}$$

Với $n = 100, \alpha = 0.05, \widehat{p} = 0.4$, $\varepsilon = \sqrt{\log 40/200} \approx 0.13581$, nên khoảng là $[0.26419, 0.53581]$.

Công thức cần nhớ. Với $p = F(x_0)$ và $\widehat{p} = \widehat{F}_n(x_0)$, Hoeffding cho $\mathbb{P}(|\widehat{p} - p| > \varepsilon) \le 2e^{-2n\varepsilon^2}$. Chọn $\varepsilon = \varepsilon_{n,\alpha}$ như trên, được khoảng $[\max(0, \widehat{p} - \varepsilon), \min(1, \widehat{p} + \varepsilon)]$ phủ ít nhất $1 - \alpha$ tại x_0.

Lưu ý. Hai công thức có cùng nửa độ rộng, nhưng Hoeffding chỉ nói về một x_0 cố định, còn DKW nói về mọi x cùng lúc. Với $n = 100, \widehat{p} = 0.4, \alpha = 0.05$, $\varepsilon \approx 0.1358$ và khoảng là $[0.2642, 0.5358]$.

Câu 9. Dựng khoảng Wald và nêu điều kiện của xấp xỉ

Slide: C1, trang 20–23.

Lời giải.

Vì $n\widehat{p} \sim \text{Bin}(n, p)$, CLT cho

$$\frac{\widehat{p} - p}{\sqrt{p(1-p)/n}} \Rightarrow N(0,1) \quad (0 < p < 1).$$

Thay p chưa biết ở mẫu số bằng $\widehat{p}$ theo Slutsky:

$$\mathbb{P}\left(-z_{1-\alpha/2} \le \frac{\widehat{p}-p}{\sqrt{\widehat{p}(1-\widehat{p})/n}} \le z_{1-\alpha/2}\right) \approx 1-\alpha.$$

Nhân với độ lệch chuẩn dương và giải hai bất đẳng thức theo p:

$$\boxed{p \in \left[\widehat{p} - z_{1-\alpha/2}\sqrt{\frac{\widehat{p}(1-\widehat{p})}{n}},\ \widehat{p} + z_{1-\alpha/2}\sqrt{\frac{\widehat{p}(1-\widehat{p})}{n}}\right].}$$

Đây là xấp xỉ Wald, không phải bảo đảm hữu hạn mẫu.

Công thức cần nhớ. Từ CLT và Slutsky, khi $0 < p < 1$, $\sqrt{n}(\widehat{p}-p)/\sqrt{\widehat{p}(1-\widehat{p})} \Rightarrow N(0,1)$. Đảo bất đẳng thức chuẩn xấp xỉ cho

$$\widehat{p} \pm z_{1-\alpha/2}\sqrt{\widehat{p}(1-\widehat{p})/n}.$$

Có thể cắt về $[0,1]$. Đây là khoảng *tiệm cận*; mẫu nhỏ hoặc $\widehat{p}$ gần 0, 1 thì chất lượng phủ kém.

Câu 10. Cỡ mẫu để nửa độ rộng DKW không quá δ

Slide: C1, trang 18–19, 25.

Lời giải.

Yêu cầu $\varepsilon_{n,\alpha} \le \delta$ tương đương

$$\begin{aligned}\sqrt{\frac{\log(2/\alpha)}{2n}} &\le \delta,\\ \frac{\log(2/\alpha)}{2n} &\le \delta^2,\\ n &\ge \frac{\log(2/\alpha)}{2\delta^2}.\end{aligned}$$

Vì n là số nguyên, lấy trần. Với $\alpha = 0.05, \delta = 0.05$:

$$n \ge \left\lceil \frac{\log 40}{2(0.05)^2} \right\rceil = \lceil 737.7759\ldots \rceil = \boxed{738}.$$

Công thức cần nhớ. Giải $\sqrt{\log(2/\alpha)/(2n)} \le \delta$ cho n:

$$n \ge \left\lceil \frac{\log(2/\alpha)}{2\delta^2} \right\rceil.$$

Ví dụ $\alpha = 0.05, \delta = 0.05$ cho $n \ge 738$.

Câu 11. Nguyên lý thế và công thức tích phân theo phân phối thực nghiệm

Slide: C1, trang 28–35.

Lời giải.

Phân phối thực nghiệm đặt khối lượng $1/n$ ở mỗi X_i: $P_n = n^{-1}\sum_i \delta_{X_i}$. Vì thế

$$\int g(x)\, d\widehat{F}_n(x) = \sum_{i=1}^{n} g(X_i)\frac{1}{n} = \frac{1}{n}\sum_{i=1}^{n} g(X_i).$$

Nếu $g(x) = x$ thì $T(\widehat{F}_n) = \bar{X}$; nếu $g(x) = x^2$ thì $T(\widehat{F}_n) = n^{-1}\sum_i X_i^2$. Do đó phiếm hàm phương sai cho

$$\widehat{\mathrm{Var}}(X) = \frac{1}{n}\sum_i X_i^2 - \bar{X}^2 = \frac{1}{n}\sum_i (X_i - \bar{X})^2.$$

Đây là ước lượng plug-in, có mẫu số n theo đúng định nghĩa.

Công thức cần nhớ. Phân phối thực nghiệm là $P_n = n^{-1}\sum_i \delta_{X_i}$, nên với g khả tích theo P_n,

$$\int g\, d\widehat{F}_n = \frac{1}{n}\sum_{i=1}^{n} g(X_i).$$

Thế F bởi $\widehat{F}_n$ trong $T(F)$ cho $\widehat{\theta} = T(\widehat{F}_n)$. Với trung bình, được $\bar{X}$; với phương sai, được $n^{-1}\sum_i (X_i - \bar{X})^2$. Nếu T liên tục *theo chuẩn sup tại* F, Glivenko–Cantelli và định lý ánh xạ liên tục cho nhất quán. Điều kiện liên tục này quan trọng: không phải mọi phiếm hàm đều liên tục theo chuẩn sup.

2 Histogram và ước lượng chiếu

Câu 12. Định nghĩa histogram và chứng minh nó là mật độ

Slide: C2, trang 12.

Lời giải.

Với ô B_j rộng h, ước lượng xác suất của ô là $\widehat{p}_j = Y_j/n$. Chọn chiều cao cột $\widehat{f}(x) = \widehat{p}_j/h = Y_j/(nh)$ cho $x \in B_j$. Rõ ràng $\widehat{f}(x) \geq 0$. Diện tích dưới toàn bộ histogram:

$$\int \widehat{f}(x)\, dx = \sum_j \int_{B_j} \frac{Y_j}{nh}\, dx = \sum_j \frac{Y_j}{nh} h = \frac{\sum_j Y_j}{n} = 1.$$

Vậy nó là một mật độ nếu các ô phủ mọi quan sát và không đếm trùng biên.

Công thức cần nhớ. Chia miền thành các ô B_j rộng h, đặt $Y_j = \#\{i : X_i \in B_j\}$ và $\widehat{f}(x) = Y_j/(nh)$ khi $x \in B_j$. Chọn quy tắc nửa mở để mỗi quan sát thuộc đúng một ô. Không âm là hiển nhiên; $\int \widehat{f} = \sum_j hY_j/(nh) = \sum_j Y_j/n = 1$ nếu các ô phủ toàn bộ mẫu.

Câu 13. Kỳ vọng, phương sai và bias histogram tại một điểm

Slide: C2, trang 13–14.

Lời giải.

Đặt $p_j = \mathbb{P}(X \in B_j) = \int_{B_j} f(u)\, du$. $Y_j = \sum_i \mathbf{1}_{\{X_i \in B_j\}} \sim \mathrm{Bin}(n, p_j)$. Với $x \in B_j$,

$$\mathbb{E}\widehat{f}(x) = \frac{np_j}{nh} = \frac{p_j}{h}, \qquad \mathrm{Var}\,\widehat{f}(x) = \frac{np_j(1-p_j)}{n^2h^2} = \frac{p_j(1-p_j)}{nh^2}.$$

Nếu c_j là trung điểm ô và f' Lipschitz, Taylor quanh x: $f(u) = f(x) + f'(x)(u-x) + O(h^2)$. Lấy trung bình trên ô,

$$\frac{1}{h}\int_{B_j} f(u)\, du - f(x) = f'(x)\left(\frac{1}{h}\int_{B_j} u\, du - x\right) + O(h^2) = f'(x)(c_j - x) + O(h^2).$$

Công thức cần nhớ. Đặt $p_j = \int_{B_j} f(u)\, du$. Vì $Y_j \sim \mathrm{Bin}(n, p_j)$, với $x \in B_j$,

$$\mathbb{E}\widehat{f}(x) = p_j/h, \qquad \mathrm{Var}\,\widehat{f}(x) = p_j(1-p_j)/(nh^2).$$

Nếu c_j là trung điểm và f đủ trơn, khai triển $f(u)$ quanh x cho $p_j/h - f(x) = f'(x)(c_j - x) + O(h^2)$. Chỉ giả thiết $f \in C^1$ thường cho phần dư $o(h)$; để khẳng định $O(h^2)$ cần thêm điều kiện trơn như f' Lipschitz.

Câu 14. Từ đâu có hằng số $1/12$ trong MISE histogram?

Slide: C2, trang 13–15.

Lời giải.

Theo câu 13, bias chính trên ô B_j là $f'(x)(c_j - x)$. Với f' gần như không đổi trong ô,

$$\int_{B_j} (c_j - x)^2 dx = \int_{-h/2}^{h/2} t^2 dt = \left[\frac{t^3}{3}\right]_{-h/2}^{h/2} = \frac{h^3}{12}.$$

Cộng các ô: bias bình phương tích phân $\sim h^2 \int (f')^2/12$. Phương sai tích phân:

$$\sum_j h \frac{p_j(1-p_j)}{nh^2} = \frac{1 - \sum_j p_j^2}{nh} \sim \frac{1}{nh}.$$

Đặt $A = \int (f')^2/12$. Từ $M(h) = Ah^2 + 1/(nh)$, $M'(h) = 2Ah - 1/(nh^2) = 0$, nên

$$h_*^3 = \frac{1}{2An} = \frac{6}{n\int (f')^2}, \qquad h_* \asymp n^{-1/3}, \quad M(h_*) \asymp n^{-2/3}.$$

Công thức cần nhớ. Trên mỗi ô, bias chính là $f'(x)(c_j - x)$. Tích phân $(c_j - x)^2$ trên ô rộng h bằng $h^3/12$. Cộng các ô và dùng tổng Riemann cho bias bình phương tích phân xấp xỉ $(h^2/12)\int (f')^2$. Phương sai tích phân là

$$\sum_j h \frac{p_j(1-p_j)}{nh^2} = \frac{1 - \sum_j p_j^2}{nh} \sim \frac{1}{nh}.$$

Do đó MISE $\approx Ah^2 + 1/(nh)$, $A = \int (f')^2/12$. Đạo hàm theo h cho $h_* = [6/(n\int (f')^2)]^{1/3}$ và tốc độ $n^{-2/3}$.

Câu 15. Suy ra công thức CV chọn độ rộng ô của histogram

Slide: C2, trang 17.

Lời giải.

Vì histogram có chiều cao $Y_j/(nh)$ trên ô j,

$$\int \widehat{f}_h^2 = \sum_j h \left(\frac{Y_j}{nh}\right)^2 = \frac{\sum_j Y_j^2}{n^2 h}.$$

Với $X_i \in B_j$, histogram bỏ quan sát i có giá trị $(Y_j - 1)/[(n-1)h]$ tại X_i. Có Y_j giá trị như vậy trong ô, nên

$$\frac{2}{n} \sum_i \widehat{f}_{h,-i}(X_i) = \frac{2}{n(n-1)h} \sum_j Y_j(Y_j - 1).$$

Lấy hiệu và dùng $\sum_j Y_j = n$:

$$\begin{aligned} \mathrm{CV}(h) &= \frac{\sum_j Y_j^2}{n^2 h} - \frac{2(\sum_j Y_j^2 - n)}{n(n-1)h} \\ &= \boxed{\frac{2}{(n-1)h} - \frac{n+1}{(n-1)h} \sum_j (Y_j/n)^2.} \end{aligned}$$

Công thức cần nhớ. Với $\widehat{p}_j = Y_j/n$, $\int \widehat{f}_h^2 = \sum_j Y_j^2/(n^2 h) = h^{-1} \sum_j \widehat{p}_j^2$. Nếu X_i thuộc ô j, histogram bỏ quan sát i tại X_i bằng $(Y_j - 1)/[(n-1)h]$. Vì vậy

$$\frac{2}{n} \sum_i \widehat{f}_{h,-i}(X_i) = \frac{2}{n(n-1)h} \sum_j Y_j(Y_j - 1).$$

Trừ hai hạng, dùng $\sum_j Y_j = n$ và rút gọn:

$$\mathrm{CV}_{\mathrm{hist}}(h) = \frac{2}{(n-1)h} - \frac{n+1}{(n-1)h}\sum_j \widehat{p}_j^{\,2}.$$

Chọn h (hay số ô $m = 1/h$) làm CV nhỏ nhất trong tập ứng viên. Phải dùng cùng gốc chia ô khi so sánh, vì histogram phụ thuộc vị trí biên ô.

Câu 16. Tại sao ước lượng phép chiếu có hệ số $\widehat{a}_j = n^{-1}\sum_i \phi_j(X_i)$?

Slide: C2, trang 30–32; C2P 4, 10–12.

Lời giải.

Trong L^2, hệ số chiếu thật của f lên ϕ_j là

$$a_j = \langle f, \phi_j\rangle = \int f(x)\phi_j(x)dx = \mathbb{E}[\phi_j(X)].$$

Ước lượng kỳ vọng bằng trung bình mẫu: $\widehat{a}_j = n^{-1}\sum_i \phi_j(X_i)$ và $\widehat{f}_D = \sum_{j=1}^D \widehat{a}_j\phi_j$. Một phép dẫn khác: với $t = \sum_j b_j\phi_j$, tính trực chuẩn cho

$$\gamma_n(t) = \|t\|_2^2 - 2P_n t = \sum_j b_j^2 - 2\sum_j b_j\widehat{a}_j.$$

Đạo hàm theo b_j: $2b_j - 2\widehat{a}_j = 0$, nên $b_j = \widehat{a}_j$ là điểm cực tiểu.

Công thức cần nhớ. Với hệ trực chuẩn $\phi_1, \ldots, \phi_D$ trong L^2, hệ số thật $a_j = \langle f, \phi_j\rangle = \int \phi_j(x)f(x)\,dx = \mathbb{E}\phi_j(X)$. Ước lượng bằng trung bình mẫu. Vì thế $\mathbb{E}\widehat{a}_j = a_j$ và $\widehat{f}_D = \sum_{j=1}^D \widehat{a}_j\phi_j$. Cũng có thể tối thiểu hóa contrast $\gamma_n(t) = \|t\|_2^2 - 2n^{-1}\sum_i t(X_i)$: với $t = \sum_j b_j\phi_j$, $\gamma_n(t) = \sum_j b_j^2 - 2\sum_j b_j\widehat{a}_j$, nên cực tiểu ở $b_j = \widehat{a}_j$.

Câu 17. Chứng minh phân rã bias–variance và cận rủi ro của phép chiếu

Slide: C2, trang 32; C2P 13–15.

Lời giải.

Viết $\widehat{f}_D - f = (\widehat{f}_D - f_D) + (f_D - f)$. Vì f_D là hình chiếu trực giao, $\langle \widehat{f}_D - f_D, f_D - f\rangle = 0$. Pythagoras cho

$$\|\widehat{f}_D - f\|_2^2 = \|f_D - f\|_2^2 + \|\widehat{f}_D - f_D\|_2^2.$$

Tính trực chuẩn và lấy kỳ vọng:

$$\mathbb{E}\|\widehat{f}_D - f_D\|_2^2 = \sum_{j=1}^D \mathbb{E}(\widehat{a}_j - a_j)^2 = \frac{1}{n}\sum_{j=1}^D \mathrm{Var}(\phi_j(X_1)).$$

Nếu $\sup_x \sum_{j=1}^D \phi_j(x)^2 \le \Phi D$ thì

$$\frac{1}{n}\sum_j \mathrm{Var}(\phi_j(X_1)) \le \frac{1}{n}\mathbb{E}\sum_j \phi_j(X_1)^2 \le \frac{\Phi D}{n}.$$

Suy ra cận rủi ro $\mathbb{E}\|\widehat{f}_D - f\|_2^2 \le \|f_D - f\|_2^2 + \Phi D/n$.

Công thức cần nhớ. Đặt $f_D = \sum_j a_j\phi_j$. Vì $f - f_D \perp S_D$ và $\widehat{f}_D - f_D \in S_D$, Pythagoras cho

$$\mathbb{E}\|\widehat{f}_D - f\|_2^2 = \|f_D - f\|_2^2 + \sum_{j=1}^D \mathrm{Var}(\widehat{a}_j).$$

Độc lập theo i cho $\mathrm{Var}(\widehat{a}_j) = \mathrm{Var}(\phi_j(X_1))/n \le \mathbb{E}\phi_j(X_1)^2/n$. Nếu $\sup_x \sum_{j=1}^{D} \phi_j(x)^2 \le \Phi D$, tổng phương sai không quá $\Phi D/n$.

Lưu ý. Điều kiện đúng là cận của *tổng* $\sum_j \phi_j(x)^2$. Riêng cơ sở histogram có $\sup_x \phi_j(x)^2 = D$ cho từng j nhưng $\sum_j \phi_j(x)^2 = D$, nên dùng $\sup_{x,j} \phi_j(x)^2 \cdot D/n$ sẽ cho cận quá thô.

Câu 18. Tại sao histogram là một ước lượng phép chiếu?

Slide: C2, trang 31–32; C2P 6, 11.

Lời giải.

Chia $[0,1]$ thành D ô B_j rộng $h = 1/D$. Đặt $\phi_j(x) = \sqrt{D}\,\mathbf{1}_{B_j}(x)$. Nếu $j = k$, $\int \phi_j^2 = D|B_j| = 1$; nếu $j \ne k$, $\int \phi_j \phi_k = 0$ vì hai ô rời nhau. Với $Y_j = \#\{i : X_i \in B_j\}$,

$$\widehat{a}_j = \frac{1}{n}\sum_i \phi_j(X_i) = \frac{\sqrt{D}\,Y_j}{n}.$$

Vậy với $x \in B_j$,

$$\widehat{f}_D(x) = \widehat{a}_j \phi_j(x) = \frac{DY_j}{n} = \frac{Y_j}{nh}.$$

Đúng bằng chiều cao histogram.

Công thức cần nhớ. Trên $[0,1]$, chia D ô B_j rộng $1/D$, đặt $\phi_j = \sqrt{D}\,\mathbf{1}_{B_j}$. Các hàm này trực chuẩn. Khi đó $\widehat{a}_j = \sqrt{D}\,Y_j/n$ và $\widehat{f}_D(x) = \sum_j (DY_j/n)\mathbf{1}_{B_j}(x) = Y_j/(nh)$ với $h = 1/D$.

Câu 19. Có thể chứng minh bất đẳng thức oracle trực tiếp từ phân rã Pythagoras không?

Slide: C2, trang 33–34; C2P 22–24.

Lời giải.

Với D cố định, câu 17 cho cận rủi ro. Nhưng $\widehat{D}$ phụ thuộc dữ liệu; muốn so sánh với mọi D, trước tiên dùng định nghĩa điểm cực tiểu:

$$\gamma_n(\widehat{f}_{\widehat{D}}) + \mathrm{pen}(\widehat{D}) \le \gamma_n(f_D) + \mathrm{pen}(D).$$

Viết $P_n t = Pt + (P_n - P)t$ và $\gamma_n(t) = \|t - f\|_2^2 - \|f\|_2^2 - 2(P_n - P)t$. Thế vào bất đẳng thức trên cho

$$\|\widehat{f}_{\widehat{D}} - f\|_2^2 \le \|f_D - f\|_2^2 + 2(P_n - P)(\widehat{f}_{\widehat{D}} - f_D) + \mathrm{pen}(D) - \mathrm{pen}(\widehat{D}).$$

Hạng quá trình thực nghiệm còn lại phải được chặn đồng thời trên các không gian; slide chỉ phác thảo bước tập trung này.

Lưu ý. Không. Pythagoras chỉ cho rủi ro ở D cố định. Với $\widehat{D}$ chọn từ dữ liệu, cần bước so sánh contrast có phạt:

$$\gamma_n(\widehat{f}_{\widehat{D}}) + \mathrm{pen}(\widehat{D}) \le \gamma_n(f_D) + \mathrm{pen}(D) \quad \text{với mọi } D,$$

sau đó khống chế quá trình thực nghiệm $\nu_n(t) = (P_n - P)t$ đồng thời trên các mô hình. Slide chỉ đưa *phác thảo*; khống chế tập trung là phần không được chứng minh ở đây. Hãy nhớ phát biểu, giả thiết và logic của các bước, không nhận một phác thảo là chứng minh đầy đủ.

Câu 20. Chứng minh cơ sở lượng giác là trực chuẩn và tính tổng bình phương cơ sở

Slide: C2P, trang 4–5.

Lời giải.

Trên $[0,1]$, đặt $\phi_1(x) = 1$, $\phi_{2k}(x) = \sqrt{2}\cos(2\pi kx)$, $\phi_{2k+1}(x) = \sqrt{2}\sin(2\pi kx)$. Với $k, l \ge 1$, các đồng nhất thức lượng giác và $\int_0^1 \cos(2\pi qx)dx = \int_0^1 \sin(2\pi qx)dx = 0$ khi $q \ne 0$ cho

$$\int_0^1 \phi_j(x)\phi_l(x)dx = \delta_{jl}.$$

Chẳng hạn khi $k=l$, $\int_0^1 2\cos^2(2\pi kx)dx = \int_0^1[1+\cos(4\pi kx)]dx = 1$; khi $k\neq l$, tích hai cos là tổng hai cos tần số khác 0 nên tích phân bằng 0. Tích sin–cos cũng bằng 0. Với $D = 2d+1$,

$$\sum_{j=1}^{D}\phi_j(x)^2 = 1 + \sum_{k=1}^{d} 2[\cos^2(2\pi kx)+\sin^2(2\pi kx)] = \boxed{D}$$

cho mọi x.

Câu 21. Dựng cơ sở Legendre bậc một trên từng ô và kiểm tra trực chuẩn

Slide: C2P, trang 7–8.

Lời giải.

Chia $[0,1]$ thành d ô $B_j = [(j-1)/d, j/d)$ và đặt $u_j(x) = 2dx - 2j + 1 \in [-1,1]$ trên ô j. Hai hàm cơ sở bậc 0 và 1 của ô ấy là

$$\phi_{j,0}(x) = \sqrt{d}\,\mathbf{1}_{B_j}(x), \qquad \phi_{j,1}(x) = \sqrt{3d}\,u_j(x)\mathbf{1}_{B_j}(x).$$

Hàm ở hai ô khác nhau có tích bằng 0. Trong cùng ô, đổi biến $u = u_j(x)$, $dx = du/(2d)$:

$$\int \phi_{j,0}^2 dx = d|B_j| = 1, \qquad \int \phi_{j,1}^2 dx = \frac{3d}{2d}\int_{-1}^{1} u^2 du = \frac{3}{2}\cdot\frac{2}{3} = 1,$$

$$\int \phi_{j,0}\phi_{j,1}dx = \frac{\sqrt{3}}{2}\int_{-1}^{1} u\,du = 0.$$

Vậy $2d$ hàm này trực chuẩn. Với bậc đa thức r, thay $1, u$ bằng các đa thức Legendre chuẩn hóa đến bậc r; số chiều là $D = d(r+1)$.

Câu 22. Đổi cơ sở trực chuẩn từ $[0,1]$ sang $[a,b]$; mật độ đổi thang ra sao?

Slide: C2P, trang 9.

Lời giải.

Cho cơ sở ϕ_j trực chuẩn trên $[0,1]$. Đặt $u = (x-a)/(b-a)$ và

$$\widetilde{\phi}_j(x) = \frac{1}{\sqrt{b-a}}\phi_j(u), \qquad x\in[a,b].$$

Vì $dx = (b-a)du$,

$$\int_a^b \widetilde{\phi}_j(x)\widetilde{\phi}_k(x)dx = \frac{1}{b-a}\int_a^b \phi_j(u)\phi_k(u)dx = \int_0^1 \phi_j(u)\phi_k(u)du = \delta_{jk}.$$

Nếu $U = (X-a)/(b-a)$ có mật độ g, thì xác suất trên khoảng nhỏ phải bằng nhau: $f_X(x)dx = g(u)du$. Từ $du = dx/(b-a)$,

$$\boxed{f_X(x) = \frac{1}{b-a}g\left(\frac{x-a}{b-a}\right).}$$

Hệ số của mật độ là $1/(b-a)$, còn hệ số của *mỗi hàm cơ sở* là $1/\sqrt{b-a}$.

Câu 23. Chứng minh f_D là điểm cực tiểu duy nhất của sai số L^2 trong S_D

Slide: C2P, trang 4, 10–12.

Lời giải.

Viết một hàm tùy ý trong S_D là $t = \sum_{j=1}^{D} b_j\phi_j$. Đặt $a_j = \langle f,\phi_j\rangle$ và $f_D = \sum_{j=1}^{D} a_j\phi_j$. Ta có $\langle f - f_D, \phi_j\rangle = a_j - a_j = 0$; vì vậy $f - f_D$ vuông góc với S_D. Pythagoras cho

$$\|f-t\|_2^2 = \|f-f_D\|_2^2 + \|f_D - t\|_2^2 = \|f-f_D\|_2^2 + \sum_{j=1}^{D}(a_j-b_j)^2.$$

Tổng bình phương cuối không âm và bằng 0 chỉ khi $b_j = a_j$ với mọi j. Do đó

$$\boxed{f_D = \operatorname*{argmin}_{t \in S_D} \|f - t\|_2^2}$$

là điểm cực tiểu duy nhất trong L^2 (tới đồng nhất gần khắp nơi).

Câu 24. Chứng minh hệ số chiếu không chệch và tính phương sai hệ số

Slide: C2P, trang 10–11, 14.

Lời giải.

Hệ số thật là $a_j = \mathbb{E}\phi_j(X)$; hệ số mẫu là $\widehat{a}_j = n^{-1}\sum_i \phi_j(X_i)$. Do tuyến tính kỳ vọng,

$$\mathbb{E}\widehat{a}_j = \frac{1}{n}\sum_i \mathbb{E}\phi_j(X_i) = a_j.$$

Do X_i độc lập theo i,

$$\operatorname{Var}(\widehat{a}_j) = \frac{1}{n^2}\sum_{i=1}^{n}\operatorname{Var}(\phi_j(X_i)) = \frac{1}{n}\left[\mathbb{E}\phi_j(X)^2 - a_j^2\right].$$

Đây là phép tính được dùng trực tiếp trong cận phương sai ở slide 14. Không cần giả sử các hệ số $\widehat{a}_j$ độc lập theo j để tính $\mathbb{E}\|\widehat{f}_D - f_D\|_2^2$: tính trực chuẩn làm mất các hạng chéo trước khi lấy kỳ vọng.

Câu 25. Phân rã rủi ro chiếu chính xác và tính thành phần phương sai

Slide: C2P, trang 13–15.

Lời giải.

Từ câu 23, $f - f_D \perp S_D$ và $\widehat{f}_D - f_D \in S_D$, nên

$$\|\widehat{f}_D - f\|_2^2 = \|f_D - f\|_2^2 + \|\widehat{f}_D - f_D\|_2^2.$$

Trực chuẩn cho $\|\widehat{f}_D - f_D\|_2^2 = \sum_{j=1}^{D}(\widehat{a}_j - a_j)^2$. Vì $\mathbb{E}\widehat{a}_j = a_j$,

$$\boxed{\mathbb{E}\|\widehat{f}_D - f\|_2^2 = \|f_D - f\|_2^2 + \frac{1}{n}\sum_{j=1}^{D}\left[\mathbb{E}\phi_j(X)^2 - a_j^2\right].}$$

Đây là đẳng thức chính xác. Nếu $\sup_x \sum_{j=1}^{D}\phi_j(x)^2 \le \Phi D$, thì bỏ các $-a_j^2$ và lấy kỳ vọng cho

$$\mathbb{E}\|\widehat{f}_D - f\|_2^2 \le \|f_D - f\|_2^2 + \frac{\Phi D}{n}.$$

Câu 26. Chứng minh cận $\|t\|_\infty \le \sqrt{D}\|t\|_2$ cho cơ sở lượng giác

Slide: C2P, trang 5, 14–15.

Lời giải.

Cho $t = \sum_{j=1}^{D} b_j\phi_j \in S_D$. Tại mỗi x, bất đẳng thức Cauchy–Schwarz cho

$$|t(x)| = \left|\sum_{j=1}^{D} b_j\phi_j(x)\right| \le \left(\sum_j b_j^2\right)^{1/2}\left(\sum_j \phi_j(x)^2\right)^{1/2}.$$

Trực chuẩn cho $\sum_j b_j^2 = \|t\|_2^2$. Với cơ sở lượng giác, câu 20 đã tính $\sum_j \phi_j(x)^2 = D$ cho mọi x. Do đó

$$|t(x)| \le \sqrt{D}\,\|t\|_2 \quad \forall x, \qquad \boxed{\|t\|_\infty \le \sqrt{D}\,\|t\|_2.}$$

Đồng thời $\Phi = 1$ trong cận phương sai của câu 25.

Câu 27. Chứng minh bias của phép chiếu histogram khi f là Hölder bậc α

Slide: C2P, trang 16–17.

Lời giải.

Với ô B_j rộng $h = 1/D$, phép chiếu lên hàm bước có giá trị

$$f_D(x) = D\int_{B_j} f(u)du \quad (x \in B_j).$$

Giả sử $0 < \alpha \le 1$ và $|f(x) - f(u)| \le L|x-u|^\alpha$. Với x, u cùng ô, $|x-u| \le h$; vì vậy

$$\begin{aligned} |f(x) - f_D(x)| &= \left| D\int_{B_j} [f(x) - f(u)]du \right| \\ &\le D\int_{B_j} L|x-u|^\alpha du \\ &\le D \cdot h \cdot Lh^\alpha = LD^{-\alpha}. \end{aligned}$$

Bình phương và tích phân trên $[0,1]$:

$$\boxed{\|f - f_D\|_2^2 \le \int_0^1 L^2 D^{-2\alpha}dx = L^2 D^{-2\alpha}.}$$

Hàm bước bậc 0 không tự hưởng thêm tốc độ khi độ trơn vượt bậc một.

Câu 28. Bias lượng giác suy ra từ Parseval; điều kiện nào còn thiếu trong slide?

Slide: C2, trang 9, 32; C2P 5, 16–19.

Lời giải.

Từ phép chiếu ở slide 4 và Parseval,

$$\boxed{\|f - f_D\|_2^2 = \sum_{j>D} a_j^2.}$$

Để chặn đuôi này bởi $L^2D^{-2\alpha}$, cần thêm một điều kiện về *hệ số Fourier tuần hoàn*, chẳng hạn $\sum_{j\ge1} j^{2\alpha}a_j^2 \le L^2$. Khi đó

$$\sum_{j>D} a_j^2 = \sum_{j>D} j^{-2\alpha}(j^{2\alpha}a_j^2) \le D^{-2\alpha}L^2.$$

Điều kiện hệ số này không được phát biểu trong slide; chỉ giả sử Hölder trên $[0,1]$ chưa đủ cho kết luận lượng giác ở trang 16. Thật vậy, $f(x) = 2x$ là mật độ Lipschitz trên $[0,1]$ nhưng không khớp hai đầu mút. Hệ số cos của nó bằng 0, còn hệ số sin tần số k là

$$a_{2k+1} = \sqrt{2}\int_0^1 2x\sin(2\pi kx)dx = -\frac{\sqrt{2}}{\pi k}.$$

Với $D = 2d+1$, Parseval cho $\|f - f_D\|_2^2 = (2/\pi^2)\sum_{k>d} k^{-2}$, có bậc D^{-1} chứ không phải D^{-2} khi $\alpha = 1$. Vì vậy không thể chứng minh khẳng định chung ấy từ giả thiết Hölder ghi trên slide.

Câu 29. Tối ưu số chiều D từ cận bias–variance; phân biệt với chọn băng thông

Slide: C2P, trang 18–20.

Lời giải.

Kết hợp bias $\le AD^{-2\alpha}$ và phương sai $\le BD/n$:

$$\mathcal{R}(D) \le \psi(D) := AD^{-2\alpha} + \frac{BD}{n}.$$

Xem D là số thực dương, lấy đạo hàm $\psi'(D) = -2\alpha AD^{-2\alpha-1} + B/n$. Giải $\psi'(D) = 0$:

$$\boxed{D_* = \left(\frac{2\alpha A}{B} n\right)^{1/(2\alpha+1)}}.$$

Làm tròn về số chiều hợp lệ. Khi thế vào hai hạng, cả hai đều bậc $n^{-2\alpha/(2\alpha+1)}$. Với histogram, $h = 1/D$ nên phép chọn D tương đương chọn độ rộng ô. Với cơ sở lượng giác, D là số hệ số tần số giữ lại; nó không phải một băng thông kernel. Phép tối ưu này chỉ có hiệu lực sau khi đã chứng minh cận bias $AD^{-2\alpha}$ cho *cơ sở và lớp hàm đang xét*: histogram bậc 0 ở câu 27 cho $0 < \alpha \le 1$; cơ sở lượng giác cần điều kiện tuần hoàn thích hợp như đã nêu ở câu 28.

Câu 30. Tính contrast tại $\widehat{f}_D$ và suy ra tiêu chuẩn chọn mô hình từ dữ liệu

Slide: C2P, trang 12, 20–22.

Lời giải.

Vì $f - f_D \perp f_D$, Pythagoras trước hết cho

$$\|f - f_D\|_2^2 = \|f\|_2^2 - \|f_D\|_2^2.$$

Khi so sánh các D, hạng $\|f\|_2^2$ là hằng số; vì vậy điểm số oracle có dạng $-\|f_D\|_2^2 + \Phi D/n$ như trang 21. Contrast thực nghiệm là $\gamma_n(t) = \|t\|_2^2 - 2P_n t$, trong đó $P_n t = n^{-1}\sum_i t(X_i)$. Với $\widehat{f}_D = \sum_{j=1}^{D} \widehat{a}_j \phi_j$, trực chuẩn cho $\|\widehat{f}_D\|_2^2 = \sum_{j=1}^{D} \widehat{a}_j^2$. Mặt khác,

$$P_n \widehat{f}_D = \sum_{j=1}^{D} \widehat{a}_j P_n \phi_j = \sum_{j=1}^{D} \widehat{a}_j^2.$$

Do đó

$$\boxed{\gamma_n(\widehat{f}_D) = -\sum_{j=1}^{D} \widehat{a}_j^2.}$$

Một quy tắc chọn số chiều tính được từ dữ liệu là

$$\boxed{\widehat{D} = \operatorname*{argmin}_{D \in \mathcal{D}} \left\{ -\sum_{j=1}^{D} \widehat{a}_j^2 + \kappa \frac{\Phi D}{n} \right\}.}$$

Hạng phạt chống việc cứ tăng D để contrast giảm.

Câu 31. So sánh tiêu chuẩn phạt giữa $D = 3$ và $D = 5$ trong ví dụ trên slide

Viết hiệu hai tiêu chuẩn bằng đúng bốn hệ số lượng giác được thêm vào; nêu điều kiện để chọn $D = 5$ khi không có dữ liệu thô trên slide.

Slide: C2P, trang 5, 22, 25–26.

Lời giải.

Trong ví dụ trang 25, slide so sánh $D = 3$ và $D = 5$ nhưng không cho các giá trị X_i, nên không thể tính các hệ số ra số cụ thể. Với cơ sở lượng giác, đặt $C_D = \gamma_n(\widehat{f}_D) + \kappa D/n$. Do $\gamma_n(\widehat{f}_D) = -\sum_{j \le D} \widehat{a}_j^2$,

$$C_5 - C_3 = -\widehat{a}_4^2 - \widehat{a}_5^2 + \frac{2\kappa}{n},$$
$$\widehat{a}_4 = \frac{\sqrt{2}}{n} \sum_{i=1}^{n} \cos(4\pi U_i),$$
$$\widehat{a}_5 = \frac{\sqrt{2}}{n} \sum_{i=1}^{n} \sin(4\pi U_i).$$

Do đó $D = 5$ thắng $D = 3$ khi $\widehat{a}_4^2 + \widehat{a}_5^2 > 2\kappa/n$; hai mô hình hòa khi bằng nhau. Với $n = 1000$ trên slide, ngưỡng là $2\kappa/1000$. Không thể kết luận lựa chọn thực tế nếu không có mẫu hoặc các hệ số. Trang 26 viết hạng phạt $\kappa(2d+1)/n$ với $d = \lfloor \sqrt{n} \rfloor$ cố định; hạng ấy không đổi theo D, nên không thể tự cân bằng độ phức tạp của các mô hình. Khi làm bài chọn mô hình, dùng phạt $\kappa D/n$ như định nghĩa ở trang 22.

Câu 32. Phác thảo chứng minh bất đẳng thức oracle: bước nào thật sự khó?

Slide: C2P, trang 23–24.

Lời giải.

Theo định nghĩa của $\widehat{D}$, với mọi D cố định,

$$\gamma_n(\widehat{f}_{\widehat{D}}) + \mathrm{pen}(\widehat{D}) \le \gamma_n(f_D) + \mathrm{pen}(D).$$

Đặt $\nu_n(t) = (P_n - P)t$. Vì $Pt = \langle t, f \rangle$,

$$\gamma_n(t) = \|t - f\|_2^2 - \|f\|_2^2 - 2\nu_n(t).$$

Thế vào bất đẳng thức chọn mô hình và khử $-\|f\|_2^2$:

$$\|\widehat{f}_{\widehat{D}} - f\|_2^2 \le \|f_D - f\|_2^2 + 2\nu_n(\widehat{f}_{\widehat{D}} - f_D) + \mathrm{pen}(D) - \mathrm{pen}(\widehat{D}).$$

Đây là bước đại số. Để lấy kỳ vọng và tối thiểu hóa theo D, cần chặn đồng thời $\nu_n(t)$ trên các không gian $S_D + S_{D'}$, thường bằng bất đẳng thức tập trung. Đó là bước sâu slide chỉ phác thảo; không thể suy ra oracle chỉ từ Pythagoras.

Câu 33. Ước lượng chiếu có luôn không âm và tích phân bằng một không?

Slide: C2P, trang 10–11, 26–28.

Lời giải.

Nếu cơ sở chứa $\phi_1 \equiv 1$ và mọi ϕ_j với $j \ge 2$ có tích phân 0, thì $\widehat{a}_1 = n^{-1} \sum_i 1 = 1$ và

$$\int_0^1 \widehat{f}_D(x)dx = \widehat{a}_1 \int_0^1 \phi_1 + \sum_{j=2}^{D} \widehat{a}_j \int_0^1 \phi_j = 1.$$

Nhưng điều này không bảo đảm không âm. Ví dụ $X_1 = \cdots = X_n = 0$, $D = 3$: $\widehat{a}_2 = \sqrt{2}$, $\widehat{a}_3 = 0$, nên

$$\widehat{f}_3(x) = 1 + 2\cos(2\pi x), \qquad \widehat{f}_3(1/2) = 1 - 2 = \boxed{-1}.$$

Vậy ước lượng chiếu tổng quát có thể âm. Với cơ sở histogram, từng hệ số tái tạo số đếm nên ước lượng vẫn không âm.

Câu 34. Viết tường minh các ước lượng $D = 3, 5$ và histogram $D = 10$ trên slide

Từ định nghĩa cơ sở, viết dạng hàm của ba ước lượng trong ví dụ $X_i \sim N(4, 25)$ sau khi chuẩn hóa dữ liệu về $[0, 1]$.

Slide: C2P, trang 5–6, 9–11, 25–26.

Lời giải.

Trang 25 dùng $X_i \sim N(4, 25)$, $n = 1000$, và chuẩn hóa $U_i = (X_i - a)/(b - a)$ như trang 26. Trên $[0, 1]$,

$$\widehat{f}_3(u) = 1 + \sqrt{2}\widehat{a}_2 \cos(2\pi u) + \sqrt{2}\widehat{a}_3 \sin(2\pi u),$$
$$\widehat{f}_5(u) = \widehat{f}_3(u) + \sqrt{2}\widehat{a}_4 \cos(4\pi u) + \sqrt{2}\widehat{a}_5 \sin(4\pi u),$$

trong đó $\widehat{a}_{2k} = \sqrt{2}\, n^{-1} \sum_i \cos(2\pi k U_i)$ và $\widehat{a}_{2k+1} = \sqrt{2}\, n^{-1} \sum_i \sin(2\pi k U_i)$. Trở về thang $x \in [a, b]$ bằng công thức mật độ

$$\boxed{\widehat{f}_{D,X}(x) = \frac{1}{b-a} \widehat{f}_D\left(\frac{x-a}{b-a}\right).}$$

Với histogram $D = 10$, đặt $B_j = [(j-1)/10, j/10)$ (ô cuối chứa điểm 1) và $Y_j = \#\{i : U_i \in B_j\}$. Khi $u \in B_j$, $\widehat{f}_{10,\text{hist}}(u) = 10Y_j/n$; trên ô tương ứng của $[a, b]$, chiều cao là $10Y_j/[n(b-a)]$. Slide không cung cấp mẫu X_i nên đây là dạng cụ thể nhất có thể tính đúng từ dữ liệu trên slide. Hệ số đổi thang của *mật độ* là $1/(b-a)$; trang 26 ghi $1/\sqrt{b-a}$, vốn là hệ số đổi thang của từng *hàm cơ sở*, không phải của mật độ.

Câu 35. Vì sao có thể cập nhật ước lượng chiều và contrast khi tăng D?

Slide: C2P, trang 20–22, 26.

Lời giải.

Với không gian lồng nhau $S_D = \text{span}(\phi_1, \ldots, \phi_D)$, tăng từ D lên $D+1$ chỉ thêm một hệ số:

$$\widehat{f}_{D+1} = \widehat{f}_D + \widehat{a}_{D+1}\phi_{D+1}.$$

Vì $\gamma_n(\widehat{f}_D) = -\sum_{j=1}^{D} \widehat{a}_j^2$,

$$\gamma_n(\widehat{f}_{D+1}) = \gamma_n(\widehat{f}_D) - \widehat{a}_{D+1}^2.$$

Với phạt $\kappa\Phi D/n$, điểm số đổi một lượng $-\widehat{a}_{D+1}^2 + \kappa\Phi/n$; thêm hệ số có lợi nếu $\widehat{a}_{D+1}^2 > \kappa\Phi/n$. Nếu chỉ xét $D = 2d+1$ của cơ sở lượng giác, mỗi lần tăng D lên 2 thêm cặp sin–cos, và tiêu chuẩn tương ứng là $\widehat{a}_{D+1}^2 + \widehat{a}_{D+2}^2 > 2\kappa\Phi/n$.

3 Ước lượng Nadaraya–Watson

Câu 36. Từ tỷ số mật độ suy ra công thức NW như thế nào?

Slide: C3, trang 12–16.

Lời giải.

Với $f_X(x) > 0$,

$$r(x) = \mathbb{E}[Y \mid X = x] = \frac{\int y f_{XY}(x, y)\, dy}{f_X(x)}.$$

Thay mật độ chung bằng $\widehat{f}_{XY}(x, y) = n^{-1} \sum_i K_h(X_i - x) K_h(Y_i - y)$. Ở tử số:

$$\int y \widehat{f}_{XY}(x, y) dy = \frac{1}{n} \sum_i K_h(X_i - x) \int y K_h(Y_i - y) dy.$$

Đặt $u = (Y_i - y)/h$, $y = Y_i - hu$:

$$\int yK_h(Y_i - y)dy = \int (Y_i - hu)K(u)du = Y_i.$$

Mẫu số là $\widehat{f}_X(x) = n^{-1}\sum_i K_h(X_i - x)$. Chia tử cho mẫu, triệt tiêu $1/n$:

$$\boxed{\widehat{r}_{NW}(x) = \frac{\sum_i Y_i K_h(X_i - x)}{\sum_i K_h(X_i - x)}.}$$

Công thức cần nhớ. Với $r(x) = \mathbb{E}[Y \mid X = x] = \int y f_{XY}(x, y)\, dy / f_X(x)$, dùng KDE chung $\widehat{f}_{XY}(x, y) = n^{-1}\sum_i K_h(X_i - x)K_h(Y_i - y)$ và KDE biên $\widehat{f}_X(x) = n^{-1}\sum_i K_h(X_i - x)$. Nếu $\int K = 1$ và $\int uK(u)\, du = 0$,

$$\int yK_h(Y_i - y)\, dy = Y_i.$$

Thay vào tỷ số cho $\widehat{r}_{NW}(x) = \sum_i Y_i K_h(X_i - x) / \sum_i K_h(X_i - x)$ khi mẫu số khác 0. Đây là phép tính trung tâm của slide 14.

Câu 37. Từ bình phương tối thiểu có trọng số suy ra NW; chứng minh tái tạo hằng số

Slide: C3, trang 16, 29, 48.

Lời giải.

Với $w_i = K_h(X_i - x) \geq 0$, đặt $Q(\theta) = \sum_i w_i(Y_i - \theta)^2$. Khai triển và đạo hàm:

$$Q'(\theta) = \sum_i 2w_i(\theta - Y_i) = 2\theta\sum_i w_i - 2\sum_i w_i Y_i.$$

Nếu $\sum_i w_i > 0$, giải $Q'(\theta) = 0$ cho $\theta = \sum_i w_i Y_i / \sum_i w_i$. Vì $Q''(\theta) = 2\sum_i w_i > 0$, đây là cực tiểu duy nhất. Đặt $W_i = w_i / \sum_j w_j$ thì $\sum_i W_i = 1$. Nếu $Y_i = c$ với mọi i, $\widehat{r}_{NW} = \sum_i W_i c = c$.

Công thức cần nhớ. Đặt $w_i = K_h(X_i - x) \geq 0$ và $Q(\theta) = \sum_i w_i(Y_i - \theta)^2$. Nếu $\sum_i w_i > 0$, $Q'(\theta) = -2\sum_i w_i Y_i + 2\theta\sum_i w_i = 0$ có nghiệm duy nhất $\widehat{r}_{NW}(x)$. Với $W_i = w_i / \sum_j w_j$, $\sum_i W_i = 1$. Nếu mọi $Y_i = c$, $\widehat{r}_{NW}(x) = c$. Nếu mẫu số 0, công thức tỷ số không xác định và phải quy định xử lý riêng.

Câu 38. Bài tập 3: kỳ vọng, phương sai và băng thông ở thiết kế cố định

Cho $X_i = i/n$, $Y_i = r(X_i) + \xi_i$ với ξ_i độc lập, trung bình 0, phương sai σ^2. Xét $\widehat{r}_h(x) = n^{-1}\sum_i Y_i K_h(X_i - x)$ ở điểm nội. Tính kỳ vọng, phương sai, bias dẫn đầu và băng thông tối ưu; nêu điều kiện cần cho phép xấp xỉ tổng bằng tích phân.

Slide: C3, trang 20, 49.

Lời giải.

Đây là *ước lượng tuyến tính không chuẩn hóa* của bài tập 3 trang 49, khác tỷ số NW. Điều kiện theo $X_i = i/n$ và dùng $\mathbb{E}\xi_i = 0$:

$$\boxed{\mathbb{E}\widehat{r}_h(x) = \frac{1}{n}\sum_{i=1}^{n} r(i/n)K_h(i/n - x).}$$

Vì các ξ_i độc lập có phương sai σ^2,

$$\boxed{\mathrm{Var}(\widehat{r}_h(x)) = \frac{\sigma^2}{n^2}\sum_{i=1}^{n} K_h(i/n - x)^2.}$$

Ở điểm nội, tổng Riemann xấp xỉ $\int_0^1 r(u)K_h(u-x)du$. Đặt $v=(u-x)/h$, khai triển Taylor và dùng $\int K=1$, $\int vK(v)dv=0$:

$$\int r(x+hv)K(v)dv = r(x)+\frac{h^2\mu_2(K)}{2}r''(x)+o(h^2).$$

Nếu rK_h có biến thiên toàn phần bậc $O(h^{-1})$, sai số Riemann là $O((nh)^{-1})$; để hạng này là $o(h^2)$ cần thêm $nh^3\to\infty$. Slide 49 chỉ ghi $nh\to\infty$, nên không đủ cho bias dẫn đầu dưới giả thiết trơn tổng quát. Tương tự, với $nh\to\infty$,

$$\mathrm{Var}(\widehat{r}_h(x)) \sim \frac{\sigma^2}{nh}\int K(v)^2dv.$$

Khi sai số rời rạc nhỏ hơn h^2, MSE dẫn đầu là $Ah^4+B/(nh)$ với $A=\mu_2(K)^2r''(x)^2/4$, $B=\sigma^2R(K)$. Nếu $A>0$, đạo hàm cho $h_*^5=B/(4An)$, nên $h_*\asymp n^{-1/5}$ và MSE $\asymp n^{-4/5}$.

Câu 39. Vì sao bias NW với thiết kế ngẫu nhiên có hạng $r'f'/f$?

Slide: C3, trang 20–23.

Lời giải.

Đặt $f=f_X$, $a=rf$, $b=f$ và $\widehat{r}_{NW}=\widehat{a}/\widehat{b}$. Ở điểm nội,

$$\mathbb{E}\widehat{a}=a+\frac{h^2\mu_2}{2}a''+o(h^2),\qquad \mathbb{E}\widehat{b}=b+\frac{h^2\mu_2}{2}b''+o(h^2).$$

Đặt $c=h^2\mu_2/2$. Khai triển tỷ số tới bậc một theo c:

$$\frac{a+ca''}{b+cb''}=\frac{a}{b}+c\frac{a''b-ab''}{b^2}+o(c)=r+c\frac{(rf)''-rf''}{f}+o(c).$$

Quy tắc đạo hàm tích cho $(rf)''=r''f+2r'f'+rf''$. Thế vào:

$$\boxed{\mathrm{Bias}_{\mathrm{leading}}=h^2\mu_2\left(\frac{r''}{2}+\frac{r'f'}{f}\right).}$$

Đây là khai triển tiệm cận của tỷ số ngẫu nhiên dưới điều kiện chuẩn, không phải đẳng thức $\mathbb{E}(A/B)=\mathbb{E}A/\mathbb{E}B$.

Công thức cần nhớ. Đặt $a(x)=r(x)f(x)$, $b(x)=f(x)$ và ước lượng nhân $\widehat{a},\widehat{b}$. Ở điểm nội, kernel đối xứng cho $\mathbb{E}\widehat{a}=a+h^2\mu_2a''/2+o(h^2)$ và $\mathbb{E}\widehat{b}=b+h^2\mu_2b''/2+o(h^2)$. Khai triển tỷ số ở cấp leading order:

$$\frac{a+h^2\mu_2a''/2}{b+h^2\mu_2b''/2}-\frac{a}{b}=\frac{h^2\mu_2}{2}\left(r''+2r'\frac{f'}{f}\right)+o(h^2).$$

Hạng $r'f'/f$ là *design bias*. Đây là khai triển tỷ số kỳ vọng/leading asymptotic bias, không phải đẳng thức hữu hạn mẫu $\mathbb{E}(\widehat{a}/\widehat{b})=\mathbb{E}\widehat{a}/\mathbb{E}\widehat{b}$.

Câu 40. Bài tập 6: chứng minh công thức leave-one-out CV cho NW và local polynomial

Slide: C3, trang 24, 50.

Lời giải.

Tại X_i, dự đoán toàn mẫu là $\widehat{r}_i=W_{ii}Y_i+\sum_{j\neq i}W_{ij}Y_j$ và $\sum_j W_{ij}=1$. Bỏ quan sát i rồi chuẩn hóa lại các trọng số còn lại:

$$\widehat{r}_i^{(-i)}=\frac{\sum_{j\neq i}W_{ij}Y_j}{1-W_{ii}}=\frac{\widehat{r}_i-W_{ii}Y_i}{1-W_{ii}}.$$

Do đó

$$Y_i - \widehat{r}_i^{(-i)} = \frac{(1-W_{ii})Y_i - \widehat{r}_i + W_{ii}Y_i}{1-W_{ii}} = \frac{Y_i - \widehat{r}_i}{1-W_{ii}}.$$

Bình phương và lấy trung bình: $\mathrm{CV}(h) = n^{-1}\sum_i [(Y_i - \widehat{r}_i)/(1-W_{ii})]^2$. Với local polynomial tại X_i, gọi v_j là hàng thiết kế, k_j là trọng số, $B = \sum_j k_j v_j v_j^\top$ và $a = \sum_j k_j v_j Y_j$. Khi bỏ quan sát i, $B_{-i} = B - k_i v_i v_i^\top$ và $a_{-i} = a - k_i v_i Y_i$. Phép nghịch đảo hạng một cho

$$\widehat{\theta}_{-i} = \widehat{\theta} - \frac{k_i B^{-1} v_i}{1 - k_i v_i^\top B^{-1} v_i}(Y_i - v_i^\top \widehat{\theta}).$$

Vì tại điểm dự đoán X_i ta có $v_i = e_0$, đặt $W_{ii} = k_i v_i^\top B^{-1} v_i$ và $\widehat{r}_i = v_i^\top \widehat{\theta}$, nhân với $v_i^\top$ cho lại cùng công thức leave-one-out ở trên. Giả thiết chỉ có $\widehat{y} = Wy$ chưa tự xác định ma trận của mô hình sau khi xóa quan sát; đẳng thức cần tính chất cập nhật này của bộ khớp.

Công thức cần nhớ. Tại X_i, viết $\widehat{r}(X_i) = \sum_j W_{ij} Y_j$, với $W_{ij} = K_h(X_j - X_i)/\sum_k K_h(X_k - X_i)$ cho NW. Bỏ quan sát i và chuẩn hóa lại cho

$$\widehat{r}^{(-i)}(X_i) = \frac{\widehat{r}(X_i) - W_{ii}Y_i}{1-W_{ii}}, \qquad Y_i - \widehat{r}^{(-i)}(X_i) = \frac{Y_i - \widehat{r}(X_i)}{1-W_{ii}}.$$

Vì thế $\mathrm{CV}(h) = n^{-1}\sum_i [(Y_i - \widehat{r}(X_i))/(1-W_{ii})]^2$, khi $W_{ii} \neq 1$. Với local polynomial, dùng hệ chuẩn và phép cập nhật bỏ một quan sát như trong lời giải. Công thức cần cấu trúc phép khớp này; chỉ biết $\widehat{y} = Wy$ chưa đủ để suy ra cách W đổi khi bỏ quan sát.

Câu 41. NW có tốc độ MSE và băng thông tối ưu nào?

Slide: C3, trang 20–23.

Lời giải.

Với bias $b(x) \approx C_b h^2$ và phương sai $\approx C_v/(nh)$,

$$\mathrm{MSE}(h) \approx C_b^2 h^4 + \frac{C_v}{nh}.$$

Đặt $A = C_b^2$, $B = C_v$. Đạo hàm và giải:

$$4Ah^3 - \frac{B}{nh^2} = 0 \Longrightarrow h_*^5 = \frac{B}{4An} \Longrightarrow h_* \asymp n^{-1/5}.$$

Thay vào hai hạng: $Ah_*^4 \asymp n^{-4/5}$ và $B/(nh_*) \asymp n^{-4/5}$. Vậy $\mathrm{MSE}(h_*) \asymp n^{-4/5}$ ở điểm nội.

Công thức cần nhớ. Ở điểm nội với đủ độ trơn, bias bậc h^2, phương sai bậc $(nh)^{-1}$. MSE có dạng $Ah^4 + B/(nh)$. Đạo hàm theo h cho $h_*^5 = B/(4An)$, nên $h_* \asymp n^{-1/5}$ và MSE tối ưu bậc $n^{-4/5}$.

Câu 42. Vì sao local linear loại được design bias và tái tạo hàm tuyến tính?

Slide: C3, trang 29–40, 49–50.

Lời giải.

Đặt $u_i = X_i - x$, $w_i = K_h(u_i)$ và $Q(a,b) = \sum_i w_i(Y_i - a - bu_i)^2$. Hai phương trình đạo hàm bằng 0 là

$$\begin{pmatrix} S_0 & S_1 \\ S_1 & S_2 \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} T_0 \\ T_1 \end{pmatrix},$$

với $S_k = \sum_i w_i u_i^k$, $T_k = \sum_i w_i u_i^k Y_i$. Giải hệ:

$$\boxed{\widehat{r}_{LL}(x) = \widehat{a} = \frac{S_2 T_0 - S_1 T_1}{S_0 S_2 - S_1^2}.}$$

Nếu $Y_i = c + dX_i$, lấy $a = c + dx, b = d$ cho $Y_i - a - b(X_i - x) = 0$ từng i. Với ma trận khả nghịch, nghiệm cực tiểu là duy nhất, nên $\widehat{r}_{LL}(x) = c + dx = r(x)$. Vì tái tạo đúng hàm tuyến tính, hạng bias do độ dốc r' bị triệt tiêu.

Công thức cần nhớ. Local linear cực tiểu $\sum_i K_h(X_i - x)[Y_i - a - b(X_i - x)]^2$ và lấy $\widehat{r}_{LL}(x) = \widehat{a}$. Đặt $S_k = \sum_i K_h(X_i - x)(X_i - x)^k$, $T_k = \sum_i K_h(X_i - x)(X_i - x)^k Y_i$. Hệ chuẩn là

$$\begin{pmatrix} S_0 & S_1 \\ S_1 & S_2 \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} T_0 \\ T_1 \end{pmatrix}, \qquad \widehat{a} = \frac{S_2 T_0 - S_1 T_1}{S_0 S_2 - S_1^2}.$$

Nếu $Y_i = c + dX_i$, cặp $(a, b) = (c + dx, d)$ làm mọi phần dư bằng 0; nghiệm là duy nhất khi ma trận khả nghịch. Vì vậy estimator tái tạo đúng hằng số và đường thẳng, làm mất thành phần bias gắn với độ dốc $r'(x)$ ở cấp leading order. Đây là nội dung của claim "không có $r'f'/f$" ở slide 40.

4 Kiểm định phi tham số: chứng minh phân phối và tính tay

Câu 43. Tại sao kiểm định dấu có phân phối nhị thức dưới H_0?

Slide: C5, trang 6–13, 40.

Lời giải.

Dưới $H_0 : m = m_0$ và phân phối liên tục,

$$\mathbb{P}(X_i > m_0) = \mathbb{P}(X_i < m_0) = \tfrac{1}{2}.$$

Đặt $B_i = \mathbf{1}_{\{X_i > m_0\}}$ cho các hiệu khác 0. Các B_i độc lập Bernoulli(1/2), nên

$$S^+ = \sum_{i=1}^{n} B_i \sim \mathrm{Bin}(n, \tfrac{1}{2}), \qquad \mathbb{P}(S^+ = j) = \binom{n}{j} 2^{-n}.$$

Nếu quan sát được s, p một phía $m > m_0$ là $\sum_{j=s}^{n} \binom{n}{j} 2^{-n}$; phía $m < m_0$ là $\sum_{j=0}^{s} \binom{n}{j} 2^{-n}$. Hai phía dùng $k = \min(s, n - s)$ và $p = \min\{1, 2\sum_{j=0}^{k} \binom{n}{j} 2^{-n}\}$.

Công thức cần nhớ. Với giả thiết phân phối liên tục và trung vị m_0 dưới H_0, $\mathbb{P}(X_i > m_0) = \mathbb{P}(X_i < m_0) = 1/2$. Sau khi loại hiệu bằng 0, dấu của các quan sát độc lập; vì thế $S^+ = \sum_i \mathbf{1}\{X_i > m_0\} \sim \mathrm{Bin}(n, 1/2)$. Hai phía với $k = \min(S^+, n - S^+)$ cho $p = \min\{1, 2\mathbb{P}(B \le k)\}$, $B \sim \mathrm{Bin}(n, 1/2)$. Một phía phải dùng đúng đuôi: $m > m_0$ dùng $\mathbb{P}(B \ge S^+)$; $m < m_0$ dùng $\mathbb{P}(B \le S^+)$.

Câu 44. Tính kiểm định dấu chính xác trên một mẫu nhỏ

Với dữ liệu thời gian phản hồi $(218, 195, 240, 232, 207, 225, 198, 250, 212, 228)$ trên slide, kiểm định trung vị $m_0 = 200$ ở mức 5%.

Slide: C5, trang 10–11.

Lời giải.

Trừ 200 khỏi từng quan sát trên slide:

$$(18, -5, 40, 32, 7, 25, -2, 50, 12, 28).$$

Có $S^+ = 8$, $S^- = 2$, không có hiệu bằng 0; do đó $n = 10$ và $k = 2$. Tính đuôi nhỏ:

$$\mathbb{P}(B \le 2) = 2^{-10}\left[\binom{10}{0} + \binom{10}{1} + \binom{10}{2}\right] = \frac{1 + 10 + 45}{1024} = \frac{56}{1024}.$$

Vì đối thuyết hai phía, $p = 2(56/1024) = 112/1024 = \boxed{0.109375}$. Ở mức $\alpha = 0.05$, $p > \alpha$; chưa bác bỏ H_0.

Lưu ý. $k = 2$ và $p = 2\sum_{j=0}^{2} \binom{10}{j} 2^{-10} = 2(1 + 10 + 45)/1024 = 0.109375$. Ở mức 5%, chưa bác bỏ H_0.

Câu 45. Tại sao phân phối Wilcoxon dấu hạng không phụ thuộc F? Tính kỳ vọng, phương sai

Slide: C5, trang 15–18, 41.

Lời giải.

Sau khi bỏ $d_i = 0$, xếp hạng các $|d_i|$ khác nhau thành $1, \dots, n$. Dưới đối xứng, dấu của mỗi d_i là Bernoulli(1/2) độc lập với độ lớn. Gọi $B_j = 1$ nếu hạng j mang dấu dương. Khi đó

$$W^+ = \sum_{j=1}^{n} jB_j, \qquad W^- = \sum_{j=1}^{n} j(1 - B_j), \qquad W^+ + W^- = \frac{n(n+1)}{2}.$$

Do $\mathbb{E}B_j = 1/2$ và $\operatorname{Var} B_j = 1/4$,

$$\mathbb{E}W^+ = \frac{1}{2}\sum_{j=1}^{n} j = \frac{n(n+1)}{4},$$
$$\operatorname{Var}(W^+) = \frac{1}{4}\sum_{j=1}^{n} j^2 = \frac{n(n+1)(2n+1)}{24}.$$

Không có tham số nào của F trong phân phối gán dấu này.

Công thức cần nhớ. Với $d_i = X_i - m_0$ liên tục và phân phối đối xứng, sau khi cố định các $|d_i|$ khác nhau, mỗi dấu là Bernoulli(1/2) độc lập và độc lập với độ lớn. Gọi B_j là dấu dương của quan sát có hạng j. Khi đó

$$W^+ = \sum_{j=1}^{n} jB_j, \qquad \mathbb{E}W^+ = \frac{1}{2}\sum_{j} j = \frac{n(n+1)}{4}, \qquad \operatorname{Var}(W^+) = \frac{1}{4}\sum_{j} j^2 = \frac{n(n+1)(2n+1)}{24}.$$

Phân phối chính xác được tạo bằng mọi cách gán dấu cho $1, \dots, n$. Điều kiện đối xứng quan trọng hơn điều kiện không chuẩn. Khi có hạng trùng, dùng hạng trung bình và phân phối/variance thích hợp.

Câu 46. Tính W^+, W^- và chọn đuôi kiểm định

Với dữ liệu thay đổi nhịp tim $(-2, 4, 8, 25, -5, 16, 3, 1, 12, 17, 20, 9)$ trên slide, kiểm định trung tâm đối xứng $m_0 = 15$ hai phía ở mức 5%.

Slide: C5, trang 19–21, 41.

Lời giải.

Trừ 15 khỏi dữ liệu nhịp tim ở trang 19:

$$d = (-17, -11, -7, 10, -20, 1, -12, -14, -3, 2, 5, -6).$$

Gán hạng cho từng người theo $|d_i|$ tăng dần:

x_i	d_i	$\lvert d_i\rvert$	R_i	Dấu
-2	-17	17	11	$-$
4	-11	11	8	$-$
8	-7	7	6	$-$
25	10	10	7	$+$
-5	-20	20	12	$-$
16	1	1	1	$+$
3	-12	12	9	$-$
1	-14	14	10	$-$
12	-3	3	3	$-$
17	2	2	2	$+$
20	5	5	4	$+$
9	-6	6	5	$-$

Sắp $|d|$ tăng dần được $1, 2, 3, 5, 6, 7, 10, 11, 12, 14, 17, 20$. Các hiệu dương có độ lớn $1, 2, 5, 10$, tức hạng $1, 2, 4, 7$. Vì vậy

$$W^+ = 1 + 2 + 4 + 7 = 14, \qquad W^- = \frac{12 \cdot 13}{2} - 14 = 64, \qquad W = 14.$$

Theo bảng trang 41, ngưỡng hai phía mức 5% ứng với cột một phía 2.5% là 13. Vì $14 > 13$, chưa bác bỏ H_0. Để tính p chính xác, đếm các tập con của $\{1, \dots, 12\}$ có tổng không quá 14. Hệ số của z^s trong $\prod_{j=1}^{12}(1 + z^j)$ là số cách có $W^+ = s$; cộng từ $s = 0$ đến 14 được 107 cách. Do đối xứng của tổng hạng,

$$\boxed{p = 2 \cdot \frac{107}{2^{12}} = \frac{214}{4096} \approx 0.05225.}$$

Ở mức 10% thì bác bỏ, đúng như kết luận trên slide.

Câu 47. Suy ra $U = R_X - n(n+1)/2$ và phân phối dưới H_0

Slide: C5, trang 23–29, 42.

Lời giải.

Gọi $X_{(i)}$ là giá trị thứ i trong riêng nhóm X, có hạng r_i trong mẫu gộp. Trong $r_i - 1$ giá trị đứng trước $X_{(i)}$, có $i - 1$ giá trị X; do đó có $(r_i - 1) - (i - 1) = r_i - i$ giá trị Y. Vì U_X đếm mọi cặp (X, Y) với $Y < X$,

$$U_X = \sum_{i=1}^{n}(r_i - i) = \underbrace{\sum_{i=1}^{n} r_i}_{R_X} - \frac{n(n+1)}{2}.$$

Dưới $H_0 : F = G$ liên tục, mỗi cách đặt n nhãn X vào $N = n + m$ hạng có xác suất $1/\binom{N}{n}$. Vì U_X chỉ là hàm của các hạng và nhãn, phân phối của nó không phụ thuộc dạng F.

Công thức cần nhớ. Gộp mẫu X cỡ n và Y cỡ m, $N = n + m$, xếp hạng. Nếu r_i là hạng toàn bộ của $X_{(i)}$, thì $r_i - i$ đúng bằng số Y nhỏ hơn $X_{(i)}$. Cộng cho $U_X = \sum_i (r_i - i) = R_X - n(n+1)/2$. Dưới $H_0 : F = G$ liên tục, mọi tập n hạng của nhóm X trong $1, \dots, N$ đều có xác suất $1/\binom{N}{n}$, nên phân phối của U chỉ phụ thuộc n, m.

Câu 48. Chứng minh kỳ vọng và phương sai Mann–Whitney U

Slide: C5, trang 24–25.

Lời giải.

Đặt $N = n + m$. Một hạng lấy đều từ $1, \dots, N$ có trung bình $\bar{r} = (N + 1)/2$ và phương sai theo mẫu số N:

$$S_N^2 = \frac{1}{N}\sum_{r=1}^{N}(r - \bar{r})^2 = \frac{N^2 - 1}{12}.$$

Tổng R_X của n hạng chọn không hoàn lại có thể chứng minh bằng biến chỉ báo $I_r = 1$ nếu hạng r được gán cho nhóm X. Khi đó $R_X = \sum_{r=1}^{N} r I_r$, $\mathbb{E}I_r = n/N$ và với $r \neq s$,

$$\mathrm{Cov}(I_r, I_s) = \frac{n(n-1)}{N(N-1)} - \frac{n^2}{N^2} = -\frac{n(N-n)}{N^2(N-1)}.$$

Thế các phương sai và hiệp phương sai vào $\mathrm{Var}(\sum_r r I_r)$, hoặc dùng $\sum_r (r - \bar{r}) = 0$, thu được

$$\mathbb{E}R_X = n\bar{r} = \frac{n(N+1)}{2}, \qquad \mathrm{Var}(R_X) = \frac{n(N-n)}{N-1} S_N^2 = \frac{nm(N+1)}{12}.$$

Vì $U_X = R_X - n(n+1)/2$,

$$\boxed{\mathbb{E}U_X = \frac{nm}{2}, \qquad \mathrm{Var}(U_X) = \frac{nm(N+1)}{12}.}$$

Công thức cần nhớ. R_X là tổng của mẫu ngẫu nhiên đơn không hoàn lại gồm n hạng từ $1, \ldots, N$. Trung bình hạng là $(N+1)/2$, phương sai tổng thể theo mẫu số N là $(N^2-1)/12$. Công thức phương sai tổng không hoàn lại cho

$$\mathbb{E}R_X = \frac{n(N+1)}{2}, \quad \mathrm{Var}(R_X) = \frac{n(N-n)}{N-1}\frac{N^2-1}{12} = \frac{nm(N+1)}{12}.$$

Trừ hằng số $n(n+1)/2$ suy ra $\mathbb{E}U = nm/2$ và $\mathrm{Var}(U) = nm(N+1)/12$.

Câu 49. Tính Mann–Whitney bằng tay

Với nhóm A $(12, 15, 9, 18, 14, 20)$ và nhóm B $(7, 10, 6, 13, 8)$ trên slide, tính tổng hạng và U_A, U_B; kiểm định hai phía ở mức 5%.

Slide: C5, trang 26–28, 42.

Lời giải.

Gộp hai nhóm trên slide và sắp tăng dần:

$$6_B, 7_B, 8_B, 9_A, 10_B, 12_A, 13_B, 14_A, 15_A, 18_A, 20_A.$$

Hạng nhóm A là $4, 6, 8, 9, 10, 11$, nên $R_A = 4+6+8+9+10+11 = 48$. Hạng nhóm B là $1, 2, 3, 5, 7$, nên $R_B = 18$. Kiểm tra $R_A + R_B = 66 = 11 \cdot 12/2$. Với $n = 6, m = 5$,

$$U_A = 48 - \frac{6 \cdot 7}{2} = 27, \qquad U_B = 18 - \frac{5 \cdot 6}{2} = 3, \qquad U_A + U_B = nm = 30.$$

Lấy $U = \min(U_A, U_B) = 3$. Bảng trang 42 cho $U_{\mathrm{crit}} = 3$ ở mức hai phía 5%; vì $U \leq U_{\mathrm{crit}}$, bác bỏ H_0. Đếm các cách gán 6 hạng A vào 11 hạng có $U_A \geq 27$ hoặc $U_A \leq 3$: mỗi đuôi có 7 cách trên $\binom{11}{6} = 462$ cách, nên

$$\boxed{p = \frac{14}{462} \approx 0.03030.}$$

Nhóm A có xu hướng giảm huyết áp nhiều hơn trong mẫu này.

Câu 50. Suy ra công thức rút gọn của Spearman

Slide: C5, trang 30–33, 43.

Lời giải.

Không có hạng trùng, $R_1, \ldots, R_n$ và $S_1, \ldots, S_n$ đều là hoán vị của $1, \ldots, n$. Do đó

$$\bar{R} = \bar{S} = \frac{n+1}{2}, \qquad A := \sum_i (R_i - \bar{R})^2 = \sum_i (S_i - \bar{S})^2 = \frac{n(n^2-1)}{12}.$$

Đặt $d_i = R_i - S_i$. Khai triển bình phương:

$$\sum_i d_i^2 = 2A - 2\sum_i (R_i - \bar{R})(S_i - \bar{S}).$$

Spearman là tích chéo chia A, nên

$$\rho_S = \frac{A - \frac{1}{2}\sum_i d_i^2}{A} = 1 - \frac{\sum_i d_i^2}{2A} = \boxed{1 - \frac{6\sum_i d_i^2}{n(n^2-1)}}.$$

Nếu có hạng trùng, hai tổng bình phương không còn bằng A; phải tính Pearson trực tiếp trên midrank.

Công thức cần nhớ. Không có hạng trùng, $\bar{R} = \bar{S} = (n+1)/2$ và $A = \sum_i (R_i - \bar{R})^2 = n(n^2-1)/12 = \sum_i (S_i - \bar{S})^2$. Đặt $d_i = R_i - S_i$. Khi đó $\sum_i d_i^2 = 2A - 2\sum_i (R_i - \bar{R})(S_i - \bar{S})$. Chia cho $2A$ được

$$\rho_S = 1 - \frac{6\sum_i d_i^2}{n(n^2-1)}.$$

Có hạng trùng thì dùng Pearson trên *hạng trung bình*, không dùng công thức rút gọn này. Phân phối tự do dưới H_0 cần giả thiết độc lập của X, Y với biên liên tục, mạnh hơn chỉ nói "tương quan bằng 0".

Câu 51. Tính Kendall τ và giải thích phương sai dưới độc lập

Slide: C5, trang 34–36, 43.

Lời giải.

Với mỗi cặp $i < j$ đặt $Z_{ij} = \operatorname{sgn}[(X_i - X_j)(Y_i - Y_j)]$. Khi không có ties, $Z_{ij} = 1$ cho cặp đồng hành và -1 cho cặp nghịch hành. Vì vậy

$$S = \sum_{i<j} Z_{ij} = n_c - n_d, \qquad \tau = \frac{S}{\binom{n}{2}}.$$

Dưới độc lập và biên liên tục, $\mathbb{E}Z_{ij} = 0$, $\operatorname{Var} Z_{ij} = 1$. Hai cặp hạng có chỉ số rời nhau độc lập. Với một bộ ba chỉ số, mỗi trong ba cặp hạng chia sẻ chỉ số có covariance $1/9$ (liệt kê sáu thứ tự của ba giá trị trong mỗi biên). Thật vậy, với hai dấu cùng gắn quan sát i, $\operatorname{sgn}(X_i - X_j)\operatorname{sgn}(X_i - X_k)$ bằng $+1$ nếu X_i nhỏ nhất hoặc lớn nhất (xác suất $2/3$), và -1 nếu X_i ở giữa (xác suất $1/3$); kỳ vọng là $1/3$. Phần Y độc lập và cũng có kỳ vọng $1/3$, nên kỳ vọng tích hai biên bằng $1/9$. Do đó

$$\operatorname{Var} S = \binom{n}{2} + 2 \cdot 3 \cdot \frac{1}{9}\binom{n}{3} = \frac{n(n-1)(2n+5)}{18}.$$

Chia cho $\binom{n}{2}^2$:

$$\boxed{\mathbb{E}\tau = 0, \qquad \operatorname{Var}(\tau) = \frac{2(2n+5)}{9n(n-1)}.}$$

Công thức cần nhớ. Với không có hạng trùng, đặt $Z_{ij} = \operatorname{sgn}[(X_i - X_j)(Y_i - Y_j)]$ cho $i < j$. Khi đó $S = \sum_{i<j} Z_{ij} = n_c - n_d$ và $\tau = S/\binom{n}{2}$. Dưới độc lập và biên liên tục, $\mathbb{E}Z_{ij} = 0$, $\operatorname{Var}(Z_{ij}) = 1$; các cặp chỉ số rời nhau có hiệp phương sai 0. Với một bộ ba chỉ số, mỗi cặp trong ba cặp hạng chia sẻ chỉ số có $\mathbb{E}(Z_{ij}Z_{ik}) = 1/9$: ở mỗi biên, liệt kê 3! thứ tự cho kỳ vọng tích dấu bằng $\pm 1/3$, rồi nhân hai biên độc lập. Khi khai triển phương sai tổng, bộ ba góp $2 \cdot 3/9 = 2/3$. Do đó

$$\operatorname{Var}(S) = \binom{n}{2} + \frac{2}{3}\binom{n}{3} = \frac{n(n-1)(2n+5)}{18}.$$

Vì vậy

$$\mathbb{E}\tau = 0, \qquad \mathrm{Var}(\tau) = \frac{2(2n+5)}{9n(n-1)}.$$

Nếu có hạng trùng, dùng biến thể τ_b và công thức phương sai khác. Phép tính chỉ số ba quan sát là phần khó nhất của chứng minh phương sai.

Câu 52. KS một mẫu: tại sao chỉ cần kiểm tra ở hai phía của mỗi điểm nhảy?

Slide: C1, trang 36–38.

Lời giải.

Đặt $D_n = \sup_x |\widehat{F}_n(x) - F_0(x)|$. Giữa hai thống kê thứ tự liên tiếp, $\widehat{F}_n(x)$ không đổi còn $F_0(x)$ liên tục, không giảm; giá trị lớn nhất của trị tuyệt đối sai khác nằm ở một đầu khoảng. Ngay trước $X_{(i)}$, $\widehat{F}_n(X_{(i)}-) = (i-1)/n$; tại $X_{(i)}$, $\widehat{F}_n(X_{(i)}) = i/n$ nếu không có ties. Do đó

$$\boxed{D_n = \max_{1\le i\le n}\left\{\frac{i}{n} - F_0(X_{(i)}),\ F_0(X_{(i)}) - \frac{i-1}{n}\right\}.}$$

Slide dùng $T_{KS} = \sqrt{n}\, D_n$. Nếu có ties, dùng các bước nhảy thực tế của ECDF.

Công thức cần nhớ. Nếu F_0 liên tục và $X_{(1)} \le \cdots \le X_{(n)}$, giữa hai quan sát liên tiếp ECDF là hằng số còn F_0 không giảm. Độ lệch cực đại trên khoảng đạt tại một đầu mút. Tại $X_{(i)}$ và ngay bên trái nó, ECDF lần lượt là i/n và $(i-1)/n$. Do đó

$$D_n = \sup_x |\widehat{F}_n(x) - F_0(x)| = \max_{1\le i\le n} \max\left\{\frac{i}{n} - F_0(X_{(i)}),\ F_0(X_{(i)}) - \frac{i-1}{n}\right\}.$$

Thống kê trên slide là $T_{KS} = \sqrt{n}D_n$. Công thức cần chú ý điều kiện F_0 liên tục và cách xử lý giá trị trùng.

Câu 53. CvM và Anderson–Darling đo loại sai khác nào?

Slide: C1, trang 39–41.

Lời giải.

Với $U_{(i)} = F_0(X_{(i)})$, hai thống kê là

$$T_{\mathrm{CvM}} = n\int (\widehat{F}_n - F_0)^2\, dF_0 = \frac{1}{12n} + \sum_{i=1}^{n}\left(U_{(i)} - \frac{2i-1}{2n}\right)^2,$$

và

$$T_{\mathrm{AD}} = n\int \frac{(\widehat{F}_n - F_0)^2}{F_0(1-F_0)}\, dF_0 = -n - \frac{1}{n}\sum_{i=1}^{n}(2i-1)\{\log U_{(i)} + \log[1 - U_{(n+1-i)}]\}.$$

Để thấy dạng tổng, đổi biến $u = F_0(x)$, đặt $U_{(0)} = 0, U_{(n+1)} = 1$. Trên $u \in [U_{(i)}, U_{(i+1)})$, ECDF bằng i/n. Do đó

$$T_{\mathrm{CvM}} = n\sum_{i=0}^{n}\int_{U_{(i)}}^{U_{(i+1)}}\left(\frac{i}{n} - u\right)^2 du.$$

Tính từng nguyên hàm $-(i/n-u)^3/3$ và thu gọn các hạng ở biên cho công thức tổng trên. Với AD, làm tương tự nhưng tích phân $n(i/n-u)^2/[u(1-u)]$; nguyên hàm chứa $\log u$ và $\log(1-u)$, cho công thức log ở trên sau khi cộng các khoảng. Trong CvM, mọi vùng được cộng theo dF_0. Trong AD, hệ số $1/[F_0(1-F_0)]$ lớn ở hai đuôi, nên cùng một sai khác ở đuôi góp nhiều hơn. Hai công thức tổng được tính bằng cách chia tích phân theo các khoảng giữa thống kê thứ tự sau phép đổi biến $u = F_0(x)$.

Lưu ý. Cramér–von Mises dùng $T_{CvM} = n\int(\widehat{F}_n - F_0)^2\,dF_0$. Với F_0 liên tục và được chỉ định hoàn toàn, đặt $U_i = F_0(X_i)$ rồi sắp thứ tự để suy ra

$$T_{CvM} = \frac{1}{12n} + \sum_{i=1}^{n}\left(U_{(i)} - \frac{2i-1}{2n}\right)^2.$$

Anderson–Darling dùng $T_{AD} = n\int(\widehat{F}_n - F_0)^2/[F_0(1-F_0)]\,dF_0$, nên nhấn mạnh vùng đuôi. Dạng tính tay là

$$T_{AD} = -n - \frac{1}{n}\sum_{i=1}^{n}(2i-1)\{\log U_{(i)} + \log[1 - U_{(n+1-i)}]\}.$$

Không tự áp dụng bảng tới hạn cho F_0 có tham số ước lượng từ chính mẫu; khi đó phân phối dưới H_0 thay đổi. Slide 40 có một câu về giá trị tới hạn dễ gây nhầm: với F_0 liên tục *được chỉ định hoàn toàn*, biến đổi xác suất tích lũy làm phân phối kiểm định không phụ thuộc dạng F_0.

Câu 54. KS hai mẫu: suy ra hệ số chuẩn hóa $\sqrt{nm/(n+m)}$

Slide: C1, trang 42–46.

Lời giải.

Dưới $H_0 : F_X = F_Y = F$, tại x cố định,

$$\operatorname{Var}\widehat{F}_X(x) = \frac{F(x)(1-F(x))}{n}, \qquad \operatorname{Var}\widehat{F}_Y(x) = \frac{F(x)(1-F(x))}{m}.$$

Hai mẫu độc lập, nên

$$\operatorname{Var}\{\widehat{F}_X(x) - \widehat{F}_Y(x)\} = F(x)(1-F(x))\left(\frac{1}{n} + \frac{1}{m}\right).$$

Vì $1/n + 1/m = (n+m)/(nm)$, hệ số chuẩn hóa nghịch căn là

$$\frac{1}{\sqrt{1/n + 1/m}} = \sqrt{\frac{nm}{n+m}}.$$

Do đó $T_{KS,2} = \sqrt{nm/(n+m)}\,\sup_x|\widehat{F}_X(x) - \widehat{F}_Y(x)|$. Phân phối giới hạn của supremum cần định lý quá trình, không suy ra chỉ từ phương sai tại một điểm.

Công thức cần nhớ. Dưới $H_0 : F_X = F_Y = F$, tại mỗi x cố định,

$$\operatorname{Var}\{\widehat{F}_X(x) - \widehat{F}_Y(x)\} = F(x)[1-F(x)]\left(\frac{1}{n} + \frac{1}{m}\right).$$

Nghịch đảo căn của $1/n + 1/m$ là $\sqrt{nm/(n+m)}$, nên đó là chuẩn hóa tự nhiên của sai khác hai ECDF. Lấy supremum cho thống kê KS hai mẫu; để suy ra phân phối Kolmogorov tiệm cận của supremum còn cần định lý quá trình thực nghiệm, không chỉ CLT tại một điểm.

5 Bổ sung từ các slide chưa được hỏi ở bản đầu

Câu 55. Định nghĩa CDF, quantile và chứng minh phép biến đổi nghịch đảo

Slide: C1, trang 6–9.

Lời giải.

Định nghĩa $F(x) = \mathbb{P}(X \le x)$ và $F^{-1}(u) = \inf\{x : F(x) \ge u\}$. Nếu $U \sim \text{Unif}(0,1)$,

$$\mathbb{P}(F^{-1}(U) \le x) = \mathbb{P}(U \le F(x)) = F(x),$$

nên $F^{-1}(U)$ có CDF F. Với phân phối mũ $F(x) = 1 - e^{-\lambda x}$ $(x \geq 0)$, giải phương trình $u = F(x)$:

$$1 - u = e^{-\lambda x} \Longrightarrow \log(1-u) = -\lambda x \Longrightarrow \boxed{F^{-1}(u) = -\frac{\log(1-u)}{\lambda}}.$$

Nếu F liên tục, phép biến đổi ngược lại cho $F(X) \sim \text{Unif}(0,1)$.

Công thức cần nhớ. $F(x) = \mathbb{P}(X \leq x)$ luôn tồn tại, không giảm và liên tục phải. Quantile tổng quát là $F^{-1}(u) = \inf\{x : F(x) \geq u\}$. Với $U \sim \text{Unif}(0,1)$, tính chất của nghịch đảo tổng quát cho $\{F^{-1}(U) \leq x\} = \{U \leq F(x)\}$ (bỏ qua các điểm biên không ảnh hưởng xác suất), do đó $\mathbb{P}(F^{-1}(U) \leq x) = F(x)$. Nếu F liên tục, $F(X) \sim \text{Unif}(0,1)$. Với $F(x) = 1 - e^{-\lambda x}$ trên $x \geq 0$, giải $u = F(x)$ được $F^{-1}(u) = -\log(1-u)/\lambda$.

Câu 56. Tại sao plug-in quantile là một thống kê thứ tự? Plug-in skewness là gì?

Slide: C1, trang 28–35.

Lời giải.

Với mẫu sắp $X_{(1)} \leq \cdots \leq X_{(n)}$, $\widehat{F}_n$ lần đầu đạt mức p ở bước $k = \lceil np \rceil$, nên

$$\boxed{\widehat{F}_n^{-1}(p) = X_{(\lceil np \rceil)}.}$$

Skewness thật là $\kappa(F) = \mathbb{E}[(X-\mu)^3]/\{\mathbb{E}[(X-\mu)^2]\}^{3/2}$. Phép thế $F \mapsto \widehat{F}_n$ biến từng kỳ vọng thành trung bình mẫu:

$$\boxed{\widehat{\kappa} = \frac{\frac{1}{n}\sum_i (X_i - \bar{X})^3}{\left[\frac{1}{n}\sum_i (X_i - \bar{X})^2\right]^{3/2}}.}$$

Nếu phương sai mẫu bằng 0, mẫu số bằng 0 và thống kê không xác định.

Công thức cần nhớ. Vì $\widehat{F}_n$ nhảy bậc $1/n$ tại từng quan sát sắp thứ tự, $\widehat{F}_n^{-1}(p) = \inf\{x : \widehat{F}_n(x) \geq p\} = X_{(\lceil np \rceil)}$ với $p \in (0,1]$. Skewness là phiếm hàm phi tuyến $\kappa(F) = \mathbb{E}[(X-\mu)^3]/\{\mathbb{E}[(X-\mu)^2]\}^{3/2}$. Thay F bằng $\widehat{F}_n$ và μ bằng $\bar{X}$ cho

$$\widehat{\kappa} = \frac{n^{-1}\sum_i (X_i - \bar{X})^3}{\{n^{-1}\sum_i (X_i - \bar{X})^2\}^{3/2}},$$

khi mẫu có phương sai dương. Cần phân biệt quy ước quantile $X_{(\lceil np \rceil)}$ của slide với các quy ước nội suy trong phần mềm.

Câu 57. Viết CvM và Anderson–Darling hai mẫu từ ECDF gộp

Slide: C1, trang 42–46.

Lời giải.

Đặt $N = n + m$ và $\widehat{H} = (n\widehat{F}_X + m\widehat{F}_Y)/N$. Vì $\widehat{H}$ đặt khối lượng $1/N$ lên mỗi quan sát gộp, với $Z_1, \ldots, Z_N$ là các giá trị gộp (kể cả lặp),

$$\int g(x)\, d\widehat{H}(x) = \frac{1}{N}\sum_{k=1}^{N} g(Z_k).$$

Chọn $g = (\widehat{F}_X - \widehat{F}_Y)^2$:

$$T_{\text{CvM},2} = \frac{nm}{N^2}\sum_{k=1}^{N} [\widehat{F}_X(Z_k) - \widehat{F}_Y(Z_k)]^2.$$

Với AD, thay mỗi bình phương bằng bình phương chia $\widehat{H}(Z_k)[1 - \widehat{H}(Z_k)]$ ở những điểm mẫu số dương. Vậy hai tích phân trên slide thành tổng hữu hạn tính trực tiếp từ ECDF gộp.

Công thức cần nhớ. Đặt $\widehat{H} = (n\widehat{F}_X + m\widehat{F}_Y)/(n+m)$, $N = n+m$. Hai thống kê trên slide 44 là

$$T_{CvM,2} = \frac{nm}{N}\int (\widehat{F}_X - \widehat{F}_Y)^2\, d\widehat{H}, \quad T_{AD,2} = \frac{nm}{N}\int \frac{(\widehat{F}_X - \widehat{F}_Y)^2}{\widehat{H}(1-\widehat{H})}\, d\widehat{H}.$$

Vì $\widehat{H}$ là phân phối rời rạc, tích phân là tổng trên các giá trị gộp; ở điểm có $\widehat{H} = 0$ hoặc 1 cần dùng quy ước loại phần hạng không xác định. AD đặt trọng số lớn hơn ở hai đuôi. Đây là định nghĩa/thao tác tính, không phải tự động là chứng minh phân phối giới hạn.

Câu 58. Định nghĩa risk và chứng minh phân rã bias–variance tổng quát

Slide: C2, trang 6–10; C3 7.

Lời giải.

Đặt $Z = \widehat{f}(x)$, $\theta = f(x)$ và $b = \mathbb{E}Z - \theta$. Khi đó

$$Z - \theta = (Z - \mathbb{E}Z) + b.$$

Bình phương rồi lấy kỳ vọng:

$$\begin{aligned}\mathbb{E}(Z-\theta)^2 &= \mathbb{E}(Z-\mathbb{E}Z)^2 + 2b\,\mathbb{E}(Z-\mathbb{E}Z) + b^2 \\ &= \mathrm{Var}(Z) + 0 + \mathrm{Bias}(Z)^2.\end{aligned}$$

Vì $(\widehat{f} - f)^2 \geq 0$, Tonelli cho

$$\mathrm{MISE} = \mathbb{E}\int (\widehat{f} - f)^2 = \int \mathbb{E}(\widehat{f}(x) - f(x))^2 dx = \int [\mathrm{Bias}(x)^2 + \mathrm{Var}\,\widehat{f}(x)]dx.$$

Công thức cần nhớ. Tại một điểm, $\mathrm{MSE}(x) = \mathbb{E}[(\widehat{f}(x) - f(x))^2]$. Cộng trừ $\mathbb{E}\widehat{f}(x)$ rồi khai triển bình phương; hạng chéo có kỳ vọng 0, nên $\mathrm{MSE}(x) = \{\mathbb{E}\widehat{f}(x) - f(x)\}^2 + \mathrm{Var}(\widehat{f}(x))$. Rủi ro tích phân là $\mathrm{MISE} = \mathbb{E}\int(\widehat{f} - f)^2 = \int \mathrm{MSE}(x)\, dx$ khi đổi thứ tự kỳ vọng–tích phân hợp lệ (Tonelli cho tích phân không âm). Đối với hồi quy, thay f bằng r.

Câu 59. Lớp Hölder, Sobolev và cận minimax trên slide nói gì?

Slide: C2, trang 9–10, 22–25; C3 6, 43.

Lời giải.

Với $\beta > 0$ không nguyên và $\ell = \lfloor \beta \rfloor$, điều kiện Hölder trên slide là

$$|f^{(\ell)}(x) - f^{(\ell)}(y)| \leq L|x-y|^{\beta-\ell}.$$

Với lớp Sobolev, điều kiện được biểu diễn qua Fourier:

$$\int_{\mathbb{R}} |f^*(u)|^2 (1+|u|^2)^{\beta} du \leq L^2.$$

Nếu một estimator có cận trên cho rủi ro tích phân $\sup_f \mathbb{E}_f \int (\widehat{f}(x) - f(x))^2 dx \leq Cn^{-2\beta/(2\beta+1)}$, ta mới chứng minh rằng estimator ấy đạt tốc độ *không chậm hơn* bậc này. Muốn gọi là minimax tối ưu còn cần cận dưới

$$\inf_{\widehat{f}} \sup_{f \in \mathcal{F}} \mathbb{E}_f \int (\widehat{f}(x) - f(x))^2 dx \geq cn^{-2\beta/(2\beta+1)}.$$

Slide phát biểu cận dưới; phép cân bằng bias–variance không chứng minh được nó.

Lưu ý. Với $\beta > 0$ không nguyên, đặt $\ell = \lfloor \beta \rfloor$; điều kiện Hölder là $|f^{(\ell)}(x) - f^{(\ell)}(y)| \leq L|x-y|^{\beta-\ell}$, cùng các điều kiện bị chặn cần thiết. Ở β nguyên, phát biểu cần một quy ước riêng (chẳng hạn $\ell = \lceil \beta \rceil - 1$) để tránh số mũ 0 không diễn đạt đúng độ trơn mong muốn. Sobolev đo độ trơn bằng

năng lượng Fourier có trọng số $\int |f^*(u)|^2(1+|u|^2)^\beta du$. Slide nêu cận minimax bậc $n^{-2\beta/(2\beta+1)}$; cận trên của ước lượng chiếu suy từ bias/variance, nhưng cận dưới đòi lập luận riêng và không tự suy ra chỉ bằng tối ưu D.

Câu 60. Phân biệt thiết kế cố định, ngẫu nhiên và regressogram

Slide: C3, trang 3–7, 11, 20–22.

Lời giải.

Nếu $X_i = i/n$ được chọn trước, khi điều kiện theo X các điểm này không ngẫu nhiên: thiết kế cố định. Nếu $X_i \overset{\text{iid}}{\sim} f_X$, đó là thiết kế ngẫu nhiên. Với ô I_k và $n_k = \sum_i \mathbf{1}_{\{X_i \in I_k\}}$, regressogram là

$$\widehat{r}_{\text{reg}}(x) = \frac{\sum_i Y_i \mathbf{1}_{\{X_i \in I_k\}}}{n_k}, \qquad x \in I_k,\ n_k > 0.$$

Nếu $n_k = 0$ thì tỷ số 0/0 chưa xác định. NW thay chỉ báo $\mathbf{1}_{\{X_i \in I_k\}}$ bằng $K_h(X_i - x)$ và chuẩn hóa bằng tổng trọng số.

Lưu ý. Thiết kế cố định coi X_i là các điểm cho trước, thí dụ $X_i = i/n$; thiết kế ngẫu nhiên coi X_i i.i.d. có mật độ f_X. Với $Y_i = r(X_i) + \xi_i$ và ô I_k chứa $n_k > 0$ điểm, regressogram tại $x \in I_k$ là $\sum_{i:X_i \in I_k} Y_i/n_k$. Đây là trung bình cục bộ theo ô, còn NW dùng trọng số nhân biến thiên trơn theo khoảng cách đến x. Ô rỗng làm regressogram chưa xác định; cần quy tắc xử lý.

Câu 61. Tính phương sai điều kiện của một bộ làm trơn tuyến tính

Slide: C3, trang 16–21, 38–40.

Lời giải.

Điều kiện theo $X = (X_1, \ldots, X_n)$ làm các trọng số $W_i(x)$ thành hằng số. Giả sử Y_i độc lập có điều kiện theo X. Từ tính chất phương sai của tổng:

$$\operatorname{Var}\left(\sum_i W_i(x) Y_i \mid X\right) = \sum_i W_i(x)^2 \operatorname{Var}(Y_i \mid X) + 2\sum_{i<j} W_i W_j \operatorname{Cov}(Y_i, Y_j \mid X).$$

Các covariance chéo bằng 0, nên nếu $\operatorname{Var}(Y_i \mid X) = \sigma_i^2$,

$$\boxed{\operatorname{Var}(\widehat{r}(x) \mid X) = \sum_i W_i(x)^2 \sigma_i^2.}$$

Trường hợp đồng phương sai cho $\sigma^2 \sum_i W_i(x)^2$.

Công thức cần nhớ. Nếu $\widehat{r}(x) = \sum_i W_i(x) Y_i$ với trọng số chỉ phụ thuộc X, và các nhiễu độc lập có $\operatorname{Var}(Y_i \mid X) = \sigma_i^2$, thì

$$\operatorname{Var}(\widehat{r}(x) \mid X) = \sum_i W_i(x)^2 \sigma_i^2.$$

Nếu đồng phương sai, kết quả bằng $\sigma^2 \sum_i W_i^2$. Đây là công thức chính xác. Với NW hoặc local linear ở điểm nội, phép xấp xỉ tiệm cận cho phương sai là

$$\frac{\sigma^2(x) R(K)}{n h f_X(x)}.$$

Tại biên, hằng số equivalent-kernel nói chung khác hằng số điểm nội; cần tính lại.

Câu 62. Ma trận làm trơn và GCV được dựng thế nào?

Slide: C3, trang 17–19, 24–25.

Lời giải.

Tại các điểm X_i, đặt $W_{ij} = W_j(X_i)$. Khi đó $\widehat{Y}_i = \sum_j W_{ij} Y_j$, hay $\widehat{y} = Wy$. Trace là $\tau = \sum_i W_{ii}$.

Từ câu 40,

$$\mathrm{CV}(h) = \frac{1}{n}\sum_i \frac{(Y_i - \widehat{Y}_i)^2}{(1 - W_{ii})^2}.$$

GCV thay các đường chéo W_{ii} bằng trung bình τ/n, nên

$$\boxed{\mathrm{GCV}(h) = \frac{n^{-1}\sum_i (Y_i - \widehat{Y}_i)^2}{(1 - \tau/n)^2}.}$$

Đây là một tiêu chuẩn xấp xỉ CV, không phải một đẳng thức giữa GCV và CV.

Công thức cần nhớ. Tại các X_i, đặt $W_{ij} = W_j(X_i)$ thì $\widehat{y} = Wy$. Trace $\tau = \mathrm{tr}(W) = \sum_i W_{ii}$ đóng vai trò bậc tự do hiệu dụng. Từ CV leave-one-out $n^{-1}\sum_i [(Y_i - \widehat{Y}_i)/(1 - W_{ii})]^2$, thay từng W_{ii} bằng trung bình τ/n cho

$$\mathrm{GCV}(h) = \frac{n^{-1}\sum_i (Y_i - \widehat{Y}_i)^2}{(1 - \tau/n)^2}.$$

Đây là tiêu chuẩn xấp xỉ CV, cần $\tau < n$ để mẫu số dương.

Câu 63. Chứng minh moment rời rạc và tái tạo đa thức cho local polynomial bậc ℓ

Slide: C3, trang 31–37, 41–43, 50.

Lời giải.

Đặt $V_{ik} = (X_i - x)^k$ với $k = 0, \ldots, \ell$, $W = \mathrm{diag}(K_h(X_i - x))$ và $B = V^\top W V$ khả nghịch. Ước lượng local polynomial tại x là hệ số hằng $\widehat{r}(x) = e_0^\top B^{-1} V^\top W Y$. Với đáp ứng đặc biệt c_k có $(c_k)_i = (X_i - x)^k$,

$$V^\top W c_k = B e_k.$$

Do đó

$$\sum_i l_i(x)(X_i - x)^k = e_0^\top B^{-1} V^\top W c_k = e_0^\top B^{-1} B e_k = \delta_{0k}.$$

Nếu $P(u) = \sum_{k=0}^{\ell} a_k (u - x)^k$, thì $\sum_i l_i(x) P(X_i) = a_0 = P(x)$. Vậy local polynomial tái tạo đúng mọi đa thức bậc không quá ℓ.

Công thức cần nhớ. Đặt hàng $V_i = (1, X_i - x, \ldots, (X_i - x)^\ell)$ và $B = V^\top W V$ khả nghịch. Vector trọng số ước lượng giá trị tại x là $\mathbf{l}^\top = e_0^\top B^{-1} V^\top W$. Nếu c_k có phần tử $(X_i - x)^k$, thì $V^\top W c_k = B e_k$ cho $0 \le k \le \ell$. Vì vậy $\sum_i l_i (X_i - x)^k = e_0^\top B^{-1} B e_k = \delta_{0k}$. Viết đa thức bậc $\le \ell$ theo các lũy thừa $(u - x)^k$ cho $\sum_i l_i P(X_i) = P(x)$. Với kernel tương đương ở điểm nội, các moment triệt tiêu tương tự. Đó là cơ chế khử bias của local polynomial.

Câu 64. Khi nào dùng phân phối chính xác, xấp xỉ chuẩn và hiệu chỉnh hạng trùng?

Slide: C5, trang 5, 8–9, 16–18, 24–25, 38–43.

Lời giải.

Với kiểm định dấu, sau khi bỏ mọi hiệu bằng 0, cỡ mẫu hiệu dụng là $n' = \#\{d_i \neq 0\}$, và dưới H_0, $S^+ \sim \mathrm{Bin}(n', 1/2)$. Với Wilcoxon dấu hạng không có ties, $W^+ = \sum_{j=1}^{n'} j B_j$; có $2^{n'}$ cách gán dấu để tính phân phối chính xác. Với Mann–Whitney không có ties, có $\binom{n+m}{n}$ cách gán nhãn vào các hạng để tính phân phối chính xác. Khi dùng xấp xỉ chuẩn, tính

$$Z = \frac{T - \mathbb{E}_0 T}{\sqrt{\mathrm{Var}_0(T)}}$$

rồi chọn đuôi theo H_1. Nếu có hạng trùng, gán midrank nhưng phải hiệu chỉnh phương sai hoặc dùng phép hoán vị điều kiện; không giữ nguyên bảng không-ties.

Lưu ý. Mẫu nhỏ: dùng nhị thức chính xác cho dấu; phân phối gán dấu cho Wilcoxon dấu hạng; phân phối hoán vị hạng cho Mann–Whitney. Mẫu lớn: chuẩn hóa bằng kỳ vọng và phương sai dưới H_0; có thể hiệu chỉnh liên tục theo chiều đuôi. Ties làm các công thức "hạng $1, \dots, n$ phân biệt" không còn áp dụng nguyên dạng: gán midrank, tính lại phương sai hoặc dùng phân phối hoán vị điều kiện phù hợp. Kiểm định dấu loại các hiệu bằng 0 và giảm cỡ mẫu hiệu dụng. Với Spearman/Kendall, giả thuyết tự do phân phối chuẩn là *độc lập* với biên liên tục, không chỉ hệ số tương quan Pearson bằng 0.

Câu 65. Tính Spearman và Kendall từ ví dụ hạng trên slide

Slide: C5, trang 30–36, 43.

Lời giải.

Với tám cặp (X_i, Y_i) trên slide 32, gán hạng riêng cho từng biến và tính $d_i = R_i - S_i$:

X_i	Y_i	R_i	S_i	d_i	d_i^2
2.0	5.5	2	3	-1	1
5.0	8.0	7	6	1	1
1.0	4.0	1	1	0	0
4.0	7.5	5	5	0	0
3.0	6.0	4	4	0	0
6.0	9.0	8	8	0	0
2.5	5.0	3	2	1	1
4.5	8.5	6	7	-1	1

Vì $n = 8$ và $\sum_i d_i^2 = 4$, nên

$$\rho_S = 1 - \frac{6 \cdot 4}{8(8^2 - 1)} = 1 - \frac{24}{504} = \boxed{\frac{20}{21} \approx 0.9524}.$$

Slide cho ngưỡng hai phía 5% là 0.714; $0.9524 > 0.714$, nên bác bỏ H_0 độc lập. Với Kendall, có $\binom{8}{2} = 28$ cặp, $n_c = 26, n_d = 2$, nên

$$\tau = \frac{26 - 2}{28} = \boxed{\frac{6}{7} \approx 0.8571}.$$

Slide cho ngưỡng của $n_c - n_d$ là 16; $26 - 2 = 24 > 16$, cũng bác bỏ H_0.

Lưu ý. Ở ví dụ $n = 8$ của slide, $\sum_i (R_i - S_i)^2 = 4$, nên $\rho_S = 1 - 6 \cdot 4/[8(8^2 - 1)] = 20/21 \approx 0.9524$. Với Kendall, $n_c = 26, n_d = 2$, nên $\tau = (26 - 2)/\binom{8}{2} = 24/28 = 6/7 \approx 0.8571$. Cả hai vượt ngưỡng hai phía 5% được nêu ở slide 33 và 36. Khi tính bài mới, phải tự lập vector hạng hoặc liệt kê 28 cặp; không suy trực tiếp τ từ ρ_S.

Phạm vi của tài liệu. Các câu hỏi trên tập trung vào ECDF, histogram như một phép chiếu, ước lượng chiếu, NW và kiểm định. Phần ước lượng mật độ bằng nhân đã được rút khỏi ngân hàng câu hỏi theo phạm vi ôn thi mới. Tài liệu không chép lại từng hình minh họa, mã R, bảng tra nguyên trang hay chứng minh đầy đủ của các kết quả sâu chỉ được slide phát biểu (DKW, cận dưới minimax, bất đẳng thức oracle và giới hạn quá trình thực nghiệm). Với các kết quả đó, mục tiêu thi là nêu đúng giả thiết, kết luận và chứng minh hệ quả/phác thảo đúng cấp độ slide.

6 Chứng minh bổ sung từ ECDF trong Chương 1

Câu 66. Phân phối đồng thời tại nhiều điểm và giới hạn Gaussian hữu hạn chiều

Với $x_1 < \cdots < x_k$, hãy suy ra phân phối của số quan sát trong các khoảng tạo bởi x_j và hiệp phương sai của vectơ ECDF. Từ đó suy ra CLT hữu hạn chiều.

Slide: C1, trang 14–16; suy rộng trực tiếp từ Bernoulli ở trang 14.

Lời giải.

Đặt $x_0 = -\infty$, $x_{k+1} = +\infty$ và $N_j = \#\{i : x_{j-1} < X_i \le x_j\}$, $j = 1, \dots, k+1$. Mỗi X_i thuộc đúng một ô với xác suất $p_j = F(x_j) - F(x_{j-1})$. Vì các X_i độc lập,

$$(N_1, \dots, N_{k+1}) \sim \text{Multinomial}(n; p_1, \dots, p_{k+1}), \qquad \widehat{F}_n(x_j) = \frac{N_1 + \cdots + N_j}{n}.$$

Do đó $\mathbb{E}\widehat{F}_n(x_j) = F(x_j)$; với $j \le \ell$, tính trực tiếp

$$\text{Cov}(\widehat{F}_n(x_j), \widehat{F}_n(x_\ell)) = \frac{F(x_j)\{1 - F(x_\ell)\}}{n}.$$

Viết $V_i = (\mathbf{1}_{X_i \le x_1}, \dots, \mathbf{1}_{X_i \le x_k})$. Các vectơ V_i i.i.d. và bị chặn; CLT nhiều chiều cho

$$\sqrt{n}\big(\widehat{F}_n(x_j) - F(x_j)\big)_{j=1}^{k} \Rightarrow N_k(0, \Sigma), \quad \Sigma_{j\ell} = F(\min\{x_j, x_\ell\}) - F(x_j)F(x_\ell).$$

Đây là kết luận tại *hữu hạn* điểm; muốn lấy supremum trên mọi x cần thêm định lý hội tụ quá trình thực nghiệm.

Câu 67. Chứng minh phép biến đổi xác suất tích lũy $F(X)$ là đều

Giả sử F liên tục. Chứng minh $F(X) \sim \text{Unif}(0, 1)$, kể cả khi F có đoạn hằng.

Slide: C1, trang 8–9.

Lời giải.

Lấy $U \sim \text{Unif}(0, 1)$ và $Q(u) = \inf\{x : F(x) \ge u\}$. Với mọi x, tính chất nghịch đảo tổng quát cho $\{Q(U) \le x\} = \{U \le F(x)\}$ gần chắc chắn, nên

$$\mathbb{P}(Q(U) \le x) = \mathbb{P}(U \le F(x)) = F(x).$$

Vì vậy $W = Q(U)$ và X có cùng phân phối. Nếu F liên tục, tại $q = Q(u)$ có $F(q) \ge u$. Nếu $F(q) > u$, tính liên tục tại q cho một $y < q$ với $F(y) > u$, trái định nghĩa infimum. Suy ra $F(Q(u)) = u$ cho $0 < u < 1$. Bởi vậy

$$F(X) \overset{d}{=} F(W) = F(Q(U)) = U.$$

Không cần giả sử F tăng nghiêm ngặt: một đoạn hằng không làm hỏng lập luận trên.

Câu 68. Vì sao KS, CvM và AD một mẫu không phụ thuộc dạng của F_0?

Giả sử F_0 liên tục và được chỉ định hoàn toàn. Dùng $U_i = F_0(X_i)$ để biến đổi ba thống kê.

Slide: C1, trang 36–40; hệ quả từ trang 8.

Lời giải.

Dưới $H_0 : F = F_0$, với F_0 liên tục, đặt $U_i = F_0(X_i)$. Theo câu trước, U_i i.i.d. $\text{Unif}(0, 1)$. Gọi $G_n(u) = n^{-1} \sum_i \mathbf{1}_{U_i \le u}$. Biến đổi $u = F_0(x)$ cho các thống kê trên slide:

$$T_{\text{KS}} = \sqrt{n} \sup_{0 \le u \le 1} |G_n(u) - u|,$$

$$T_{\text{CvM}} = n \int_0^1 [G_n(u) - u]^2 \, du,$$

$$T_{\text{AD}} = n \int_0^1 \frac{[G_n(u) - u]^2}{u(1-u)} \, du.$$

Các biểu thức bên phải chỉ phụ thuộc vào mẫu đều, nên phân phối dưới H_0 không phụ thuộc hình dạng F_0. Điều này áp dụng khi F_0 *được chỉ định hoàn toàn*; nếu tham số của F_0 được ước lượng từ chính mẫu, U_i sau khi thế tham số không còn là mẫu đều độc lập.

Câu 69. Tự tính tích phân và chứng minh công thức tổng của CvM

Chứng minh $n\int(\widehat{F}_n - F_0)^2\,dF_0 = 1/(12n) + \sum_{i=1}^{n}[U_{(i)} - (2i-1)/(2n)]^2$ khi F_0 liên tục.

Slide: C1, trang 39.

Lời giải.

Viết $u_i = U_{(i)}$, $u_0 = 0$, $u_{n+1} = 1$ và $c_i = i/n$. Trên $[u_i, u_{i+1})$, $G_n(u) = c_i$. Khai triển tích phân:

$$T_{\text{CvM}} = n\sum_{i=0}^{n}\int_{u_i}^{u_{i+1}}(c_i - u)^2 du = \frac{n}{3} + n\sum_{i=0}^{n} c_i^2(u_{i+1} - u_i) - n\sum_{i=0}^{n} c_i(u_{i+1}^2 - u_i^2).$$

Hai tổng cuối lần lượt rút gọn bằng phép chuyển chỉ số:

$$n\sum_{i=0}^{n} c_i^2(u_{i+1} - u_i) = n - \frac{1}{n}\sum_{i=1}^{n}(2i-1)u_i,$$
$$n\sum_{i=0}^{n} c_i(u_{i+1}^2 - u_i^2) = n - \sum_{i=1}^{n} u_i^2.$$

Thế vào và hoàn thành bình phương:

$$T_{\text{CvM}} = \sum_{i=1}^{n} u_i^2 - \frac{1}{n}\sum_{i=1}^{n}(2i-1)u_i + \frac{n}{3} = \sum_{i=1}^{n}\left(u_i - \frac{2i-1}{2n}\right)^2 + \frac{1}{12n}.$$

Đẳng thức cuối dùng $\sum_{i=1}^{n}(2i-1)^2 = n(4n^2-1)/3$.

Câu 70. Tự tính tích phân và chứng minh công thức log của Anderson–Darling

Chứng minh dạng tổng của $n\int(\widehat{F}_n - F_0)^2/[F_0(1-F_0)]\,dF_0$ bằng cách phân tích phân thức trên từng khoảng giữa các $U_{(i)}$.

Slide: C1, trang 40.

Lời giải.

Vẫn viết $u_i = U_{(i)}$, $u_0 = 0$, $u_{n+1} = 1$, $c_i = i/n$. Phân tích phân thức ngay trên khoảng thứ i:

$$\frac{(c_i - u)^2}{u(1-u)} = \frac{c_i^2}{u} + \frac{(1-c_i)^2}{1-u} - 1.$$

Nguyên hàm là $c_i^2\log u - (1-c_i)^2\log(1-u) - u$. Hạng $-u$ cộng trên các khoảng cho $-n$. Tại điểm trong u_i, hệ số của $\log u_i$ sau khi cộng khoảng bên trái và bên phải là

$$n(c_{i-1}^2 - c_i^2) = -\frac{2i-1}{n}.$$

Tương tự, hệ số của $\log(1-u_i)$ là

$$n\{(1-c_i)^2 - (1-c_{i-1})^2\} = -\frac{2(n-i)+1}{n}.$$

Ở biên 0 và 1, hệ số log tương ứng bằng 0. Đổi chỉ số $i \mapsto n+1-i$ trong tổng log thứ hai:

$$\boxed{T_{\text{AD}} = -n - \frac{1}{n}\sum_{i=1}^{n}(2i-1)\big[\log u_i + \log(1-u_{n+1-i})\big].}$$

Dưới giả thiết F_0 liên tục, $0 < u_i < 1$ gần chắc chắn, nên các log xác định.

Câu 71. Chứng minh phân vị mẫu nhất quán từ Glivenko–Cantelli

Đặt $q = F^{-1}(p)$ và $\widehat{q}_n = \widehat{F}_n^{-1}(p)$. Phát biểu điều kiện tại q để $\widehat{q}_n \to q$ gần chắc chắn và chứng minh bằng hai điểm $q - \varepsilon, q + \varepsilon$.

Slide: C1, trang 16–17, 31, 35.

Lời giải.

Giả sử $p \in (0,1)$, $q = F^{-1}(p)$ là hữu hạn và với mọi $\varepsilon > 0$ đủ nhỏ,

$$F(q-\varepsilon) < p < F(q+\varepsilon).$$

Đặt $\delta_- = p - F(q-\varepsilon) > 0$ và $\delta_+ = F(q+\varepsilon) - p > 0$. Trên biến cố Glivenko–Cantelli có xác suất 1, với n đủ lớn, $\|\widehat{F}_n - F\|_\infty < \min(\delta_-, \delta_+)$. Vì vậy

$$\widehat{F}_n(q-\varepsilon) < p < \widehat{F}_n(q+\varepsilon).$$

Theo định nghĩa nghịch đảo tổng quát, $q - \varepsilon < \widehat{F}_n^{-1}(p) \le q + \varepsilon$. Lấy một dãy $\varepsilon \downarrow 0$ đếm được và giao các biến cố xác suất 1, suy ra $\boxed{\widehat{F}_n^{-1}(p) \to q \quad \text{gần chắc chắn.}}$ Điều kiện hai phía loại trường hợp F nằm ngang ở mức p; khi đó hội tụ đều của CDF một mình chưa đủ để xác định phân vị duy nhất.

Câu 72. Từ DKW suy ra cận kỳ vọng của sai số đều

Với $Z_n = \sup_x |\widehat{F}_n(x) - F(x)|$, chứng minh $\mathbb{E}Z_n \le \sqrt{\pi/(2n)}$ bằng công thức tích phân đuôi.

Slide: C1, trang 18; hệ quả trực tiếp của DKW.

Lời giải.

Vì $Z_n \ge 0$, công thức tích phân đuôi cho $\mathbb{E}Z_n = \int_0^\infty \mathbb{P}(Z_n > t)\,dt$. Thế cận DKW rồi mở rộng miền tích phân:

$$\begin{aligned}\mathbb{E}Z_n &\le \int_0^\infty 2e^{-2nt^2}\,dt \\ &= 2 \cdot \frac{1}{2}\sqrt{\frac{\pi}{2n}} = \boxed{\sqrt{\frac{\pi}{2n}}}.\end{aligned}$$

Cận này suy từ DKW, không phải phát biểu riêng trên slide.

Câu 73. Đảo băng DKW thành khoảng tin cậy cho phân vị

Nếu $L \le F \le U$ đồng thời, chứng minh $U^{-1}(p) \le F^{-1}(p) \le L^{-1}(p)$ khi các nghịch đảo hữu hạn; áp dụng với băng DKW và nêu điều kiện biên.

Slide: C1, trang 8, 19, 35; hệ quả trực tiếp.

Lời giải.

Với một hàm CDF G, viết $G^{-1}(p) = \inf\{x : G(x) \ge p\}$. Nếu $L(x) \le F(x) \le U(x)$ với mọi x, thì

$$\{x : L(x) \ge p\} \subseteq \{x : F(x) \ge p\} \subseteq \{x : U(x) \ge p\}.$$

Lấy infimum, thứ tự đảo chiều: $U^{-1}(p) \le F^{-1}(p) \le L^{-1}(p)$. Với băng DKW có nửa độ rộng ε, nếu $\varepsilon < p < 1 - \varepsilon$ thì

$$U^{-1}(p) = \widehat{F}_n^{-1}(p - \varepsilon), \qquad L^{-1}(p) = \widehat{F}_n^{-1}(p + \varepsilon).$$

Do đó, với xác suất ít nhất $1 - \alpha$,

$$\boxed{\widehat{F}_n^{-1}(p - \varepsilon_{n,\alpha}) \le F^{-1}(p) \le \widehat{F}_n^{-1}(p + \varepsilon_{n,\alpha}).}$$

Nếu $p \le \varepsilon$ hoặc $p \ge 1 - \varepsilon$, một đầu khoảng có thể vô hạn; không được dùng công thức phân vị mẫu ngoài mức $(0,1)$.

Câu 74. Vì sao phương sai plug-in chia cho n và có bias?

Tính kỳ vọng của $n^{-1}\sum_i (X_i - \bar{X})^2$ khi X_i có phương sai $\sigma^2 < \infty$.

Slide: C1, trang 30, 33–34; tính chất suy ra từ công thức trên slide.

Lời giải.

Đặt $\widehat{\sigma}_n^2 = n^{-1}\sum_i (X_i - \bar{X})^2$. Đẳng thức đại số cho

$$\sum_i (X_i - \bar{X})^2 = \sum_i (X_i - \mu)^2 - n(\bar{X} - \mu)^2.$$

Lấy kỳ vọng, dùng $\mathbb{E}(X_i - \mu)^2 = \sigma^2$ và $\mathbb{E}(\bar{X} - \mu)^2 = \mathrm{Var}(\bar{X}) = \sigma^2/n$:

$$\mathbb{E}\widehat{\sigma}_n^2 = \frac{1}{n}\{n\sigma^2 - n(\sigma^2/n)\} = \frac{n-1}{n}\sigma^2.$$

Vậy bias là $-\sigma^2/n$. Nhân với $n/(n-1)$ cho ước lượng không chệch khi $n > 1$; phép hiệu chỉnh đó không còn là plug-in trực tiếp của phiếm hàm phương sai.

Câu 75. Vì sao hội tụ đều của CDF chưa đủ cho mọi phiếm hàm plug-in?

Cho một dãy CDF hội tụ đều về F nhưng trung bình không hội tụ. Từ đó nêu đúng điều kiện liên tục cần dùng trong nguyên lý thế.

Slide: C1, trang 17, 28–31; kiểm tra giả thiết của mệnh đề trên slide.

Lời giải.

Đặt $F = \delta_0$ và, với $M \geq 2$, $G_M = (1 - M^{-1})\delta_0 + M^{-1}\delta_{M^2}$. Trên $0 \leq x < M^2$ có $F(x) = 1$ và $G_M(x) = 1 - M^{-1}$; ngoài miền đó hai CDF bằng nhau. Bởi vậy

$$\|G_M - F\|_\infty = \frac{1}{M} \longrightarrow 0.$$

Nhưng trung bình của F là 0 còn

$$\int x\, dG_M(x) = \frac{1}{M}M^2 = M \longrightarrow \infty.$$

Vậy phiếm hàm trung bình không liên tục theo chuẩn sup tại F trên lớp mọi phân phối có trung bình hữu hạn. Mệnh đề plug-in dùng trực tiếp Glivenko–Cantelli cần T liên tục theo chuẩn sup tại F; với trung bình, có thể dùng luật số lớn và giả thiết $\mathbb{E}|X| < \infty$ để chứng minh nhất quán theo cách khác.

7 Bổ sung chứng minh và bài tập từ slide ước lượng chiếu

Câu 76. Tính rủi ro chính xác cho cơ sở lượng giác và histogram

Dùng tính chất $\sum_{j=1}^{D} \phi_j(x)^2 = D$ để viết rủi ro thành biểu thức chính xác.

Slide: C2P, trang 5–6, 13–15.

Lời giải.

Câu 25 cho đẳng thức rủi ro

$$\mathbb{E}\|\widehat{f}_D - f\|_2^2 = \|f - f_D\|_2^2 + \frac{1}{n}\left\{\mathbb{E}\sum_{j=1}^{D}\phi_j(X)^2 - \sum_{j=1}^{D} a_j^2\right\}.$$

Cả cơ sở lượng giác ở slide 5 lẫn histogram đều ô ở slide 6 đều thỏa $\sum_j \phi_j(x)^2 = D$. Theo Parseval, $\sum_j a_j^2 = \|f_D\|_2^2$. Vậy trong hai trường hợp này,

$$\boxed{\mathbb{E}\|\widehat{f}_D - f\|_2^2 = \|f - f_D\|_2^2 + \frac{D - \|f_D\|_2^2}{n}.}$$

Đây là phép tính chính xác hơn cận $\Phi D/n$ ở slide 14 vì giữ lại phần $-\|f_D\|_2^2/n$.

Câu 77. Chứng minh cận chuẩn vô cùng của cơ sở Legendre từng ô

Với d ô, đa thức đến bậc r và $D = d(r+1)$, chứng minh $\|t\|_\infty \le \sqrt{r+1}\sqrt{D}\|t\|_2$ từ các hàm cơ sở trên slide.

Slide: C2P, trang 7–8.

Lời giải.

Trên ô thứ j, slide đặt

$$\phi_{j,k}(x) = \sqrt{2d}\, Q_k(2dx - 2j + 1), \qquad k = 0, \dots, r.$$

Viết $Q_k(u) = \sqrt{(2k+1)/2}\, P_k(u)$ với P_k là đa thức Legendre chuẩn thông thường. Dùng tính chất cơ bản $|P_k(u)| \le 1$ trên $[-1, 1]$:

$$\sum_{k=0}^{r} \phi_{j,k}(x)^2 \le 2d \sum_{k=0}^{r} \frac{2k+1}{2} = d(r+1)^2 = (r+1)D.$$

Tại mỗi x, chỉ một ô đóng góp. Với $t = \sum_{j,k} b_{j,k}\phi_{j,k}$, Cauchy–Schwarz và trực chuẩn cho

$$|t(x)|^2 \le \left(\sum_{j,k} b_{j,k}^2\right)\left(\sum_{j,k} \phi_{j,k}(x)^2\right) \le \|t\|_2^2 (r+1)D.$$

Lấy căn và supremum:

$$\boxed{\|t\|_\infty \le \sqrt{r+1}\sqrt{D}\|t\|_2.}$$

Đây là hằng số Φ_0 của mệnh đề ở slide 7; phép chặn dùng thêm tính chất chuẩn của đa thức Legendre.

Câu 78. Vì sao các không gian histogram đều ô không lồng nhau khi tăng D?

So sánh $D = 2$ và $D = 3$; đối chiếu với tính lồng nhau của cơ sở lượng giác.

Slide: C2P, trang 5–6, 8, 22.

Lời giải.

Với $D = 2$, hàm $h(x) = \mathbf{1}_{[0,1/2)}(x)$ thuộc không gian histogram S_2: nó hằng trên mỗi nửa khoảng. Với $D = 3$, ô giữa là $[1/3, 2/3)$, cắt qua $1/2$. Trên ô này $h = 1$ ở $[1/3, 1/2)$ nhưng $h = 0$ ở $[1/2, 2/3)$; vì thế $h \notin S_3$. Vậy $S_2 \not\subset S_3$. Ngược lại, $\mathbf{1}_{[0,1/3)} \in S_3$ nhưng không hằng trên ô $[0, 1/2)$ của S_2, nên $S_3 \not\subset S_2$. Với cơ sở lượng giác, S_D được tạo bởi D hàm đầu tiên của cùng một dãy, nên $S_D \subset S_{D+1}$. Do đó phép cập nhật hệ số ở trang 22 chỉ áp dụng trực tiếp cho không gian lồng nhau.

Câu 79. Kiểm tra dấu của hạng quá trình thực nghiệm trong phác thảo oracle

Từ định nghĩa $\gamma_n(t) = \|t\|_2^2 - 2P_n t$ và $\nu_n(t) = (P_n - P)t$, tự khai triển $\gamma_n(t) - \gamma_n(s)$; chỉ ra dấu đúng trong công thức trên slide 24.

Slide: C2P, trang 12, 23–24.

Lời giải.

Từ $Pt = \int tf = \langle t, f\rangle$ và $P_n t = Pt + \nu_n(t)$,

$$\begin{aligned}\gamma_n(t) &= \|t\|_2^2 - 2Pt - 2\nu_n(t)\\ &= \|t - f\|_2^2 - \|f\|_2^2 - 2\nu_n(t).\end{aligned}$$

Trừ cùng đẳng thức viết cho s:

$$\boxed{\gamma_n(t) - \gamma_n(s) = \|t - f\|_2^2 - \|s - f\|_2^2 - 2\nu_n(t - s).}$$

Slide 24 in dấu $+2\nu_n(t-s)$, trong khi định nghĩa $\nu_n = (P_n - P)$ của chính slide cho dấu trừ. Đặt $t = \widehat{f}_{\widehat{D}}$ và $s = f_D$ trong bất đẳng thức chọn mô hình, chuyển $-2\nu_n$ sang vế phải sẽ được $+2\nu_n(\widehat{f}_{\widehat{D}} - f_D)$, đúng như câu 32. Đây là bước đại số; bước tập trung để hoàn tất oracle chỉ được phác thảo trên slide.

8 Bài tập và chứng minh bổ sung từ slide hồi quy và kiểm định

Câu 80. Bài tập dấu cho dữ liệu cặp trước–sau trên slide

Từ 12 hiệu số cân nặng ở C5 trang 12, bỏ hiệu bằng 0, tính S^+ và p một phía cho $H_1 : m_D < 0$, rồi kết luận ở mức 5%.

Slide: C5, trang 12–13.

Lời giải.

Tính $D_i = \text{sau} - \text{trước}$ từ hai hàng số liệu trang 12 (tách bảng làm hai nửa để dễ kiểm):

i	1	2	3	4	5	6
Trước	85	90	78	92	88	75
Sau	82	88	79	87	85	74
D_i	-3	-2	1	-5	-3	-1

i	7	8	9	10	11	12
Trước	82	95	80	87	91	83
Sau	80	92	80	84	89	81
D_i	-2	-3	0	-3	-2	-2

Ghép lại, hiệu trên slide là

$$(-3, -2, 1, -5, -3, -1, -2, -3, 0, -3, -2, -2).$$

Bỏ hiệu thứ 9 bằng 0, còn $n = 11$ dấu: $S^+ = 1$ và $S^- = 10$. Dưới H_0 cùng giả thiết hai phía quanh 0 cân bằng, $B \sim \text{Bin}(11, 1/2)$. Với $H_1 : m_D < 0$, dùng đuôi trái:

$$p = \mathbb{P}(B \le 1) = \binom{11}{0} 2^{-11} + \binom{11}{1} 2^{-11} = \frac{12}{2048} \approx \boxed{0.00586}.$$

Vì $p < 0.05$, bác bỏ H_0; dữ liệu ủng hộ trung vị hiệu cân nặng âm. Việc bỏ hiệu 0 chỉ giữ phân phối nhị thức $1/2$ nếu dưới H_0 hai xác suất dấu dương và âm bằng nhau sau khi điều kiện trên hiệu khác 0.

Câu 81. Bài tập 4: suy ra trọng số local linear từ hệ chuẩn 2×2

Từ S_k, T_k của C3 trang 35, biến đổi nghiệm $\widehat{r}_{LL}(x)$ thành trung bình có trọng số $w_i = K_h(X_i - x)[S_2 - (X_i - x)S_1]$ và kiểm tra tổng trọng số.

Slide: C3, trang 32–35, 49.

Lời giải.

Đặt $u_i = X_i - x$, $k_i = K_h(u_i)$. Hệ chuẩn 2×2 của slide là

$$\begin{pmatrix} S_0 & S_1 \\ S_1 & S_2 \end{pmatrix} \begin{pmatrix} \widehat{a} \\ \widehat{b} \end{pmatrix} = \begin{pmatrix} T_0 \\ T_1 \end{pmatrix}, \quad S_j = \sum_i k_i u_i^j, \quad T_j = \sum_i k_i u_i^j Y_i.$$

Nếu $\Delta = S_0 S_2 - S_1^2 > 0$, công thức nghịch đảo ma trận cho

$$\widehat{r}_{LL}(x) = \widehat{a} = \frac{S_2 T_0 - S_1 T_1}{\Delta} = \frac{\sum_i k_i (S_2 - u_i S_1) Y_i}{\Delta}.$$

Đặt $w_i = k_i(S_2 - u_i S_1)$; tổng của chúng là

$$\sum_i w_i = S_2 \sum_i k_i - S_1 \sum_i k_i u_i = S_2 S_0 - S_1^2 = \Delta.$$

Vậy $\widehat{r}_{LL}(x) = \sum_i w_i Y_i / \sum_i w_i$. Các w_i có thể âm dù kernel K không âm; đó là lý do local linear có thể hiệu chỉnh bias ở biên.

Câu 82. Chứng minh local linear khử hạng bias bậc một tại điểm nội và biên

Dùng hai moment rời rạc $\sum_i \ell_i = 1$ và $\sum_i \ell_i(X_i - x) = 0$ để khai triển bias có điều kiện theo thiết kế; nêu điều kiện cần cho bậc $O(h^2)$.

Slide: C3, trang 36–40, 46–47.

Lời giải.

Viết $u_i = X_i - x$ và $\widehat{r}_{LL}(x) = \sum_i \ell_i(x) Y_i$. Điều kiện theo thiết kế X, dùng $\mathbb{E}(Y_i \mid X) = r(X_i)$:

$$\mathbb{E}(\widehat{r}_{LL}(x) \mid X) - r(x) = \sum_i \ell_i(x)[r(X_i) - r(x)].$$

Khai triển Taylor quanh x:

$$r(X_i) - r(x) = r'(x)u_i + \tfrac{1}{2} r''(x) u_i^2 + o(u_i^2).$$

Moment rời rạc trang 36 cho $\sum_i \ell_i = 1$ và $\sum_i \ell_i u_i = 0$. Do đó

$$\boxed{\mathbb{E}(\widehat{r}_{LL}(x) \mid X) - r(x) = \tfrac{1}{2} r''(x) \sum_i \ell_i u_i^2 + \sum_i \ell_i o(u_i^2).}$$

Nếu r'' liên tục và các trọng số hữu hiệu tập trung ở $|u_i| = O(h)$ với $\sum_i |\ell_i| = O(1)$, cả hai hạng còn lại có bậc $O(h^2)$. Lập luận moment vẫn đúng ở biên, nên không còn hạng bias bậc h. Hằng số trước h^2 ở biên có thể khác $\mu_2(K)/2$ do kernel tương đương một phía; khẳng định đúng từ slide là *bậc* $O(h^2)$.

Câu 83. Chứng minh các moment của equivalent kernel

Từ $K_\ell^*(u) = e_0^\top S^{-1}(1, u, \ldots, u^\ell)^\top K(u)$, chứng minh $\int u^k K_\ell^*(u)du = \delta_{0k}$ cho $0 \le k \le \ell$.

Slide: C3, trang 41–43.

Lời giải.

Đặt $v(u) = (1, u, \ldots, u^\ell)^\top$ và $S = \int v(u)v(u)^\top K(u)du$ khả nghịch. Khi $0 \le k \le \ell$, vectơ $\int v(u)u^k K(u)du$ là cột thứ k của S, tức Se_k. Bởi vậy

$$\begin{aligned}\int u^k K_\ell^*(u)du &= e_0^\top S^{-1} \int v(u)u^k K(u)du \\ &= e_0^\top S^{-1} S e_k = \boxed{\delta_{0k}}.\end{aligned}$$

Riêng $k = 0$ cho tích phân 1; $k = 1, \ldots, \ell$ cho các moment bằng 0. Với $\ell = 1$ và kernel đối xứng ở điểm nội, S là ma trận chéo có $S_{00} = 1$, nên $K_1^*(u) = K(u)$. Ở biên miền tích phân hiệu dụng bị cắt và kernel tương đương thay đổi.

Câu 84. Bài tập 7: tính CV, GCV và so sánh NW với local linear trên mcycle

Dùng dữ liệu `MASS::mcycle` của slide; chọn băng thông trên lưới $0.5, 0.75, \ldots, 15$ bằng CV và GCV cho từng estimator, rồi xem đồ thị ở biên.

Slide: C3, trang 8–10, 24–25, 44–50.

Lời giải.

Chạy mã R đi kèm trên `MASS::mcycle` ($n = 133$):

Dùng $h \in \{0.5, 0.75, \dots, 15\}$. Với từng h, ma trận làm trơn $W(h)$ cho

$$\mathrm{CV}(h) = \frac{1}{n}\sum_{i}\left[\frac{Y_i - (WY)_i}{1 - W_{ii}}\right]^2, \qquad \mathrm{GCV}(h) = \frac{n^{-1}\sum_i [Y_i - (WY)_i]^2}{[1 - \mathrm{tr}(W)/n]^2}.$$

Để thấy một hạng của CV được tính ra sao, xét hàng đầu tiên trên dữ liệu: $X_1 = 2.4$, $Y_1 = 0$. Với NW và $h = 1.0$, tổng trọng số Gaussian là $\sum_j k_j = 1.38515946$, tổng có đáp ứng là $\sum_j k_j Y_j = -1.59098933$. Do đó

$$\widehat{r}_1 = \frac{-1.59098933}{1.38515946} \approx -1.14860, \quad W_{11} = \frac{K(0)}{1.38515946} \approx 0.288012.$$

Khi bỏ đúng hàng thứ nhất,

$$\widehat{r}^{(-1)}(X_1) = \frac{\widehat{r}_1 - W_{11}Y_1}{1 - W_{11}} \approx -1.61322, \quad [Y_1 - \widehat{r}^{(-1)}(X_1)]^2 \approx 2.60249.$$

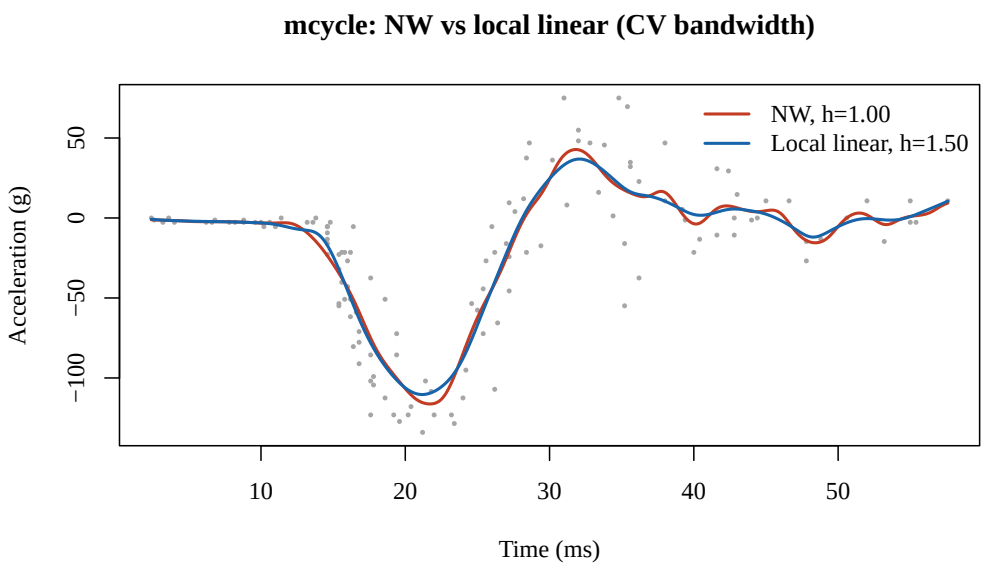
Với local linear và $h = 1.5$, các moment tại X_1 là

$$(S_0, S_1, S_2) \approx (1.68633, 1.18842, 1.73899), \quad (T_0, T_1) \approx (-2.13258, -2.12576).$$

Tử $S_2T_0 - S_1T_1 \approx -1.18224$, mẫu $S_0S_2 - S_1^2 \approx 1.52017$, nên $\widehat{r}_1 \approx -0.77770$. Tính $W_{11} \approx 0.456368$ rồi dùng công thức leave-one-out cho $\widehat{r}^{(-1)}(X_1) \approx -1.43057$, bình phương phần dư ≈ 2.04652. CV là trung bình của 133 hạng như vậy. Kết quả từ dữ liệu slide và lưới băng thông đã ghi:

Phương pháp	h_{CV}	min CV	h_{GCV}	min GCV
NW	1.00	597.06	1.00	650.95
Local linear	1.50	561.40	1.50	600.11

Mỗi tiêu chuẩn chỉ so sánh các băng thông *cùng* phương pháp. Đồ thị dưới đây cho các đường khớp với băng thông chọn bằng CV:



Mã slide 28 bỏ mọi quan sát có $X_j = X_i$; nếu có thời gian trùng, điều đó bỏ nhiều hàng thay vì đúng một hàng. Công thức ma trận trên chỉ bỏ quan sát thứ i, đúng với leave-one-out.

Câu 85. Chứng minh chuẩn tiệm cận của W^+ bằng định lý Lyapunov

Từ biểu diễn gán dấu $W^+ = \sum_{j=1}^{n} jB_j$ ở slide, kiểm tra điều kiện Lyapunov rồi suy ra CLT khi không có hạng trùng.

Slide: C5, trang 16–18.

Lời giải.

Dưới đối xứng liên tục, B_j độc lập Bernoulli(1/2) và $W^+ = \sum_{j=1}^{n} jB_j$. Đặt $Z_j = j(B_j - 1/2)$; khi đó $\mathbb{E}Z_j = 0$, $\operatorname{Var} Z_j = j^2/4$ và $\mathbb{E}|Z_j|^3 = j^3/8$. Tổng phương sai $s_n^2 = \frac{1}{4}\sum_{j=1}^{n} j^2 \asymp n^3$, nên $s_n^3 \asymp n^{9/2}$. Mặt khác $\sum_j \mathbb{E}|Z_j|^3 = \frac{1}{8}\sum_j j^3 = O(n^4)$. Vì vậy tỷ số Lyapunov bậc 3 là

$$\frac{\sum_j \mathbb{E}|Z_j|^3}{s_n^3} = O(n^{-1/2}) \longrightarrow 0.$$

Định lý CLT Lyapunov cho

$$\boxed{\frac{W^+ - n(n+1)/4}{\sqrt{n(n+1)(2n+1)/24}} \Rightarrow N(0,1).}$$

Đây là chứng minh hệ quả chuẩn tiệm cận phát biểu ở trang 17, dưới giả thiết không có hạng trùng.

Câu 86. Kiểm tra p chính xác của ví dụ Spearman và Kendall trên slide

Với vector hạng ở C5 trang 32 và dãy điểm theo X ở trang 35, đếm các hoán vị cực đoan; so sánh với các p và ngưỡng được in trên slide.

Slide: C5, trang 32–36, 43.

Lời giải.

Ví dụ Spearman có $n = 8$ và $\sum_i (R_i - S_i)^2 = 4$, nên $\rho_S = 20/21$. Dưới H_0 độc lập với biên liên tục, mọi hoán vị của hạng $1, \ldots, 8$ đều xác suất $1/8!$. Điều kiện $\rho_S \geq 20/21$ tương đương $\sum_i (i - \pi(i))^2 \leq 4$. Có 1 hoán vị đồng nhất (tổng 0), 7 phép đổi chỗ hai hạng kề nhau (tổng 2), và $\binom{7}{2} - 6 = 15$ cách đổi hai cặp kề nhau rời nhau (tổng 4). Không còn dạng khác với tổng không quá 4. Vậy một đuôi có $1 + 7 + 15 = 23$ hoán vị; đối xứng cho hai đuôi 46 hoán vị:

$$\boxed{p_{\text{Spearman}} = \frac{46}{8!} \approx 0.001141.}$$

Slide 33 ghi 0.0003, không khớp phép đếm chính xác. Slide 33 ghi ngưỡng 0.714 cho $n = 8$, còn phụ lục trang 43 ghi 0.738; cả hai đều nhỏ hơn 20/21, nên quyết định bác bỏ ở 5% không đổi. Với Kendall, xếp theo X thì dãy Y ở slide 35 là $(4, 5.5, 5, 6, 7.5, 8.5, 8, 9)$. Chỉ có hai cặp nghịch hành: $(5.5, 5)$ và $(8.5, 8)$. Do đó $n_d = 2$, $n_c = 28 - 2 = 26$ và $\tau = 6/7$. Số hoán vị 8 phần tử có 0, 1, 2 nghịch thế lần lượt là $1, 7, 27$; hai phía có $2(1 + 7 + 27) = 70$ hoán vị.

$$\boxed{p_{\text{Kendall}} = \frac{70}{8!} \approx 0.001736,}$$

khớp 0.0017 làm tròn trên slide 36.

Câu 87. Hệ số local polynomial ước lượng các đạo hàm như thế nào?

Đối chiếu cơ sở Taylor chuẩn hóa $V_\ell(z) = (1, z, z^2/2!, \ldots)$ ở trang 30 với cơ sở đơn thức thô ở trang 32; xác định đúng hệ số ước lượng $r^{(k)}(x)$.

Slide: C3, trang 29–32, 42.

Lời giải.

Taylor tại x cho

$$r(x + hz) = \sum_{k=0}^{\ell} \frac{r^{(k)}(x) h^k}{k!} z^k + R_\ell.$$

Nếu dùng cơ sở trang 30 $V_\ell(z) = (1, z, z^2/2!, \dots, z^\ell/\ell!)^\top$, thì tích vô hướng $\theta^\top V_\ell(z)$ khớp Taylor khi

$$\boxed{\theta_k = r^{(k)}(x)h^k, \qquad r^{(k)}(x) = \theta_k/h^k} \quad (k = 0, \dots, \ell).$$

Nếu đổi sang đơn thức thô $(X_i - x)^k$ như trang 32, hệ số tương ứng là $\beta_k = r^{(k)}(x)/k!$, nên $r^{(k)}(x) = k!\beta_k$. Hai tham số hóa cho cùng hệ số hằng $r(x)$. Trang 42 viết thêm $/k!$ trong công thức cho θ_k dù trang 30 đã đặt $1/k!$ vào V_ℓ; không được chia factorial hai lần.

Câu 88. Từ bias h^β và variance $(nh)^{-1}$ suy ra tốc độ local polynomial

Tối ưu cận MSE ở C3 trang 42–43 theo h và nêu rõ đây là cận trên; khi nào được gọi là minimax tối ưu?

Slide: C3, trang 42–43.

Lời giải.

Từ cận ở trang 42, đặt $M(h) = Ah^{2\beta} + B/(nh)$ với $A, B > 0$. Đạo hàm theo h:

$$M'(h) = 2\beta A h^{2\beta-1} - \frac{B}{nh^2}.$$

Giải $M'(h) = 0$:

$$\boxed{h_*^{2\beta+1} = \frac{B}{2\beta A n}, \qquad h_* \asymp n^{-1/(2\beta+1)}.}$$

Thế lại, hai hạng bias bình phương và phương sai đều có bậc $n^{-2\beta/(2\beta+1)}$, nên

$$\boxed{\mathrm{MSE}(h_*) = O\left(n^{-2\beta/(2\beta+1)}\right).}$$

Đây là *cận trên* chứng minh bằng tối ưu hóa. Slide 43 gọi tốc độ minimax tối ưu; để chứng minh chữ "minimax" còn cần cận dưới cho mọi estimator, không được suy ra chỉ từ đạo hàm trên.

Câu 89. Xấp xỉ chuẩn và hiệu chỉnh liên tục cho kiểm định dấu, Wilcoxon, Mann–Whitney

Viết các trung bình, phương sai dưới H_0 từ slide và chỉ rõ cách chọn dấu 0.5 khi tính đuôi trái hoặc phải.

Slide: C5, trang 8–9, 17–18, 25, 40–42.

Lời giải.

Ba thống kê nguyên trên slide có các tham số dưới H_0:

T	μ_0	σ_0^2
S^+	$n/2$	$n/4$
W^+	$n(n+1)/4$	$n(n+1)(2n+1)/24$
U	$nm/2$	$nm(n+m+1)/12$

Với một thống kê nguyên T, xấp xỉ chuẩn có hiệu chỉnh liên tục cho hai đuôi là

$$\mathbb{P}_0(T \le t) \approx \Phi\left(\frac{t + 0.5 - \mu_0}{\sigma_0}\right), \qquad \mathbb{P}_0(T \ge t) \approx 1 - \Phi\left(\frac{t - 0.5 - \mu_0}{\sigma_0}\right).$$

Với kiểm định hai phía đối xứng, đặt $d = |t - \mu_0|$ và lấy

$$p \approx 2\left[1 - \Phi\left(\frac{d - 0.5}{\sigma_0}\right)\right],$$

cắt về $[0, 1]$ nếu cần. Công thức trang 9 cho kiểm định dấu chính là chuẩn hóa này. Trang 18 ghi -0.5 trong Z của W^+; dấu ấy phù hợp với *đuôi phải*; đuôi trái dùng $+0.5$ theo công thức đầu. Với mẫu nhỏ, ưu tiên phân phối nhị thức hoặc hoán vị chính xác trên slide.

9 Ví dụ trên slide: giải từng phép tính

Câu 90. Ví dụ ECDF trên hình ở Chương 1

Với năm quan sát $(1, 1.2, 1.5, 2, 2.5)$ trên C1 trang 12, viết toàn bộ hàm bậc thang, kiểm tra giá trị ngay trước/sau từng điểm nhảy và tính xác suất thực nghiệm của $(1.2, 2]$.

Slide: C1, trang 11–12.

Lời giải.

Sắp mẫu theo thứ tự đã cho: $1 < 1.2 < 1.5 < 2 < 2.5$, nên $n = 5$ và mỗi quan sát đóng góp $1/5$ vào ECDF khi x đi qua nó. Đếm số quan sát không vượt quá x trên từng khoảng:

$$\widehat{F}_n(x) = \begin{cases} 0, & x < 1, \\ 1/5, & 1 \le x < 1.2, \\ 2/5, & 1.2 \le x < 1.5, \\ 3/5, & 1.5 \le x < 2, \\ 4/5, & 2 \le x < 2.5, \\ 1, & x \ge 2.5. \end{cases}$$

Chẳng hạn $\widehat{F}_n(1.5-) = 2/5$, $\widehat{F}_n(1.5) = 3/5$, nên bước nhảy tại 1.5 là $1/5$; các điểm còn lại cũng có bước nhảy $1/5$ vì mẫu không trùng. Khoảng $(1.2, 2]$ chứa 1.5 và 2, do đó

$$\boxed{\widehat{P}((1.2, 2]) = \widehat{F}_n(2) - \widehat{F}_n(1.2) = 4/5 - 2/5 = 2/5.}$$

Nếu lấy $[1.2, 2]$ thì còn thêm quan sát 1.2, và phải dùng $\widehat{F}_n(2) - \widehat{F}_n(1.2-) = 3/5$.

Câu 91. Ví dụ nhị thức $X_i \sim U[0, 2]$ ở Chương 1

Với $n = 100$ và $x_0 = 0.8$, viết phân phối chính xác của $\widehat{F}_n(0.8)$, tính kỳ vọng, phương sai và độ lệch chuẩn.

Slide: C1, trang 14–15, 20.

Lời giải.

Vì $X_i \sim U[0, 2]$, với $x_0 = 0.8$ ta có

$$p = F(0.8) = \mathbb{P}(X_i \le 0.8) = \frac{0.8 - 0}{2 - 0} = 0.4.$$

Đặt $I_i = \mathbf{1}_{\{X_i \le 0.8\}}$; I_i độc lập Bernoulli(0.4) và $100\widehat{F}_n(0.8) = \sum_{i=1}^{100} I_i \sim \text{Bin}(100, 0.4)$. Với $k = 0, 1, \ldots, 100$,

$$\mathbb{P}\left(\widehat{F}_n(0.8) = \frac{k}{100}\right) = \binom{100}{k} (0.4)^k (0.6)^{100-k}.$$

Vậy

$$\mathbb{E}\widehat{F}_n(0.8) = 0.4, \quad \text{Var}\,\widehat{F}_n(0.8) = \frac{0.4(0.6)}{100} = 0.0024, \quad \text{SD}\,\widehat{F}_n(0.8) = \sqrt{0.0024} \approx 0.04899.$$

0.4 là giá trị thật $F(0.8)$; $\widehat{F}_n(0.8)$ vẫn ngẫu nhiên trước khi quan sát mẫu.

Câu 92. Ví dụ Wald và Hoeffding cùng dữ liệu $n = 100, \widehat{p} = 0.4$

Tính hai khoảng tin cậy 95% trên C1 trang 21 và 26 từng phép tính; so sánh ý nghĩa bảo đảm phủ của chúng.

Slide: C1, trang 20–27.

Lời giải.

Giả sử mẫu quan sát cho $\widehat{p} = 0.4$ với $n = 100$. Với mức tin cậy 95%, $z_{0.975} \approx 1.96$. Sai số chuẩn cắm vào của Wald là

$$\widehat{\text{se}} = \sqrt{\frac{0.4(1-0.4)}{100}} = \sqrt{0.0024} \approx 0.04899.$$

Nửa độ rộng Wald là $1.96(0.04899) \approx 0.09602$; do đó

$$\boxed{I_{\text{Wald}} = [0.4 - 0.09602,\ 0.4 + 0.09602] \approx [0.304, 0.496].}$$

Với Hoeffding, đặt $\alpha = 0.05$:

$$2e^{-2(100)\varepsilon^2} = 0.05 \iff \varepsilon = \sqrt{\frac{\log(2/0.05)}{200}} = \sqrt{\frac{\log 40}{200}} \approx 0.13581.$$

Vì vậy

$$\boxed{I_{\text{Hoeffding}} = [0.4 - 0.13581,\ 0.4 + 0.13581] \approx [0.264, 0.536].}$$

Wald hẹp hơn trong ví dụ này nhưng chỉ có độ phủ xấp xỉ tiệm cận. Hoeffding bảo đảm độ phủ ít nhất 95% ở mọi cỡ mẫu cho một x_0 cố định. Slide 21 viết $\widehat{p} = F(0.8) = 0.4$; đúng hơn là $F(0.8) = 0.4$ trong mô hình và $\widehat{p} = 0.4$ chỉ khi mẫu quan sát cho tần suất ấy.

Câu 93. Ví dụ mô phỏng phân phối mũ bằng nghịch đảo CDF

Từ $F(x) = 1 - e^{-\lambda x}$ trên C1 trang 9, giải F^{-1} và kiểm tra trực tiếp rằng $X = -\log(1-U)/\lambda$ có phân phối mũ.

Slide: C1, trang 8–9.

Lời giải.

Với $x \geq 0$, giải phương trình $u = F(x)$:

$$\begin{aligned} u &= 1 - e^{-\lambda x}, \\ 1 - u &= e^{-\lambda x}, \\ \log(1-u) &= -\lambda x, \\ x &= -\frac{\log(1-u)}{\lambda}. \end{aligned}$$

Lấy $U \sim U(0,1)$ rồi đặt $X = -\log(1-U)/\lambda$. Với $x < 0$, $\mathbb{P}(X \leq x) = 0$. Với $x \geq 0$,

$$\begin{aligned} \mathbb{P}(X \leq x) &= \mathbb{P}(-\log(1-U) \leq \lambda x) \\ &= \mathbb{P}\Big(U \leq 1 - e^{-\lambda x}\Big) \\ &= 1 - e^{-\lambda x} = F(x). \end{aligned}$$

Đó là kiểm tra trực tiếp của thuật toán mô phỏng ở slide 9; $\lambda > 0$ và $U = 1$ có xác suất 0.

Câu 94. Ví dụ mô phỏng hồi quy trên slide: ba băng thông, CV và biên

Tái lập dữ liệu $n = 200$, $r(x) = \sin(2\pi x) + 0.5x$, seed 2025; tính băng thông NW bằng CV theo lưới trên slide và so sánh NW với local linear tại $x = 0, 0.5, 1$.

Slide: C3, trang 26–28, 44–47.

Lời giải.

Chạy đúng thiết lập slide 26: $X_i \sim U[0,1]$, $r(x) = \sin(2\pi x) + 0.5x$, $Y_i = r(X_i) + \xi_i$, $\xi_i \sim N(0, 0.25^2)$, $n = 200$, `set.seed(2025)`. Mã tái lập trong tệp

`Final_Exam_Regression_SlideSimulation.R`

Trang 27 so ba giá trị băng thông của `ksmooth`: $0.02, 0.08, 0.30$. Trang 28 tính CV của NW trên 40 giá trị từ 0.01 đến 0.30. Với mỗi h và mỗi i, bỏ hàng thứ i, tính $\widehat{r}_{-i,h}(X_i)$, rồi lấy

$$\mathrm{CV}(h) = \frac{1}{200}\sum_{i=1}^{200}[Y_i - \widehat{r}_{-i,h}(X_i)]^2.$$

Chạy theo seed và lưới trên cho $\boxed{h_{\mathrm{CV}} \approx 0.02487179}$, $\min \mathrm{CV} \approx 0.06163277$. Chẳng hạn với quan sát thứ nhất, $X_1 \approx 0.00459119$, $Y_1 \approx 0.20374538$. Tại băng thông chọn được, bỏ hàng này cho $\widehat{r}_{-1,h_{\mathrm{CV}}}(X_1) \approx 0.10705432$. Hạng thứ nhất của tổng CV là

$$(0.20374538 - 0.10705432)^2 \approx 0.00934916.$$

Ở $x = 0$ với NW và $h = 0.10$,

$$\sum_i K((X_i - 0)/h)Y_i \approx 4.70238791, \qquad \sum_i K((X_i - 0)/h) \approx 9.23387630,$$

cho $\widehat{r}_{NW}(0) \approx 4.70238791/9.23387630 = 0.50925394$. Với local linear $h = 0.05$ tại cùng điểm,

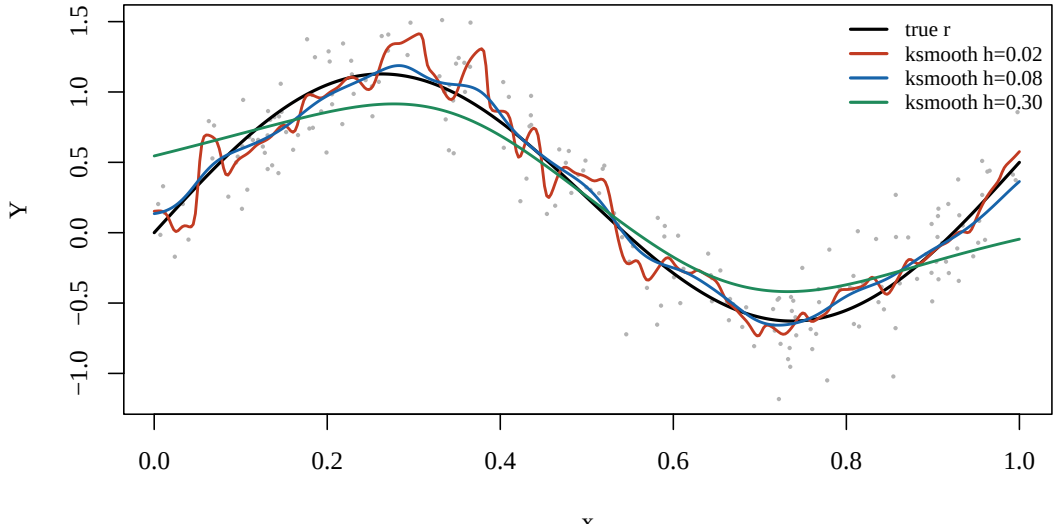
$$(S_0, S_1, S_2) \approx (3.66315099, 0.14466935, 0.01083560),$$
$$(T_0, T_1) \approx (0.93056722, 0.06295645).$$

Vậy tử $S_2T_0 - S_1T_1 \approx 0.00097538$, mẫu $S_0S_2 - S_1^2 \approx 0.01876320$, và $\widehat{r}_{LL}(0) \approx 0.05198375$. Ở ba điểm kiểm tra, hàm thật và hai ước lượng theo công thức Gaussian của slide cho

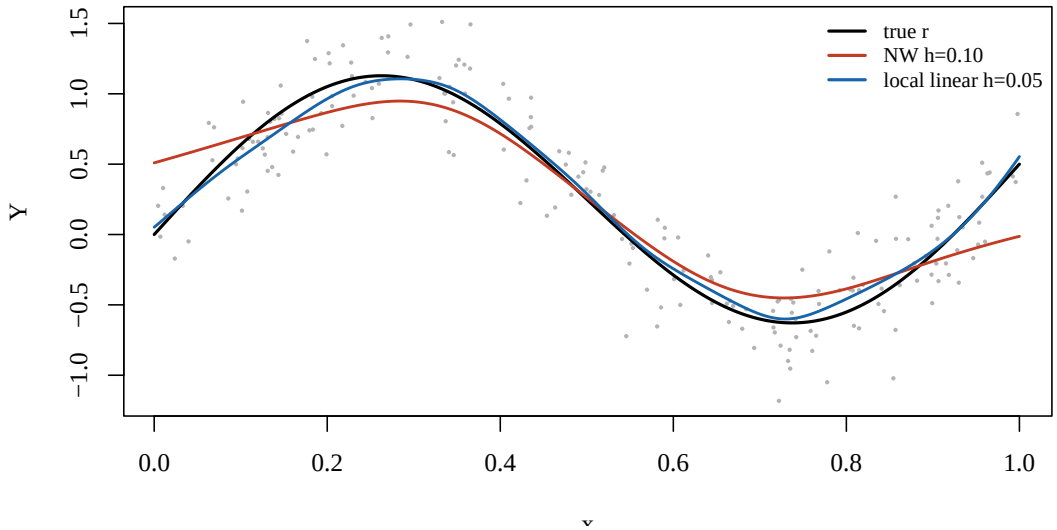
x	$r(x)$	$\widehat{r}_{NW,h=0.10}(x)$	$\widehat{r}_{LL,h=0.05}(x)$
0	0	0.50925	0.05198
0.5	0.25	0.26258	0.28903
1	0.5	−0.01299	0.55408

Tại $x = 0$ và $x = 1$, local linear gần $r(x)$ hơn trong lần mô phỏng này; tại $x = 0.5$ cả hai gần nhau.

Slide 27: effect of bandwidth



Slides 44–47: NW and local linear near boundaries



`ksmooth` ở trang 27 và công thức `dnorm((X-x)/h)` ở trang 28 dùng hai cách diễn giải đối số băng thông trong R; vì thế không so trực tiếp số 0.08 trên hình với h_{CV} của công thức NW tự viết.

Câu 95. Ví dụ phép chiếu $N(4,25)$: tính được gì khi slide không cho mẫu thô?

Với $n = 1000$, viết từng bước chuẩn hóa, các hệ số và ba ước lượng $D = 3, 5$ và histogram $D = 10$ trên C2P trang 25; tính giá trị của mật độ thật tại $x = 4$.

Slide: C2P, trang 9–11, 25–26.

Lời giải.

Trên slide, $X_i \sim N(4, 25)$ và $n = 1000$. Mật độ thật là

$$f(x) = \frac{1}{5\sqrt{2\pi}} \exp\left[-\frac{(x-4)^2}{50}\right], \qquad \boxed{f(4) = \frac{1}{5\sqrt{2\pi}} \approx 0.07979.}$$

Từ mẫu, tính $a = \min_i X_i$, $b = \max_i X_i$ rồi $U_i = (X_i - a)/(b - a)$. Trên $[0, 1]$,

$$\widehat{a}_1 = 1, \quad \widehat{a}_{2k} = \frac{\sqrt{2}}{1000} \sum_{i=1}^{1000} \cos(2\pi k U_i), \quad \widehat{a}_{2k+1} = \frac{\sqrt{2}}{1000} \sum_{i=1}^{1000} \sin(2\pi k U_i).$$

Thế hệ số $k = 1$ cho $\widehat{f}_3$; thêm $k = 2$ cho $\widehat{f}_5$. Với histogram $D = 10$, đếm $Y_j = \#\{i : U_i \in [(j-1)/10, j/10)\}$ (ô cuối nhận $U_i = 1$) và đặt $\widehat{f}_{10}(u) = 10Y_j/1000$ trên ô j. Cuối cùng, mọi mật độ ước lượng trên thang x là $\widehat{f}_{D,X}(x) = \widehat{f}_D((x-a)/(b-a))/(b-a)$. Slide không công bố 1000 giá trị X_i hoặc seed, nên không thể tính số cụ thể của $a, b, \widehat{a}_j, Y_j$ hay giá trị $\widehat{f}_D(4)$ từ slide; nhận xét $D = 3$ quá trơn, $D = 5$ khớp hơn và histogram $D = 10$ gián đoạn là đánh giá từ hình minh họa.

Câu 96. Ví dụ gán hạng đầu Chương 5

Từ mẫu $(5, 2, 6, 3, 8, 1)$ trên C5 trang 5, sắp thứ tự, gán hạng từng quan sát theo đúng vị trí ban đầu và kiểm tra tổng hạng.

Slide: C5, trang 5.

Lời giải.

Sắp sáu quan sát tăng dần:

$$1 < 2 < 3 < 5 < 6 < 8.$$

Gán hạng theo thứ tự này: $1 \mapsto 1$, $2 \mapsto 2$, $3 \mapsto 3$, $5 \mapsto 4$, $6 \mapsto 5$, $8 \mapsto 6$. Trả lại thứ tự ban đầu $(5, 2, 6, 3, 8, 1)$:

$$\boxed{(R_1, \ldots, R_6) = (4, 2, 5, 3, 6, 1).}$$

Kiểm tra $\sum_i R_i = 4 + 2 + 5 + 3 + 6 + 1 = 21 = 6 \cdot 7/2$. Ví dụ không có giá trị trùng nên không cần midrank.

Câu 97. Ba ví dụ CDF trên slide đầu Chương 1

Viết CDF cho $U[0, 1]$, Exp(0.5) và biến hỗn hợp bằng 0.5 với xác suất $1/2$, còn lại phân phối đều trên $[0, 1]$; tính bước nhảy tại 0.5 của biến hỗn hợp.

Slide: C1, trang 6–7.

Lời giải.

Với $X \sim U[0, 1]$, độ dài đoạn $[0, x]$ trong $[0, 1]$ là x khi $0 \le x \le 1$, nên

$$F_U(x) = \begin{cases} 0, & x < 0, \\ x, & 0 \le x \le 1, \\ 1, & x > 1. \end{cases}$$

Với $X \sim \text{Exp}(0.5)$, mật độ là $0.5e^{-0.5x}$ cho $x \ge 0$; tích phân từ 0 đến x cho

$$F_E(x) = \begin{cases} 0, & x < 0, \\ 1 - e^{-0.5x}, & x \ge 0. \end{cases}$$

Với biến hỗn hợp, gọi $B = 1$ nếu ta chọn khối điểm 0.5, $\mathbb{P}(B = 1) = 1/2$; nếu $B = 0$, lấy $U \sim U[0, 1]$. Theo công thức xác suất toàn phần,

$$F_M(x) = \tfrac{1}{2}\mathbf{1}_{\{x \geq 0.5\}} + \tfrac{1}{2}F_U(x) = \begin{cases} 0, & x < 0, \\ x/2, & 0 \leq x < 0.5, \\ (1+x)/2, & 0.5 \leq x \leq 1, \\ 1, & x > 1. \end{cases}$$

Vì $F_M(0.5-) = 0.25$ và $F_M(0.5) = 0.75$,

$$\boxed{\mathbb{P}(X = 0.5) = F_M(0.5) - F_M(0.5-) = 0.5.}$$

Ví dụ này cho thấy CDF tồn tại dù phân phối vừa có khối điểm vừa có phần liên tục.

Câu 98. Tính từng ước lượng plug-in được liệt kê ở Chương 1

Từ $P_n = n^{-1}\sum_i \delta_{X_i}$, suy ra công thức mẫu cho trung bình, moment bậc k, xác suất đuôi, giá trị CDF, phương sai, skewness, phân vị và tương quan hai biến.

Slide: C1, trang 28–35.

Lời giải.

Phân phối thực nghiệm đặt khối lượng $1/n$ tại mỗi X_i. Vì thế, với mọi g tính được tại các quan sát,

$$\int g(x)\, d\widehat{F}_n(x) = \frac{1}{n}\sum_{i=1}^{n} g(X_i).$$

Thay lần lượt các hàm g của slide 29:

$$\begin{aligned} \widehat{\mu} &= \int x\, d\widehat{F}_n = \frac{1}{n}\sum_i X_i = \bar{X}, \\ \widehat{m}_k &= \int x^k\, d\widehat{F}_n = \frac{1}{n}\sum_i X_i^k, \\ \widehat{P}(X > c) &= \int \mathbf{1}_{\{x>c\}}\, d\widehat{F}_n = \frac{\#\{i : X_i > c\}}{n} = 1 - \widehat{F}_n(c), \\ \widehat{F}(t) &= \int \mathbf{1}_{\{x\leq t\}}\, d\widehat{F}_n = \frac{\#\{i : X_i \leq t\}}{n} = \widehat{F}_n(t). \end{aligned}$$

Với phiếm hàm phi tuyến ở slide 30, trước hết tính $\bar{X}$ và $\widehat{m}_2$, rồi

$$\widehat{\sigma}^2 = \widehat{m}_2 - \bar{X}^2 = \frac{1}{n}\sum_i (X_i - \bar{X})^2.$$

Tiếp theo dùng moment trung tâm bậc ba:

$$\widehat{\kappa} = \frac{n^{-1}\sum_i (X_i - \bar{X})^3}{[n^{-1}\sum_i (X_i - \bar{X})^2]^{3/2}},$$

khi mẫu số dương. Với phân vị mức $p \in (0, 1)$, sắp mẫu và lấy $\boxed{\widehat{q}_p = \widehat{F}_n^{-1}(p) = X_{(\lceil np \rceil)}}$; đặc biệt theo quy ước slide, median mẫu khi n chẵn là thống kê thứ tự thứ $n/2$, không lấy trung bình hai giá trị giữa. Nếu quan sát cặp (X_i, Y_i), thay phân phối chung bằng $P_n = n^{-1}\sum_i \delta_{(X_i, Y_i)}$. Tính $\bar{X}, \bar{Y}$, hai phương sai và tích chéo:

$$\widehat{\rho} = \frac{\sum_i (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_i (X_i - \bar{X})^2 \sum_i (Y_i - \bar{Y})^2}},$$

nếu cả hai phương sai dương. Các slide 29–35 không cho mẫu số liệu để thế thành giá trị cụ thể.

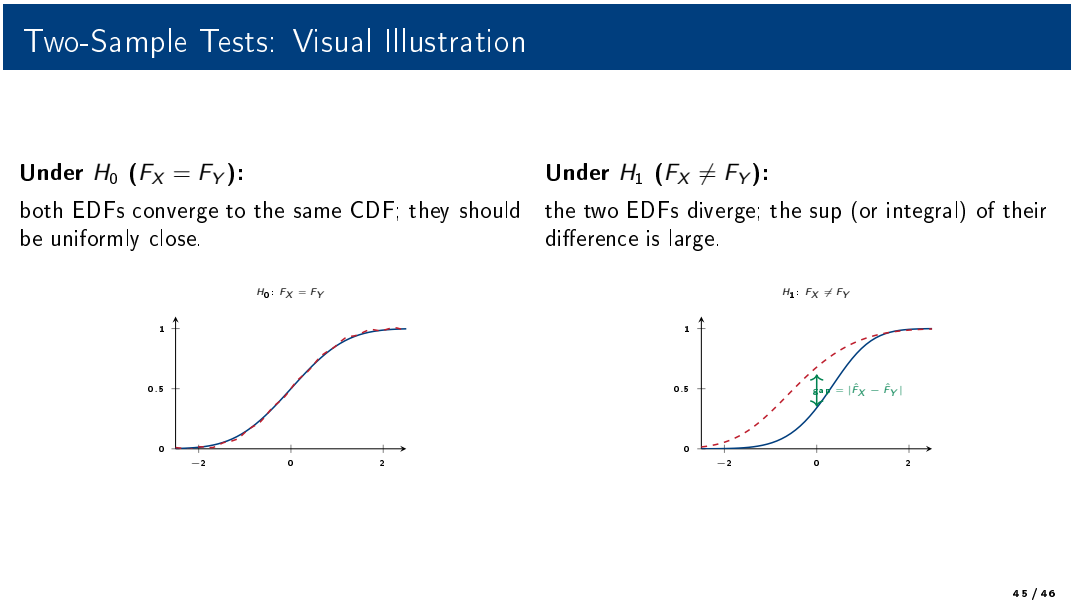
Câu 99. Giải thích hai hình ECDF hai mẫu dưới H_0 và H_1

Từ hai ECDF của C1 trang 45, chỉ rõ sai khác nào được KS, CvM và Anderson–Darling đo; nêu phần không thể tính số khi slide chỉ cung cấp hình.

Slide: C1, trang 42–46.

Lời giải.

Hai hình ở slide 45 vẽ ECDF của nhóm X và Y. Ở hình trái, $F_X = F_Y$ dưới H_0; hai đường thực nghiệm gần nhau nhưng vẫn có sai khác do ngẫu nhiên hữu hạn mẫu. Ở hình phải, hai phân phối khác nhau và khoảng cách giữa hai đường lớn hơn.



Từ hai đường đó, trước hết tính $\Delta(x) = \widehat{F}_X(x) - \widehat{F}_Y(x)$. KS lấy độ lệch lớn nhất:

$$T_{KS,2} = \sqrt{\frac{nm}{n+m}} \sup_x |\Delta(x)|.$$

Đặt $\widehat{H} = (n\widehat{F}_X + m\widehat{F}_Y)/(n+m)$. CvM cộng sai khác bình phương trên toàn miền, còn AD tăng trọng số gần hai đuôi:

$$T_{CvM,2} = \frac{nm}{n+m} \int \Delta(x)^2 d\widehat{H}(x), \quad T_{AD,2} = \frac{nm}{n+m} \int \frac{\Delta(x)^2}{\widehat{H}(x)(1-\widehat{H}(x))} d\widehat{H}(x).$$

Hình không liệt kê các X_i, Y_i và không có ngưỡng hay p-giá trị, nên không thể tính ba thống kê ra số hoặc kết luận kiểm định chính thức chỉ từ hình minh họa.

Câu 100. Tái lập ví dụ local linear và local quadratic trên slide hồi quy

Với dữ liệu mô phỏng seed 2025 và cùng băng thông 0.08, tính các giá trị ở $x = 0, 0.5, 1$ bằng `KernSmooth::locpoly` bậc 1, 2; so sánh đồ thị với hàm thật.

Slide: C3, trang 26, 44–47.

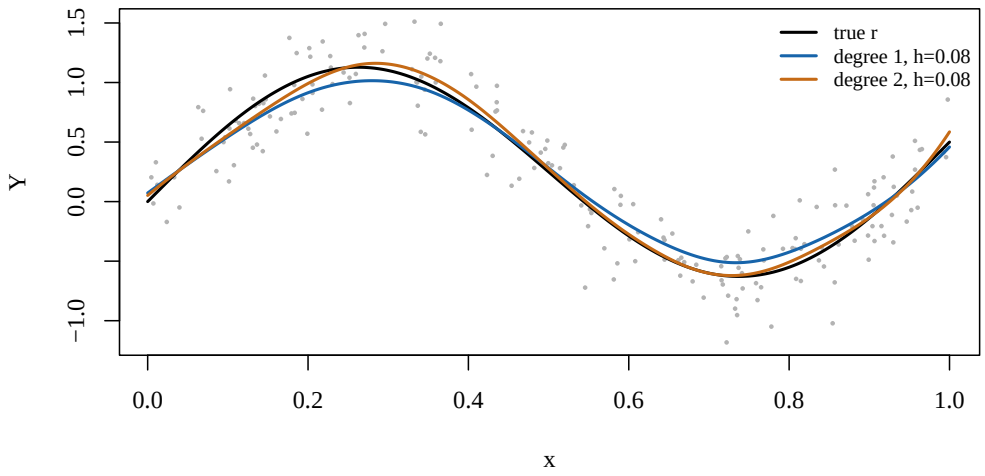
Lời giải.

Dùng đúng mẫu mô phỏng seed 2025 của slide 26. Chạy `KernSmooth::locpoly` với `degree=1` và `degree=2`, cùng `bandwidth=0.08` như slide 45; đặt lưới dự đoán từ 0 đến 1. Giá trị tại ba điểm là

x	$r(x)$	local linear	local quadratic
0	0	0.07221	0.05169
0.5	0.25	0.28226	0.27732
1	0.5	0.45877	0.58559

Ví dụ ở $x = 0$, sai số tuyệt đối lần lượt là $|0.07221 - 0| = 0.07221$ và $|0.05169 - 0| = 0.05169$; ở $x = 1$, chúng là 0.04123 và 0.08559. Vì vậy bậc 2 không thắng ở mọi điểm trong lần mô phỏng này; đồ thị cho thấy nó theo sát vài đoạn cong hơn nhưng cũng dao động hơn.

Slide 45: local linear vs local quadratic



Hai đường dùng cùng dữ liệu và cùng đối số băng thông, nên sự khác biệt ở đây đến từ bậc đa thức. Mã tái lập nằm trong `Final_Exam_Regression_SlideSimulation.R`.

10 Bảng tự kiểm cuối cùng

1. Với mỗi claim, nêu rõ giả thiết: i.i.d., liên tục, đối xứng, trơn, kernel không âm, không có hạng trùng, hay $f_X(x) > 0$.
2. Với mỗi chứng minh, chỉ đúng bước quyết định: Bernoulli, đổi biến, Taylor, trực chuẩn/Pythagoras, gán dấu ngẫu nhiên, hay hoán vị hạng.
3. Với mỗi bài kiểm định, viết đúng H_0, H_1, chiều đuôi, thống kê, phân phối dưới H_0, p-value/ngưỡng và kết luận theo bối cảnh.
4. Phân biệt định lý được *phát biểu* trên slide (DKW, cận minimax, oracle, giới hạn quá trình) với hệ quả có thể tự chứng minh ở thời lượng thi.