

Thống kê phi tham số — Hỏi & Đáp

Những điều cần nắm khi học môn Nonparametric Statistics

Lớp: Cao học LT Thống kê Toán — GV: Hoàng Văn Hà

Ký hiệu: [W] = Wasserman, *All of Nonparametric Statistics*; [SS] = Sprent & Smeeton, *Applied Nonparametric Statistical Methods*. Mỗi câu gồm: **Chốt nhanh** (trả lời trong 30 giây) → **Trực giác** → **Chi tiết toán học** → Ví dụ → Bấy.

Mục lục câu hỏi

1	Thống kê phi tham số là gì, khác gì thống kê tham số?	1
2	Vì sao lấy CDF làm công cụ trung tâm, không phải PDF/PMF?	2
3	ECDF và các tính chất thống kê của nó	3
4	ECDF liên kết thế nào với phân phối Bernoulli?	5
5	Ước lượng hàm phân phối khác gì ước lượng phiếm hàm?	7
6	Một dãy hàm nghĩa là gì? Hình dung nó ra sao?	9
7	Hội tụ điểm và hội tụ đều khác nhau thế nào?	10
8	Hội tụ theo phân phối và hội tụ theo xác suất có phải là một?	12
9	Không gian hàm là gì, và vì sao F chưa biết lại có mật độ $f = F'$?	14
10	Vì sao phương pháp phi tham số hội tụ chậm hơn tham số?	16
11	Bảng ký hiệu tiệm cận, sai số và hội tụ nghĩa là gì?	18

Chương 1. Giới thiệu & Hàm phân phối thực nghiệm (ECDF)

Câu 1. Thống kê phi tham số là gì, khác gì thống kê tham số?

Thế nào là một mô hình *phi tham số*? Nó khác mô hình tham số ở điểm nào, và ta được gì — mất gì khi chọn hướng phi tham số?

Chốt nhanh

Mô hình tham số giả định phân phối nằm gọn trong một họ được mô tả bởi *hữu hạn* tham số ($X \sim P_\theta, \theta \in \Theta \subseteq \mathbb{R}^d, d < \infty$); mô hình phi tham số chỉ giả định $X \sim F$ với F thuộc một lớp *vô hạn chiều* $\mathcal{F}$ (ví dụ “mọi phân phối liên tục”). Tinh thần (Wasserman): *dùng dữ liệu để suy diễn về một đại lượng chưa biết trong khi đặt càng ít giả định càng tốt*. Đổi lại tính linh hoạt và bền vững, ta mất một phần hiệu quả (efficiency) và cần nhiều dữ liệu hơn.

1. Trực giác

Tham số hóa là một lời hứa về dạng của F . Nếu lời hứa đúng, ta chỉ còn phải ước lượng vài con số $\Rightarrow$ rất hiệu quả. Nếu lời hứa sai (*model mis-specification*), mọi suy diễn phía sau đều lệch một cách

hệ thống, và tăng n cũng không cứu được. Phi tham số từ chối đưa ra lời hứa đó: chấp nhận trả giá bằng phương sai lớn hơn để không phải gánh rủi ro chệch do sai mô hình.

2. Chi tiết toán học

- **Tham số:** $\mathcal{P} = \{P_\theta : \theta \in \Theta \subseteq \mathbb{R}^d\}$, $d < \infty$. Ví dụ $\mathcal{N}(\mu, \sigma^2)$, $\text{Poisson}(\lambda)$, $\text{Bernoulli}(p)$.
- **Phi tham số:** $\mathcal{F} = \{F : F \text{ là hàm phân phối}\}$ hoặc một lớp con bị ràng buộc *định tính* (liên tục, có mật độ trơn, đơn điệu...) — không tham số hóa được bằng $\mathbb{R}^d$ với d hữu hạn.
- Năm bài toán trung tâm của suy diễn phi tham số:
 1. Ước lượng hàm phân phối $F(x) = \mathbb{P}(X \leq x)$ (*nội dung chương 1*);
 2. Ước lượng phiếm hàm thống kê $T(F)$, ví dụ $T(F) = \int x dF(x)$;
 3. Ước lượng mật độ $f(x) = F'(x)$;
 4. Hồi quy phi tham số $r(x) = \mathbb{E}[Y | X = x]$;
 5. Kiểm định giả thuyết: goodness-of-fit, hai mẫu, kiểm định dựa trên hạng.

3. Được & mất

Ưu điểm	Nhược điểm
Linh hoạt: mô tả được cấu trúc phức tạp mà không áp đặt dạng hàm	Hiệu quả: nếu mô hình tham số <i>đúng</i> thì phương pháp tham số hiệu quả hơn (dù mức thiệt thường nhỏ)
Bền vững: ít nhạy với ngoại lai và với sai mô hình	Diễn giải: kết quả đôi khi khó diễn giải hơn
Tổng quát: dùng được cho dữ liệu thứ bậc (rank-based)	Tính toán: tốn kém hơn (nay đã được máy tính hiện đại hoá giải)
Hợp lệ: bảo vệ trước rủi ro sai đặc tả mô hình	Cỡ mẫu: thường cần nhiều dữ liệu hơn

Lưu ý & bấy thường gặp

“Phi tham số” **không** có nghĩa là “không có giả định nào”. Ta vẫn luôn giả định i.i.d. (hoặc một cấu trúc phụ thuộc nào đó), và thường thêm các giả định định tính như F liên tục, f khả vi, r trơn. Chính xác hơn: *ít giả định về dạng hàm*, chứ không phải *không giả định*.

Liên hệ: Slide tr. 3–5; [W] Ch. 1.

Câu 2. Vì sao lấy CDF làm công cụ trung tâm, không phải PDF/PMF?

Tại sao trong thống kê phi tham số ta xuất phát từ hàm phân phối tích lũy F mà không phải hàm mật độ f hay hàm khối xác suất?

Chốt nhanh

Vì **CDF luôn tồn tại** với mọi biến ngẫu nhiên, còn PDF chỉ tồn tại cho biến liên tục và PMF chỉ cho biến rời rạc. CDF là biểu diễn *thống nhất* duy nhất — kể cả với biến hỗn hợp không có cả PDF lẫn PMF. Thêm nữa, F ước lượng được với tốc độ $n^{-1/2}$ mà không cần tham số trơn hoá, trong khi ước lượng mật độ luôn chậm hơn và phải chọn băng thông.

1. Chi tiết toán học

Với biến ngẫu nhiên X , hàm phân phối tích lũy là

$$F(x) = \mathbb{P}(X \leq x), \quad x \in \mathbb{R},$$

với các tính chất đặc trưng:

- (Miền giá trị) $0 \leq F(x) \leq 1$;
- (Đơn điệu) $x \leq y \Rightarrow F(x) \leq F(y)$;
- (Liên tục phải) $\lim_{x \rightarrow y^+} F(x) = F(y)$;
- $\lim_{x \rightarrow -\infty} F(x) = 0, \lim_{x \rightarrow +\infty} F(x) = 1$;
- Bước nhảy tại x chính là khối xác suất: $\mathbb{P}(X = x) = F(x) - F(x^-)$.

Ngược lại, mọi hàm thỏa bốn tính chất đầu đều là CDF của một phân phối nào đó — nên làm việc với F là làm việc trực tiếp trên toàn bộ lớp mô hình $\mathcal{F}$.

2. Ví dụ: biến không có PDF lẫn PMF

Cho $X = 0.5$ với xác suất $1/2$; ngược lại $X \sim \mathcal{U}([0, 1])$. Khi đó X không liên tục (có một nguyên tử tại 0.5) và cũng không rời rạc (phần còn lại trải liên tục trên $[0, 1]$), nên *không* có PDF, cũng *không* có PMF — nhưng CDF vẫn tồn tại và mô tả trọn vẹn phân phối:

$$F(x) = \begin{cases} 0, & x < 0, \\ x/2, & 0 \leq x < 0.5, \\ x/2 + 1/2, & 0.5 \leq x \leq 1, \\ 1, & x > 1. \end{cases}$$

3. Hệ quả dùng nhiều: phép biến đổi nghịch đảo

Hàm nghịch đảo suy rộng (hàm phân vị) $F^{-1}(u) = \inf\{x : F(x) \geq u\}$, $u \in (0, 1)$, cho ta:

- Nếu $U \sim \mathcal{U}([0, 1])$ thì $W = F^{-1}(U)$ có hàm phân phối đúng bằng F ;
- Ngược lại, nếu $X \sim F$ với F liên tục thì $V = F(X) \sim \mathcal{U}([0, 1])$ (*probability integral transform*).

Ví dụ với $\text{Exp}(\lambda)$: $F(x) = 1 - e^{-\lambda x} \Rightarrow F^{-1}(u) = -\frac{1}{\lambda} \log(1 - u)$, nên sinh $U \sim \mathcal{U}([0, 1])$ rồi đặt $X = -\frac{1}{\lambda} \log(1 - U)$ ta được mẫu $\text{Exp}(\lambda)$. Đây là nền tảng của bộ sinh số ngẫu nhiên và của mô phỏng Monte Carlo.

Lưu ý & bất thường gặp

F^{-1} ở đây là *nghịch đảo suy rộng* (dùng $\inf$), không đòi hỏi F đơn điệu ngặt hay liên tục — nhờ vậy công thức vẫn đúng cho phân phối rời rạc và hỗn hợp. Chiều thuận ($F^{-1}(U) \sim F$) đúng cho *mọi* F ; chiều ngược ($F(X) \sim \mathcal{U}$) cần F liên tục.

Liên hệ: Slide tr. 6–9; xem Câu 3 cho phiên bản thực nghiệm $\hat{F}_n$.

Câu 3. ECDF và các tính chất thống kê của nó

Hàm phân phối thực nghiệm $\hat{F}_n$ được định nghĩa thế nào, và vì sao nó là ước lượng “tốt” của F ? Nêu các tính chất điểm và tính chất đều.

Chốt nhanh

$\widehat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i \leq x)$ — hàm bậc thang đặt khối lượng $1/n$ tại mỗi quan sát. Tại mỗi x cố định, $n\widehat{F}_n(x) \sim \mathcal{B}(n, F(x))$, nên $\widehat{F}_n(x)$ **không chệch, vững**, và **tiệm cận chuẩn**. Mạnh hơn nữa, Glivenko–Cantelli cho hội tụ *đều* h.c.c. trên toàn $\mathbb{R}$, và bất đẳng thức DKW cho một chặn *hữu hạn mẫu* dùng để dựng dải tin cậy.

1. Trực giác

$F(x_0) = \mathbb{P}(X_i \leq x_0)$ là một *xác suất*; cách ước lượng tự nhiên nhất cho xác suất là *tần suất*. Luật số lớn bảo đảm tần suất hội tụ về xác suất; làm việc này đồng thời cho mọi x ta được một ước lượng cho *toàn bộ* hàm F .

2. Chi tiết toán học

Với $X_1, \dots, X_n \stackrel{iid}{\sim} F$, đặt $Y_i = \mathbb{I}(X_i \leq x)$ với x cố định. Khi đó $Y_i \stackrel{iid}{\sim} \text{Bernoulli}(p)$ với $p = F(x)$, và $\widehat{F}_n(x) = \bar{Y}$, $n\widehat{F}_n(x) \sim \mathcal{B}(n, F(x))$. Suy ra:

$$\mathbb{E}[\widehat{F}_n(x)] = F(x), \quad \mathbb{V}[\widehat{F}_n(x)] = \frac{F(x)(1 - F(x))}{n}.$$

- Không chệch:** $\text{Bias}[\widehat{F}_n(x)] = 0$ với mọi n .
- Vững:** $\mathbb{V}[\widehat{F}_n(x)] \rightarrow 0$ khi $n \rightarrow \infty$, do đó $\widehat{F}_n(x) \xrightarrow{P} F(x)$.
- Tiệm cận chuẩn (CLT):**

$$\sqrt{n}(\widehat{F}_n(x) - F(x)) \xrightarrow{d} \mathcal{N}(0, F(x)(1 - F(x))).$$

- Glivenko–Cantelli (hội tụ đều):**

$$\sup_{x \in \mathbb{R}} |\widehat{F}_n(x) - F(x)| \xrightarrow{a.s.} 0.$$

- DKW (chặn hữu hạn mẫu):** với mọi $\varepsilon > 0$ và mọi $n \geq 1$,

$$\mathbb{P}\left(\sup_{x \in \mathbb{R}} |F(x) - \widehat{F}_n(x)| > \varepsilon\right) \leq 2e^{-2n\varepsilon^2}.$$

Chọn $\varepsilon_n = \sqrt{\log(2/\alpha)/(2n)}$ và đặt $L(x) = \max\{\widehat{F}_n(x) - \varepsilon_n, 0\}$, $U(x) = \min\{\widehat{F}_n(x) + \varepsilon_n, 1\}$ thì $\mathbb{P}(L(x) \leq F(x) \leq U(x) \ \forall x) \geq 1 - \alpha$ — *dải tin cậy đồng thời*, đúng với mọi F và mọi n .

3. Ví dụ số

Cho $X_1, \dots, X_{100} \stackrel{iid}{\sim} \mathcal{U}([0, 2])$, tìm phân phối của $\widehat{F}_n(0.8)$. Ta có $F(0.8) = 0.8/2 = 0.4$, nên

$$\mathbb{E}[\widehat{F}_n(0.8)] = 0.4, \quad \mathbb{V}[\widehat{F}_n(0.8)] = \frac{0.4 \times 0.6}{100} = 2.4 \times 10^{-3},$$

và $100\widehat{F}_n(0.8) \sim \mathcal{B}(100, 0.4)$.

```
# R: vẽ ECDF cùng dải tin cậy DKW 95%
set.seed(1); x <- rnorm(100); alpha <- 0.05
eps <- sqrt(log(2/alpha) / (2*length(x)))
Fn <- ecdf(x); grid <- sort(x)
plot(Fn, main = "ECDF + dải DKW 95%")
lines(grid, pmax(Fn(grid) - eps, 0), lty = 2)
lines(grid, pmin(Fn(grid) + eps, 1), lty = 2)
```

Lưu ý & bẫy thường gặp

- Ba tính chất (1)–(3) là **theo từng điểm** (x cố định); Glivenko–Cantelli và DKW mới là **đều theo x** . Đừng dùng khoảng tin cậy điểm rồi tuyên bố nó phủ F tại *mọi* x .
- ε_n của DKW *không* phụ thuộc x nên dải có bề rộng hằng số — rộng hơn khoảng tin cậy điểm ở hai đuôi, đó là cái giá của bảo đảm đồng thời.
- Phương sai $F(x)(1 - F(x))/n$ đạt cực đại tại $F(x) = 1/2$ và tiến về 0 ở hai đuôi; nhớ cắt tỉa các nút về $[0, 1]$.

Liên hệ: Slide tr. 10–19; [W] Ch. 2. Xem thêm bài tập chương 1 (Delta-method cho $\sqrt{F(x_0)}$, khoảng tin cậy Hoeffding).

Câu 4. ECDF liên kết thế nào với phân phối Bernoulli?

ECDF có liên kết gì với phân phối Bernoulli? Vì sao mối liên kết đó lại quan trọng đến vậy?

Chốt nhanh

Cố định ngưỡng x thì $Y_i(x) = \mathbb{I}(X_i \leq x)$ là biến Bernoulli với tham số $p = F(x)$, và $\widehat{F}_n(x)$ chính là *trung bình mẫu* của chúng, $n\widehat{F}_n(x) \sim \text{Binomial}(n, F(x))$. Nhờ vậy toàn bộ kho công cụ cho Bernoulli/nhị thức — LLN, CLT, Hoeffding/Chernoff — áp thẳng được lên ECDF.

A. Motivation & Ý nghĩa (The “Why”)

Hàm phân phối tích lũy thực nghiệm (ECDF) $\widehat{F}_n(x)$ thực chất là **tỷ lệ số quan sát rơi vào khoảng $(-\infty, x]$** .

Khi cố định một ngưỡng x , bài toán thống kê phi tham số phức tạp lập tức biến thành bài toán cơ bản nhất của xác suất: **đếm số lần thành công trong một chuỗi phép thử đồng xu (Bernoulli trials)**.

- Với mỗi mẫu X_i , ta chỉ quan tâm: nó có “nhỏ hơn hoặc bằng x ” hay không?
- Sự kiện này chỉ có 2 kết cục: **Thành công (1)** hoặc **Thất bại (0)**.
- Nhờ mối liên hệ này, toàn bộ các công cụ mạnh mẽ dành cho phân phối Bernoulli và phân phối Nhị thức (Binomial) như Định luật số lớn, Định lý giới hạn trung tâm, Bất đẳng thức Hoeffding/Chernoff đều được áp dụng trực tiếp lên ECDF.

B. Chi tiết Toán học (The “How”)

1. **Định nghĩa và biến đổi đại số.** Cho mẫu ngẫu nhiên i.i.d. $X_1, X_2, \dots, X_n \sim F$. Cố định một điểm $x \in \mathbb{R}$. Định nghĩa biến chỉ thị (indicator variable):

$$Y_i(x) = \mathbb{I}(X_i \leq x) = \begin{cases} 1 & \text{nếu } X_i \leq x, \\ 0 & \text{nếu } X_i > x. \end{cases}$$

Vì X_i là các biến ngẫu nhiên độc lập cùng phân phối:

- $P(Y_i(x) = 1) = P(X_i \leq x) = F(x) = p$;
- $P(Y_i(x) = 0) = 1 - F(x) = 1 - p$.

Do đó

$$Y_i(x) \stackrel{\text{i.i.d}}{\sim} \text{Bernoulli}(p), \quad \text{với } p = F(x).$$

2. *ECDF là trung bình mẫu của các biến Bernoulli.* ECDF tại điểm x được viết lại dưới dạng

$$\widehat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i \leq x) = \frac{1}{n} \sum_{i=1}^n Y_i(x) = \bar{Y}_n(x).$$

Nếu nhân cả hai vế với n , tổng số điểm nhỏ hơn hoặc bằng x tuân theo phân phối nhị thức:

$$n\widehat{F}_n(x) = \sum_{i=1}^n Y_i(x) \sim \text{Binomial}(n, F(x)).$$

3. *Các hệ quả trực tiếp từ tính chất Bernoulli.* Từ các đặc trưng của phân phối Bernoulli(p) với $p = F(x)$:

- **Kỳ vọng (tính không chệch — unbiased):**

$$\mathbb{E}[\widehat{F}_n(x)] = \mathbb{E}[Y_i(x)] = F(x) \implies \text{bias} = 0.$$

- **Phương sai (variance & standard error):**

$$\mathbb{V}(\widehat{F}_n(x)) = \frac{\mathbb{V}(Y_i(x))}{n} = \frac{F(x)(1 - F(x))}{n} \implies \text{se} = \sqrt{\frac{F(x)(1 - F(x))}{n}}.$$

- **Hội tụ theo xác suất (pointwise consistency):** theo luật mạnh số lớn (SLLN) áp dụng cho dãy Bernoulli Y_i ,

$$\widehat{F}_n(x) \xrightarrow{a.s.} F(x).$$

- **Tính chuẩn tiệm cận (asymptotic normality):** theo định lý giới hạn trung tâm (CLT),

$$\sqrt{n}(\widehat{F}_n(x) - F(x)) \rightsquigarrow \mathcal{N}(0, F(x)(1 - F(x))).$$

C. Ví dụ Thực tế & Đa ngành (The “Where”)

- **Cybersecurity & IAM (đánh giá tỷ lệ Risk Score vượt ngưỡng):**

- Đặt X_i là risk score của các phiên truy cập login. Ta muốn ước lượng xác suất một phiên truy cập là an toàn ($X_i \leq x_{\text{threshold}}$).
- Mỗi log truy cập đổ về đóng vai trò là một phép thử Bernoulli $Y_i = \mathbb{I}(X_i \leq x_{\text{threshold}})$.
- ECDF $\widehat{F}_n(x_{\text{threshold}})$ chính là tỷ lệ thành công của mẫu. Nhờ phân phối Bernoulli, ta dựng được ngay khoảng tin cậy Clopper–Pearson hoặc Wilson Score Interval chính xác cho tỷ lệ rủi ro của hệ thống mà không cần giả định phân phối log ban đầu.

- **Non-parametric Statistical Inference (dựng dải tin cậy Dvoretzky–Kiefer–Wolfowitz):**

- Vì từng điểm là Bernoulli, ta có thể áp dụng bất đẳng thức nồng độ **Hoeffding’s Inequality** cho tổng Bernoulli để chặn sai số cực đại:

$$P\left(\sup_x |\widehat{F}_n(x) - F(x)| > \varepsilon\right) \leq 2e^{-2n\varepsilon^2}.$$

- Bất đẳng thức DKW này cho phép kỹ sư/nhà nghiên cứu dựng một **Confidence Band (dải tin cậy)** bao phủ toàn bộ đường cong phân phối xác suất với độ tin cậy $1 - \alpha$ chuẩn xác cho mọi cỡ mẫu n .

Liên hệ: Slide tr. 14–15, 18–19; xem Câu 3 (tính chất ECDF) và Câu 11 (bias/se/MSE).

Câu 5. Ước lượng hàm phân phối khác gì ước lượng phiếm hàm?

Đâu là sự khác nhau giữa **ước lượng hàm phân phối xác suất** (estimating the distribution function) và **ước lượng phiếm hàm** (estimating statistical functionals)?

Chốt nhanh

Khác nhau cốt lõi nằm ở **đối tượng toán học cần ước lượng**: một bên khôi phục toàn bộ một *hàm số* — đối tượng vô hạn chiều $F \in \mathcal{F}$ (hoặc mật độ f); bên kia chỉ ước lượng một *đặc trưng tổng hợp* $\theta = T(F)$ — một ánh xạ vô hướng (hữu hạn chiều) trích ra từ phân phối đó, ví dụ trung bình, phương sai, phân vị, entropy.

1. Động cơ & trực giác

- **Ước lượng hàm phân phối (toàn cục / toàn diện).** Mục tiêu: hiểu bức tranh tổng thể về cơ chế sinh dữ liệu mà không áp đặt một giả định tham số cứng nhắc. Trực giác: khôi phục lại *toàn bộ hình dáng* của $F(x)$ (hoặc $f(x)$) trên toàn miền xác định.
- **Ước lượng phiếm hàm (cục bộ / đặc trưng hoá).** Mục tiêu: không cần biết toàn bộ phân phối, chỉ quan tâm một đại lượng tóm tắt phục vụ trực tiếp cho ra quyết định hoặc kiểm định giả thuyết. Trực giác: một *phiếm hàm* $T(F)$ là ánh xạ nhận đầu vào là cả hàm phân phối F và trả về một số thực (hoặc vector trong $\mathbb{R}^k$).

Tiêu chí	Ước lượng hàm phân phối	Ước lượng phiếm hàm
Không gian đích	Không gian hàm vô hạn chiều $\mathcal{F}$	Không gian hữu hạn chiều $\mathbb{R}$ hoặc $\mathbb{R}^k$
Tốc độ hội tụ	Chậm hơn (L_∞ , Glivenko–Cantelli; KDE đạt $n^{-2/5}$)	Thường đạt tốc độ chuẩn $\sqrt{n}$
Công cụ đánh giá	Hội tụ đều $\sup_x \hat{F}_n(x) - F(x) $, mất mát L_2	Chuẩn tiệm cận, hàm ảnh hưởng, hiệu quả bán tham số

2. Chi tiết toán học

2.1. *Ước lượng hàm phân phối.* Cho mẫu i.i.d. $X_1, \dots, X_n \sim F$, ước lượng hiển nhiên là ECDF

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i \leq x).$$

- *Hội tụ điểm:* với mọi x , $\hat{F}_n(x) \xrightarrow{P} F(x)$ theo luật số lớn.
- *Hội tụ đều* — định lý Glivenko–Cantelli:

$$\sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| \xrightarrow{a.s.} 0.$$

- *Quá trình thực nghiệm* — định lý Donsker:

$$\sqrt{n}(\hat{F}_n(x) - F(x)) \rightsquigarrow \mathbb{G}(x) \quad (\text{cầu Brown, Brownian bridge}).$$

2.2. *Ước lượng phiếm hàm.* Một phiếm hàm thống kê là ánh xạ $T : \mathcal{F} \rightarrow \mathbb{R}$, tham số cần ước lượng là $\theta = T(F)$.

- **Ước lượng cắm vào (plug-in):** $\hat{\theta}_n = T(\hat{F}_n)$.

• **Phiếm hàm tuyến tính:**

$$T(F) = \int g(x) dF(x) \implies T(\widehat{F}_n) = \frac{1}{n} \sum_{i=1}^n g(X_i),$$

ví dụ kỳ vọng ứng với $g(x) = x$.

- **Phiếm hàm phi tuyến & đạo hàm Von Mises.** Khi T phi tuyến (phân vị, entropy...), ta khai triển Taylor trong không gian phiếm hàm:

$$T(\widehat{F}_n) - T(F) = \int \text{IF}(x; T, F) d(\widehat{F}_n - F)(x) + R_n,$$

với **hàm ảnh hưởng** (influence function)

$$\text{IF}(x; T, F) = \lim_{\epsilon \rightarrow 0} \frac{T((1 - \epsilon)F + \epsilon \delta_x) - T(F)}{\epsilon}.$$

Khi phần dư thoả $R_n = o_P(n^{-1/2})$, ta thu được tính chuẩn tiệm cận

$$\sqrt{n}(T(\widehat{F}_n) - T(F)) \xrightarrow{d} \mathcal{N}\left(0, \int \text{IF}(x; T, F)^2 dF(x)\right).$$

3. Ví dụ thực tế & đa ngành

- **An ninh mạng & IAM (phát hiện mối đe dọa nội bộ, chấm điểm bất thường).** *Ước lượng phân phối:* dựng mô hình KDE trên toàn không gian hành vi đăng nhập (thời điểm truy cập, lượng dữ liệu tải xuống) để có phân phối nền $f(x)$ cho từng nhóm user/role. *Ước lượng phiếm hàm:* chỉ cần phân vị 99%, $q_{0.99} = F^{-1}(0.99)$, hoặc entropy vi phân $H(F) = - \int f(x) \log f(x) dx$ của luồng authentication log. Entropy tụt đột ngột (dấu hiệu botnet brute-force tự động) hoặc log-volume vượt $q_{0.99}$ thì kích hoạt xác thực bước hai (MFA).
- **Tài chính & quản trị rủi ro.** *Ước lượng phân phối:* mô phỏng toàn bộ đường phân phối lợi suất tài sản tương lai bằng ECDF. *Ước lượng phiếm hàm:* tính trực tiếp VaR, $T(F) = F^{-1}(\alpha)$, hoặc CVaR (Expected Shortfall), $T(F) = \mathbb{E}[X | X \leq F^{-1}(\alpha)]$.

Lưu ý & cảnh thường gặp

- Hai bài toán không tách rời: nguyên lý plug-in nói rằng cứ ước lượng F trước rồi *cắm* $\widehat{F}_n$ vào T . Glivenko–Cantelli chính là thứ bảo đảm $T(\widehat{F}_n) \xrightarrow{a.s.} T(F)$ với mọi T liên tục theo chuẩn sup.
- Đừng nhầm “tốc độ $\sqrt{n}$ ” là đặc quyền của mọi phiếm hàm: chỉ những T khả vi Hadamard với phần dư $R_n = o_P(n^{-1/2})$ mới đạt được. Các phiếm hàm phụ thuộc mật độ (ví dụ $f(x_0)$, mode) vẫn chịu tốc độ chậm kiểu phi tham số.
- Ước lượng F ($n^{-1/2}$, đều) *dễ* hơn ước lượng f ($n^{-2/5}$ với KDE bằng thông tối ưu) — đạo hàm là phép toán không ổn định, đây là lý do ta luôn xuất phát từ CDF.

Liên hệ: Slide tr. 5, 21–26 (Statistical Functionals & Plug-in Principle); [W] Ch. 2–3. Xem thêm Câu 3.

Nền giải tích cho suy diễn phi tham số: dãy hàm, hội tụ & không gian hàm

Câu 6. Một dãy hàm nghĩa là gì? Hình dung nó ra sao?

Khi nói “dãy hàm f_n ” thì thực chất ta đang nói về đối tượng gì, và nên hình dung nó như thế nào cho trực quan?

Chốt nhanh

Một dãy *số* cho mỗi n một con số; một dãy *hàm* cho mỗi n nguyên một *đồ thị*. Hãy hình dung nó như một thước phim hoạt hình: mỗi n là một khung hình chứa nguyên đường cong $y = f_n(x)$, và khi $n \rightarrow \infty$ toàn bộ sợi dây đồ thị uốn lượn, xếp xuống hay dịch chuyển để biến dần thành hình dáng đích $f(x)$.

A. Motivation & Ý nghĩa (The “Why”)

Thay vì nghĩ đến một dãy số quen thuộc như $1, \frac{1}{2}, \frac{1}{3}, \dots$ (mỗi bước n cho ra một **con số**), hãy hình dung một dãy hàm $f_n(x)$ giống như một **thước phim hoạt hình (animation)**:

- Mỗi số nguyên $n = 1, 2, 3, \dots$ tương ứng với một **khung hình (frame)**.
- Tại mỗi khung hình n , ta có nguyên một **đồ thị đường cong** $y = f_n(x)$ trải dài trên trục hoành.
- Khi cho n chạy từ $1 \rightarrow \infty$, thước phim bắt đầu chuyển động: **toàn bộ sợi dây đồ thị uốn lượn, xếp xuống, dốc lên hoặc dịch chuyển** để biến đổi dần thành một hình dáng đích cuối cùng (gọi là hàm giới hạn $f(x)$).

B. Chi tiết Toán học (The “How”)

Để thấy rõ “hình hài” của một dãy hàm, hãy quan sát 2 ví dụ trực quan đối lập nhau:

1. *Dãy hàm hội tụ đều*: “Sợi dây co giãn ép sát về 0”. Xét dãy hàm $f_n(x) = \frac{\sin(nx)}{n}$ trên đoạn $[-\pi, \pi]$:

- $n = 1$: Đồ thị là đường sóng sin chuẩn $y = \sin(x)$, dao động giữa -1 và 1 .
- $n = 2$: $y = \frac{\sin(2x)}{2}$, sóng gọn nhanh gấp đôi nhưng biên độ co lại chỉ còn giữa -0.5 và 0.5 .
- $n = 100$: $y = \frac{\sin(100x)}{100}$, sóng gọn li ti và biên độ chỉ còn tối đa 0.01 .

Toàn bộ đường cong $f_n(x)$ bị kẹp chặt giữa hai dải biên giới $\pm \frac{1}{n} \rightarrow 0$. Toàn bộ sợi dây đồ thị đồng loạt dẹp lép thành đường thẳng $y = 0$ (Hội tụ đều).

2. *Dãy hàm chỉ hội tụ điểm*: “Góc gấp ngày càng nhọn”. Xét dãy hàm $f_n(x) = x^n$ trên $[0, 1]$:

- $n = 1$: Đường chéo $y = x$.
- $n = 2$: Parabol $y = x^2$ võng xuống.
- $n = 10$: Đồ thị gần như dán sát đáy trục hoành ở hầu hết đoạn $[0, 0.8]$, nhưng đến sát $x = 1$ thì bất ngờ dựng ngược dốc đứng lên điểm $(1, 1)$.
- $n \rightarrow \infty$: Với bất kỳ điểm $x < 1$ nào, giá trị đều bị kéo tụt về 0. Nhưng tại đúng $x = 1$, giá trị luôn giữ nguyên bằng 1. Sợi dây liên tục bị “kéo đứt” tại điểm cuối.

C. Ví dụ Thực tế & Đa ngành (The “Where”)

- Thống kê & Data Science (Empirical CDF $\hat{F}_n(x)$):**

- Mỗi khi thu thập thêm dữ liệu ($n = 10, 100, 1000$ mẫu), ta vẽ lại đồ thị hàm phân phối bậc thang $\hat{F}_n(x)$.
- Dãy hàm ở đây chính là **chuỗi các đường bậc thang**. Khi n tăng dần, các bậc thang mịn dần và uốn nắn thành đường cong liên tục mượt mà của hàm phân phối lý thuyết $F(x)$.
- **ML & Deep Learning (Quá trình Training Mạng Neural):**
 - Đặt $f_n(x)$ là hàm dự đoán của model tại epoch thứ n (với x là vector đặc trưng đầu vào).
 - Qua từng vòng lặp Gradient Descent, đồ thị hàm quyết định (decision boundary) $f_n(x)$ liên tục uốn lượn, dịch chuyển trong không gian để fit vào dữ liệu phân loại. Dãy các mô hình qua từng epoch chính là một dãy hàm.

Liên hệ: Kiến thức nền cho Câu 7; ứng dụng trực tiếp vào $\hat{F}_n$ ở Câu 3.

Câu 7. Hội tụ điểm và hội tụ đều khác nhau thế nào?

Phân biệt **hội tụ điểm** (pointwise convergence) và **hội tụ đều** (uniform convergence) của một dãy hàm. Vì sao sự phân biệt này lại quan trọng trong thống kê phi tham số?

Chốt nhanh

Hội tụ điểm: mỗi x có ngưỡng $N(x, \varepsilon)$ riêng, tốc độ hội tụ độc lập giữa các điểm nên không kiểm soát được điểm tệ nhất — và do đó *không bảo toàn* tính liên tục hay phép lấy giới hạn qua tích phân/đạo hàm. Hội tụ đều: một ngưỡng $N(\varepsilon)$ dùng chung cho *mọi* x , tương đương $\sup_x |f_n(x) - f(x)| \rightarrow 0$ — toàn bộ đồ thị bị ép vào một dải hẹp quanh f cùng lúc. Glivenko–Cantelli chính là phiên bản “hội tụ đều” cho ECDF.

A. Motivation & Ý nghĩa (The “Why”)

Trong giải tích hàm và lý thuyết xác suất, việc xét một dãy hàm $f_n(x)$ tiến về $f(x)$ khi $n \rightarrow \infty$ phức tạp hơn dãy số thông thường rất nhiều, vì mỗi điểm x có thể tiến về đích với một “tốc độ” khác nhau.

- **Hội tụ điểm (Pointwise Convergence):**
 - *Bản chất:* Ta đứng yên tại một điểm x_0 cố định và quan sát giá trị $f_n(x_0)$. Khi $n \rightarrow \infty$, giá trị này tiến về $f(x_0)$.
 - *Vấn đề:* Mỗi điểm x có tốc độ hội tụ độc lập. Có điểm cần $n = 100$ là đã sát đích, nhưng có điểm lân cận lại cần $n = 1.000.000$. Do không kiểm soát được điểm tệ nhất (worst-case), hội tụ điểm **không bảo toàn các tính chất tốt** như tính liên tục hay phép lấy tích phân/đạo hàm qua giới hạn.
- **Hội tụ đều (Uniform Convergence):**
 - *Bản chất:* Toàn bộ đồ thị hàm số f_n bị “ép” dần vào một dải hẹp quanh đồ thị f trên **toàn bộ miền xác định** cùng một lúc.
 - *Ý nghĩa:* Tốc độ hội tụ được đảm bảo đồng đều trên mọi x . Đây là điều kiện chuẩn mực giúp bảo toàn tính liên tục và đảm bảo sai số toàn cục được chặn trên một cách an toàn.

B. Chi tiết Toán học (The “How”)

1. *Định nghĩa chuẩn tắc.* Cho dãy hàm $f_n : E \rightarrow \mathbb{R}$ và hàm giới hạn $f : E \rightarrow \mathbb{R}$.

- **Hội tụ điểm** ($f_n \xrightarrow{\text{pointwise}} f$):

$$\forall x \in E, \forall \varepsilon > 0, \exists N(x, \varepsilon) \in \mathbb{N} \text{ sao cho } \forall n \geq N \Rightarrow |f_n(x) - f(x)| < \varepsilon.$$

(Lưu ý: N phụ thuộc vào cả ε và vị trí x .)

- **Hội tụ đều** ($f_n \xrightarrow{\text{uniform}} f$ hay $f_n \rightrightarrows f$):

$$\forall \varepsilon > 0, \exists N(\varepsilon) \in \mathbb{N} \text{ sao cho } \forall n \geq N, \forall x \in E \Rightarrow |f_n(x) - f(x)| < \varepsilon.$$

Tương đương với việc chuẩn cực đại (supremum norm) của sai số tiến về 0:

$$\lim_{n \rightarrow \infty} \sup_{x \in E} |f_n(x) - f(x)| = 0.$$

2. *Phản ví dụ kinh điển: mất tính liên tục khi chỉ hội tụ điểm.* Xét dãy hàm $f_n(x) = x^n$ trên đoạn $[0, 1]$:

- Khi $x \in [0, 1)$: $\lim_{n \rightarrow \infty} x^n = 0$.
- Khi $x = 1$: $\lim_{n \rightarrow \infty} 1^n = 1$.

Hàm giới hạn là

$$f(x) = \begin{cases} 0 & \text{khi } 0 \leq x < 1, \\ 1 & \text{khi } x = 1. \end{cases}$$

Mặc dù mọi $f_n(x) = x^n$ đều là hàm liên tục, hàm giới hạn $f(x)$ lại bị **gián đoạn** tại $x = 1$. Lý do: càng tiến gần về 1, giá trị x^n tiến về 0 càng chậm, khiến sai số cực đại luôn là $\sup_{x \in [0, 1)} |x^n - 0| = 1 \neq 0$ (không thể hội tụ đều trên $[0, 1]$).

3. *Cầu nối sang Xác suất & Thống kê: Glivenko–Cantelli.* Khi áp dụng vào hàm phân phối thực nghiệm $\widehat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i \leq x)$:

- **Hội tụ điểm:** Theo Luật số lớn (LLN), với mỗi ngưỡng x cố định, biến ngẫu nhiên $\mathbb{I}(X_i \leq x)$ là biến Bernoulli, nên $\widehat{F}_n(x) \xrightarrow{P} F(x)$.
- **Hội tụ đều (Định lý Glivenko–Cantelli):** Kết quả mạnh hơn rất nhiều:

$$\|\widehat{F}_n - F\|_\infty = \sup_{x \in \mathbb{R}} |\widehat{F}_n(x) - F(x)| \xrightarrow{a.s.} 0.$$

Nghĩa là sai số trên toàn bộ miền giá trị đồng thời co về 0, đảm bảo đường cong thực nghiệm tiến sát hoàn toàn vào đường cong lý thuyết.

C. Ví dụ Thực tế & Đa ngành (The “Where”)

- **Cybersecurity & Threat Detection (KS-Test for Anomaly/Drift Detection):**
 - Để kiểm tra xem phân phối log truy cập hiện tại có bị tấn công (Data Drift / Adversarial Shift) so với phân phối chuẩn hay không, ta dùng **Kolmogorov–Smirnov Test**:

$$D_n = \sup_x |\widehat{F}_n(x) - F_0(x)|.$$

- Kiểm định này hoạt động được là nhờ **hội tụ đều**. Nếu chỉ có hội tụ điểm, giá trị D_n lớn nhất có thể bị thổi phồng ở các điểm biên (edge cases), gây ra tỷ lệ False Positive (báo động giả) cực cao khi phân tích log.

• **Machine Learning & Generalization Bounds (Vapnik–Chervonenkis / PAC Learning):**

- Trong ML, ta tối ưu hoá Empirical Risk $\widehat{R}_n(h) = \frac{1}{n} \sum L(h(x_i), y_i)$ để hy vọng True Risk $R(h) = \mathbb{E}[L(h(X), Y)]$ cũng nhỏ.
- Nếu thuật toán chỉ hội tụ điểm cho từng mô hình h , ta dễ gặp hiện tượng **Overfitting** (chọn được một model h có $\widehat{R}_n(h)$ rất nhỏ nhưng $R(h)$ lại rất lớn).
- Khái niệm **Uniform Convergence over Hypothesis Class** $\mathcal{H}$ ($\sup_{h \in \mathcal{H}} |\widehat{R}_n(h) - R(h)| \rightarrow 0$) là điều kiện nền tảng để đảm bảo mô hình không bị học vẹt.

Liên hệ: Slide tr. 16–17 (Glivenko–Cantelli); [W] Ch. 2. Xem thêm Câu 3.

Câu 8. Hội tụ theo phân phối và hội tụ theo xác suất có phải là một?

Convergence in distribution và *convergence in probability* có phải là một khái niệm không? Nếu không, quan hệ giữa chúng là gì?

Chốt nhanh

Không, hai khái niệm này **không phải là một**. *Convergence in probability* (hội tụ theo xác suất) là một điều kiện **mạnh hơn** và kéo theo *convergence in distribution* (hội tụ theo phân phối). Chiều ngược lại nhìn chung **không đúng** (trừ trường hợp giới hạn là một hằng số).

A. Motivation & Ý nghĩa (The “Why”)

Sự khác biệt cốt lõi nằm ở việc ta đang so sánh **giá trị cụ thể của các biến ngẫu nhiên trên cùng không gian mẫu** hay chỉ đang so sánh **hình dáng quy luật phân phối** của chúng.

- **Convergence in Probability** ($X_n \xrightarrow{P} X$ — so sánh giá trị thực tế):
 - *Bản chất*: X_n và X phải sống trên **cùng một không gian xác suất** $(\Omega, \mathcal{F}, P)$.
 - *Trực giác*: Với n đủ lớn, xác suất để giá trị cụ thể của $X_n(\omega)$ lệch khỏi $X(\omega)$ một khoảng đủ rất nhỏ ε sẽ tiến về 0. Nghĩa là X_n và X gần như biến thành “cùng một đại lượng” với từng kết cục ω .
- **Convergence in Distribution** ($X_n \xrightarrow{d} X$ hay $X_n \rightsquigarrow X$ — so sánh hình dáng/quy luật):
 - *Bản chất*: X_n và X **không cần** sống chung một không gian xác suất.
 - *Trực giác*: Ta hoàn toàn không quan tâm từng giá trị $X_n(\omega)$ có gần $X(\omega)$ hay không. Ta chỉ quan tâm đường cong phân phối xác suất (CDF/PDF) của X_n có biến đổi dần để khớp với đường cong phân phối của X hay không.

B. Chi tiết Toán học (The “How”)

1. *Định nghĩa chuẩn*. Cho dãy biến ngẫu nhiên $X_1, X_2, \dots, X_n$ và biến ngẫu nhiên X :

- **Hội tụ theo xác suất** ($X_n \xrightarrow{P} X$):

$$\forall \varepsilon > 0, \quad \lim_{n \rightarrow \infty} P(|X_n - X| > \varepsilon) = 0.$$

- **Hội tụ theo phân phối** ($X_n \xrightarrow{d} X$):

$$\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x) \quad \text{tại mọi điểm } x \text{ mà } F_X \text{ liên tục.}$$

(Tương đương: $\mathbb{E}[g(X_n)] \rightarrow \mathbb{E}[g(X)]$ với mọi hàm g liên tục và bị chặn.)

2. Mối quan hệ và hệ phân cấp (Hierarchy of Convergence).

Hội tụ hầu chắc chắn (almost sure) $\Rightarrow X_n \xrightarrow{P} X \Rightarrow X_n \xrightarrow{d} X$.

- **Định lý đảo đặc biệt:** Nếu giới hạn là một hằng số c (không phải biến ngẫu nhiên), thì hai khái niệm này tương đương:

$$X_n \xrightarrow{d} c \iff X_n \xrightarrow{P} c.$$

3. Phản ví dụ kinh điển: hội tụ theo phân phối NHƯNG KHÔNG hội tụ theo xác suất. Xét phép tung một đồng xu cân bằng:

- Cho $X \sim \text{Bernoulli}(0.5)$ nhận giá trị 1 (Ngửa) hoặc -1 (Sấp) với xác suất 0.5.
- Đặt dãy biến ngẫu nhiên $X_n = -X$ với mọi $n \geq 1$.

Phân tích:

1. Xét hội tụ theo phân phối ($X_n \xrightarrow{d} X$):

- $P(X_n = 1) = P(-X = 1) = P(X = -1) = 0.5$.
- $P(X_n = -1) = P(-X = -1) = P(X = 1) = 0.5$.
- Phân phối của X_n và X hoàn toàn giống hệt nhau ở mọi n . Do đó hiển nhiên $X_n \xrightarrow{d} X$.

2. Xét hội tụ theo xác suất ($X_n \xrightarrow{P} X$):

- Ta xét khoảng cách $|X_n - X| = |-X - X| = |-2X| = 2|X| = 2$ (luôn bằng 2 với xác suất 100%).
- Chọn $\varepsilon = 1$:

$$P(|X_n - X| > 1) = P(2 > 1) = 1 \neq 0 \quad \text{khi } n \rightarrow \infty.$$
- $\Rightarrow X_n$ **không thể** hội tụ theo xác suất về X . Dù hai biến có phân phối giống hệt nhau, chúng luôn trái dấu nhau ở mọi phép thử.

C. Ví dụ Thực tế & Đa ngành (The “Where”)

• Luật số lớn (WLLN) vs. Định lý Giới hạn Trung tâm (CLT):

- **Weak Law of Large Numbers:** $\bar{X}_n \xrightarrow{P} \mu$. Trung bình mẫu thực sự **bằng** giá trị kỳ vọng lý thuyết khi dữ liệu đủ lớn (ước lượng điểm nhất quán — consistent estimator).
- **Central Limit Theorem:** $\sqrt{n}(\bar{X}_n - \mu) / \sigma \xrightarrow{d} \mathcal{N}(0, 1)$. Đại lượng này không biến thành một con số cố định, mà **hình dáng sai số** của nó biến thành hình chuông Gauss chuẩn để ta tính khoảng tin cậy (confidence interval) và p-value.

• Cyber Security & IAM (Behavioral Analytics & Anomaly Detection):

- *Scenario:* Theo dõi độ trễ xác thực (authentication latency) T_n của một user.
- Nếu hệ thống yêu cầu $T_n \xrightarrow{P} T_{\text{baseline}}$: mỗi lần đăng nhập, thời gian phản hồi của người dùng phải sát khớp với hành vi gốc (nếu lệch $\rightarrow$ nghi ngờ replay attack hoặc bot script).
- Nếu hệ thống kiểm tra $T_n \xrightarrow{d} T_{\text{baseline}}$: hệ thống chỉ cần kiểm tra xem tổng thể phân phối độ trễ trong ngày có tuân theo profile chuẩn hay không (dùng kiểm định Kolmogorov–Smirnov), không bắt buộc từng phiên đơn lẻ phải giống nhau.

Liên hệ: Xem Câu 7 (hội tụ điểm/đều) và Câu 3 (tính chất của $\hat{F}_n$); [W] Ch. 5.

Câu 9. Không gian hàm là gì, và vì sao F chưa biết lại có mật độ $f = F'$?

Không gian hàm (function space) nghĩa là gì trong bài toán ước lượng mật độ, và vì sao một hàm phân phối F chưa biết lại có mật độ $f = F'$?

Chốt nhanh

Ước lượng phi tham số phải tìm nghiệm trong một *không gian hàm* vô hạn chiều (L^1 , L^2 , Sobolev H^s) thay vì trong $\mathbb{R}^k$, vì đối tượng cần tìm là cả một hàm số chứ không phải vài con số. Còn $f = F'$ tồn tại **không phải hiển nhiên**: nó là hệ quả của định lý Radon–Nikodym khi độ đo P_X *tuyệt đối liên tục* theo độ đo Lebesgue λ ; nếu $P_X \perp \lambda$ (ví dụ phân phối Cantor) thì F vẫn liên tục và tăng nhưng *không* có mật độ nào cả.

A. Motivation & Ý nghĩa (The “Why”)

Trong thống kê cổ điển (Parametric Estimation), không gian tìm kiếm là không gian Euclid hữu hạn chiều $\mathbb{R}^k$ (ví dụ tìm vector tham số $\theta = (\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}^+$). Khi bước sang **Non-parametric Density Estimation**, ta không giả định hàm mật độ thuộc bất kỳ họ tham số cụ thể nào. Mục tiêu lúc này là tìm một **hàm số** f chưa biết.

Để làm được điều đó, ta phải mở rộng không gian tìm kiếm từ vector hữu hạn chiều sang **không gian hàm (Function Space)** — một không gian vector vô hạn chiều được trang bị cấu trúc metric/norm để đo lường khoảng cách sai số giữa hàm ước lượng $\hat{f}$ và chân lý f .

Về mặt dữ liệu thực nghiệm, mẫu quan sát $X_1, \dots, X_n$ cho phép ta dễ dàng xấp xỉ hàm phân phối tích lũy $F(x) = P(X \leq x)$ thông qua hàm phân phối thực nghiệm (Empirical CDF) $F_n(x)$. Tuy nhiên, $F(x)$ chỉ cung cấp thông tin tích lũy toàn cục. Để xác định tốc độ tập trung xác suất cục bộ (local concentration of probability) hay phát hiện các bất thường tại từng điểm dữ liệu, ta cần tốc độ biến thiên tức thời của xác suất, tức hàm mật độ $f(x) = F'(x)$.

B. Chi tiết Toán học (The “How”)

1. *Không gian hàm trong Density Estimation.* Một không gian hàm $\mathcal{F}$ là một không gian vector mà mỗi phần tử của nó là một hàm số $g : \mathbb{R}^d \rightarrow \mathbb{R}$. Trong Density Estimation, ba lớp không gian đóng vai trò then chốt:

- **Không gian Lebesgue $L^p(\mathbb{R})$:** tập hợp các hàm đo được thỏa mãn $\int |g(x)|^p dx < \infty$.
 - $L^1(\mathbb{R})$: ràng buộc cốt lõi của hàm mật độ xác suất ($\|f\|_{L^1} = \int |f(x)| dx = 1, f(x) \geq 0$).
 - $L^2(\mathbb{R})$: không gian Hilbert trang bị tích vô hướng $\langle u, v \rangle = \int u(x)v(x) dx$ và chuẩn $\|u\|_{L^2} = \sqrt{\int u(x)^2 dx}$. Đây là không gian tiêu chuẩn để tính sai số toàn phương tích hợp **MISE (Mean Integrated Squared Error)**:

$$\text{MISE}(\hat{f}) = \mathbb{E}[\|\hat{f} - f\|_{L^2}^2] = \int \text{Var}(\hat{f}(x)) dx + \int \text{Bias}^2(\hat{f}(x)) dx.$$

- **Không gian Sobolev $H^s(\mathbb{R})$:** không gian chứa các hàm $f \in L^2(\mathbb{R})$ có các đạo hàm suy rộng (weak derivatives) đến cấp s cũng thuộc $L^2(\mathbb{R})$. Độ trơn s trong không gian Sobolev đặt ra giới hạn lý thuyết cho tốc độ hội tụ minimax tối ưu của bài toán ước lượng:

$$R_n^* \asymp n^{-\frac{2s}{2s+1}}.$$

2. *Tại sao hàm phân phối F lại có mật độ $f = F'$?* Mối quan hệ giữa F và f được thiết lập chặt chẽ thông qua **lý thuyết độ đo (Measure Theory)**:

- **Độ đo xác suất và độ đo Lebesgue.** Xét không gian xác suất $(\Omega, \mathcal{F}, P)$ và biến ngẫu nhiên X . X cảm sinh ra một độ đo xác suất P_X trên không gian Borel $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$:

$$P_X(B) = P(X^{-1}(B)) = P(X \in B) \quad \forall B \in \mathcal{B}(\mathbb{R}).$$

Gọi λ là độ đo Lebesgue chuẩn trên $\mathbb{R}$.

- **Tính tuyệt đối liên tục (Absolute Continuity).** Độ đo P_X được gọi là tuyệt đối liên tục đối với λ (ký hiệu $P_X \ll \lambda$) nếu

$$\forall B \in \mathcal{B}(\mathbb{R}), \quad \lambda(B) = 0 \implies P_X(B) = 0.$$

- **Định lý Radon–Nikodym.** Nếu $P_X \ll \lambda$, thì tồn tại duy nhất (hầu khắp nơi — *almost everywhere*, a.e., theo độ đo λ) một hàm đo được $f : \mathbb{R} \rightarrow [0, \infty)$ khả tích Lebesgue sao cho với mọi tập Borel B :

$$P_X(B) = \int_B f(x) d\lambda(x).$$

Hàm $f = \frac{dP_X}{d\lambda}$ được gọi là **đạo hàm Radon–Nikodym** của P_X theo λ , chính là **hàm mật độ xác suất (Probability Density Function — PDF)**.

- **Định lý cơ bản của giải tích Lebesgue (Lebesgue Differentiation Theorem).** Khi $B = (-\infty, x]$, hàm phân phối tích lũy là

$$F(x) = P_X((-\infty, x]) = \int_{-\infty}^x f(t) dt.$$

Do $f \in L^1(\mathbb{R})$, hàm $F(x)$ là hàm tuyệt đối liên tục trên mọi đoạn hữu hạn. Theo định lý vi phân Lebesgue, $F(x)$ khả vi hầu khắp nơi trên $\mathbb{R}$ và

$$F'(x) = \lim_{h \rightarrow 0} \frac{F(x+h) - F(x)}{h} = \lim_{h \rightarrow 0} \frac{1}{h} \int_x^{x+h} f(t) dt = f(x) \quad \text{a.e. } [\lambda].$$

Điều kiện biên / Phản ví dụ (Singular Distribution): Nếu F liên tục nhưng **không tuyệt đối liên tục** (ví dụ: hàm phân phối Cantor / Devil's Staircase), ta có $F'(x) = 0$ hầu khắp nơi, nhưng F vẫn tăng liên tục từ 0 lên 1. Khi đó $P_X \perp \lambda$ (hai độ đo trực giao nhau) và **không tồn tại hàm mật độ f theo nghĩa Lebesgue thông thường**.

C. Ví dụ Thực tế & Đa ngành (The “Where”)

- **Bản chất của Empirical Data trong Security/IAM Logs.** Trong bài toán User and Entity Behavior Analytics (UEBA), log hành vi như kích thước gói tin chuyển giao (outbound bytes) hay thời gian giữa các lần gửi request tạo ra một tập điểm rời rạc. Hàm phân phối thực nghiệm $F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i \leq x)$ là một hàm bậc thang. Đạo hàm cổ điển $F'_n(x)$ bằng 0 ở khắp nơi ngoại trừ các điểm nhảy (tại đó là các hàm Dirac delta $\delta(x - X_i)$). Phân phối thực nghiệm này không nằm trong $L^2(\mathbb{R})$ dưới dạng hàm thông thường.
- **Kernel Smoothing như phép chiếu không gian hàm.** Kỹ thuật Kernel Density Estimation (KDE) thực chất là tích chập (convolution) F_n với một hàm nhân trơn $K \in H^s(\mathbb{R})$:

$$\hat{f}_h(x) = (F'_n * K_h)(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right).$$

Phép biến đổi này chiếu phân phối dữ liệu rời rạc về lại một không gian hàm trơn Sobolev H^s , cho phép tính giá trị $f(x)$ liên tục. Từ đó, ta tính được Log-Likelihood $\log \hat{f}(x)$ để gán điểm rủi ro (Risk Score) cho các hành vi bất thường trong kiến trúc Zero Trust.

Liên hệ: Nối tiếp Câu 2 (vì sao CDF luôn tồn tại còn PDF thì không) và Câu 11 (phân rã bias–variance, tốc độ minimax); [W] Ch. 6 (Density Estimation).

Câu 10. Vì sao phương pháp phi tham số hội tụ chậm hơn tham số?

Tại sao các phương pháp phi tham số lại bị coi là hội tụ chậm hơn so với các phương pháp tham số?

Chốt nhanh

Vì **không gian giả thuyết** lớn hơn hẳn: tham số chỉ phải tìm k con số nên MSE đạt $\mathcal{O}(n^{-1})$ độc lập với số chiều d ; phi tham số phải tìm cả một hàm trong không gian vô hạn chiều, ước lượng cục bộ trên lân cận thể tích h^d , nên tốc độ tối ưu chỉ là $\mathcal{O}(n^{-2s/(2s+d)})$ — xấu đi theo d . Đó chính là lời nguyền số chiều.

A. Motivation & Ý nghĩa (The “Why”)

Sự khác biệt về tốc độ hội tụ bắt nguồn từ **kích thước của không gian giả thuyết (Hypothesis Space)**:

- **Phương pháp tham số (Parametric)**: Giả định phân phối thuộc một họ hàm hữu hạn chiều $\mathcal{P} = \{f_\theta : \theta \in \Theta \subset \mathbb{R}^k\}$. Ta chỉ cần ước lượng k con số (ví dụ: μ, σ^2). Khi số chiều dữ liệu d tăng lên, nếu mô hình đúng (well-specified), bài toán vẫn giữ nguyên số lượng tham số cần tìm.
- **Phương pháp phi tham số (Non-parametric)**: Giả thuyết nằm trong một không gian hàm vô hạn chiều (như Sobolev space H^s hoặc Hölder class $\Sigma(s, L)$). Không có giả định hình dạng tiên nghiệm, thuật toán phải tự “khám phá” cục bộ cấu trúc hàm mật độ tại từng lân cận điểm x .

Khi dữ liệu phân tán trong không gian nhiều chiều, thể tích không gian tăng theo hàm mũ, dẫn đến hiện tượng dữ liệu cực kỳ thưa thớt (**Lời nguyền số chiều — Curse of Dimensionality**). Để phủ kín các lân cận cục bộ và làm mượt hàm mật độ, số lượng mẫu n đòi hỏi phải tăng theo cấp số nhân.

B. Chi tiết Toán học (The “How”)

1. **Tốc độ hội tụ của Parametric Estimation (MLE)**. Xét ước lượng hợp lý cực đại (MLE) $\hat{\theta}_n$ cho tham số $\theta_0 \in \mathbb{R}^k$. Dưới các điều kiện chính quy (regularity conditions) chuẩn:

- Theo **định lý giới hạn trung tâm (CLT) cho MLE**:

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} \mathcal{N}(0, I(\theta_0)^{-1}),$$

với $I(\theta_0)$ là ma trận thông tin Fisher.

- Sai số toàn phương trung bình (MSE) giảm theo tốc độ

$$\text{MSE}(\hat{\theta}_n) = \mathbb{E}[\|\hat{\theta}_n - \theta_0\|^2] = \mathcal{O}\left(\frac{1}{n}\right) = \mathcal{O}(n^{-1}).$$

- Đặc biệt, sai số ước lượng hàm mật độ tham số $\|\hat{f} - f\|_{L_2}^2$ cũng đạt tốc độ $\mathcal{O}(n^{-1})$ bất kể số chiều d của dữ liệu.

2. **Tốc độ hội tụ của Non-parametric Estimation (KDE)**. Xét ước lượng KDE đa chiều với mẫu $X_1, \dots, X_n \in \mathbb{R}^d$ và ma trận băng thông $H = h^2 I_d$:

$$\hat{f}_h(x) = \frac{1}{nh^d} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right).$$

Phân rã sai số toàn phương tích hợp tiệm cận (**AMISE**):

- **Variance:** Do ước lượng cục bộ trên một hình cầu thể tích cỡ h^d , số lượng mẫu rơi vào lân cận của x tỷ lệ với nh^d . Phương sai tiệm cận là

$$\text{Var}(\hat{f}_h(x)) \approx \frac{f(x)R(K)}{nh^d} \Rightarrow \int \text{Var}(\hat{f}_h(x))dx = \mathcal{O}\left(\frac{1}{nh^d}\right),$$

(với $R(K) = \int K(u)^2 du$).

- **Bias:** Sử dụng khai triển Taylor bậc 2 cho hàm mật độ trơn bậc 2 ($f \in C^2$):

$$\mathbb{E}[\hat{f}_h(x)] - f(x) \approx \frac{1}{2}h^2\mu_2(K)\nabla^2 f(x) \Rightarrow \int \text{Bias}^2(\hat{f}_h(x))dx = \mathcal{O}(h^4),$$

(với $\mu_2(K) = \int u^2 K(u)du$).

- **Tối ưu hoá AMISE:**

$$\text{AMISE}(h) = \mathcal{O}(h^4) + \mathcal{O}\left(\frac{1}{nh^d}\right).$$

Để cân bằng Bias và Variance, ta đạo hàm theo h và giải:

$$\frac{d}{dh}\text{AMISE}(h) = 4c_1h^3 - \frac{d \cdot c_2}{nh^{d+1}} = 0 \Rightarrow h^* \asymp n^{-\frac{1}{4+d}}.$$

- **Tốc độ hội tụ tối ưu (Minimax Optimal Rate):** Thế h^* trở lại biểu thức AMISE:

$$\text{MISE}(\hat{f}) \asymp (h^*)^4 \asymp \left(n^{-\frac{1}{4+d}}\right)^4 = \mathcal{O}\left(n^{-\frac{4}{4+d}}\right).$$

Tổng quát hoá với không gian Sobolev $H^s(\mathbb{R}^d)$ (độ trơn cấp s):

$$\text{MISE}^* \asymp n^{-\frac{2s}{2s+d}}.$$

Phương diện	Parametric (MLE)	Non-parametric (KDE)
Không gian giả thuyết	Hữu hạn chiều ($\Theta \subset \mathbb{R}^k$)	Vô hạn chiều ($f \in H^s(\mathbb{R}^d)$)
Tốc độ hội tụ MSE/MISE	$\mathcal{O}(n^{-1})$ (độc lập với d)	$\mathcal{O}(n^{-\frac{2s}{2s+d}})$ (phụ thuộc vào d)
Khi $d = 1, s = 2$	$\mathcal{O}(n^{-1}) = \mathcal{O}(n^{-1.00})$	$\mathcal{O}(n^{-4/5}) = \mathcal{O}(n^{-0.80})$
Khi $d = 4, s = 2$	$\mathcal{O}(n^{-1}) = \mathcal{O}(n^{-1.00})$	$\mathcal{O}(n^{-4/8}) = \mathcal{O}(n^{-0.50})$
Khi $d = 16, s = 2$	$\mathcal{O}(n^{-1}) = \mathcal{O}(n^{-1.00})$	$\mathcal{O}(n^{-4/20}) = \mathcal{O}(n^{-0.20})$

Hệ quả số mẫu: Để giảm sai số đi 10 lần ở $d = 16$ ($s = 2$), phương pháp tham số cần gấp 10 lần mẫu (10^1), trong khi phi tham số cần gấp $10^{20/4} = 10^5 = 100,000$ lần mẫu.

C. Ví dụ Thực tế & Đa ngành (The “Where”)

- **Security Logs & Insider Threat Detection (CERT Dataset / UEBA):** Nếu ta mô hình hoá hành vi tải file của người dùng bằng một vector đặc trưng $d = 20$ chiều (gồm: dung lượng file, giờ trong ngày, tần suất request, entropy đường dẫn, độ dài session, v.v.):
 - **Parametric (Multivariate Gaussian / GMM):** Hội tụ rất nhanh chỉ với vài nghìn log lines, nhưng nếu hành vi người dùng là phân phối đa đỉnh phức tạp hoặc lệch (skewed/multimodal) mà mô hình không khớp, ta sẽ bị **Misspecification Bias** vĩnh viễn không thể triệt tiêu dù $n \rightarrow \infty$.

- **Standard KDE:** Không chịu bias mô hình tiên nghiệm, nhưng với $d = 20$, tốc độ hội tụ $\mathcal{O}(n^{-4/24}) = \mathcal{O}(n^{-1/6})$ khiến việc ước lượng trên streaming logs đòi hỏi hàng tỷ records và tính toán cực kỳ nặng nề.
- **Hướng giải quyết trong Engineering/MLOps:** Để khắc phục tốc độ hội tụ chậm của Non-parametric trên không gian nhiều chiều:
 1. **Giảm chiều (Dimensionality Reduction):** Chiếu dữ liệu xuống manifold chiều thấp ($d \leq 3$) bằng UMAP, PCA hoặc Autoencoder trước khi áp KDE.
 2. **Mô hình lai (Semiparametric / Normalizing Flows):** Sử dụng mạng nơ-ron khả nghịch (Invertible Neural Networks) biến đổi phân phối phức tạp về một phân phối chuẩn đa biến $z \sim \mathcal{N}(0, I)$, kết hợp ưu điểm hội tụ tham số với tính linh hoạt của phi tham số.

Liên hệ: Định lượng lại đánh đổi đã nêu ở Câu 1; dùng không gian hàm & MISE của Câu 9 và ký hiệu $\mathcal{O}, \asymp$ ở Câu 11; [W] Ch. 6.

Bảng ký hiệu & từ vựng tiệm cận thường gặp

Câu 11. Bảng ký hiệu tiệm cận, sai số và hội tụ nghĩa là gì?

Giải nghĩa bộ ký hiệu hay gặp trong giáo trình: $o, O, \sim, \asymp, \xrightarrow{a.s.}, \xrightarrow{P}, \rightsquigarrow$; bias, se, MSE, Φ, z_α . Chúng liên hệ với nhau thế nào?

Chốt nhanh

Bảng ký hiệu này (thường thấy trong các giáo trình Thống kê Nâng cao & Lý thuyết Tiệm cận kinh điển như *All of Nonparametric Statistics* của Larry Wasserman) là **bộ từ vựng nền tảng** để đo lường chất lượng của các thuật toán và mô hình ước lượng khi kích thước mẫu $n \rightarrow \infty$.

A. Motivation & Ý nghĩa (The “Why”)

Để đánh giá một mô hình thống kê / Machine Learning khi có nhiều dữ liệu, ta cần trả lời 3 câu hỏi cốt lõi:

1. **Tốc độ tăng trưởng / suy giảm thế nào?** → Dùng **ký hiệu tiệm cận** (asymptotics: $o, O, \sim, \asymp$).
2. **Ước lượng có tiến về đúng giá trị thực hay không?** → Dùng các **dạng hội tụ ngẫu nhiên** ($\xrightarrow{a.s.}, \xrightarrow{P}, \rightsquigarrow$).
3. **Sai số cụ thể đo bằng gì và dựng khoảng tin cậy ra sao?** → Dùng **chỉ số sai số & phân phối chuẩn** (bias, se, MSE, Φ, z_α).

Ba nhóm ký hiệu này không đứng rời rạc mà kết nối chặt chẽ thành một pipeline: **đo lường sai số** (MSE) → **khảo sát tốc độ co lại theo n** (O, o) → **thiết lập định lý giới hạn** ($\rightsquigarrow \Phi$) → **suy diễn thống kê** (z_α).

B. Chi tiết Toán học & Mối liên hệ (The “How”)

Ước lượng $\hat{\theta}_n$ — đi theo ba nhánh:

1. **Sai số mẫu hữu hạn:** $MSE = \text{bias}^2 + \text{se}^2$.
2. **Tốc độ thu nhỏ sai số:** $MSE = O(1/n)$ hoặc $o(1)$.
3. **Tiệm cận vô hạn:**
 - Hội tụ mạnh: $\hat{\theta}_n \xrightarrow{a.s.} \theta$ (nhất quán mạnh)
 - Hội tụ theo xác suất: $\hat{\theta}_n \xrightarrow{P} \theta$ (nhất quán yếu)
 - Chuẩn hoá tiệm cận: $\frac{\hat{\theta}_n - \theta}{\widehat{se}} \rightsquigarrow \mathcal{N}(0, 1)$ (CDF là Φ)
 $\hookrightarrow$ Dựng khoảng tin cậy: $\hat{\theta}_n \pm z_{\alpha/2} \cdot \widehat{se}$

1. **Nhóm tiệm cận giải tích (Asymptotic Notations).** Nhóm này đo tương quan tốc độ giữa hai đại lượng a_n và b_n :

- $x_n = o(a_n)$ (**little-o**): x_n nhỏ hơn và tắt nhanh hơn hẳn a_n ($\lim \frac{x_n}{a_n} = 0$).
- $x_n = O(a_n)$ (**big-O**): x_n bị chặn trên bởi a_n về bậc độ lớn (cùng bậc hoặc nhỏ hơn).
- $a_n \sim b_n$ (**asymptotic equivalence**): a_n và b_n tiến sát nhau theo tỷ lệ 1:1 ($\lim \frac{a_n}{b_n} = 1$).
- $a_n \asymp b_n$ (**same order / tight bound**): a_n và b_n cùng tốc độ tăng/giảm (tương đương $\Theta(b_n)$ trong khoa học máy tính).

2. **Nhóm đo lường sai số của ước lượng (Estimator Properties).** Cho $\hat{\theta}_n$ là ước lượng của tham số đích θ :

- $\text{bias} = \mathbb{E}(\hat{\theta}_n) - \theta$: sai số hệ thống (độ lệch tâm). Ước lượng là không chệch (unbiased) nếu $\text{bias} = 0$.
- $\text{se} = \sqrt{\mathbb{V}(\hat{\theta}_n)}$: độ lệch chuẩn của ước lượng (đo độ phân tán/dao động quanh tâm). Vì $\mathbb{V}(\hat{\theta}_n)$ chứa tham số chưa biết, ta dùng $\widehat{se}$ (cắm dữ liệu mẫu vào) để tính toán thực tế.
- **Mối liên hệ MSE Decomposition (định lý phân rã bias–variance):**

$$MSE = \mathbb{E}[(\hat{\theta}_n - \theta)^2] = \text{bias}^2 + \text{se}^2.$$

3. **Nhóm dạng hội tụ ngẫu nhiên (Modes of Convergence).** Thứ bậc chặt chẽ giữa các khái niệm hội tụ:

$$X_n \xrightarrow{a.s.} X \implies X_n \xrightarrow{P} X \implies X_n \rightsquigarrow X.$$

- **Consistency (tính nhất quán):** Nếu $MSE \rightarrow 0$ (hay $\text{bias} = o(1)$ và $\text{se} = o(1)$), theo bất đẳng thức Chebyshev kéo theo $\hat{\theta}_n \xrightarrow{P} \theta$.
- **Strong consistency:** Khi $\hat{\theta}_n \xrightarrow{a.s.} \theta$ (theo luật mạnh số lớn — SLLN).

4. **Nhóm phân phối chuẩn & suy diễn (Asymptotic Normality).**

- $\Phi(z)$: hàm phân phối tích lũy của phân phối chuẩn $\mathcal{N}(0, 1)$.
- $z_\alpha = \Phi^{-1}(1 - \alpha)$: điểm phân vị trên (sao cho $P(Z > z_\alpha) = \alpha$).
- **Kết nối suy diễn:** Theo định lý giới hạn trung tâm (CLT):

$$\frac{\hat{\theta}_n - \theta}{\widehat{se}} \rightsquigarrow Z \sim \mathcal{N}(0, 1) \quad (\text{có CDF là } \Phi).$$

Từ đó, khoảng tin cậy $(1 - \alpha)$ xấp xỉ của θ được viết thành

$$\left[\hat{\theta}_n - z_{\alpha/2} \widehat{se}, \hat{\theta}_n + z_{\alpha/2} \widehat{se} \right].$$

C. Ví dụ Thực tế & Đa ngành (The “Where”)

- **Cyber Security & IAM (Real-time Anomaly Scoring / Rate-Limiter):**

- Đặt θ là tần suất đăng nhập trung bình thực sự của một User/Role trong giờ cao điểm. Ta dùng $\hat{\theta}_n$ (trung bình trượt qua n log events).
- Ta chứng minh thuật toán có bias = $O(1/n)$ và se $\asymp 1/\sqrt{n}$, suy ra $\text{MSE} = O(1/n) \rightarrow 0 \Rightarrow \hat{\theta}_n \xrightarrow{P} \theta$ (mô hình không bị lệch khi log dồn về).
- Ngưỡng cảnh báo tự động (anomaly threshold) cho hệ thống SIEM/SOC được dựng bằng khoảng tin cậy: $\text{Threshold} = \hat{\theta}_n + z_{0.005} \cdot \widehat{\text{se}}$ (với mức tin cậy 99%).

- **Machine Learning & MLOps (Generalization Rate):**

- Trong Non-parametric Regression / KDE, sai số xấp xỉ không đạt tốc độ thông thường $O(1/n)$ mà bị làm chậm bởi hiện tượng số chiều (curse of dimensionality): $\text{MSE} \asymp n^{-\frac{2\beta}{2\beta+d}}$. Ta dùng ký hiệu $a_n \asymp b_n$ để khẳng định tốc độ này là tối ưu (minimax optimal).

Liên hệ: Dùng chung cho toàn bộ tài liệu; xem Câu 8 (thứ bậc hội tụ) và Câu 3 (áp dụng cho $\widehat{F}_n$).