THỐNG KÊ PHI THAM SỐ

Giáo trình lấy gốc và luyện giải bài tập

EDF, histogram, KDE, phép chiếu và hồi quy phi tham số

Tài liệu tự học dựa trên slide Chương 1–2 trong thư mục môn học, Wasserman [4] và Tsybakov [5]. Các chứng minh và bài mẫu được diễn giải lại để đọc độc lập. Đây là tài liệu học tập; danh sách bài luyện không được coi là đề thi chính thức.

Mục lục

Cách học và kiến thức nền **5**

1 Hàm phân phối thực nghiệm và nguyên lý thế **8**
1.1 Từ dữ liệu đến một phân phối 8
1.2 Kỳ vọng, phương sai và hiệp phương sai 8
1.3 Nhất quán và CLT tại một điểm 9
1.4 Hội tụ đều và băng tin cậy DKW 10
1.5 Functional và nguyên lý thế 10
1.5.1 Functional tuyến tính 11
1.5.2 Trung bình, phương sai và độ lệch 11
1.5.3 Tương quan và quantile 12
1.6 Kiểm định sự phù hợp 12
1.6.1 Kolmogorov–Smirnov 12
1.6.2 Cramér–von Mises 13
1.6.3 Anderson–Darling 13
1.7 Tự kiểm tra trước khi sang Chương 2 14

2 Ước lượng mật độ bằng histogram **15**
2.1 Đếm trong ô rồi chia cho độ rộng 15
2.2 Kỳ vọng và phương sai chính xác 15
2.3 Taylor và độ chệch tại một điểm 16
2.4 Từ sai số tại điểm đến MISE 16
2.4.1 Tích phân bình phương chệch: nguồn gốc 1/12 16
2.4.2 Phương sai tích phân: công thức chính xác 17
2.4.3 Băng thông và tốc độ tối ưu 17
2.5 Leave-one-out cross-validation 17
2.6 Bốn hạn chế cốt lõi 19

3 Ước lượng mật độ bằng nhân **20**
3.1 Định nghĩa và tính hợp lệ 20
3.1.1 KDE liên hệ với EDF như thế nào? 20
3.2 Bảy kernel và đạo hàm 20
3.2.1 Khả vi tại điểm nối 21
3.2.2 Ước lượng đạo hàm mật độ 21
3.3 Chứng minh độ chệch của KDE 22
3.3.1 Ý nghĩa hình học của độ cong 23
3.4 Chứng minh phương sai và AMSE 23
3.5 AMISE và băng thông toàn cục 24
3.6 Quy tắc tham chiếu chuẩn và Silverman 25
3.6.1 Dẫn ra hệ số 1.06 25
3.6.2 Các phiên bản thực hành cần phân biệt 25

3.7 LOOCV cho KDE: công thức hữu hạn mẫu chính xác . . . 26
3.8 Nhân bậc cao . . . 27
3.9 Lớp Hölder và chặn rủi ro . . . 27
3.9.1 Định nghĩa không suy biến ở bậc nguyên . . . 27
3.9.2 Chặn bias bằng Taylor có phần dư Hölder . . . 27
3.9.3 Chặn variance và MSE . . . 28
3.9.4 Minimax: vì sao đây là tốc độ tốt nhất? . . . 28
3.10 Chệch biên và cách xử lý . . . 29
3.10.1 Phản xạ . . . 29
3.10.2 Boundary kernel . . . 29
3.11 Suy luận thống kê cho mật độ: kiểm soát chệch . . . 30

4 Ước lượng chiếu và lựa chọn mô hình 31
4.1 Bắt đầu bằng ba câu hỏi, chưa cần toán cao cấp . . . 31
4.2 Một ví dụ histogram dùng xuyên suốt chương . . . 31
4.2.1 Dữ liệu và ba cách chia ô . . . 31
4.2.2 Tại sao đây đã là một bài toán chọn mô hình? . . . 32
4.3 Hàm cơ sở và hệ số: đọc như một công thức ghép hình . . . 32
4.3.1 Trước tiên, dùng hai hình chữ nhật . . . 32
4.3.2 Tại sao trong slide lại có căn bậc hai? . . . 32
4.3.3 Tính hệ số từ mẫu, rồi ghép lại . . . 33
4.4 Phân biệt ba đường: thật, xấp xỉ và ước lượng . . . 33
4.4.1 Vì sao gọi là “chiếu”? . . . 34
4.5 Đo sai số và hiểu Pythagoras bằng một ví dụ . . . 34
4.5.1 Chuẩn L2 chỉ là tích phân sai khác bình phương . . . 34
4.5.2 Ví dụ với một mật độ thật được cho để luyện tính . . . 34
4.5.3 Chứng minh vì sao hai phần cộng được . . . 35
4.5.4 Bias–variance đọc bằng lời . . . 35
4.6 Contrast: một điểm số tính được khi không biết mật độ thật . . . 36
4.6.1 Vì sao phải tạo điểm số khác? . . . 36
4.6.2 Tại sao cực tiểu contrast cho đúng hệ số mẫu? . . . 36
4.7 Lựa chọn mô hình: tính điểm rồi cộng phạt . . . 37
4.7.1 Vì sao contrast chưa đủ? . . . 37
4.7.2 Tính tất cả điểm số trên mẫu tám quan sát . . . 37
4.7.3 Giải mã công thức trên slide . . . 37
4.8 Oracle và thích nghi: hiểu lời hứa của định lý . . . 38
4.8.1 Oracle là người so sánh tưởng tượng biết mật độ thật . . . 38
4.8.2 Bất đẳng thức oracle nói gì bằng lời? . . . 38
4.8.3 Thích nghi nghĩa là tự điều chỉnh mức chi tiết . . . 38
4.9 Năm câu tự kiểm tra trước khi đọc chứng minh sâu . . . 39
4.10 Đọc thêm: chuỗi trực chuẩn và cơ sở lượng giác . . . 39
4.10.1 Mở rộng từ hai hình chữ nhật sang nhiều hình dạng . . . 39
4.10.2 Sin và cos cho một cách ghép khác . . . 39
4.11 Đọc thêm: rủi ro và tốc độ hội tụ . . . 40
4.11.1 Từ trực chuẩn đến tổng bình phương hệ số . . . 40
4.11.2 Vì sao chặn trên variance có dạng số chiều chia cỡ mẫu? . . . 40
4.11.3 Bỏ hằng số không làm đổi mô hình tốt nhất . . . 40
4.11.4 Độ trơn ảnh hưởng số chiều như thế nào? . . . 41
4.12 Đọc thêm: phác thảo chứng minh oracle . . . 41
4.12.1 Nếu dữ liệu nằm trên một khoảng khác . . . 42

5 Hồi quy phi tham số và các mở rộng **43**
5.1 Mục tiêu hồi quy khác mục tiêu mật độ 43
5.2 Nadaraya–Watson từ bình phương tối thiểu cục bộ 43
5.2.1 Từ tỷ số mật độ đến công thức NW 43
5.3 Design bias: thành phần phụ thuộc mật độ thiết kế 44
5.4 Local linear: hệ phương trình và trọng số 45
5.5 Vì sao local linear giảm design bias và chệch biên? 45
5.5.1 Chứng minh trực tiếp bằng tái tạo tuyến tính 45
5.5.2 Hằng số tại điểm nội và tại biên 46
5.5.3 Phương sai và điều kiện sử dụng 46
5.6 Root–Unroot: từ số đếm đến hồi quy 47
5.6.1 Binning và xấp xỉ Poisson 47
5.6.2 Lấy căn để ổn định phương sai 47
5.6.3 Hồi quy, lấy phần dương và chuyển ngược 47
5.7 Root–Unroot và băng tin cậy: mục tiêu nào được phủ? 48
5.8 KDE nhiều chiều và lời nguyền số chiều 48

6 Ngân hàng bài tập có lời giải từng bước **50**
6.1 Dạng 1: tính KDE và đạo hàm 50
6.2 Dạng 2: tích phân hằng số kernel 52
6.3 Dạng 3: bandwidth và cross-validation 53
6.4 Dạng 4: kiểm định KS từng bước 55
6.5 Bốn bài chứng minh củng cố 56
6.6 Cách tự chấm bài 58

A Bảng tra cứu, nguồn và tái lập **59**
A.1 Các hằng số kernel 59
A.2 Bảng công thức và điều kiện tối thiểu cần nhớ 59
A.3 Bản đồ nguồn để đọc sâu 60
A.3.1 Các điểm được làm rõ khi đối chiếu 60
A.4 Tái lập bản PDF và kiểm chứng 61

Tài liệu tham khảo **62**

Cách học và kiến thức nền

Lộ trình học

Hãy đọc phần nền này trước, rồi học Chương 1–3 theo thứ tự. Chương 4 dùng tích vô hướng và trực chuẩn; Chương 5 dùng thêm bình phương tối thiểu. Trong Chương 6, nhóm bài tính KDE chỉ cần định nghĩa, nhưng nhóm bandwidth cần hiểu bias–variance. Với mỗi chứng minh, tự viết lại phép đổi biến và kiểm tra điều kiện trước khi xem lời giải.

Mục tiêu của "phi tham số" là không cố định mật độ hoặc hàm hồi quy trong một họ hữu hạn chiều như $\{N(\mu, \sigma^2)\}$. Ta vẫn có giả thiết: mẫu độc lập, độ trơn, miền giá đỡ, moment và mật độ thiết kế. Càng ít ràng buộc về hình dạng, càng cần dữ liệu để ước lượng cả một hàm.

Bảng ký hiệu

Ký hiệu	Ý nghĩa
$X_1, \dots, X_n$	Mẫu i.i.d. (độc lập, cùng phân phối), trừ khi ghi khác.
$F(x)$, $f(x)$	CDF $\mathbb{P}(X \le x)$ và mật độ, nếu phân phối tuyệt đối liên tục.
$\widehat{F}_n$, $\hat{f}_h$	EDF và KDE; dấu mũ biểu thị đại lượng tính từ mẫu.
$h > 0$, D	Băng thông hoặc độ rộng ô; số chiều mô hình phép chiếu.
p_j, $\hat{p}_j$	Xác suất thật trong ô B_j; tần suất quan sát trong ô.
K, $\mu_j(K)$	Kernel; moment $\int u^j K(u)\,du$.
$R(g)$	$\int g(x)^2\,dx$; ở đây chữ R trong $R(g)$ không phải ký hiệu rủi ro khác.
$\|g\|_2^2$	$\int g^2$ trên miền đang xét.
Bias, Var	Chệch có dấu và phương sai lấy mẫu của ước lượng.
ISE, MISE	Sai số bình phương tích phân của một mẫu; kỳ vọng của sai số đó.
AMSE, AMISE	Xấp xỉ tiệm cận của MSE tại điểm và MISE toàn cục.
φ, Φ	Mật độ và CDF chuẩn tắc $N(0,1)$.
$r(x)$, $\sigma^2(x)$	$\mathbb{E}(Y \mid X = x)$ và $\mathrm{Var}(Y \mid X = x)$.

CDF, mật độ và xác suất

Một CDF không giảm, liên tục phải và có giới hạn 0, 1 tại hai đầu trục số. Nếu F tuyệt đối liên tục thì $F(x) = \int_{-\infty}^{x} f(t)\,dt$, $f \ge 0$ và $\int f = 1$. Khi đó

$$\mathbb{P}(a < X \le b) = F(b) - F(a) = \int_a^b f(t)\,dt.$$

Mật độ là chiều cao, không phải xác suất tại điểm. Chẳng hạn mật độ đều trên $[0, 0.1]$ cao 10 nhưng diện tích là 1. Một phân phối rời rạc có CDF nhưng không có mật độ theo độ đo Lebesgue; EDF luôn là phân phối rời rạc.

Với một hàm a khả tích, $\int a\,dF$ là kỳ vọng $\mathbb{E}a(X)$. Nếu có mật độ thì bằng $\int a(x) f(x)\,dx$; với EDF thì bằng $n^{-1}\sum_i a(X_i)$. Ký hiệu dF do đó dùng chung cho cả liên tục và rời rạc.

Biến chỉ báo và các quy tắc tính

Đặt $I = \mathbf{1}_A$. Vì $I^2 = I$,

$$\mathbb{E}I = \mathbb{P}(A) = p, \qquad \operatorname{Var} I = \mathbb{E}I^2 - (\mathbb{E}I)^2 = p(1-p).$$

Với hai sự kiện A, B, $\operatorname{Cov}(\mathbf{1}_A, \mathbf{1}_B) = \mathbb{P}(A \cap B) - \mathbb{P}(A)\mathbb{P}(B)$. Tuyến tính của kỳ vọng không đòi độc lập. Ngược lại,

$$\operatorname{Var}\left(\sum_i Z_i\right) = \sum_i \operatorname{Var} Z_i + 2\sum_{i<j} \operatorname{Cov}(Z_i, Z_j).$$

Chỉ khi các hiệp phương sai bằng 0 mới bỏ được tổng chéo. Với i.i.d. có phương sai hữu hạn, $\operatorname{Var}(n^{-1}\sum_i Z_i) = \operatorname{Var}(Z_1)/n$.

Chệch, phương sai và rủi ro

Đặt $m = \mathbb{E}\hat{\theta}$ và θ là giá trị thật.

$$\begin{aligned}\mathbb{E}(\hat{\theta} - \theta)^2 &= \mathbb{E}[(\hat{\theta} - m) + (m - \theta)]^2 \\ &= \mathbb{E}(\hat{\theta} - m)^2 + (m-\theta)^2 + 2(m-\theta)\mathbb{E}(\hat{\theta} - m) \\ &= \operatorname{Var}(\hat{\theta}) + \operatorname{Bias}(\hat{\theta})^2.\end{aligned}$$

Hạng chéo bằng 0 vì $\mathbb{E}(\hat{\theta} - m) = 0$, không phải vì hai hạng "độc lập". Với hàm mật độ,

$$\mathrm{ISE} = \int (\hat{f} - f)^2, \qquad \mathrm{MISE} = \mathbb{E}\,\mathrm{ISE} = \int \operatorname{Bias}(\hat{f}(x))^2\,dx + \int \operatorname{Var}(\hat{f}(x))\,dx.$$

Tonelli cho phép đổi kỳ vọng và tích phân của hàm không âm $(\hat{f} - f)^2$, kể cả khi tích phân vô hạn. Để tách hoặc đổi thứ tự những tích phân có dấu, cần điều kiện khả tích tuyệt đối.

Trực giác và ý nghĩa thực tiễn. Chệch đo vị trí trung bình của các ước lượng qua nhiều mẫu; phương sai đo mức dao động quanh vị trí đó. Một đường ước lượng rất đẹp trên một mẫu chưa chứng minh được rủi ro nhỏ.

Hội tụ và ký hiệu tiệm cận

- $Z_n \xrightarrow{a.s.} Z$: ngoài một sự kiện xác suất 0, dãy giá trị hội tụ. $Z_n \xrightarrow{P} Z$: với mọi $\epsilon > 0$, $\mathbb{P}(|Z_n - Z| > \epsilon) \to 0$.
- $Z_n \Rightarrow Z$: hội tụ phân phối. CLT mô tả phân phối của sai số sau chuẩn hóa, không nói sai số chưa chuẩn hóa giữ nguyên độ lớn.
- $a_n = O(b_n)$: $|a_n| \le C|b_n|$ khi n đủ lớn; $a_n = o(b_n)$: $a_n/b_n \to 0$; $a_n \asymp b_n$: chặn trên và dưới bởi các hằng số dương.
- $Z_n = O_P(b_n)$: Z_n/b_n bị chặn theo xác suất; $Z_n = o_P(b_n)$: $Z_n/b_n \xrightarrow{P} 0$.

LLN: nếu Z_i i.i.d. và $\mathbb{E}|Z_1| < \infty$, $\overline{Z}_n \xrightarrow{a.s.} \mathbb{E}Z_1$. CLT: nếu thêm $0 < \operatorname{Var} Z_1 = \tau^2 < \infty$,

$$\sqrt{n}(\overline{Z}_n - \mathbb{E}Z_1) \Rightarrow N(0, \tau^2).$$

Hội tụ điểm của $g_n(x)$ kiểm soát mỗi x cố định; hội tụ đều kiểm soát $\sup_x |g_n(x) - g(x)|$. Không tự đổi x thành một điểm phụ thuộc mẫu trong một kết quả chỉ có hội tụ điểm.

Taylor, delta method và phép đổi biến

Nếu g đủ trơn gần x,

$$g(x+t) = g(x) + tg'(x) + \frac{t^2}{2}g''(x) + \cdots.$$

Muốn tích phân phần dư trên toàn trục phải có chặn khả tích thích hợp. Chỉ biết g'' liên tục cho phần dư $o(t^2)$, không tự cho $O(t^4)$. Khi $u = (x-t)/h$, ta có $t = x - hu$, $dt = -h\,du$. Hai cận đảo thứ tự nên dấu âm mất khi viết lại tích phân từ $-\infty$ đến ∞.

Delta method: nếu $\sqrt{n}(\hat{\theta} - \theta) \Rightarrow N(0, \tau^2)$ và g khả vi tại θ, thì khi $g'(\theta) \neq 0$,

$$\sqrt{n}[g(\hat{\theta}) - g(\theta)] \Rightarrow N(0, [g'(\theta)]^2\tau^2).$$

Nguồn gốc là khai triển $g(\hat{\theta}) - g(\theta) = g'(\theta)(\hat{\theta} - \theta) + o_P(n^{-1/2})$. Nếu đạo hàm bằng 0, phải xét bậc khai triển tiếp theo.

Tích vô hướng và trực chuẩn

Trên $[0,1]$, đặt $\langle g, q\rangle = \int_0^1 gq$ và $\|g\|_2^2 = \langle g, g\rangle$. Nếu $\langle \phi_j, \phi_k\rangle = \delta_{jk}$ thì

$$\left\| \sum_{j=1}^{D} b_j \phi_j \right\|_2^2 = \sum_{j,k} b_j b_k \langle \phi_j, \phi_k \rangle = \sum_j b_j^2.$$

Hạng chéo mất do tích phân các hàm trực giao, không do các hệ số ngẫu nhiên độc lập. Đây là nền tảng của Chương 4.

Một phép tối ưu dùng xuyên suốt tài liệu

Với $A, B, \beta > 0$, xét $G(h) = Ah^{2\beta} + B/(nh)$.

$$G'(h) = 2\beta A h^{2\beta-1} - \frac{B}{nh^2} = 0 \quad \Longleftrightarrow \quad h_*^{2\beta+1} = \frac{B}{2\beta A n}.$$

Vì $G(h) \to \infty$ khi $h \to 0$ hoặc $h \to \infty$ và nghiệm dương duy nhất, đây là cực tiểu toàn cục. Thế lại:

$$h_* \asymp n^{-1/(2\beta+1)}, \qquad G(h_*) \asymp n^{-2\beta/(2\beta+1)}.$$

Với $\beta = 1$ nhận histogram, với $\beta = 2$ nhận KDE bậc hai. Đây là tối ưu một biểu thức xấp xỉ hoặc một chặn trên, không phải tự động nghiệm tối ưu chính xác của rủi ro hữu hạn mẫu.

Chương 1

Hàm phân phối thực nghiệm và nguyên lý thế

1.1 Từ dữ liệu đến một phân phối

Với mẫu i.i.d. từ một CDF bất kỳ F, định nghĩa

$$\boxed{\widehat{F}_n(x) = \frac{1}{n}\sum_{i=1}^{n} \mathbf{1}_{\{X_i \le x\}}.}$$

Mỗi điểm dữ liệu được gán khối lượng $1/n$; nếu giá trị xuất hiện k lần, bước nhảy tại đó cao k/n. Hàm không giảm, liên tục phải, bằng 0 dưới giá trị nhỏ nhất và bằng 1 từ giá trị lớn nhất trở đi.

Ví dụ 1.1. Với $X = (1, 2, 4, 5)$,

$$\widehat{F}_n(x) = \begin{cases} 0, & x < 1, \\ 1/4, & 1 \le x < 2, \\ 1/2, & 2 \le x < 4, \\ 3/4, & 4 \le x < 5, \\ 1, & x \ge 5. \end{cases}$$

Vì định nghĩa dùng $\le$, $\widehat{F}_n(2) = 1/2$, còn $\widehat{F}_n(2-) = 1/4$. Xác suất thực nghiệm của $(2, 4]$ bằng $1/4$; của $[2, 4]$ bằng $1/2$ vì khoảng thứ hai có thêm điểm 2.

Trực giác và ý nghĩa thực tiễn. EDF trả lời câu hỏi "tỷ lệ dữ liệu không vượt quá ngưỡng này là bao nhiêu?". Nó không cần chọn ô hay bandwidth và không cần giả thiết phân phối có mật độ.
Đối chiếu nguồn: [1], slide 10–17; [4], Chương 2.

1.2 Kỳ vọng, phương sai và hiệp phương sai

Mệnh đề 1.2. *Với mỗi x, y cố định,*

$$\begin{aligned} \mathbb{E}\widehat{F}_n(x) &= F(x), \\ \operatorname{Var}\widehat{F}_n(x) &= \frac{F(x)[1 - F(x)]}{n}, \\ \operatorname{Cov}(\widehat{F}_n(x), \widehat{F}_n(y)) &= \frac{F(\min(x, y)) - F(x)F(y)}{n}. \end{aligned}$$

Chứng minh. Đặt $I_i(x) = \mathbf{1}_{\{X_i \le x\}}$. Với x cố định, $I_i(x) \sim \text{Bernoulli}(F(x))$. Do đó

$$\mathbb{E}\widehat{F}_n(x) = \frac{1}{n}\sum_i \mathbb{E}I_i(x) = \frac{nF(x)}{n} = F(x).$$

Các $I_i(x)$ độc lập theo chỉ số quan sát, nên

$$\operatorname{Var}\widehat{F}_n(x) = \frac{1}{n^2}\sum_i \operatorname{Var} I_i(x) = \frac{nF(x)[1-F(x)]}{n^2}.$$

Khi xét hai ngưỡng, phải giữ hiệp phương sai của chỉ báo từ cùng một quan sát:

$$\begin{aligned}\operatorname{Cov}(\widehat{F}_n(x), \widehat{F}_n(y)) &= \frac{1}{n^2}\sum_{i,k} \operatorname{Cov}(I_i(x), I_k(y)) \\ &= \frac{1}{n^2}\sum_i \operatorname{Cov}(I_i(x), I_i(y)) \\ &= \frac{1}{n}\{\mathbb{E}[I_1(x)I_1(y)] - F(x)F(y)\}.\end{aligned}$$

Với $i \neq k$, độc lập của X_i, X_k làm hạng chéo bằng 0. Tích hai chỉ báo bằng $\mathbf{1}_{\{X_1 \le \min(x,y)\}}$, vì đồng thời thỏa cả hai bất đẳng thức tương đương thỏa ngưỡng nhỏ hơn. Lấy kỳ vọng cho kết quả. Đặc biệt, nếu $x < y$ thì

$$\boxed{\operatorname{Cov}(\widehat{F}_n(x), \widehat{F}_n(y)) = \frac{F(x)[1-F(y)]}{n}.}$$

□

Ví dụ 1.3. Nếu $n = 100$, $F(x) = 0.2$, $F(y) = 0.7$, $x < y$, thì phương sai tại x là 0.0016, độ lệch chuẩn 0.04, và hiệp phương sai hai điểm là 0.0006. Các giá trị của đường EDF không độc lập.

Trực giác và ý nghĩa thực tiễn. Nếu một mẫu có nhiều điểm nhỏ hơn x, nó cũng có xu hướng có nhiều điểm nhỏ hơn $y > x$. Do các sự kiện lồng nhau, hiệp phương sai không âm.

1.3 Nhất quán và CLT tại một điểm

Mệnh đề 1.4. *Với mỗi x cố định, $\widehat{F}_n(x) \xrightarrow{a.s.} F(x)$. Nếu $0 < F(x) < 1$ thì*

$$\boxed{\sqrt{n}[\widehat{F}_n(x) - F(x)] \Rightarrow N(0, F(x)[1-F(x)]).}$$

Chứng minh. LLN áp dụng cho các chỉ báo i.i.d. vì $\mathbb{E}|I_i(x)| \le 1$. CLT áp dụng vì phương sai $F(x)[1-F(x)]$ hữu hạn và dương. Nếu $F(x) = 0$ hoặc 1, các chỉ báo bằng cùng một hằng số gần chắc chắn, nên sai số bằng 0, không có phân phối chuẩn không suy biến. □

Một khoảng Wald tại điểm, khi cỡ mẫu và tần suất đủ lớn, là

$$\left[\widehat{F}_n(x) - z_{1-\alpha/2}\sqrt{\frac{\widehat{F}_n(x)[1-\widehat{F}_n(x)]}{n}},\quad \widehat{F}_n(x) + z_{1-\alpha/2}\sqrt{\frac{\widehat{F}_n(x)[1-\widehat{F}_n(x)]}{n}}\right] \cap [0,1].$$

Đây là xấp xỉ cho một ngưỡng cố định. Nếu n nhỏ hoặc xác suất gần 0, 1, khoảng Wald có thể rất kém; bài toán tại điểm chính là khoảng tin cậy cho xác suất nhị thức, có thể dùng Wilson hoặc khoảng nhị thức chính xác.

Trực giác và ý nghĩa thực tiễn. Sai số EDF tại một ngưỡng thường ở thang $n^{-1/2}$. Giảm một nửa độ lệch chuẩn thường đòi tăng cỡ mẫu bốn lần.

1.4 Hội tụ đều và băng tin cậy DKW

Định lý 1.5 (Dvoretzky–Kiefer–Wolfowitz)**.** *Với mẫu i.i.d. và mọi $\epsilon > 0$,*

$$\boxed{\mathbb{P}\left(\sup_{x\in\mathbb{R}} |\widehat{F}_n(x) - F(x)| > \epsilon\right) \le 2e^{-2n\epsilon^2}.}$$

Không yêu cầu F liên tục.

Đây là bất đẳng thức xác suất được viện dẫn. Chứng minh đầy đủ hằng số tối ưu 2 vượt quá phần nền; dưới đây chứng minh các hệ quả cần sử dụng.

Định lý 1.6 (Glivenko–Cantelli)**.** $\sup_x |\widehat{F}_n(x) - F(x)| \xrightarrow{a.s.} 0$.

Chứng minh. Đặt $Z_n = \sup_x |\widehat{F}_n(x) - F(x)|$. Với mỗi số nguyên $k \ge 1$,

$$\sum_{n=1}^{\infty} \mathbb{P}(Z_n > 1/k) \le 2\sum_{n=1}^{\infty} e^{-2n/k^2} < \infty,$$

vì vế phải là chuỗi hình học có công bội nhỏ hơn 1. Bổ đề Borel–Cantelli thứ nhất cho biết $Z_n > 1/k$ chỉ xảy ra hữu hạn lần, gần chắc chắn. Giao các sự kiện xác suất 1 này trên $k = 1, 2, \ldots$ vẫn có xác suất 1. Trên giao đó, với mọi $\epsilon > 0$, chọn k sao cho $1/k < \epsilon$; từ một chỉ số trở đi $Z_n \le 1/k < \epsilon$. Đó chính là hội tụ gần chắc chắn về 0. □

Dựng băng đồng thời. Giải $2e^{-2n\epsilon_n^2} = \alpha$:

$$\epsilon_n = \sqrt{\frac{\log(2/\alpha)}{2n}}, \quad L_n(x) = \max\{0, \widehat{F}_n(x) - \epsilon_n\}, \quad U_n(x) = \min\{1, \widehat{F}_n(x) + \epsilon_n\}.$$

Trên sự kiện $Z_n \le \epsilon_n$, bất đẳng thức $\widehat{F}_n(x) - \epsilon_n \le F(x) \le \widehat{F}_n(x) + \epsilon_n$ đúng *đồng thời cho mọi* x. Cắt tại 0 và 1 không làm mất giá trị thật vì $0 \le F(x) \le 1$. Vì vậy

$$\boxed{\mathbb{P}(\forall x:\ L_n(x) \le F(x) \le U_n(x)) \ge 1 - \alpha.}$$

Mức bao phủ ít nhất $1 - \alpha$, không nhất thiết đúng bằng mức đó. Với $n = 100$, $\alpha = 0.05$, $\epsilon_n \approx 0.13581$. Nếu muốn nửa độ rộng không vượt δ, cần $n \ge \lceil \log(2/\alpha)/(2\delta^2) \rceil$; với $\delta = 0.05$, mức 95%, cần $n \ge 738$.

Trực giác và ý nghĩa thực tiễn. Khoảng tại điểm là bảo đảm cho một ngưỡng; băng DKW là bảo đảm cho toàn bộ đường. Cùng mức tin cậy, yêu cầu đồng thời thường cần băng rộng hơn.

Lỗi dễ mắc. Lấy 100 khoảng Wald mức 95% không tạo ra một băng đồng thời 95%. EDF có bước nhảy không làm DKW mất hiệu lực.

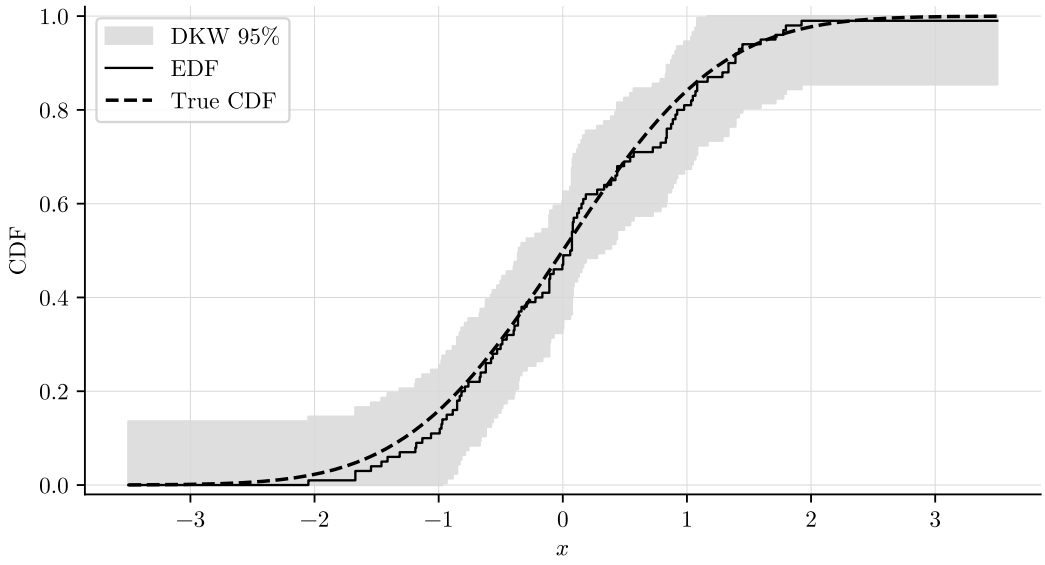
Đối chiếu nguồn: [1], slide 16–20; [4], Chương 2.

1.5 Functional và nguyên lý thế

Một *functional* là ánh xạ từ phân phối thành một số hoặc vectơ: $T : F \mapsto T(F)$. Nguyên lý thế định nghĩa

$$\boxed{\hat{\theta} = T(\widehat{F}_n).}$$

Nếu T liên tục tại F theo chuẩn sup của CDF thì Glivenko–Cantelli và tính liên tục cho $T(\widehat{F}_n) \xrightarrow{a.s.} T(F)$. Tính liên tục là giả thiết, không phải tính chất của mọi functional. Chẳng hạn trung bình trên miền không bị chặn không liên tục theo chuẩn sup: $F_m = (1-1/m)\delta_0 + (1/m)\delta_{m^2}$ cách δ_0 không quá $1/m$ về CDF, nhưng trung bình của F_m bằng m. Trung bình mẫu vẫn nhất quán khi moment tuyệt đối bậc nhất hữu hạn, nhờ LLN.



Hình 1.1: EDF và băng DKW 95% trên một mẫu chuẩn mô phỏng, $n = 100$. Đường liền là CDF thật để đối chiếu; băng tính từ dữ liệu. Một hình đơn lẻ không chứng minh mức bao phủ qua các mẫu lặp lại.

1.5.1 Functional tuyến tính

Với $T(F) = \int a(x)\,dF(x)$ và $\mathbb{E}|a(X)| < \infty$,

$$T(\widehat{F}_n) = \int a(x)\frac{1}{n}\sum_i \delta_{X_i}(dx) = \frac{1}{n}\sum_i a(X_i).$$

Tích phân theo khối lượng điểm δ_{X_i} bằng giá trị hàm tại X_i. Từ LLN, ước lượng nhất quán; từ tuyến tính của kỳ vọng, không chệch. Nếu $\mathrm{Var}(a(X)) < \infty$,

$$\mathrm{Var}(T(\widehat{F}_n)) = \frac{\mathrm{Var}(a(X))}{n}, \qquad \sqrt{n}[T(\widehat{F}_n) - T(F)] \Rightarrow N(0, \mathrm{Var}(a(X))).$$

Trung bình, moment thô và xác suất một tập cố định là những ví dụ.

1.5.2 Trung bình, phương sai và độ lệch

Đặt $\mu = \int x\,dF$, $\sigma^2 = \int (x-\mu)^2\,dF$.

$$\hat{\mu} = \overline{X}, \qquad \hat{\sigma}^2_{\text{plug}} = \frac{1}{n}\sum_i (X_i - \overline{X})^2 = \overline{X^2} - \overline{X}^2.$$

Functional phương sai phi tuyến vì μ cũng phụ thuộc F. Từ $\mathbb{E}\overline{X^2} = \sigma^2 + \mu^2$ và $\mathbb{E}\overline{X}^2 = \sigma^2/n + \mu^2$, suy ra

$$\mathbb{E}\hat{\sigma}^2_{\text{plug}} = \frac{n-1}{n}\sigma^2.$$

Ước lượng không chệch là $s^2 = (n-1)^{-1}\sum_i (X_i - \overline{X})^2$, không phải đúng estimator plug-in của functional phương sai. Cả hai nhất quán nếu $\mathbb{E}X^2 < \infty$.

Skewness của phân phối có $\sigma > 0$ và moment tuyệt đối bậc ba hữu hạn:

$$\gamma_1(F) = \frac{\mathbb{E}(X-\mu)^3}{\sigma^3}, \qquad \hat{\gamma}_1 = \frac{n^{-1}\sum_i (X_i - \overline{X})^3}{[n^{-1}\sum_i (X_i - \overline{X})^2]^{3/2}}.$$

Nếu phương sai mẫu bằng 0, tỷ số không xác định. Các phiên bản hiệu chỉnh skewness trong phần mềm có thể khác công thức plug-in này.

Ví dụ 1.7. Với $(1, 2, 4, 5)$, $\overline{X} = 3$, tổng bình phương độ lệch là 10. Phương sai plug-in là 2.5, $s^2 = 10/3$. Tổng lập phương độ lệch là $-8 - 1 + 1 + 8 = 0$, nên skewness plug-in bằng 0.

1.5.3 Tương quan và quantile

Với mẫu cặp (X_i, Y_i), dùng *phân phối thực nghiệm đồng thời*. Khi hai phương sai dương,

$$\hat{\rho} = \frac{\sum_i (X_i - \overline{X})(Y_i - \overline{Y})}{\sqrt{\sum_i (X_i - \overline{X})^2 \sum_i (Y_i - \overline{Y})^2}}.$$

Các hệ số $1/n$ triệt tiêu giữa tử và mẫu. Không thể khôi phục tương quan chỉ từ hai CDF biên: cần cấu trúc phụ thuộc của các cặp.

Với $0 < p < 1$, quantile là nghịch đảo suy rộng:

$$q_p = \inf\{x : F(x) \geq p\}, \qquad \hat{q}_p = \inf\{x : \widehat{F}_n(x) \geq p\} = X_{(\lceil np \rceil)}.$$

Đây là quy ước quantile dùng xuyên suốt tài liệu. Với mẫu bốn điểm trên, $\hat{q}_{0.5} = 2$, khác trung vị nội suy 3 thường dùng trong mô tả. Nếu F có quantile duy nhất và liên tục, tăng thực sự quanh q_p, ước lượng quantile nhất quán. Nếu thêm $f(q_p) > 0$ và f liên tục gần đó, biểu diễn tuyến tính tiệm cận là

$$\hat{q}_p - q_p = -\frac{\widehat{F}_n(q_p) - p}{f(q_p)} + o_P(n^{-1/2}), \quad \sqrt{n}(\hat{q}_p - q_p) \Rightarrow N\left(0, \frac{p(1-p)}{f(q_p)^2}\right).$$

Đây là kết quả được viện dẫn về quantile; trực giác đến từ $F(q_p + t) \approx p + f(q_p)t$. Sai số theo chiều đứng của EDF được chia cho độ dốc để đổi sang sai số theo chiều ngang. Mật độ nhỏ quanh quantile làm sai số vị trí lớn.

Trực giác và ý nghĩa thực tiễn. Plug-in biến một phân phối thực nghiệm thành thống kê quen thuộc. Tính đúng đắn của suy luận phụ thuộc moment, tính liên tục và mẫu số của functional, không chỉ phụ thuộc EDF hội tụ.

Đối chiếu nguồn: [1], slide 30–35; [4], Chương 2.

1.6 Kiểm định sự phù hợp

Xét $H_0 : F = F_0$ với F_0 *liên tục, được chỉ định đầy đủ*. Khi đó $U_i = F_0(X_i)$ i.i.d. đều trên $[0, 1]$ dưới H_0. Điều này giải thích tính không phụ thuộc phân phối của các thống kê sau.

1.6.1 Kolmogorov–Smirnov

$$D_n = \sup_x |\widehat{F}_n(x) - F_0(x)|.$$

Với $X_{(1)} \leq \cdots \leq X_{(n)}$, cần kiểm tra hai phía của mỗi bước nhảy. Trong các khoảng không có dữ liệu, EDF hằng còn F_0 không giảm; độ lệch lớn nhất đạt ở giới hạn hai đầu khoảng. Vì vậy

$$D_n^+ = \max_i \left\{ \frac{i}{n} - F_0(X_{(i)}) \right\},$$
$$D_n^- = \max_i \left\{ F_0(X_{(i)}) - \frac{i-1}{n} \right\}, \qquad \boxed{D_n = \max(D_n^+, D_n^-).}$$

DKW cho kiểm định bảo thủ hữu hạn mẫu: bác bỏ khi $D_n > \sqrt{\log(2/\alpha)/(2n)}$. Với phân phối liên tục, giới hạn của $\sqrt{n}D_n$ là $\sup_{0\le t\le 1}|B(t)|$, với B là cầu Brown.

$$\mathbb{P}\big(\sup_t |B(t)| > z\big) = 2\sum_{k=1}^{\infty}(-1)^{k-1}e^{-2k^2z^2}, \quad z>0.$$

Đây là định lý giới hạn được viện dẫn. Mốc tiệm cận 95% thường dùng là $1.358/\sqrt{n}$; cần bảng hoặc thuật toán chính xác khi mẫu nhỏ.

1.6.2 Cramér–von Mises

CvM đo sai khác bình phương, tích phân theo F_0:

$$W_n^2 = n\int [\widehat{F}_n(x) - F_0(x)]^2\, dF_0(x) = \frac{1}{12n} + \sum_{i=1}^{n}\left[F_0(X_{(i)}) - \frac{2i-1}{2n}\right]^2.$$

Để thấy nguồn gốc công thức, đặt $u_i = F_0(X_{(i)})$, $u_0 = 0$, $u_{n+1} = 1$. CDF thực nghiệm trên (u_i, u_{i+1}) bằng i/n:

$$W_n^2 = n\sum_{i=0}^{n}\int_{u_i}^{u_{i+1}} (i/n - t)^2\, dt.$$

Lấy nguyên hàm $t^3/3 - (i/n)t^2 + (i/n)^2 t$ và thu gọn các đầu mút, ta được $n/3 + \sum_i [u_i^2 - (2i-1)u_i/n]$. Hoàn thành bình phương từng hạng và dùng $\sum_i (2i-1)^2 = n(4n^2-1)/3$ cho công thức trên.

1.6.3 Anderson–Darling

AD tăng trọng số ở hai đuôi:

$$A_n^2 = n\int \frac{[\widehat{F}_n(x) - F_0(x)]^2}{F_0(x)[1-F_0(x)]}\, dF_0(x).$$

Khi $0 < u_i < 1$, công thức tính là

$$\boxed{A_n^2 = -n - \frac{1}{n}\sum_{i=1}^{n}(2i-1)\{\log u_i + \log(1-u_{n+1-i})\}.}$$

Có thể kiểm tra bằng chia khoảng như CvM và phân tích

$$\frac{(c-t)^2}{t(1-t)} = \frac{c^2}{t} + \frac{(1-c)^2}{1-t} - 1.$$

Nguyên hàm là $c^2\log t - (1-c)^2\log(1-t) - t$. Thế $c = i/n$ trên từng khoảng; hiệu hệ số ở một đầu mút cho các trọng số $(2i-1)/n$. Ở khoảng sát 0 hoặc 1, hệ số đi với log phân kỳ bằng 0; lấy giới hạn một phía để thu gọn. Nếu dữ liệu có $u_i = 0$ hoặc 1, AD có thể vô hạn: không tùy ý thay log 0 bằng 0.

Kiểm định	Đo sai khác	Nhấn mạnh
KS	Sai khác lớn nhất	Vị trí lệch nhiều nhất
CvM	Bình phương tích phân	Sai khác trên toàn miền
AD	Bình phương có trọng số	Hai đuôi

Trực giác và ý nghĩa thực tiễn. KS nhìn điểm tệ nhất; CvM cộng sai khác; AD phóng đại sai khác ở những vùng CDF gần 0 hoặc 1. Không có thống kê tốt nhất cho mọi đối thuyết.

Lỗi dễ mắc. Nếu dùng mẫu để ước lượng μ, σ rồi kiểm định với $N(\hat{\mu}, \hat{\sigma}^2)$, bảng KS chuẩn không còn đúng. Cần hiệu chỉnh tương ứng hoặc bootstrap tham số có bước fit lại trong mỗi lần lặp. Với F_0 rời rạc, phân phối null cũng khác. Không bác bỏ H_0 không có nghĩa chứng minh H_0 đúng.

Đối chiếu nguồn: [1], slide 36–46.

1.7 Tự kiểm tra trước khi sang Chương 2

Bạn cần tự làm được: viết EDF có dữ liệu trùng; phân biệt $F_n(x)$ và $F_n(x-)$; chứng minh covariance bằng tích chỉ báo; suy ra băng DKW; giải thích vì sao phương sai plug-in có mẫu số n; tính KS bằng cả D_n^+ và D_n^-. Chương 6 có ba bài KS và một bài EDF/DKW để luyện.

Chương 2

Ước lượng mật độ bằng histogram

2.1 Đếm trong ô rồi chia cho độ rộng

Giả sử trước hết $X_i \in [0,1]$, phân phối có mật độ f trên miền này. Chia thành m ô bằng nhau, $h = 1/m$:

$$B_j = [(j-1)h, jh), \quad j < m, \qquad B_m = [(m-1)h, 1].$$

Quy ước ô trái đóng, phải mở, ngoại trừ ô cuối, đảm bảo mỗi quan sát được đếm đúng một lần. Đặt

$$N_j = \sum_i \mathbf{1}_{\{X_i \in B_j\}}, \quad p_j = \int_{B_j} f(u)\,du, \quad \hat{p}_j = N_j/n.$$

Histogram ước lượng mật độ là

$$\boxed{\hat{f}_{\text{hist}}(x) = \frac{\hat{p}_j}{h} = \frac{N_j}{nh}, \quad x \in B_j,}$$

và bằng 0 ngoài $[0,1]$. p_j/h là chiều cao trung bình thật trong ô; $\hat{p}_j/h$ mới là ước lượng từ mẫu.

Kiểm tra là mật độ. Chiều cao không âm. Vì diện tích của ô j là chiều cao nhân chiều rộng,

$$\int \hat{f}_{\text{hist}}(x)\,dx = \sum_{j=1}^{m} \frac{N_j}{nh} h = \frac{1}{n}\sum_j N_j = 1.$$

Trên $[a,b]$, dùng $h = (b-a)/m$, trung điểm $c_j = a + (j-1/2)h$. Nếu chuyển $U = (X-a)/(b-a)$ về $[0,1]$, thì mật độ gốc phải là $\hat{f}_X(x) = \hat{f}_U((x-a)/(b-a))/(b-a)$. Không thiếu hệ số Jacobian này.

Trực giác và ý nghĩa thực tiễn. Chiều cao histogram là "xác suất trong ô trên mỗi đơn vị độ dài". Biểu đồ số đếm chỉ có chiều cao N_j chưa phải mật độ chuẩn hóa.

Đối chiếu nguồn: [2], slide 12; [4], Mục 6.2.

2.2 Kỳ vọng và phương sai chính xác

Mỗi $N_j \sim \text{Binomial}(n, p_j)$, dù các số đếm giữa ô khác nhau không độc lập. Với $x \in B_j$,

$$\mathbb{E}\hat{f}_{\text{hist}}(x) = \frac{p_j}{h}, \qquad \boxed{\text{Var}\,\hat{f}_{\text{hist}}(x) = \frac{p_j(1-p_j)}{nh^2}.}$$

Từ $\text{Var}\,N_j = np_j(1-p_j)$, chỉ cần chia cho $(nh)^2$. Kỳ vọng không phải $f(x)$ nói chung: estimator lấy trung bình mật độ trong ô chứ không khôi phục biến thiên bên trong ô.

2.3 Taylor và độ chệch tại một điểm

Giả sử $f \in C^2([0,1])$, các đạo hàm được hiểu một phía ở biên. Với $u, x \in B_j$ và $\|f''\|_\infty < \infty$,

$$f(u) = f(x) + f'(x)(u-x) + O((u-x)^2).$$

Vì $|u-x| \le h$, tích phân phần dư trên một ô có độ dài h là $O(h^3)$. Đặt $c_j = (j-1/2)h$:

$$\begin{aligned} p_j &= hf(x) + f'(x)\int_{(j-1)h}^{jh} (u-x)\,du + O(h^3) \\ &= hf(x) + hf'(x)(c_j - x) + O(h^3), \end{aligned}$$

vì trung bình của u trên ô là c_j. Chia cho h, rồi trừ $f(x)$, nhận

$$\boxed{\mathrm{Bias}(\hat{f}_{\mathrm{hist}}(x)) = f'(x)(c_j - x) + O(h^2) = O(h).}$$

Tại đúng trung điểm $x = c_j$, số hạng bậc nhất mất. Taylor quanh c_j còn cho $p_j/h - f(c_j) = h^2 f''(c_j)/24 + o(h^2)$. Đây là cải thiện ở trung điểm, không phải bias $O(h^2)$ cho toàn histogram.

Thế $p_j = hf(x) + O(h^2)$ vào phương sai:

$$\frac{p_j(1-p_j)}{nh^2} = \frac{f(x)}{nh} + O(1/n).$$

Nếu $f(x) > 0$, số hạng chính là $f(x)/(nh)$; nếu $f(x) = 0$, không thể hiểu ký hiệu xấp xỉ theo tỷ số với số hạng chính bằng 0. Khi $h \to 0$, $nh \to \infty$, bias và variance cùng về 0, nên histogram nhất quán theo MSE tại những điểm thỏa điều kiện trên.

Trực giác và ý nghĩa thực tiễn. Ở ô có mật độ tăng, trung bình ô lớn hơn giá trị bên trái và nhỏ hơn giá trị bên phải. Dấu chệch phụ thuộc vị trí của x so với trung điểm, không chỉ phụ thuộc độ dốc.

Đối chiếu nguồn: [2], slide 13–14; [4], trang in 128–129, phụ lục chứng minh trang in 140–142 (PDF 149–151).

2.4 Từ sai số tại điểm đến MISE

2.4.1 Tích phân bình phương chệch: nguồn gốc 1/12

Trong ô B_j, có thể viết đều theo x: $b(x) = f'(c_j)(c_j - x) + O(h^2)$. Khi bình phương, hạng chéo được chặn bởi $O(h^3)$ tại điểm; tích phân qua $m = 1/h$ ô tổng độ dài 1 cho phần dư $O(h^3)$.

$$\begin{aligned} \int_0^1 b(x)^2\,dx &= \sum_j f'(c_j)^2 \int_{B_j} (c_j - x)^2\,dx + O(h^3) \\ &= \sum_j f'(c_j)^2 \int_{-h/2}^{h/2} t^2\,dt + O(h^3) \\ &= \frac{h^3}{12}\sum_j f'(c_j)^2 + O(h^3) \\ &= \frac{h^2}{12}\int_0^1 f'(x)^2\,dx + o(h^2). \end{aligned}$$

Ở bước hai, đặt $t = x - c_j$, $dx = dt$. Bước ba dùng $[t^3/3]_{-h/2}^{h/2} = h^3/12$. Bước cuối dùng hội tụ tổng Riemann $h\sum_j f'(c_j)^2 \to \int_0^1 f'^2$.

2.4.2 Phương sai tích phân: công thức chính xác

Phương sai là hằng trong mỗi ô, nên

$$\begin{aligned}\int_0^1 \operatorname{Var} \hat{f}_{\text{hist}}(x)\,dx &= \sum_j h\frac{p_j(1-p_j)}{nh^2} \\ &= \frac{1}{nh}\left(\sum_j p_j - \sum_j p_j^2\right) \\ &= \boxed{\frac{1}{nh}\left(1-\sum_j p_j^2\right)}.\end{aligned}$$

Với f liên tục, $p_j = hf(\xi_j)$ cho một $\xi_j \in B_j$; $\sum_j p_j^2/h = h\sum_j f(\xi_j)^2 \to \int_0^1 f^2$. Vậy phương sai tích phân bằng

$$\frac{1}{nh} - \frac{1}{n}\int_0^1 f(x)^2\,dx + o(1/n).$$

Số hạng $-R(f)/n$ có bậc nhỏ hơn $1/(nh)$ khi $h \to 0$; nó không bằng 0 trong công thức chính xác.

2.4.3 Băng thông và tốc độ tối ưu

Đặt $A = \int_0^1 f'^2 > 0$. Biểu thức tiệm cận chính là

$$\text{AMISE}_{\text{hist}}(h) = \frac{A}{12}h^2 + \frac{1}{nh}.$$

Đạo hàm bằng $Ah/6 - 1/(nh^2)$, nên

$$\boxed{h_* = (6/A)^{1/3}n^{-1/3}, \qquad \text{AMISE}_{\text{hist}}(h_*) = \frac{6^{2/3}}{4}A^{1/3}n^{-2/3}.}$$

Để kiểm tra hệ số, tại nghiệm $1/(nh_*) = Ah_*^2/6$, bằng hai lần phần bình phương chệch. Tổng bằng $Ah_*^2/4$. Với $h = 1/m$, chọn số nguyên m gần $1/h_*$, so sánh hai ứng viên lân cận. Nếu $A = 0$, công thức suy biến: với mật độ đều trên miền biết trước $[0,1]$, một ô duy nhất cho mật độ đúng bằng 1, rủi ro 0.

Ví dụ 2.1. Với $f(x) = 2x$ trên $[0,1]$, $A = 4$, nên $h_* = (3/(2n))^{1/3}$. Nếu $n = 96$, $h_* = 1/4$, $m = 4$. Phần bình phương chệch chính là $1/48$, phương sai chính $1/24$, tổng $1/16$. Đây là AMISE, không phải MISE chính xác.

Trực giác và ý nghĩa thực tiễn. Ô rộng giảm dao động số đếm nhưng làm mất độ dốc bên trong ô. Ở tối ưu, hai thành phần có cùng bậc theo n, nhưng không bằng nhau về hằng số. Histogram đạt $n^{-2/3}$ dưới điều kiện đang xét.

Đối chiếu nguồn: [2], slide 15–16; [4], Mục 6.2.

2.5 Leave-one-out cross-validation

Ta muốn chọn h mà không biết A. Khai triển mất mát của một mẫu:

$$\text{ISE}(h) = \int \hat{f}_h^2 - 2\int \hat{f}_h f + R(f).$$

Hạng $R(f)$ không phụ thuộc h, nên bỏ khi tối ưu. Thay $\int \hat{f}_h f$ bằng trung bình leave-one-out:

$$\widehat{J}(h) = \int \hat{f}_h^2(x)\,dx - \frac{2}{n}\sum_i \hat{f}_{(-i),h}(X_i).$$

Giữ *cùng phân hoạch* khi bỏ quan sát, chỉ đổi số đếm và mẫu số. Nếu $X_i \in B_j$, $\hat{f}_{(-i),h}(X_i) = (N_j - 1)/((n-1)h)$. Do đó

$$\begin{aligned}\int \hat{f}_h^2 &= \frac{1}{n^2 h}\sum_j N_j^2,\\ \frac{2}{n}\sum_i \hat{f}_{(-i),h}(X_i) &= \frac{2}{n(n-1)h}\sum_j N_j(N_j-1)\\ &= \frac{2}{n(n-1)h}\left(\sum_j N_j^2 - n\right).\end{aligned}$$

Trừ hai dòng, đổi $N_j^2 = n^2\hat{p}_j^2$:

$$\boxed{\widehat{J}(h) = \frac{2}{(n-1)h} - \frac{n+1}{(n-1)h}\sum_j \hat{p}_j^2.}$$

Với phân hoạch cố định, $\mathbb{E}\hat{f}_{(-i),h}(x) = p_j/h = \mathbb{E}\hat{f}_{n,h}(x)$ trên ô j. Vì X_i độc lập với mẫu bỏ i,

$$\mathbb{E}\hat{f}_{(-i),h}(X_i) = \int \mathbb{E}\hat{f}_{(-i),h}(x) f(x)\,dx = \mathbb{E}\int \hat{f}_{n,h}(x) f(x)\,dx.$$

Suy ra $\mathbb{E}\widehat{J}(h) = \mathrm{MISE}_n(h) - R(f)$. Phần bình phương đầu dùng estimator cỡ mẫu n; không tự thay tất cả thành estimator cỡ mẫu $n-1$.

Ví dụ 2.2. Mẫu $(0.1, 0.2, 0.4, 0.8)$, ứng viên $m = 2, 4$. Với $m = 2$, số đếm $(3, 1)$ và $\sum \hat{p}_j^2 = 10/16$:

$$\widehat{J}(1/2) = \frac{2}{3/2} - \frac{5}{3/2}\frac{10}{16} = -\frac{3}{4}.$$

Với $m = 4$, số đếm $(2, 1, 0, 1)$ và $\sum \hat{p}_j^2 = 6/16$:

$$\widehat{J}(1/4) = \frac{2}{3/4} - \frac{5}{3/4}\frac{6}{16} = \frac{1}{6}.$$

Chọn $m = 2$ trong hai ứng viên. Điểm CV âm là bình thường vì nó ước lượng MISE trừ một hằng số dương.

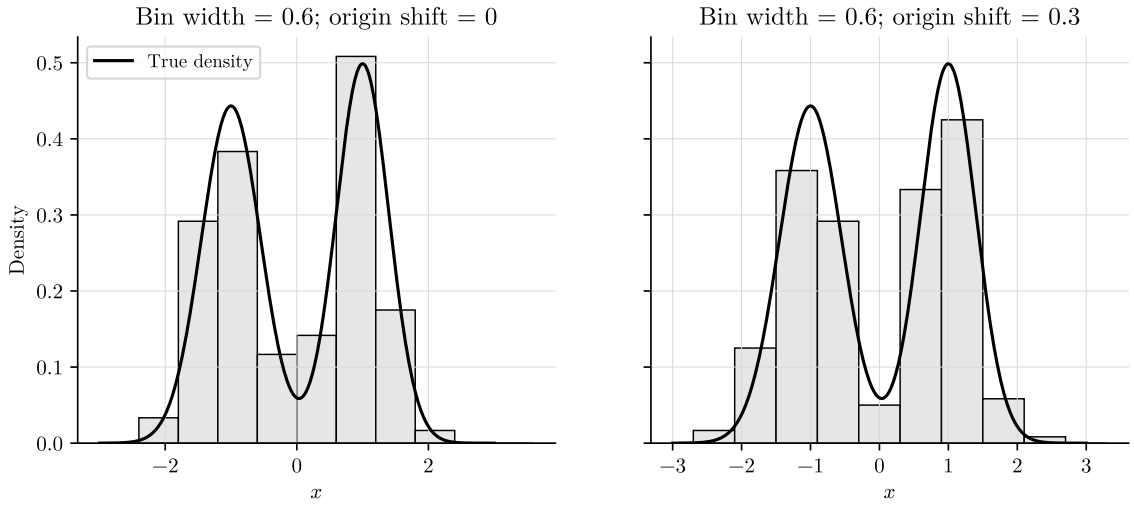
Lỗi dễ mắc. Nếu dùng chính X_i để đánh giá mật độ có chứa nó, quan sát tự đóng góp vào mật độ và làm thiên lệch tiêu chuẩn. Nếu chọn gốc ô từ mẫu, chứng minh không chệch cho phân hoạch cố định không còn áp dụng nguyên xi.

Trực giác và ý nghĩa thực tiễn. CV dùng một quan sát làm điểm đánh giá cho mô hình học từ những quan sát còn lại. Mục tiêu là tối ưu rủi ro, không phải làm đường cong trông đẹp nhất bằng mắt.

Đối chiếu nguồn: [2], slide 17; [4], Mục 6.1–6.2.

2.6 Bốn hạn chế cốt lõi

1. **Không liên tục.** Đường mật độ nhảy ở ranh giới ô; không phù hợp nếu muốn đạo hàm trơn hoặc vị trí đỉnh ổn định.
2. **Nhạy với gốc chia ô.** Dịch phân hoạch có thể làm một đỉnh bị tách hoặc gộp dù dữ liệu và độ rộng ô không đổi.
3. **Khả năng tận dụng độ trơn hạn chế.** Với hàm có độ dốc, bias thường $O(h)$, tốc độ MISE $n^{-2/3}$, chậm hơn KDE bậc hai trong lớp mật độ đủ trơn và điều kiện biên phù hợp.
4. **Khó mở rộng theo số chiều.** Với ô lập phương cạnh h, số ô tăng như h^{-d}, dữ liệu trong mỗi ô ít đi; phương sai có bậc $1/(nh^d)$.



Hình 2.1: Cùng mẫu và độ rộng ô, hai gốc chia ô khác nhau cho hai histogram. Đường liền là mật độ hỗn hợp thật. Hình dùng ô trên toàn trục để minh họa độ nhạy với gốc, khác thiết lập $h = 1/m$ trên $[0, 1]$ của phần chứng minh.

Trực giác và ý nghĩa thực tiễn. KDE thay việc gán toàn bộ khối lượng vào một ô bằng việc đặt một bản kernel quanh mỗi quan sát. Điều này loại bỏ gốc lưới cố định; mức độ trơn vẫn phụ thuộc kernel được chọn.

Đối chiếu nguồn: [2], slide 18.

Chương 3

Ước lượng mật độ bằng nhân

3.1 Định nghĩa và tính hợp lệ

Một kernel mật độ thông thường thỏa $K \geq 0$, $\int_{\mathbb{R}} K = 1$. Trong các khai triển bậc hai, còn dùng K đối xứng, $\mu_2(K) = \int u^2 K(u)\,du < \infty$ và $R(K) = \int K^2 < \infty$. Với $h > 0$,

$$\boxed{\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - X_i}{h}\right).}$$

Đây là trung bình của n mật độ co giãn, mỗi mật độ có tâm X_i.

Kiểm tra chuẩn hóa. Mỗi số hạng không âm, nên $\hat{f}_h \geq 0$. Trong số hạng thứ i, đặt $u = (x - X_i)/h$, $x = X_i + hu$, $dx = h\,du$:

$$\int_{\mathbb{R}} \hat{f}_h(x)\,dx = \frac{1}{n} \sum_i \int_{\mathbb{R}} \frac{1}{h} K((x - X_i)/h)\,dx = \frac{1}{n} \sum_i \int_{\mathbb{R}} K(u)\,du = 1.$$

Tổng hữu hạn cho phép đổi tổng và tích phân. Nhân có phần âm vẫn cho tích phân 1 nếu khả tích và chuẩn hóa, nhưng không đảm bảo không âm. □

3.1.1 KDE liên hệ với EDF như thế nào?

Đặt $G(t) = \int_{-\infty}^{t} K(u)\,du$. CDF của KDE là

$$\widetilde{F}_{n,h}(x) = \frac{1}{n} \sum_i G((x - X_i)/h) = \int K(u) \widehat{F}_n(x - hu)\,du.$$

Đẳng thức thứ hai đến từ $\mathbf{1}_{\{X_i \leq x - hu\}} = \mathbf{1}_{\{u \leq (x - X_i)/h\}}$. Nếu K liên tục, đạo hàm CDF này chính là KDE ở mọi điểm; với Uniform, đẳng thức đạo hàm đúng hầu khắp nơi.

Trực giác và ý nghĩa thực tiễn. EDF đặt các khối lượng điểm; KDE trải từng khối lượng đó ra một vùng rộng theo h. Tăng h là tăng mức trộn các vùng lân cận.
Đối chiếu nguồn: [2], slide 19–20; [4], trang in 132 (PDF 141).

3.2 Bảy kernel và đạo hàm

Trong bảng dưới, các kernel compact bằng 0 khi $|u| > 1$. Các biểu thức đạo hàm compact được ghi *bên trong* $|u| < 1$; ngoài miền giá đỡ, các đạo hàm bằng 0. Các điểm nối phải kiểm tra riêng. Đặt $t = |u|$, $\operatorname{sgn}(u) = u/|u|$ khi $u \neq 0$.

Kernel	$K(u)$, $K'(u)$, $K''(u)$
Gaussian	$K(u) = \varphi(u) = (2\pi)^{-1/2} e^{-u^2/2}$, $u \in \mathbb{R}$.
	$K'(u) = -u\varphi(u)$.
	$K''(u) = (u^2 - 1)\varphi(u)$.
Epanechnikov	$K(u) = \frac{3}{4}(1 - u^2)$.
	$K'(u) = -\frac{3}{2}u$.
	$K''(u) = -\frac{3}{2}$.
Uniform	$K(u) = \frac{1}{2}$.
	$K'(u) = 0$, $K''(u) = 0$.
Triangular	$K(u) = 1 - \lvert u \rvert$.
	$K'(u) = -\operatorname{sgn}(u)$ nếu $u \neq 0$.
	$K''(u) = 0$ nếu $u \neq 0$.
Biweight	$K(u) = \frac{15}{16}(1 - u^2)^2$.
	$K'(u) = -\frac{15}{4}u(1 - u^2)$.
	$K''(u) = \frac{15}{4}(3u^2 - 1)$.
Triweight	$K(u) = \frac{35}{32}(1 - u^2)^3$.
	$K'(u) = -\frac{105}{16}u(1 - u^2)^2$.
	$K''(u) = -\frac{105}{16}(1 - u^2)(1 - 5u^2)$.
Tricube	$K(u) = \frac{70}{81}(1 - t^3)^3$.
	$K'(u) = -\frac{70}{9}ut(1 - t^3)^2$.
	$K''(u) = -\frac{140}{9}t(1 - t^3)(1 - 4t^3)$.

Quy ước $K(\pm 1) = 1/2$ cho Uniform; các kernel compact còn lại có $K(\pm 1) = 0$. Giá trị tại hữu hạn điểm không ảnh hưởng moment nhưng có thể ảnh hưởng bài tính điểm khi quan sát nằm đúng trên ranh giới.

3.2.1 Khả vi tại điểm nối

- Gaussian trơn mọi bậc.
- Uniform không liên tục tại $u = \pm 1$, nên không có đạo hàm cổ điển ở đó.
- Epanechnikov liên tục nhưng không khả vi tại ± 1.
- Triangular không khả vi tại $-1, 0, 1$.
- Biweight khả vi liên tục bậc một; $K'(\pm 1) = 0$, nhưng K'' không tồn tại tại ± 1 vì giới hạn độ dốc của K' khác nhau.
- Triweight khả vi liên tục bậc hai, $K'(\pm 1) = K''(\pm 1) = 0$.
- Tricube khả vi liên tục bậc hai tại cả 0 và ± 1; $K'(0) = K''(0) = K'(\pm 1) = K''(\pm 1) = 0$.

Ví dụ, Epanechnikov có đạo hàm từ phía trong tại $u = 1$ bằng $-3/2$, phía ngoài bằng 0. Viết "$K'(1) = 0$ do có chỉ báo" là sai. Với Tricube, tính bên $u > 0$ rồi dùng tính chẵn của K, tính lẻ của K' để mở rộng; công thức K'' là chẵn và liên tục tại 0.

3.2.2 Ước lượng đạo hàm mật độ

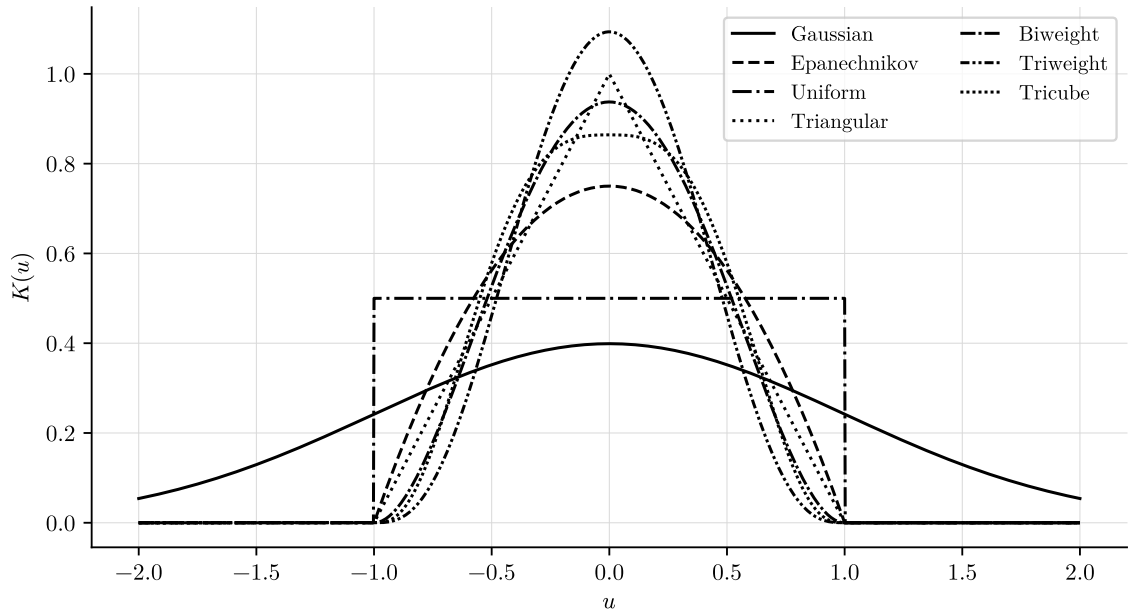
Tại một điểm mà mọi số hạng có đạo hàm tương ứng,

$$\boxed{\hat{f}_h'(x) = \frac{1}{nh^2} \sum_i K'((x - X_i)/h), \qquad \hat{f}_h''(x) = \frac{1}{nh^3} \sum_i K''((x - X_i)/h).}$$

Mỗi lần dùng quy tắc dây chuyền, $d[(x - X_i)/h]/dx = 1/h$, nên xuất hiện thêm một thừa số $1/h$. Nếu một số hạng không khả vi, phải xét *tổng* bằng giới hạn một phía; các điểm gãy đôi khi có thể triệt tiêu. Không tự kết luận chỉ bằng tính khả vi của một số hạng.

Đặc biệt, đạo hàm Uniform bằng 0 hầu khắp nơi, nhưng không phải một ước lượng nhất quán hữu ích của f' thông qua công thức đạo hàm cổ điển. Đạo hàm theo nghĩa phân phối có khối lượng Dirac ở các bước nhảy; nó không phải giá trị số của một hàm mật độ đạo hàm thông thường. Với kernel đủ trơn, phương sai của estimator đạo hàm bậc q có bậc $1/(nh^{2q+1})$, cho thấy ước lượng đạo hàm khó hơn ước lượng mật độ.

Trực giác và ý nghĩa thực tiễn. Độ trơn của KDE đến từ kernel. "KDE luôn trơn" không đúng với Uniform hoặc Triangular. Muốn tìm độ cong một cách ổn định, nên dùng kernel có đủ đạo hàm và bandwidth phù hợp với mục tiêu đạo hàm.



Hình 3.1: Bảy kernel đã chuẩn hóa. Tất cả compact có giá đỡ $[-1, 1]$; Gaussian có đuôi trên toàn trục. Hình không thay thế kiểm tra khả vi tại điểm nối.

3.3 Chứng minh độ chệch của KDE

Xét điểm nội, hoặc mật độ đủ trơn trên toàn $\mathbb{R}$ mà không có gián đoạn do biên. Một bộ giả thiết đủ cho khai triển dưới đây là $f \in C^4(\mathbb{R})$ với đạo hàm bậc bốn bị chặn, K đối xứng, $\int |u|^4 |K(u)|\, du < \infty$, $\int K = 1$.

Bước 1: đưa kỳ vọng về tích phân làm trơn. Đặt $Z_i(x) = h^{-1}K((x - X_i)/h)$. Tuyến tính cho $\mathbb{E}\hat{f}_h(x) = \mathbb{E}Z_1(x)$. Dùng $u = (x - t)/h$,

$$\begin{aligned}\mathbb{E}\hat{f}_h(x) &= \int \frac{1}{h} K((x-t)/h) f(t)\, dt \\ &= \int K(u) f(x - hu)\, du.\end{aligned}$$

Hệ số $1/h$ triệt tiêu với h trong vi phân; dấu âm của vi phân được triệt tiêu khi đảo cận.

Bước 2: Taylor đến bậc ba và chặn phần dư.

$$f(x - hu) = f(x) - huf'(x) + \frac{h^2u^2}{2} f''(x) - \frac{h^3u^3}{6} f'''(x) + \mathcal{R}_4(x, u, h),$$

với $|\mathcal{R}_4| \le \|f^{(4)}\|_\infty h^4|u|^4/24$. Tích phân phần dư nhân K có trị tuyệt đối $O(h^4)$ nhờ moment tuyệt đối bậc bốn hữu hạn.

Bước 3: dùng moment của kernel. Vì kernel chẵn, $uK(u)$ và $u^3K(u)$ lẻ và khả tích, nên tích phân trên miền đối xứng bằng 0. Vì $\int K = 1$,

$$\mathbb{E}\hat{f}_h(x) = f(x) + \frac{h^2}{2}\mu_2(K)f''(x) + O(h^4),$$

$$\boxed{\text{Bias}(\hat{f}_h(x)) = \frac{h^2}{2}\mu_2(K)f''(x) + O(h^4).}$$

Nếu chỉ có f'' liên tục và điều kiện chi phối phù hợp, kết quả thường là $h^2\mu_2 f''/2 + o(h^2)$; không tự nâng phần dư lên $O(h^4)$.

3.3.1 Ý nghĩa hình học của độ cong

Với kernel không âm, $\mu_2(K) > 0$. Ở đỉnh cong xuống, $f''(x) < 0$: chệch dẫn đầu âm, KDE trung bình làm thấp đỉnh (undershoot). Ở đáy cong lên, $f''(x) > 0$: chệch dẫn đầu dương, KDE làm đầy đáy (overshoot). Nếu $f''(x) = 0$, số hạng dẫn đầu mất; cần xem bậc cao hơn thay vì dùng công thức tối ưu chia cho $f''(x)^2$.

Trực giác và ý nghĩa thực tiễn. Làm trơn là lấy trung bình các giá trị lân cận. Đỉnh lấy trung bình với các giá trị thấp hơn, đáy với các giá trị cao hơn. Độ cong, không phải độ dốc đơn thuần, điều khiển bias bậc hai vì moment lẻ đã triệt tiêu.

Đối chiếu nguồn: [2], slide 21; [4], trang in 133–134 (PDF 142–143).

3.4 Chứng minh phương sai và AMSE

Giả sử thêm f bị chặn và Lipschitz, $\int |u|K(u)^2\,du < \infty$.

Bước 1: dùng độc lập giữa các quan sát.

$$\text{Var}\,\hat{f}_h(x) = \frac{1}{n}\,\text{Var}\,Z_1(x) = \frac{1}{n}\{\mathbb{E}Z_1(x)^2 - [\mathbb{E}Z_1(x)]^2\}.$$

Bước 2: tính moment bậc hai bằng đổi biến.

$$\mathbb{E}Z_1(x)^2 = \int \frac{1}{h^2}K((x-t)/h)^2 f(t)\,dt = \frac{1}{h}\int K(u)^2 f(x-hu)\,du.$$

Do Lipschitz, $|f(x-hu) - f(x)| \le Ch|u|$, nên

$$\mathbb{E}Z_1(x)^2 = \frac{f(x)R(K)}{h} + O(1).$$

Mặt khác, $\mathbb{E}Z_1(x)$ bị chặn bởi $\|f\|_\infty \int |K|$, nên bình phương kỳ vọng là $O(1)$. Suy ra

$$\boxed{\text{Var}\,\hat{f}_h(x) = \frac{f(x)R(K)}{nh} + O(1/n).}$$

Với f chỉ liên tục tại x và điều kiện chi phối, thường có dạng $f(x)R(K)/(nh) + o(1/(nh))$; phần dư cụ thể cần điều kiện cụ thể.

Bước 3: cộng bình phương chệch và phương sai.

$$\boxed{\text{AMSE}_x(h) = \frac{h^4}{4}\mu_2(K)^2 f''(x)^2 + \frac{f(x)R(K)}{nh}.}$$

Nếu $f(x) > 0$, $f''(x) \neq 0$, tối ưu tại điểm cho

$$h_{*,x} = \left[\frac{f(x)R(K)}{\mu_2(K)^2 f''(x)^2}\right]^{1/5} n^{-1/5}.$$

Nếu $h \to 0$, $nh \to \infty$, bias và variance về 0, nên $\hat{f}_h(x) \xrightarrow{P} f(x)$ qua bất đẳng thức Markov cho sai số bình phương. Với kernel bị chặn, compact và f liên tục tại x, chứng minh nhất quán này không cần đủ bốn đạo hàm.

Trực giác và ý nghĩa thực tiễn. Một cửa sổ rộng chứa khoảng $nhf(x)$ quan sát. Khi cửa sổ hẹp đi, số quan sát hữu hiệu giảm và mật độ dao động mạnh hơn.

3.5 AMISE và băng thông toàn cục

Để tích phân khai triển bias, cần kiểm soát phần dư theo chuẩn L_2, không chỉ theo từng điểm. Một bộ giả thiết đủ là $f \in L_2(\mathbb{R})$, các đạo hàm yếu đến bậc bốn thuộc L_2, và $\int |u|^4 |K(u)|\, du < \infty$. Khi đó Taylor theo chuẩn L_2 cho

$$\left\| \mathbb{E}\hat{f}_h - f - \tfrac{1}{2}h^2\mu_2(K) f'' \right\|_2 = O(h^4),$$

nên tích phân bình phương bias bằng $h^4\mu_2(K)^2 R(f'')/4 + O(h^6)$. Hạng chéo được chặn bằng Cauchy–Schwarz: $2\left\|h^2\mu_2 f''/2\right\|_2 O(h^4) = O(h^6)$.

Phương sai tích phân có đẳng thức hữu ích, với $f_h = K_h * f$:

$$\begin{aligned}\int \operatorname{Var}\hat{f}_h(x)\, dx &= \frac{1}{nh}\int\int K(u)^2 f(x - hu)\, du\, dx - \frac{1}{n}\int f_h(x)^2\, dx \\ &= \boxed{\frac{R(K)}{nh} - \frac{R(f_h)}{n}}.\end{aligned}$$

Tích phân hai lớp đầu không âm nên dùng Tonelli; với mỗi u, $\int f(x - hu)\, dx = 1$. Nếu K khả tích, $f \in L_2$ thì $\|f_h\|_2 \le \|K\|_1 \|f\|_2$, nên số hạng trừ là $O(1/n)$. Không được tích phân một chặn $O(1/n)$ hằng theo x trên toàn $\mathbb{R}$ để kết luận nó vẫn là $O(1/n)$; đẳng thức này tránh lỗi đó.

Đặt $A = R(f'') > 0$. Khi bỏ các hạng bậc nhỏ,

$$\operatorname{AMISE}(h) = \frac{\mu_2(K)^2 A}{4} h^4 + \frac{R(K)}{nh}.$$

Đạo hàm và giải:

$$\mu_2(K)^2 A h^3 - \frac{R(K)}{nh^2} = 0, \qquad \boxed{h_* = \left[\frac{R(K)}{\mu_2(K)^2 R(f'')}\right]^{1/5} n^{-1/5}.}$$

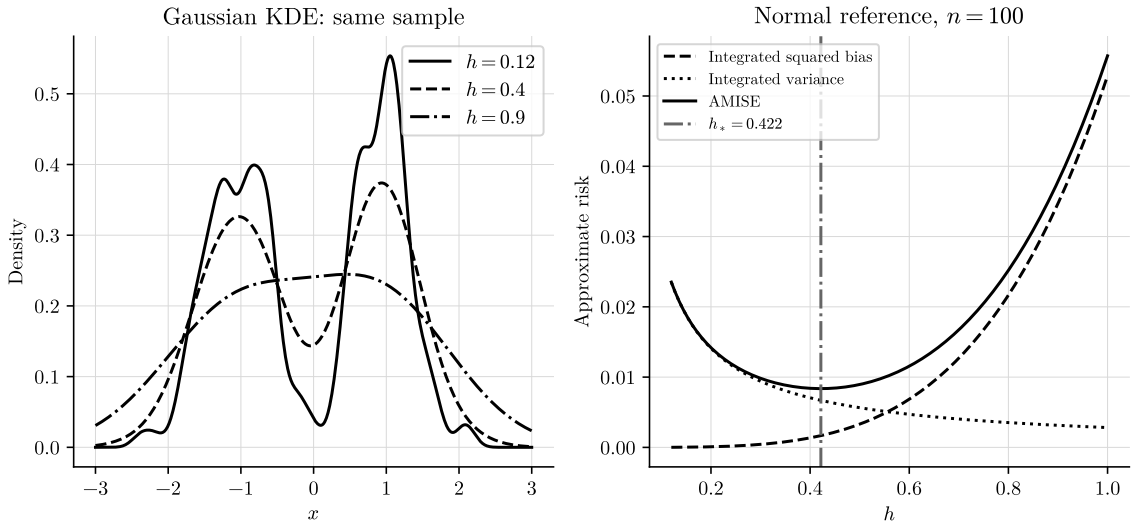
Tại nghiệm, variance chính bằng bốn lần squared bias chính. Vì vậy

$$\boxed{\operatorname{AMISE}(h_*) = \frac{5}{4} R(K)^{4/5}\mu_2(K)^{2/5} R(f'')^{1/5} n^{-4/5}.}$$

Histogram bậc một cho $n^{-2/3}$; KDE bậc hai cho $n^{-4/5}$ trong thiết lập đủ trơn, không bị chệch biên chi phối. Đây là tốc độ MISE, không phải tốc độ RMSE: căn của $n^{-4/5}$ là $n^{-2/5}$.

Trực giác và ý nghĩa thực tiễn. Bandwidth nhỏ không miễn phí: giảm chệch nhưng tăng phương sai. So sánh kernel cùng bậc thường thay đổi hằng số; thay bandwidth thay đổi cả hai thành phần rủi ro theo các lũy thừa khác nhau.

Đối chiếu nguồn: [2], slide 25–26; [4], trang in 133–135 (PDF 142–144).



Hình 3.2: Trái: cùng mẫu, ba bandwidth KDE Gaussian. Phải: hai thành phần AMISE và tổng của chúng trong mô hình chuẩn chuẩn tắc, $n = 100$. Các đường AMISE là xấp xỉ lý thuyết, không phải MISE thực nghiệm.

3.6 Quy tắc tham chiếu chuẩn và Silverman

3.6.1 Dẫn ra hệ số 1.06

Giả sử dùng kernel Gaussian và lấy mật độ chuẩn $N(\mu, \sigma^2)$ làm tham chiếu. Với $z = (x - \mu)/\sigma$,

$$f(x) = \frac{1}{\sigma}\varphi(z), \qquad f''(x) = \frac{z^2 - 1}{\sigma^3}\varphi(z).$$

Vì $dx = \sigma\, dz$,

$$\begin{aligned} R(f'') &= \frac{1}{2\pi\sigma^5}\int (z^2-1)^2 e^{-z^2}\, dz \\ &= \frac{1}{2\pi\sigma^5}\left(\frac{3\sqrt{\pi}}{4} - 2\frac{\sqrt{\pi}}{2} + \sqrt{\pi}\right) = \frac{3}{8\sqrt{\pi}\sigma^5}. \end{aligned}$$

Các tích phân được tính từ $\int e^{-z^2} = \sqrt{\pi}$ và tích phân từng phần $\int z^{2k} e^{-z^2} = (2k-1)\int z^{2k-2}e^{-z^2}/2$. Hạng biên $z^{2k-1}e^{-z^2}$ về 0 ở hai đầu. Với Gaussian, $\mu_2(K) = 1$, $R(K) = 1/(2\sqrt{\pi})$, nên

$$h_*^5 = \frac{1/(2\sqrt{\pi})}{3/(8\sqrt{\pi}\sigma^5)n} = \frac{4\sigma^5}{3n}, \qquad \boxed{h_{\mathrm{NR}} = (4/3)^{1/5}\sigma n^{-1/5} \approx 1.059224\sigma n^{-1/5}.}$$

Thay σ bằng độ lệch chuẩn mẫu s cho $1.06 s n^{-1/5}$. Mô hình chuẩn là giả thiết dùng để tính bandwidth, không phải kết luận rằng dữ liệu thật có phân phối chuẩn.

3.6.2 Các phiên bản thực hành cần phân biệt

Ở $N(\mu, \sigma^2)$, $\mathrm{IQR} = 2\Phi^{-1}(0.75)\sigma \approx 1.349\sigma$. Đặt $a = \min\{s, \mathrm{IQR}/1.34\}$. Wasserman dùng $1.06 a n^{-1/5}$ cho quy tắc tham chiếu chuẩn; quy tắc Silverman bền vững thường viết $0.9 a n^{-1/5}$. Hệ số 0.9 không xuất phát từ cùng phép tối ưu chuẩn vừa chứng minh. Trong bài số của giáo trình, nếu không ghi khác, dùng $s^2 = (n-1)^{-1}\sum_i (X_i - \overline{X})^2$ và hệ số chính xác $(4/3)^{1/5}$, rồi mới làm tròn thành 1.06 khi cần minh họa. Nếu tính IQR, dùng quantile thực nghiệm đã định nghĩa ở Chương 1; các phần mềm nội suy có thể cho IQR khác ở mẫu nhỏ. Nếu $s = 0$, công

thức cho bandwidth 0, không hợp lệ cho KDE: phải có thông tin về độ phân giải hoặc chọn một bandwidth dương bên ngoài quy tắc; không âm thầm chia cho 0.

Trực giác và ý nghĩa thực tiễn. Quy tắc chuẩn nhanh vì thay đại lượng khó $R(f'')$ bằng công thức của một mật độ tham chiếu. Mật độ nhiều đỉnh hoặc có đỉnh hẹp có thể bị làm trơn quá mức; CV là một lựa chọn khác.

Đối chiếu nguồn: [2], slide 27; [4], trang in 135 (PDF 144).

3.7 LOOCV cho KDE: công thức hữu hạn mẫu chính xác

Giữ cùng h khi bỏ quan sát:

$$\hat{f}_{(-i),h}(X_i) = \frac{1}{(n-1)h} \sum_{j \neq i} K((X_i - X_j)/h).$$

Với $n \geq 2$, dùng

$$\widehat{J}(h) = \int \hat{f}_h^2(x)\, dx - \frac{2}{n} \sum_i \hat{f}_{(-i),h}(X_i).$$

Để tính tích phân đầu, khai triển bình phương thành tổng đôi. Trong cặp (i, j), đặt $u = (x - X_i)/h$, $dx = h\, du$:

$$\int \frac{1}{h^2} K((x - X_i)/h) K((x - X_j)/h)\, dx = \frac{1}{h} \int K(u) K(u + (X_i - X_j)/h)\, du.$$

Đặt $C_K(v) = \int K(u)K(u + v)\, du$. Với kernel chẵn, $C_K = K * K$ và ký hiệu $K^{(2)}$ thường được dùng. Suy ra công thức chính xác

$$\boxed{\widehat{J}(h) = \frac{1}{n^2 h} \sum_{i,j} C_K((X_i - X_j)/h) - \frac{2}{n(n-1)h} \sum_{i \neq j} K((X_i - X_j)/h).}$$

Tổng đầu có đường chéo, tổng sau không có. Với Gaussian,

$$C_K(v) = \frac{1}{2\sqrt{\pi}} e^{-v^2/4},$$

là mật độ $N(0, 2)$, có độ lệch chuẩn $\sqrt{2}$, không phải 2. Với Uniform, $C_K(v) = (2 - |v|)_+/4$, vì tích hai chiều cao bằng $1/4$ trên khoảng giao dài $(2 - |v|)_+$.

Tính không chệch của tiêu chuẩn. X_i độc lập với mẫu bỏ i, nên $\mathbb{E}\hat{f}_{(-i),h}(X_i) = \int f_h(x) f(x)\, dx$. Mặt khác $\mathbb{E}\hat{f}_h = f_h$ dù dùng n hay $n - 1$ quan sát. Khai triển MISE cho

$$\boxed{\mathbb{E}\widehat{J}(h) = \mathrm{MISE}_n(h) - R(f).}$$

Điều kiện $f \in L_2$, $K \in L_1 \cap L_2$ đảm bảo các hạng này hữu hạn. Đẳng thức đúng cho h cố định; chọn cực tiểu theo dữ liệu không làm $\widehat{J}(\hat{h})$ thành ước lượng không chệch của rủi ro được chọn.

Trong thực hành, chọn một tập hữu hạn bandwidth dương và lấy điểm CV nhỏ nhất; nếu bằng nhau, quy ước chọn bandwidth lớn hơn để ưu tiên làm trơn. Một ứng viên nhỏ nhất ở mép lưới là tín hiệu cần kiểm tra phạm vi lưới. Không có bảo đảm rằng CV hữu hạn mẫu luôn chọn tốt nhất; với dữ liệu trùng lặp, bandwidth cực nhỏ có thể gây hành vi suy biến.

Trực giác và ý nghĩa thực tiễn. LOO loại sự tự đóng góp $K(0)/(nh)$ của mỗi điểm. Tổng đôi chính xác giúp tính CV mà không cần tích phân số cả một đường KDE.

Đối chiếu nguồn: [4], trang in 135–136 (PDF 144–145), phương trình 6.33; ở đây giữ mẫu số $n - 1$ chính xác thay vì dùng dạng xấp xỉ 6.35.

3.8 Nhân bậc cao

Trong tài liệu này, kernel bậc ℓ nghĩa là

$$\int K = 1, \quad \mu_j(K) = 0 \ (1 \le j < \ell), \quad \mu_\ell(K) \neq 0.$$

Đây là một quy ước; Tsybakov dùng cách đặt tên khác cho số moment bị triệt tiêu. Luôn kiểm tra các moment thực tế thay vì chỉ đọc chữ "bậc". Với f có đủ đạo hàm, moment tuyệt đối bậc ℓ hữu hạn và điều kiện phần dư thích hợp,

$$\mathrm{Bias}(\hat{f}_h(x)) = \frac{(-h)^\ell}{\ell!}\mu_\ell(K) f^{(\ell)}(x) + o(h^\ell).$$

Tất cả hạng bậc thấp mất nhờ moment bằng 0. Nếu khai triển đúng theo L_2, MISE có phần chính $Ah^{2\ell} + R(K)/(nh)$, nên

$$h_* \asymp n^{-1/(2\ell+1)}, \qquad \mathrm{MISE} = O(n^{-2\ell/(2\ell+1)}).$$

Không thể dùng tốc độ này khi mật độ không có độ trơn tương ứng.

Ví dụ 3.1 (Kernel Gaussian bậc bốn)**.** Đặt $K_4(u) = (3 - u^2)\varphi(u)/2$. Moment chuẩn tắc cho $\mathbb{E}Z^2 = 1$, $\mathbb{E}Z^4 = 3$, $\mathbb{E}Z^6 = 15$:

$$\int K_4 = (3-1)/2 = 1, \quad \mu_2(K_4) = (3-3)/2 = 0, \quad \mu_4(K_4) = (9-15)/2 = -3.$$

Moment lẻ bằng 0 do đối xứng. Vậy đây là kernel bậc bốn theo quy ước trên, cho bias $-h^4 f^{(4)}(x)/8 + o(h^4)$ và tốc độ $n^{-8/9}$. Nhưng $K_4(u) < 0$ khi $|u| > \sqrt{3}$: KDE có thể âm.

Một kernel không âm, chuẩn hóa không thể có $\mu_2 = 0$ trừ một phân phối tập trung tại 0, vốn không phải kernel mật độ thông thường: $u^2 K(u) \ge 0$ mà tích phân bằng 0 thì $K = 0$ hầu khắp nơi ngoài 0. Do đó triệt tiêu moment bậc hai buộc kernel thông thường có phần âm.

Trực giác và ý nghĩa thực tiễn. Nhân bậc cao dùng các vùng âm để bù chệch của vùng dương. Đổi lại tốc độ nhanh hơn trên hàm rất trơn là mất tính không âm và tăng yêu cầu về độ trơn của mật độ.

Đối chiếu nguồn: [2], slide 22; [5], Mục 1.2.2.

3.9 Lớp Hölder và chặn rủi ro

3.9.1 Định nghĩa không suy biến ở bậc nguyên

Với $\beta > 0$, đặt $r = \lceil \beta \rceil - 1$, $\eta = \beta - r \in (0, 1]$. Một hàm trong $\Sigma(\beta, L)$ có đạo hàm liên tục đến bậc r và

$$|f^{(r)}(x) - f^{(r)}(y)| \le L|x - y|^\eta.$$

Đồng thời yêu cầu $f \ge 0$, $\int f = 1$ khi xét lớp mật độ; dùng thêm chặn $\|f\|_\infty \le M$ khi chứng minh chặn phương sai. Với $r = 0$ đây là điều kiện trực tiếp trên f; với $\beta = 2$, f' là Lipschitz. Không viết $|f(x) - f(y)| \le L|x - y|^\beta$ cho mọi $\beta > 1$ trên một khoảng: điều kiện ấy buộc f hằng.

3.9.2 Chặn bias bằng Taylor có phần dư Hölder

Taylor đến bậc r cho

$$f(x + t) = \sum_{j=0}^{r} \frac{f^{(j)}(x)}{j!} t^j + \mathcal{R}_\beta, \qquad |\mathcal{R}_\beta| \le \frac{L}{r!}|t|^\beta.$$

Với $r = 0$ đây chính là định nghĩa. Với $r \geq 1$, Taylor dạng tích phân đến bậc $r-1$, rồi trừ và cộng $f^{(r)}(x)$ trong tích phân:

$$\mathcal{R}_\beta = \frac{t^r}{(r-1)!} \int_0^1 (1-s)^{r-1} [f^{(r)}(x+st) - f^{(r)}(x)]\, ds.$$

Trị tuyệt đối bị chặn bởi $L|t|^{r+\eta}/(r-1)!$ nhân $\int_0^1 (1-s)^{r-1} s^\eta ds \leq 1/r$; đó là chặn đã nêu. Nếu kernel triệt tiêu moment $1, \dots, r$ và $M_\beta(K) = \int |u|^\beta |K(u)|\, du < \infty$, thì

$$\operatorname{Bias}(\hat{f}_h(x)) = \int K(u) \mathcal{R}_\beta(x, -hu)\, du,$$

$$\boxed{|\operatorname{Bias}(\hat{f}_h(x))|} \boxed{\leq (L/r!) M_\beta(K) h^\beta.}$$

Tính đối xứng chỉ tự triệt tiêu moment lẻ, không triệt tiêu mọi moment.

3.9.3 Chặn variance và MSE

Không cần Taylor để có chặn phương sai:

$$\operatorname{Var} \hat{f}_h(x) \leq \frac{1}{n} \mathbb{E} Z_1(x)^2 = \frac{1}{nh} \int K^2(u) f(x-hu)\, du \leq \boxed{\frac{MR(K)}{nh}}.$$

Đặt $C_b = (L/r!) M_\beta(K)$, ta có

$$\sup_f \operatorname{MSE}_f(\hat{f}_h(x)) \leq C_b^2 h^{2\beta} + \frac{MR(K)}{nh}.$$

Chọn $h \asymp n^{-1/(2\beta+1)}$ cho chặn $O(n^{-2\beta/(2\beta+1)})$. Đây là chặn đều *tại điểm*; không tích phân hằng số trên toàn $\mathbb{R}$ để suy ra MISE hữu hạn. Để có MISE cùng bậc, dùng điều kiện độ trơn theo chuẩn L_2 như lớp Sobolev, hoặc miền compact với xử lý biên và chặn bias đồng đều. Phương sai tích phân luôn bị chặn bởi $R(K)/(nh)$.

Đối chiếu nguồn: [5], Mệnh đề 1.1–1.2 và Định lý 1.1, trang in 4–9 (PDF 15–20); Mệnh đề 1.4, trang in 12 (PDF 23).

3.9.4 Minimax: vì sao đây là tốc độ tốt nhất?

Với lớp mật độ Hölder có chặn nêu trên và x_0 ở miền nội thích hợp, đặt

$$\mathcal{R}_n^*(x_0) = \inf_{T_n} \sup_{f \in \mathcal{F}} \mathbb{E}_f [T_n - f(x_0)]^2.$$

Infimum chạy trên mọi estimator đo được từ mẫu. Kết quả lower bound cho lớp đủ phong phú là

$$\mathcal{R}_n^*(x_0) \geq c n^{-2\beta/(2\beta+1)},$$

với $c > 0$ phụ thuộc lớp, không phụ thuộc n. Kết hợp chặn trên vừa chứng minh cho tốc độ minimax. Chặn trên của riêng KDE không tự chứng minh lower bound cho mọi estimator.

Phác thảo lower bound tại điểm. Chọn mật độ nền f_0 dương quanh x_0, thêm một nhiễu $\delta a^\beta \psi((x-x_0)/a)$ có $\int \psi = 0$, $\psi(0) \neq 0$, compact và đủ trơn. Với δ nhỏ, mật độ mới f_1 vẫn không âm, chuẩn hóa và ở cùng lớp. Hai giá trị tại x_0 cách nhau bậc a^β.

$$\int \frac{(f_1 - f_0)^2}{f_0}\, dx = O(a^{2\beta+1}), \quad \operatorname{KL}(P_1^n, P_0^n) = O(n a^{2\beta+1}).$$

Chọn $a \asymp n^{-1/(2\beta+1)}$ để hai luật mẫu khó phân biệt. Lower bound kiểm định hai giả thuyết (Le Cam) buộc sai số bình phương ít nhất có bậc $a^{2\beta}$. Đây là phác thảo, các bổ đề kiểm định được viện dẫn từ [5], Chương 2. Với rủi ro tích phân, đặt nhiều nhiễu trên các ô rời nhau và dùng Assouad/Fano; Wasserman Định lý 6.31 cho lower bound MISE trên lớp $R(f^{(m)}) \le c^2$, đạt $n^{-2m/(2m+1)}$.

Trực giác và ý nghĩa thực tiễn. Độ trơn cho phép mượn thông tin ở lân cận. Lower bound nói rằng dù chọn thuật toán nào, một lớp có nhiều nhiễu nhỏ khó phân biệt vẫn đặt ra giới hạn thông tin. Minimax là kết luận theo lớp và loại mất mát.

3.10 Chệch biên và cách xử lý

Giả sử miền giá đỡ là $[0,\infty)$, $f(0+) > 0$, kernel chẵn. Tại 0,

$$\mathbb{E}\hat{f}_h(0) = \int_0^\infty \frac{1}{h} K(-t/h) f(t)\, dt = \int_0^\infty K(u) f(hu)\, du.$$

Nếu f liên tục phải và điều kiện chi phối thỏa, giới hạn bằng $f(0+)\int_0^\infty K = f(0+)/2$. Vì vậy

$$\boxed{\text{Bias}(\hat{f}_h(0)) \to -f(0+)/2.}$$

Chệch ngay tại biên có thể là $O(1)$, không phải $O(h)$. Vùng biên rộng $O(h)$ với chệch không tiêu biến có thể làm squared bias tích phân bậc $O(h)$ và phá tốc độ AMISE nội miền.

3.10.1 Phản xạ

Trên nửa trục, định nghĩa

$$\hat{f}_R(x) = \frac{1}{nh} \sum_i \{K((x - X_i)/h) + K((x + X_i)/h)\}, \quad x \ge 0.$$

Với kernel chẵn, tổng diện tích của hai bản kernel trên $[0,\infty)$ bằng 1 cho mỗi quan sát: phần bị cắt của bản tâm X_i được bản tâm $-X_i$ bù lại. Vì vậy estimator không âm và tích phân 1 trên nửa trục. Tại 0,

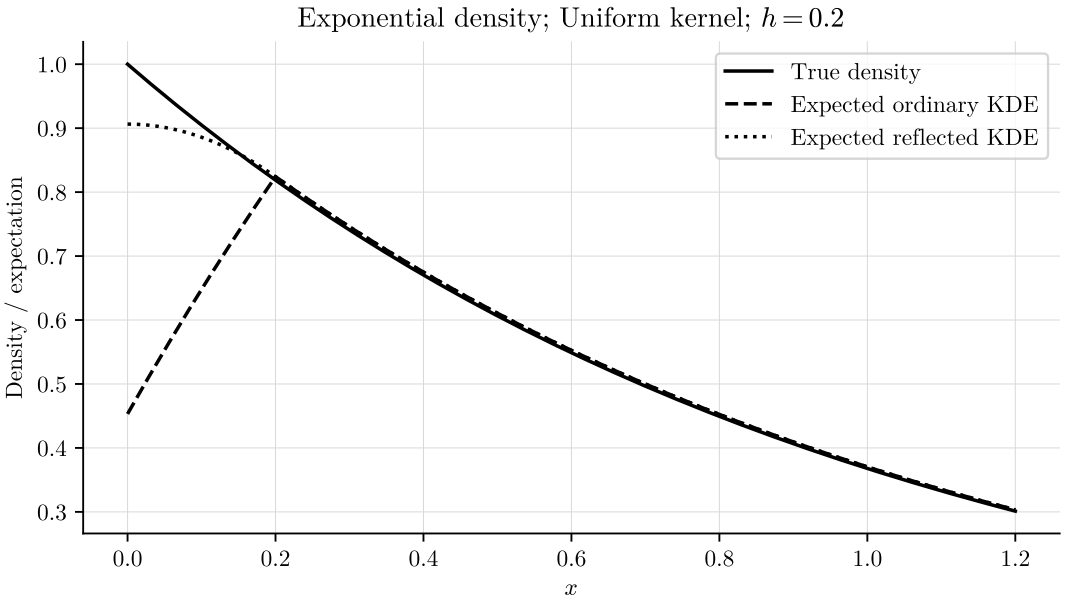
$$\begin{aligned}\mathbb{E}\hat{f}_R(0) &= 2\int_0^\infty K(u) f(hu)\, du \\ &= f(0+) + 2hf'(0+)\int_0^\infty uK(u)\, du + O(h^2).\end{aligned}$$

Phản xạ bỏ chệch hằng số, nhưng nếu $f'(0+) \ne 0$, bias vẫn $O(h)$. Nếu $f'(0+) = 0$ và đủ trơn, có thể đạt $O(h^2)$. Với $f(x) = e^{-x}\mathbf{1}_{x\ge 0}$ và Uniform, $\mathbb{E}\hat{f}_h(0) = (1-e^{-h})/(2h)$, $\mathbb{E}\hat{f}_R(0) = (1-e^{-h})/h = 1 - h/2 + O(h^2)$.

3.10.2 Boundary kernel

Ở biên 0, có thể dùng trọng số tương đương L trên $[0,1]$ thỏa $\int_0^1 L = 1$, $\int_0^1 uL(u)du = 0$. Ví dụ $L(u) = 4 - 6u$ trên $[0,1]$. Khi đó estimator $(nh)^{-1}\sum_i L(X_i/h)\mathbf{1}_{\{0\le X_i\le h\}}$ có kỳ vọng $\int_0^1 L(u)f(hu)du = f(0) + O(h^2)$. Moment bậc một triệt tiêu cả khi cửa sổ chỉ một phía. Nhưng L có phần âm; estimator không tự động là mật độ không âm, và đây là công thức *tại biên*, không phải kernel chung cho toàn miền. Chỉ chuẩn hóa lại kernel bị cắt mà không triệt tiêu moment bậc một thường chỉ cải thiện bias về $O(h)$.

Trực giác và ý nghĩa thực tiễn. Kernel đối xứng chỉ triệt tiêu moment lẻ khi có dữ liệu ở cả hai phía. Ở biên, một phía không tồn tại nên phép triệt tiêu mất hiệu lực.



Hình 3.3: Mật độ mũ và kỳ vọng KDE Uniform tại $h = 0.2$. Reflection sửa phần thiếu khối lượng nhưng vẫn còn chệch bậc nhất tại 0. Đường vẽ là kỳ vọng tính giải tích, không phải KDE của một mẫu.

3.11 Suy luận thống kê cho mật độ: kiểm soát chệch

Ở điểm nội với $f(x) > 0$, kernel và mật độ thỏa điều kiện CLT cho mảng tam giác, $h \to 0$, $nh \to \infty$,

$$\sqrt{nh}[\hat{f}_h(x) - \mathbb{E}\hat{f}_h(x)] \Rightarrow N(0, f(x)R(K)).$$

CLT này canh tâm ở $f_h(x) = \mathbb{E}\hat{f}_h(x)$, không tự ở $f(x)$. Nếu $h \asymp n^{-1/5}$, bias h^2 và độ lệch chuẩn $(nh)^{-1/2}$ cùng bậc. Muốn bỏ bias để suy luận cho $f(x)$, một điều kiện đủ là

$$\sqrt{nh}\, h^2 \to 0 \quad \Longleftrightarrow \quad nh^5 \to 0,$$

đồng thời $nh \to \infty$; đây là undersmoothing. Khi các điều kiện này thỏa, khoảng tại điểm xấp xỉ là $\hat{f}_h(x) \pm z_{1-\alpha/2}\sqrt{R(K)\hat{f}_h(x)/(nh)}$ với kernel mật độ không âm. Một băng đồng thời cần thêm kiểm soát supremum của quá trình ngẫu nhiên, không chỉ lấy cùng hệ số chuẩn ở mọi x.

Trực giác và ý nghĩa thực tiễn. Bandwidth tối ưu để ước lượng theo MSE chưa chắc phù hợp để lập khoảng tin cậy bỏ qua bias. Chương 5 tiếp tục vấn đề này với Root–Unroot.

Đối chiếu nguồn: [2], slide 28; [4], Chương 5, Mục 5.7 và Chương 6.

Chương 4

Ước lượng chiếu và lựa chọn mô hình

4.1 Bắt đầu bằng ba câu hỏi, chưa cần toán cao cấp

Bạn đã gặp histogram ở Chương 2: chia miền thành các ô, đếm dữ liệu, rồi vẽ một chiều cao trên mỗi ô. Ước lượng chiếu mở rộng ý tưởng này: *chọn một số hình dạng đơn giản, rồi ghép chúng thành đường ước lượng.*

Trong chương này, ta trả lời lần lượt ba câu hỏi:

1. **Ghép bằng cái gì?** Dùng các hàm cơ sở: có thể là hình chữ nhật, hoặc sóng sin và cos.
2. **Mỗi hình dạng đóng góp bao nhiêu?** Tính các hệ số từ dữ liệu.
3. **Dùng bao nhiêu hình dạng?** Chọn số chiều D: ít quá thì mất chi tiết, nhiều quá thì giữ cả nhiễu của mẫu.

Cách đọc. Lần đầu, đọc từ ví dụ histogram đến phần oracle và câu hỏi tự kiểm tra. Phần "Đọc thêm" ở cuối giữ các chứng minh nâng cao; bạn có thể quay lại sau khi giải thích được ví dụ bằng lời. Không cần hiểu chuỗi vô hạn ngay để tính được một ước lượng chiếu.

Trực giác và ý nghĩa thực tiễn. Hãy coi D là số thành phần bạn cho phép đường ước lượng sử dụng. Bài toán có hai bước riêng: với D đã cho, dựng đường; sau đó mới so sánh các D để chọn đường phù hợp.

4.2 Một ví dụ histogram dùng xuyên suốt chương

4.2.1 Dữ liệu và ba cách chia ô

Giả sử dữ liệu nằm trên $[0, 1]$. Cho tám quan sát

$$X = (0.10, 0.12, 0.20, 0.30, 0.40, 0.60, 0.80, 0.90), \qquad n = 8.$$

Ta thử $D = 1, 2, 4$ ô bằng nhau. Độ rộng mỗi ô là $h = 1/D$. Chiều cao mật độ trong một ô luôn là

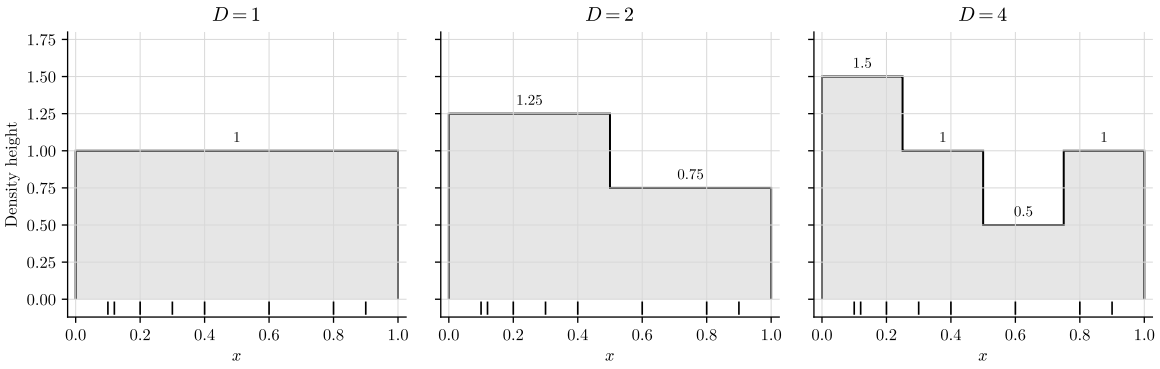
$$\boxed{\text{chiều cao} = \frac{\text{số điểm trong ô}}{n \times h}.}$$

Số ô D	Độ rộng h	Số đếm trong các ô	Chiều cao mật độ
1	1	(8)	(1)
2	1/2	(5, 3)	(5/4, 3/4)
4	1/4	(3, 2, 1, 2)	(3/2, 1, 1/2, 1)

Ví dụ, với $D = 2$, ô trái có năm điểm nên chiều cao là $5/(8 \times 1/2) = 5/4$. Ô phải có ba điểm nên chiều cao là $3/4$. Diện tích hai ô là $5/4 \times 1/2 + 3/4 \times 1/2 = 1$.

4.2.2 Tại sao đây đã là một bài toán chọn mô hình?

Với một ô, đường chỉ có một mức cao nên không thể hiện sự khác nhau giữa hai nửa miền. Với bốn ô, đường có thể hiện nhiều chi tiết hơn; nhưng chỉ một điểm đi sang ô kế bên cũng có thể làm chiều cao đổi đáng kể. Cả ba đường đều được dựng từ cùng tám điểm. *Nhiều ô hơn không tự động có nghĩa gần mật độ thật hơn.* Ta chưa biết mật độ thật để chấm sai số trực tiếp; đó là lý do cần tiêu chuẩn lựa chọn mô hình.



Hình 4.1: Cùng tám quan sát, ba mô hình histogram với $D = 1, 2, 4$. Các vạch dưới trục là dữ liệu. Chiều cao từng ô được tính trong bảng; không có đường mật độ thật trong hình vì ví dụ chỉ cho dữ liệu.

Trực giác và ý nghĩa thực tiễn. Ở ví dụ hàm bước, "mô hình D chiều" chỉ là tập các đường có một chiều cao trên mỗi ô. Chọn mô hình nghĩa là chọn mức độ chi tiết.

4.3 Hàm cơ sở và hệ số: đọc như một công thức ghép hình

4.3.1 Trước tiên, dùng hai hình chữ nhật

Với $D = 2$, đặt $B_1 = [0, 1/2)$, $B_2 = [1/2, 1]$. Một hàm chỉ báo $\mathbf{1}_{B_j}(x)$ bằng 1 khi x trong ô j, bằng 0 ở ngoài. Ta có thể viết histogram thành

$$\hat{f}_2(x) = \frac{5}{4}\mathbf{1}_{B_1}(x) + \frac{3}{4}\mathbf{1}_{B_2}(x).$$

Dòng này chỉ nói: ở ô trái, lấy chiều cao 5/4; ở ô phải, lấy 3/4. Các hình chữ nhật là *hàm cơ sở*; các số đứng trước chúng là *hệ số*. Với cơ sở tổng quát, hệ số không nhất thiết là chiều cao hay xác suất của một ô.

4.3.2 Tại sao trong slide lại có căn bậc hai?

Để phép tính gọn hơn, ta dùng các hàm cơ sở được chuẩn hóa:

$$\phi_1(x) = \sqrt{2}\,\mathbf{1}_{B_1}(x), \qquad \phi_2(x) = \sqrt{2}\,\mathbf{1}_{B_2}(x).$$

Mỗi hình chữ nhật cao $\sqrt{2}$, rộng $1/2$. Vì vậy tích phân *bình phương* của mỗi hàm bằng $(\sqrt{2})^2 \times 1/2 = 1$. Hai hàm không chồng lên nhau, nên tích của chúng bằng 0 tại mọi điểm. Ta gọi hai tính chất này là *trực chuẩn*:

$$\int_0^1 \phi_1^2 = \int_0^1 \phi_2^2 = 1, \qquad \int_0^1 \phi_1\phi_2 = 0.$$

"Chuẩn" nghĩa là độ lớn đã đưa về 1; "trực" nghĩa là hai hình dạng không có phần tích chung khi lấy tích phân. Với sin và cos, các hàm có thể chồng lên nhau nhưng các phần dương và âm của tích triệt tiêu.

4.3.3 Tính hệ số từ mẫu, rồi ghép lại

Công thức hệ số mẫu là trung bình các giá trị hàm cơ sở tại dữ liệu:

$$\hat{a}_j = \frac{1}{n}\sum_{i=1}^{n} \phi_j(X_i).$$

Ở ví dụ hai ô, $\phi_1(X_i)$ bằng $\sqrt{2}$ ở năm điểm, bằng 0 ở ba điểm. Do đó

$$\hat{a}_1 = \frac{5\sqrt{2}}{8}, \qquad \hat{a}_2 = \frac{3\sqrt{2}}{8}.$$

Ghép hai hình dạng:

$$\begin{aligned}\hat{f}_2(x) &= \hat{a}_1\phi_1(x) + \hat{a}_2\phi_2(x) \\ &= \frac{5\sqrt{2}}{8}\sqrt{2}\,\mathbf{1}_{B_1}(x) + \frac{3\sqrt{2}}{8}\sqrt{2}\,\mathbf{1}_{B_2}(x) \\ &= \frac{5}{4}\mathbf{1}_{B_1}(x) + \frac{3}{4}\mathbf{1}_{B_2}(x).\end{aligned}$$

Hai căn nhân nhau thành 2, nên kết quả trùng histogram ban đầu. **Bạn chưa học một estimator khác: bạn vừa viết lại histogram bằng ngôn ngữ hàm cơ sở.**

Với D ô, mỗi ô rộng $1/D$, cơ sở chuẩn hóa cao $\sqrt{D}$:

$$\phi_{D,j} = \sqrt{D}\,\mathbf{1}_{B_j}, \qquad \hat{a}_{D,j} = \frac{\sqrt{D}N_j}{n}, \qquad \hat{f}_D(x) = \frac{DN_j}{n} \quad (x \in B_j).$$

Chỉ số D, j nhắc rằng cơ sở hàm bước thay đổi khi đổi phân hoạch.

Trực giác và ý nghĩa thực tiễn. Hàm cơ sở cho hình dạng; hệ số cho mức đóng góp. Căn bậc hai là cách chuẩn hóa để phép tính bình phương đơn giản, không phải một thao tác bí ẩn trên dữ liệu.

Đối chiếu nguồn: [3], slide 8–12; [2], slide 30–31.

4.4 Phân biệt ba đường: thật, xấp xỉ và ước lượng

Đây là ba ký hiệu dễ nhầm nhất trong chương:

Ký hiệu	Đọc bằng lời	Ta có tính từ dữ liệu không?
f	Mật độ thật cần tìm	Không, nói chung chưa biết.
f_D	Đường gần f nhất trong mô hình D đã chọn	Không, cần biết f.
$\hat{f}_D$	Đường ta dựng từ mẫu, trong mô hình D	Có.

Dấu mũ có nghĩa là dùng dữ liệu để ước lượng. f_D không có dấu mũ vì nó là một đối tượng lý thuyết, không phải kết quả tính từ mẫu.

Với một cơ sở trực chuẩn, hệ số thật và hệ số mẫu là

$$a_j = \int_0^1 \phi_j(x)f(x)\,dx = \mathbb{E}\phi_j(X), \qquad \hat{a}_j = \frac{1}{n}\sum_i \phi_j(X_i).$$

Công thức bên trái lấy trung bình theo phân phối thật, bên phải lấy trung bình tám giá trị quan sát. Đó là nguyên lý thế của Chương 1.

$$\boxed{f_D = \sum_{j=1}^{D} a_j \phi_j, \qquad \hat{f}_D = \sum_{j=1}^{D} \hat{a}_j \phi_j.}$$

Vì trung bình mẫu có kỳ vọng bằng trung bình thật, $\mathbb{E}\hat{a}_j = a_j$ và $\mathbb{E}\hat{f}_D = f_D$. Nhưng f_D có thể khác f: mô hình quá đơn giản vẫn làm mất chi tiết, ngay cả khi các hệ số được tính chính xác.

4.4.1 Vì sao gọi là "chiếu"?

Hãy nghĩ đến việc biểu diễn một vật bằng cái bóng của nó trên một mặt phẳng. Cái bóng chỉ giữ phần thông tin biểu diễn được trên mặt phẳng ấy. Tương tự, f_D chỉ giữ những hình dạng nằm trong mô hình đã chọn.

Tên chính thức của mô hình là S_D, tức tập các tổng $g = \sum_{j=1}^{D} b_j \phi_j$ khi các hệ số b_j được phép thay đổi. Từ "span" trong slide chỉ chính tập những tổng đó. Phép chiếu chọn tổng gần f nhất theo sai số bình phương tích phân; khái niệm gần sẽ được tính cụ thể ngay dưới đây.

Trực giác và ý nghĩa thực tiễn. Có hai nguyên nhân gây sai: mô hình chưa đủ biểu diễn đường thật, và mẫu hữu hạn làm các hệ số bị lệch khỏi giá trị thật. Đừng gộp f_D và $\hat{f}_D$ thành một đường.

4.5 Đo sai số và hiểu Pythagoras bằng một ví dụ

4.5.1 Chuẩn L2 chỉ là tích phân sai khác bình phương

Ký hiệu trong slide

$$\|g - f\|_2^2 = \int_0^1 [g(x) - f(x)]^2 \, dx$$

được đọc như sau: tại mỗi vị trí, lấy chênh lệch hai chiều cao; bình phương để sai khác âm không bù sai khác dương; cộng liên tục trên toàn miền bằng tích phân. Giá trị càng nhỏ thì hai đường càng gần theo tiêu chí này. L_2 là tên của không gian các hàm có tích phân bình phương hữu hạn; trong phần tính bài, hãy nhớ công thức tích phân ở trên.

Nếu hai đường hằng trên cùng các ô, không cần tích phân khó:

$$\text{sai số} = \sum_{j} (\text{chênh lệch chiều cao ở ô } j)^2 \times \text{độ rộng ô } j.$$

Còn ký hiệu $\langle g, q \rangle = \int_0^1 g(x)q(x)dx$ được gọi là tích vô hướng. Nó giúp kiểm tra các phần sai số có trực giao hay không.

4.5.2 Ví dụ với một mật độ thật được cho để luyện tính

Riêng mục này, giả sử *đề cho* $f(x) = 2x$ trên $[0, 1]$. Với hai ô, đường tốt nhất hằng trên mỗi ô lấy chiều cao trung bình thật:

$$f_2(x) = \begin{cases} 1/2, & 0 \le x < 1/2, \\ 3/2, & 1/2 \le x \le 1. \end{cases}$$

Chẳng hạn chiều cao ô trái là $(1/(1/2)) \int_0^{1/2} 2x \, dx = 2(1/4) = 1/2$. Trong khi đó mẫu tám điểm phía trên cho chiều cao $(5/4, 3/4)$ của $\hat{f}_2$. Mẫu nhỏ này không nhất thiết đại diện tốt cho f đã cho.

Sai số thứ nhất: mô hình làm mất độ dốc. Đường f_2 hằng trong ô, còn f tăng. Tính được

$$\int_0^{1/2} (2x - 1/2)^2 dx + \int_{1/2}^1 (2x - 3/2)^2 dx = \frac{1}{12}.$$

Để tự kiểm tra, nguyên hàm của $(2x-c)^2$ là $4x^3/3 - 2cx^2 + c^2x$; dùng $c = 1/2$ hoặc $3/2$ ở từng ô.

Sai số thứ hai: hệ số tính từ mẫu khác hệ số thật. Trong hai ô, chênh lệch chiều cao giữa $\hat{f}_2$ và f_2 là $3/4$ và $-3/4$. Do đó

$$\left\|\hat{f}_2 - f_2\right\|_2^2 = (3/4)^2(1/2) + (-3/4)^2(1/2) = \frac{9}{16}.$$

Tổng sai số. Tính trực tiếp từ đường thật đến đường ước lượng cho

$$\left\|f - \hat{f}_2\right\|_2^2 = \int_0^{1/2} (2x - 5/4)^2 dx + \int_{1/2}^1 (2x - 3/4)^2 dx = \frac{31}{48} = \frac{1}{12} + \frac{9}{16}.$$

Đây là sai số của mẫu cụ thể này, không phải kỳ vọng qua mọi mẫu.

4.5.3 Chứng minh vì sao hai phần cộng được

Đặt $e_1 = f - f_D$, $e_2 = f_D - \hat{f}_D$. Khi đó $f - \hat{f}_D = e_1 + e_2$. Khai triển bình phương như với hai số thông thường:

$$\int (e_1 + e_2)^2 = \int e_1^2 + \int e_2^2 + 2\int e_1 e_2.$$

Với histogram, e_2 hằng trong mỗi ô, còn $\int_{B_j}(f - f_D) = 0$ vì f_D là trung bình ô. Do đó trên mỗi ô, hằng số e_2 nhân tích phân bằng 0: $\int_{B_j} e_1 e_2 = e_2|_{B_j} \int_{B_j} e_1 = 0$. Cộng các ô cho hạng chéo bằng 0.

Với cơ sở trực chuẩn tổng quát, lý do tương tự: $\langle f - f_D, \phi_j \rangle = a_j - a_j = 0$ cho $j \le D$, trong khi e_2 là một tổng các ϕ_j đó. Vì vậy $\langle e_1, e_2 \rangle = 0$ và

$$\boxed{\underbrace{\left\|f - \hat{f}_D\right\|_2^2}_{\text{tổng sai số}} = \underbrace{\|f - f_D\|_2^2}_{\text{sai do mô hình}} + \underbrace{\left\|f_D - \hat{f}_D\right\|_2^2}_{\text{sai do mẫu}}.}$$

Đây là Pythagoras trong không gian hàm. Hạng chéo mất do trực giao, không phải vì các hệ số độc lập.

4.5.4 Bias–variance đọc bằng lời

Lấy trung bình tổng sai số qua nhiều mẫu mới được rủi ro:

$$\mathbb{E}\left\|f - \hat{f}_D\right\|_2^2 = \|f - f_D\|_2^2 + \mathbb{E}\left\|f_D - \hat{f}_D\right\|_2^2.$$

Phần đầu không đổi khi lấy mẫu lại: đó là bình phương bias tích phân. Phần sau dao động theo mẫu: kỳ vọng của nó là tổng variance của các hệ số.

Trực giác và ý nghĩa thực tiễn. Bạn có thể biết chính xác mật độ nhưng vẫn không vẽ được độ dốc bằng một ô hằng; đó là giới hạn mô hình. Ngược lại, dù đã chọn mô hình tốt, ít dữ liệu vẫn làm chiều cao ước lượng thiếu ổn định.

Đối chiếu nguồn: [3], slide 13–15; [2], slide 32.

4.6 Contrast: một điểm số tính được khi không biết mật độ thật

4.6.1 Vì sao phải tạo điểm số khác?

Ta muốn chấm $\int (g-f)^2$, nhưng không biết f. Khai triển:

$$\int (g-f)^2 = \int g^2 - 2\int gf + \int f^2.$$

Hạng cuối giống nhau cho tất cả đường g, nên bỏ nó không đổi thứ tự so sánh. Với hai điểm số $A+c$ và $B+c$, so sánh vẫn như A với B. Hạng $\int gf$ là kỳ vọng $\mathbb{E}g(X)$, được ước lượng bằng trung bình mẫu. Do đó định nghĩa

$$\boxed{\gamma_n(g) = \int_0^1 g(x)^2 dx - \frac{2}{n}\sum_{i=1}^{n} g(X_i).}$$

Chữ γ_n là tên điểm số, gọi là *contrast* hay hàm tương phản. Nó có thể âm; không phải chính sai số bình phương. Với g cố định trước khi nhìn mẫu, $\mathbb{E}\gamma_n(g) = \|g-f\|_2^2 - \|f\|_2^2$. Nếu g được chọn từ chính mẫu, không tự áp dụng đẳng thức này như thể g cố định; bước chọn mô hình cần kiểm soát riêng.

4.6.2 Tại sao cực tiểu contrast cho đúng hệ số mẫu?

Đặt $g = \sum_{j=1}^{D} b_j \phi_j$; b_j là những hệ số ta đang thử. Trực chuẩn làm $\int g^2 = \sum_j b_j^2$. Trung bình mẫu của g là

$$\frac{1}{n}\sum_i g(X_i) = \sum_j b_j \left(\frac{1}{n}\sum_i \phi_j(X_i)\right) = \sum_j b_j \hat{a}_j.$$

Vậy

$$\begin{aligned}\gamma_n(g) &= \sum_j (b_j^2 - 2b_j\hat{a}_j) \\ &= \sum_j \{(b_j-\hat{a}_j)^2 - \hat{a}_j^2\}.\end{aligned}$$

Ở dòng cuối dùng $(b-a)^2 = b^2 - 2ba + a^2$. Các $\hat{a}_j$ đã tính được từ mẫu nên là hằng khi ta thay đổi b_j. Để điểm số nhỏ nhất, chỉ cần làm mọi $(b_j-\hat{a}_j)^2$ bằng 0: chọn $b_j = \hat{a}_j$.

$$\boxed{\text{Đường có contrast nhỏ nhất trong } S_D \text{ là } \hat{f}_D.}$$

Không cần đạo hàm hay nghịch đảo ma trận để hiểu kết luận này. Thế các hệ số tối ưu lại cho

$$\gamma_n(\hat{f}_D) = -\sum_j \hat{a}_j^2 = -\left\|\hat{f}_D\right\|_2^2.$$

Trực giác và ý nghĩa thực tiễn. Contrast là cách dùng mẫu thay phần không biết trong công thức sai số. Với mỗi mô hình đã cho, hoàn thành bình phương giải thích ngay vì sao ta lấy trung bình mẫu làm hệ số.

Đối chiếu nguồn: [3], slide 12; [2], slide 33.

4.7 Lựa chọn mô hình: tính điểm rồi cộng phạt

4.7.1 Vì sao contrast chưa đủ?

Khi các mô hình lồng nhau, thêm thành phần có thể làm $\sum_j \hat{a}_j^2$ tăng, nên điểm số âm $-\sum_j \hat{a}_j^2$ giảm. Chỉ lấy contrast nhỏ nhất dễ luôn ưu tiên mô hình lớn, kể cả khi thành phần mới chủ yếu là nhiễu.

Ta thêm một khoản phạt tăng theo số chiều:

$$\text{điểm chọn mô hình} = \underbrace{-\left\|\hat{f}_D\right\|_2^2}_{\text{contrast}} + \underbrace{\kappa\phi_0 D/n}_{\text{phạt độ phức tạp}} .$$

κ quyết định phạt mạnh hay nhẹ. ϕ_0 là một hằng số kiểm soát độ lớn cơ sở; với histogram chia đều, dùng $\phi_0 = 1$. Ý nghĩa quan trọng trước tiên: mô hình lớn phải cải thiện contrast đủ nhiều để bù khoản phạt thêm.

4.7.2 Tính tất cả điểm số trên mẫu tám quan sát

Với hàm hằng theo ô, $\left\|\hat{f}_D\right\|_2^2$ bằng tổng *chiều cao bình phương nhân độ rộng*. Từ bảng đầu chương:

$$\begin{aligned} D = 1: &\quad 1^2 \times 1 = 1, \\ D = 2: &\quad (5/4)^2(1/2) + (3/4)^2(1/2) = 17/16, \\ D = 4: &\quad [(3/2)^2 + 1^2 + (1/2)^2 + 1^2]/4 = 9/8. \end{aligned}$$

Riêng bài tính này, cho $\kappa = 1/3$, $\phi_0 = 1$, $n = 8$. Penalty bằng $D/24$; không cần tự tìm κ.

D	Contrast	Phạt $D/24$	Tổng điểm
1	-1	$1/24$	$-23/24 \approx -0.95833$
2	$-17/16$	$1/12$	$-47/48 \approx -0.97917$
4	$-9/8$	$1/6$	$-23/24 \approx -0.95833$

Số nhỏ nhất là $-47/48$, nên chọn $\boxed{\widehat{D} = 2}$ và dùng histogram hai ô. Nếu bỏ khoản phạt, $D = 4$ có contrast nhỏ nhất. Ví dụ minh họa phép tính điểm; không khẳng định $\kappa = 1/3$ là hệ số đủ cho định lý oracle hoặc hai ô chắc chắn tốt nhất với mật độ thật.

4.7.3 Giải mã công thức trên slide

$$\boxed{\widehat{D} \in \arg\min_{D \in \mathcal{D}_n} \{-\left\|\hat{f}_D\right\|_2^2 + \text{pen}(D)\}.}$$

Đọc từng phần: $\mathcal{D}_n$ là danh sách số chiều ứng viên, ở ví dụ là $\{1, 2, 4\}$; pen(D) là khoản phạt; arg min nghĩa là *lấy giá trị D làm điểm số nhỏ nhất*, không phải lấy chính điểm số nhỏ nhất. Ví dụ arg min trả về 2, còn điểm nhỏ nhất là $-47/48$. Nếu nhiều D bằng điểm, chọn D nhỏ hơn.

Một mô hình gọi là *lồng nhau* khi mọi đường của mô hình nhỏ cũng biểu diễn được trong mô hình lớn. Histogram một ô nằm trong mô hình hai ô: chỉ cần hai chiều cao bằng nhau. Mô hình hai ô nằm trong mô hình bốn ô: mỗi ô cũ được chia đôi, dùng cùng chiều cao trên hai ô mới. Vì vậy $D = 1, 2, 4, 8, \ldots$ cho mô hình lồng nhau. Các phân hoạch $D = 2$ và $D = 3$ nói chung không có tính chất ấy.

Trực giác và ý nghĩa thực tiễn. Chọn mô hình là so sánh lợi ích của thêm chi tiết với giá phải trả do thêm nhiễu. Penalty lớn hơn thường thiên về mô hình đơn giản hơn. Đừng học thuộc arg min trước khi tự tính được bảng điểm.

Đối chiếu nguồn: [3], slide 20–23; [2], slide 33.

4.8 Oracle và thích nghi: hiểu lời hứa của định lý

4.8.1 Oracle là người so sánh tưởng tượng biết mật độ thật

Nếu biết f, ta có thể chọn D dựa trên

$$\underbrace{\|f - f_D\|_2^2}_{\text{mất chi tiết}} + \underbrace{\phi_0 D/n}_{\text{chặn trên cho nhiễu lấy mẫu}}.$$

Người tưởng tượng biết f để chọn như vậy được gọi là *oracle*. Ta không có người này; oracle chỉ là chuẩn so sánh tốt nhất trong *họ mô hình đang xét*. Nó không có nghĩa biết mọi điều hay tìm được estimator tốt nhất trong tất cả phương pháp có thể có.

4.8.2 Bất đẳng thức oracle nói gì bằng lời?

Trong những điều kiện phù hợp, định lý nói:

> Sai số trung bình của cách chọn bằng dữ liệu không vượt quá một bội của mức tốt nhất mà oracle chọn được, cộng một phần dư nhỏ.

Công thức là

$$\mathbb{E}\left\|\hat{f}_{\widehat{D}} - f\right\|_2^2 \le C \inf_{D \in \mathcal{D}_n} \left\{\|f - f_D\|_2^2 + \frac{\phi_0 D}{n}\right\} + \frac{C'}{n}.$$

- Vế trái: lấy mẫu, tự chọn D, dựng đường, tính sai số; rồi lấy trung bình qua các mẫu.
- $\inf_D$: mức tốt nhất trong các ứng viên; với danh sách hữu hạn của ví dụ, đây là giá trị nhỏ nhất.
- C: một hệ số cho phép cách chọn thực tế kém hơn oracle một mức. Không tự hiểu $C = 1$ hoặc gần 1.
- C'/n: phần dư giảm khi cỡ mẫu tăng; với C' cố định, tăng n gấp đôi làm phần dư này giảm một nửa.

Định lý nói về *sai số trung bình*, không hứa chọn đúng mô hình oracle trên từng mẫu. Nó cần giả thiết về mật độ, cơ sở, họ mô hình và penalty đủ lớn tương ứng. Không dùng bất kỳ $\kappa > 0$ rồi tự tuyên bố có bảo đảm. Phần chứng minh xác suất được giữ ở mục đọc thêm.

4.8.3 Thích nghi nghĩa là tự điều chỉnh mức chi tiết

Một mật độ khá đơn giản có thể chỉ cần ít thành phần. Mật độ nhiều chi tiết có thể cần nhiều thành phần hơn. Ta chưa biết độ trơn của mật độ thật, nhưng muốn cùng một quy tắc chọn mô hình hoạt động tốt trong nhiều lớp độ trơn. Nếu định lý oracle và điều kiện xấp xỉ của các lớp ấy thỏa, việc tự chọn $\widehat{D}$ có thể đạt tốc độ rủi ro phù hợp với độ trơn thật mà không nhập độ trơn vào quy tắc. Đó là *thích nghi*. Ở lần đọc đầu, chưa cần nhớ số mũ tiệm cận; hãy nhớ đây là bảo đảm về khả năng tự chọn mức chi tiết dưới các giả thiết của định lý.

Trực giác và ý nghĩa thực tiễn. Oracle cho một chuẩn để đánh giá cách chọn từ dữ liệu. Thích nghi nói rằng quy tắc có thể tự điều chỉnh mức chi tiết khi chưa biết độ trơn; không nói rằng mẫu nào cũng nhận ra cấu trúc thật chính xác.

Đối chiếu nguồn: [3], slide 23–24; [2], slide 34.

4.9 Năm câu tự kiểm tra trước khi đọc chứng minh sâu

1. D **là gì?** Số thành phần cơ sở được dùng; với histogram chia đều, đó là số ô.
2. **Dấu mũ trong $\hat{f}_D$ nhắc gì?** Đường tính từ mẫu; khác f_D, là đường chiếu lý thuyết của mật độ thật.
3. **Tại sao có hai phần sai số?** Mô hình mất chi tiết, và mẫu làm hệ số bị nhiễu. Pythagoras tách đúng hai phần nhờ trực giao.
4. $\arg\min$ **trả về gì?** Số chiều có điểm tốt nhất, không phải giá trị điểm số. Trong bảng trên trả về 2.
5. **Vì sao cộng phạt?** Để thành phần thêm vào phải cải thiện contrast đủ nhiều, tránh luôn thưởng cho mô hình lớn.

Bài thử ngắn. Với mẫu tám điểm và $D = 4$, hãy tính chiều cao ô $[1/2, 3/4)$. Có một điểm 0.60, nên chiều cao là $1/(8 \times 1/4) = 1/2$. Tại $x = 0.60$, chỉ một hàm cơ sở hình chữ nhật khác 0; những hàm cơ sở khác không đóng góp. Nếu bạn tự giải thích được các câu này, bạn đã nắm phần cốt lõi của ước lượng chiếu và chọn mô hình. Các mục dưới đây phát triển cùng ý tưởng bằng ký hiệu tổng quát.

4.10 Đọc thêm: chuỗi trực chuẩn và cơ sở lượng giác

4.10.1 Mở rộng từ hai hình chữ nhật sang nhiều hình dạng

Trên $[0, 1]$, giả sử $f \in L_2$ và $\{\phi_j\}_{j \geq 1}$ là cơ sở trực chuẩn đầy đủ. "Đầy đủ" nghĩa là với đủ nhiều thành phần, các tổng có thể xấp xỉ mọi hàm trong không gian đang xét theo chuẩn L_2.

$$f = \sum_{j=1}^{\infty} a_j \phi_j, \qquad \int_0^1 \phi_j \phi_k = \begin{cases} 1, & j = k, \\ 0, & j \neq k. \end{cases}$$

Đẳng thức chuỗi hiểu theo hội tụ L_2, không tự theo từng điểm. Lấy tích vô hướng với ϕ_k chỉ giữ lại a_k:

$$a_k = \int_0^1 f \phi_k = \mathbb{E}\phi_k(X).$$

Giữ D thành phần đầu cho f_D; thay a_j bằng trung bình mẫu cho $\hat{f}_D$. Đây vẫn là quy trình ghép hình vừa học.

4.10.2 Sin và cos cho một cách ghép khác

$$\phi_1(x) = 1, \quad \phi_{2k}(x) = \sqrt{2}\cos(2\pi k x), \quad \phi_{2k+1}(x) = \sqrt{2}\sin(2\pi k x), \quad k \geq 1.$$

Hàm hằng cho mức nền; các sóng cho các dạng biến thiên. Tích phân sin và cos trên một chu kỳ bằng 0; tích phân bình phương bằng $1/2$, nên nhân $\sqrt{2}$ đưa độ lớn bình phương về 1. Các công thức tích thành tổng kiểm tra trực giao giữa tần số khác nhau.

Ví dụ, với mẫu $(0, 0, 1/4, 1/4)$, giá trị cos ở hai vị trí là 1 và 0; giá trị sin là 0 và 1. Do mỗi vị trí lặp hai lần,

$$\hat{a}_1 = 1, \qquad \hat{a}_2 = \hat{a}_3 = \sqrt{2}/2.$$

Ghép lại cho $\hat{f}_3(x) = 1 + \cos(2\pi x) + \sin(2\pi x)$. Đường có tích phân 1 nhưng tại $x = 5/8$ bằng $1 - \sqrt{2} < 0$. Vì vậy phép chiếu tổng quát không tự cho mật độ không âm. Lấy phần dương rồi chuẩn hóa là một hiệu chỉnh thêm; khi ấy không giữ nguyên mọi đẳng thức của estimator chiếu ban đầu.

Trực giác và ý nghĩa thực tiễn. Histogram dùng hình chữ nhật; lượng giác dùng sóng. Thay cơ sở làm thay khả năng biểu diễn, nhưng cách ước lượng hệ số vẫn là trung bình giá trị hàm cơ sở trên các quan sát.

4.11 Đọc thêm: rủi ro và tốc độ hội tụ

4.11.1 Từ trực chuẩn đến tổng bình phương hệ số

Với $g = \sum_j b_j \phi_j$, khai triển rồi tích phân:

$$\|g\|_2^2 = \sum_{j,k} b_j b_k \int \phi_j \phi_k = \sum_j b_j^2.$$

Các tích $j \neq k$ có tích phân 0. Áp dụng cho $f_D - \hat{f}_D = \sum_{j \leq D} (a_j - \hat{a}_j)\phi_j$ và phần chuỗi bị bỏ đi:

$$\left\| f_D - \hat{f}_D \right\|_2^2 = \sum_{j \leq D} (a_j - \hat{a}_j)^2, \qquad \|f - f_D\|_2^2 = \sum_{j > D} a_j^2.$$

Vì $\hat{a}_j$ là trung bình n quan sát độc lập,

$$\operatorname{Var} \hat{a}_j = \frac{1}{n} \operatorname{Var}(\phi_j(X)) = \frac{1}{n} \left(\int \phi_j^2 f - a_j^2 \right).$$

Lấy kỳ vọng trong Pythagoras cho

$$\boxed{\mathbb{E} \left\| f - \hat{f}_D \right\|_2^2 = \sum_{j > D} a_j^2 + \frac{1}{n} \sum_{j \leq D} \left(\int \phi_j^2 f - a_j^2 \right).}$$

Độc lập giữa các quan sát cho hệ số $1/n$; trực chuẩn, chứ không phải độc lập giữa các hệ số, loại các tích chéo.

4.11.2 Vì sao chặn trên variance có dạng số chiều chia cỡ mẫu?

Giả sử $\sup_x \sum_{j \leq D} \phi_j(x)^2 \leq \phi_0 D$. Với histogram, tại mỗi điểm chỉ một hàm cao $\sqrt{D}$ khác 0, nên tổng bình phương bằng D; vì vậy $\phi_0 = 1$. Với lượng giác, mỗi hàm có bình phương không quá 2, nên có thể dùng $\phi_0 = 2$. Khi đó

$$\begin{aligned} \frac{1}{n} \sum_j \operatorname{Var}(\phi_j(X)) &\leq \frac{1}{n} \sum_j \mathbb{E} \phi_j(X)^2 \\ &= \frac{1}{n} \int \left(\sum_j \phi_j(x)^2 \right) f(x) dx \\ &\leq \frac{\phi_0 D}{n} \int f = \frac{\phi_0 D}{n}. \end{aligned}$$

Đây là chặn trên, không phải variance chính xác trong mọi bài.

4.11.3 Bỏ hằng số không làm đổi mô hình tốt nhất

Trực giao của f_D và $f - f_D$ cho $\|f\|_2^2 = \|f - f_D\|_2^2 + \|f_D\|_2^2$. Vậy

$$\left\| f - \hat{f}_D \right\|_2^2 = \|f\|_2^2 - \|f_D\|_2^2 + \left\| f_D - \hat{f}_D \right\|_2^2.$$

Khi so sánh các D, $\|f\|_2^2$ giống nhau nên bỏ được:

$$\arg\min_D \left\|f - \hat{f}_D\right\|_2^2 = \arg\min_D \{-\|f_D\|_2^2 + \left\|f_D - \hat{f}_D\right\|_2^2\}.$$

Đây là mục tiêu lý thuyết vì chứa f_D chưa biết. Nếu tối ưu rủi ro, phải lấy kỳ vọng trước khi chọn; không tự đổi thứ tự kỳ vọng và arg min.

4.11.4 Độ trơn ảnh hưởng số chiều như thế nào?

Với histogram, nếu $|f(x) - f(y)| \le L|x-y|^\beta$, $0 < \beta \le 1$, trung bình ô cho

$$|f(x) - f_D(x)| \le D \int_{B_j} L|x-u|^\beta du \le LD^{-\beta}.$$

Bình phương và tích phân trên miền dài 1 cho $\|f - f_D\|_2^2 \le L^2 D^{-2\beta}$. Không mở rộng kết luận này cho histogram với mọi $\beta > 1$. Với cơ sở lượng giác phù hợp lớp Sobolev tuần hoàn, điều kiện $\sum_{j\ge 2} j^{2\beta} a_j^2 \le L^2$ cũng cho

$$\sum_{j>D} a_j^2 \le D^{-2\beta} \sum_{j>D} j^{2\beta} a_j^2 \le L^2 D^{-2\beta}.$$

Cần xét điều kiện biên của lớp khi dùng cơ sở lượng giác.

Chặn rủi ro có dạng $G(D) = L^2 D^{-2\beta} + \phi_0 D/n$: phần đầu giảm khi tăng D, phần sau tăng. Xem D như biến dương để lấy đạo hàm:

$$G'(D) = -2\beta L^2 D^{-2\beta-1} + \phi_0/n = 0 \quad \Longrightarrow \quad D_* = (2\beta L^2 n/\phi_0)^{1/(2\beta+1)}.$$

Chọn mức nguyên hoặc mức ứng viên gần đó cho $D_* \asymp n^{1/(2\beta+1)}$, rủi ro $O(n^{-2\beta/(2\beta+1)})$. Thích nghi suy ra từ oracle khi họ ứng viên có mức gần D_* và cơ sở có chặn xấp xỉ phù hợp; phần dư $1/n$ có bậc nhỏ hơn tốc độ trên.

Trực giác và ý nghĩa thực tiễn. Công thức tốc độ định lượng câu chuyện đã học: mô hình lớn giảm mất chi tiết nhưng tăng nhiễu. Nó cần giả thiết lớp và cơ sở, không phải kết quả tự động cho mọi mật độ.

Đối chiếu nguồn: [3], slide 13–18; [5], Mục 1.7.

4.12 Đọc thêm: phác thảo chứng minh oracle

Mục này là phần nâng cao. Bạn có thể nắm ý nghĩa và tính tiêu chuẩn chọn mô hình mà chưa đọc nó. Phác thảo giữ các bước đại số, còn bất đẳng thức tập trung xác suất được viện dẫn dưới điều kiện nêu rõ.

Đặt $Pg = \mathbb{E}g(X) = \langle g, f\rangle$ và $\nu_n(g) = (P_n - P)g$. Từ định nghĩa contrast,

$$\gamma_n(g) = \|g - f\|_2^2 - \|f\|_2^2 - 2\nu_n(g).$$

Dấu trước $2\nu_n$ là *âm*. Bởi cực tiểu hóa và $f_D \in S_D$, với mọi D cố định,

$$\begin{aligned}\gamma_n(\hat{f}_{\widehat{D}}) + \mathrm{pen}(\widehat{D}) &\le \gamma_n(\hat{f}_D) + \mathrm{pen}(D) \\ &\le \gamma_n(f_D) + \mathrm{pen}(D).\end{aligned}$$

Thay công thức contrast, ký hiệu $A = \left\|\hat{f}_{\widehat{D}} - f\right\|_2^2$, $B = \|f_D - f\|_2^2$, cho

$$A \le B + 2\nu_n(\hat{f}_{\widehat{D}} - f_D) + \mathrm{pen}(D) - \mathrm{pen}(\widehat{D}).$$

Đặt $Z_{D,D'} = \sup\{|\nu_n(t)| : t \in S_D + S_{D'}, \|t\|_2 = 1\}$. Tính tuyến tính cho $|\nu_n(g)| \le \|g\|_2 Z_{D,D'}$ trên không gian đó. Dùng $2uv \le u^2/4 + 4v^2$ và $\left\|\hat f_{\widehat D} - f_D\right\|_2^2 \le 2A + 2B$:

$$A \le \tfrac{3}{2}B + \tfrac{1}{2}A + 4Z^2_{D,\widehat D} + \operatorname{pen}(D) - \operatorname{pen}(\widehat D).$$

Chuyển $A/2$ qua trái và nhân 2:

$$A \le 3B + 8Z^2_{D,\widehat D} + 2\operatorname{pen}(D) - 2\operatorname{pen}(\widehat D).$$

Điều kiện tập trung được viện dẫn trong phác thảo: có các mức $p(D, D')$ sao cho

$$8p(D,D') \le \operatorname{pen}(D) + \operatorname{pen}(D'), \qquad \sum_{D' \in \mathcal{D}_n} \mathbb{E}[Z^2_{D,D'} - p(D,D')]_+ \le C_0/n.$$

Kiểm chứng điều kiện này cần bất đẳng thức quá trình thực nghiệm (chẳng hạn Talagrand) và giả thiết họ mô hình; đó là phần xác suất nâng cao được viện dẫn, không được chứng minh trong giáo trình lấy gốc. Thế $Z^2 \le p + (Z^2 - p)_+$ và bỏ số hạng phạt âm còn lại:

$$A \le 3B + 3\operatorname{pen}(D) + 8\sum_{D'}[Z^2_{D,D'} - p(D,D')]_+.$$

Lấy kỳ vọng và infimum theo D cho phiên bản oracle chặt chẽ dưới điều kiện tập trung đã nêu:

$$\mathbb{E}A \le 3\inf_D\{B + \operatorname{pen}(D)\} + 8C_0/n.$$

Nếu penalty tỷ lệ $\phi_0 D/n$ với hệ số cố định đủ lớn, đây chính là dạng oracle ở trên sau khi gộp hằng số.

Đối chiếu nguồn: [3], slide 20–24; [2], slide 33–34. Dấu của đồng nhất thức contrast được kiểm tra từ định nghĩa.

4.12.1 Nếu dữ liệu nằm trên một khoảng khác

Với miền biết trước $[a, b]$, đổi $U = (X - a)/(b - a)$, ước lượng trên $[0, 1]$, rồi chuyển mật độ về đơn vị ban đầu:

$$\hat f_X(x) = \frac{1}{b-a}\hat f_U((x-a)/(b-a)).$$

Chiều dài mới gấp $b-a$ lần, nên chiều cao chia cho $b-a$ để diện tích vẫn bằng 1. Hệ số $1/\sqrt{b-a}$ chỉ dành cho chuẩn hóa cơ sở L_2, không thay thế hệ số đổi mật độ này.

Chương 5

Hồi quy phi tham số và các mở rộng

5.1 Mục tiêu hồi quy khác mục tiêu mật độ

Quan sát các cặp i.i.d. (X_i, Y_i), mô hình

$$Y_i = r(X_i) + \varepsilon_i, \qquad \mathbb{E}(\varepsilon_i \mid X_i) = 0, \qquad \mathrm{Var}(\varepsilon_i \mid X_i) = \sigma^2(X_i).$$

Ta ước lượng $r(x) = \mathbb{E}(Y \mid X = x)$. Ký hiệu $f(x)$ trong chương này là mật độ của *biến thiết kế* X, không phải hàm hồi quy. Hàm r không cần không âm hay tích phân bằng 1. Giả thiết kỳ vọng có điều kiện bằng 0 là điều cần để nhận r là hàm hồi quy; chỉ $\mathbb{E}\varepsilon = 0$ chưa đủ.

Trực giác và ý nghĩa thực tiễn. KDE hỏi "dữ liệu X tập trung ở đâu?"; hồi quy hỏi "tại giá trị $X = x$, trung bình Y là bao nhiêu?". Cùng kernel nhưng khác đối tượng cần ước lượng.

5.2 Nadaraya–Watson từ bình phương tối thiểu cục bộ

Với $k_i(x) = K((X_i - x)/h)$, $K \geq 0$, xấp xỉ r gần x bằng hằng a và giải $Q(a) = \sum_i k_i (Y_i - a)^2$.

$$Q'(a) = -2 \sum_i k_i Y_i + 2a \sum_i k_i = 0.$$

Nếu $\sum_i k_i > 0$, $Q''(a) = 2 \sum_i k_i > 0$ nên nghiệm duy nhất:

$$\boxed{\hat{r}_{\mathrm{NW}}(x) = \frac{\sum_i k_i Y_i}{\sum_i k_i} = \sum_i w_i Y_i, \qquad w_i = \frac{k_i}{\sum_j k_j}.}$$

Trọng số không âm, tổng 1, nên dự đoán nằm giữa các Y_i có trọng số. Nếu dùng $K((x - X_i)/h)$, cùng công thức cho kernel đối xứng. Nhân compact có thể cho mẫu số 0 khi không có điểm trong cửa sổ; estimator khi đó không xác định, không gán 0 tùy ý.

Ví dụ 5.1. $X = (1, 2, 4, 5)$, $Y = (2, 3, 7, 8)$, $x = 3, h = 2$, Epanechnikov cho $k = (0, 9/16, 9/16, 0)$. Vì thế

$$\hat{r}_{\mathrm{NW}}(3) = \frac{(9/16)3 + (9/16)7}{9/16 + 9/16} = 5.$$

Trong bài KDE với cùng X, kết quả mật độ là $9/64$, một đại lượng khác.

5.2.1 Từ tỷ số mật độ đến công thức NW

Nếu (X, Y) có mật độ đồng thời $p(x, y)$ và $f(x) > 0$, $r(x) = \int y p(x, y) dy / f(x)$. Dùng nhân tích cho mật độ đồng thời,

$$\hat{p}(x, y) = \frac{1}{nhb} \sum_i K((x - X_i)/h) L((y - Y_i)/b).$$

Giả sử $\int L = 1$, $\int vL(v)dv = 0$, moment tuyệt đối bậc nhất hữu hạn. Đặt $v = (y - Y_i)/b$:

$$\int y \frac{1}{b} L((y - Y_i)/b)\, dy = \int (Y_i + bv) L(v)\, dv = Y_i.$$

Tích phân theo y cho mật độ biên $(nh)^{-1} \sum_i K((x - X_i)/h)$; tích phân có thừa số y cho $(nh)^{-1} \sum_i K((x - X_i)/h) Y_i$. Tỷ số triệt tiêu $1/(nh)$, chính là NW. Mối liên hệ này không yêu cầu mọi bài hồi quy đều có mật độ đồng thời; phép suy ra từ bình phương tối thiểu vẫn dùng được khi Y rời rạc.

Trực giác và ý nghĩa thực tiễn. NW là trung bình có trọng số của các đáp ứng gần x. Ở nơi mật độ thiết kế cao hơn, có nhiều quan sát hơn kéo trung bình về phía đó.

Đối chiếu nguồn: [4], Mục 5.4.1, trang in 72–73 (PDF 82–83); [5], Mục 1.5.

5.3 Design bias: thành phần phụ thuộc mật độ thiết kế

Xét mục tiêu làm trơn ở mức quần thể

$$r_h(x) = \frac{\int K(u) r(x + hu) f(x + hu) du}{\int K(u) f(x + hu) du}.$$

Đây là tỷ số các kỳ vọng, không phải đẳng thức chính xác với $\mathbb{E}\hat{r}_{\mathrm{NW}}(x)$ ở mẫu hữu hạn. Giả sử x là điểm nội, $f(x) > 0$, f, r có hai đạo hàm liên tục và kernel chẵn có moment bậc hai. Đặt $g = rf$, $c = h^2 \mu_2(K)/2$:

$$\int K(u) g(x + hu) du = g(x) + c g''(x) + o(h^2), \quad \int K(u) f(x + hu) du = f(x) + c f''(x) + o(h^2).$$

Vì $1/(f + cf'' + o(h^2)) = f^{-1} - cf'' f^{-2} + o(h^2)$,

$$\begin{aligned} r_h(x) &= r(x) + c \left[\frac{(rf)''}{f} - \frac{rf''}{f} \right] + o(h^2) \\ &= r(x) + c \left[r''(x) + 2 \frac{r'(x) f'(x)}{f(x)} \right] + o(h^2), \end{aligned}$$

vì $(rf)'' = r''f + 2r'f' + rf''$; hai hạng rf''/f triệt tiêu. Vậy bias làm trơn dẫn đầu là

$$\boxed{r_h(x) - r(x) = \frac{h^2 \mu_2(K)}{2} \left[r''(x) + 2 \frac{r'(x) f'(x)}{f(x)} \right] + o(h^2).}$$

Phần $2r'f'/f$ được gọi là *design bias*. Nếu r tuyến tính, $r'' = 0$ nhưng $r'f' \neq 0$, NW vẫn chệch. Với $r(x) = x$, $f(x) = 2x$ tại $x = 1/2$, thành phần trong ngoặc bằng 4.

Để chuyển sang phát biểu tiệm cận cho estimator ngẫu nhiên cần kiểm soát tỷ số và dao động của các moment thiết kế. Với kernel compact bị chặn, mật độ thiết kế dương, trơn và $nh^3 \to \infty$, sai số moment bậc một do mẫu có bậc $O_P(h/\sqrt{nh}) = o_P(h^2)$, nên bias có điều kiện theo thiết kế cũng có khai triển trên ở điểm nội. Phương sai do nhiễu có dạng chính

$$\mathrm{Var}(\hat{r}_{\mathrm{NW}}(x) \mid X_1, \ldots, X_n) \approx \frac{\sigma^2(x) R(K)}{nh f(x)}.$$

Không nhầm với variance KDE $f(x)R(K)/(nh)$: trong hồi quy, mật độ thiết kế nhỏ làm ít dữ liệu hữu hiệu và tăng variance.

Trực giác và ý nghĩa thực tiễn. NW dùng một hằng số để xấp xỉ đoạn có độ dốc. Khi các điểm không cân đối hai phía, hằng số bị kéo về phía đông dữ liệu.

5.4 Local linear: hệ phương trình và trọng số

Thay hằng số bằng đường thẳng cục bộ, $d_i = X_i - x$:

$$\min_{a_0,a_1} \sum_i k_i [Y_i - a_0 - a_1 d_i]^2.$$

Đặt $S_q = \sum_i k_i d_i^q$, $T_q = \sum_i k_i d_i^q Y_i$. Đạo hàm theo hai hệ số cho hệ phương trình chuẩn

$$\begin{pmatrix} S_0 & S_1 \\ S_1 & S_2 \end{pmatrix} \begin{pmatrix} \hat{a}_0 \\ \hat{a}_1 \end{pmatrix} = \begin{pmatrix} T_0 \\ T_1 \end{pmatrix}.$$

Nếu $\Delta = S_0 S_2 - S_1^2 > 0$, nghịch đảo ma trận cho

$$\boxed{\hat{r}_{\mathrm{LL}}(x) = \hat{a}_0 = \frac{S_2 T_0 - S_1 T_1}{\Delta} = \sum_i w_i^{\mathrm{LL}} Y_i, \quad w_i^{\mathrm{LL}} = \frac{k_i (S_2 - S_1 d_i)}{\Delta}.}$$

Với $S_0 > 0$, Δ / S_0^2 là phương sai có trọng số của các d_i. Do đó $\Delta > 0$ khi có ít nhất hai vị trí X_i khác nhau với trọng số dương. Nếu chỉ một vị trí, đường thẳng không xác định duy nhất.

Hai đẳng thức then chốt:

$$\sum_i w_i^{\mathrm{LL}} = \frac{S_2 S_0 - S_1^2}{\Delta} = 1, \qquad \sum_i w_i^{\mathrm{LL}} d_i = \frac{S_2 S_1 - S_1 S_2}{\Delta} = 0.$$

Trọng số có thể âm nhưng tổng vẫn 1. Nếu $Y_i = a + bX_i$, khi $\Delta > 0$,

$$\hat{r}_{\mathrm{LL}}(x) = \sum_i w_i [a + bx + b d_i] = a + bx,$$

nên local linear tái tạo chính xác mọi hàm tuyến tính, kể cả gần biên.

Trực giác và ý nghĩa thực tiễn. Trọng số local linear tự điều chỉnh để moment bậc một bằng 0. Không cần dữ liệu hai phía cân đối để triệt tiêu ảnh hưởng của độ dốc.

Đối chiếu nguồn: [4], Mục 5.4.2; [5], Mục 1.6, Mệnh đề 1.12, trang in 36 (PDF 47).

5.5 Vì sao local linear giảm design bias và chệch biên?

5.5.1 Chứng minh trực tiếp bằng tái tạo tuyến tính

Lấy kỳ vọng có điều kiện theo các X_i và khai triển r:

$$\begin{aligned} \mathbb{E}(\hat{r}_{\mathrm{LL}}(x) \mid X) &= \sum_i w_i [r(x) + r'(x) d_i + \tfrac{1}{2} r''(x) d_i^2 + o(d_i^2)] \\ &= r(x) + \tfrac{1}{2} r''(x) \sum_i w_i d_i^2 + \sum_i w_i o(d_i^2). \end{aligned}$$

Hằng số giữ nguyên do tổng trọng số bằng 1; hạng bậc nhất mất do tổng $w_i d_i$ bằng 0. Không xuất hiện phần $r' f' / f$. Với kernel compact, $|d_i| \le h$ khi $k_i > 0$. Nếu ma trận moment không suy biến và $\sum_i |w_i|$ bị chặn,

$$|\mathbb{E}(\hat{r}_{\mathrm{LL}}(x) \mid X) - r(x)| \le \tfrac{1}{2} \|r''\|_\infty h^2 \sum_i |w_i| = O(h^2).$$

Điều này áp dụng cả ở biên khi moment một phía vẫn không suy biến. "Giảm boundary bias" nghĩa là bỏ chệch bậc nhất, không phải bias bằng 0. Các giả thiết thiết kế dương trên miền, độ trơn và kiểm soát nghịch đảo ma trận là cần thiết; không tuyên bố $O(h^2)$ ở điểm không có dữ liệu.

5.5.2 Hằng số tại điểm nội và tại biên

Ở điểm nội, moment thiết kế có dạng $S_q/(nh^{q+1}) \to f(x)\mu_q(K)$. Với kernel chẵn, $\mu_1 = 0$, nên

$$\sum_i w_i d_i^2 = \frac{S_2^2 - S_1 S_3}{\Delta} = h^2 \mu_2(K) + o_P(h^2).$$

Bias chính là $h^2\mu_2 r''/2$, không có design bias bậc hai. Tại biên trái $x = 0$ trên $[0, 1]$, dùng moment một phía $m_q = \int_0^1 u^q K(u)du$ cho kernel compact:

$$\sum_i w_i d_i^2 \approx h^2 \frac{m_2^2 - m_1 m_3}{m_0 m_2 - m_1^2}.$$

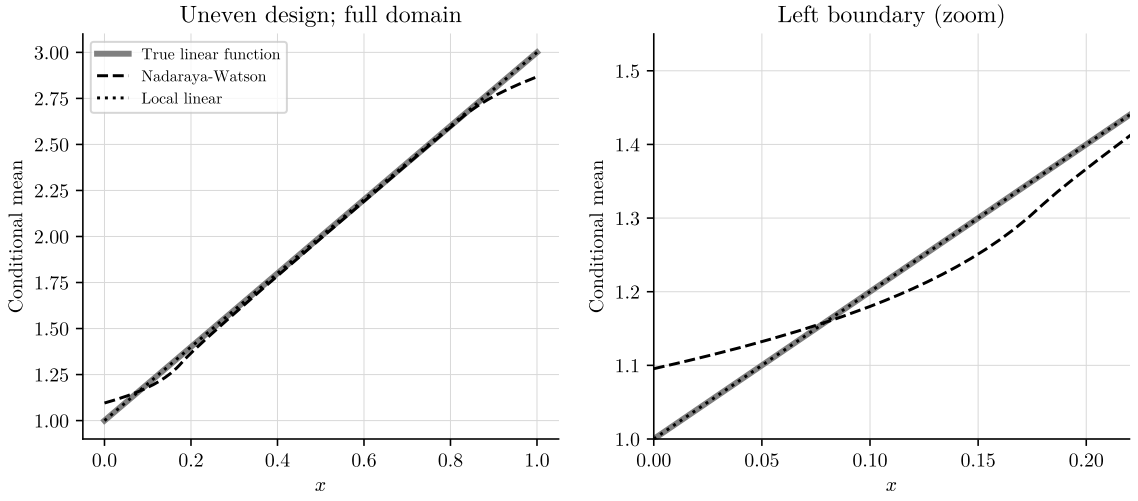
Với Uniform, $(m_0, m_1, m_2, m_3) = (1/2, 1/4, 1/6, 1/8)$, tỷ số bằng $-1/6$, nên bias tại 0 là $-h^2 r''(0)/12$. NW tại 0 có bias làm trơn $hr'(0)/2 + O(h^2)$. Kernel tương đương của local linear tại biên là $4 - 6u$ trên $[0, 1]$, cùng cấu trúc moment với boundary kernel ở Chương 3.

5.5.3 Phương sai và điều kiện sử dụng

Với nhiễu độc lập có điều kiện theo thiết kế,

$$\mathrm{Var}(\hat{r}_{\mathrm{LL}}(x) \mid X) = \sum_i w_i^2 \sigma^2(X_i).$$

Nếu $\max_i |w_i| = O(1/(nh))$, $\sum_i |w_i| = O(1)$ và variance nhiễu bị chặn, variance là $O(1/(nh))$. Ở điểm nội có hằng số chính $\sigma^2(x)R(K)/(nhf(x))$ với kernel đối xứng chuẩn hóa. Ở biên, thay $R(K)$ bằng bình phương tích phân của kernel tương đương; hằng số thường lớn hơn. Trọng số âm giúp sửa bias nhưng có thể làm dự đoán ra ngoài khoảng các Y_i lân cận. Nếu ma trận gần suy biến, cần mở rộng bandwidth hoặc báo thiếu hỗ trợ thiết kế, không nghịch đảo máy móc.



Hình 5.1: Làm trơn hàm tuyến tính trên các điểm thiết kế không đều, $h = 0.18$, kernel Epanechnikov. Đường vẽ dùng $Y_i = r(X_i)$ không có nhiễu, nên biểu diễn kỳ vọng có điều kiện. Local linear tái tạo đường thẳng; NW bị kéo bởi thiết kế và gần biên.

Trực giác và ý nghĩa thực tiễn. Local linear dùng độ dốc như một tham số phụ để ước lượng giá trị tại tâm chính xác hơn. Độ dốc không cần phải được báo cáo để phương pháp tận dụng được nó.

5.6 Root–Unroot: từ số đếm đến hồi quy

5.6.1 Binning và xấp xỉ Poisson

Giả sử mật độ trên $[0,1]$. Chia k ô bằng nhau, trung điểm $t_j = (j-1/2)/k$, số đếm N_j, xác suất ô p_j. Nếu f ít biến thiên trong ô, $p_j \approx f(t_j)/k$ và $\lambda_j = np_j \approx nf(t_j)/k$. Trong mô hình cố định n, $(N_1, \dots, N_k)$ đa thức,

$$\mathbb{E}N_j = np_j, \quad \operatorname{Var} N_j = np_j(1-p_j), \quad \operatorname{Cov}(N_j, N_\ell) = -np_jp_\ell \quad (j \neq \ell).$$

Các số đếm không độc lập. Với ô có xác suất nhỏ, từng số đếm có thể xấp xỉ Poisson; trong mô hình Poisson hóa tổng số quan sát, các số đếm độc lập Poisson thật sự.

5.6.2 Lấy căn để ổn định phương sai

Với $N \sim \text{Poisson}(\lambda)$, xét $g(N) = \sqrt{N+c}$. Delta method cho

$$\operatorname{Var} g(N) \approx [g'(\lambda)]^2\lambda = \frac{\lambda}{4(\lambda+c)} \approx \frac{1}{4}$$

khi λ lớn. Taylor bậc hai cho kỳ vọng:

$$\begin{aligned}\mathbb{E}g(N) &\approx \sqrt{\lambda+c} - \frac{\lambda}{8(\lambda+c)^{3/2}} \\ &= \sqrt{\lambda} + \frac{c/2 - 1/8}{\sqrt{\lambda}} + \text{các hạng bậc nhỏ hơn.}\end{aligned}$$

Chọn $c = 1/4$ triệt tiêu hiệu chỉnh bias dẫn đầu. Đây là xấp xỉ, không phải kỳ vọng chính xác của căn số đếm. Đặt

$$\boxed{Y_j = \sqrt{\frac{k}{n}(N_j + 1/4).}}$$

Khi xấp xỉ đủ tốt,

$$Y_j \approx r(t_j) + \sigma\varepsilon_j, \quad r(x) = \sqrt{f(x)}, \quad \sigma^2 \approx \frac{k}{4n}, \quad \varepsilon_j \text{ gần chuẩn tắc.}$$

Ở ô rất ít số đếm, gần chuẩn có thể kém. Quy tắc $k \approx n/10$ trong Wasserman là lựa chọn thực hành, không bảo đảm điều kiện tiệm cận hay đếm đủ lớn ở mọi ô.

5.6.3 Hồi quy, lấy phần dương và chuyển ngược

Áp dụng hồi quy phi tham số cho (t_j, Y_j) để có $\hat{r}(x)$. Đặt $r_+(x) = \max\{\hat{r}(x), 0\}$ và

$$\boxed{\hat{f}_{\text{RU}}(x) = \frac{r_+(x)^2}{\int_0^1 r_+(t)^2\,dt}.}$$

Phải kiểm tra mẫu số hữu hạn và dương. Nếu mẫu số bằng 0, quy trình không trả được mật độ, cần xem lại hồi quy hoặc dữ liệu. Lấy phần dương trước bình phương tránh biến một dự đoán âm của căn mật độ thành mật độ lớn giả tạo. Chuẩn hóa đảm bảo tổng diện tích 1.

Ví dụ 5.2. $n = 40$, $k = 4$, số đếm $(4, 8, 12, 16)$, nên

$$Y_j^2 = (N_j + 1/4)/10 = (0.425, 0.825, 1.225, 1.625).$$

$\sigma^2 \approx 0.025$, $\sigma \approx 0.15811$. Nếu *chưa làm trơn* và giữ căn hằng theo từng ô, tích phân bình phương là $(0.425 + 0.825 + 1.225 + 1.625)/4 = 1.025$. Chiều cao chuẩn hóa là $(17, 33, 49, 65)/41$. Ví dụ chỉ kiểm tra biến đổi và chuẩn hóa; bước hồi quy thực sự vẫn cần thiết lập bandwidth hoặc mức mô hình riêng.

Trực giác và ý nghĩa thực tiễn. Binning tạo dữ liệu hồi quy; bước hồi quy mới quyết định độ trơn cuối cùng. Lấy căn làm nhiễu ở các ô có mật độ khác nhau gần cùng variance, rồi unroot đưa kết quả về mật độ.

Đối chiếu nguồn: [4], Mục 6.6, trang in 139–140 (PDF 148–149).

5.7 Root–Unroot và băng tin cậy: mục tiêu nào được phủ?

Trong mô hình Gaussian hồi quy lý tưởng, một smoother tuyến tính $\hat{r}(x) = \sum_j \ell_j(x) Y_j$ có kỳ vọng $r_s(x) = \sum_j \ell_j(x) r(t_j)$ và variance $\sigma^2 \sum_j \ell_j(x)^2$ nếu các nhiễu độc lập. Trên lưới q điểm $x_1, \dots, x_q$, khi σ biết và mô hình đúng, Bonferroni cho khoảng đồng thời của r_s trên lưới:

$$\hat{r}(x_a) \pm z_{1-\alpha/(2q)} \sigma \sqrt{\sum_j \ell_j(x_a)^2}, \quad a = 1, \dots, q.$$

Vì tổng xác suất thất bại ở q điểm không quá α, các khoảng phủ đồng thời ít nhất $1 - \alpha$. Đây chưa phải băng trên continuum; mô hình Root–Unroot thật còn có sai số Poisson/Gaussian và binning. Muốn phủ $r = \sqrt{f}$ thay vì r_s, phải xử lý bias hoặc undersmooth.

Giả sử đã có băng hợp lệ $L(x) \le \sqrt{f(x)} \le U(x)$ trên cả miền. Vì hàm bình phương đơn điệu trên $[0, \infty)$,

$$[\max\{L(x), 0\}]^2 \le f(x) \le [\max\{U(x), 0\}]^2$$

trên sự kiện phủ. Không tự chuẩn hóa hai đầu băng bằng cùng mẫu số ngẫu nhiên của estimator: điều đó đổi đối tượng phủ và cần chứng minh riêng. Chỉ bình phương khoảng cho r_s cho khoảng của r_s^2, không nhất thiết của mật độ thật f.

Trực giác và ý nghĩa thực tiễn. Một biến đổi đẹp không xóa chệch làm trơn hay sự phụ thuộc của số đếm. Cần báo rõ băng phủ hàm thật, hàm đã làm trơn, hay chỉ các giá trị trên một lưới.

Đối chiếu nguồn: [4], Mục 5.7, đặc biệt trang in 89–90 (PDF 99–100), và Mục 6.6.

5.8 KDE nhiều chiều và lời nguyền số chiều

Với $X_i \in \mathbb{R}^d$, kernel tích chuẩn hóa và bandwidth chung h,

$$\hat{f}_h(x) = \frac{1}{nh^d} \sum_i \prod_{a=1}^{d} K((x_a - X_{ia})/h).$$

Đổi biến từng tọa độ cho $dx = h^d du$, nên tích phân estimator bằng 1. Với kernel đối xứng bậc hai, mật độ đủ trơn, miền không gây bias biên, Taylor nhiều chiều cho

$$\operatorname{Bias}(\hat{f}_h(x)) = \frac{h^2 \mu_2(K)}{2} \sum_{a=1}^{d} \partial_{aa} f(x) + o(h^2), \quad \operatorname{Var} \hat{f}_h(x) \approx \frac{f(x) R(K)^d}{nh^d}.$$

Hạng bậc một mất do moment một bằng 0. Hạng hỗn hợp $u_a u_b$ với $a \neq b$ mất vì tích hai moment một; hạng đường chéo u_a^2 giữ lại, cho Laplacian $\sum_a \partial_{aa} f$. Với phần dư tích phân kiểm soát được, AMISE có dạng $Ah^4 + B/(nh^d)$. Đạo hàm:

$$4Ah^3 - \frac{dB}{nh^{d+1}} = 0 \quad \Longrightarrow \quad \boxed{h_* \asymp n^{-1/(4+d)}, \quad \text{MISE} = O(n^{-4/(4+d)}).}$$

Ở $d = 1$, số mũ 4/5; $d = 6$, số mũ chỉ còn 2/5. Giả sử bỏ qua hằng số và muốn cùng quy mô sai số như $d = 1$, cỡ mẫu n_1, cần $n_d \approx n_1^{(d+4)/5}$. Nếu $n_1 = 100$, thì $n_2 \approx 251$, $n_6 \approx 10\,000$, $n_{10} \approx 398\,107$. Đây chỉ là so sánh theo tốc độ, không phải cỡ mẫu bảo đảm cho mọi mật độ.

Trực giác và ý nghĩa thực tiễn. Thể tích cửa sổ giảm theo h^d, nên dữ liệu lân cận nhanh chóng thưa khi tăng số chiều. Cấu trúc bổ sung như mô hình cộng hoặc chiều nội tại thấp có thể giúp, nhưng thay đổi lớp bài toán và giả thiết.

Đối chiếu nguồn: [4], Mục 6.5, trang in 138–139 (PDF 147–148).

Chương 6

Ngân hàng bài tập có lời giải từng bước

Các bài dưới đây là bài luyện tự biên soạn hoặc diễn giải từ dạng bài trong các nguồn ở thư mục môn học, không được gán số bài của sách hay đề thi chính thức. Dùng cùng quy ước kernel và quantile trong giáo trình. Làm tròn ở bước cuối; giữ phân số hoặc biểu thức chuẩn tắc càng lâu càng tốt.

6.1 Dạng 1: tính KDE và đạo hàm

Bài 6.1 (Mẫu gốc và điểm không khả vi)**.** Cho $X = (1, 2, 4, 5)$, $x = 3$, $h = 2$. Tính $\hat{f}_2(3)$, $\hat{f}_2'(3)$, $\hat{f}_2''(3)$ với Epanechnikov, Uniform, Triangular và Gaussian. Giải thích nếu đạo hàm không tồn tại.

Lời giải.

1. Chuẩn hóa khoảng cách và các mẫu số. $n = 4$, $(u_1, u_2, u_3, u_4) = (1, 1/2, -1/2, -1)$. Các mẫu số cho mật độ, đạo hàm một và hai là $nh = 8$, $nh^2 = 16$, $nh^3 = 32$.

u	Epanechnikov	Uniform	Triangular	Gaussian
1	0	1/2	0	$\varphi(1)$
1/2	9/16	1/2	1/2	$\varphi(1/2)$
$-1/2$	9/16	1/2	1/2	$\varphi(1/2)$
-1	0	1/2	0	$\varphi(1)$

2. Cộng trọng số và chia cho nh.

$$\hat{f}_{\mathrm{E}}(3) = \frac{18/16}{8} = \boxed{\frac{9}{64}}, \quad \hat{f}_{\mathrm{U}}(3) = \frac{2}{8} = \boxed{\frac{1}{4}}, \quad \hat{f}_{\mathrm{T}}(3) = \frac{1}{8} = \boxed{\frac{1}{8}}.$$

Với Gaussian,

$$\hat{f}_{\mathrm{G}}(3) = \boxed{\frac{\varphi(1) + \varphi(1/2)}{4}} \approx 0.14850901.$$

Uniform dùng đầu mút đóng; nếu dùng $|u| < 1$, giá trị tại đúng 3 sẽ là 1/8. Giá trị giới hạn quanh 3 vẫn phải kiểm tra riêng.

3. Gaussian: dùng trực tiếp công thức đạo hàm. K' lẻ, nên các cặp đối xứng triệt tiêu và $\hat{f}_{\mathrm{G}}'(3) = 0$. $K''(\pm 1) = 0$, $K''(\pm 1/2) = -3\varphi(1/2)/4$, nên

$$\hat{f}_{\mathrm{G}}''(3) = \frac{-3\varphi(1/2)/2}{32} = \boxed{-\frac{3\varphi(1/2)}{64}} \approx -0.01650306.$$

4. Epanechnikov: xét tổng ở $3+\delta$. Với $|\delta|$ đủ nhỏ, hai điểm 2 và 4 ở trong cửa sổ. Tổng kernel của chúng bằng $9/8 - 3\delta^2/8$. Nếu $\delta > 0$, chỉ điểm 5 ở đầu ngoài đi vào cửa sổ, đóng góp $3\delta/4 - 3\delta^2/16$; nếu $\delta < 0$, điểm 1 đi vào, cho $-3\delta/4 - 3\delta^2/16$. Ghép hai phía:

$$\hat{f}_{\mathrm{E}}(3+\delta) = \frac{9}{64} + \frac{3}{32}|\delta| - \frac{9}{128}\delta^2.$$

Thương sai phân từ trái tiến về $-3/32$, từ phải về $3/32$. Vì hai giới hạn khác nhau, $\boxed{\hat{f}'_{\mathrm{E}}(3) \text{ không tồn tại}}$; đạo hàm bậc hai cổ điển cũng không tồn tại. Tính đối xứng của hàm không buộc đạo hàm tại tâm tồn tại: $|\delta|$ là phản ví dụ đơn giản.

5. Triangular và Uniform: kiểm tra tương tự. Với Triangular, hai điểm nội cho tổng 1; một điểm ở ranh giới đi vào cho $|\delta|/2$:

$$\hat{f}_{\mathrm{T}}(3+\delta) = \frac{1}{8} + \frac{1}{16}|\delta|.$$

Hai độ dốc là $-1/16$ và $1/16$, nên cả hai đạo hàm yêu cầu không tồn tại. Với Uniform đóng, tại 3 có bốn điểm được đếm, nhưng với $0 < |\delta|$ đủ nhỏ chỉ còn ba điểm. Vì thế

$$\lim_{\delta \to 0,\, \delta \neq 0} \hat{f}_{\mathrm{U}}(3+\delta) = \frac{3}{16} \neq \frac{1}{4} = \hat{f}_{\mathrm{U}}(3).$$

Hàm không liên tục tại 3, nên không có đạo hàm một hoặc hai ở đó.

Lỗi dễ mắc. Không dùng giá trị $K'' = -3/2$ của Epanechnikov ở điểm nối; không bỏ các điểm $u = \pm 1$ khi kiểm tra giới hạn. Giá trị mật độ tại đầu mút và tính khả vi của tổng là hai câu hỏi khác nhau.

Bài 6.2 (Cùng mẫu, điểm khả vi)**.** Giữ $X = (1, 2, 4, 5)$ và $x = 3$, đổi $h = 3/2$. Tính ba đại lượng trên cho cùng bốn kernel.

Lời giải.

1. Xác định điểm nội và ngoại. $u = (4/3, 2/3, -2/3, -4/3)$. Với các kernel compact, hai điểm ngoài không đóng góp, hai điểm còn lại không ở điểm nối hoặc ở 0. Các mẫu số là $nh = 6$, $nh^2 = 9$, $nh^3 = 27/2$.

2. Epanechnikov. $K(\pm 2/3) = \frac{3}{4}(1 - 4/9) = 5/12$, nên

$$\hat{f}(3) = \frac{2(5/12)}{6} = \boxed{\frac{5}{36}}, \quad \hat{f}'(3) = \frac{-1+1}{9} = \boxed{0}, \quad \hat{f}''(3) = \frac{-3}{27/2} = \boxed{-\frac{2}{9}}.$$

3. Uniform và Triangular. Uniform cho $\hat{f}(3) = 2(1/2)/6 = \boxed{1/6}$, hai đạo hàm bằng 0 vì estimator hằng trong một lân cận của 3. Triangular cho $\hat{f}(3) = 2(1/3)/6 = \boxed{1/9}$, đạo hàm một bằng $(-1+1)/9 = 0$, đạo hàm hai bằng 0 tại điểm này.

4. Gaussian. Đặt $a = \varphi(4/3)$, $b = \varphi(2/3)$:

$$\hat{f}(3) = \boxed{\frac{a+b}{3}} \approx 0.16115269, \quad \hat{f}'(3) = \boxed{0},$$

$$\hat{f}''(3) = \frac{2[(7/9)a - (5/9)b]}{27/2} = \boxed{\frac{4(7a-5b)}{243}} \approx -0.00739374.$$

Ở đây áp dụng công thức đạo hàm hợp lệ vì tất cả đối số tránh điểm không khả vi. Đây không phải chứng cứ rằng Uniform ước lượng f'' tốt: đạo hàm bằng 0 chỉ phản ánh hàm hằng từng đoạn.

Bài 6.3 (Biweight ở một điểm nội)**.** Cho $X = (0, 1, 2)$, $x = 1$, $h = 2$, kernel Biweight. Tính mật độ, đạo hàm một và hai.

Lời giải.

1. Lập bảng ba giá trị. $u = (1/2, 0, -1/2)$, mẫu số $(nh, nh^2, nh^3) = (6, 12, 24)$.

$$K(\pm 1/2) = \frac{15}{16}\left(\frac{3}{4}\right)^2 = \frac{135}{256}, \qquad K(0) = \frac{15}{16}.$$

2. Mật độ.

$$\widehat{f}_2(1) = \frac{270/256 + 240/256}{6} = \boxed{\frac{85}{256}}.$$

3. Đạo hàm. K' lẻ nên tổng bằng 0. Với $K''(u) = 15(3u^2 - 1)/4$,

$$K''(\pm 1/2) = -\frac{15}{16}, \qquad K''(0) = -\frac{15}{4},$$

$$\boxed{\widehat{f}_2'(1) = 0, \qquad \widehat{f}_2''(1) = \frac{-15/16 - 15/4 - 15/16}{24} = -\frac{15}{64}.}$$

Độ cong âm thể hiện hình dạng lõm xuống của estimator tại tâm mẫu này.

6.2 Dạng 2: tích phân hằng số kernel

Bài 6.4 (Uniform và Triangular)**.** Tính trực tiếp $\mu_2(K)$ và $R(K)$ của hai kernel.

Lời giải.

1. Uniform. Đối xứng cho

$$\mu_2 = 2\int_0^1 u^2 \frac{1}{2} du = [u^3/3]_0^1 = \boxed{1/3}, \quad R = 2\int_0^1 (1/2)^2 du = \boxed{1/2}.$$

2. Triangular. Trên $[0, 1]$, $K = 1 - u$, nên

$$\mu_2 = 2\int_0^1 (u^2 - u^3) du = 2\left(\frac{1}{3} - \frac{1}{4}\right) = \boxed{1/6},$$

$$R = 2\int_0^1 (1 - 2u + u^2) du = 2\left(1 - 1 + \frac{1}{3}\right) = \boxed{2/3}.$$

Không bỏ hệ số 2 khi chuyển tích phân kernel chẵn từ $[-1, 1]$ sang $[0, 1]$.

Bài 6.5 (Epanechnikov)**.** Kiểm tra chuẩn hóa, rồi tính μ_2 và R.

Lời giải.

1. Diện tích. $\int K = (3/2)\int_0^1 (1 - u^2) du = (3/2)(1 - 1/3) = 1$.

2. Moment bậc hai.

$$\mu_2 = \frac{3}{2}\int_0^1 (u^2 - u^4) du = \frac{3}{2}\left(\frac{1}{3} - \frac{1}{5}\right) = \boxed{\frac{1}{5}}.$$

3. Bình phương kernel. Phải bình phương cả hệ số 3/4:

$$R = \frac{9}{8}\int_0^1 (1 - 2u^2 + u^4)du = \frac{9}{8}\left(1 - \frac{2}{3} + \frac{1}{5}\right) = \frac{9}{8}\frac{8}{15} = \boxed{\frac{3}{5}}.$$

Hai hằng số này đi vào AMISE theo cách khác nhau: μ_2 bình phương trong squared bias, R tuyến tính trong variance.

Bài 6.6 (Biweight)**.** Tính μ_2 và R bằng khai triển đa thức.

Lời giải.

1. Chuẩn hóa.

$$\int K = \frac{15}{8}\int_0^1 (1 - 2u^2 + u^4)du = \frac{15}{8}\frac{8}{15} = 1.$$

2. Moment bậc hai.

$$\mu_2 = \frac{15}{8}\int_0^1 (u^2 - 2u^4 + u^6)du = \frac{15}{8}\left(\frac{1}{3} - \frac{2}{5} + \frac{1}{7}\right) = \frac{15}{8}\frac{8}{105} = \boxed{\frac{1}{7}}.$$

3. Bình phương. $(1 - u^2)^4 = 1 - 4u^2 + 6u^4 - 4u^6 + u^8$, nên

$$\begin{aligned} R &= \frac{225}{128}\left(1 - \frac{4}{3} + \frac{6}{5} - \frac{4}{7} + \frac{1}{9}\right) \\ &= \frac{225}{128}\frac{128}{315} = \boxed{\frac{5}{7}}. \end{aligned}$$

Giữ phân số tránh sai số khi các số hạng đa thức triệt tiêu mạnh.

6.3 Dạng 3: bandwidth và cross-validation

Bài 6.7 (Bandwidth tham chiếu chuẩn)**.** Với $X = (1, 2, 4, 5)$, tính bandwidth Gaussian normal-reference. So sánh hệ số chính xác $(4/3)^{1/5}$ với hệ số làm tròn 1.06.

Lời giải.

1. Tính độ lệch chuẩn mẫu. $\overline{X} = 3$, tổng bình phương độ lệch là 10.

$$s^2 = \frac{10}{4-1} = \frac{10}{3}, \qquad s \approx 1.82574186.$$

2. Tính thừa số cỡ mẫu. $4^{-1/5} \approx 0.75785828$. Do đó

$$\boxed{h_{\mathrm{NR}} = (4/3)^{1/5}\sqrt{10/3}\,4^{-1/5} \approx 1.46559887.}$$

Dùng 1.06 cho $h \approx 1.46667281$. Khác biệt là làm tròn hệ số, không phải phương pháp khác.

3. Nếu dùng scale bền vững. Theo quantile nghịch đảo EDF, $Q_{0.25} = 1$, $Q_{0.75} = 4$, nên $\mathrm{IQR} = 3$, $\mathrm{IQR}/1.34 \approx 2.23881 > s$. Vậy $a = \min(s, \mathrm{IQR}/1.34) = s$. Quy tắc hệ số 0.9 cho $0.9s4^{-1/5} \approx 1.24528823$.

Lỗi dễ mắc. Dùng phương sai plug-in 2.5 thay $s^2 = 10/3$ làm thay đổi đáp số. Phải ghi rõ định nghĩa scale và quy ước quantile.

Bài 6.8 (Uniform LOOCV bằng phân số)**.** Cho $X = (0, 1, 2)$, kernel Uniform. Tính $\widehat{J}(h)$ với $h = 3/4, 3/2$, rồi chọn trong hai ứng viên.

Lời giải.

1. Tính tích phân bằng độ dài giao. Mỗi cửa sổ dài $2h$, cao $1/(2nh)$. Hai cửa sổ cách tâm d giao trên đoạn dài $(2h - |d|)_+$. Do đó

$$\int \hat{f}_h^2 = \frac{1}{4n^2h^2} \sum_{i,j} (2h - |X_i - X_j|)_+.$$

Trong chín cặp có thứ tự: ba cặp khoảng cách 0, bốn cặp khoảng cách 1, hai cặp khoảng cách 2.

2. Bandwidth $h = 3/4$. Tổng độ dài giao là $3(3/2) + 4(1/2) = 13/2$. Tích phân bình phương bằng $(13/2)/(36 \cdot 9/16) = 26/81$. Không có quan sát khác trong khoảng cách h của mỗi điểm, nên tổng LOO bằng 0:

$$\boxed{\widehat{J}(3/4) = 26/81 \approx 0.32098765.}$$

3. Bandwidth $h = 3/2$. Tổng độ dài giao là $3(3) + 4(2) + 2(1) = 19$. Tích phân bằng $19/(36 \cdot 9/4) = 19/81$. Số hàng xóm LOO lần lượt là $(1, 2, 1)$, nên các mật độ LOO bằng $(1/6, 1/3, 1/6)$ và tổng bằng $2/3$.

$$\boxed{\widehat{J}(3/2) = \frac{19}{81} - \frac{2}{3}\frac{2}{3} = -\frac{17}{81} \approx -0.20987654.}$$

Chọn $\boxed{h = 3/2}$ trong hai ứng viên vì tiêu chuẩn nhỏ hơn.

Lỗi dễ mắc. LOO đếm khoảng cách $\le h$, còn phần tích phân bình phương phụ thuộc khoảng giao khi khoảng cách $< 2h$. Các bài này tránh trường hợp khoảng cách bằng đúng h, nên quy ước đầu mút không đổi điểm CV.

Bài 6.9 (Gaussian LOOCV bằng tổng đôi)**.** Cho $X = (0, 1)$, Gaussian. Tính CV tại $h = 1/2, 1$.

Lời giải.

1. Dùng kernel tích chập. $C_K(v) = e^{-v^2/4}/(2\sqrt{\pi})$. Có hai cặp đường chéo và hai cặp ngoài đường chéo, nên

$$\int \hat{f}_h^2 = \frac{2C_K(0) + 2C_K(1/h)}{4h} = \frac{1 + e^{-1/(4h^2)}}{4\sqrt{\pi}h}.$$

2. Mật độ LOO. Sau khi bỏ một điểm chỉ còn một điểm; mỗi giá trị LOO bằng $\varphi(1/h)/h$. Vì $2/n = 1$, số hạng trừ là $2\varphi(1/h)/h$. Do đó

$$\boxed{\widehat{J}(h) = \frac{1 + e^{-1/(4h^2)}}{4\sqrt{\pi}h} - \frac{2\varphi(1/h)}{h}.}$$

3. Thế số.

h	$\int \hat{f}_h^2$	Tổng LOO	$\widehat{J}(h)$
$1/2$	0.38587167	0.21596387	0.16990780
1	0.25089522	0.48394145	−0.23304623

Chọn $\boxed{h = 1}$ trong hai ứng viên. Với mẫu rất nhỏ, quyết định chỉ minh họa phép tính; không cho biết bandwidth tối ưu toàn bộ miền dương.

6.4 Dạng 4: kiểm định KS từng bước

Bài 6.10 (Mẫu trên $[0,1]$)**.** Cho $X = (0.1, 0.4, 0.6, 0.8)$, kiểm định $H_0 : X \sim U[0,1]$. Tính D_n^+, D_n^-, D_n. Dùng DKW mức 5% để quyết định.

Lời giải.

1. Sắp xếp và tính CDF null. Mẫu đã sắp, $F_0(X_{(i)}) = X_{(i)}$.

i	u_i	$i/4 - u_i$	$u_i - (i-1)/4$
1	0.10	0.15	0.10
2	0.40	0.10	0.15
3	0.60	0.15	0.10
4	0.80	0.20	0.05

2. Lấy cực đại của hai cột sai khác.

$$\boxed{D_4^+ = 0.20, \quad D_4^- = 0.15, \quad D_4 = 0.20.}$$

3. So với ngưỡng bảo thủ hữu hạn mẫu. $\epsilon_4 = \sqrt{\log 40/8} \approx 0.67905$. $0.20 < 0.67905$, nên không bác bỏ bằng kiểm định DKW này. Ngưỡng lớn phản ánh mẫu chỉ có bốn quan sát; không thể kết luận phân phối đều đúng vì không bác bỏ.

4. Kiểm tra thêm CvM và AD trên cùng mẫu. Các tâm so sánh CvM lần lượt là

$$(0.125, 0.375, 0.625, 0.875).$$

$$W_4^2 = \frac{1}{48} + (-.025)^2 + (.025)^2 + (-.025)^2 + (-.075)^2 = \boxed{\frac{17}{600} \approx 0.02833333}.$$

AD dùng công thức log ở Chương 1 cho $\boxed{A_4^2 \approx 0.20438803}$. Các số này là thống kê; cần phân phối null tương ứng để đưa ra quyết định CvM hoặc AD, không so chúng với ngưỡng KS.

Bài 6.11 (Null mũ được chỉ định đầy đủ)**.** Cho $X = (0.2, 0.5, 1, 1.5)$, kiểm định với $F_0(x) = 1 - e^{-x}$, $x \geq 0$, tức tốc độ mũ cố định bằng 1. Tính KS.

Lời giải.

1. Tính u_i.

i	$X_{(i)}$	u_i	$i/4 - u_i$	$u_i - (i-1)/4$
1	0.2	.18126925	.06873075	.18126925
2	0.5	.39346934	.10653066	.14346934
3	1.0	.63212056	.11787944	.13212056
4	1.5	.77686984	.22313016	.02686984

2. Cực đại hai phía.

$$\boxed{D_4^+ = e^{-1.5} \approx 0.22313016, \quad D_4^- = 1 - e^{-0.2} \approx 0.18126925, \quad D_4 \approx 0.22313016.}$$

Nếu dùng DKW 5%, không bác bỏ vì nhỏ hơn 0.67905. Không thay tốc độ bằng $1/\overline{X}$ trong bài này: đề đã chỉ định tốc độ 1. Nếu fit tốc độ từ mẫu, cần phân phối null được hiệu chỉnh.

Bài 6.12 (Dữ liệu trùng và giới hạn trái)**.** Cho $X = (0.2, 0.2, 0.7, 0.9)$, null đều trên $[0, 1]$. Tính KS và giải thích cách xử lý bước nhảy cao $2/4$.

Lời giải.

1. Viết hai cột với tất cả thứ tự thống kê. Các $u_i = (.2, .2, .7, .9)$.

$$\left(\frac{i}{4} - u_i\right) = (.05, .30, .05, .10), \quad \left(u_i - \frac{i-1}{4}\right) = (.20, -.05, .20, .15).$$

Các giá trị ở thứ hạng giữa một nhóm trùng không tương ứng EDF thực ở một khoảng riêng, nhưng cực đại đúng vẫn được giữ: dùng thứ hạng cuối nhóm cho phía phải, thứ hạng đầu nhóm cho giới hạn trái.

2. Kiểm tra tại giá trị khác nhau. Tại $x = .2$, $\widehat{F}_n(.2) = .5$, $\widehat{F}_n(.2-) = 0$. Sai khác bên phải là $.5 - .2 = .3$, bên trái là $.2 - 0 = .2$. Tại .7, hai sai khác là $.75 - .7 = .05$ và $.7 - .5 = .2$; tại .9, là .1 và .15. Vậy

$$\boxed{D_4^+ = .3, \quad D_4^- = .2, \quad D_4 = .3.}$$

Nếu dữ liệu trùng do làm tròn hoặc do phân phối rời rạc, mô hình quan sát cần được xét lại khi hiệu chỉnh mức kiểm định. Trong một mô hình liên tục chính xác, xác suất có các giá trị trùng đúng bằng nhau là 0. Phép tính thống kê vẫn xác định; diễn giải null phải phù hợp dữ liệu.

6.5 Bốn bài chứng minh củng cố

Bài 6.13 (EDF, covariance và DKW)**.** Chứng minh covariance EDF khi $x < y$ bằng số đếm; tìm cỡ mẫu để băng DKW 95% có nửa độ rộng không quá 0.05.

Lời giải.

1. Chia ba vùng loại trừ nhau. Đặt $A_i = \mathbf{1}_{X_i \le x}$, $B_i = \mathbf{1}_{x < X_i \le y}$. Với $p = F(x)$, $q = F(y)$, $\mathbb{E}A_i = p$, $\mathbb{E}B_i = q - p$, và $A_i B_i = 0$. Vì thế $\mathrm{Cov}(A_i, B_i) = -p(q-p)$.

2. Dùng $\mathbf{1}_{X_i \le y} = A_i + B_i$.

$$\mathrm{Cov}(A_i, A_i + B_i) = p(1-p) - p(q-p) = p(1-q).$$

Giữa quan sát khác nhau, covariance bằng 0. Chia tổng covariance cho n^2 cho $\boxed{p(1-q)/n}$.

3. Giải điều kiện độ rộng.

$$\sqrt{\frac{\log 40}{2n}} \le .05 \iff n \ge \frac{\log 40}{2(.05)^2} \approx 737.77589.$$

Lấy số nguyên lớn hơn hoặc bằng: $\boxed{n \ge 738}$. Không làm tròn xuống vì cần bảo đảm bất đẳng thức.

Bài 6.14 (Histogram: MISE chính xác cho mật độ tuyến tính)**.** Cho $f(x) = 2x$ trên $[0, 1]$, $n = 96$, $m = 4$. Tính squared bias tích phân và phương sai tích phân chính xác, rồi so với AMISE.

Lời giải.

1. Xác suất từng ô. $h = 1/4$ và

$$p_j = \int_{(j-1)/4}^{j/4} 2x\,dx = \frac{j^2 - (j-1)^2}{16} = \frac{2j-1}{16}.$$

Vì thế $p = (1,3,5,7)/16$; kỳ vọng histogram ở ô j là $p_j/h = (2j-1)/4$, bằng $2c_j$. Bias tại x là $2(c_j - x)$, chính xác vì mật độ tuyến tính.

2. Squared bias tích phân.

$$\int b^2 = \sum_{j=1}^{4} \int_{-h/2}^{h/2} 4t^2 dt = 4\frac{4h^3}{12} = \boxed{\frac{1}{48}}.$$

3. Phương sai tích phân. $\sum_j p_j^2 = (1+9+25+49)/256 = 21/64$.

$$\int \mathrm{Var} = \frac{1}{96/4}\left(1 - \frac{21}{64}\right) = \boxed{\frac{43}{1536}}.$$

Tổng MISE $= 1/48 + 43/1536 = \boxed{25/512 \approx 0.04882813}$.

4. So với AMISE. $R(f') = 4$ nên $h_* = (6/(4\cdot 96))^{1/3} = 1/4$. AMISE tại đó là $4h^2/12 + 1/(nh) = 1/48 + 1/24 = \boxed{1/16}$. AMISE khác MISE vì bỏ số hạng âm bậc $1/n$ trong variance tích phân.

Bài 6.15 (AMISE và độ nhạy bandwidth)**.** Với Epanechnikov, $R(f'') = 1$, $n = 480$, tìm h_*, AMISE tối ưu và AMISE tại $h_*/2$, $2h_*$; chứng minh tỷ số tổng quát.

Lời giải.

1. Thế các hằng số kernel.

$$\mathrm{AMISE}(h) = \frac{(1/5)^2}{4}h^4 + \frac{3/5}{480h} = \frac{h^4}{100} + \frac{1}{800h}.$$

2. Đạo hàm và nghiệm. $4h^3/100 - 1/(800h^2) = 0 \iff h^5 = 1/32$, nên $\boxed{h_* = 1/2}$. Khi đó squared bias bằng $1/1600$, variance bằng $1/400$, tổng $\boxed{1/320}$.

3. Hai ứng viên lệch tối ưu.

$$\mathrm{AMISE}(1/4) = \frac{1}{25600} + \frac{1}{200} = \boxed{\frac{129}{25600}}, \quad \mathrm{AMISE}(1) = \frac{1}{100} + \frac{1}{800} = \boxed{\frac{9}{800}}.$$

4. Tỷ số tổng quát. Viết AMISE là $Ah^4 + B/(nh)$. Tại nghiệm, $B/(nh_*) = 4Ah_*^4$. Vì vậy

$$\boxed{\frac{\mathrm{AMISE}(ch_*)}{\mathrm{AMISE}(h_*)} = \frac{c^4 Ah_*^4 + 4Ah_*^4/c}{5Ah_*^4} = \frac{c^4 + 4/c}{5}.}$$

Đổi bandwidth nửa lần hoặc hai lần không gây thay đổi đối xứng về rủi ro, vì bias bình phương tăng theo lũy thừa bốn.

Bài 6.16 (Contrast, Pythagoras và tái tạo tuyến tính)**.** Chứng minh ba sự triệt tiêu sau: contrast có cực tiểu tại hệ số mẫu; hạng chéo sai số chiếu bằng 0; local linear triệt tiêu thành phần độ dốc. Nêu nguyên nhân khác nhau của mỗi sự triệt tiêu.

Lời giải.

1. Contrast. Với $g = \sum_{j \le D} b_j \phi_j$,

$$\gamma_n(g) = \sum_j (b_j^2 - 2b_j \hat{a}_j) = \sum_j (b_j - \hat{a}_j)^2 - \sum_j \hat{a}_j^2.$$

Tổng bình phương cực tiểu bằng 0 khi $b_j = \hat{a}_j$. Đó là hoàn thành bình phương, không phải một giả thiết độc lập.

2. Pythagoras. $f - f_D$ có tích vô hướng 0 với mọi ϕ_j, $j \le D$; $f_D - \hat{f}_D$ là tổ hợp của các hàm này. Do tuyến tính, $\left\langle f - f_D, f_D - \hat{f}_D \right\rangle = 0$. Khi khai triển bình phương chuẩn, hạng chéo mất do *trực giao trong không gian hàm.*

3. Local linear. Với $w_i = k_i(S_2 - S_1 d_i)/\Delta$,

$$\sum_i w_i d_i = \frac{S_2 \sum_i k_i d_i - S_1 \sum_i k_i d_i^2}{\Delta} = \frac{S_2 S_1 - S_1 S_2}{\Delta} = 0.$$

Taylor $r(X_i) = r(x) + r'(x) d_i + O(h^2)$; $r'(x) \sum_i w_i d_i = 0$. Đây là *đẳng thức moment của trọng số*, đúng với thiết kế cụ thể nếu $\Delta > 0$.

4. Kết luận. Ba thao tác cùng loại bỏ hạng nhưng lý do khác nhau: tối ưu đại số, trực giao hàm, và ràng buộc moment. Không viết chung một câu "do các biến độc lập" cho cả ba.

6.6 Cách tự chấm bài

Một lời giải đủ cần có định nghĩa estimator, bảng đối số hoặc ô, mẫu số đúng, miền áp dụng, phép cộng/tích phân và kết luận. Với đạo hàm, kiểm tra điểm nối trước khi tính. Với bandwidth, ghi đây là tối ưu AMSE tại điểm, AMISE toàn cục hay CV trên tập ứng viên. Với kiểm định, ghi null, thống kê, ngưỡng và quyết định; tránh biến "không bác bỏ" thành "chứng minh đúng".

Phụ lục A

Bảng tra cứu, nguồn và tái lập

A.1 Các hằng số kernel

Mọi kernel compact trong bảng dùng giá đỡ $[-1, 1]$ và chuẩn hóa như Chương 3. Với kernel Uniform có giá đỡ $[-1/2, 1/2]$, các hằng số sẽ khác; không trộn hai cách chuẩn hóa khi dùng cùng bandwidth.

Kernel	$\mu_2(K)$	$R(K)$
Gaussian	1	$1/(2\sqrt{\pi})$
Epanechnikov	1/5	3/5
Uniform	1/3	1/2
Triangular	1/6	2/3
Biweight	1/7	5/7
Triweight	1/9	350/429
Tricube	35/243	175/247

Các hằng số compact được kiểm chứng bằng tích phân đa thức chính xác và tích phân số độc lập. Với Gaussian dùng tích phân chuẩn tắc.

A.2 Bảng công thức và điều kiện tối thiểu cần nhớ

Chủ đề	Công thức và điều kiện
EDF	$\mathbb{E}\widehat{F}_n(x) = F(x)$, $\operatorname{Var}\widehat{F}_n(x) = F(x)(1-F(x))/n$; mẫu i.i.d., không yêu cầu có mật độ.
DKW	$\epsilon_n = \sqrt{\log(2/\alpha)/(2n)}$; băng cắt tại 0 và 1, phủ đồng thời ít nhất $1-\alpha$.
Plug-in	$T(\widehat{F}_n)$; nhất quán cần tính liên tục phù hợp hoặc LLN và điều kiện moment của thống kê cụ thể.
KS	$D_n = \max_i\{i/n - F_0(X_{(i)}), F_0(X_{(i)}) - (i-1)/n\}$; bảng null chuẩn dùng F_0 liên tục, đã chỉ định đầy đủ.
Histogram	$N_j/(nh)$; bias thường $O(h)$, variance $O(1/(nh))$; MISE $n^{-2/3}$ trong thiết lập trơn bậc một và phân hoạch thích hợp.
KDE	$(nh)^{-1}\sum K((x-X_i)/h)$; $K \geq 0$, $\int K = 1$ đảm bảo mật độ.
Bias KDE	$h^2\mu_2 f''/2 + O(h^4)$ dưới điều kiện đạo hàm bậc bốn và moment tuyệt đối bậc bốn; không áp dụng ở biên chưa hiệu chỉnh.

Chủ đề	Công thức và điều kiện
AMISE KDE	$h^4\mu_2^2 R(f'')/4 + R(K)/(nh)$; cần điều kiện phần dư tích phân. $h_* \asymp n^{-1/5}$, MISE $O(n^{-4/5})$.
Normal reference	$(4/3)^{1/5} s n^{-1/5}$ với Gaussian và mật độ tham chiếu chuẩn; scale bền vững hoặc hệ số 0.9 cần ghi riêng.
CV	$\int \hat{f}_h^2 - (2/n)\sum_i \hat{f}_{(-i),h}(X_i)$; giữ h, estimator LOO có mẫu số $n-1$.
Phép chiếu	$\sum_{j\le D} \hat{a}_j \phi_j$; rủi ro bằng sai số xấp xỉ cộng tổng variance hệ số. Không tự không âm.
NW	$\sum k_i Y_i / \sum k_i$; mẫu số dương, bias nội miền có design bias $2r'f'/f$.
Local linear	$(S_2T_0 - S_1T_1)/(S_0S_2 - S_1^2)$; ma trận không suy biến, $\sum w_i = 1$, $\sum w_i(X_i - x) = 0$.
Root–Unroot	$Y_j = \sqrt{(k/n)(N_j + 1/4)}$; variance gần $k/(4n)$ trong xấp xỉ Poisson đủ tốt; hồi quy, lấy phần dương, bình phương và chuẩn hóa.
Nhiều chiều	Với trơn bậc hai và xử lý biên phù hợp, $h_* \asymp n^{-1/(4+d)}$, MISE $O(n^{-4/(4+d)})$.

A.3 Bản đồ nguồn để đọc sâu

Số trang PDF tính từ 1 và có tính cả bìa; số trang in là số trong giáo trình. Trong các slide, số slide trùng thứ tự trang PDF của các bản hiện có.

Nội dung	Nguồn chính
EDF, plug-in, GOF	[1], 46 trang PDF; Wasserman Chương 2. EDF/hội tụ đều ở slide 10–20; plug-in 30–35; GOF 36–46.
Histogram	[2], slide 12–18; Wasserman Mục 6.2, chứng minh MISE trong phụ lục trang in 140–142, PDF 149–151.
KDE và bandwidth	[2], slide 19–29; Wasserman Mục 6.3, trang in 132–136, PDF 141–145.
Hölder và minimax	Tsybakov Mục 1.2, đặc biệt Mệnh đề 1.1–1.2 và Định lý 1.1, trang in 4–9, PDF 15–20; Chương 2 cho công cụ lower bound. Wasserman Định lý 6.31, trang in 134–135, PDF 143–144, cho lower bound MISE trên lớp đạo hàm L_2.
Phép chiếu	[3], slide 8–24; [2], slide 30–34. Tsybakov Mục 1.7 bổ sung nền chuỗi trực chuẩn; lưu ý phần đó chủ yếu xét hồi quy, không thay nguyên xi variance hồi quy bằng variance mật độ.
Hồi quy và băng	Wasserman Mục 5.4 về hồi quy cục bộ, Mục 5.7 về băng tin cậy; trang in 89–90, PDF 99–100, nêu vấn đề mục tiêu làm trơn so với hàm thật. Tsybakov Mục 1.5–1.6.
Root–Unroot	Wasserman Mục 6.6, trang in 139–140, PDF 148–149.
KDE nhiều chiều	Wasserman Mục 6.5, trang in 138–139, PDF 147–148.

A.3.1 Các điểm được làm rõ khi đối chiếu

1. Chệch histogram và KDE cần phân biệt giá trị tại điểm, toàn miền, và tích phân. Không tích phân một chặn điểm hằng trên miền vô hạn.
2. Nhân $K_4 = (3 - u^2)\varphi/2$ là bậc bốn theo định nghĩa moment của tài liệu; tên "bậc ba" trong một số quy ước chỉ đếm số moment bị triệt tiêu. Công thức moment mới là căn cứ.

3. Hölder bậc lớn hơn 1 phải dùng đạo hàm; histogram không tự đạt $D^{-2\beta}$ với mọi β chỉ vì mật độ trơn.

4. Đồng nhất thức contrast dùng $-2\nu_n(g)$ với $\nu_n = P_n - P$. Dấu được suy lại từ định nghĩa, không sao chép dấu cộng trong phác thảo slide chiếu.

5. Chuyển mật độ từ $[0,1]$ về $[a,b]$ cần hệ số $1/(b-a)$; $1/\sqrt{b-a}$ chỉ là hệ số chuẩn hóa cơ sở L_2.

6. Không gán một hằng số phạt phổ quát từ ví dụ mô phỏng cho một định lý oracle. Phác thảo Chương 4 ghi tường minh bước tập trung được viện dẫn.

A.4 Tái lập bản PDF và kiểm chứng

Thư mục chứa `main.tex`, các chương trong `chapters/`, bảy hình PDF trong `figures/`, script `verify_and_figures.py` và báo cáo `verification.json`. Chạy tại thư mục tài liệu:

```
python3 verify_and_figures.py
latexmk -xelatex -interaction=nonstopmode -halt-on-error main.tex
```

Python cần NumPy, SciPy, SymPy, Matplotlib. Trên môi trường workspace hiện tại, interpreter có sẵn các thư viện là `/opt/anaconda3/bin/python`; có thể thay `python3` bằng đường dẫn đó. XeLaTeX dùng Latin Modern, `polyglossia` và các gói trong preamble; không yêu cầu font thương mại hay font cài riêng từ hệ điều hành. Lệnh `make check` chạy cả kiểm chứng số, biên dịch và kiểm tra cấu trúc PDF bằng `check_document.py`; bước cuối cần thêm PyMuPDF. Nếu cần chọn interpreter, dùng `make check PYTHON=/opt/anaconda3/bin/python`.

Script dùng seed cố định, kiểm tra moment bằng đại số và tích phân số, kiểm tra công thức đạo hàm bên trong miền, giới hạn một phía ở bài gốc, CV qua công thức và tích phân độc lập, KS qua thuật toán thư viện, CvM/AD qua tích phân trực tiếp, và tái tạo tuyến tính ở cả hai biên. Các phép kiểm số không thay thế chứng minh tiệm cận hoặc lower bound.

Trực giác và ý nghĩa thực tiễn. Nguồn, quy ước và cách chạy là một phần của tính tái lập. Nếu đáp số khác phần mềm, kiểm tra chuẩn hóa kernel, quantile, mẫu số variance và quy ước đầu mút trước khi kết luận công thức sai.

Tài liệu tham khảo

[1] Slide môn học, *TKPTS_Chương 1*, 46 trang PDF.

[2] Slide môn học, *Chap2_Density_estimation (handout)*, 37 trang PDF.

[3] Slide môn học, *Chap2_Density_Estimation_Projection_estimator-2*, 29 trang PDF.

[4] Larry Wasserman (2006), *All of Nonparametric Statistics*, Springer.

[5] Alexandre B. Tsybakov (2009), *Introduction to Nonparametric Estimation*, Springer.

[6] Các bài tập và lời giải tại `../Exercise/`, đặc biệt `Chuong1_ECDF_BaiTap`, `test_loi_giai_mo_rong`, `KDE_Exam_Complete_Solutions`. Đây là nguồn bài luyện phụ trợ; mọi công thức dùng trong giáo trình được kiểm tra lại.